

常量、变元、函数。

用否定、析取、合取、蕴涵、等价等连接词以及全称量词、存在量词把一些简单命题连接起来构成一个复合命题,以表示一个比较复杂的含义。

位于量词后面的单个谓词或者用括弧括起来的谓词公式称为量词的辖域,辖域内与量词中同名的变元称为约束变元,不受约束的变元称为自由变元。

对于谓词公式 P ,如果至少存在一个解释使得公式 P 在此解释下的真值为 T ,则称公式 P 是可满足的,否则,则称公式 P 是不可满足的。

当且仅当 $(P_1 \wedge P_2 \wedge \cdots \wedge P_n) \wedge \neg Q$ 是不可满足的,则 Q 为 $P_1, P_2, \dots, P_n$ 的逻辑结论。

一阶谓词逻辑表示法具有自然、精确、严密、容易实现等优点,但有不能表示不确定的知识、组合爆炸、效率低等缺点。

3. 产生式表示法

产生式表示法是目前应用最多的一种知识表示模型,许多成功的专家系统都用它来表示知识。

产生式通常用于表示事实、规则以及它们的不确定性度量。谓词逻辑中的蕴涵式只是产生式的一种特殊情况。

产生式不仅可以表示确定性规则,还可以表示各种操作、规则、变换、算子、函数等。产生式不仅可以表示确定性知识,而且还可以表示不确定性知识。

产生式表示法具有自然性、模块性、有效性、清晰性等优点,但存在效率不高、不能表达具有结构性的知识等缺点,适合表示由许多相对独立的知识元组成的领域知识、具有经验性及不确定性的知识,也可以表示为一系列相对独立的求解问题的操作。

一个产生式系统由规则库、综合数据库、控制系统(推理机)三部分组成。产生式系统求解问题的过程是一个不断地从规则库中选择可用规则与综合数据库中的已知事实进行匹配的过程,规则的每一次成功匹配都使综合数据库增加了新的内容,并朝着问题的解决方向前进了一步。这一过程称为推理,是专家系统中的核心内容。

4. 框架表示法

框架是一种描述所讨论对象(一个事物、事件或概念)属性的数据结构。

一个框架由若干个被称为“槽”(slot)的结构组成,一个槽描述所讨论对象某一方面的属性。每一个槽又可根据实际情况划分为若干个“侧面”(facet),一个侧面描述相应属性的一个方面。槽和侧面所具有的属性值分别被称为槽值和侧面值。

框架表示法具有结构性、继承性、自然性的特点。

5. 知识图谱

知识图谱是一种互联网环境下的知识表示方法,由一些相互连接的实体及其属性构成的。

知识图谱三元组的基本形式主要分为两种形式:(实体1-关系-实体2)、(实体-属性-属性值)。

知识图谱在逻辑上可分为模式层与数据层。数据层主要是由一系列的事实组成,而知识

以事实为单位进行存储。模式层构建在数据层之上,是知识图谱的核心。

知识图谱主要有自顶向下与自底向上两种构建方式。自顶向下指的是先为知识图谱定义好本体与数据模式,再将实体加入知识库。自底向上指的是从一些开放链接数据中提取出实体,选择其中置信度较高的加入知识库,再构建顶层的本体模式。

思考题

- 2.1 什么是知识?它有哪些特性?有哪几种分类方法?
- 2.2 什么是知识表示?如何选择知识表示方法?
- 2.3 什么是命题?请写出三个真值为 T 及真值为 F 的命题。
- 2.4 什么是谓词?什么是谓词个体及个体域?函数与谓词的区别是什么?
- 2.5 谓词逻辑和命题逻辑的关系如何?有何异同?
- 2.6 什么是谓词的项?什么是谓词的阶?请写出谓词的一般形式。
- 2.7 什么是谓词公式?什么是谓词公式的解释?
- 2.8 一阶谓词逻辑表示法是结构化知识还是非结构化知识?适合于表示哪种类型的知识?它有哪些特点?
- 2.9 请写出用一阶谓词逻辑表示法表示知识的步骤。
- 2.10 产生式的基本形式是什么?它与谓词逻辑中蕴涵式有什么共同处和不同处?
- 2.11 产生式系统由哪几部分组成?
- 2.12 试述产生式系统求解问题的一般步骤。
- 2.13 产生式系统中,推理机的推理方式有哪几种?在产生式推理过程中,如果发生策略冲突,如何解决?
- 2.14 试述产生式表示法的特点。
- 2.15 框架的一般表示形式是什么?
- 2.16 框架表示法有何特点?请叙述用框架表示法表示知识的步骤。
- 2.17 试构造一个描述读者的办公室或卧室的框架系统。
- 2.18 试构造一个描述计算机主机的框架系统。
- 2.19 请给出一个知识图谱实例。

习题

- 2.1 设有下列语句,请用相应的谓词公式把它们表示出来:
 - (1) 有的人喜欢梅花,有的人喜欢菊花,有的人既喜欢梅花又喜欢菊花。
 - (2) 他每天下午都去玩足球。
 - (3) 所有人都有饭吃。
 - (4) 喜欢玩篮球的人必喜欢玩排球。
 - (5) 要想出国留学,必须通过外语考试。

2.2 分别指出下列谓词公式中各量词的辖域,并指出哪些是约束变元,哪些是自由变元。

$$(1) (\forall x)(P(x,y) \vee (\exists y)(Q(x,y) \wedge R(x,y)))$$

$$(2) (\exists z)(\forall y)(P(z,y) \vee Q(z,x)) \vee R(u,v)$$

$$(3) (\forall x)(\neg P(x,f(x)) \vee (\exists z)(Q(x,z) \wedge \neg R(z,y)))$$

$$(4) (\forall z)((\exists y)((\exists t)(P(z,t) \vee Q(y,t))) \wedge R(z,y))$$

2.3 设 $D=\{1,2\}$, 试给出谓词公式 $(\exists x)(\forall y)(P(x,y) \rightarrow Q(x,y))$ 的一个解释,并且指出该谓词公式的真值。

2.4 试用谓词逻辑表达描述下列推理:

(1) 如果张三比李四大,那么李四比张三小。

(2) 甲和乙结婚了,则或者甲为男,乙为女;或者甲为女,乙为男。

(3) 如果一个人是老实人,他就不会说谎;张三说谎了,所以张三不是一个老实人。

2.5 用产生式表示异或(XOR)逻辑。

2.6 用产生式表示:如果一个人发烧、呕吐、出现黄疸,那么得肝炎的可能性有7成。

2.7 将下面一则消息用框架表示:“今天,一次强度为里氏8.5级的强烈地震袭击了下斯洛文尼亚(Low Slabovia)地区,造成25人死亡和5亿美元的财产损失。下斯洛文尼亚地区的主席说:多年来,靠近萨迪壕金斯(Sadie Haw Kins)断层的重灾区一直是一个危险地区。这是本地区发生的第3号地震。”

读一读

人工智能之父约翰·麦卡锡

约翰·麦卡锡(J. McCarthy)于1948年获加州理工学院数学学士学位,1951年获普林斯顿大学数学博士学位。然后在加州理工学院、斯坦福大学工作两年多后,到达特茅斯学院(Dartmouth College)任教。

1956年,28岁的约翰·麦卡锡、同龄的马文·明斯基、37岁的洛切斯特和40岁的香农四人,提议在麦卡锡工作的达特茅斯学院召开“达特茅斯夏季人工智能研究会议”。参加会议的还有6位年轻的科学家,包括40岁的赫伯特·西蒙和28岁的艾伦·纽厄尔。在这次研讨会上,大家讨论了当时计算机科学领域尚未解决的一些重要问题,包括人工智能、自然语言处理和神经网络等。在这次会上,正式使用麦卡锡提出的“人工智能”术语。麦卡锡被称为人工智能之父。

在达特茅斯会议前后,麦卡锡的主要研究方向正是计算机下棋。下棋程序的关键之一是如何减少计算机需要考虑的棋步。麦卡锡发明了著名的 α - β 搜索法,在采取最佳招数的情况下允许忽略一些未来不会发生的事情。 α - β 搜索法在低于或者超过搜索中的 α 或者 β 值时就不再搜索,所以这种算法也称为 α - β 剪枝算法。这种算法至今仍是人工智能中一种常用的高效搜索方法。当年IBM的国际象棋程序深蓝,靠的正是在拥有30个IBM RS/6000处理器的并行计算机上运行的 α - β 搜索法,击败了世界冠军卡斯帕罗夫而闻名世界。

后来麦卡锡到麻省理工学院(MIT)任教,并邀请明斯基到MIT,共同创建了世界上第一座人工智能实验室——MIT AI Lab。在那里他又做出了三项十分重要的贡献。第一是他定义了高级语言Lisp语言,垄断了人工智能领域的应用。第二,麦卡锡和他的同事发明了分时技术。第三,麦卡锡发表了题为“有常识的程序”的文章,文中他描述了一种系统,取名为意见接收者,任务是使用知识来搜索问题的解,这个假想也被看成是第一个完整的人工智能系统。

读一读

人工智能之父马文·明斯基

马文·明斯基(Marvin Lee Minsky, 1927—2016), 出生于美国纽约的一个眼科医生家庭。他高中毕业后加入了海军, 1946 年退伍后前往哈佛大学深造, 主修物理学, 但也选修了包括电气工程、数学、遗传学、心理学等多个学科的课程。1950 年, 明斯基在本科的最后一年, 和同学 Dean Edmonds 建造了世界上第一台神经网络计算机, 并命名为 SNARC (Stochastic Neural Analog Reinforcement Calculator)。这台计算机由 3 000 个真空管和 B-24 轰炸机上一个多余的自动指示装置来模拟 40 个神经元组成的网络。他于 1950 年进入普林斯顿大学攻读数学博士学位, 完成博士论文“神经网络和脑模型问题”。博士毕业后, 被引荐到哈佛大学做助理研究员, 他发现遗传学有趣但不够深远, 物理吸引力一般, 最后他选择了智能领域。

1958 年, 他离开哈佛大学到 MIT 与约翰·麦卡锡再次会合, 共同建立了世界上第一个人工智能实验室“MIT AI”。在那里, 明斯基设计和建造了一个带有扫描仪和触觉传感器的 14 度自由机械手, 可以像人一样搭积木。20 世纪 60 年代, 明斯基首次提出“telepresence”(远程介入) 概念, 即利用微型摄像机、运动传感器等设备, 让人体验驾驶飞机、在战场上参加战斗、在水下游泳这些现实中未发生的事情, 为他奠定了“虚拟现实”(virtual reality) 倡导者的重要地位。后来麦卡锡和明斯基在某些观点上产生了分歧, 导致他们的合作没有继续。

由于明斯基的研究引领了人工智能、认知心理学、神经网络、图灵机理论和回归函数这些领域的理论与实践的发展潮流, 并在图像处理领域、符号计算、知识表述、计算语义学、机器感知和符号连接学习领域做出了诸多贡献, 1969 年, 他被授予计算机界的诺贝尔奖——图灵奖。明斯基是第一位获此殊荣的人工智能学者。

了解了知识表示方法,就可以把知识用某种模式表示出来存储到计算机中去。但是,为使计算机具有智能,仅仅使计算机拥有知识是不够的,还必须使它具有思维能力,即能运用知识求解问题。推理是求解问题的一种重要方法。因此,推理方法成为人工智能的一个重要研究课题。目前,人们已经对推理方法进行了比较多的研究,提出了多种可在计算机上实现的推理方法。

下面首先讨论推理的基本概念,然后着重介绍鲁宾逊归结原理及其在机器定理证明和问题求解中的应用。其基本思想是先将要证明的定理表示为谓词公式,并化为子句集,然后再进行归结,如果归结出空子句,则定理得证。鲁宾逊归结原理使定理证明能够在计算机上实现。

3.1 推理的基本概念

3.1.1 推理的定义

人们在对各种事物进行分析、综合并最后做出决策时,通常是从已知的事实出发,通过运用已掌握的知识,找出其中蕴涵的事实,或归纳出新的事实。这一过程通常称为推理,即从初始证据出发,按某种策略不断运用知识库中的已知知识,逐步推出结论的过程称为推理。

在人工智能系统中,推理是由程序实现的,称为推理机。已知事实和知识是构成推理的两个基本要素。已知事实又称为证据,用以指出推理的出发点及推理时应该使用的知识;而知识是使推理得以向前推进,并逐步达到最终目标的依据。例如,在医疗诊断专家系统中,专家的经验及医学常识以某种表示形式存储于知识库中。为患者诊治疾病时,推理机就从存储在综合数据库中的患者症状及化验结果等初始证据出发,按某种搜索策略在知识库中搜寻可与之匹配的知识,推出某些中间结论,然后再以这些中间结论为证据,在知识库中搜索与之匹配的知识,推出进一步的中间结论,如此反复进行,直到最终推出结论,即患者的病因与治疗方案为止。

3.1.2 推理方式及其分类

人类的智能活动有多种思维方式。人工智能作为对人类智能的模拟,相应地也有多种推理方式。下面分别从不同的角度对它们进行分类。

1. 演绎推理、归纳推理、默认推理

若从推出结论的途径来划分,推理可分为演绎推理、归纳推理和默认推理。

演绎推理(deductive reasoning)是从全称判断推导出单称判断的过程,即由一般性知识推出适合于某一具体情况的结论。这是一种从一般到个别的推理。

演绎推理是人工智能中的一种重要的推理方式。许多智能系统中采用了演绎推理。演绎推理有多种形式,经常用的是三段论式。它包括以下几项。

- ① 大前提:已知的一般性知识或假设。
- ② 小前提:关于所研究的具体情况或个别事实的判断。
- ③ 结论:由大前提推出的适合于小前提所示情况的新判断。

下面是一个三段论推理的例子。

- ① 大前提:足球运动员的身体都是强壮的。
- ② 小前提:高波是一名足球运动员。
- ③ 结论:高波的身体是强壮的。

归纳推理(inductive reasoning)是从足够多的事例中归纳出一般性结论的推理过程,是一种从个别到一般的推理。

若从归纳时所选的事例的广泛性来划分,归纳推理又可分为完全归纳推理和不完全归纳推理两种。

完全归纳推理是指在进行归纳时考察了相应事物的全部对象,并根据这些对象是否都具有某种属性,从而推出这个事物是否具有这个属性。例如,某厂进行产品质量检查,如果对每一件产品都进行了严格检查,并且都是合格的,则推导出结论“该厂生产的产品是合格的”。

不完全归纳推理是指考察了相应事物的部分对象,就得出了结论。例如,检查产品质量时,只是随机地抽查了部分产品,只要它们都合格,就得出了“该厂生产的产品是合格”的结论。

不完全归纳推理推出的结论不具有必然性,属于非必然性推理,而完全归纳推理是必然性推理。但由于要考察事物的所有对象通常都比较困难,因而大多数归纳推理都是不完全归纳推理。归纳推理是人类思维活动中最基本、最常用的一种推理形式。人们由个别到一般的思维过程中经常要用到它。

默认推理又称为缺省推理(default reasoning),是在知识不完全的情况下假设某些条件已经具备所进行的推理。

例如,在条件A已成立的情况下,如果没有足够的证据能证明条件B不成立,则默认B是成立的,并在此默认的前提下进行推理,推导出某个结论。例如,要设计一种鸟笼,但不知道要放的鸟是否会飞,则默认这只鸟会飞,因此,推出这个鸟笼要有盖子的结论。

由于这种推理允许默认某些条件是成立的,所以在知识不完全的情况下也能进行。在默认推理的过程中,如果到某一时刻发现原先所做的默认不正确,则要撤销所做的默认以及由此默认推出的所有结论,重新按新情况进行推理。

2. 确定性推理、不确定性推理

若按推理时所用知识的确定性来划分,推理可分为确定性推理与不确定性推理。

确定性推理是指推理时所用的知识与证据都是确定的,推出的结论也是确定的,其真值或者为真或者为假,没有第三种情况出现。

本章将讨论的经典逻辑推理就属于这一类。经典逻辑推理是最先提出的一类推理方法,是根据经典逻辑(命题逻辑及一阶谓词逻辑)的逻辑规则进行的一种推理,主要有自然演绎推理、归结演绎推理及与/或形演绎推理等。由于这种推理是基于经典逻辑的,其真值只有“真”和“假”两种,因此它是一种确定性推理。

不确定性推理是指推理时所用的知识与证据不都是确定的,推出的结论也是不确定的。

现实世界中的事物和现象大都是不确定的,或者模糊的,很难用精确的数学模型来表示与处理。不确定性推理又分为似然推理与近似推理或模糊推理,前者是基于概率论的推理,后者是基于模糊逻辑的推理。人们经常在知识不完全、不精确的情况下进行推理,因此,要使计算机能模拟人类的思维活动,就必须使它具有不确定性推理的能力。

3. 单调推理、非单调推理

若按推理过程中推出的结论是否越来越接近最终目标来划分,推理又分为单调推理与非单调推理。

单调推理是在推理过程中随着推理向前推进及新知识的加入,推出的结论越来越接近最终目标。

单调推理的推理过程中不会出现反复的情况,即不会由于新知识的加入而否定前面推出的结论,从而使推理又退回到前面的某一步。本章将要介绍的基于经典逻辑的演绎推理属于单调性推理。

非单调推理是在推理过程中由于新知识的加入,不仅没有加强已推出的结论,反而要否定它,使推理退回到前面的某一步,然后重新开始。

非单调推理一般是在知识不完全的情况下发生的。由于知识不完全,为使推理进行下去,就要先做某些假设,并在假设的基础上进行推理。当以后由于新知识的加入发现原先的假设不正确时,就需要推翻该假设以及由此假设推出的所有结论,再用新知识重新进行推理。显然,默认推理是一种非单调推理。

在人们的日常生活及社会实践中,很多情况下进行的推理都是非单调推理。明斯基举了一个非单调推理的例子:当知道 X 是一只鸟时,一般认为 X 会飞,但之后又知道 X 是企鹅,而企鹅是不会飞的,则取消先前加入的 X 能飞的结论,而加入 X 是不会飞的结论。

4. 启发式推理、非启发式推理

若按推理中是否运用与推理有关的启发性知识来划分,推理可分为启发式推理(heuristic

inference) 与非启发式推理。

如果推理过程中运用与推理有关的启发性知识,则称为启发式推理,否则称为非启发式推理。

所谓启发性知识是指与问题有关且能加快推理过程、求得问题最优解的知识。例如,推理的目标是要在脑膜炎、肺炎、流感这三种疾病中选择一个,又设有 r_1 、 r_2 、 r_3 这三条产生式规则可供使用,其中 r_1 推出的是脑膜炎, r_2 推出的是肺炎, r_3 推出的是流感。如果希望尽早地排除脑膜炎这一危险疾病,应该先选用 r_1 ;如果本地区目前正在盛行流感,则应考虑首先选择 r_3 。这里,“脑膜炎危险”及“目前正在盛行流感”是与问题求解有关的启发性信息。

3.1.3 推理的方向

推理过程是求解问题的过程。问题求解的质量与效率不仅依赖于所采用的求解方法(如匹配方法、不确定性的传递算法等),还依赖于求解问题的策略,即推理的控制策略。

推理的控制策略主要包括推理方向、搜索策略、冲突消解策略、求解策略及限制策略等。推理方向分为正向推理、逆向推理、混合推理及双向推理四种。

1. 正向推理

正向推理是以已知事实作为出发点的一种推理。

正向推理的基本思想:从用户提供的初始已知事实出发,在知识库 KB 中找出当前可适用的知识,构成可适用知识集 KS,然后按某种冲突消解策略从 KS 中选出一条知识进行推理,并将推出的新事实加入数据库中作为下一步推理的已知事实,此后再在知识库中选取可适用知识进行推理,如此重复这一过程,直到求得问题的解或者知识库中再无可适用的知识为止。

正向推理的推理过程可用如下算法描述。

- ① 将用户提供的初始已知事实送入数据库 DB。
- ② 检查数据库 DB 是否已经包含了问题的解,若有,则求解结束,并成功退出;否则,执行下一步。
- ③ 根据数据库 DB 中的已知事实,扫描知识库 KB,检查 KB 中是否有可适用(即可与 DB 中已知事实匹配)的知识,若有,则转向④,否则转向⑥。
- ④ 把 KB 中所有的适用知识都选出来,构成可适用知识集 KS。
- ⑤ 若 KS 不空,则按某种冲突消解策略从中选出一条知识进行推理,并将推出的新事实加入 DB 中,然后转向②;若 KS 空,则转向⑥。
- ⑥ 询问用户是否可进一步补充新的事实,若可补充,则将补充的新事实加入 DB 中,然后转向③;否则表示求不出解,失败退出。

以上算法如图 3.1 所示。

为了实现正向推理,有许多具体问题需要解决。例如,要从知识库中选出可适用的知识,就要用知识库中的知识与数据库中已知事实进行匹配,为此就需要确定匹配的方法。匹配通常难以做到完全一致,因此还需要解决怎样才算是匹配成功的问题。




图 3.1 正向推理示意图

2. 逆向推理

逆向推理是以某个假设目标作为出发点的一种推理。

逆向推理的基本思想是：首先选定一个假设目标，然后寻找支持该假设的证据，若所需的证据都能找到，则说明原假设是成立的；若无论如何都找不到所需要的证据，则说明原假设是不成立的，为此需要另作新的假设。

逆向推理过程可用如下算法描述。

① 提出要求证的目标(假设)。

② 检查该目标是否已在数据库中，若在，则该目标成立，退出推理或者对下一个假设目标进行验证；否则，转下一步。

③ 判断该目标是否是证据,即它是否为应由用户证实的原始事实,若是,则询问用户;否则,转下一步。

④ 在知识库中找出所有能导出该目标的知识,形成适用的知识集 KS,然后转下一步。

⑤ 从 KS 中选出一条知识,并将该知识的运用条件作为新的假设目标,然后转向②。

该算法可用图 3.2 示意。




图 3.2 逆向推理示意图

与正向推理相比,逆向推理更复杂一些,上述算法只是描述了它的大致过程,许多细节没有反映出来。例如,如何判断一个假设是否是证据?当导出假设的知识有多条时,如何确定先选哪一条?另外,一条知识的运用条件一般有多条,当其中的一个经过验证成立后,如何自动地换为对另一个的验证?在验证一个运用条件时,需要把它当作新的假设,并查找可导出该假设的知识,这样就又会产生一组新的运用条件,形成一个树状结构,当到达叶结点(即数据库中有相应的事实或者用户可肯定相应事实存在等)时,又需逐层向上返回,返回过程中有可能又要下到下一层,这样上上下下重复多次,才会导出原假设是否成立的结论。这是一个比较复杂的推理过程。

逆向推理的主要优点是不必使用与目标无关的知识,目的性强,同时它还有利于向用户提供解释。其主要缺点是起始目标的选择有盲目性,若不符合实际,就要多次提出假设,影响系统的效率。

3. 混合推理

正向推理具有盲目、效率低等缺点,推理过程中可能会推出许多与问题无关的子目标。逆向推理中,若提出的假设目标不符合实际,也会降低系统的效率。为解决这些问题,可把正向推理与逆向推理结合起来,使其各自发挥自己的优势,取长补短。这种既有正向又有逆向的推理称为混合推理。另外,在下述几种情况下,通常也需要进行混合推理。

(1) 已知的事实不充分

当数据库中的已知事实不够充分时,若用这些事实与知识的运用条件相匹配进行正向推理,可能连一条适用知识都选不出来,这就使推理无法进行下去。此时,可通过正向推理先将其运用条件不能完全匹配的知识都找出来,并把这些知识可导出的结论作为假设,然后分别对这些假设进行逆向推理。由于在逆向推理中可以向用户询问有关证据,这就有可能使推理进行下去。

(2) 正向推理推出的结论可信度不高

用正向推理进行推理时,虽然推出了结论,但可信度可能不高,达不到预定的要求。因此为了得到一个可信度符合要求的结论,可用这些结论作为假设,然后进行逆向推理,通过向用户询问进一步的信息,得到一个可信度较高的结论。

(3) 希望得到更多的结论

在逆向推理过程中,由于要与用户进行对话,有针对性地向用户提出询问,这就有可能获得一些原来不掌握的有用信息。这些信息不仅可用于证实要证明的假设,同时还有助于推出一些其他结论。因此,在用逆向推理证实了某个假设之后,可以再用正向推理推出另外一些结论。例如,在医疗诊断系统中,先用逆向推理证实某患者患有某种病,然后再利用逆向推理过程中获得的信息进行正向推理,就有可能推出该患者还患有别的什么病。

由以上讨论可以看出,混合推理分为两种情况:一种是先进行正向推理,帮助选择某个目标,即从已知事实演绎出部分结果,然后再用逆向推理证实该目标或提高其可信度;另一种情况是先假设一个目标进行逆向推理,然后再利用逆向推理中得到的信息进行正向推理,以推出更多的结论。

先正向后逆向的推理过程如图 3.3 所示。先逆向后正向的推理过程如图 3.4 所示。

4. 双向推理

在定理的机器证明等问题中,经常采用双向推理。所谓双向推理是指正向推理与逆向推理同时进行,且在推理过程中的某一步骤上“碰头”的一种推理。其基本思想是:一方面根据已知事实进行正向推理,但并不推到最终目标;另一方面从某假设目标出发进行逆向推理,但并不推至原始事实,而是让它们在中途相遇,即由正向推理所得到的中间结论恰好是逆向推理此时所要求的证据,这时推理就可结束,逆向推理时所做的假设就是推理的最终结论。

双向推理的困难在于“碰头”判断。另外,如何权衡正向推理与逆向推理的比重,即如何确定“碰头”的时机也是一个困难问题。




图 3.3 先正向后逆向混合推理示意图




图 3.4 先逆向后正向混合推理示意图

3.1.4 冲突消解策略

在推理过程中,系统要不断地用当前已知的事实与知识库中的知识进行匹配。此时,可能发生如下三种情况。

- ① 已知事实恰好只与知识库中的一个知识匹配成功。
- ② 已知事实不能与知识库中的任何知识匹配成功。
- ③ 已知事实可与知识库中的多个知识匹配成功。或者多个(组)已知事实都可与知识库中的某一个知识匹配成功;或者有多个(组)已知事实可与知识库中的多个知识匹配成功。

这里已知事实与知识库中的知识匹配成功的含义,对正向推理而言,是指产生式规则的前件和已知事实匹配成功;对逆向推理而言,是指产生式规则的后件和假设匹配成功。

对于第一种情况,由于匹配成功的知识只有一个,所以它就是可应用的知识,可直接把它应用于当前的推理。

当第二种情况发生时,由于找不到可与当前已知事实匹配成功的知识,使得推理无法继续进行下去。这或者是由于知识库中缺少某些必要的知识,或者由于要求解的问题超出了系统功能范围等,此时可根据当前的实际情况做相应的处理。

第三种情况刚好与第二种情况相反,推理过程中不仅有知识匹配成功,而且有多个知识匹配成功,称为发生了冲突。按一定的策略从匹配成功的多个知识中挑出一个知识用于当前的

推理的过程称为冲突消解(conflict resolution)。解决冲突时所用的策略称为冲突消解策略。对正向推理而言,它将决定选择哪一组已知事实来激活哪一条产生式规则,使它用于当前的推理,产生其后件指出的结论或执行相应的操作。对逆向推理而言,它将决定哪一个假设与哪一个产生式规则的后件进行匹配,从而推出相应的前件,作为新的假设。

目前已有多种消解冲突的策略,其基本思想都是对知识进行排序。常用的有以下几种。

1. 按规则的针对性排序

本策略是优先选用针对性较强的产生式规则。如果 r_2 中除了包括 r_1 要求的全部条件外,还包括其他条件,则称 r_2 比 r_1 有更大的针对性, r_1 比 r_2 有更大的通用性。因此,当 r_2 与 r_1 发生冲突时,优先选用 r_2 。因为它要求的条件较多,其结论一般更接近于目标,一旦得到满足,可缩短推理过程。

2. 按已知事实的新鲜性排序

在产生式系统的推理过程中,每应用一条产生式规则就会得到一个或多个结论或者执行某个操作,数据库就会增加新的事实。另外,在推理时还会向用户询问有关的信息,也使数据库的内容发生变化。一般把数据库中后生成的事实称为新鲜的事实,即后生成的事实比先生成的事实具有较大的新鲜性。若一条规则被应用后生成了多个结论,则既可以认为这些结论有相同的新鲜性,也可以认为排在前面(或后面)的结论有较大的新鲜性,根据情况决定。

设规则 r_1 可与事实组 A 匹配成功,规则 r_2 可与事实组 B 匹配成功,则 A 与 B 中哪一组较新鲜,与它匹配的产生式规则就先被应用。

如何衡量 A 与 B 中哪一组事实更新鲜呢?常用的方法有以下三种。

① 把 A 与 B 中的事实逐个比较其新鲜性,若 A 中包含的更新鲜的事实比 B 多,就认为 A 比 B 新鲜。例如,设 A 与 B 中各有五个事实,而 A 中有三个事实比 B 中的事实更新鲜,则认为 A 比 B 新鲜。

② 以 A 中最新鲜的事实与 B 中最新鲜的事实相比较,哪一个更新鲜,就认为相应的事实组更新鲜。

③ 以 A 中最不新鲜的事实与 B 中最不新鲜的事实相比较,哪一个更不新鲜,就认为相应的事实组有较小的新鲜性。

3. 按匹配度排序

在不确定性推理中,需要计算已知事实与知识的匹配度,当其匹配度达到某个预先规定的值时,就认为它们是可匹配的。若产生式规则 r_1 与 r_2 都可匹配成功,则优先选用匹配度较大的产生式规则。

4. 按条件个数排序

如果有多条产生式规则生成的结论相同,则优先应用条件少的产生式规则,因为条件少的规则匹配时花费的时间较少。

5. 随机选择

一种最简单的冲突消解策略是随机选一条产生式规则执行。

在具体应用时,可对上述几种策略进行组合,尽量减少冲突的发生,使推理有较快的速度和较高的效率。

在逆向推理中也存在冲突消解问题,可采用与正向推理一样的方法解决。

3.2 自然演绎推理

从一组已知为真的事实出发,直接运用经典逻辑的推理规则推出结论的过程称为自然演绎推理。其中,基本的推理是 P 规则、 T 规则、假言推理、拒取式推理等。

假言推理的一般形式是

$$P, P \rightarrow Q \Rightarrow Q$$

它表示:由 $P \rightarrow Q$ 及 P 为真,可推出 Q 为真。

例如,由“如果 x 是金属,则 x 能导电”及“铜是金属”可推出“铜能导电”的结论。

拒取式推理的一般形式是

$$P \rightarrow Q, \neg Q \Rightarrow \neg P$$

它表示:由 $P \rightarrow Q$ 为真及 Q 为假,可推出 P 为假。

例如,由“如果下雨,则地上就湿”及“地上不湿”可推出“没有下雨”的结论。

这里,应该注意避免如下两类错误:一种是肯定后件(Q)的错误,另一种是否定前件(P)的错误。所谓肯定后件是指,当 $P \rightarrow Q$ 为真时,希望通过肯定后件 Q 为真来推出前件 P 为真,这是不允许的。例如,伽利略在论证哥白尼的日心说时,曾使用了如下推理。

① 如果行星系统是以太阳为中心的,则金星会显示出位相变化。

② 金星显示出位相变化(肯定后件)。

③ 所以,行星系统是以太阳为中心。

这里使用了肯定后件的推理,违反了经典逻辑规则,他因此遭到非难。

所谓否定前件是指,当 $P \rightarrow Q$ 为真时,希望通过否定前件 P 来推出后件 Q 为假,这也是不允许的。例如,下面的推理就是使用了否定前件的推理,从而违反了逻辑规则。

① 如果下雨,则地上是湿的。

② 没有下雨(否定前件)。

③ 所以,地上不湿。

这显然是不正确的。因为当地上洒水时,地上也会湿。事实上,只要仔细分析蕴涵 $P \rightarrow Q$ 的定义,就会发现当 $P \rightarrow Q$ 为真时,肯定后件或否定前件所得的结论既可能为真,也可能为假,不能确定。

下面举例说明自然演绎推理方法。

例 3.1 设已知如下事实:

① 凡是容易的课程小王(*Wang*)都喜欢;

② *C* 班的课程都是容易的;

③ *ds* 是 *C* 班的一门课程。

求证:小王喜欢 *ds* 这门课程。

证明 首先定义谓词:

$EASY(x)$:*x* 是容易的;

$LIKE(y, x)$:*y* 喜欢 *x*;

$C(x)$:*x* 是 *C* 班的一门课程。

把上述已知事实及待求证的问题用谓词公式表示出来:

$(\forall x)(EASY(x) \rightarrow LIKE(Wang, x))$ 凡是容易的课程小王都是喜欢的;

$(\forall x)(C(x) \rightarrow EASY(x))$ *C* 班的课程都是容易的;

$C(ds)$ *ds* 是 *C* 班的课程;

$LIKE(Wang, ds)$ 小王喜欢的 *ds* 这门课程,这是待求证的问题。

应用推理规则进行推理:

因为

$(\forall x)(EASY(x) \rightarrow LIKE(Wang, x))$

所以由全称固化得

$EASY(z) \rightarrow LIKE(Wang, z)$

因为

$(\forall x)(C(x) \rightarrow EASY(x))$

所以由全称固化得

$C(y) \rightarrow EASY(y)$

由 *P* 规则及假言推理得

$C(ds), C(y) \rightarrow EASY(y) \Rightarrow EASY(ds)$

$EASY(ds), EASY(z) \rightarrow LIKE(Wang, z)$

由 *T* 规则及假言推理得

$LIKE(Wang, ds)$

即小王喜欢 *ds* 这门课程。

一般来说,由已知事实推出的结论可能有多个,只要其中包括了待证明的结论,就认为问题得到了解决。

自然演绎推理的优点是表达定理证明过程自然,容易理解,而且它拥有丰富的推理规则,推理过程灵活,便于在它的推理规则中嵌入领域启发式知识。其缺点是容易产生组合爆炸,推理过程得到的中间结论一般呈指数形式递增,这对于一个大的推理问题来说是十分不利的。

3.3 谓词公式化为子句集的方法

在谓词逻辑中,有下述定义:

原子(atom)谓词公式是一个不能再分解的命题。

原子谓词公式及其否定,统称为文字(literal)。 P 称为正文字, $\neg P$ 称为负文字。 P 与 $\neg P$ 为互补文字。

文字的析取式称为子句(clause)。文字本身也是子句。

由子句构成的集合称为子句集。

不包含任何文字的子句称为空子句,表示为 NIL 。

由于空子句不含有文字,它不能被任何解释满足,所以,空子句是永假的、不可满足的。

在谓词逻辑中,任何一个谓词公式都可以通过应用等价关系及推理规则化成相应的子句集,从而能够比较容易地判定谓词公式的不可满足性。下面结合一个具体的例子,说明把谓词公式化为子句集的步骤。

例 3.2 将下列谓词公式化为子句集:

$$(\forall x)((\forall y)P(x,y) \rightarrow \neg(\forall y)(Q(x,y) \rightarrow R(x,y)))$$

解 (1) 消去谓词公式中的“ $\rightarrow$ ”和“ $\leftrightarrow$ ”符号

利用谓词公式的等价关系:

$$P \rightarrow Q \Leftrightarrow \neg P \vee Q$$

$$P \leftrightarrow Q \Leftrightarrow (P \wedge Q) \vee (\neg P \wedge \neg Q)$$

上例等价变换为

$$(\forall x)(\neg(\forall y)P(x,y) \vee \neg(\forall y)(\neg Q(x,y) \vee R(x,y)))$$

(2) 把否定符号移到紧靠谓词的位置上

利用谓词公式的等价关系:

$$\text{双重否定律} \quad \neg(\neg P) \Leftrightarrow P$$

$$\text{德摩根律} \quad \neg(P \wedge Q) \Leftrightarrow \neg P \vee \neg Q$$

$$\neg(P \vee Q) \Leftrightarrow \neg P \wedge \neg Q$$

$$\text{量词转换律} \quad \neg(\forall x)P \Leftrightarrow (\exists x)\neg P$$

$$\neg(\exists x)P \Leftrightarrow (\forall x)\neg P$$

把否定符号移到紧靠谓词的位置上,减少了否定符号的辖域。

上例等价变换为

$$(\forall x)((\exists y)\neg P(x,y) \vee (\exists y)(Q(x,y) \wedge \neg R(x,y)))$$

(3) 变量标准化

所谓变量标准化就是重新命名变元,使每个量词采用不同的变元,从而使不同量词的约束变元有不同的名字。这是因为在任一量词辖域内,受到该量词约束的变元为一哑元(虚构变

量),它可以在该辖域内被另一个没有出现过的任意变元统一代替,而不改变谓词公式的值。

$$(\forall x)P(x) \equiv (\forall y)P(y)$$

$$(\exists x)P(x) \equiv (\exists y)P(y)$$

上例等价变换为

$$(\forall x)((\exists y)\neg P(x,y) \vee (\exists z)(Q(x,z) \wedge \neg R(x,z)))$$

(4) 消去存在量词

分两种情况。

一种情况是存在量词不出现在全称量词的辖域内。此时只要用一个新的个体常量替换受该存在量词约束的变元,就可以消去存在量词。因为如原谓词公式为真,则总能够找到一个个体常量,替换后仍然使谓词公式为真。这里的个体常量就是不含变量的 Skolem 函数。

另一种情况是存在量词出现在一个或者多个全称量词的辖域内。此时要用 Skolem 函数替换受该存在量词约束的变元,从而消去存在量词。这里认为所存在的 y 依赖于 x 值,它们的依赖关系由 Skolem 函数所定义。

对于一般情况

$$(\forall x_1)(\forall x_2)\cdots(\forall x_n)(\exists y)P(x_1,x_2,\cdots,x_n,y)$$

存在量词 y 的 Skolem 函数记为

$$y=f(x_1,x_2,\cdots,x_n)$$

可见,Skolem 函数把每个 $x_1,x_2,\cdots,x_n$ 值映射到存在的那个 y 。

用 Skolem 函数代替每个存在量词量化的变量的过程称为 Skolem 化。Skolem 函数所使用的函数符号必须是新的。

对于上面的例子,存在量词 $(\exists y)$ 及 $(\exists z)$ 都位于全称量词 $(\forall x)$ 的辖域内,所以都需要用 Skolem 函数代替。将 y 和 z 的 Skolem 函数分别记为 $f(x)$ 和 $g(x)$,则替换后得到

$$(\forall x)(\neg P(x,f(x)) \vee (Q(x,g(x)) \wedge \neg R(x,g(x))))$$

(5) 化为前束形

所谓前束形,就是把所有的全称量词都移到公式的前面,使每个量词的辖域都包括公式后的整个部分,即

$$\text{前束形} = (\text{前缀})\{\text{母式}\}$$

其中, (前缀) 是全称量词串, $\{\text{母式}\}$ 是不含量词的谓词公式。

对于上面的例子,因为只有一个全称量词,而且已经位于公式的最左边,所以,这一步不需要做任何工作。

(6) 化为 Skolem 标准形

Skolem 标准形的一般形式是

$$(\forall x_1)(\forall x_2)\cdots(\forall x_n)M$$

其中, M 是子句的合取式,称为 Skolem 标准形的母式。

一般利用

$$P \vee (Q \wedge R) \Leftrightarrow (P \vee Q) \wedge (P \vee R)$$

或

$$P \wedge (Q \vee R) \Leftrightarrow (P \wedge Q) \vee (P \wedge R)$$

把谓词公式化为 Skolem 标准形。

对于上面的例子,有

$$(\forall x)((\neg P(x, f(x)) \vee Q(x, g(x))) \wedge (\neg P(x, f(x)) \vee \neg R(x, g(x))))$$

(7) 略去全称量词

由于公式中所有变量都是全称量词量化的变量,因此,可以省略全称量词。母式中的变量仍然认为是全称量词量化的变量。

对于上面的例子,有

$$(\neg P(x, f(x)) \vee Q(x, g(x))) \wedge (\neg P(x, f(x)) \vee \neg R(x, g(x)))$$

(8) 消去合取词,把母式用子句集表示

对于上面的例子,有

$$\{\neg P(x, f(x)) \vee Q(x, g(x)), \neg P(x, f(x)) \vee \neg R(x, g(x))\}$$

(9) 子句变量标准化,即使每个子句中的变量符号不同

谓词公式的性质有

$$(\forall x)[P(x) \wedge Q(x)] \equiv (\forall x)P(x) \wedge (\forall y)Q(y)$$

对于上面的例子,有

$$\{\neg P(x, f(x)) \vee Q(x, g(x)), \neg P(y, f(y)) \vee \neg R(y, g(y))\}$$

显然,在子句集中各子句之间是合取关系。

上面介绍了将谓词公式化为子句集的步骤。下面再举几个例子进一步说明。

例 3.3 将下列谓词公式化为子句集:

$$(\forall x)\{[\neg P(x) \vee \neg Q(x)] \rightarrow (\exists y)[S(x, y) \wedge Q(x)]\} \wedge (\forall x)[P(x) \vee B(x)]$$

解 (1) 消去蕴涵符号

$$(\forall x)\{\neg[\neg P(x) \vee \neg Q(x)] \vee (\exists y)[S(x, y) \wedge Q(x)]\} \wedge (\forall x)[P(x) \vee B(x)]$$

(2) 把否定符号移到每个谓词前面

$$(\forall x)\{[P(x) \wedge Q(x)] \vee (\exists y)[S(x, y) \wedge Q(x)]\} \wedge (\forall x)[P(x) \vee B(x)]$$

(3) 变量标准化

$$(\forall x)\{[P(x) \wedge Q(x)] \vee (\exists y)[S(x, y) \wedge Q(x)]\} \wedge (\forall w)[P(w) \vee B(w)]$$

(4) 消去存在量词

设 y 的 Skolem 函数是 $f(x)$, 则

$$(\forall x)\{[P(x) \wedge Q(x)] \vee [S(x, f(x)) \wedge Q(x)]\} \wedge (\forall w)[P(w) \vee B(w)]$$

(5) 化为前束形

$$(\forall x)(\forall w)\{[P(x) \wedge Q(x)] \vee [S(x, f(x)) \wedge Q(x)]\} \wedge [P(w) \vee B(w)]$$

(6) 化为 Skolem 标准形

根据

$$P \wedge (Q \vee R) \Leftrightarrow (P \wedge Q) \vee (P \wedge R)$$

或者

$$(P \wedge Q) \vee (P \wedge R) \Leftrightarrow P \wedge (Q \vee R)$$

可以得到

$$\begin{aligned} & (\forall x)(\forall w) \{ \{ [Q(x) \wedge P(x)] \vee [Q(x) \wedge S(x, f(x))] \} \wedge [P(w) \vee B(w)] \} \\ & (\forall x)(\forall w) \{ Q(x) \wedge [P(x) \vee S(x, f(x))] \wedge [P(w) \vee B(w)] \} \end{aligned}$$

(7) 略去全称量词

$$Q(x) \wedge [P(x) \vee S(x, f(x))] \wedge [P(w) \vee B(w)]$$

(8) 消去合取词,把母式用子句集表示

$$\{Q(x), P(x) \vee S(x, f(x)), P(w) \vee B(w)\}$$

(9) 子句变量标准化,即使每个子句中的变量符号不同

$$\{Q(x), P(y) \vee S(y, f(y)), P(w) \vee B(w)\}$$

例 3.4 将下列谓词公式化为子句集:

$$(\forall x) \{P(x) \rightarrow \{(\forall y)[P(y) \rightarrow P(f(x, y))] \wedge \neg(\forall y)[Q(x, y) \rightarrow P(y)]\}\}$$

解 (1) 消去蕴涵符号

$$(\forall x) \{\neg P(x) \vee \{(\forall y)[\neg P(y) \vee P(f(x, y))] \wedge \neg(\forall y)[\neg Q(x, y) \vee P(y)]\}\}$$

(2) 把否定符号移到每个谓词前面

$$\begin{aligned} & (\forall x) \{\neg P(x) \vee \{(\forall y)[\neg P(y) \vee P(f(x, y))] \wedge (\exists y)\{\neg[\neg Q(x, y) \vee P(y)]\}\}\} \\ & (\forall x) \{\neg P(x) \vee \{(\forall y)[\neg P(y) \vee P(f(x, y))] \wedge (\exists y)[Q(x, y) \wedge \neg P(y)]\}\} \end{aligned}$$

(3) 变量标准化

$$(\forall x) \{\neg P(x) \vee \{(\forall y)[\neg P(y) \vee P(f(x, y))] \wedge (\exists w)[Q(x, w) \wedge \neg P(w)]\}\}$$

(4) 消去存在量词

设 w 的 Skolem 函数是 $g(x)$, 则

$$(\forall x) \{\neg P(x) \vee \{(\forall y)[\neg P(y) \vee P(f(x, y))] \wedge [Q(x, g(x)) \wedge \neg P(g(x))]\}\}$$

(5) 化为前束形

$$(\forall x)(\forall y) \{\neg P(x) \vee \{[\neg P(y) \vee P(f(x, y))] \wedge [Q(x, g(x)) \wedge \neg P(g(x))]\}\}$$

(6) 化为 Skolem 标准形

$$\begin{aligned} & (\forall x)(\forall y) \{[\neg P(x) \vee \neg P(y) \vee P(f(x, y))] \wedge \\ & [\neg P(x) \vee Q(x, g(x))] \wedge [\neg P(x) \vee \neg P(g(x))]\} \end{aligned}$$

(7) 略去全称量词

$$\{[\neg P(x) \vee \neg P(y) \vee P(f(x, y))] \wedge [\neg P(x) \vee Q(x, g(x))] \wedge [\neg P(x) \vee \neg P(g(x))]\}$$

(8) 消去合取词,把母式用子句集表示

$$\{\neg P(x) \vee \neg P(y) \vee P(f(x, y)), \neg P(x) \vee Q(x, g(x)), \neg P(x) \vee \neg P(g(x))\}$$

(9) 子句变量标准化,即使每个子句中的变量符号不同

$$\{\neg P(x_1) \vee \neg P(y) \vee P(f(x_1, y)), \neg P(x_2) \vee Q(x_2, g(x_2)), \neg P(x_3) \vee \neg P(g(x_3))\}$$

例 3.5 将下列谓词公式化为不含存在量词的前束形:

$$(\exists x)(\forall y)((\forall z)(P(z) \wedge \neg Q(x,z)) \rightarrow R(x,y,f(a)))$$

解 消去存在量词,得

$$(\forall y)((\forall z)(P(z) \wedge \neg Q(b,z)) \rightarrow R(b,y,f(a)))$$

消去蕴涵符号,得

$$(\forall y)(\neg(\forall z)(P(z) \wedge \neg Q(b,z)) \vee R(b,y,f(a)))$$

$$(\forall y)((\exists z)(\neg P(z) \vee Q(b,z)) \vee R(b,y,f(a)))$$

设 z 的 Skolem 函数是 $g(y)$, 则有

$$(\forall y)(\neg P(g(y)) \vee Q(b,g(y)) \vee R(b,y,f(a)))$$

上面把谓词公式化成了相应的子句集,下面的定理表明两者的不可满足性是等价的。

定理 3.1 谓词公式不可满足的充要条件是其子句集不可满足。

由此定理可知,要证明一个谓词公式是不可满足的,只要证明相应的子句集是不可满足的就可以了。如何证明一个子句集是不可满足的呢? 下面介绍一下鲁宾逊归结原理。

3.4 鲁宾逊归结原理

从前面的分析可以看出,谓词公式的不可满足性分析可以转化为子句集中子句的不可满足性分析。为了判定子句集的不可满足性,就需要对子句集中的子句进行判定。而为了判定一个子句的不可满足性,需要对个体域上的一切解释逐个地进行判定,只有当子句对任何非空个体域上的任何一个解释都是不可满足的时候,才能判定该子句是不可满足的,这是一件非常困难的工作,要在计算机上实现其证明过程是很困难的。1965 年鲁宾逊提出了归结原理,使机器定理证明进入应用阶段。

鲁宾逊归结原理(Robinson resolution principle)又称为消解原理,是一种证明子句集不可满足性,从而实现定理证明的一种理论及方法。它是机器定理证明的基础。

由谓词公式转化为子句集的过程可以看出,在子句集中,子句之间是合取关系,其中只要有一个子句不可满足,则子句集就不可满足。由于空子句是不可满足的,所以,若一个子句集中包含空子句,则这个子句集一定是不可满足的。鲁宾逊归结原理就是基于这个思想提出来的。其基本方法是:检查子句集 S 中是否包含空子句,若包含,则 S 不可满足;若不包含,就在子句集中选择合适的子句进行归结,一旦通过归结得到空子句,就说明子句集 S 是不可满足的。

下面对命题逻辑及谓词逻辑分别给出归结的定义。

3.4.1 命题逻辑中的归结原理

定义 3.1 设 C_1 与 C_2 是子句集中的任意两个子句,如果 C_1 中的文字 L_1 与 C_2 中的文字 L_2 互补,那么从 C_1 和 C_2 中分别消去 L_1 和 L_2 ,并将两个子句中余下的部分析取,构成一个新子

句 C_{12} , 这一过程称为归结。 C_{12} 称为 C_1 和 C_2 的归结式, C_1 和 C_2 称为 C_{12} 的亲本子句。

下面举例说明具体的归结方法。

例如, 在子句集中取两个子句 $C_1 = P, C_2 = \neg P$, 可见, C_1 与 C_2 是互补的, 则通过归结可得归结式 $C_{12} = NIL$ 。这里 NIL 代表空子句。

又如, 设 $C_1 = \neg P \vee Q \vee R, C_2 = \neg Q \vee S$, 可见, 这里 $L_1 = Q, L_2 = \neg Q$, 通过归结可得归结式 $C_{12} = \neg P \vee R \vee S$

例如, 设 $C_1 = \neg P \vee Q, C_2 = \neg Q \vee R, C_3 = P$ 。

首先对 C_1 和 C_2 进行归结, 得到

$$C_{12} = \neg P \vee R$$

然后再用 C_{12} 与 C_3 进行归结, 得到

$$C_{123} = R$$

如果首先对 C_1 和 C_3 进行归结, 然后再把其归结式与 C_2 进行归结, 将得到相同的结果。归结过程可用树形图直观地表示出来。上面的归结过程可用图 3.5 表示。




图 3.5 归结过程的树形表示

定理 3.2 归结式 C_{12} 是其亲本子句 C_1 与 C_2 的逻辑结论。即如果 C_1 与 C_2 为真, 则 C_{12} 为真。

证明 设 $C_1 = L \vee C'_1, C_2 = \neg L \vee C'_2$,

通过归结可以得到 C_1 和 C_2 的归结式 $C_{12} = C'_1 \vee C'_2$ 。

因为

$$C'_1 \vee L \Leftrightarrow \neg C'_1 \rightarrow L$$

$$\neg L \vee C'_2 \Leftrightarrow L \rightarrow C'_2$$

所以

$$C_1 \wedge C_2 = (\neg C'_1 \rightarrow L) \wedge (L \rightarrow C'_2)$$

根据假言三段论得到

$$(\neg C'_1 \rightarrow L) \wedge (L \rightarrow C'_2) \Rightarrow \neg C'_1 \rightarrow C'_2$$

因为

$$\neg C'_1 \rightarrow C'_2 \Leftrightarrow C'_1 \vee C'_2 = C_{12}$$

所以

$$C_1 \wedge C_2 \Rightarrow C_{12}$$

由逻辑结论的定义即由 $C_1 \wedge C_2$ 的不可满足性可推出 C_{12} 的不可满足性, 可知 C_{12} 是其亲本子句 C_1 和 C_2 的逻辑结论。

(证毕)

这个定理是归结原理中的一个很重要的定理。由它可得到如下两个重要的推论。

推论 1 设 C_1 与 C_2 是子句集 S 中的两个子句, C_{12} 是它们的归结式, 若用 C_{12} 代替 C_1 和 C_2 后得到新子句集 S_1 , 则由 S_1 不可满足性可推出原子句集 S 的不可满足性, 即

$$S_1 \text{ 的不可满足性} \Rightarrow S \text{ 的不可满足性}$$

推论 2 设 C_1 与 C_2 是子句集 S 中的两个子句, C_{12} 是它们的归结式, 若把 C_{12} 加入原子句集 S 中, 得到新子句集 S_2 , 则 S 与 S_2 在不可满足的意义上是等价的, 即

$$S_2 \text{ 的不可满足性} \Leftrightarrow S \text{ 的不可满足性}$$

这两个推论说明: 为要证明子句集 S 的不可满足性, 只要对其中可进行归结的子句进行归结, 并把归结式加入子句集 S , 或者用归结式替换它的亲本子句, 然后对新子句集 (S_1 或 S_2) 证明不可满足性就可以了。注意到空子句是不可满足的, 因此, 如果经过归结能得到空子句, 则立即可得到原子句集 S 是不可满足的结论。这就是用归结原理证明子句集不可满足性的基本思想。

3.4.2 谓词逻辑中的归结原理

在谓词逻辑中, 由于子句中含有变元, 所以不像命题逻辑那样可直接消去互补文字, 而需先用最一般合一对变元进行代换, 然后才能进行归结。

例如, 设有如下两个子句

$$C_1 = P(x) \vee Q(x)$$

$$C_2 = \neg P(a) \vee R(y)$$

由于 $P(x)$ 与 $P(a)$ 不同, 所以 C_1 与 C_2 不能直接进行归结, 但若用最一般合一

$$\sigma = \{a/x\}$$

对两个子句分别进行代换

$$C_1\sigma = P(a) \vee Q(a)$$

$$C_2\sigma = \neg P(a) \vee R(y)$$

就可对它们进行直接归结, 消去 $P(a)$ 与 $\neg P(a)$, 得到如下归结式

$$Q(a) \vee R(y)$$

下面给出谓词逻辑中关于归结的定义。

定义 3.2 设 C_1 与 C_2 是两个没有相同变元的子句, L_1 和 L_2 分别是 C_1 和 C_2 中的文字, 若 σ 是 L_1 和 $\neg L_2$ 的最一般合一, 则称

$$C_{12} = (C_1\sigma - \{L_1\sigma\}) \vee (C_2\sigma - \{L_2\sigma\})$$

为 C_1 和 C_2 的二元归结式。

例 3.6 设 $C_1 = P(a) \vee \neg Q(x) \vee R(x)$, $C_2 = \neg P(y) \vee Q(b)$, 求其二元归结式。

解 若选 $L_1 = P(a)$, $L_2 = \neg P(y)$, 则 $\sigma = \{a/y\}$ 是 L_1 与 $\neg L_2$ 的最一般合一。因此,

$$C_1\sigma = P(a) \vee \neg Q(x) \vee R(x)$$

$$C_2\sigma = \neg P(a) \vee Q(b)$$

根据定义可得

$$\begin{aligned}
 C_{12} &= (C_1\sigma - \{L_1\sigma\}) \vee (C_2\sigma - \{L_2\sigma\}) \\
 &= (\{P(a), \neg Q(x), R(x)\} - \{P(a)\}) \vee (\{\neg P(a), Q(b)\} - \{\neg P(a)\}) \\
 &= (\{\neg Q(x), R(x)\}) \vee (\{Q(b)\}) \\
 &= \{\neg Q(x), R(x), Q(b)\} \\
 &= \neg Q(x) \vee R(x) \vee Q(b)
 \end{aligned}$$

若选 $L_1 = \neg Q(x), L_2 = Q(b), \sigma = \{b/x\}$, 则可得

$$\begin{aligned}
 C_{12} &= (\{P(a), \neg Q(b), R(b)\} - \{\neg Q(b)\}) \vee (\{\neg P(y), Q(b)\} - \{Q(b)\}) \\
 &= (\{P(a), R(b)\}) \vee (\{\neg P(y)\}) \\
 &= \{P(a), R(b), \neg P(y)\} \\
 &= P(a) \vee R(b) \vee \neg P(y)
 \end{aligned}$$

例 3.7 设 $C_1 = P(x) \vee Q(a), C_2 = \neg P(b) \vee R(x)$, 求其二元归结式。

解 由于 C_1 与 C_2 有相同的变元, 不符合定义的要求。为了进行归结, 需修改 C_2 中的变元的名字, 令 $C_2 = \neg P(b) \vee R(y)$ 。此时, $L_1 = P(x), L_2 = \neg P(b)$ 。

L_1 与 $\neg L_2$ 的最一般合一 $\sigma = \{b/x\}$ 。则

$$\begin{aligned}
 C_{12} &= (\{P(b), Q(a)\} - \{P(b)\}) \vee (\{\neg P(b), R(y)\} - \{\neg P(b)\}) \\
 &= \{Q(a), R(y)\} \\
 &= Q(a) \vee R(y)
 \end{aligned}$$

如果在参加归结的子句内部含有可合一的文字, 则在归结之前应对这些文字先进行合一。

例 3.8 设有如下两个子句 $C_1 = P(x) \vee P(f(a)) \vee Q(x), C_2 = \neg P(y) \vee R(b)$, 求其二元归结式。

解 在 C_1 中有可合一的文字 $P(x)$ 与 $P(f(a))$, 若用它们的最一般合一 $\theta = \{f(a)/x\}$ 进行代换, 得到 $C_1\theta = P(f(a)) \vee Q(f(a))$ 。此时可对 $C_1\theta$ 和 C_2 进行归结, 从而得到 C_1 与 C_2 的二元归结式。

对 $C_1\theta$ 和 C_2 分别选 $L_1 = P(f(a)), L_2 = \neg P(y)$ 。 L_1 和 $\neg L_2$ 的最一般合一是 $\sigma = \{f(a)/y\}$, 则 $C_{12} = R(b) \vee Q(f(a))$ 。

在上例中, 把 $C_1\theta$ 称为 C_1 的因子。一般来说, 若子句 C 中有两个或两个以上的文字具有最一般的合一 σ , 则称 $C\sigma$ 为子句 C 的因子。如果 $C\sigma$ 是一个单文字, 则称它为 C 的单元因子。

应用因子的概念, 可对谓词逻辑中的归结原理给出如下定义。

定义 3.3 子句 C_1 和 C_2 的归结式是下列二元归结式之一:

- ① C_1 与 C_2 的二元归结式;
- ② C_1 的因子 $C_1\sigma_1$ 与 C_2 的二元归结式;
- ③ C_1 与 C_2 的因子 $C_2\sigma_2$ 的二元归结式;
- ④ C_1 的因子 $C_1\sigma_1$ 与 C_2 的因子 $C_2\sigma_2$ 的二元归结式。

与命题逻辑中的归结原理相同,对于谓词逻辑,归结式是其亲本子句的逻辑结论。用归结式取代它在子句集 S 中的亲本子句所得到的新子句集仍然保持着原子句集 S 的不可满足性。

另外,对于一阶谓词逻辑,从不可满足的意义上说,归结原理也是完备的。即若子句集是不可满足的,则必存在一个从该子句集到空子句的归结演绎;若从子句集存在一个到空子句的演绎,则该子句集是不可满足的。关于归结原理的完备性可用海伯伦的有关理论进行证明,这里不再讨论。

需要指出的是,如果没有归结出空子句,则既不能说 S 不可满足,也不能说 S 是可满足的。因为,有可能 S 是可满足的,而归结不出空子句;也可能是没有找到合适的归结演绎步骤,而归结不出空子句。但是,如果确定不存在任何方法归结出空子句,则可以确定 S 是可满足的。

归结原理的能力是有限的,例如,用归结原理证明“两个连续函数之和仍然是连续函数”时,推导 10 万步也没能证明出结果。

3.5 归结反演

归结原理给出了证明子句集不可满足性的方法。根据第 2 章的知识可知,如欲证明 Q 为 $P_1, P_2, \dots, P_n$ 的逻辑结论,只需证明

$$(P_1 \wedge P_2 \wedge \dots \wedge P_n) \wedge \neg Q$$

是不可满足的。再根据定理 3.1 可知,在不可满足的意义上,谓词公式的不可满足性与其子句集的不可满足性是等价的。因此,可用归结原理进行定理的自动证明。

应用归结原理证明定理的过程称为归结反演。归结反演的一般步骤是:

- ① 将已知前提表示为谓词公式 F ;
- ② 将待证明的结论表示为谓词公式 Q , 并否定得到 $\neg Q$;
- ③ 把谓词公式集 $\{F, \neg Q\}$ 化为子句集 S ;
- ④ 应用归结原理对子句集 S 中的子句进行归结, 并把每次归结得到的归结式都并入到 S 中。如此反复进行, 若出现了空子句, 则停止归结, 此时就证明了 Q 为真。

例 3.9 某公司招聘工作人员, A, B, C 三人应试, 经面试后公司表示如下想法:

- ① 三人中至少录取一人;
- ② 如果录取 A 而不录取 B , 则一定录取 C ;
- ③ 如果录取 B , 则一定录取 C 。

求证: 公司一定录取 C 。

证明 设谓词 $P(x)$ 表示录取 x , 则把公司的想法用谓词公式表示如下:

- (1) $P(A) \vee P(B) \vee P(C)$
- (2) $P(A) \wedge \neg P(B) \rightarrow P(C)$
- (3) $P(B) \rightarrow P(C)$

把要求证的结论用谓词公式表示出来并否定, 得

(4) $\neg P(C)$

把上述公式化成子句集

- (1) $P(A) \vee P(B) \vee P(C)$
- (2) $\neg P(A) \vee P(B) \vee P(C)$
- (3) $\neg P(B) \vee P(C)$
- (4) $\neg P(C)$

应用归结原理进行归结

- | | |
|----------------------|-----------|
| (5) $P(B) \vee P(C)$ | (1)与(2)归结 |
| (6) $P(C)$ | (3)与(5)归结 |
| (7) NIL | (4)与(6)归结 |

所以公司一定录取 C 。

上述归结过程可用图 3.6 的归结树表示。




图 3.6 例 3.9 的归结树

例 3.10 已知如下信息。

规则 1:任何人的兄弟不是女性。

规则 2:任何人的姐妹必是女性。

事实: Mary 是 Bill 的姐妹。

求证: Mary 不是 Tom 的兄弟。

解 定义谓词:

$brother(x,y)$: x 是 y 的兄弟

$sister(x,y)$: x 是 y 的姐妹

$woman(x)$: x 是女性

把已知规则与事实表示成谓词公式,得

规则 1: $\forall x \forall y (brother(x,y) \rightarrow \neg woman(x))$

规则 2: $\forall x \forall y (sister(x,y) \rightarrow woman(x))$

事实: $sister(Mary,Bill)$

把要求证的结论表示成谓词公式,得

求证: $\neg \text{brother}(\text{Mary}, \text{Tom})$

化规则 1 为子句

$$\forall x \forall y (\neg \text{brother}(x, y) \vee \neg \text{woman}(x))$$

$$C_1 = \neg \text{brother}(x, y) \vee \neg \text{woman}(x)$$

化规则 2 为子句

$$\forall x \forall y (\neg \text{sister}(x, y) \vee \text{woman}(x))$$

$$C_2 = \neg \text{sister}(u, v) \vee \text{woman}(u)$$

事实原来就是子句形式

$$C_3 = \text{sister}(\text{Mary}, \text{Bill})$$

C_2 与 C_3 归结为

$$C_{23} = \text{woman}(\text{Mary})$$

C_{23} 与 C_1 归结为

$$C_{123} = \neg \text{brother}(\text{Mary}, y)$$

设 $C_4 = \text{brother}(\text{Mary}, \text{Tom})$, 则

$$C_{1234} = \text{NIL}$$

所以,得证。

对子句集进行归结时,关键的一步是从子句集中找出可以进行归结的一对子句。由于事先不知道哪两个子句可以进行归结,更不知道通过对哪些子句对的归结可以尽快地得到空子句,必须对子句集中的所有子句逐对地进行比较,对任何一对可归结的子句对都进行归结。这样不仅耗费时间,而且还会因为归结出了许多无用的归结式而占用许多存储空间,造成时空的浪费,降低效率。为解决这些问题,人们研究出了多种归结策略。这些归结策略大致可分为两大类:一类是删除策略,另一类是限制策略。前一类通过删除某些无用的子句来缩小归结的范围,后一类通过对参加归结的子句进行种种限制,尽可能地减少归结的盲目性,使其尽快地归结出空子句。关于归结策略可以参看有关书籍。

3.6 应用归结原理求解问题

归结原理除了可用于定理证明外,还可用来求取问题的答案,其思想与定理证明类似。下面给出应用归结原理求解问题的步骤:

- ① 把已知前提用谓词公式表示出来,并且化为相应的子句集,设该子句集的名字为 S ;
- ② 把待求解的问题也用谓词公式表示出来,然后把它否定并与答案谓词 $ANSWER$ 构成析取式, $ANSWER$ 是一个为了求解问题而专设的谓词,其变元必须与问题公式的变元完全一致;
- ③ 把②中得到的析取式化为子句集,并把该子句集并入到子句集 S 中,得到子句集 S' ;
- ④ 对 S' 应用归结原理进行归结;

⑤ 若得到归结式 $ANSWER$, 则答案就在 $ANSWER$ 中。

例 3.11 已知如下信息。

F_1 : 王 ($Wang$) 先生是小李 (Li) 的老师。

F_2 : 小李与小张 ($Zhang$) 是同班同学。

F_3 : 如果 x 与 y 是同班同学, 则 x 的老师也是 y 的老师。

求小张的老师是谁?

解 定义谓词。

$T(x, y)$: x 是 y 的老师。

$C(x, y)$: x 与 y 是同班同学。

把已知前提及待求解的问题表示成谓词公式, 得

$F_1: T(Wang, Li)$

$F_2: C(Li, Zhang)$

$F_3: (\forall x)(\forall y)(\forall z)(C(x, y) \wedge T(z, x) \rightarrow T(z, y))$

把待求解的问题表示成谓词公式, 并把它否定后与谓词 $ANSWER(x)$ 析取, 得

$G: \neg (\exists x) T(x, Zhang) \vee ANSWER(x)$

把上述谓词公式化为子句集。

(1) $T(Wang, Li)$

(2) $C(Li, Zhang)$

(3) $\neg C(x, y) \vee \neg T(z, x) \vee T(z, y)$

(4) $\neg T(u, Zhang) \vee ANSWER(u)$

应用归结原理进行归结。

(5) $\neg C(Li, y) \vee T(Wang, y)$ (1) 与 (3) 归结

(6) $\neg C(Li, Zhang) \vee ANSWER(Wang)$ (4) 与 (5) 归结

(7) $ANSWER(Wang)$ (2) 与 (6) 归结

由 $ANSWER(Wang)$ 得知小张的老师是王先生。

上述归结过程可用图 3.7 的归结树表示。




图 3.7 例 3.11 的归结树

例 3.12 设 A, B, C 三人中有人从不说真话, 也有人从不说假话, 某人向这三人分别提出同一个问题: 谁是说谎者? A 答: “ B 和 C 都是说谎者”; B 答: “ A 和 C 都是说谎者”; C 答: “ A 和 B 中至少有一个是说谎者”。求谁是老实人, 谁是说谎者。

解 设用 $T(x)$ 表示 x 说真话。

如果 A 说真话, 则有

$$T(A) \rightarrow \neg T(B) \wedge \neg T(C)$$

如果 A 说的是假话, 则有

$$\neg T(A) \rightarrow T(B) \vee T(C)$$

对 B 和 C 说的话作相同的处理, 可得

$$T(B) \rightarrow \neg T(A) \wedge \neg T(C)$$

$$\neg T(B) \rightarrow T(A) \vee T(C)$$

$$T(C) \rightarrow \neg T(A) \vee \neg T(B)$$

$$\neg T(C) \rightarrow T(A) \wedge T(B)$$

把上面这些公式化成子句集, 得到 S 。

$$(1) \neg T(A) \vee \neg T(B)$$

$$(2) \neg T(A) \vee \neg T(C)$$

$$(3) T(A) \vee T(B) \vee T(C)$$

$$(4) \neg T(B) \vee \neg T(C)$$

$$(5) \neg T(C) \vee \neg T(A) \vee \neg T(B)$$

$$(6) T(C) \vee T(A)$$

$$(7) T(C) \vee T(B)$$

下面首先求谁是老实人。把 $\neg T(x) \vee ANSWER(x)$ 并入 S 得到 S_1 。即 S_1 比 S 多如下一个子句。

$$(8) \neg T(x) \vee ANSWER(x)$$

应用归结原理对 S_1 进行归结。

$$(9) \neg T(A) \vee T(C) \quad (1) \text{ 和 } (7) \text{ 归结}$$

$$(10) T(C) \quad (6) \text{ 和 } (9) \text{ 归结}$$

$$(11) ANSWER(C) \quad (8) \text{ 和 } (10) \text{ 归结}$$

所以 C 是老实人, 即 C 从不说假话。

事实上, 无论如何对 S_1 进行归结, 都推不出 $ANSWER(B)$ 与 $ANSWER(A)$ 。

注意: (2) 与 (3) 不能归结出 $T(B)$ 。

下面来证明 A 和 B 不是老实人。

设 A 不是老实人, 则有 $\neg T(A)$, 把它否定并入 S 中, 得到子句集 S_2 , 即 S_2 比 S 多如下一个子句。

$$(12) \neg (\neg T(A)) \text{ 即 } T(A)$$

应用归结原理对 S_2 进行归结。

- | | |
|----------------------------|----------------|
| (13) $\neg T(A) \vee T(C)$ | (1) 和 (7) 归结 |
| (14) $\neg T(A)$ | (2) 和 (13) 归结 |
| (15) NIL | (12) 和 (14) 归结 |

所以 A 不是老实人。

同样,可证明 B 也不是老实人。

由上面的例子可以看出,在归结过程中,一个子句可以多次被用来进行归结,也可以不被用来归结。在归结时并不一定要把子句集的全部子句都用到,只要在定理证明时能归结出空子句,在求取问题答案时能归结出 $ANSWER$ 就可以了。

3.7 小 结

1. 推理的概念

从初始证据出发,按某种策略不断运用知识库中的已知知识,逐步推出结论的过程称为推理。

演绎推理是从一般性知识推出适合于某一具体情况的结论。这是一种从一般到个别的推理过程。归纳推理是从足够多的事例中归纳出一般性结论的推理,是一种从个别到一般的推理过程。默认推理是在知识不完全的情况下假设某些条件已经具备所进行的推理。

所谓确定性推理是指推理时所用的知识与证据都是确定的,推出的结论也是确定的。所谓不确定性推理是指推理时所用的知识与证据不都是确定的,推出的结论也是不确定的。

单调推理是在推理过程中随着推理向前推进及新知识的加入,推出的结论越来越接近最终目标。非单调推理是在推理过程中由于新知识的加入,不仅没有加强已推出的结论,反而要否定它,使推理退回到前面的某一步,然后重新开始。

若按推理中是否运用与推理有关的启发性知识来划分,推理可分为启发式推理与非启发式推理。

正向推理是以已知事实作为出发点的一种推理。逆向推理是以某个假设目标作为出发点的一种推理。既有正向又有逆向的推理称为混合推理。

2. 推理的方法

从一组已知为真的事实出发,直接运用经典逻辑的推理规则推出结论的过程称为自然演绎推理。

原子谓词公式及其否定,称为文字。任何文字的析取式称为子句。

把谓词公式可以化成子句集。谓词公式不可满足的充要条件是其子句集不可满足。

鲁宾逊归结原理是机器定理证明的基础,是一种证明子句集不可满足性,从而实现定理证明的一种理论及方法。它的基本方法是:将要证明的定理表示为谓词公式,并化为子句集,然后进行归结,一旦归结出空子句,则定理得证。

应用归结原理求解问题的方法:把已知前提用谓词公式表示出来,并且化为相应的子句集,把待求解的问题也用谓词公式表示出来,然后把它否定并与谓词 *ANSWER* 构成析取式,化为子句集;对子句集进行归结,若得到归结式 *ANSWER*,则答案就在 *ANSWER* 中。

思考题

- 3.1 什么是推理、正向推理、逆向推理、混合推理? 试列出常用的几种推理方式并列出每种推理方式的特点。
- 3.2 什么是冲突? 在产生式系统中解决冲突的策略有哪些?
- 3.3 什么是子句? 什么是子句集? 请写出求谓词公式子句集的步骤。
- 3.4 谓词公式与它的子句集等价吗? 在什么情况下它们才会等价?
- 3.5 引入鲁宾逊归结原理有何意义? 什么是归结原理? 什么是归结式?
- 3.6 请写出利用归结原理求解问题答案的步骤。

习题

- 3.1 设已知下述事实: $A; B; A \rightarrow C; B \wedge C \rightarrow D; D \rightarrow Q$ 。求证: Q 为真。

- 3.2 将下列谓词公式化为相应的子句集。

$$\neg \exists x \forall y \exists z \forall w P(x, y, z, w)$$

- 3.3 将下列逻辑表达式化为不含存在量词的前束形。

$$(\exists x)(\forall y)[(\forall z)P(x, z) \rightarrow R(x, y, f(a))]$$

- 3.4 把下列谓词公式分别化为相应的子句集。

$$(1) (\forall z)(\forall y)(P(z, y) \wedge Q(z, y))$$

$$(2) (\forall x)(\forall y)(P(x, y) \rightarrow Q(x, y))$$

$$(3) (\forall x)(\exists y)(P(x, y) \vee Q(x, y) \rightarrow R(x, y))$$

$$(4) (\forall x)(\forall y)(P(x, y) \vee Q(x, y) \rightarrow R(x, y))$$

$$(5) (\forall x)(\forall y)(\exists z)(P(x, y) \rightarrow Q(x, y) \vee R(x, z))$$

$$(6) (\exists x)(\exists y)(\forall z)(\exists u)(\forall v)(\exists w)(P(x, y, z, u, v, w) \wedge (Q(x, y, z, u, v, w) \vee \neg R(x, z, w)))$$

$$(7) (\forall x)\{(\forall y)P(x, y) \rightarrow \neg(\forall y)[Q(x, y) \rightarrow R(x, y)]\}$$

- 3.5 判断下列子句集中哪些是不可满足的。

$$(1) S = \{\neg P \vee Q, \neg Q, P, \neg P\}$$

$$(2) S = \{P \vee Q, \neg P \vee Q, P \vee \neg Q, \neg P \vee \neg Q\}$$

$$(3) S = \{P(y) \vee Q(y), \neg P(f(x)) \vee R(a)\}$$

$$(4) S = \{\neg P(x) \vee Q(x), \neg P(y) \vee R(y), P(a), S(a), \neg S(z) \vee \neg R(z)\}$$

$$(5) S = \{\neg P(x) \vee \neg Q(y) \vee \neg L(x, y), P(a), \neg R(z) \vee L(a, z), R(b), Q(b)\}$$

- 3.6 对下列各题分别证明 G 为 $F_1, F_2, \dots, F_n$ 的逻辑结论。

$$(1) F_1: (\exists x)(\exists y)P(x, y)$$

$$G: (\forall y)(\exists x)P(x,y)$$

$$(2) F_1: (\forall x)(P(x) \wedge (Q(a) \vee Q(b)))$$

$$G: (\exists x)(P(x) \wedge Q(x))$$

$$(3) F_1: (\exists x)(\exists y)(P(f(x)) \wedge Q(f(y)))$$

$$G: P(f(a)) \wedge P(y) \wedge Q(y)$$

$$(4) F_1: (\forall x)(P(x) \rightarrow (\forall y)(Q(y) \rightarrow \neg L(x,y)))$$

$$F_2: (\exists x)(P(x) \wedge (\forall y)(R(y) \rightarrow L(x,y)))$$

$$G: (\forall x)(R(x) \rightarrow \neg Q(x))$$

$$(5) F_1: (\forall x)(P(x) \rightarrow (Q(x) \wedge R(x)))$$

$$F_2: (\exists x)(P(x) \wedge S(x))$$

$$G: (\exists x)(S(x) \wedge R(x))$$

$$(6) F_1: (\forall z)(A(z) \wedge \neg B(z) \rightarrow (\exists y)(D(z,y) \wedge C(y)))$$

$$F_2: (\exists z)(E(z) \wedge A(z) \wedge (\forall y)(D(z,y) \rightarrow E(y)))$$

$$F_3: (\forall z)(E(z) \rightarrow \neg B(z))$$

$$G: (\exists z)(E(z) \wedge C(z))$$

3.7 已知:

① 能够阅读的都是有文化的;

② 海豚是没有文化的;

③ 某些海豚是有智能的。

用归结原理证明:某些有智能的并不能阅读。

3.8 已知前提:每个储蓄钱的人都获得利息。

用归结原理证明:如果没有利息,那么就沒有人去储蓄钱。

3.9 已知:每个使用 Internet 的人都想从网络获得信息。

用归结原理证明:如果没有信息就不会有人使用 Internet。

3.10 设有如下关系:

① 如果 x 是 y 的父亲, y 又是 z 的父亲, 则 x 是 z 的祖父;

② 老李是大李的父亲;

③ 大李是小李的父亲;

用归结原理回答:上述人员中谁和谁是祖孙关系?

3.11 已知:

F_1 : 小张(Zhang)在哪里, 则小李(Li)就去那里。

F_2 : 小张在学校里。

用归结原理回答:小李在哪里?

3.12 设 TONY、MIKE 和 JOHN 属于 ALPINE 俱乐部, ALPINE 俱乐部的成员不是滑雪运动员就是登山运动员。登山运动员不喜欢雨, 而且任何不喜欢雪的人不是滑雪运动员。MIKE 讨厌 TONY 所喜欢的一切东西, 而喜欢 TONY 所讨厌的一切东西。TONY 喜欢雨和雪。试用谓词公式的集合表示这段知识, 用归结原理回答问题: “ALPINE 俱乐部的一个成员, 他是一个登山运动员但不是一个滑雪运动员, 他是谁?”

读一读

国家最高科学技术奖得主吴文俊院士

吴文俊,1919年5月12日出生于上海,祖籍浙江嘉兴,因战乱迁至地势高、远离战乱的青浦县朱家角。1932年上海“一·二八”事变爆发后,吴文俊被送回浙江嘉兴老家,躲避战乱。半年之后,他返回上海继续读书。

吴文俊高中毕业时,其实兴趣在物理而不在数学。一次物理考试题很难,他却成绩出色。毕业时校方讨论保送,物理老师却以他独到的眼光推荐他学数学。他也认为自己物理考得好的原因在于数学,攻读数学才能使他的才能得到更好更多地发挥。1936年,吴文俊被保送至交通大学数学系。他大三以自学为主学实变函数论,读经典著作。有了实变函数论的基础,很快进入康托尔集合论,钻研点集拓扑。

1946年初,吴文俊到上海临时大学任郑太朴教授的助手;同年8月,陈省身吸收吴文俊到数学所任助理研究员。1947年,完成一项重要拓扑学研究,证明 Whitney 乘积公式和对偶定理,1948年在 *Annals of Math* 上发表;同年10月,他经推荐到巴黎留学,在斯特拉斯堡大学跟随 C. Ehresmann 学习。1949年,去苏黎世访问,完成博士论文《论球丛空间结构的示性类》,获法国斯特拉斯堡大学博士学位;同年秋天,应 H. 嘉当邀请入巴黎法国国家科学研究中心工作。1950年,与 Thom 合作发表关于流形上 Stiefel-Whitney 示性类的论文,后通称为吴类与吴公式,至今仍被国际同行广泛引用。

1951年8月,回到中国,在北京大学数学系任教授。1952年10月,到新建中国科学院数学与系统科学研究院任研究员。1957年,当选为中国科学院学部委员(院士)。“文革”期间他在无线电一厂(计算机厂)下放,开始对计算机感兴趣,研究机器证明。1977年大年初一,受中国数学史研究启发,取得了机器证明的突破,“初等几何判定问题与机器证明”同年在《中国科学》发表。逻辑定理证明先驱王浩在得知吴文俊的结果后,于1978年4月10日写信建议他利用已有的代数包,自己考虑编程实现吴方法。王浩扩大了吴文俊的工作在定理证明界的影响。

1979年,吴文俊在中国科学院领导支持下申请到2万美元去美国购买了一台电脑,以实现他的吴文俊方法。60岁高龄的他开始学习编程,先是 BASIC,后又学 Algo 和 Fortran,在这台电脑上不断取得新成果。

1991年,当选第三世界科学院院士;1997年获得第四届 Herbrand 奖;2001年2月,获2000年度国家最高科学技术奖。2017年5月7日7时21分,吴文俊在北京去世,享年98岁。

读一读

中国人工智能学会

中国人工智能学会(Chinese Association for Artificial Intelligence, CAAI)成立于1981年,是经民政部正式注册的我国智能科学技术领域的国家级学会,是中国科学技术协会的正式团体会员。

目前拥有61个分支机构,包括52个专业委员会和9个工作委员会,覆盖了智能科学与技术领域。学会活动的学术领域是智能科学技术,活动地域是中华人民共和国全境,基本任务是团结全国智能科学技术工作者和积极分子通过学术研究、国内外学术交流、科学普及、学术教育、科技会展、学术出版、人才推荐、学术评价、学术咨询、技术评审与奖励等活动促进我国智能科学技术的发展,为国家的经济发展、社会进步、文明提升、安全保障提供智能化的科学技术服务。

学会自主创办全球人工智能技术大会、中国人工智能大会、中国智能产业高峰论坛、“华为杯”全国大学生智能设计竞赛、全国大学生计算机博弈大赛、IEEE云计算与智能系统国际会议等规模化、系列化学术活动。为智能科学技术工作者提供了一个展示、交流、融合科研成果的平台,有效地促进智能科学技术的发展。

学会主办有公开出版物《智能系统学报》(*CAAI Transactions on Intelligent Systems*)(中文核心期刊);内部刊物《智能技术学报》(*CAAI Transactions on Intelligent Technology*)、《中国人工智能学会通讯》、《学会通讯》青年专刊、《AI学者》网络文摘等中文杂志,另有在日本出版的英文刊物 *International Journal of Advanced Intelligence*。

学会充分利用行业和学科资源、发挥自身优势,结合学会学术活动、学科行业重大科技事件、学科行业发展需求及人才储备等,开展有特色、有创新、具有典型示范作用的科普工作,让公众尽可能直观、形象地了解、体验智能科技带来的便捷,取得良好社会效果。

学会高度重视人才队伍建设,大力开展人才奖励与举荐优秀科技人才工作,同时发挥青年工作委员会的优势,把发现人才、培养人才、举荐人才作为人才建设的抓手,为促进人才队伍的建设做出大量的工作,收效良好。学会围绕“吴文俊人工智能科学技术奖”“中国人工智能学会优秀博士学位论文评选”“学会先进个人”等奖项及院士推荐等推荐申报工作,表彰了一批优秀青年人才,推出了一大批的优秀科技工作者和优秀研究成果。

第4章

不确定性推理方法

第3章讨论了建立在经典逻辑基础上的确定性推理。这是一种运用确定性知识,从确定的事实或证据进行精确推理得到确定性结论的推理方法。但现实世界中的事物以及事物之间的关系是极其复杂的。由于客观上存在的随机性、模糊性以及某些事物或现象暴露得不充分性,导致人们对它们的认识往往是不精确、不完全的,具有一定程度的不确定性。这种认识上的不确定性反映到知识以及由观察所得到的证据上来,就分别形成了不确定性的知识及不确定性的证据。人们通常是在信息不完善、不精确的情况下运用不确定性知识进行思维、求解问题的,推出的结论也是不确定的。因而还必须对不确定性知识的表示及推理进行研究。这就是本章将要讨论的不确定性推理。

下面首先讨论不确定性推理中的基本问题,然后着重介绍基于概率论的有关理论发展起来的不确定性推理方法,主要介绍可信度方法、证据理论,最后介绍目前在专家系统、信息处理、自动控制等领域广泛应用的依据模糊理论发展起来的模糊推理方法。

4.1 不确定性推理的概念

不确定性推理是从不确定性的初始证据出发,通过运用不确定性的知识,最终推出具有一定程度的不确定性但却是合理或者近乎合理的结论的思维过程。

在不确定性推理中,知识和证据都具有某种程度的不确定性,这就为推理机的设计与实现增加了复杂性和难度。它除了必须解决推理方向、推理方法、控制策略等基本问题外,一般还需要解决不确定性的表示与度量、不确定性匹配、不确定性的传递算法以及不确定性的合成等重要问题。

1. 不确定性的表示与度量

在不确定性推理中,“不确定性”一般分为两类:一是知识的不确定性,二是证据的不确定性。它们都要求有相应的表示方式和度量标准。

(1) 知识不确定性的表示

知识的表示与推理是密切相关的两个方面,不同的推理方法要求有相应的知识表示模式与之对应。在不确定性推理中,由于要进行不确定性的计算,因而必须用适当的方法把不确定

性及不确定的程度表示出来。

在确立不确定性的表示方法时,有两个直接相关的因素需要考虑:一是要能根据领域问题的特征把其不确定性比较准确地描述出来,满足问题求解的需要;二是要便于推理过程中对不确定性的推算。只有把这两个因素结合起来统筹考虑,相应的表示方法才是实用的。

目前,在专家系统中知识的不确定性一般是由领域专家给出的,通常是一个数值,它表示相应知识的不确定性程度,称为知识的静态强度。

静态强度可以是相应知识在应用中成功的概率,也可以是该条知识的可信程度或其他,其值的大小范围因其意义与使用方法的不同而不同。今后在讨论各种不确定性推理模型时,将具体地给出静态强度的表示方法及其含义。

(2) 证据不确定性的表示

在推理中,有两种来源不同的证据:一种是用户在求解问题时提供的初始证据,例如,患者的症状、化验结果等;另一种是在推理中用前面推出的结论作为当前推理的证据。对于前一种情况,即用户提供的初始证据,由于这种证据多来源于观察,因而通常是不精确、不完全的,即具有不确定性。对于后一种情况,由于所使用的知识及证据都具有不确定性,因而推出的结论当然也具有不确定性,当把它用作后面推理的证据时,它亦是不确定性的证据。

一般来说,证据不确定性的表示方法应与知识不确定性的表示方法保持一致,以便于推理过程中对不确定性进行统一的处理。在有些系统中,为了便于用户的使用,对初始证据的不确定性与知识的不确定性采取了不同的表示方法,但这只是形式上的,在系统内部亦做了相应的转换处理。

证据的不确定性通常也用一个数值表示。它代表相应证据的不确定性程度,称之为动态强度。对于初始证据,其值由用户给出;对于用前面推理所得结论作为当前推理的证据,其值由推理中不确定性的传递算法计算得到。

(3) 不确定性的度量

对于不同的知识及不同的证据,其不确定性的程度一般是不相同的,需要用不同的数据表示其不确定性的程度,同时还需要事先规定它的取值范围,只有这样每个数据才会有确定的意义。例如,在专家系统 MYCIN 中,用可信度表示知识及证据的不确定性,取值范围为 $[-1, 1]$ 。当可信度取大于零的数值时,其值越大表示相应的知识或证据越接近于“真”;当可信度的取值小于零时,其值越小表示相应的知识或证据越接近于“假”。

在确定一种度量方法及其范围时,应注意以下几点。

① 度量要能充分表达相应知识及证据不确定性的程度。

② 度量范围的指定应便于领域专家及用户对不确定性的估计。

③ 度量要便于对不确定性的传递进行计算,而且对结论算出的不确定性度量不能超出度量规定的范围。

④ 度量的确定应当是直观的,同时应有相应的理论依据。

2. 不确定性匹配算法及阈值

推理是一个不断运用知识的过程。在这一过程中,为了找到所需的知识,需要用知识的前提条件与数据库中已知的证据进行匹配,只有匹配成功的知识才有可能被应用。

对于不确定性推理,由于知识和证据都具有不确定性,而且知识所要求的不确定性程度与证据实际具有的不确定性程度不一定相同,因而就出现了“怎么才算匹配成功”的问题。对于这个问题,目前常用的解决方法是,设计一个算法用来计算匹配双方相似的程度,另外再指定一个相似的“限度”,用来衡量匹配双方相似的程度是否落在指定的限度内。如果落在指定的限度内,就称它们是可匹配的,相应知识可被应用,否则就称它们是不可匹配的,相应知识不可应用。上述用来计算匹配双方相似程度的算法称为不确定性匹配算法,用来指出相似的“限度”称为阈值。

3. 组合证据不确定性的算法

在基于产生式规则的系统中,知识的前提条件既可以是简单条件,也可以是用 AND 或 OR 把多个简单条件连接起来构成的复合条件。进行匹配时,一个简单条件对应于一个单一的证据,一个复合条件对应于一组证据,这一组证据称为组合证据。在不确定性推理中,由于结论的不确定性通常是通过证据及知识的不确定性进行某种运算得到的,因而需要有合适的算法计算组合证据的不确定性。目前,关于组合证据不确定性的计算已经提出了多种方法,如最大最小方法、Hamacher 方法、概率方法、有界方法、Einstein 方法等。每种方法都有相应的适应范围和使用条件,如概率方法只能在事件之间完全独立时使用。

4. 不确定性的传递算法

不确定性推理的根本目的是根据用户提供的初始证据,通过运用不确定性知识,最终推出不确定性的结论,并推算出结论的不确定性程度。因此,需要解决下面两个问题。

- ① 在每一步推理中,如何把证据及知识的不确定性传递给结论。
- ② 在多步推理中,如何把初始证据的不确定性传递给最终结论。

对于第一个问题,在不同的不确定性推理方法中所采用的处理方法各不相同,这将在下面的几节中分别进行讨论。

对于第二个问题,各种方法所采用的处理方法基本相同,即把当前推出的结论及其不确定性度量作为证据放入数据库中,供以后推理使用。由于最初那一步推理的结论是用初始证据推出的,其不确定性包含了初始证据的不确定性对它所产生的影响,因而当它又用作证据推出进一步的结论时,其结论的不确定性仍然会受到初始证据的影响。由此一步步地进行推理,必然就会把初始证据的不确定性传递给最终结论。

5. 结论不确定性的合成

推理中有时会出现这样一种情况:用不同知识进行推理得到了相同的结论,但不确定性的程度却不相同。此时,需要用合适的算法对它们进行合成。在不同的不确定性推理方法中所采用的合成方法各不相同。

以上简要地列出了不确定性推理中一般应该考虑的一些基本问题,但这并不是说任何一

个不确定性推理都必须包括上述各项内容。

长期以来,概率论的有关理论和方法都被用作度量不确定性的重要手段,因为它不仅有完善的理论,而且还为不确定性的合成与传递提供了现成的公式,因而它被最早用于不确定性知识的表示与处理,像这样纯粹用概率模型来表示和处理不确定性的方法称为纯概率方法或概率方法。

纯概率方法虽然有严密的理论依据,但它通常要求给出事件的先验概率和条件概率,而这些数据又不易获得,因此其应用受到了限制。为了解决这个问题,人们在概率理论的基础上发展起来了一些新的方法及理论,主要有主观 Bayes 方法、可信度方法、证据理论等。

基于概率的方法虽然可以表示和处理现实世界中存在的某些不确定性,在人工智能的不确定性推理方面占有重要地位,但它们都没有把事物自身所具有的模糊性反映出来,也不能对其客观存在的模糊性进行有效的处理。扎德等人提出的模糊集理论及其在此基础上发展起来的模糊逻辑弥补了这一缺憾,对由模糊性引起的不确定性的表示及处理开辟了一种新途径,得到了广泛应用。

下面详细讨论几种简单实用的不确定性推理方法。

4.2 可信度方法

可信度方法是肖特里菲(E. H. Shortliffe)等人在确定性理论(theory of confirmation)的基础上,结合概率论等提出的一种不确定性推理方法。它首先在专家系统 MYCIN 中得到了成功的应用。由于该方法比较直观、简单,而且效果也比较好,因而受到人们的重视。目前,许多专家系统都是基于这一方法建造起来的。

人们在长期的实践活动中,对客观世界的认识积累了大量的经验,当面临一个新事物或新情况时,往往可用这些经验对问题的真、假或为真的程度作出判断。这种根据经验对一个事物或现象为真的相信程度称为可信度(certainty)。

显然,可信度带有较大的主观性和经验性,其准确性难以把握。但由于人工智能所面向的多是结构不良的复杂问题,难以给出精确的数学模型,先验概率及条件概率的确定又比较困难,因而用可信度来表示知识及证据的不确定性仍不失为一种可行的方法。另外,由于领域专家有丰富的专业知识及实践经验,也不难对领域内的知识给出其可信度。

C-F 模型是基于可信度表示的不确定性推理的基本方法,其他可信度方法都是在此基础上发展起来的。

1. 知识不确定性的表示

在 C-F 模型中,知识是用产生式规则表示的,其一般形式为

$$\text{IF } E \text{ THEN } H \quad (CF(H, E))$$

其中, $CF(H, E)$ 是该条知识的可信度,称为可信度因子(certainty factor)。

$CF(H, E)$ 反映了前提条件与结论的联系强度,反映当前提条件 E 所对应的证据为真时,它对结论 H 为真的支持程度, $CF(H, E)$ 的值越大,就越支持结论 H 为真。例如

IF 头痛 AND 流涕 THEN 感冒 (0.7)

表示当患者确实有“头痛”及“流涕”的症状时,则有七成的把握认为他是患了感冒。

$CF(H, E)$ 在 $[-1, 1]$ 上取值, $CF(H, E)$ 的值要求领域专家直接给出。其原则是:若由于相应证据的出现增加结论 H 为真的可信度,则取 $CF(H, E) > 0$,证据的出现越是支持 H 为真,就使 $CF(H, E)$ 的值越大;反之,取 $CF(H, E) < 0$,证据的出现越是支持 H 为假,就使 $CF(H, E)$ 的值越小;若证据的出现与否与 H 无关,则取 $CF(H, E) = 0$ 。

2. 证据不确定性的表示

在 C-F 模型中,证据的不确定性也是用可信度因子表示的。例如, $CF(E) = 0.6$ 表示 E 的可信度为 0.6。

证据可信度值的来源分两种情况:对于初始证据,其可信度的值由提供证据的用户给出;对于用先前推出的结论作为当前推理的证据,其可信度的值在推出该结论时通过不确定性传递算法计算得到。

证据 E 的可信度 $CF(E)$ 也是在 $[-1, 1]$ 上取值的。对于初始证据,若对它的所有观察 S 能肯定它为真,则取 $CF(E) = 1$;若肯定它为假,则取 $CF(E) = -1$;若它以某种程度为真,则取 $CF(E)$ 为 $(0, 1)$ 中的某一个值,即 $0 < CF(E) < 1$;若它以某种程度为假,则取 $CF(E)$ 为 $(-1, 0)$ 中的某一个值,即 $-1 < CF(E) < 0$;若它还未获得任何相关的观察,此时可看作观察 S 与它无关,则取 $CF(E) = 0$ 。

在该模型中,尽管知识的静态强度与证据的动态强度都是用可信度因子 CF 表示的,但它们所表示的意义不相同。静态强度 $CF(H, E)$ 表示的是知识的强度,即当 E 所对应的证据为真时对 H 的影响程度,而动态强度 $CF(E)$ 表示的是证据 E 当前的不确定性程度。

3. 组合证据不确定性的算法

当组合证据是多个单一证据的合取时,即

$$E = E_1 \quad \text{AND} \quad E_2 \quad \text{AND} \quad \cdots \quad \text{AND} \quad E_n$$

若已知 $CF(E_1), CF(E_2), \dots, CF(E_n)$, 则

$$CF(E) = \min\{CF(E_1), CF(E_2), \dots, CF(E_n)\} \quad (4.1)$$

当组合证据是多个单一证据的析取时,即

$$E = E_1 \quad \text{OR} \quad E_2 \quad \text{OR} \quad \cdots \quad \text{OR} \quad E_n$$

若已知 $CF(E_1), CF(E_2), \dots, CF(E_n)$, 则

$$CF(E) = \max\{CF(E_1), CF(E_2), \dots, CF(E_n)\} \quad (4.2)$$

4. 不确定性的传递算法

C-F 模型中的不确定性推理从不确定的初始证据出发,通过运用相关的不确定性知识,最终推出结论并求出结论的可信度值。其中,结论 H 的可信度由下式计算:

$$CF(H) = CF(H, E) \times \max\{0, CF(E)\} \quad (4.3)$$

由上式可以看出,当相应证据以某种程度为假,即 $CF(E) < 0$ 时,则

$$CF(H) = 0$$

这说明在该模型中没有考虑证据为假时对结论 H 所产生的影响。另外,当证据为真,即 $CF(E) = 1$ 时,由上式可推出

$$CF(H) = CF(H, E)$$

这说明知识中的规则强度 $CF(H, E)$ 实际上就是在前提条件对应的证据为真时结论 H 的可信度。或者说,当知识的前提条件所对应的证据存在且为真时,结论 H 有 $CF(H, E)$ 大小的可信度。

5. 结论不确定性的合成算法

若由多条不同知识推出了相同的结论,但可信度不同,则可用合成算法求出综合可信度。

由于对多条知识的综合可通过两两的合成实现,所以下面只考虑两条知识的情况。

设有如下知识

IF E_1 THEN H ($CF(H, E_1)$)

IF E_2 THEN H ($CF(H, E_2)$)

则结论 H 的综合可信度可分为如下两步算出:

(1) 分别对每一条知识求出 $CF(H)$

$$CF_1(H) = CF(H, E_1) \times \max\{0, CF(E_1)\}$$

$$CF_2(H) = CF(H, E_2) \times \max\{0, CF(E_2)\}$$

(2) 用下述公式求出 E_1 与 E_2 对 H 的综合影响所形成的可信度 $CF_{1,2}(H)$

$$CF_{1,2}(H) = \begin{cases} CF_1(H) + CF_2(H) - CF_1(H)CF_2(H) & \text{若 } CF_1(H) \geq 0, CF_2(H) \geq 0 \\ CF_1(H) + CF_2(H) + CF_1(H)CF_2(H) & \text{若 } CF_1(H) < 0, CF_2(H) < 0 \\ \frac{CF_1(H) + CF_2(H)}{1 - \min\{|CF_1(H)|, |CF_2(H)|\}} & \text{若 } CF_1(H)CF_2(H) < 0 \end{cases}$$

(4.4)

例 4.1 设有如下一组知识:

r_1 : IF E_1 THEN H (0.8)

r_2 : IF E_2 THEN H (0.6)

r_3 : IF E_3 THEN H (-0.5)

r_4 : IF E_4 AND (E_5 OR E_6) THEN E_1 (0.7)

r_5 : IF E_7 AND E_8 THEN E_3 (0.9)

已知: $CF(E_2) = 0.8, CF(E_4) = 0.5, CF(E_5) = 0.6, CF(E_6) = 0.7, CF(E_7) = 0.6, CF(E_8) = 0.9$ 。
求 $CF(H)$ 。

解 第一步:对每一条规则求出 $CF(H)$ 。

由 r_4 得到

$$\begin{aligned}
CF(E_1) &= 0.7 \times \max\{0, CF[E_4 \text{ AND } (E_5 \text{ OR } E_6)]\} \\
&= 0.7 \times \max\{0, \min\{CF(E_4), CF(E_5 \text{ OR } E_6)\}\} \\
&= 0.7 \times \max\{0, \min\{CF(E_4), \max\{CF(E_5), CF(E_6)\}\}\} \\
&= 0.7 \times \max\{0, \min\{0.5, \max\{0.6, 0.7\}\}\} \\
&= 0.7 \times \max\{0, 0.5\} \\
&= 0.35
\end{aligned}$$

由 r_5 得到

$$\begin{aligned}
CF(E_3) &= 0.9 \times \max\{0, CF(E_7 \text{ AND } E_8)\} \\
&= 0.9 \times \max\{0, \min\{CF(E_7), CF(E_8)\}\} \\
&= 0.9 \times \max\{0, \min\{0.6, 0.9\}\} \\
&= 0.9 \times \max\{0, 0.6\} \\
&= 0.54
\end{aligned}$$

由 r_1 得到

$$\begin{aligned}
CF_1(H) &= 0.8 \times \max\{0, CF(E_1)\} \\
&= 0.8 \times \max\{0, 0.35\} \\
&= 0.28
\end{aligned}$$

由 r_2 得到

$$\begin{aligned}
CF_2(H) &= 0.6 \times \max\{0, CF(E_2)\} \\
&= 0.6 \times \max\{0, 0.8\} \\
&= 0.48
\end{aligned}$$

由 r_3 得到

$$\begin{aligned}
CF_3(H) &= -0.5 \times \max\{0, CF(E_3)\} \\
&= -0.5 \times \max\{0, 0.54\} \\
&= -0.27
\end{aligned}$$

第二步:根据结论不确定性的合成算法得到

$$\begin{aligned}
CF_{1,2}(H) &= CF_1(H) + CF_2(H) - CF_1(H) \times CF_2(H) \\
&= 0.28 + 0.48 - 0.28 \times 0.48 = 0.63 \\
CF_{1,2,3}(H) &= \frac{CF_{1,2}(H) + CF_3(H)}{1 - \min\{|CF_{1,2}(H)|, |CF_3(H)|\}} \\
&= \frac{0.63 - 0.27}{1 - \min\{0.63, 0.27\}} = \frac{0.36}{0.73} = 0.49
\end{aligned}$$

即综合可信度为

$$CF(H) = 0.49$$

4.3 证据理论

证据理论(theory of evidence)是由德普斯特(A. P. Dempster)于20世纪60年代首先提出,并由沙佛(G. Shafer)在20世纪70年代中期进一步发展起来的一种处理不确定性的理论,所以又称为D-S理论。1981年巴纳特(J. A. Barnett)把该理论引入专家系统中,同年卡威(J. Garvey)等人用它实现了不确定性推理。由于该理论能够区分“不确定”与“不知道”的差异,并能处理由“不知道”引起的不确定性,具有较大的灵活性,因而受到了人们的重视。目前,在证据理论的基础上已经发展了多种不确定性推理模型。本节简单介绍几种不确定性推理模型。

4.3.1 概率分配函数

证据理论是用集合表示命题的。

设 D 是变量 x 所有可能取值的集合,且 D 中的元素是互斥的,在任一时刻 x 都取且只能取 D 中的某一个元素为值,则称 D 为 x 的样本空间。

在证据理论中, D 的任何一个子集 A 都对应于一个关于 x 的命题,称该命题为“ x 的值是在 A 中”。例如,用 x 代表打靶时所击中的环数, $D=\{1,2,\dots,10\}$,则 $A=\{5\}$ 表示“ x 的值是5”或者“击中的环数为5”; $A=\{5,6,7,8\}$ 表示“击中的环数是5,6,7,8中的某一个”。又如,用 x 代表所看到的颜色, $D=\{\text{红}, \text{黄}, \text{蓝}\}$,则 $A=\{\text{红}\}$ 表示“ x 是红色”;若 $A=\{\text{红}, \text{蓝}\}$,则它表示“ x 或者是红色,或者是蓝色”。

证据理论中,为了描述和处理不确定性,引入了概率分配函数、信任函数及似然函数等概念。下面首先介绍概率分配函数的概念。

设 D 为样本空间,领域内的命题都用 D 的子集表示,则基本概率分配函数(basic probability assignment function)定义如下:

定义 4.1 设函数 $M:2^D \rightarrow [0,1]$,即对任何一个属于 D 的子集 A ,命它对应一个数 $M \in [0,1]$,且满足

$$\begin{aligned} M(\emptyset) &= 0 \\ \sum_{A \subseteq D} M(A) &= 1 \end{aligned}$$

则称 M 是 2^D 上的基本概率分配函数, $M(A)$ 称为 A 的基本概率数。

关于概率分配函数的定义有以下几点说明。

① 设样本空间 D 中有 n 个元素,则 D 中子集的个数为 2^n 个,定义中的 2^D 就表示这些子集。例如,设

$$D = \{\text{红}, \text{黄}, \text{蓝}\}$$

则它的子集个数刚好是 $2^3=8$ 个,具体为

$$\begin{aligned} A_1 &= \{\text{红}\}, & A_2 &= \{\text{黄}\}, & A_3 &= \{\text{蓝}\}, & A_4 &= \{\text{红}, \text{黄}\}, \\ A_5 &= \{\text{红}, \text{蓝}\}, & A_6 &= \{\text{黄}, \text{蓝}\}, & A_7 &= \{\text{红}, \text{黄}, \text{蓝}\}, & A_8 &= \emptyset \end{aligned}$$

其中, $\emptyset$ 表示空集。

② 概率分配函数的作用是把 D 的任意一个子集 A 都映射为 $[0,1]$ 上的一个数 $M(A)$ 。概率分配函数实际上是对 D 的各个子集进行信任分配, $M(A)$ 表示分配给 A 的那一部分。例如, 设

$$A = \{\text{红}\}, \quad M(A) = 0.3$$

它表示对命题“ x 是红色”的正确性的信任度是 0.3。

当 A 由多个元素组成时, $M(A)$ 不包括对 A 的子集的信任度, 而且也不知道该对它如何进行分配。例如, 在

$$M(\{\text{红}, \text{黄}\}) = 0.2$$

中不包括对 $A = \{\text{红}\}$ 的信任度 0.3, 而且也不知道该把这个 0.2 分配给 $\{\text{红}\}$ 还是分配给 $\{\text{黄}\}$ 。

当 $A = D$ 时, $M(A)$ 是对 D 的各子集进行信任分配后剩下的部分, 它表示不知道该对这部分如何进行分配。例如, 当

$$M(D) = M(\{\text{红}, \text{黄}, \text{蓝}\}) = 0.1$$

时, 它表示不知道该对这个 0.1 如何分配, 但它不是属于 $\{\text{红}\}$, 就一定是属于 $\{\text{黄}\}$ 或 $\{\text{蓝}\}$, 只是由于存在某些未知信息, 不知道应该如何分配。

③ 概率分配函数与概率不同。例如, 设

$$D = \{\text{红}, \text{黄}, \text{蓝}\}$$

且设

$$M(\{\text{红}\}) = 0.3, \quad M(\{\text{黄}\}) = 0, \quad M(\{\text{蓝}\}) = 0.1, \quad M(\{\text{红}, \text{黄}\}) = 0.2,$$

$$M(\{\text{红}, \text{蓝}\}) = 0.2, \quad M(\{\text{黄}, \text{蓝}\}) = 0.1, \quad M(\{\text{红}, \text{黄}, \text{蓝}\}) = 0.1, \quad M(\emptyset) = 0$$

显然, M 符合概率分配函数的定义, 但是

$$M(\{\text{红}\}) + M(\{\text{黄}\}) + M(\{\text{蓝}\}) = 0.4$$

若按概率的要求, 这三者的和应等于 1。

4.3.2 信任函数

定义 4.2 命题的信任函数 (belief function) $Bel: 2^D \rightarrow [0,1]$, 且

$$Bel(A) = \sum_{B \subseteq A} M(B) \quad \forall A \subseteq D \quad (4.5)$$

其中 2^D 表示 D 的所有子集。

Bel 函数又称为下限函数, $Bel(A)$ 表示对命题 A 为真的总的信任程度。

由信任函数及概率分配函数的定义容易推出

$$Bel(\emptyset) = M(\emptyset) = 0$$

$$Bel(D) = \sum_{B \subseteq D} M(B) = 1$$

根据上面给出的数据, 可以求得

$$Bel(\{\text{红}\}) = M(\{\text{红}\}) = 0.3$$

$$\begin{aligned} Bel(\{\text{红}, \text{黄}\}) &= M(\{\text{红}\}) + M(\{\text{黄}\}) + M(\{\text{红}, \text{黄}\}) \\ &= 0.3 + 0.2 = 0.5 \end{aligned}$$

$$\begin{aligned} Bel(\{\text{红}, \text{黄}, \text{蓝}\}) &= M(\{\text{红}\}) + M(\{\text{黄}\}) + M(\{\text{蓝}\}) + M(\{\text{红}, \text{黄}\}) \\ &\quad + M(\{\text{红}, \text{蓝}\}) + M(\{\text{黄}, \text{蓝}\}) + M(\{\text{红}, \text{黄}, \text{蓝}\}) \\ &= 0.3 + 0 + 0.1 + 0.2 + 0.2 + 0.1 + 0.1 = 1 \end{aligned}$$

4.3.3 似然函数

似然函数(plausibility function)又称为不可驳斥函数或上限函数,下面给出它的定义。

定义 4.3 似然函数 $Pl: 2^D \rightarrow [0, 1]$, 且

$$Pl(A) = 1 - Bel(\neg A) \quad \forall A \subseteq D \quad (4.6)$$

现在介绍似然函数的含义。由于 $Bel(A)$ 表示对 A 为真的信任程度, 所以 $Bel(\neg A)$ 就表示对 $\neg A$ 为真, 即 A 为假的信任程度, 由此可推出 $Pl(A)$ 表示对 A 为非假的信任程度。下面来看两个例子, 其中用到的基本概率数仍为上面给出的数据。

$$\begin{aligned} Pl(\{\text{红}\}) &= 1 - Bel(\neg \{\text{红}\}) \\ &= 1 - Bel(\{\text{黄}, \text{蓝}\}) \\ &= 1 - [M(\{\text{黄}\}) + M(\{\text{蓝}\}) + M(\{\text{黄}, \text{蓝}\})] \\ &= 1 - [0 + 0.1 + 0.1] \\ &= 0.8 \end{aligned}$$

$$\begin{aligned} Pl(\{\text{黄}, \text{蓝}\}) &= 1 - Bel(\neg \{\text{黄}, \text{蓝}\}) \\ &= 1 - Bel(\{\text{红}\}) \\ &= 1 - 0.3 \\ &= 0.7 \end{aligned}$$

4.3.4 概率分配函数的正交和(证据的组合)

有时对同样的证据会得到两个不同的概率分配函数, 例如, 对样本空间

$$D = \{a, b\}$$

从不同的来源分别得到如下两个概率分配函数

$$\begin{aligned} M_1(\{a\}) &= 0.3, \quad M_1(\{b\}) = 0.6, \quad M_1(\{a, b\}) = 0.1, \quad M_1(\emptyset) = 0 \\ M_2(\{a\}) &= 0.4, \quad M_2(\{b\}) = 0.4, \quad M_2(\{a, b\}) = 0.2, \quad M_2(\emptyset) = 0 \end{aligned}$$

此时需要对它们进行组合, 德普斯特(A. P. Dempster)提出的组合方法就是对这两个概率分配函数进行正交和运算。

定义 4.4 设 M_1 和 M_2 是两个概率分配函数, 则其正交和 $M = M_1 \oplus M_2$ 为

$$\begin{aligned} M(\emptyset) &= 0 \\ M(A) &= K^{-1} \sum_{x \cap y = A} M_1(x) M_2(y) \end{aligned} \quad (4.7a)$$

其中, K 由下式计算

$$K = 1 - \sum_{x \cap y = \emptyset} M_1(x) M_2(y) = \sum_{x \cap y \neq \emptyset} M_1(x) M_2(y) \quad (4.7b)$$

如果 $K \neq 0$, 则正交和 M 也是一个概率分配函数; 如果 $K = 0$, 则不存在正交和 M , 即没有可能存在概率函数, 称 M_1 与 M_2 矛盾。

对于多个概率分配函数 $M_1, M_2, \dots, M_n$, 如果它们可以组合, 也可通过正交和运算将它们组合为一个概率分配函数。

下面举例说明求正交和的方法。

例 4.2 设 $D = \{\text{黑}, \text{白}\}$, 且设

$$M_1(\{\text{黑}\}, \{\text{白}\}, \{\text{黑}, \text{白}\}, \emptyset) = (0.3, 0.5, 0.2, 0)$$

$$M_2(\{\text{黑}\}, \{\text{白}\}, \{\text{黑}, \text{白}\}, \emptyset) = (0.6, 0.3, 0.1, 0)$$

求 M_1 与 M_2 的正交和。

解 由定义 4.4 得到

$$\begin{aligned} K &= 1 - \sum_{x \cap y = \emptyset} M_1(x) M_2(y) \\ &= 1 - [M_1(\{\text{黑}\}) M_2(\{\text{白}\}) + M_1(\{\text{白}\}) M_2(\{\text{黑}\})] \\ &= 1 - (0.3 \times 0.3 + 0.5 \times 0.6) = 0.61 \end{aligned}$$

$$\begin{aligned} M(\{\text{黑}\}) &= K^{-1} \sum_{x \cap y = \{\text{黑}\}} M_1(x) M_2(y) \\ &= \frac{1}{0.61} [M_1(\{\text{黑}\}) M_2(\{\text{黑}\}) + M_1(\{\text{黑}\}) M_2(\{\text{黑}, \text{白}\}) + M_1(\{\text{黑}, \text{白}\}) M_2(\{\text{黑}\})] \\ &= \frac{1}{0.61} (0.3 \times 0.6 + 0.3 \times 0.1 + 0.2 \times 0.6) = 0.54 \end{aligned}$$

同理可得

$$M(\{\text{白}\}) = 0.43$$

$$M(\{\text{黑}, \text{白}\}) = 0.03$$

所以, 经对 M_1 与 M_2 进行组合后得到的概率分配函数为

$$M(\{\text{黑}\}, \{\text{白}\}, \{\text{黑}, \text{白}\}, \emptyset) = (0.54, 0.43, 0.03, 0)$$

4.3.5 基于证据理论的不确定性推理

基于证据理论的不确定性推理, 大体可分为以下步骤。

- ① 建立问题的样本空间 D 。
- ② 由经验给出, 或者由随机性规则和事实的信度度量计算求得幂集 2^D 的基本概率分配函数。
- ③ 计算所关心的子集 $A \in 2^D$ 的信任函数值 $Bel(A)$ 或者似然函数值 $Pl(A)$ 。
- ④ 由 $Bel(A)$ 或者 $Pl(A)$ 得出结论。

下面通过实例进行说明。

例 4.3 设有规则：

- (1) 如果 流鼻涕 则 感冒但非过敏性鼻炎(0.9)
或 过敏性鼻炎但非感冒(0.1)
(2) 如果 眼发炎 则 感冒但非过敏性鼻炎(0.8)
或 过敏性鼻炎但非感冒(0.05)

又有事实：

- (1) 小王流鼻涕(0.9)
(2) 小王眼发炎(0.4)

括号中的数字表示规则和事实的可信度。

用证据理论推理小王患的什么病？

解 首先,取样本空间

$$D = \{h_1, h_2, h_3\}$$

其中, h_1 表示“感冒但非过敏性鼻炎”, h_2 表示“过敏性鼻炎但非感冒”, h_3 表示“同时得了两种病”。

由式(4.3)可以计算该问题的样本空间的基本概率分配函数。根据第一条规则和第一个事实的可信度：

$$CF(E_1) = 0.9$$

$$CF(H_1, E_1) = 0.9$$

$$CF(H_2, E_1) = 0.1$$

$$CF(H_3, E_1) = 0$$

得到基本概率分配函数为

$$M_1(\{h_1\}) = 0.9 \times 0.9 = 0.81$$

$$M_1(\{h_2\}) = 0.9 \times 0.1 = 0.09$$

$$M_1(\{h_3\}) = 0.9 \times 0 = 0$$

$$M_1(\{h_1, h_2\}) = 0$$

$$M_1(\{h_1, h_3\}) = 0$$

$$M_1(\{h_2, h_3\}) = 0$$

$$M_1(\{h_1, h_2, h_3\}) = 1 - M_1(\{h_1\}) - M_1(\{h_2\}) - M_1(\{h_3\}) - M_1(\{h_1, h_2\}) - M_1(\{h_1, h_3\}) -$$

$$M_1(\{h_2, h_3\}) = 1 - 0.81 - 0.09 = 0.1$$

根据第二条规则和第二个事实的可信度：

$$CF(E_2) = 0.4$$

$$CF(H_1, E_2) = 0.8$$

$$CF(H_2, E_2) = 0.05$$

$$CF(H_3, E_2) = 0$$

得到基本概率分配函数为

$$M_2(\{h_1\}) = 0.4 \times 0.8 = 0.32$$

$$M_2(\{h_2\}) = 0.4 \times 0.05 = 0.02$$

$$M_2(\{h_3\}) = 0.4 \times 0 = 0$$

$$M_2(\{h_1, h_2\}) = 0$$

$$M_2(\{h_1, h_3\}) = 0$$

$$M_2(\{h_2, h_3\}) = 0$$

$$M_2(\{h_1, h_2, h_3\}) = 1 - M_2(\{h_1\}) - M_2(\{h_2\}) - M_2(\{h_3\}) - M_2(\{h_1, h_2\}) - M_2(\{h_1, h_3\}) -$$

$$M_2(\{h_2, h_3\}) = 1 - 0.32 - 0.02 = 0.66$$

用证据理论将上述两个由不同规则得到的概率分配函数组合,得

$$K = 1 - [M_1(\{h_1\})M_2(\{h_2\}) + M_1(\{h_2\})M_2(\{h_1\})]$$

$$= 1 - (0.81 \times 0.02 + 0.09 \times 0.32)$$

$$= 1 - 0.045 = 0.955$$

$$M(\{h_1\}) = K^{-1} [M_1(\{h_1\})M_2(\{h_1\}) + M_1(\{h_1\})M_2(\{h_1, h_2, h_3\}) \\ + M_1(\{h_1, h_2, h_3\})M_2(\{h_1\})]$$

$$= \frac{1}{0.955} \times 0.8258 = 0.87$$

$$M(\{h_2\}) = K^{-1} [M_1(\{h_2\})M_2(\{h_2\}) + M_1(\{h_2\})M_2(\{h_1, h_2, h_3\}) \\ + M_1(\{h_1, h_2, h_3\})M_2(\{h_2\})]$$

$$= \frac{1}{0.955} \times 0.0632 = 0.066$$

$$M(\{h_1, h_2, h_3\}) = 1 - M(\{h_1\}) - M(\{h_2\}) = 1 - 0.87 - 0.066 = 0.064$$

由信任函数的定义得

$$Bel(\{h_1\}) = M(\{h_1\}) = 0.87$$

$$Bel(\{h_2\}) = M(\{h_2\}) = 0.066$$

由似然函数的定义得

$$Pl(\{h_1\}) = 1 - Bel(\neg \{h_1\}) = 1 - Bel(\{h_2, h_3\})$$

$$= 1 - [M(\{h_2\}) + M(\{h_3\})]$$

$$= 1 - [0.066 + 0] = 0.934$$

$$Pl(\{h_2\}) = 1 - Bel(\neg \{h_2\}) = 1 - Bel(\{h_1, h_3\})$$

$$= 1 - [M(\{h_1\}) + M(\{h_3\})]$$

$$= 1 - (0.87 + 0) = 0.13$$

综合上述结果得,

“感冒但非过敏性鼻炎”为真的信任度为 0.87,非假的信任度为 0.934;

“过敏性鼻炎但非感冒”为真的信任度为 0.066,非假的信任度为 0.13。

因此,患者是感冒了而非过敏性鼻炎。

4.4 模糊推理方法

4.4.1 模糊逻辑的提出与发展

“模糊”是人类感知万物,获取知识,思维推理,决策实施的重要特征。“模糊”比“清晰”所拥有的信息容量更大,内涵更丰富,更符合客观世界。为了用数学方法描述和处理自然界出现的不精确、不完整的信息,如人类语言信息和图像信息,1965 年美国著名学者加利福尼亚大学教授扎德(L. A. Zadeh)发表了关于“fuzzy set”的论文,首先提出了模糊理论。

在刚提出模糊理论的年代,由于科学技术,尤其是计算机技术发展的限制,以及科技界对“模糊”含义的误解,使得模糊理论没有得到应有的发展。在美国、欧洲、中国和日本,只有少数科学家研究模糊理论。在 20 世纪 80 年代之前,虽然理论文章发表了约 5000 篇,但实际应用却寥寥无几。

模糊理论成功的应用首先是在自动控制领域。1974 年,英国伦敦大学教授 Mamdani 首次将模糊理论应用于热电厂的蒸汽机控制,揭开了模糊理论在控制领域应用的新篇章,充分展示了模糊控制技术的应用前景。1976 年,Mamdani 又将模糊理论应用于水泥旋转炉的控制。在所有应用中,模糊控制在欧洲主要用于工业自动化,在美国主要用于军事领域。尽管在此之后的 10 多年内,模糊控制技术应用取得了很好的效果,然而,没有取得根本上的突破。

到 20 世纪 80 年代,随着计算机技术的发展,日本科学家将模糊理论成功地运用于工业控制和消费品控制,在世界范围内掀起了模糊控制应用高潮。1983 年日本 Fuji Electric 公司实现了饮水处理装置的模糊控制。1987 年日本 Hitachi 公司研制出地铁的模糊控制系统。1987—1990 年在日本申报的模糊产品专利就达 319 种,分布在过程控制、汽车电子、图像识别/图像数据处理、测量技术/传感器、机器人、诊断、家用电器控制等领域。

目前,各种模糊产品充满市场,如模糊洗衣机、模糊吸尘器、模糊电冰箱和模糊摄像机等。各国都将模糊技术作为本国重点发展的关键技术。

在日常生活中,人们往往用“较少”“较多”“小一些”“很小”等模糊语言来进行控制。例如,当我们拧开水阀向水桶放水时,有这样的经验:桶里没有水或水较少时,水阀应开大一些;桶里的水比较多时,水阀应开小一些;水桶快满时应把阀门开得很小;水桶里的水满时,应迅速关掉水阀。这里的水阀开“大一些”“小一些”,水桶水“比较多”“快满”“比较少”等都是模糊概念。

模糊控制是以模糊数学为基础,运用语言规则知识表示方法和先进的计算机技术,是由模糊推理进行决策的一种高级控制策略。它无疑属于智能控制范畴,而且已成为人工智能领域中的一个重要分支。

常规控制一般都要求系统有精确的数学模型。但大多数的工业过程的参数呈现极强的时变非线性特性,一般很难建立数学模型,所以对于不确定性系统,采用常规控制很难实现有效控制,而模糊控制可以利用语言信息却不需要精确的数学模型,从而实现对不确定性系统较好的控制。模糊控制技术是由模糊数学、计算机科学、人工智能、知识工程等多门学科相互渗透,且理论性很强的科学技术。

在人工智能领域里,特别是在知识表示方面,模糊逻辑有相当广阔的应用前景。目前在自动控制、模式识别、自然语言理解、机器人及专家系统研制等方面,应用模糊逻辑取得了一定的成果,引起了本领域的越来越多专家学者的关注。

4.4.2 模糊集合

1. 模糊集合的定义

模糊集合(fuzzy sets)是经典集合的扩充。下面首先介绍集合论中的几个名词。

论域:所讨论的全体对象称为论域。一般用 U 、 E 等大写字母表示论域。

元素:论域中的每个对象。一般用 a, b, c, x, y, z 等小写字母表示集合中的元素。

集合:论域中具有某种相同属性的确定的、可以彼此区分的元素的全体,常用 A, B, C, X, Y, Z 等表示集合。如 $A = \{x \mid f(x) > 0\}$ 。

在经典集合中,元素 a 和集合 A 的关系只有两种: a 属于 A 或 a 不属于 A ,即只有两个真值“真”和“假”。

例如,若定义 18 岁以上的人为“成年人”集合,则一位超过 18 岁的人属于“成年人”集合,而另外一位不足 18 岁的人,哪怕只差一天也不属于该集合。

经典集合可用特征函数表示。例如,“成年人”集合可以表示为

$$\mu_{\text{成年人}}(x) = \begin{cases} 1 & x \geq 18 \\ 0 & x < 18 \end{cases}$$

如图 4.1 所示。这是一种对事物的二值描述即二值逻辑。

经典集合只能描述确定性的概念,而不能描述现实世界中模糊的概念。例如,“天气很热”等概念。模糊逻辑模仿人类的智慧,引入隶属度(degree of membership)的概念,描述介于“真”与“假”中间的过程。

模糊集合中每一个元素被赋予一个介于 0 和 1 之间的实数,描述其元素属于这个模糊集合的强度,该实数称为元素属于这个模糊集合的隶属函数。如上述例子中,一个人变成“成年人”的过程可用一连续曲线表示,如图 4.2 所示。

模糊集合是经典集合的推广;而经典集合是模糊集合中隶属函数取 0 或 1 时的特例。




图 4.1 “成年人”特征函数




图 4.2 “成年人”隶属函数

2. 模糊集合的表示方法

与经典集合表示不同的是,模糊集合中不仅要列出属于这个集合的元素,而且要注明这个元素属于这个集合的隶属度。

当论域中元素数目有限时,模糊集合 A 的数学描述为

$$A = \{(x, \mu_A(x)), x \in X\} \quad (4.8)$$

其中, $\mu_A(x)$ 为元素 x 属于模糊集 A 的隶属度, X 是元素 x 的论域。

(1) Zadeh 表示法

① 当论域是离散且元素数目有限时,常采用模糊集合的 Zadeh 表示法

$$A = \mu_A(x_1)/x_1 + \mu_A(x_2)/x_2 + \cdots + \mu_A(x_n)/x_n = \sum_{i=1}^n \mu_A(x_i)/x_i \quad (4.9)$$

其中, x_i 表示模糊集合所对应的论域中的元素; $\mu_A(x_i)$ 表示相应的隶属度; “/” 只是一个分隔符号,并不表示分数。符号 “+” 或者 “ Σ ” 也不表示求和,而是表示模糊集合在论域上的整体。

上式也可以等价地表示为

$$A = \{\mu_A(x_1)/x_1, \mu_A(x_2)/x_2, \cdots, \mu_A(x_n)/x_n\} \quad (4.10)$$

② 当论域是连续的,或者其中元素数目无限时,Zadeh 将模糊集 A 表示为

$$A = \int_{x \in U} \mu_A(x)/x \quad (4.11)$$

这里的 “ $\int$ ” 不是数学中的积分符号,只是表示论域中各元素与其隶属度对应关系的总括,是一个记号。

(2) 序偶表示法

$$A = \{(\mu_A(x_1), x_1), (\mu_A(x_2), x_2), \cdots, (\mu_A(x_n), x_n)\} \quad (4.12)$$

(3) 向量表示法

$$A = [\mu_A(x_1), \mu_A(x_2), \cdots, \mu_A(x_n)] \quad (4.13)$$

在向量表示法中,因为默认模糊集合中的元素依次是 $x_1, x_2, \cdots, x_n$, 所以,隶属度为 0 的项不能省略。

3. 隶属函数

模糊集中所有元素的隶属度整体构成模糊集的隶属函数。

正确地确定隶属函数 (membership function) 是运用模糊集合理论解决实际问题的基础。隶属函数是对模糊概念的定量描述。我们遇到的模糊概念不胜枚举,然而准确地反映模糊集的隶属函数,却无法找到统一的模式。

隶属函数的确定过程,本质上说应该是客观的,但每个人对于同一个模糊概念的认识理解又有差异。因此,隶属函数的确定又带有主观性。实际上,引进隶属度后,将人们对事物认识的模糊性转化为隶属度确定的主观性。隶属函数一般根据经验或统计进行确定,也可由专家给出。对于同一个模糊概念,不同的人会建立不完全相同的隶属函数,尽管形式不完全相同,只要能反映同一模糊概念,仍然能够较好地解决和处理实际模糊信息的问题。

例如,以年龄作论域,取 $U=[0,200]$,扎德给出的“年老” O 与“年青” Y 两个模糊集的隶属函数为

$$\mu_O(u) = \begin{cases} 0 & 0 \leq u \leq 50 \\ \left[1 + \left(\frac{5}{u-50} \right)^2 \right]^{-1} & 50 < u \leq 200 \end{cases}$$

$$\mu_Y(u) = \begin{cases} 1 & 0 \leq u \leq 25 \\ \left[1 + \left(\frac{u-25}{5} \right)^2 \right]^{-1} & 25 < u \leq 200 \end{cases}$$

采用 Zadeh 表示法,“年老” O 与“年青” Y 两个模糊集可以表示为

$$O = \int_{50 < u \leq 200} \left[1 + \left(\frac{5}{u-50} \right)^2 \right]^{-1} / u$$

$$Y = \int_{0 \leq u \leq 25} 1/u + \int_{25 < u \leq 200} \left[1 + \left(\frac{u-25}{5} \right)^2 \right]^{-1} / u$$

常见模糊隶属函数有:正态分布、三角分布、梯形分布等。

4.4.3 模糊集的运算

模糊集是经典集的推广,所以,经典集的运算可以推广到模糊集。但由于模糊集要由它的隶属函数加以确定,所以,需要重新定义模糊集的基本运算。

(1) 模糊集的包含关系

若 $\mu_A(x) \geq \mu_B(x)$, 则称 A 包含 B , 记作 $A \supseteq B$ 。

(2) 模糊集的相等关系

若 $\mu_A(x) = \mu_B(x)$, 则称 A 与 B 相等, 记作 $A = B$ 。

(3) 模糊集之交并补运算

设 A, B 是论域 U 中的两个模糊集。

① 交运算 (intersection) $A \cap B$:

$$\mu_{A \cap B}(x) = \min\{\mu_A(x), \mu_B(x)\} = \mu_A(x) \wedge \mu_B(x) \quad (4.14)$$

② 并运算(union) $A \cup B$:

$$\mu_{A \cup B}(x) = \max\{\mu_A(x), \mu_B(x)\} = \mu_A(x) \vee \mu_B(x) \quad (4.15)$$

③ 补运算(complement) $\bar{A}$ 或者 A^c :

$$\mu_{\bar{A}}(x) = 1 - \mu_A(x) \quad (4.16)$$

其中, $\wedge$ 表示取小运算; $\vee$ 表示取大运算。

例 4.4 设论域 $U = \{x_1, x_2, x_3, x_4\}$, A 及 B 是论域 U 上的两个模糊集合, 已知

$$A = 0.3/x_1 + 0.5/x_2 + 0.7/x_3 + 0.4/x_4$$

$$B = 0.5/x_1 + 1/x_2 + 0.8/x_3$$

求 $\bar{A}$ 、 $\bar{B}$ 、 $A \cap B$ 、 $A \cup B$ 。

解

$$\bar{A} = 0.7/x_1 + 0.5/x_2 + 0.3/x_3 + 0.6/x_4$$

$$\bar{B} = 0.5/x_1 + 0.2/x_3 + 1/x_4$$

$$\begin{aligned} A \cap B &= \frac{0.3 \wedge 0.5}{x_1} + \frac{0.5 \wedge 1}{x_2} + \frac{0.7 \wedge 0.8}{x_3} + \frac{0.4 \wedge 0}{x_4} \\ &= 0.3/x_1 + 0.5/x_2 + 0.7/x_3 \end{aligned}$$

$$\begin{aligned} A \cup B &= \frac{0.3 \vee 0.5}{x_1} + \frac{0.5 \vee 1}{x_2} + \frac{0.7 \vee 0.8}{x_3} + \frac{0.4 \vee 0}{x_4} \\ &= 0.5/x_1 + 1/x_2 + 0.8/x_3 + 0.4/x_4 \end{aligned}$$

(4) 模糊集合的代数运算

设 A 、 B 是论域 U 中的两个模糊集。

① 代数积:

$$\mu_{A \cdot B}(x) = \mu_A(x) \mu_B(x)$$

② 代数和:

$$\mu_{A+B}(x) = \mu_A(x) + \mu_B(x) - \mu_{A \cdot B}(x)$$

③ 有界和:

$$\mu_{A \oplus B}(x) = \min\{1, \mu_A(x) + \mu_B(x)\} = 1 \wedge [\mu_A(x) + \mu_B(x)]$$

④ 有界积:

$$\mu_{A \otimes B}(x) = \max\{0, \mu_A(x) + \mu_B(x) - 1\} = 0 \vee [\mu_A(x) + \mu_B(x) - 1]$$

例 4.5 设论域 $U = \{x_1, x_2, x_3, x_4, x_5\}$, A 及 B 是论域上的两个模糊集合, 已知

$$A = 0.2/x_1 + 0.4/x_2 + 0.9/x_3 + 0.5/x_5$$

$$B = 0.1/x_1 + 0.7/x_3 + 1.0/x_4 + 0.3/x_5$$

求 $A \cdot B$ 、 $A+B$ 、 $A \oplus B$ 、 $A \otimes B$ 。

解

$$A \cdot B = 0.02/x_1 + 0.63/x_3 + 0.15/x_5$$

$$A + B = 0.28/x_1 + 0.4/x_2 + 0.97/x_3 + 1.0/x_4 + 0.65/x_5$$

$$A \oplus B = 0.3/x_1 + 0.4/x_2 + 1.0/x_3 + 1.0/x_4 + 0.8/x_5$$

$$A \otimes B = 0.6/x_3$$

4.4.4 模糊关系与模糊关系的合成

1. 模糊关系

在模糊集合论中,模糊关系占有重要地位。模糊关系是普通关系的推广。普通关系是描述两个集合中的元素之间是否有关联。模糊关系描述两个模糊集合中的元素之间的关联程度。当论域为有限时,可以采用模糊矩阵表示模糊关系。

例 4.6 某地区人的身高论域 $X = \{140, 150, 160, 170, 180\}$ (单位:cm), 体重论域 $Y = \{40, 50, 60, 70, 80\}$ (单位:kg)。身高与体重两个集合的元素之间没有确定的关系,只有一定程度的关联。它们的关联程度如表 4.1 所示。

表 4.1 身高与体重的模糊关系

R Y X	40	50	60	70	80
140	1	0.8	0.2	0.1	0
150	0.8	1	0.8	0.2	0.1
160	0.2	0.8	1	0.8	0.2
170	0.1	0.2	0.8	1	0.8
180	0	0.1	0.2	0.8	1

它是从 X 到 Y 的一个模糊关系 R , 可用模糊矩阵表示为

$$R = \begin{bmatrix} 1 & 0.8 & 0.2 & 0.1 & 0 \\ 0.8 & 1 & 0.8 & 0.2 & 0.1 \\ 0.2 & 0.8 & 1 & 0.8 & 0.2 \\ 0.1 & 0.2 & 0.8 & 1 & 0.8 \\ 0 & 0.1 & 0.2 & 0.8 & 1 \end{bmatrix}$$

下面给出模糊关系的定义。

设 A, B 为两个模糊集合, 在模糊数学中, 模糊关系可用叉积 (cartesian product) 表示。在模糊逻辑中, 这种叉积常用最小算子运算, 即

$$\mu_{A \times B}(a, b) = \min \{ \mu_A(a), \mu_B(b) \} \quad (4.17)$$

若 A, B 为离散模糊集, 其隶属函数分别为

$$\mu_A = [\mu_A(a_1), \mu_A(a_2), \dots, \mu_A(a_n)]$$

$$\mu_B = [\mu_B(b_1), \mu_B(b_2), \dots, \mu_B(b_n)]$$

则其叉积运算为

$$\mu_{A \times B}(a, b) = \mu_A^T \circ \mu_B \quad (4.18)$$

其中“ $\circ$ ”为模糊向量乘积。

上述定义的模糊关系,又称为二元模糊关系。通常所谓的模糊关系 R ,一般是指二元模糊关系。下面举例说明模糊关系的具体求取方法。

例 4.7 已知输入的模糊集合 A 和输出的模糊集合 B 分别为

$$A = 1.0/a_1 + 0.8/a_2 + 0.5/a_3 + 0.2/a_4 + 0.0/a_5$$

$$B = 0.7/b_1 + 1.0/b_2 + 0.6/b_3 + 0.0/b_4$$

求 A 到 B 的模糊关系 R 。

解

$$\begin{aligned} R = A \times B = \mu_A^T \circ \mu_B &= \begin{bmatrix} 1.0 \\ 0.8 \\ 0.5 \\ 0.2 \\ 0.0 \end{bmatrix} \circ [0.7 \quad 1.0 \quad 0.6 \quad 0.0] \\ &= \begin{bmatrix} 1.0 \wedge 0.7 & 1.0 \wedge 1.0 & 1.0 \wedge 0.6 & 1.0 \wedge 0.0 \\ 0.8 \wedge 0.7 & 0.8 \wedge 1.0 & 0.8 \wedge 0.6 & 0.8 \wedge 0.0 \\ 0.5 \wedge 0.7 & 0.5 \wedge 1.0 & 0.5 \wedge 0.6 & 0.5 \wedge 0.0 \\ 0.2 \wedge 0.7 & 0.2 \wedge 1.0 & 0.2 \wedge 0.6 & 0.2 \wedge 0.0 \\ 0.0 \wedge 0.7 & 0.0 \wedge 1.0 & 0.0 \wedge 0.6 & 0.0 \wedge 0.0 \end{bmatrix} \\ &= \begin{bmatrix} 0.7 & 1.0 & 0.6 & 0.0 \\ 0.7 & 0.8 & 0.6 & 0.0 \\ 0.5 & 0.5 & 0.5 & 0.0 \\ 0.2 & 0.2 & 0.2 & 0.0 \\ 0.0 & 0.0 & 0.0 & 0.0 \end{bmatrix} \end{aligned}$$

可以看出,两个模糊向量的叉积,类似于两个向量的乘积,只是其中的乘积运算用取小 $\wedge$ 运算代替。

2. 模糊关系的合成

设模糊关系 $Q \in X \times Y, R \in Y \times Z$, 则模糊关系 $S \in X \times Z$ 称为模糊关系 Q 与 R 的合成。模糊关系 Q 与模糊关系 R 的合成 S 是模糊矩阵的叉乘 $S = Q \circ R$ 。

模糊矩阵的合成可以由多种计算方法得到,如下列常用的几种计算方法。

① 最大-最小合成法:写出矩阵乘积 QR 中的每个元素,然后将其中的乘积运算用取小 $\wedge$ 运算代替,求和运算用取大 $\vee$ 运算代替。

② 最大-代数积合成法:写出矩阵乘积 QR 中的每个元素,然后将其中的求和运算用取大

$\vee$ 运算代替,而乘积运算不变。

例 4.8 设模糊集合 X, Y, Z 分别为 $X = \{x_1, x_2, x_3, x_4\}, Y = \{y_1, y_2, y_3\}, Z = \{z_1, z_2\}$, 记 $Q \in X \times Y, R \in Y \times Z, S \in X \times Z$, 已知

$$Q = \begin{bmatrix} 0.5 & 0.6 & 0.3 \\ 0.7 & 0.4 & 1 \\ 0 & 0.8 & 0 \\ 1 & 0.2 & 0.9 \end{bmatrix} \quad R = \begin{bmatrix} 0.2 & 1 \\ 0.8 & 0.4 \\ 0.5 & 0.3 \end{bmatrix}$$

求模糊关系 Q 与模糊关系 R 的合成 S 。

解 (1) 最大-最小合成法

$$\begin{aligned} S = Q \circ R &= \begin{bmatrix} 0.5 & 0.6 & 0.3 \\ 0.7 & 0.4 & 1 \\ 0 & 0.8 & 0 \\ 1 & 0.2 & 0.9 \end{bmatrix} \circ \begin{bmatrix} 0.2 & 1 \\ 0.8 & 0.4 \\ 0.5 & 0.3 \end{bmatrix} \\ &= \begin{bmatrix} (0.5 \wedge 0.2) \vee (0.6 \wedge 0.8) \vee (0.3 \wedge 0.5) & (0.5 \wedge 1) \vee (0.6 \wedge 0.4) \vee (0.3 \wedge 0.3) \\ (0.7 \wedge 0.2) \vee (0.4 \wedge 0.8) \vee (1 \wedge 0.5) & (0.7 \wedge 1) \vee (0.4 \wedge 0.4) \vee (1 \wedge 0.3) \\ (0 \wedge 0.2) \vee (0.8 \wedge 0.8) \vee (0 \wedge 0.5) & (0 \wedge 1) \vee (0.8 \wedge 0.4) \vee (0 \wedge 0.3) \\ (1 \wedge 0.2) \vee (0.2 \wedge 0.8) \vee (0.9 \wedge 0.5) & (1 \wedge 1) \vee (0.2 \wedge 0.4) \vee (0.9 \wedge 0.3) \end{bmatrix} \\ &= \begin{bmatrix} 0.6 & 0.5 \\ 0.5 & 0.7 \\ 0.8 & 0.4 \\ 0.5 & 1 \end{bmatrix} \end{aligned}$$

(2) 最大-代数积合成法

$$\begin{aligned} S = Q \circ R &= \begin{bmatrix} 0.5 & 0.6 & 0.3 \\ 0.7 & 0.4 & 1 \\ 0 & 0.8 & 0 \\ 1 & 0.2 & 0.9 \end{bmatrix} \circ \begin{bmatrix} 0.2 & 1 \\ 0.8 & 0.4 \\ 0.5 & 0.3 \end{bmatrix} \\ &= \begin{bmatrix} (0.5 \times 0.2) \vee (0.6 \times 0.8) \vee (0.3 \times 0.5) & (0.5 \times 1) \vee (0.6 \times 0.4) \vee (0.3 \times 0.3) \\ (0.7 \times 0.2) \vee (0.4 \times 0.8) \vee (1 \times 0.5) & (0.7 \times 1) \vee (0.4 \times 0.4) \vee (1 \times 0.3) \\ (0 \times 0.2) \vee (0.8 \times 0.8) \vee (0 \times 0.5) & (0 \times 1) \vee (0.8 \times 0.4) \vee (0 \times 0.3) \\ (1 \times 0.2) \vee (0.2 \times 0.8) \vee (0.9 \times 0.5) & (1 \times 1) \vee (0.2 \times 0.4) \vee (0.9 \times 0.3) \end{bmatrix} \\ &= \begin{bmatrix} 0.48 & 0.5 \\ 0.5 & 0.7 \\ 0.64 & 0.32 \\ 0.45 & 1 \end{bmatrix} \end{aligned}$$

4.4.5 模糊推理

1. 模糊知识表示

对于模糊不确定性,一般采用隶属度来刻画。隶属度是一个命题中所描述的事物的属性、状态和关系等的强度。例如,用三元组(张三,体型,(胖,0.9))表示命题“张三比较胖”,其中的0.9就代替“比较”而刻画了张三“胖”的程度。

这种隶属度表示法,一般是一种针对对象的表示法。模糊知识表示一般形式为
($\langle$ 对象 $\rangle$, $\langle$ 属性 $\rangle$,($\langle$ 属性值 $\rangle$, $\langle$ 隶属度 $\rangle$))

可以看出,它实际是通常三元组($\langle$ 对象 $\rangle$, $\langle$ 属性 $\rangle$, $\langle$ 属性值 $\rangle$)的细化,其中的 $\langle$ 隶属度 $\rangle$ 一项是对前面属性值的精确刻画。

事实上,这种思想和方法还可广泛用于产生式规则、谓词逻辑、框架、语义网络等多种知识表示方法中,从而扩充它们的表示范围和能力。下面举例说明。

人类思维判断的基本形式是

如果 (条件) $\rightarrow$ 则 (结论)

其中的条件和结论常常是模糊的。

例如,对下列模糊知识

如果 压力较高且温度在缓慢上升 则 阀门略开

可以用模糊集合表示这个知识中压力、温度和阀门值的不确定性。

(锅炉,工况,(压力,0.80)) $\wedge$ (锅炉,工况,(温度,0.3)) $\rightarrow$ (阀门,状态,(开,0.2))

例如,模糊规则

如果 患者有些头疼并且发高烧 则 他患了重感冒

可表示为

(患者,症状,(头疼,0.3)) $\wedge$ (患者,症状,(发烧,0.9)) $\rightarrow$ (患者,疾病,(感冒,0.9))

许多模糊规则实际上是一组多重条件语句,可以表示为从条件论域到结论论域的模糊关系矩阵 R 。通过条件模糊向量与模糊关系 R 的合成进行模糊推理,得到结论的模糊向量,然后采用“清晰化”方法将模糊结论转换为精确量。

根据模糊集合和模糊关系理论,对于不同类型的模糊规则可用不同的模糊推理方法。

2. 对 IF A THEN B 类型的模糊规则的推理

若已知输入为 A ,则输出为 B ;若现在已知输入为 A' ,则输出 B' 用合成规则求取

$$B' = A' \circ R \quad (4.19)$$

其中 R 为 A 到 B 的模糊关系。

例 4.9 对于例 4.7 所示模糊系统,求当输入为

$$A' = 0.4/a_1 + 0.7/a_2 + 1.0/a_3 + 0.6/a_4 + 0.0/a_5$$

时,系统的输出 B' 。

解 在例 4.7 中已经得到模糊关系,下面进行模糊合成得到模糊输出。

$$\begin{aligned}
B' = A' \circ R &= \begin{bmatrix} 0.4 \\ 0.7 \\ 1.0 \\ 0.6 \\ 0.0 \end{bmatrix}^T \circ \begin{bmatrix} 0.7 & 1.0 & 0.6 & 0.0 \\ 0.7 & 0.8 & 0.6 & 0.0 \\ 0.5 & 0.5 & 0.5 & 0.0 \\ 0.2 & 0.2 & 0.2 & 0.0 \\ 0.0 & 0.0 & 0.0 & 0.0 \end{bmatrix} \\
&= [(0.4 \wedge 0.7) \vee (0.7 \wedge 0.7) \vee (1.0 \wedge 0.5) \vee (0.6 \wedge 0.2) \vee (0.0 \wedge 0.0), \\
&\quad (0.4 \wedge 1.0) \vee (0.7 \wedge 0.8) \vee (1.0 \wedge 0.5) \vee (0.6 \wedge 0.2) \vee (0.0 \wedge 0.0), \\
&\quad (0.4 \wedge 0.6) \vee (0.7 \wedge 0.6) \vee (1.0 \wedge 0.5) \vee (0.6 \wedge 0.2) \vee (0.0 \wedge 0.0), \\
&\quad (0.4 \wedge 0.0) \vee (0.7 \wedge 0.0) \vee (1.0 \wedge 0.0) \vee (0.6 \wedge 0.0) \vee (0.0 \wedge 0.0)] \\
&= [(0.4 \vee 0.7 \vee 0.5 \vee 0.2 \vee 0.0), (0.4 \vee 0.7 \vee 0.5 \vee 0.2 \vee 0.0), \\
&\quad (0.4 \vee 0.6 \vee 0.5 \vee 0.2 \vee 0.0), (0.0 \vee 0.0 \vee 0.0 \vee 0.0 \vee 0.0)] \\
&= (0.7, 0.7, 0.6, 0.0)
\end{aligned}$$

则

$$B' = 0.7/b_1 + 0.7/b_2 + 0.6/b_3 + 0.0/b_4$$

系统的控制规则库一般是由若干条规则组成的,对于每一条推理规则都可以得到一个相应的模糊关系, n 条规则就有 n 个模糊关系: $R_1, R_2, \dots, R_n$,对于整个系统的全部控制规则所对应的模糊关系 R ,可通过对 n 个模糊关系 $R_i (i=1, 2, \dots, n)$ 取“并”操作得到,即

$$R = R_1 \cup R_2 \cup \dots \cup R_n = \bigcup_{i=1}^n R_i \quad (4.20)$$

4.4.6 模糊决策

由上述模糊推理得到的结论或者操作是一个模糊向量,不能直接应用,需要先转化为确定值。将模糊推理得到的模糊向量,转化为确定值的过程称为“模糊决策”,或者“模糊判决”“清晰化”“反模糊化”(defuzzification)等。下面介绍3种简单、实用的模糊决策方法。

1. 最大隶属度法

最大隶属度法是在模糊向量中,取隶属度最大的量作为推理结果。

例如,当得到模糊向量为

$$U' = 0.1/2 + 0.4/3 + 0.7/4 + 1.0/5 + 0.7/6 + 0.3/7$$

由于推理结果隶属于等级5的隶属度为最大,所以取结论为

$$U = 5$$

如果有两个以上的元素均为最大(一般依次相邻),则可以取它们的平均值。例如

$$U' = 0.5/-3 + 0.5/-2 + 0.5/-1 + 0.0/0 + 0.0/1 + 0.0/2 + 0.0/3$$

则

$$U = \frac{-3 - 2 - 1}{3} = -2$$

如果 U 不是整数,可以取整处理。实际上,由于推理本身就是模糊的,所以可以取较高的等级,也可以取较低的等级,对模糊系统性能影响不大。

最大隶属度法的优点是简单易行,缺点是完全排除了其他隶属度较小的量的影响和作用,没有充分利用推理过程取得的信息。

2. 加权平均判决法

为了克服最大隶属度法的缺点,可以采用加权平均判决法,即

$$U = \frac{\sum_{i=1}^n \mu(u_i) u_i}{\sum_{i=1}^n \mu(u_i)} \quad (4.21)$$

例如

$$U' = 0.1/2 + 0.6/3 + 0.5/4 + 0.4/5 + 0.2/6$$

则

$$U = \frac{2 \times 0.1 + 3 \times 0.6 + 4 \times 0.5 + 5 \times 0.4 + 6 \times 0.2}{0.1 + 0.6 + 0.5 + 0.4 + 0.2} = 4$$

3. 中位数法

论域上把隶属函数曲线与横坐标围成的面积平分为两部分的元素称为模糊集的中位数。

中位数法就是把模糊集的中位数作为系统控制量。

当论域为有限离散点时,中位数 u^* 可以用下列公式求取

$$\sum_{u_1}^{u^*} \mu(u_i) = \sum_{u^*+1}^{u_n} \mu(u_j) \quad (4.22)$$

例如, $U' = 0.1/-4 + 0.5/-3 + 0.1/-2 + 0.0/-1 + 0.1/0 + 0.2/1 + 0.4/2 + 0.5/3 + 0.1/4$, 由于 $u_1 = -4, u_9 = 4$, 则当 $u^* = u_6$ 时, $\sum_{u_1}^{u_6} \mu(u_i) = \sum_{u_7}^{u_9} \mu(u_i) = 1$, 所以中位数为 $u^* = u_6 = 1$, 则 $U = 1$ 。

如果该点在有限元素之间,例如, $U' = 0.1/-4 + 0.5/-3 + 0.3/-2 + 0.1/-1 + 0.1/0 + 0.4/1 + 0.5/2 + 0.1/3 + 0.2/4$, $\sum_{u_1}^{u_5} \mu(u_i) = 1.1, \sum_{u_6}^{u_9} \mu(u_i) = 1.2$, 显然, u^* 在 0 和 1 之间,可以简单地取 $u^* = 0$ 或者 $u^* = 1$ 。

与最大隶属度法相比,这种方法利用了更多的信息,但计算比较复杂,特别是在连续隶属度函数时,需要求解积分方程,因此应用场合要比加权平均法少。

加权平均法比中位数法具有更佳的性能,而中位数法的动态性能要优于加权平均法,静态性能则略逊于加权平均法。使用中位数法的模糊控制器类似于多级继电器控制,加权平均法则类似于 PI 控制器。一般情况下,都优于最大隶属度法。

4.4.7 模糊推理的应用

例 4.10 设有模糊控制规则：“如果温度低,则将风门开大”。设温度和风门开度的论域为 $\{1,2,3,4,5\}$ 。“温度低”和“风门大”的模糊量可以表示为

$$\text{“温度低”} = 1.0/1 + 0.6/2 + 0.3/3 + 0.0/4 + 0.0/5$$

$$\text{“风门大”} = 0.0/1 + 0.0/2 + 0.3/3 + 0.6/4 + 1.0/5$$

已知事实“温度较低”,可以表示为

$$\text{“温度较低”} = 0.8/1 + 1.0/2 + 0.6/3 + 0.3/4 + 0.0/5$$

试用模糊推理确定风门开度。

解 (1) 确定模糊关系 R

$$\begin{aligned} R &= \begin{bmatrix} 1.0 \\ 0.6 \\ 0.3 \\ 0.0 \\ 0.0 \end{bmatrix} \circ [0.0 \quad 0.0 \quad 0.3 \quad 0.6 \quad 1.0] \\ &= \begin{bmatrix} 1.0 \wedge 0.0 & 1.0 \wedge 0.0 & 1.0 \wedge 0.3 & 1.0 \wedge 0.6 & 1.0 \wedge 1.0 \\ 0.6 \wedge 0.0 & 0.6 \wedge 0.0 & 0.6 \wedge 0.3 & 0.6 \wedge 0.6 & 0.6 \wedge 1.0 \\ 0.3 \wedge 0.0 & 0.3 \wedge 0.0 & 0.3 \wedge 0.3 & 0.3 \wedge 0.6 & 0.3 \wedge 1.0 \\ 0.0 \wedge 0.0 & 0.0 \wedge 0.0 & 0.0 \wedge 0.3 & 0.0 \wedge 0.6 & 0.0 \wedge 1.0 \\ 0.0 \wedge 0.0 & 0.0 \wedge 0.0 & 0.0 \wedge 0.3 & 0.0 \wedge 0.6 & 0.0 \wedge 1.0 \end{bmatrix} \\ &= \begin{bmatrix} 0.0 & 0.0 & 0.3 & 0.6 & 1.0 \\ 0.0 & 0.0 & 0.3 & 0.6 & 0.6 \\ 0.0 & 0.0 & 0.3 & 0.3 & 0.3 \\ 0.0 & 0.0 & 0.0 & 0.0 & 0.0 \\ 0.0 & 0.0 & 0.0 & 0.0 & 0.0 \end{bmatrix} \end{aligned}$$

(2) 模糊推理

$$\begin{aligned} B' = A' \circ R &= \begin{bmatrix} 0.8 \\ 1.0 \\ 0.6 \\ 0.3 \\ 0.0 \end{bmatrix}^T \circ \begin{bmatrix} 0.0 & 0.0 & 0.3 & 0.6 & 1.0 \\ 0.0 & 0.0 & 0.3 & 0.6 & 0.6 \\ 0.0 & 0.0 & 0.3 & 0.3 & 0.3 \\ 0.0 & 0.0 & 0.0 & 0.0 & 0.0 \\ 0.0 & 0.0 & 0.0 & 0.0 & 0.0 \end{bmatrix} \\ &= [0.0 \quad 0.0 \quad 0.3 \quad 0.6 \quad 0.8] \end{aligned}$$

(3) 模糊决策

用最大隶属度法进行决策得风门开度为 5。用加权平均判决法和中位数法进行决策得风门开度为 4。

4.5 小 结

1. 不确定性推理中的基本问题

- (1) 知识与证据不确定性的表示与度量
- (2) 不确定性匹配算法及阈值
- (3) 组合证据不确定性的算法
- (4) 不确定性的传递算法
- (5) 结论不确定性的合成

2. 可信度方法

可信度因子 $CF(H, E)$ 在 $[-1, 1]$ 上取值, 反映了前提条件与结论的联系强度。若由于相应证据的出现增加结论 H 为真的可信度, 则取 $CF(H, E) > 0$, 证据的出现越是支持 H 为真, 就使 $CF(H, E)$ 的值越大; 反之, 取 $CF(H, E) < 0$, 证据的出现越是支持 H 为假, 就使 $CF(H, E)$ 的值越小; 若证据的出现与否与 H 无关, 则取 $CF(H, E) = 0$ 。

证据 E 的可信度 $CF(E)$ 也是在 $[-1, 1]$ 上取值的。对于初始证据, 若对它的所有观察 S 能肯定它为真, 取 $CF(E) = 1$; 若肯定它为假, 取 $CF(E) = -1$; 若它以某种程度为真, 取 $CF(E)$ 为 $(0, 1)$ 中的某一个值; 若它以某种程度为假, 取 $CF(E)$ 为 $(-1, 0)$ 中的某一个值; 若它还未获得任何相关的观察, 此时可看作观察 S 与它无关, 取 $CF(E) = 0$ 。

3. D-S 证据理论

D-S 证据理论引入概率分配函数、信任函数, 而非采用概率来度量不确定性; 引用似然函数来处理由不知道而引起的不确定性; 用概率分配函数的正交和来进行证据组合。

4. 模糊推理

在模糊逻辑中, 给集合中每一个元素赋予一个介于 0 和 1 之间的实数, 描述其属于一个集合的程度, 该实数称为元素属于一个集合的隶属度。集合中所有元素的隶属度全体构成集合的隶属函数。

模糊关系描述两个模糊集合中的元素之间的关联程度。当论域为有限时, 模糊关系的合成可用模糊矩阵的合成表示。模糊矩阵的合成可以由多种计算方法得到。常用的几种计算方法: 最大-最小合成法、最大-代数积合成法。

通过条件模糊向量与模糊关系 R 的合成进行模糊推理, 得到结论的模糊向量, 然后采用模糊决策将模糊结论转换为精确量。

模糊决策方法有最大隶属度法、加权平均判决法、中位数法等。

思 考 题

4.1 什么是不确定性推理? 有哪几类不确定性推理方法? 不确定性推理中需要解决的基本问题有

哪些?

- 4.2 什么是可信度? 由可信度因子 $CF(H, E)$ 的定义说明它的含义。
- 4.3 简述求取问题结论可信度的步骤。
- 4.4 说明概率分配函数、信任函数、似然函数的含义。
- 4.5 概率分配函数与概率相同吗? 为什么?
- 4.6 如何用 D-S 证据理论描述假设、规则和证据的不确定性, 并实现不确定性的推理和组合?
- 4.7 什么是模糊性? 它与随机性有什么区别? 试举出几个日常生活中的模糊概念。
- 4.8 模糊推理的一般过程是什么?

习 题

4.1 设有如下一组推理规则

- $$\begin{aligned} r_1: & \text{ IF } E_1 \quad \text{ THEN } E_2 \quad (0.6) \\ r_2: & \text{ IF } E_2 \quad \text{ AND } E_3 \quad \text{ THEN } E_4 \quad (0.8) \\ r_3: & \text{ IF } E_4 \quad \text{ THEN } H \quad (0.7) \\ r_4: & \text{ IF } E_5 \quad \text{ THEN } H \quad (0.9) \end{aligned}$$

且已知 $CF(E_1) = 0.5$, $CF(E_3) = 0.6$, $CF(E_5) = 0.4$, 结论 H 的初始可信度一无所知。求 $CF(H)$ 为多少?

4.2 已知: 规则可信度为

- $$\begin{aligned} r_1: & \text{ IF } E_1 \quad \text{ THEN } H_1 \quad (0.7) \\ r_2: & \text{ IF } E_2 \quad \text{ THEN } H_1 \quad (0.6) \\ r_3: & \text{ IF } E_3 \quad \text{ THEN } H_1 \quad (0.4) \\ r_4: & \text{ IF } (H_1 \text{ AND } E_4) \quad \text{ THEN } H_2 \quad (0.2) \end{aligned}$$

证据可信度为: $CF(E_1) = CF(E_2) = CF(E_3) = CF(E_4) = 0.5$, H_1 的初始可信度一无所知, H_2 的初始可信度 $CF_0(H_2) = 0.3$, 计算结论 H_2 的可信度 $CF(H_2)$ 。

4.3 设有如下规则

- $$\begin{aligned} r_1: & \text{ IF } E_1 \quad \text{ THEN } H_1 \quad (0.8) \\ r_2: & \text{ IF } E_2 \quad \text{ THEN } H_1 \quad (0.9) \\ r_3: & \text{ IF } E_3 \quad \text{ AND } E_4 \quad \text{ THEN } E_1 \quad (0.9) \\ r_4: & \text{ IF } E_5 \quad \text{ THEN } E_2 \quad (0.7) \\ r_5: & \text{ IF } E_6 \quad \text{ OR } E_7 \quad \text{ THEN } E_2 \quad (-0.3) \end{aligned}$$

并已知初始证据的可信度为 $CF(E_3) = 0.8$, $CF(E_4) = 0.9$, $CF(E_5) = 0.8$, $CF(E_6) = 0.1$, $CF(E_7) = 0.5$, 试画出推理网络, 并用可信度法计算 $CF(H_1)$ 。

4.4 设样本空间 $D = \{a, b, c, d\}$, M_1, M_2 为定义在 2^D 上的概率分布函数:

$M_1: M_1(\{b, c, d\}) = 0.7, M_1(\{a, b, c, d\}) = 0.3, M_1$ 的其余基本概率数均为 0;

$M_2: M_2(\{a, b\}) = 0.6, M_2(\{a, b, c, d\}) = 0.4, M_2$ 的其余基本概率数均为 0。

求它们的正交和 $M = M_1 \oplus M_2$ 。

4.5 设有论域 $U = \{x_1, x_2, x_3, x_4, x_5\}$, A, B 是 U 上的两个模糊集, 且有

$$A = 0.85/x_1 + 0.7/x_2 + 0.9/x_3 + 0.9/x_4 + 0.7/x_5$$

$$B = 0.5/x_1 + 0.65/x_2 + 0.8/x_3 + 0.98/x_4 + 0.77/x_5$$

求 $A \cap B$, $A \cup B$ 和 $\bar{A}$ 。

4.6 设有如下两个模糊关系

$$A = \begin{bmatrix} 0.7 & 0.6 & 0.3 \\ 0.7 & 0.6 & 0.2 \\ 0.5 & 0.5 & 0.2 \end{bmatrix} \quad B = \begin{bmatrix} 0.8 & 0.4 \\ 0.6 & 0.2 \\ 0.9 & 0.4 \end{bmatrix}$$

求 $A \circ B$ 。

4.7 设有如下两个模糊关系

$$R_1 = \begin{bmatrix} 0.2 & 0.8 & 0.4 \\ 0.4 & 0 & 1.0 \\ 1.0 & 0.5 & 0 \\ 0.7 & 0.6 & 0.5 \end{bmatrix} \quad R_2 = \begin{bmatrix} 0.7 & 0.3 \\ 0.4 & 0.8 \\ 0.2 & 0.9 \end{bmatrix}$$

求两个模糊关系的合成 $R_1 \circ R_2$ 。

4.8 设有如下三个模糊关系

$$R_1 = \begin{bmatrix} 1.0 & 0.0 & 0.7 \\ 0.3 & 0.2 & 0.0 \\ 0.0 & 0.5 & 1.0 \end{bmatrix} \quad R_2 = \begin{bmatrix} 0.6 & 0.6 & 0.0 \\ 0.0 & 0.6 & 0.1 \\ 0.0 & 0.1 & 0.0 \end{bmatrix} \quad R_3 = \begin{bmatrix} 1.0 & 0.0 & 0.7 \\ 0.0 & 1.0 & 0.0 \\ 0.7 & 0.0 & 1.0 \end{bmatrix}$$

求模糊关系的合成 $R_1 \circ R_2$, $R_1 \circ R_3$, $R_1 \circ R_2 \circ R_3$ 。

4.9 用 $X = \{x_1, x_2, x_3\}$ 表示患者集合, $Y = \{y_1, y_2, y_3, y_4, y_5\}$ 表示患者症状集合, $Z = \{z_1, z_2, z_3\}$ 表示病名集合。已知患者集合 X 与患者症状集合 Y 之间的模糊关系 Q 、患者症状集合 Y 与病名集合 Z 之间的模糊关系 R 分别为

$$Q = \begin{bmatrix} 0.1 & 0.8 & 0.2 & 0.6 & 0.1 \\ 0.7 & 0.2 & 0.1 & 0.1 & 0.8 \\ 0.8 & 0.2 & 0.6 & 0.2 & 0.1 \end{bmatrix} \quad R = \begin{bmatrix} 0.3 & 0.7 & 1.0 \\ 1.0 & 0.3 & 0.2 \\ 0.3 & 1.0 & 1.0 \\ 1.0 & 0.3 & 0.2 \\ 0.3 & 1.0 & 0.7 \end{bmatrix}$$

确定患者集合 X 与病名集合 Z 之间的模糊关系 S 。

读一读

模糊理论之父扎德

扎德(Zadeh. L. A. ,1921—2017),美国自动控制专家,美国工程科学院院士。1921年2月生于苏联巴库。1949年获哥伦比亚大学电机工程博士。生前曾任加利福尼亚大学伯克利分校电机工程与计算机科学系教授。

1965年,控制论专家扎德在《信息与控制》杂志第8期上发表文章《模糊集》,用数学描写模糊概念,从外延上把精确集合扩展成模糊集合,从数学上消除了计算机不能处理模糊概念的禁锢,开创了模糊理论,引起了各国数学家和自动控制专家们的注意。他提出用语言变量代替数值变量来描述系统的行为,使人们找到了一种处理不确定性的方法,并给出一种较好的人类推理模式。

模糊数学为人类架起了一座连接定性与定量的桥梁,成为人工智能的重要的数学基础,不仅在理工科,在人文和社会科学领域也都广泛应用模糊理论,使模糊理论成为解决不确定性问题的最有效的方法之一,获得了大量的应用。他因发展模糊集理论的先驱性工作而获电气与电子工程师学会(IEEE)的教育勋章。

在求解一个问题时,涉及两个方面:一是该问题的表示,如果一个问题找不到一个合适的表示方法,就谈不上对它求解;二是选择一种相对合适的求解方法。在人工智能中,问题求解的基本方法有搜索法、归约法、归结法、推理法及产生式等。由于绝大多数需要用人工智能方法求解的问题缺乏直接求解的方法,因此,搜索不失为一种求解问题的一般方法。搜索求解方法的应用非常广泛,例如在下棋等游戏软件中。

下面首先讨论搜索的基本概念,然后着重介绍状态空间知识表示和搜索策略,主要有回溯策略、宽度优先搜索、深度优先搜索等盲目的图搜索策略,以及 A 及 A^* 、蒙特卡洛树等启发式图搜索策略。

5.1 搜索的概念

5.1.1 搜索的基本问题与主要过程

1. 在搜索中需要解决的基本问题

- ① 搜索过程是否一定能找到一个解。
- ② 当搜索过程找到一个解时,找到的是否是最佳解。
- ③ 搜索过程的时间与空间复杂性如何。
- ④ 搜索过程是否终止运行或是否会陷入一个死循环。

2. 搜索的主要过程

- ① 从初始或目的状态出发,并将它作为当前状态。
- ② 扫描操作算子集,将适用当前状态的一些操作算子作用在其上而得到新的状态,并建立指向其父结点的指针。
- ③ 检查所生成的新状态是否满足结束状态,如果满足,则得到解,并可沿着有关指针从结束状态反向到达开始状态,给出一解答路径;否则,将新状态作为当前状态,返回第②步再进行搜索。