

人工智能基础与应用 · 大模型实训

M3 · Transformer 内部机制

从零实现大模型：M0-M9 知识主干（16 周 / 11 课题 / 零预算）

孙承泽 · 能动强基 2501 · 西安交通大学

2026-09-17 生成 · 版本 v1.0

Markdown 母版：人工智能基础与应用/讲义/ 下的 .md 文件 · 配套上游：CS336 A1-A5 · nanochat · minimind

讲义 M3 • Transformer 内部机制

对应课题：课题 02 Transformer 骨架 (W2-W3) | 模块：M3 | 预计 2-3 个时段 对标材料：CS336 lecture 03-04 + A1 handout (模型部分) · rasbt 《LLMs-from-scratch》ch3-ch4 (附录含 GQA/MLA/MoE) 这是全学科最核心的一讲：唐杰作业①的“从零写 Transformer”就落在这里。

〇、本讲要回答的 5 个问题

1. 注意力到底在算什么？为什么缩放因子是 $\frac{1}{\sqrt{d_k}}$ ？
2. 为什么要多头？多头比单头强在哪、代价是什么？
3. RoPE 凭什么比可学习位置嵌入更能外推？
4. RMSNorm 凭什么能替代 LayerNorm？pre-norm 与 post-norm 差在哪？
5. 一个 d 宽、 L 层、词表 V 的 Transformer 有多少参数？KV cache 有多大？

一、注意力：加权检索 + 为什么缩放 $\frac{1}{\sqrt{d_k}}$

计算式 (先记住形状，再看含义)：

$$\text{Attn}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right)V$$

其中 $Q, K, V \in \mathbb{R}^{L \times d_k}$ ， M 是因果掩码 (下三角为 0、其余 $-\infty$)。

含义：每个位置发出一个查询 q ，去和所有位置的键 k 做内积 (相似度)，softmax 归一化成权重，再对值 v 做加权平均。它就是“按相似度检索并汇总”。

为什么除以 $\sqrt{d_k}$ ：设 q, k 各分量独立、均值 0 方差 1，则内积 $q \cdot k = \sum_{i=1}^{d_k} q_i k_i$ 的方差是 d_k (方差可加)。 d_k 越大，内积的取值范围越宽 $\rightarrow$ softmax 越容易“饱和” (一个位置拿走几乎全部权重) $\rightarrow$ 梯度趋近 0 $\rightarrow$ 训练不动。除以 $\sqrt{d_k}$ 把内积的方差重新拉回 1 量级。这是“训练稳定性”的第一课。

因果掩码：语言模型不能看未来。做法是在 softmax 之前给未来位置加 $-\infty$ (实现上常用 -10^9 之类的大负数，而不是 0) —— 因为在 softmax 之后置零会改变概率归一化 (等价于把已分配的概率丢掉，剩下的位置没有重新归一)。

在代码里长什么样：手写/里会有 `scaled_dot_product_attention` 与 `multihead_self_attention` (含 causal 与 RoPE 两个变体)；上游对照 `nanochat/gpt.py` 的 `CausalSelfAttention`。注意接口而非实现：CS336 的 `tests/adapters.py` 规定了你要暴露的函数签名。

二、多头：拆开看不同关系，但总算力不变

做法：把 d 维拆成 h 份、每份 $d_k = \frac{d}{h}$ ，各自独立做注意力，再拼回来过一个输出投影 W_O 。

关键理解 (常被误解)：多头不增加注意力的总计算量——单个头用满 d 维时， $QK^\top$ 是 $L^2 d$ ； h 个头各 $\frac{d}{h}$ 维合计仍是 $L^2 d$ 。多头的收益在于归纳偏置：不同的头可以在不同子空间里学不同的关系 (有的学“上一个词是谁”，有的学“括号配对”，有的学“句子边界”)，比单一头更灵活。

变体 (现代模型常用)：

变体	做法	动机
MQA	所有头共享一份 K/V	KV cache 减小 h 倍，但质量略降

变体	做法	动机
GQA	头分组，组内共享 K/V（如 8 组）	折中：cache 减小、质量几乎不掉 ← 现代主流
MLA	把 K/V 压成低维潜变量再解压	更激进，DeepSeek 系

为什么都在动 K/V：推理时的瓶颈是 **KV cache 的显存**（见 § 五），它随 层数 × 序列长度 × 头数 线性增长，与“生成速度”直接相关。这是“架构为推理服务”的典型例子。

三、位置编码：从“贴标签”到“转角度”

问题：注意力的内积是置换不变的——把 token 顺序打乱，结果不变。所以必须注入位置信息。

三代方案：

方案	做法	缺陷
可学习绝对嵌入	学一个 $L_{\max} \times d$ 的查表	不能外推 ：训练 2048，推理 4096 时后一半没学过
正弦绝对编码（原论文）	$\frac{\sin}{\cos}$ 固定频率	可外推性弱，实践中被 RoPE 取代
RoPE（旋转位置编码）	把 q, k 按二维子空间旋转角度 $\theta \cdot m$	内积只依赖 相对距离 $m - n$ ；外推性好

RoPE 的核心恒等式（这是它存在的全部理由）：

$$\langle R_m q, R_n k \rangle = \langle q, R_{n-m} k \rangle$$

即：在内积里只出现“位置差”，绝对位置被“旋转”吸收掉了。推导要点：旋转矩阵是正交阵， $R_m^\top R_n = R_{n-m}$ 。

频率分配：第 i 对维度的角频率 $\theta_i = 10000^{-2\frac{i}{d}}$ —— 低维（ i 小）转得快（管近距离），高维转得慢（管远距离）。“10000”这个底数是“能覆盖多长上下文”的旋钮，这就是所谓 YaRN / NTK 插值等长上下文外推技巧的入口。

在代码里长什么样：手写/ 的 rope 与前缀 rope 的多头注意力；CS336 有单独的 run_rope 测试点。

四、归一化与残差：让 100 层能训起来的两件套

LayerNorm：对每个 token 的 d 维向量做 $\frac{x-\mu}{\sqrt{\sigma^2+\epsilon}}$ ，再缩放和平移。**RMSNorm：**只做 $\frac{x}{\sqrt{\text{mean}(x^2)+\epsilon}}$ ，再乘一个可学缩放 g 。

- 省掉了**减均值与平移**：更便宜（少一次归约、少一组参数）
- 效果相当：真正起作用的是**尺度不变性**（分母归一化），而中心化贡献有限
- 现代模型（LLaMA/Qwen/GLM 系）默认 RMSNorm

残差连接： $x \leftarrow x + f(\text{norm}(x))$ （pre-norm）。它防的是**梯度消失**：反向传播时，加法的 Jacobian 是单位阵，于是梯度有一条**恒等通路**可以直达浅层。没有它，几十层的网络基本训不动。

pre-norm vs post-norm（原论文是 post-norm）：

	形式	性质
post-norm	$\text{norm}(x + f(x))$	原版；深了需要小心 warmup，容易发散
pre-norm	$x + f(\text{norm}(x))$	训练稳，是现代默认；代价是“深度”的表示能力稍弱

课题 02 会做“去掉残差”的改坏实验：你会亲眼看到 loss 从“平稳下降”变成“几乎不动”。

五、FFN、参数量与 KV cache（把结构换算成资源）

FFN 的演化：两层线性 + 激活。原版 $d_{ff} = 4d$ 配 ReLU。SwiGLU 用三个矩阵：Swish(xW_1) $\odot$ (xW_3) 再过 W_2 ；为保持参数量不变，取 $d_{ff} \approx \frac{8}{3}d$ （3 个矩阵 $\times 8/3 \approx 4$ 个矩阵 $\times d$ 的等价参数量）。

单层参数量（ d 宽，标准 MHA）：

- 注意力： W_Q, W_K, W_V, W_O 各 $d \times d \rightarrow 4d^2$
- MLP (SwiGLU, $d_{ff} = \frac{8}{3}d$)： $3 \cdot d \cdot \frac{8}{3}d = 8d^2$
- 两处 RMSNorm 缩放： $2d$ （可忽略）
- 合计 $\approx 12d^2$ 每层 $\rightarrow$ 全模型 $\approx 12Ld^2 + Vd$ （权重共享时）

验算习惯：拿到任何模型的配置（如 $d=768, L=12, V=50257$ ），先心算 $12 \times 12 \times 768^2 \approx 85M$ ，加嵌入 $50257 \times 768 \approx 39M$ （共享则算 1 份） $\approx 124M$ —— 与 GPT-2 的 124M 吻合。这种“能不能心算”是 M3 的验收标志之一。

KV cache 显存（推理，重点）：

$$\text{bytes} = 2 \times L_{\text{layers}} \times L_{\text{seq}} \times n_{kv} \times d_k \times \text{bytes/elem}$$

（乘 2 是因为 K 和 V）。用 GQA 后 n_{kv} 从 h 降到组数，cache 直接按比例缩小——这就是 GQA 流行的真正原因。课题 05 会实测这个数字。

六、常见误解（每条配反例）

误解	反例 / 更正
“注意力=可解释的检索”	注意力权重高 $\neq$ 因果重要（已有大量反例）；它是 加权平均的权重 ，别过度解读
“多头=多算”	总 FLOPs 不变（§ 二），只是分成子空间
“位置编码只是加个向量”	RoPE 是 旋转 Q/K ，不是加到输入上；且它只影响内积的相位
“RMSNorm 是 LayerNorm 的近似”	它 省略了中心化 ，不是近似；在很多模型上效果更好且更省
“参数量大就一定强”	同样算力下，参数与数据要按 scaling law 配比（课题 03 的正题）
“因果 mask 随便加个大负数就行”	必须在 softmax 之前 ；加在之后会破坏归一化

七、能立刻跑的实验与改坏实验（课题 02 的里程碑）

基础验证（跑通即达里程碑 M1-M3）：

```
bash 环境/bootstrap_cpu.sh --with-torch # 课题02 起需要 torch
环境/judge/judge.sh 02 --quick # 形状与数值测试（判分器按需接入）
```

三组改坏实验（先写预测，再跑，再记录——这是本讲的核心作业）：

#	改哪里	先预测什么	预期观察（跑完记得回来对照）
1	去掉因果 mask(让所有位置互相可见)	训练 loss 会大幅下降，但采样出来的文本“语法很好、内容胡说”	典型“作弊”：loss 好看，能力为零
2	RoPE 换成可学习绝对嵌入	训练集内正常，超出训练长度立刻崩	外推性丧失；正是课程要“用实验看见”的性质
3	去掉残差连接	浅层（ ≤ 4 层）还能训，深了就完全不收敛	梯度消失的实证

记录要求：每条都要有“预测 $\rightarrow$ 现象 $\rightarrow$ 解释”三段，落进 课题 02/证据/。预测错是资产，不是污点。

八、代码级提问 (3-5 道)

1. 【推导】用“方差可加”说明： $q \cdot k$ 的方差是 d_k ，并解释为何要除以 $\sqrt{d_k}$ 而不是 d_k 。
2. 【心算】配置 $d = 1024, L = 24, V = 100000$ ，权重共享。估算参数量（结果用 G/M 表示），并拆出嵌入层占比。
3. 【改坏预测】把 causal mask 从“softmax 之前”挪到“softmax 之后”（对已归一化权重置零），训练会发生什么？给出两个可能的现象并说明理由。
4. 【联系】用 M0 的 logsumexp 解释：为什么 flash attention 的分块计算能保持数值稳定？
5. 【代价】序列长度从 2k 增到 32k：①注意力计算量变几倍 ②KV cache 变几倍 ③哪个先撞墙？

九、记忆锚

- 隐喻：注意力 = “会议室里的自由讨论”——每人 (query) 挑自己关心的话题 (key)，按关心程度 (softmax 权重) 听别人 (value) 说话；因果 mask = “不许听后面发言的人”；多头 = 同时开 h 个并行分会场；RoPE = 每个人的座位号刻在朝向上，所以只关心“相隔几个座位”。
- 口诀：“缩放防饱和、掩码在软前、多头不减算、旋转只认距、残差是命脉、归一挑 RMS”
- 符号位置法： $\frac{QK^T}{\sqrt{d_k}}$ —— 把 $\sqrt{d_k}$ 写在分数线下方，心里念“维度越高，内积越炸，除以根号拉回来”。