共享单车租赁需求预测（线性回归）

姓名：_____

学号：_____

一、模型

以温度、湿度、风速、降雨量、降雪量、季节与节假日为特征，建立线性回归模型：

$$y = b + \sum_{i=1}^{9} w_i x_i = b + w_1 x_1 + w_2 x_2 + \cdots + w_9 x_9 \tag{1}$$

其中 x1–x5 为温度、湿度、风速、降雨量、降雪量；x6–x8 为季节哑变量（春季、夏季、秋季，以冬季为基准）；x9 为节假日（1=节假日，0=非节假日）。共 9 个特征、10 个参数（b, w1, ⋯, w9）。

二、数据处理与求解过程

数据：训练集 100 条、测试集 60 条；经检查两集均无缺失值与重复样本。

处理：（1）季节（4 类）与节假日（2 类）做哑变量编码，季节以冬季为基准，避免与常数列共线；（2）对 5 个连续特征做标准化 $z = (x - \mu) / \sigma$，μ、σ 只由训练集估计、测试集直接套用（表 1），使设计矩阵条件数由 497.4 降至 12.1，保证数值稳定。

求解：以最小二乘为目标（式 2），令梯度为零得正规方程（式 3），用数值线性代数求解；并与 scikit-learn 的 LinearRegression 对照，参数最大偏差 < 1e-12。所得参数处于标准化尺度，按 $z = (x - \mu) / \sigma$ 精确反变换回原始尺度（表 2）。

$$L(b, \mathbf{w}) = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2, \qquad \hat{y}_i = b + \sum_{j=1}^{9} w_j x_{ij} \tag{2}$$

$$\frac{\partial L}{\partial b} = 0,\ \frac{\partial L}{\partial \mathbf{w}} = 0 \implies \mathbf{X}^\top \mathbf{X}\,\mathbf{w} = \mathbf{X}^\top \mathbf{y} \implies \mathbf{w}^* = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} \tag{3}$$

表 1 标准化统计量（由训练集 100 条估计）

连续特征	均值 μ	标准差 σ
温度 (°C)	11.078	12.368
湿度 (%)	56.890	20.546
风速 (m/s)	1.848	1.199
降雨量 (mm)	0.106	0.448
降雪量 (cm)	0.129	0.471

三、模型学习得到的参数

学得原始尺度模型（保留 3 位小数）：

$$y = 1055.483 + 39.199 \cdot x1(温度) - 11.039 \cdot x2(湿度) - 61.311 \cdot x3(风速) - 233.790 \cdot x4(降雨) - 39.490 \cdot x5(降雪) + 97.676 \cdot I(春季) - 220.914 \cdot I(夏季) - 33.487 \cdot I(秋季) - 269.995 \cdot I(节假日)$$

表 2 参数估计结果（原始尺度，单位：辆）

参数	含义	取值
b	截距（基准：冬季、非节假日、0 °C、无风无雨雪）	+1055.483
w1	温度 (°C)	+39.199
w2	湿度 (%)	-11.039
w3	风速 (m/s)	-61.311
w4	降雨量 (mm)	-233.790
w5	降雪量 (cm)	-39.490
w6	季节=春季	+97.676
w7	季节=夏季	-220.914
w8	季节=秋季	-33.487
w9	节假日	-269.995

四、训练集与测试集表现

表 3 模型性能

数据集	R^2	RMSE（辆）	MAE（辆）
训练集（n=100）	0.506	471.0	355.9
测试集（n=60）	0.345	508.2	387.9

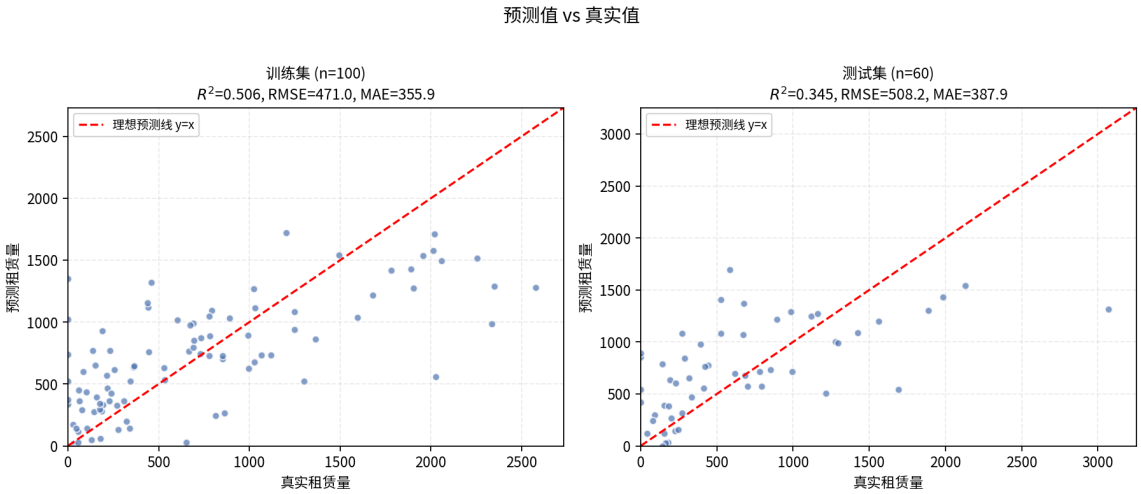


图 1 预测值 vs 真实值（左：训练集；右：测试集）

训练集 R^2 = 0.506、RMSE = 471.0 辆；测试集 R^2 = 0.345、RMSE = 508.2 辆，相对“以训练集均值预测”的基线（测试集 RMSE = 631.2 辆）误差降低约 20%，模型具有实际预测能力。

训练与测试 R^2 相差 0.161；5 折交叉验证 R^2 = 0.389 ± 0.120，测试成绩处于该波动范围内，未见明显过拟合（训练样本仅 100 条，参数估计不确定性本身较大）。

从参数看：温度每升高 1 °C 需求平均增加 39.2 辆（p<0.01，影响最强）；湿度每升高 1% 减少 11.0 辆（p<0.01）；降雨为边际显著负效应（p=0.066）；风速、降雪、季节与节假日的系数不显著（p>0.2），对预测贡献有限。

主要局限：特征只有气象与日历信息，缺少小时、星期等时间维度；且线性假设会把预测拉向均值（预测值标准差仅为真实值的 71%），高需求时段被系统性低估，是误差的主要来源。