

课题02-Transformer骨架

Contents

1	课题02 开题简报 · Transformer 骨架与训练循环	1
1.1	一、研究背景	1
1.2	二、研究问题（一句话）	2
1.3	三、攻关线索	2
1.4	四、里程碑	2
1.5	五、交付物	2
1.6	六、讲课锚点（讲义 M3 + 对标）	3
1.7	七、代码级提问示例（讲课中出，先预测后验证）	3
1.8	八、风险与提醒	3

1 课题02 开题简报 · Transformer 骨架与训练循环

模块：M0/M1/M3 | 周次：W2-W3 (09-21→10-04) |
算力：T0 纯 CPU, 0 GPU·小时 唐杰作业对应：① 从零写
Transformer 的后半 | 判分来源：CS336 A1 tests/test_model.
py、test_nn_utils.py、test_optimizer.py、test_serialization.py 手写
：R2 (Transformer 全部组件) + R3 (训练循环与优化器) +
R4 (反向传播验证)

1.1 一、研究背景

2017 年《Attention Is All You Need》删掉 RNN，用自注意力 + 前馈层实现 O(1) 依赖路径 + 全并行。此后所有主流大模型都是它的变体，但细节已经换了一轮：正弦位置编码 → RoPE；LayerNorm → RMSNorm；post-norm → pre-norm；ReLU MLP → SwiGLU；MHA → GQA。本课题要求你把现代版写出来，而不是复刻 2017 版。

1.2 二、研究问题（一句话）

一个“能从零训起来”的现代 **Transformer** 层，最少需要哪几个组件？每个组件去掉之后，训练会以什么方式失败？

1.3 三、攻关线索

1. 形状先行：写下每一步的张量形状（含 batch、序列、头数），先能在纸上跑通，再写代码。
2. 注意力的三个动作：投影出 Q/K/V → 缩放点积 + 因果掩码 → softmax 加权求和并输出投影。哪一步最容易错？为什么？
3. 位置信息：RoPE 为什么是“旋转 Q/K”而不是“加到输入上”？（讲义 M3 §三给了恒等式）
4. 归一化与残差：为什么 pre-norm 比 post-norm 好训？残差提供了什么“通路”？
5. 优化器：AdamW 里“解耦权重衰减”解耦的是什么？为什么它比 L2 正则更常用？
6. 稳定性：梯度裁剪在什么情况下救命？fp16 vs bf16 的差别如何影响 loss 曲线？

1.4 四、里程碑

- M1 手写全部组件：注意力（含因果 mask 与 RoPE）、RMSNorm、SwiGLU、FFN、残差堆叠、初始化
- M2 形状与数值判分通过：test_model.py / test_nn_utils.py 全绿
- M3 手写训练循环 + AdamW + LR 调度 + 梯度裁剪 → test_optimizer.py / test_serialization.py 全绿
- M4 端到端：CPU 上训一个极小模型（d4–d8），loss 稳定下降，并保存/加载 checkpoint 续训成功
- M5 **R4** 反向传播验证：与 PyTorch autograd 的数值梯度对照（相对误差 $< 1e-6$ ）
- M6 三组改坏实验（去 mask / 换位置编码 / 去残差）：每组先写预测，再跑，再记录
- M7 一页报告 + 知识卡 ≥ 3 张

1.5 五、交付物

交付物	位置	验收
实现	手写/（你写）	M2/M3 判分全绿
判分输出	判卷记录.md	证据/judge-*.log 原文

交付物	位置	验收
改坏实验记录	证据/改坏实验.md	预测→现象→解释 三段齐全
loss 曲线	证据/	训练日志 + 图（含坐标轴与步数）
报告	报告.md	一页四段

1.6 六、讲课锚点（讲义 M3 + 对标）

- 讲义：讲义/M3-Transformer内部机制.md（主干）+ 讲义/M0-数学与机器学习地基.md（§一 自动微分、§五 排查顺序）
- 对标：CS336 lecture 03-04 · rasbt ch3-ch4 · 李沐 d2l ch10-ch11
- 必备工具链：bash 环境/bootstrap_cpu.sh --with-torch（本课题起需要 torch）

1.7 七、代码级提问示例（讲课中出，先预测后验证）

1. 把因果 mask 从 softmax 之前挪到之后，训练现象会怎样？
2. 去掉残差后，4 层还能训、12 层完全不动——请用梯度路径解释。
3. 你把 RoPE 的最大频率底数从 10000 改成 100：短文训练会受影响吗？长上下文外推呢？
4. AdamW 的 weight_decay 若改成“直接加到梯度上”（即 L2），在大学生习率下会出现什么差异？

1.8 八、风险与提醒

- △ CPU 训练极慢：本课题只要能训起来、loss 下降即可，不追求指标（真训练在课题04）。
- △ 形状错误是最高频故障：先写形状注释再写实现，可省一半时间。
- △ 判分器需要 torch；bootstrap --with-torch 首次约 555MB（沙箱网络受限时可能失败，届时改用 Kaggle CPU 会话）。