

课题03-Scaling-Law

Contents

1 课题03 开题简报 · Scaling Law 预演与打脸链路	1
1.1 一、研究背景	1
1.2 二、研究问题（一句话）	2
1.3 三、攻关线索	2
1.4 四、里程碑	2
1.5 五、交付物	2
1.6 六、讲课锚点	3
1.7 七、代码级提问示例	3
1.8 八、风险与提醒	3

1 课题03 开题简报 · **Scaling Law** 预演与打脸链路

模块：**M4** | 周次：**W4 (10-05→10-11)** | 算力：**T0 纯 CPU**（极小规模 **sweep**）唐杰作业对应：③ 拟合 **scaling law** 再外推 | 判分来源：无官方判分器（CS336 A3 需 8 位学号 API key，不可得）→ 自建判分：预测 **vs** 实测的偏差 手写：**R6**（拟合与外推）

1.1 一、研究背景

Kaplan 等（2020）与 Chinchilla（2022）发现：loss 随参数量 N 与数据量 D 呈幂律下降，且存在一个算力最优配比。这条规律是“为什么敢花几千万训一次大模型”的全部依据。但初学者最常见的错误是：把外推当预言，不做回溯验证就把曲线画到天上去。

本课题的核心不是“拟合出一条漂亮的线”，而是建立“预测 → 验证 → 承认偏差”的科研习惯。这也是本学科“预测—打脸日志”（memory/MEMORY.md）的主要产地。

1.2 二、研究问题（一句话）

在极小规模（我的 CPU 能承受的范围内）跑 4–5 个点，能否外推出更大模型的 loss？外推误差有多大、什么时候会崩？

1.3 三、攻关线索

1. 口径：横轴用什么？参数量 N ？token 数 D ？（提示：固定预算时， N 与 D 不能同时变）
2. 记账：用 $M0$ 的 $6ND$ 估算每一次跑的算力，确保不同点是在“同样算力预算”下比较（否则曲线无意义）
3. 拟合：幂律 $L = aN^{-\alpha} + c$ 的形式里，那个常数项 c 代表什么？它会不会让外推失效？
4. 外推：拟合完先把预测写死在文件里（带日期），再去跑验证点——顺序不能反
5. 偏差来源：小规模数据是否“无限数据区”？学习率是否随规模重新调过？这些都是外推失准的技术原因

1.4 四、里程碑

- ☐ M1 设计 sweep：4–5 个规模点（如 d4/d6/d8/d10），预算固定、口径统一
- ☐ M2 跑完 sweep，记录每个点的最终 loss/bpb 与耗时（CPU 上即可，分钟级）
- ☐ M3 拟合幂律并画图（含数据点、拟合线、坐标轴标注）
- ☐ M4 先写死外推预测（例如 d12 的 bpb 预测值 + 置信区间），归档到证据/
- ☐ M5 跑验证点，计算偏差，并解释偏差的方向与原因
- ☐ M6 一页报告：包含“预测 vs 实测”对照表（这一条是验收硬指标）

1.5 五、交付物

交付物	位置	验收
sweep 原始数据	证据/sweep.csv	含配置、loss、耗时、算力估算
拟合脚本与图	脚手架/ + 证据/	图有坐标轴、有拟合优度
外推预测存档	证据/预测-<日期>.md	跑验证点之前的文件时间戳

交付物	位置	验收
报告	报告.md	预测 vs 实测对照表

1.6 六、讲课锚点

- 讲义：讲义/M4-M9-待展开大纲.md 的 M4 部分（W3 展开为完整版 M4-训练.md）
- 对标：CS336 lecture 09/11 (scaling laws) · nanochat/runs/scaling_laws.sh 与其 miniseries 文档 · d2l 的线性回归/最小二乘（拟合的数学基础）
- 搭桥：probability/ 的方差与回归 —— 拟合优度、残差分析直接可用

1.7 七、代码级提问示例

1. 为什么横轴常画 **FLOPs** 而不是参数量？（提示：Chinchilla 的核心结论是什么）
2. 你拟合出的 c （常数项）为负，说明了什么？还能外推吗？
3. 如果两个规模点用了不同的学习率，曲线还能一起拟合吗？为什么？
4. 【下注】你预测 d12 的 bpb 会比你拟合线的预测值偏高还是偏低？先写下答案再跑。

1.8 八、风险与提醒

- Δ 不要为了“好看”调学习率：每个点的超参策略必须写进 证据/，否则外推无意义。
- Δ 极小规模会出现“学习率不敏感/过于敏感”的异常区间 —— 这本身就是很好的报告素材（no-go 不擦除）。
- Δ 本课题不花 GPU；如发现 CPU 太慢，优先“缩小语料/减步数”，不要上 Kaggle（配额留给课题04）。