

人工智能基础与应用 · 大模型实训

课题 03-Scaling-Law

开题简报 · 交付要求 · 判卷记录

孙承泽 · 能动强基 2501 · 西安交通大学

2026-09-17 生成 · 版本 v1.0

课题 03 开题简报 · Scaling Law 预演与打脸链路

模块：M4 | 周次：W4 (10-05→10-11) | 算力：T0 纯 CPU (极小规模 sweep) 唐杰作业对应：③ 拟合 scaling law 再外推 | 判分来源：无官方判分器 (CS336 A3 需 8 位学号 API key, 不可得) → 自建判分：预测 vs 实测的偏差 手写：R6 (拟合与外推)

一、研究背景

Kaplan 等 (2020) 与 Chinchilla (2022) 发现：loss 随参数量 N 与数据量 D 呈幂律下降，且存在一个算力最优配比。这条规律是“为什么敢花几千万训一次大模型”的全部依据。但初学者最常见的错误是：把外推当预言，不做回溯验证就把曲线画到天上去。

本课题的核心不是“拟合出一条漂亮的线”，而是建立“预测 → 验证 → 承认偏差”的科研习惯。这也是本学科“预测—打脸日志” (memory/MEMORY.md) 的主要产地。

二、研究问题（一句话）

在极小规模（我的 CPU 能承受的范围内）跑 4–5 个点，能否外推出更大模型的 loss？外推误差有多大、什么时候会崩？

三、攻关线索

- 口径：横轴用什么？参数量 N ？token 数 D ？（提示：固定预算时， N 与 D 不能同时变）
- 记账：用 M0 的 $6ND$ 估算每一次跑的算力，确保不同点是在“同样算力预算”下比较（否则曲线无意义）
- 拟合：幂律 $L = aN^{-\alpha} + c$ 的形式里，那个常数项 c 代表什么？它会不会让外推失效？
- 外推：拟合完先把预测写死在文件里（带日期），再去跑验证点 —— 顺序不能反
- 偏差来源：小规模数据是否“无限数据区”？学习率是否随规模重新调过？这些都是外推失准的技术原因

四、里程碑

- M1 设计 sweep：4–5 个规模点（如 d4/d6/d8/d10），预算固定、口径统一
- M2 跑完 sweep，记录每个点的最终 loss/bpb 与耗时（CPU 上即可，分钟级）
- M3 拟合幂律并画图（含数据点、拟合线、坐标轴标注）
- M4 先写死外推预测（例如 d12 的 bpb 预测值 + 置信区间），归档到 证据/
- M5 跑验证点，计算偏差，并解释偏差的方向与原因
- M6 一页报告：包含“预测 vs 实测”对照表（这一条是验收硬指标）

五、交付物

交付物	位置	验收
sweep 原始数据	证据/sweep.csv	含配置、loss、耗时、算力估算
拟合脚本与图	脚手架/ + 证据/	图有坐标轴、有拟合优度
外推预测存档	证据/预测-<日期>.md	跑验证点之前的文件时间戳
报告	报告.md	预测 vs 实测对照表

六、讲课锚点

- 讲义：讲义/M4-M9-待展开大纲.md 的 M4 部分 (W3 展开为完整版 M4-训练.md)

- **对标**: CS336 lecture 09/11 (scaling laws) · nanochat/runs/scaling_laws.sh 与其 miniseries 文档 · d2l 的线性回归/最小二乘 (拟合的数学基础)
- **搭桥**: probability/ 的方差与回归 —— 拟合优度、残差分析直接可用

七、代码级提问示例

1. 为什么横轴常画 **FLOPs** 而不是参数量? (提示: Chinchilla 的核心结论是什么)
2. 你拟合出的 c (常数项) 为负, 说明了什么? 还能外推吗?
3. 如果两个规模点用了不同的学习率, 曲线还能一起拟合吗? 为什么?
4. 【下注】 你预测 d12 的 bpb 会比你拟合线的预测值偏高还是偏低? 先写下答案再跑。

八、风险与提醒

- ⚠ **不要为了“好看”调学习率**: 每个点的超参策略必须写进 证据/, 否则外推无意义。
- ⚠ 极小规模会出现“学习率不敏感/过于敏感”的异常区间 —— 这本身就是很好的报告素材 (no-go 不擦除)。
- ⚠ 本课题**不花 GPU**; 如发现 CPU 太慢, 优先“缩小语料/减步数”, 不要上 Kaggle (配额留给课题 04)。