

人工智能基础与应用 · 大模型实训

课题 06-多卡与分布式

开题简报 · 交付要求 · 判卷记录

孙承泽 · 能动强基 2501 · 西安交通大学

2026-09-17 生成 · 版本 v1.0

课题 06 开题简报 · 多卡与分布式训练

模块: M4 | 周次: W9 (11-09→11-15) | 算力: T2 Kaggle 2×T4, 计划 8 GPU·小时 唐杰作业对应: ② 的“多卡训练增益”部分 | 判分来源: CS336 A2 分布式部分 + 自建 benchmark 手写: R3 的延伸 (并行策略选择与通信原语判断)

一、研究背景

数据并行 (DDP) 把同一模型复制到每张卡、各自算一个微批、再**同步梯度**; 当模型放不下单卡时, 才有 FSDP/ZeRO (切分参数、梯度、优化器状态)、张量并行 (切层内矩阵)、流水线并行 (切层)。Kaggle 免费档给的是 2×T4, 且走 PCIe 而非 NVLink —— 这恰好是“观察通信成为瓶颈”的最佳实验台。

二、研究问题

在弱互联 (PCIe) 的 2×T4 上, DDP 的扩展效率是多少? 瓶颈是计算还是通信? FSDP 在什么规模才开始划算?

三、攻关线索

1. 先对齐正确性: DDP 后的梯度应与单卡 (同等效批大小) **数值一致**, 先验证再谈性能
2. 批大小语义: 2 卡 × 每卡 batch = 等效批大小; 若显存受限要**同步调整学习率** (线性/平方根缩放)
3. 计时口径: step time 要区分“纯计算时间”与“含 all-reduce 的时间”; 用 torch.profiler 或手写计时
4. 扩展效率: $E = \frac{T_1}{2T_2}$ 。先**预测** (PCIe 下 0.6–0.8?) 再测
5. 通信占比: 梯度同步量与参数量成正比 (2N 字节/步, all-reduce 近似); 序列长/批小时通信占比更高
6. FSDP 的代价: 切分带来额外通信 (all-gather + reduce-scatter), **小模型上往往更慢**

四、里程碑

- ☐ M1 DDP 梯度一致性验证 (与单卡同等效批) → 记录最大误差
- ☐ M2 单卡 vs 双卡的 step time、tokens/s 对照 (同模型、同等效批)
- ☐ M3 **扩展效率曲线** (至少 3 个配置点: 不同 batch/序列长度)
- ☐ M4 **通信占比分解**: 计算 / all-reduce / 数据加载 三段计时
- ☐ M5 一次 FSDP 实验并解释“为什么 (不) 划算”
- ☐ M6 **先写预测再实测**: 预测扩展效率, 跑完对照 (进 memory/MEMORY.md 打脸日志)
- ☐ M7 一页报告

五、交付物

交付物	位置	验收
分布式脚本	手写 / 或 脚手架 / (按 B3 分类)	可复跑
计时原始数据	证据/bench.csv	含每配置 3 次重复
扩展效率曲线	证据/	标注硬件 (2×T4 PCIe) 与对比基准
报告	报告.md	解释“为什么不是 2 倍”

六、讲课锚点

- 讲义: M4-训练.md (W3 展开) 中并行一节

- **对标:** CS336 lecture 07-08 (Parallelism) · nanochat/optim.py (分布式优化器实现) · HF Ultra-Scale Playbook (用前先核)
- **搭桥:** M0 的“梯度累加” → DDP 就是跨卡的梯度累加

七、代码级提问示例

1. $2 \times T4$ 上 DDP 只快了 1.4 倍，列出三个最可能的原因。
2. 把每卡 batch 减半、用梯度累积补回等效批，通信量会怎么变？
3. 什么情况下 FSDP 会比 DDP 慢？（用通信量解释）
4. all-reduce 的通信量是多少字节/步？用参数量 N 表示。

八、风险与提醒

- ⚠ Kaggle 双 T4 会话**不稳定**（可能只给一张）：预检时确认 `torch.cuda.device_count()==2`。
- ⚠ 不要在本课题纠缠“调到最快”——目标是理解扩展效率的成因，配额要留给课题 08。