

课题07-数据清洗与去重

Contents

1 课题07 开题简报 · 数据清洗与去重 1

1.1 一、研究背景 1

1.2 二、研究问题 1

1.3 三、攻关线索 2

1.4 四、里程碑 2

1.5 五、交付物 2

1.6 六、讲课锚点 2

1.7 七、代码级提问示例 3

1.8 八、风险与提醒 3

1 课题07 开题简报 · 数据清洗与去重

模块：M7/M4 | 周次：W10 (11-16→11-22) | 算力：T1
Kaggle 1×T4, 计划 6 GPU·小时 唐杰作业对应：③ 从 raw
dump 洗语料 | 判分来源：CS336 A4 (过滤/去重规格) + 自
建消融 手写：R8 (过滤/去重的判定规则设计)

1.1 一、研究背景

“数据决定上限”已是共识：C4/FineWeb/Dolma 等工作的主要贡献不是模型而是数据管线。典型手段：语言识别、质量启发式（重复度、符号比、平均行长）、有毒内容过滤、近似去重（MinHash/LSH）。最有教学价值的现象：清洗规则过严会伤害模型（把有价值的长尾数据也删了）。

1.2 二、研究问题

在固定算力下，“清洗 + 去重”能把同样规模模型的下游表现提升多少？每条规则的收益与代价各是多少？

1.3 三、攻关线索

1. 基线优先：先训一个“未清洗”的基线（可与课题04 的结果复用）——没有对照就无法声称“清洗有效”
2. 规则设计：至少三条可解释规则（如：短行比例、符号-词比、n-gram 重复率），每条要能说清“它在拦什么”
3. 去重量级：精确去重（哈希）与近似去重（MinHash + LSH）的成本差异；文档级 vs 段落级
4. 消融：逐条关掉规则各跑一次（小规模即可），得“每条规则的边际贡献”表
5. 口径：所有对照必须同 **token** 预算、同分词器、同评测（否则结论无效）
6. 常用工具对照：datajuicer/data-juicer（Apache-2.0，活跃）与 allenai/dolma 的规则集可作参考

1.4 四、里程碑

- M1 数据来源与规模确定（用 owt-sample / TinyStories 扩样，或小规模 CC 采样）
- M2 手写 3 条启发式规则 + 1 个去重算法（精确哈希起步，有余力再上 MinHash）
- M3 规则单元测试（含假阳性样例：被误删的好数据长什么样）
- M4 训练对照：未清洗 vs 全部清洗 vs 逐条消融（ ≥ 4 组跑）
- M5 结果表：每组的下游指标 + 数据保留率（这是被忽略的关键列）
- M6 一页报告：必须回答“哪条规则最值钱、哪条可能有害”

1.5 五、交付物

交付物	位置	验收
过滤/去重实现	手写/	M3 单测通过
规则清单与理由	报告.md	每条规则说明“拦什么、代价是什么”
对照实验数据	证据/对照.csv	含保留率与指标
假阳性样例	证据/	≥ 5 条被误删的好数据

1.6 六、讲课锚点

- 讲义：M7-评测.md（W9 展开）中“数据质量与评测的关系”
- 对标：CS336 lecture 13-14（Data）+ A4 handout · datajuicer/data-juicer 规则文档 · Dolma 论文

- 搭桥：概率论的采样与分布 —— 过滤本质是“改变训练分布”，会引入选择偏差

1.7 七、代码级提问示例

1. 过滤掉“短行”能提分，但会不会系统性删掉对话/代码类数据？怎么检测这种偏差？
2. 精确去重 vs 近似去重：各自漏掉什么、误杀什么？
3. 数据保留率从 90% 降到 50%，你如何判断“这是提纯还是阉割”？
4. 【下注】预测“全部清洗”相对“未清洗”的提升幅度，先写再测。

1.8 八、风险与提醒

- △ 磁盘：本课题可能涉及较大语料，大文件绝不进 `git`（见学科 . `gitignore`）。
- △ 不要一开始就上 MinHash 集群版：先精确去重跑通闭环，再考虑近似。
- △ 4 组对照训练会吃掉配额：用小模型 + 短序列，保证口径一致即可。