

人工智能基础与应用 · 大模型实训

课题 07-数据清洗与去重

开题简报 · 交付要求 · 判卷记录

孙承泽 · 能动强基 2501 · 西安交通大学

2026-09-17 生成 · 版本 v1.0

课题 07 开题简报 · 数据清洗与去重

模块：M7/M4 | 周次：W10 (11-16→11-22) | 算力：T1 Kaggle 1×T4，计划 6 GPU·小时 唐杰作业对应：③ 从 raw dump 洗语料 | 判分来源：CS336 A4 (过滤/去重规格) + 自建消融 手写：R8 (过滤/去重的判定规则设计)

一、研究背景

“数据决定上限”已是共识：C4/FineWeb/Dolma 等工作的主要贡献不是模型而是数据管线。典型手段：语言识别、质量启发式（重复度、符号比、平均行长）、有毒内容过滤、近似去重（MinHash/LSH）。最有教学价值的现象：**清洗规则过严会伤害模型**（把有价值的长尾数据也删了）。

二、研究问题

在固定算力下，“清洗 + 去重”能把同样规模模型的下游表现提升多少？每条规则的收益与代价各是多少？

三、攻关线索

1. **基线优先**：先训一个“未清洗”的基线（可与课题 04 的结果复用）—— **没有对照就无法声称“清洗有效”**
2. **规则设计**：至少三条可解释规则（如：短行比例、符号-词比、n-gram 重复率），每条要能说清“它在拦什么”
3. **去重量级**：精确去重（哈希）与近似去重（MinHash + LSH）的成本差异；文档级 vs 段落级
4. **消融**：逐条关掉规则各跑一次（小规模即可），得“每条规则的边际贡献”表
5. **口径**：所有对照必须同 **token 预算、同分词器、同评测**（否则结论无效）
6. **常用工具对照**：datajuicer/data-juicer（Apache-2.0，活跃）与 allenai/dolma 的规则集可作参考

四、里程碑

- ☐ M1 数据来源与规模确定（用 owt-sample / TinyStories 扩样，或小规模 CC 采样）
- ☐ M2 手写 3 条启发式规则 + 1 个去重算法（精确哈希起步，有余力再上 MinHash）
- ☐ M3 规则单元测试（含**假阳性样例**：被误删的好数据长什么样）
- ☐ M4 训练对照：未清洗 vs 全部清洗 vs 逐条消融（≥4 组跑）
- ☐ M5 结果表：每组的下游指标 + **数据保留率**（这是被忽略的关键列）
- ☐ M6 一页报告：必须回答“哪条规则最值钱、哪条可能有害”

五、交付物

交付物	位置	验收
过滤/去重实现	手写/	M3 单测通过
规则清单与理由	报告.md	每条规则说明“拦什么、代价是什么”
对照实验数据	证据/对照.csv	含保留率与指标
假阳性样例	证据/	≥5 条被误删的好数据

六、讲课锚点

- **讲义**：M7-评测.md（W9 展开）中“数据质量与评测的关系”
- **对标**：CS336 lecture 13-14 (Data) + A4 handout · datajuicer/data-juicer 规则文档 · Dolma 论文
- **搭桥**：概率论的采样与分布 —— 过滤本质是“改变训练分布”，会引入选择偏差

七、代码级提问示例

1. 过滤掉“短行”能提分，但会不会系统性删掉对话/代码类数据？怎么检测这种偏差？
2. 精确去重 vs 近似去重：各自漏掉什么、误杀什么？
3. 数据保留率从 90% 降到 50%，你如何判断“这是提纯还是阉割”？
4. 【下注】预测“全部清洗”相对“未清洗”的提升幅度，先写再测。

八、风险与提醒

- ⚠ 磁盘：本课题可能涉及较大语料，**大文件绝不进 git**（见学科 .gitignore）。
- ⚠ 不要一开始就上 MinHash 集群版：**先精确去重跑通闭环**，再考虑近似。
- ⚠ 4 组对照训练会吃掉配额：**用小模型 + 短序列**，保证口径一致即可。