

课题08-SFT-DPO-RLVR

Contents

1 课题08 开题简报 · SFT / DPO / RLVR 三方对照	1
1.1 一、研究背景	1
1.2 二、研究问题	2
1.3 三、攻关线索	2
1.4 四、里程碑	2
1.5 五、交付物	2
1.6 六、讲课锚点	3
1.7 七、代码级提问示例	3
1.8 八、风险与提醒	3

1 课题08 开题简报 · SFT / DPO / RLVR 三方对照

模块：M6/M7 | 周次：W11-W12 (11-23→12-06) | 算力：
T2 Kaggle 2×T4, 计划 18 GPU·小时 (全学期最贵) 唐杰作业对应：④ 同一基座上把 SFT、DPO、RLVR 做对照 |
判分来源：CS336 A5 tests/test_grpo.py + 自建三方对照 手写：
R7 (损失函数与优势估计)

1.1 一、研究背景

预训练给“知识”，后训练给“行为”。三条主流路线：| 方法 | 需要什么 | 优化什么 | |—|—|—| | SFT | (指令, 回答) 对 | 最大似然 (只对回答部分算 loss) | | DPO | (指令, 好回答, 坏回答) 偏好对 | 隐式奖励差 (无需显式 reward model) | | RLVR | 可判对错的答案 + 验证器 | 期望可验证奖励 (GRPO 用组内相对优势) |

本课题的教学价值极高：它是课程大纲“机器学习 (强化学习)”“与唐杰作业④的交点，也是“知识讲解”最能发挥的地方——GRPO 的每一项都能在概率论里找到根 (期望、方差、条件期望)。

1.2 二、研究问题

同一个基座、同一套评测，**SFT / DPO / RLVR** 各自把什么能力提升了、把什么能力损害了？训练奖励的上升，有多少是真的能力提升？

1.3 三、攻关线索

1. 基座与数据：基座用课题04 的模型（或 0.1B 级开源小模型）；任务是可验证的（数学题/格式约束/单元测试）
2. **SFT** 的损失掩码：只对回答部分算 **loss**，指令部分不算 —— 这是个高频错误点
3. **DPO** 的推导：为什么 $\sigma(\beta \log \frac{\pi(y_w)}{\pi_{ref}(y_w)} - \beta \log \frac{\pi(y_l)}{\pi_{ref}(y_l)})$ 能等价于”隐式奖励”？
4. **GRPO** 的四步：采样一组输出 G 个 $\rightarrow$ 打分 $\rightarrow$ 组内归一化得优势 $A_i = \frac{r_i - \text{mean}(r)}{\text{std}(r)}$ $\rightarrow$ 加权策略梯度 + KL 惩罚
5. **KL** 惩罚的作用：防止策略跑离参考模型太远（对应 RLHF Book 的”过度优化”章）
6. 评测口径：训练奖励 $\neq$ 能力。必须在 held-out 题集上评，并且给误差棒
7. 制造一次 **reward hacking**：例如让模型学到”输出格式对了但答案是瞎猜”，记录现象（这是本课题最好的素材）

1.4 四、里程碑

- ☐ M1 SFT 基线（含损失掩码正确性验证：打印一条样本的 mask）
- ☐ M2 DPO 跑通 + 与 SFT 的对照（held-out）
- ☐ M3 手写 GRPO 损失并逐项注释（优势从哪来、为什么要除标准差）
- ☐ M4 tests/test_grpo.py 通过（判分器接入后）
- ☐ M5 三方对照表（同基座、同评测、同种子策略，带误差棒）
- ☐ M6 **reward hacking** 实验：故意设计一个”可被钻空子”的奖励，观察并记录
- ☐ M7 一页报告 + 知识卡（GRPO 递推必须能徒手推）

1.5 五、交付物

交付物	位置	验收
三个训练脚本	手写/（损失与优势估计属 R7）	可复跑
判分输出	判卷记录.md	test_grpo.py 原文

交付物	位置	验收
对照表	证据/	含误差棒与评测口径说明
reward hacking 记录	证据/	现象 + 机制解释
报告	报告.md	“能力提升 vs 训练奖励”必须分开讨论

1.6 六、讲课锚点

- 讲义：M6-后训练.md (W10 展开)
- 对标：rasbt 《Reasoning from Scratch》ch3 (先建评测) + ch6–ch7 (GRPO) · 《RLHF Book》ch4/6/8/14 · CS336 A5 + lecture 15–17 · minimind/trainer/train_grpo.py (中文工程实现) · nano-aha-moment (单文件)
- 搭桥 (重点)：probability/ 的期望、方差、条件期望——GRPO 的优势归一化就是”标准化”，KL 惩罚就是”分布差异”，REINFORCE 就是”用样本均值估期望”

1.7 七、代码级提问示例

1. 为什么 SFT 只对回答部分算 loss? 若指令部分也算，会发生什么?
2. GRPO 里为什么要除以组内标准差? 如果一组所有奖励完全相同，优势是多少? 这时梯度会怎样?
3. DPO 不需要 reward model, 那它的”奖励”藏在哪儿? (用对数比写出来)
4. 训练奖励从 0.3 涨到 0.8, held-out 准确率却从 40% 掉到 35%。列出三个可能原因。
5. 【下注】预测三方在 held-out 上的排序，先写再测。

1.8 八、风险与提醒

- 🚫 最贵的一周：18 GPU·小时是全学期 1/5，三个方法各只跑一次正式实验，其余用小规模调试。
- 🚫 不做 held-out 评测就等于自欺：训练奖励必须与独立评测同时报 (写进报告硬要求)。
- ⚠️ A5 官方仓库未声明 SPDX 许可 → 只做本地学习对照，不复制进仓 (见《上游锁定清单》§三)。
- ⚠️ Kaggle 会话上限 9–12h: RL 训练务必支持断点续训，否则一次会话跑不完。