

人工智能基础与应用 · 大模型实训

课题 08-SFT-DPO-RLVR

开题简报 · 交付要求 · 判卷记录

孙承泽 · 能动强基 2501 · 西安交通大学

2026-09-17 生成 · 版本 v1.0

课题 08 开题简报 · SFT / DPO / RLVR 三方对照

模块: M6/M7 | 周次: W11-W12 (11-23→12-06) | 算力: T2 Kaggle 2×T4, 计划 18 GPU·小时 (全学期最贵) 唐杰作业对应: ④ 同一基座上把 SFT、DPO、RLVR 做对照 | 判分来源: CS336 A5 tests/test_grpo.py + 自建三方对照 手写: R7 (损失函数与优势估计)

一、研究背景

预训练给“知识”，后训练给“行为”。三条主流路线：

方法	需要什么	优化什么
SFT	(指令, 回答) 对	最大似然 (只对回答部分算 loss)
DPO	(指令, 好回答, 坏回答) 偏好对	隐式奖励差 (无需显式 reward model)
RLVR	可判对错的答案 + 验证器	期望可验证奖励 (GRPO 用组内相对优势)

本课题的教学价值极高：它是课程大纲“机器学习（强化学习）”与唐杰作业④的交点，也是“知识讲解”最能发挥的地方——GRPO 的每一项都能在概率论里找到根（期望、方差、条件期望）。

二、研究问题

同一个基座、同一套评测，SFT / DPO / RLVR 各自把什么能力提升了、把什么能力损害了？训练奖励的上升，有多少是真的能力提升？

三、攻关线索

- 基座与数据**：基座用课题 04 的模型（或 0.1B 级开源小模型）；任务是可验证的（数学题/格式约束/单元测试）
- SFT 的损失掩码**：只对回答部分算 loss，指令部分不算——这是个高频错误点
- DPO 的推导**：为什么 $\sigma\left(\beta \log \frac{\pi(y_w)}{\pi_{ref}(y_w)} - \beta \log \frac{\pi(y_l)}{\pi_{ref}(y_l)}\right)$ 能等价于“隐式奖励”？
- GRPO 的四步**：采样一组输出 G 个 → 打分 → 组内归一化得优势 $A_i = \frac{r_i - \text{mean}(r)}{\text{std}(r)}$ → 加权策略梯度 + KL 惩罚
- KL 惩罚的作用**：防止策略跑离参考模型太远（对应 RLHF Book 的“过度优化”章）
- 评测口径**：训练奖励 ≠ 能力。必须在 held-out 题集上评，并且给误差棒
- 制造一次 reward hacking**：例如让模型学到“输出格式对了但答案是瞎猜”，记录现象（这是本课题最好的素材）

四、里程碑

- M1 SFT 基线（含损失掩码正确性验证：打印一条样本的 mask）
- M2 DPO 跑通 + 与 SFT 的对照（held-out）
- M3 手写 GRPO 损失并逐项注释（优势从哪来、为什么要除标准差）
- M4 tests/test_grpo.py 通过（判分器接入后）
- M5 三方对照表（同基座、同评测、同种子策略，带误差棒）
- M6 reward hacking 实验：故意设计一个“可被钻空子”的奖励，观察并记录
- M7 一页报告 + 知识卡（GRPO 递推必须能徒手推）

五、交付物

交付物	位置	验收
三个训练脚本	手写/（损失与优势估计属 R7）	可复跑
判分输出	判卷记录.md	test_grpo.py 原文
对照表	证据/	含误差棒与评测口径说明
reward hacking 记录	证据/	现象 + 机制解释
报告	报告.md	“能力提升 vs 训练奖励” 必须分开讨论

六、讲课锚点

- 讲义：M6-后训练.md（W10 展开）
- 对标：rasbt《Reasoning from Scratch》ch3（先建评测）+ ch6–ch7（GRPO）·《RLHF Book》ch4/6/8/14·CS336 A5 + lecture 15–17·minimind/trainer/train_grpo.py（中文工程实现）·nano-aha-moment（单文件）
- 搭桥（重点）：probability/ 的期望、方差、条件期望——GRPO 的优势归一化就是“标准化”，KL 惩罚就是“分布差异”，REINFORCE 就是“用样本均值估期望”

七、代码级提问示例

1. 为什么 SFT 只对回答部分算 loss？若指令部分也算，会发生什么？
2. GRPO 里为什么要除以组内标准差？如果一组所有奖励完全相同，优势是多少？这时梯度会怎样？
3. DPO 不需要 reward model，那它的“奖励”藏在哪儿？（用对数比写出来）
4. 训练奖励从 0.3 涨到 0.8，held-out 准确率却从 40% 掉到 35%。列出三个可能原因。
- 5.【下注】预测三方在 held-out 上的排序，先写再测。

八、风险与提醒

- **！最贵的一周**：18 GPU·小时是全学期 1/5，三个方法各只跑一次正式实验，其余用小规模调试。
- **！不做 held-out 评测就等于自欺**：训练奖励必须与独立评测同时报（写进报告硬要求）。
- ⚠ A5 官方仓库未声明 SPDX 许可 → 只做本地学习对照，不复制进仓（见《上游锁定清单》§ 三）。
- ⚠ Kaggle 会话上限 9–12h：RL 训练务必支持断点续训，否则一次会话跑不完。