

人工智能基础与应用 · 大模型实训

课题 09-可验证环境

开题简报 · 交付要求 · 判卷记录

孙承泽 · 能动强基 2501 · 西安交通大学

2026-09-17 生成 · 版本 v1.0

课题 09 开题简报 · 可验证环境 + harness

模块: M7/M8 | 周次: W13 (12-07→12-13) | 算力: T2 Kaggle 2×T4, 计划 6 GPU·小时 唐杰作业对应: ⑤ 搭可验证环境 + harness | 判分来源: 自建 (判定逻辑单测 + rollout 成功率) 手写: R9 (判定逻辑 / verifier)

一、研究背景

2026 年的关键词是“可验证奖励”: 与其训练一个会拍马屁的奖励模型, 不如造一个能判定对错的环境。CS336 没有这一环, Berkeley Agentic AI MOOC 专门有一讲叫 “Post-Training Verifiable Agents”, PrimeIntellect-ai/verifiers 把它抽象成库。唐杰作业⑤要求“搭可验证环境 + harness”正是这个方向。“可验证”的三要素: ①任务是可判定的 (不是主观好坏) ②环境能给出稳定反馈 ③harness 能重复运行并复现。

二、研究问题

我能为一个小程序设计一个“可自动判定”的任务环境吗? 判定逻辑的假阳性/假阴性有多高? 模型在这个环境里的成功率是多少?

三、攻关线索

- 选题: 从三个里选一个 (按成本从低到高)
 - ①数学题解答 (用数值比对 + 容错; MATH-500 风格)
 - ②函数补全 (隐藏单元测试; 本质是迷你 HumanEval)
 - ③格式约束生成 (如严格 JSON / 表格填充, 规则判定)
- 判定逻辑的三大坑: 等价但不相同 ($1/2$ vs 0.5)、解析失败当错、边界用例漏判
- 假阳性检测: 人为构造“错误但能骗过判定器”的答案 → 测出假阳性率 (这是质量的核心指标)
- harness 设计: 任务装载 → 模型生成 → 判定 → 记录轨迹 → 复现 (固定种子)
- 可重复性: 同一批任务跑两次, 成功率波动多大? (误差棒思维, M7 讲过)
- 对照: 可验证奖励 vs 规则弱判定 (如只看格式), 用同一模型比成功率差异

四、里程碑

- ☐ M1 选定任务类型, 写 30–100 道题的题集 (含标准答案与判定规则)
- ☐ M2 判定逻辑单测: 等价形式、边界、异常输入 (≥ 10 个用例)
- ☐ M3 假阳性实验: 构造 10 个“错误但可能蒙混”的答案, 测出漏判率
- ☐ M4 harness 跑通: 给基座模型跑一遍, 得成功率 + 失败样本
- ☐ M5 失败分类: 把失败归成 3–5 类 (格式错 / 计算错 / 中途放弃 / 判定器误杀)
- ☐ M6 一页报告: 判定器质量 + 模型表现 两个都要报

五、交付物

交付物	位置	验收
题集与判定器	手写 / (判定逻辑 R9)	M2 单测通过
harness 脚本	脚手架 / (B3)	固定种子可复跑
失败样本	证据 /	≥ 20 条, 分类标注

交付物	位置	验收
假阳性报告	报告.md	含漏判率与典型案例

六、讲课锚点

- **讲义**：M8-智能体.md (W13 展开)
- **对标**：Berkeley Agentic AI MOOC 的 “Post-Training Verifiable Agents” 与 “Agent Evaluation” 讲 · PrimeIntellect-ai/verifiers (只读概念，不引入代码) · harbor-framework/terminal-bench 的任务设计思路 · **rasbt ch3** (评测器设计：解析 + verifier + 基准式检查)

七、代码级提问示例

1. 你的判定器把 1/2 判错、把 0.50 判对——这属于哪一类错误？如何系统性避免？
2. 假阳性率高会导致 RL 训练出现什么后果？(联系课题 08 的 reward hacking)
3. 同一批任务两次运行成功率差 8%。你会先怀疑模型还是 harness？怎么验证？
4. 为什么“用 LLM 当裁判”在可验证任务上通常是**退步**？

八、风险与提醒

- ⚠ **判定器本身也要被评测**：只报模型成功率不报判定器质量，是不完整的实验。
- ⚠ 题集不要抄公开 benchmark (污染问题)，**自己出题 + 自己判定**才是本课题的价值。
- ⚠ 配额有限：优先“题集质量高、任务简单”，不要一上来做代码执行沙箱 (那是课题 10 的事)。