




图 8.15 卷积神经网络

输入图像为 32×32 大小。这样能够使一些重要特征如笔画、断点或角点能够出现在最高层特征监测子感受域的中心。

C1 层是一个卷积层,由 6 个特征图构成。这之间有个单通道卷积核 $5 \times 5 \times 1 \rightarrow 6$, $\text{stride} = 5$ 。卷积核大小为 $5 \times 5 \times 1 = 25$,有一个可加偏置,6 种卷积核得到 C1 的 6 个特征图。通过卷积运算,可以使原信号特征增强和噪声降低。特征图中每个神经元与输入中 5×5 的邻域相连。特征图的大小为 28×28 ,这样能防止输入的连接掉到边界之外。C1 有 $(5 \times 5 \times 1 + 1) \times 6 = 156$ 个可训练参数。C1 共有 $156 \times (28 \times 28) = 122\,304$ 个连接。

S2 层是一个池化层,有 6 个 14×14 的特征图。对图像进行池化,可以减少数据处理量同时保留有用信息。特征图中的每个单元与 C1 中相对应特征图的 2×2 邻域相连接。C1 层每个单元的 4 个输入相加,乘以一个可训练参数,再加上一个可训练偏置可得到 S2 层。每个单元的 2×2 感受野并不重叠,因此 S2 中每个特征图的大小是 C1 中特征图大小的 $1/4$ (行和列各 $1/2$)。S2 层有 $6 \times (1 + 1) = 12$ 个可训练参数和 $14 \times 14 \times 6 \times (2 \times 2 + 1) = 5\,880$ 个连接。

C3 层也是一个卷积层。它同样通过 5×5 的卷积核去卷积层 S2,然后得到的特征图 map 就只有 10×10 个神经元,但是它有 16 种不同的卷积核,所以就存在 16 个特征映射。

注意:C3 中的每个特征映射并不都连接到 S2 中的所有特征映射,将连接的数量保持在合理范围内,而且使不同的特征图有不同的输入,迫使它们抽取不同的特征。这里用组合模拟人的视觉系统,底层的结构构成上层更抽象的结构,如边缘构成形状或者目标的部分。

8.6.6 胶囊网络

针对卷积神经网络训练数据需求大、环境适应能力弱、可解释性差、数据分享难等不足,2017 年 10 月,辛顿等提出了新型神经网络结构——胶囊网络 (capsule networks, CapsNet)。

一个浅层胶囊网络 CapsNet 结构如图 8.16 所示。这个结构只有 4 层,即输入层、两个隐含层和一个全连接层。输入层就是数字图片本身。后面三层分别记作 Conv1、PrimaryCaps 和 DigitCaps。虽然 CapsNet 网络架构的层数并不多,但由于它利用了向量神经元和动态路由等技

术,导致其性能与深层卷积神经网络差不多。




图 8.16 CapsNet 结构示意图

胶囊网络有一个全连接层。胶囊网络和一般的全连接神经网络的连接方式一样,前一层每一个胶囊神经单元都会和后一层每一个胶囊神经单元相连,如图 8.17 所示。胶囊网络的每一个连接也有权重。在一般的全连接神经网络中,每一个神经元都是标量,所以每个权重都只是一个标量。但在胶囊网络中,每一个胶囊神经单元都是向量,所以,每个胶囊神经元的权值 W 是一个向量。 W 仍然可以采用 BP 学习算法更新。




图 8.17 CapsNet 连接结构图

在图 8.16 中,输入是一张 28×28 的手写字的图片。Conv1 是一个标准的卷积层,有 256 个通道,每个通道均用 9×9 的卷积核,将输入层图片中的像素亮度转化成局部特征输出,然后作为 Conv1 层的输入。该层的激活函数是 ReLU。由于一层卷积神经网络不足以抽取到合适的特征,因此,在 Conv1 之后,CapsNet 又加了一个卷积层 Primary Capsules(简称 PrimaryCaps),称为初级胶囊层。

PrimaryCaps 是一个卷积的胶囊层,包含 32 个胶囊。PrimaryCaps 才是胶囊真正开始的地方。该层使用 9×9 的卷积核对 ReLU Conv1 做卷积操作,并将其调整成适用于 CapsNet 的向量

神经元层 PrimaryCaps(每个输出都是8维向量),而不是以往的标量神经元。PrimaryCaps 到 DigitCaps 层的传播也就是 CapsNet 和以往 CNN 操作的最大区别。在 PrimaryCaps 层中,参与卷积操作的对象不再是单个神经元,而是粒度更大的神经胶囊。因此,可以将 PrimaryCaps 理解为“胶囊版”的卷积层。

DigitCaps 层是胶囊网络的全连接层,称为高级胶囊层。在这一层里,胶囊个数对应分类任务的目标类别数,每个胶囊对应的向量长度代表某一类别所能呈现的不同状态及其存在的概率。例如,要识别的是10类数字(0~9),因此该层的胶囊个数共有10个,每个胶囊表示的向量中元素的个数为16,代表着不同状态下的同一个数字。每个胶囊接受一个 $6 \times 6 \times 32$ 的8维向量作为输入,通过 W_{ij} 将8维输入空间映射到16维胶囊输出空间。因为拓扑结构为全连接,所以每个胶囊都会接受前一层(即 PrimaryCaps)所有胶囊的输出。对这10个向量求模,求得模值最大的那个向量代表的就是图片概率最大的那个分类。

在胶囊网络中,用向量模的大小衡量某个实体出现的概率,模值越大,概率越大。因此,CapsNet 更适合去检测那些重叠在一起的图片。例如,在人脸识别中,每个胶囊都代表着一个检测任务,最后的输出层只要2个胶囊,即分别检测的是“脸”和“不是脸”。中间层的胶囊都负责检测一些更低级特征的任务,如鼻子、眼睛、嘴巴等,还有一些如耳环、眼镜等。这些中间层的胶囊要把激活值输出给下一层的胶囊,如输出给“脸”和“不是脸”这两个胶囊。胶囊更倾向于选择和自己最接近也是最相似的输出胶囊或者关系最大的胶囊,例如,“眼睛”“鼻子”“嘴”这一类的胶囊可能应该选择“脸”的胶囊的概率更大,而选择“不是脸”的胶囊的概率更小。而“眼镜”这一类的胶囊可能应该选择“不是脸”的胶囊的概率更大,而选择“脸”的胶囊的概率更小。

胶囊不是传统神经网络中的一个神经元,而是一组神经元。胶囊里封装的检测特征的相关信息是以向量的形式存在的,其输入输出均为高维的活动向量,胶囊的输入是一个向量,是用一组神经元来表示多个特征的。通过归一化处理,向量的“长度”可表示检测实体存在的概率,也就是向量的输出数值大小;向量的“方向”表示检测实体的各个属性,也就是向量的各个维度信息。

胶囊网络用向量神经元(vector neuron, VN)的向量输出代替传统标量神经元(scalar neuron, SN)的标量输出,可以表示更丰富的内容,从而能够识别更加复杂多变的场景。特别是胶囊网络具有一定的可解释性,为深度学习提供了一种新的神经网络结构及方法。与卷积神经网络的工作机理相比,胶囊网络更接近于人类大脑的工作方式。胶囊网络擅长处理不同类型的视觉刺激,在视频中人类行为定位、医学图像目标分割、文本分类等任务上都取得更好的效果。胶囊网络有可能会取代目前常用的卷积神经网络。

2019年,牛津大学博士生 Adam R. Kosiorek 等提出了堆叠式胶囊自动编码器(stacked capsule autoencoder, SCAE),这是他在谷歌大脑实习期间完成的研究成果。深度学习创始人、图灵奖得主 Hinton 亲自指导了这项研究,担任论文的通讯作者,并称赞它是一种非常好的胶囊网络新版本。

SCAE 在无标签数据上训练时捕获整体和部分之间的空间关系,自我监督和归纳偏差在更

高效的学习中扮演了重要的角色,可以无监督地学习图像中的特征,所以,SCAE 是一个无监督胶囊网络。神经编码器通过解码器的反向传播进行训练,推测物体胶囊的位置和姿势。

SCAE 在 SVHN 的无监督分类上达到了目前最先进的水平(55%),在 MNIST 上达到了接近最先进水平(98.5%)。但 SCAE 目前还不能够处理图像中多次出现相同类型的部件,在 CIFAR-10、ImageNet 等数据集上准确率也不如 CNN。

8.7 生成对抗网络及其应用

人工神经网络的模型可大致分为判别模型和生成模型,以前,人工神经网络取得的成果主要集中在判别模型。判别模型是将一个高维的感官输入映射为一个类别标签。研究生成模型不多的主要原因是对深度神经网络使用最大似然估计时,遇到了麻烦的概率计算问题,而生成对抗网络的提出则巧妙地绕过了这个问题,驱动了生成式人工智能的飞速发展。

生成对抗网络中有两个角色:生成器和判别器。金庸武侠小说《射雕英雄传》里描写的“老顽童”周伯通,被困在桃花岛期间创造了“左右互搏”之术,即用自己的左手跟自己的右手打架,在左右手互搏过程中提高自己的功力。生成对抗网络基本原理类似于“左右互搏”之术。生成器类似于左手扮演攻方,判别器类似于右手扮演守方。造假币技术和验钞技术也一样,生成器扮演造假币的机器造出以假乱真的假钞,判别器扮演验钞机判别是不是假钞。造假币技术和验钞技术在对抗中提高各自的生成和判别能力。

8.7.1 生成对抗网络的基本原理

著名物理学家 Richard 指出,要想真正理解一样东西必须能够把它创造出来。因此,要想让机器理解现实世界,并基于此进行推理与创造,从而实现真正的人工智能,必须使机器能够通过观测现实世界的样本,学习其内在统计规律,并基于此生成类似样本,这种能够反映数据内在概率分布规律并生成全新数据的模型,称为生成模型。

生成方法是机器学习方法中一个重要分支,涉及对数据显式或隐式变量的分布假设和对分布参数的学习,基于学习得到的模型采样出新样本。生成模型则是通过上述生成方法学习得到的模型,概念图如图 8.18 所示。




图 8.18 参数化生成模型概念图

在图 8.18 中,每个黑点分别表示采样于真实数据分布 $p_{\text{data}}(x)$ 的一张图像,参数化生成模型将一个高斯噪声矢量 z 映射为一个生成概率分布 $p_g(x)$,通过优化损失函数调整参数 θ ,使生成概率分布 $p_g(x)$ 尽可能逼近真实数据分布 $p_{\text{data}}(x)$,从而准确解释真实数据。

生成网络把随机点变成与数据集相似的图片。这些随机点是从一个潜在空间中随机抽取的。生成网络其实就是一个实现点到点变换的函数,把潜在点空间中的点变成图像空间中的点。生成网络生成的点称为生成点。生成网络将潜在空间中的分布变换为图像空间中的分布,称为生成分布,所以生成网络也称为生成器。

生成模型是一个极具挑战的机器学习问题,首先,对真实世界进行建模需要大量先验知识,建模的好坏直接影响生成模型的性能;其次,真实世界的数据往往非常复杂,简单的函数很难把这些随机点恰好都变到真实图像的位置,所以需要非常复杂的模型,拟合模型所需计算量往往非常庞大,甚至难以承受。针对上述两大困难,当时还在蒙特利尔大学读博士的伊恩·古德费洛(Ian J. Goodfellow)于 2014 年提出一种新型生成模型——生成对抗网络(generative adversarial network, GAN)。

传统生成模型往往采用最大似然函数作为损失函数,而 GAN 则在生成模型之外引入一个判别模型,通过两者之间的对抗训练达到优化目的。生成对抗网络是属于无监督学习的一种深度学习模型,通过让“生成模型”和“判别模型”两个神经网络以相互博弈的方式进行学习。


生成对抗网络的核心思想源于博弈论的纳什均衡。在二元零和博弈中,博弈双方的利益之和为零或一个常数,即一方有所得,另一方必有所失。基于这个思想,GAN 的框架中包含一对相互对抗的模型:生成器和判别器。判别器的目的是正确区分真实数据和生成数据,从而最大化判别准确率;生成器则是尽可能逼近真实数据的潜在分布。为了在博弈中胜出,二者需不断提高各自的判别能力和生成能力,优化的目标就是寻找二者间的纳什均衡。这类似于造假钞和验假钞的博弈。生成器类似于造假钞的机器,希望制造出尽可能以假乱真的假钞,而判别器类似于验钞机,希望尽可能鉴别是否为假钞。造假钞的人和警察双方在博弈中,不断提升各自的能力。对于 GAN 来说,博弈的最终结果就是生成模型恢复了训练数据的分布(生成了和真实数据一模一样的样本),判别模型判别准确率为 50%,也就是相当于乱猜。这时两个网络都得到利益最大化,于是不再改变自己的策略,即不再更新自己的权值。

8.7.2 生成对抗网络的结构与训练

1. GAN 的结构

生成对抗网络是由生成网络(generative network)和判别网络(discriminative network)两部分构成,如图 8.19 所示。其中前者随机生成观测数据,例如,“创作”出某个人的照片,而后者负责辨别数据的真伪,即判别一张图片是来自真实数据,还是由生成网络“伪造”的数据。例如,判断一张照片是某个人真正的照片,还是计算机创作的照片。

生成器(图 8.19 中虚线框内的多层感知机)的输入是一个来自常见概率分布的随机噪声矢量 z ,输出是计算机生成的伪数据;判别器(图 8.19 中实线框内的多层感知机)的输入是图片



x, x 可能采样于真实数据,也可能采样于生成数据,判别器的输出是一个标量,用来代表 x 是真实图片的概率,即当判别器认为 x 是真实图片时输出 1,反之输出 0。判别器和生成器不断优化,当判别器无法正确区分数据来源时,可以认为生成器捕捉到真实数据样本的分布。

该算法的目标是令生成器生成与真实数据几乎没有区别的样本,即成为一个造假一流的生成模型。

生成对抗网络是一类算法,其中生成器和判别器可以是卷积神经网络等深度神经网络,也可以是 BP 神经网络等。

2. GAN 的训练

GAN 的训练过程包括两个相互交替的阶段:一个是固定生成网络,用来训练判别网络;另一个是固定判别网络,用来训练生成网络。两个网络相互对抗的过程,就是各自网络参数不断调整的过程,而参数的调整过程就是学习过程。

固定生成网络,训练判别网络。在训练判别网络时,通过不断给它输入两种类别的图片,并标注不同的分值。一类图片是生成网络生成的图片,另一类是真实图片。将生成图片和真实图片组成一个二分类的数据集,训练判别网络。将生成图片和实际图片分别输入到判别网络,如果输入图片是来自真实数据集,则输出为 1。如果输入图片来自生成网络,则输出为 0。通过这样的训练,来提高判别网络的甄别能力,同时给生成网络的进一步训练提供信息。

固定判别网络,训练生成网络。持续地在潜空间中生成一些随机数据,用生成网络将这些数据变换为生成图片,分值越高,说明图片越逼真。将这些图片输入到判别器中,得到“这个图片为真实图片”的概率,概率越大,说明图片越逼真。例如,概率 0.5,它表示这个图片有 50% 的概率来自真实数据集,也有 50% 的概率来自生成网络。生成网络利用这些信息调整生成网络参数,使得后面生成出来的图片更接近实际图片。

3. GAN 的缺点

GAN 在训练中也容易出现一些问题,训练过程具有强烈的不稳定性,实验结果随机,难以复现,具体表现在以下几个方面。

(1) 训练过程难以收敛,经常出现震荡。

(2) 训练收敛,但是出现模式崩溃(model collapse)。用数据集训练,训练后的 GAN 模型只能生成训练数据集中部分数据,而失去其他模式。例如,用 MNIST 数据集训练 GAN 模型,但只能生成十个数字中的某一个或者几个。其主要原因是深度神经网络只能逼近连续映射,而传输映射本身是具有间断点的非连续映射。目前已经提出了一些改进算法。

(3) 训练收敛,但是 GAN 还会生成一些没有意义或者现实中不可能出现的图片。

8.7.3 生成对抗网络在博弈中的应用

目前,深度学习已经得到非常广泛的应用,而且新的应用正在像雨后春笋不断出现。生成对抗网络因为其内部对抗训练的机制,可以解决一些传统的机器学习面临的数据不足的问题,因此可以应用在半监督学习,无监督学习,多视角、多任务学习的任务中。下面仅列出几个方面的应用。

人工智能举世瞩目的应用是在博弈中的应用。1997 年 IBM 公司的深蓝计算机系统击败国际象棋棋王卡斯帕罗夫,此后的十年里,人类与机器在国际象棋比赛上互有胜负,直到 2006 年棋王姆尼克被国际象棋软件深弗里茨(Deep Fritz)击败后,人类再也没有击败过计算机。2016 年 3 月,AlphaGo 以 4:1 战胜韩国棋手李世石,成为第一个击败人类职业围棋选手的计算机程序。2016 年 12 月,AlphaGo 身披“Master”马甲,5 天内横扫中日韩棋坛,以 60 场连胜纪录告退。2017 年 5 月,AlphaGo 在乌镇以 3:0 完胜柯洁。

与深蓝等其他博弈软件不同,AlphaGo 可以自己梳理决策模式,吸取比赛经验,并通过与自己下棋来强化学习。这是机器学习的重大进展。

8.7.4 生成对抗网络在图像处理中的应用

生成对抗网络最先被应用于图像处理领域,后被推广到语音处理和自然语言处理等。

作为一个生成模型,GAN 可以生成一些图像和视频,以及生成一些自然语句和音乐等。目前,GAN 应用最成功的领域是生成以假乱真的图像和视频、三维物体模型等,生成各种图像、数字、人脸等,如图像风格迁移、图像翻译、图像修复、图像上色、人脸图像编辑以及构成各种逼真的室内外场景,从物体轮廓恢复物体图像等。

(1) 超分辨率

这是一个能把低分辨率图像重建为高清图像的技术。在机器学习中,实现超分辨率(super resolution)需要用成对样本对系统进行训练:一个是原始高清图像,一个是降采样后的低分辨率图像。低分辨率图像输入到生成器,重建出高分辨率图像。目标函数由对抗损失函数和内容损失函数共同构成,其中,对抗损失函数通过训练判别器区分真实图片和由生成器进行超分辨率重构的图片,通过峰值信噪比和结构相似性等指标对重建图像进行评估,然后,重建图片和原始图片输入到判别器,判断哪一幅是原始图像。

(2) 图像修复

Denton 等将 GAN 应用到图像修复,以图像缺失部分的周边像素为条件训练生成式模型,生成完整的修复图像。利用对抗思想训练判别器对真实样本和修复样本进行判断。经对抗训练后,生成器所生成的修复图像与遮挡区块周边是连贯的,而且是符合语义的,如图 8.20 所示。

人脸图像去遮挡是图像修复的延伸应用,Zhao 等训练判别器区分真实无遮挡人脸图像和基于有遮挡图像而复原的人脸图像,能有效移除人脸图像中的遮挡物并用于人脸识别。GAN 应用于人脸图片编辑,如图 8.21 所示。





图 8.20 图像修复



图 8.21 人脸图像编辑

(3) 图像风格迁移

GAN 除了能够生成高质量的自然图像(如手写字体、卧室、人眼和人脸等)外,还能生成抽象的艺术作品。图 8.22 所示将 GAN 应用于图像风格迁移。其中图 8.22(f)是运用深度学习算法,根据 19 世纪英国著名画家特纳的作品《沉船》,将小镇变化成另一幅“作品”。



(a) 莫奈风格画→照片



(b) 斑马→马



(c) 照片→莫奈风格画



(d) 马→斑马



(e) 19世纪英国著名画家特纳的《沉船》



(f) 另一种风格的《沉船》

图 8.22 图像风格迁移

(4) 图像翻译

图 8.23 所示将 GAN 应用于根据地图生成航拍图像、根据轮廓图像生成照片、根据白天图像生成对应夜景等,大大增加了生成图像的多样性。由 Google 开发的 AI 算法 AutoDraw,可以根据艺术家制作的草图制作艺术作品,如图 8.23(b)所示。它基于自动完成原则工作,根据草图或艺术家的轮廓猜测所需的输出并提供艺术作品选项。人工智能将速度、效率和精度的古老技术原则带入艺术创作领域。



图 8.23 图像翻译

图 8.24 进一步将图像翻译拓展到多模态图像翻译,增加了生成图像的多样性。




图 8.24 多模态图像翻译

除了从二维图像到二维图像的翻译外,Gadelha 等提出的 PrGAN 能够以一种完全无监督的训练方式将给定的一系列甚至是一张 2D 图像翻译为该物体的 3D 体素形状和深度信息。

(5) 艺术创作

艺术和创意是人类思想的专属领域? 艺术将是人工智能正在“攻占”的下一个领域。人工智能已经闯入艺术和创意,在制作音乐、诗歌、歌曲等艺术品上取得不少成绩。音乐作曲家、画家或诗人等艺术家可以依靠 AI 来产生基本输出,然后再进行扩展或巩固。人工智能能够协助艺术家提高生产力和产出,加快创作来改变艺术产业。

图 8.25 所示是谷歌 AI 系统 Deep Dream 在计算机上创作的画作。



图 8.25 Deep Dream 的画作

2018 年 7 月,英国举办机器人艺术比赛 RobotArt,展示机器人研究领域的工程师如何开发会作画的机器人,即机器人像画家一样拿画笔作画,而不是在计算机中生成图像。比赛规则明确要求“上颜料或作画的动作必须由机器人系统使用一支或多支真实的画笔进行”。全球 19 个机器人团队共提交 100 多幅作品。图 8.26 所示是作画机器人用多支真实的画笔创作的作品。




图 8.26 机器人作画

8.7.5 生成对抗网络在语言处理中的应用

相对于在计算机视觉领域的应用,GAN 在语言处理领域的报道较少。这是由于图像和视频数据的取值是连续的,可直接应用梯度下降对可微的生成器和判别器进行训练,而语言生成

模型中的音节、字母和单词等都是离散值,难以直接应用到基于梯度的生成对抗网络。

1. 文本生成

人工智能不仅广泛用于体裁比较固定的新闻写作,而且能够进行诗歌写作等文学创作。

(1) 人工智能新闻系统

2014年3月17日清晨,梦乡中的洛杉矶市民被轻微的地面晃动惊醒。地震发生后不到3分钟,《洛杉矶时报》就报道了这次地震,不但提及了地震台网观测到的详细数据,还给出了旧金山区域近10天的地震观测情况。人们十分惊讶,为什么这则新闻如此神速?其实这要归功于人工智能新闻系统。在地震发生的瞬间,人工智能系统从地震台网的数据接口中获得地震信息,然后飞速生成英文报道全文。刚刚从睡梦中惊醒的记者看见屏幕上的报道文稿,快速审回,署名后点击发布,这则新闻就在第一时间面世了。

2011年,思科公司的工程师罗比·艾伦创办了 Automated Insights 公司,专门开发写作程序,用机器自动撰写新闻稿件。2013年,机器自动撰写的新闻稿件已达3亿篇,超过所有主要新闻机构的稿件产出量。2014年,稿件数量更是超过10亿篇,大大减轻人类记者和编辑的劳动强度。

(2) 诗歌创作系统

人工智能不仅广泛用于体裁比较固定的新闻写作,而且能够进行诗歌写作等文学创作。

“早春江上雨初晴,杨柳丝丝夹岸莺。画舫烟波双桨急,小桥风浪一帆轻。”谁能想到,这是清华大学孙茂松教授团队历时三年研发的人工智能诗歌创作系统“九歌”,以“早春”为关键词创作的一首诗。2017年4月在中央电视台《机智过人》公开亮相,把机器人创作的诗歌与文艺青年创作的诗歌放在一起让专家们辨别,结果机器人创作的诗歌更像人创作的。2017年9月九歌 V1.0 正式上线。


九歌人工智能诗歌创作系统输入了30多万首古诗作为语料库,利用深度学习模型让计算机学习。除了对诗句平仄、押韵规定外,并未人为给出任何规则,而是让计算机自己学习古诗中的“潜规则”。孙茂松教授说:每首古诗像一串项链,项链上的珠子就是字词。深度学习模型先把项链彻底打散,然后通过自动学习,将每颗珠子与其他珠子的隐含关联赋予不同权重。作诗时,再将不同珠子重穿成新项链。

2. 将文本翻译成图像


GAN 可以将文本翻译成图像。输入一段文字描述,计算机自动生成与文字描述相近的图片。相比从图像到图像的转换,从文本到图像的转换困难得多,因为以文本描述为条件的图像分布往往是高度多模态的,有太多的例子符合文本描述的内容,符合同样文本描述的生成图像之间差别可能很大。另一方面,虽然从图像生成文字也面临着同样问题,但由于文本能按照一定语法规则分解,因此,从图像生成文本是一个比从文本生成图像更容易定义的预测问题。

通过 GAN 的生成器和判别器分别进行文本到图像、图像到文本的转换,二者经过对抗训练后能够生成以假乱真的图像。例如根据文字“这只小鸟有着小小的鸟喙、胫骨和双足,蓝色的冠部和覆羽以及黑色的脸颊”生成图 8.27(a)所示的图片。输入“这朵花有着长长的粉色花

瓣和朝上的橘黄色雄蕊”,则输出图 8.27(b)所示的图片。



(a) 根据文字生成鸟的图片



(b) 根据文字生成花的图片

图 8.27 从文字描述生成图片

通过对输入变量进行可解释的拆分,能改变图像的风格、角度和背景。当然,目前所合成的图像尺寸依然较小,该研究的下一步工作是尝试合成像素更高的图像和增加文字所描述的特征数量。根据文本创作图像的方法可以验证生成模型模拟真实数据样本的性能。

8.7.6 生成对抗网络在视频生成中的应用

GAN 能从静态照片中生成多帧视频。首先,识别静态图片的对象,然后,生成 32 帧的视频,这些生成视频中对象的动作非常合乎常理。这种对动作的预测能力是机器未来融入人类生活的关键,因为这使机器能辨别什么动作于人于己都是没有伤害的。

(1) 实时 3D 变脸技术

南加州大学的 Pinscreen 团队以 GAN 等技术实现实时 3D 变脸技术。输入一张实验者的照片,GAN 变脸软件能够生成实验者的 3D 视频,并且通过软件控制 3D 视频中人物的动作,例如,眨眼、张嘴、微笑等。用生成的实验者的 3D 视频代替实验者本人能够通过刷脸测试。为了防止变脸技术造成的信息安全,美国国防部开发了 AI 侦测工具,识别是实验者本人的视频,还是计算机生成的实验者视频,反变脸精度达到 99%。

(2) 人工智能主持人

2018 年 11 月 7—9 日,在乌镇第五届世界互联网大会上,新华社对外宣布:中国首个“人工智能主持人”正式上岗,如图 8.28(a)所示。2019 年 2 月 19 日新华社又发布站立式合成主播上岗,如图 8.28(b)和图 8.28(c)所示。



(a) 邱浩——新小浩



(b) 邱浩——新小浩站立式



(c) 屈萌——新小萌站立式

图 8.28 人工智能主持人

真正的主持人主持一段节目,用3D扫描仪收集主持人主持节目的视觉数据,计算机生成的主持人化身看上去与其真正的主持人真假难辨。采集真正的主持人嗓音作为深度学习的输入数据,然后人工智能会学习嗓音特征,并能以主持人的嗓音生成新的内容——说话或者唱歌,并记录主体的行为和动作等个人数据,由此就可以再现他们的说话模式和性格特点。

8.7.7 生成对抗网络在医疗中的应用

人工智能在医疗中的应用是最有前景和最有价值的领域。

(1) 医学影像识别

基于深度学习等人工智能技术的X光、核磁、CT、超声等医疗影像多模态大数据分析技术,

提取二维或三维医疗影像隐含的疾病特征。例如,黑色素瘤识别:将1万张有标记的影像交给机器学习,然后让3名医生和计算机一起看另外的3000张影像。人的识别精度为84%,计算机的识别精度达到97%。

Schlegl 等将 GAN 用于医学图像的异常检测,通过学习健康数据集的特征能抽象出病变特征,例如,能够检测到测试样本中的视网膜积液,而这在训练样本集中并没有出现过。

(2) 药物匹配

Insilico Medicine 的研究人员提出了一种运用 GAN 进行药物匹配的方法。他们的目标是训练生成器,以尽可能精确地从一个药物数据库中对现有药物进行按病取药的操作。经过训练后,可以使用生成器获得一种以前不可治愈的疾病的药方,并使用判别器确定生成的药方是否治愈了特定疾病。

(3) 蛋白质结构预测

Alpha 系横扫世界围棋棋坛后,破解生命谜题再突破。2020年10月1日,国际蛋白质结构预测竞赛(CASP)宣布:谷歌 DeepMind 研制的 AlphaFold2,精确预测了单体蛋白质的三维结构。2021年8月 DeepMind 在 *Nature* 上公布 AlphaFold2 精确预测了来自人类和20种其他生物共35万种蛋白质的三维结构。

8.8 小 结

1. 人工神经网络的概念

神经元的数学模型由加权求和、线性动态系统和非线性函数映射三部分组成。

前馈型神经网络中,各神经元接受前一层的输入,并输出给下一层,没有反馈。

在反馈型神经网络中,存在一些神经元的输出经过若干个神经元后,再反馈到这些神经元的输入端。最典型的反馈型神经网络是 Hopfield 神经网络。它是全互连神经网络。

2. BP 神经网络的学习

神经网络的学习是指调整神经网络的连接权值或者结构,使输入与输出具有需要的特性。

Hebb 学习规则:当某一突触两端的神经元同时处于兴奋状态,那么该连接的权值应该增强。

存在一个三层 BP 神经网络,可以逼近任意的连续函数。BP 学习算法可以归纳为式(8.16)至式(8.18)。

3. Hopfield 神经网络及其改进

Hopfield 神经网络可能有若干个稳定状态。从任一初始状态开始运动,总可以达到某个稳定状态。这些稳定状态可以通过改变各个神经元之间的连接权值得到。

连续型 Hopfield 神经网络的电子线路实现如图 8.10 所示。

对于连续型 Hopfield 神经网络,若 $f^1(\cdot)$ 为单调递增的连续函数, $C_i > 0$, $w_{ij} = w_{ji}$, 则 $\frac{dE(t)}{dt} \leq 0$ 。

在随机神经网络中,神经元状态为 1 是随机的,服从一定的概率分布。例如,服从玻耳兹曼(Boltzmann)分布,从而构成玻耳兹曼机。

4. Hopfield 神经网络的应用

如果将 Hopfield 网络的稳态作为一个联想记忆问题的样本,那么初态朝稳态的收敛过程便是联想记忆的过程。

如果将 Hopfield 网络的稳态作为一个优化问题的目标函数的极小点,那么初态朝稳态的收敛过程便是优化计算的过程。

5. 卷积神经网络

卷积神经网络是一个多层的神经网络,每层由多个二维平面组成,每个平面由多个独立神经元组成。特征提取层 C 代表对输入图像进行滤波后得到的所有组成的层。和特征映射层 S 代表对输入图像进行下采样得到的层。

卷积神经网络使用 4 个关键技术来利用自然信号的属性:局部连接、权值共享、多卷积核以及池化的使用。

6. 神经胶囊网络

神经胶囊网络中胶囊不是传统神经网络中的一个神经元,而是一组神经元,其输入输出均为高维的活动向量,通过归一化处理,向量的“长度”可表示检测实体存在的概率,也就是向量的输出数值大小;向量的“方向”表示检测实体的各个属性,也就是向量的各个维度信息,表示的内容丰富,便于识别更加复杂多变的场景。

7. 生成对抗网络

生成对抗网络中包含生成器和判别器。使用对抗训练机制对生成器和判别器两个神经网络同时进行训练。

生成器的输入是一个来自常见概率分布的随机噪声矢量,输出是计算机生成的伪数据。

判别器的输入是图片(可能采样于真实数据,也可能采样于生成数据),判别器的输出是一个标量,用来代表是真实图片的概率。

GAN 应用最成功的领域是计算机视觉,包括图像和视频的生成,如图像翻译、图像超分辨率、图像修复、图像上色、人脸图像编辑以及视频生成等。

思考题

8.1 为什么说人工神经网络是一个非线性系统?如果 BP 神经网络中所有结点都为线性函数,那么,BP 神经网络还是一个非线性系统吗?

8.2 简述人工神经网络的知识表示形式和推理机制,试举例说明。

8.3 BP 学习算法是什么类型的学习算法?它主要有哪些不足?

8.4 Hopfield 神经网络分为哪两类?两者的区别是什么?

8.5 Hopfield 神经网络优化方法的基本步骤和主要特点是什么?

- 8.6 Hopfield 神经网络与 BP 神经网络结构有什么区别?
- 8.7 简述卷积神经网络的学习机理。
- 8.8 简述卷积神经网络的结构。
- 8.9 什么是卷积神经网络中的局部连接?
- 8.10 什么是卷积神经网络中的权值共享?
- 8.11 为什么要采用多卷积核?
- 8.12 什么是卷积神经网络中的池化? 常用的有哪些方法? 池化过程有什么缺点?
- 8.13 简述生成对抗网络的结构和基本原理。
- 8.14 为什么生成对抗网络中的生成网络能够生成以假乱真的图片?

习 题

- 8.1 验证下列神经网络描述了与逻辑关系,如图 8.29 所示。其中 $y = \begin{cases} 1 & x \geq \theta \\ 0 & x < \theta \end{cases}$ 。




图 8.29 用神经网络表示与逻辑

- 8.2 异或 (Exclusive-OR) (XOR) 问题可以用 4 条产生式规则表示:

IF $x_1 = 0$ AND $x_2 = 0$ THEN $y = 0$

IF $x_1 = 0$ AND $x_2 = 1$ THEN $y = 1$

IF $x_1 = 1$ AND $x_2 = 0$ THEN $y = 1$

IF $x_1 = 1$ AND $x_2 = 1$ THEN $y = 0$

验证异或问题可以表示为图 8.30 中的神经网络: 其中 $f(x) = \begin{cases} 1 & x \geq \theta \\ 0 & x < \theta \end{cases}$ 。




图 8.30 用神经网络表示异或问题

8.3 给定样本为 $X=[1,-1,1]$, $Y=[1,1]$, 选 $\varepsilon=0.1$, BP 神经网络的初始权值矩阵选为

$$W_1 = \begin{bmatrix} 1 & 1 & 1 \\ 2 & 0 & 2 \\ 3 & 3 & -3 \end{bmatrix}, \quad W_2 = \begin{bmatrix} 1 & -1 & 1 \\ 0 & 1 & 1 \end{bmatrix}$$

如图 8.31 所示。




图 8.31 BP 神经网络

隐含层和输出层的神经元的输入与输出非线性函数取为 $f(x) = \frac{2}{1+e^{-x}} - 1$ 。试用 BP 学习算法计算权值的调整过程。

8.4 已知下列函数：

- ① $f(x) = \frac{1}{x}, 1 \leq x \leq 100$ 。
- ② $f(x) = \lg x, 1 \leq x \leq 10$ 。
- ③ $f(x) = e^{-x}, 1 \leq x \leq 10$ 。
- ④ $f(x) = \sin x, 1 \leq x \leq \frac{\pi}{2}$ 。

利用 BP 算法及 Sigmoid 函数, 对上面的函数完成如下工作。

- ① 获取两组数据, 一组作为训练集, 一组作为测试集。
- ② 利用训练集, 训练一个单隐含层的网络。
- ③ 利用测试集检验训练结果, 改变隐含层神经元个数, 研究它对逼近效果的影响。




图 8.32 字母样本

8.5 用三层 BP 神经网络解决字母 T 和 L 的识别问题。如图 8.32 所示, 每个字母用 3×3 的二维二值图表示, 令黑方格为 1, 白方格为 0, 每个字母有 4 个样本, 包括字母正常位置及旋转 90° 、 180° 和 270° 的图像, 希望输入不同的位置下的 T 时, 网络输出为 1, 而输入不同的位置下的 L 时, 网络输出为 0。用 BP 算法求出权系数和阈值

(建议:选择网络结构为9-3-1。隐单元非线性函数为 $f(x)=\frac{2}{1+e^{-\alpha x}}-1$,输出单元非线性函数为 $f(x)=\frac{1}{1+e^{-\alpha x}}$)。

8.6 澳大利亚野兔眼睛晶状体的质量与其年龄的关系如表8.3所示。不能用一个单值函数表示之间的关系,可以用如下非线性最小平方模型描述:

$$Y = 233.846[1 - \exp(-0.006042x)] + \varepsilon$$

其中, ε 是误差项。试利用反向传播算法,设计一个BP神经网络,能够为这个数据集提供一个非线性最小平方逼近,并与上述最小平方模型比较结果。

表8.3 澳大利亚野兔眼睛晶状体质量与其年龄的关系

年龄/天	质量/mg	年龄/天	质量/mg	年龄/天	质量/mg	年龄/天	质量/mg
15	21.66	75	94.6	218	174.18	338	203.23
15	22.75	82	92.5	218	173.03	347	188.38
15	22.3	85	105	219	173.54	354	189.7
18	31.25	91	101.7	224	178.86	357	195.31
28	44.79	91	102.9	225	177.68	375	202.63
29	40.55	97	110	227	173.73	394	224.82
37	50.25	98	104.3	232	159.98	513	203.3
37	46.88	125	134.9	232	161.29	535	209.7
44	52.03	142	130.68	237	187.07	554	233.9
50	63.47	142	140.58	246	176.13	591	234.7
50	61.13	147	155.3	258	183.4	648	244.3
60	81	147	152.2	276	186.26	660	231
61	73.09	150	144.5	285	189.66	705	242.4
64	79.09	159	142.15	300	186.09	723	230.77
65	79.51	165	139.81	301	186.7	756	242.57
65	65.31	183	153.22	305	186.8	768	232.12
72	71.9	192	145.72	312	195.1	860	246.7
75	86.1	195	161.1	317	216.41		

8.7 已知有3个神经元的离散Hopfield神经网络的权值矩阵为

$$W = \begin{bmatrix} 0 & 1 & -2 \\ 1 & 0 & 3 \\ -2 & 3 & 0 \end{bmatrix}, \quad \theta = \begin{bmatrix} -1 \\ 2 \\ 1 \end{bmatrix}$$

计算该神经网络当状态为 $V(0) = \{1, 0, 1\}$ 时的能量。

8.8 已知有 4 个神经元的离散 Hopfield 神经网络的权值矩阵为

$$W = \begin{bmatrix} 0 & 2.8 & 2.5 & -2.6 \\ 2.8 & 0 & 4.5 & -1.1 \\ 2.5 & 4.5 & 0 & -5.5 \\ -2.6 & -1.1 & -5.5 & 0 \end{bmatrix}, \quad \theta = \begin{bmatrix} 5.2 \\ -3.2 \\ -1.6 \\ -7.6 \end{bmatrix}$$

计算该神经网络当状态为 $V(0) = \{1, 0, 1, 0\}$ 时的能量。

8.9 已知只有 3 个神经元的离散型 Hopfield 神经网络的权值矩阵为

$$W = \begin{bmatrix} 0 & -\frac{2}{3} & \frac{2}{3} \\ -\frac{2}{3} & 0 & -\frac{2}{3} \\ \frac{2}{3} & -\frac{2}{3} & 0 \end{bmatrix}$$

3 个神经元的阈值取为 0。因为有 3 个神经元, 所以有 $2^3 = 8$ 个状态。试计算验证: $(1, -1, 1)$ 和 $(-1, 1, -1)$ 是稳定状态, 其他状态都会收敛到与之邻近的稳定状态上。

8.10 已知有 4 个神经元的离散型 Hopfield 神经网络的权值矩阵为

$$W = \begin{bmatrix} 0 & 3.4 & 2.8 & -3.1 \\ 3.4 & 0 & 4.7 & -1.2 \\ 2.8 & 4.7 & 0 & -5.9 \\ -3.1 & -1.2 & -5.9 & 0 \end{bmatrix}$$

4 个神经元的阈值取为 $(6.3, -4.3, -2.5, -9.6)$ 。任意给定一个初始状态 $V(0) = \{1, 0, 1, 0\}$, 计算这个状态的能量, 确定一个稳定状态。

读一读

人工神经网络创立者麦卡洛克、皮茨和罗森布拉特

麦卡洛克(W. S. McCulloch)和皮茨(W. Pitts)1943年在《数学生物物理期刊》上发表“A Logical Calculus of Ideas Immanent in Nervous Activity”论文,开创了人工神经网络的研究。

皮茨小时候就很喜欢数学和哲学,初中时还读过罗素的《数学原理》,并和罗素通信。罗素很爱才,邀请他到英国跟随自己学习逻辑。但皮茨家贫连高中都读不起,更不可能去英国留学。他十五岁时,他父亲强行要他退学上班,皮茨一怒就离家出走了。他打听到罗素在芝加哥大学任教,就只身来到芝加哥见罗素。罗素把他推荐给也在芝加哥任教的卡尔纳普。卡尔纳普把自己的《语言的逻辑句法》一书送给皮茨。没过一个月,皮茨就看完了,把写满笔记的原书还给卡尔纳普。卡尔纳普非常吃惊,于是给他在芝加哥大学安排了份打扫卫生的工作,能够让他继续研究。皮茨后来结识了麦卡洛克。皮茨于1969年离世,年仅46岁。

麦卡洛克的本科在耶鲁大学学哲学和心理学,后在哥伦比亚获得了心理学硕士和医学博士学位。毕业后做了几年实习医生,先去了耶鲁大学研究神经生理学,后又去了伊利诺伊大学芝加哥分校,做精神病学系的教授。麦卡洛克的强项是神经科学,但不懂数学,他和十七岁的数学天才皮茨是绝配,两人共同开创了人工神经网络的研究。

罗森布拉特(Frank Rosenblatt, 1928—1971)出生在纽约,父亲是医生,其1956年在Cornell大学拿到博士学位后,留校任教,研究方向为心理学和认知心理学。1957年,罗森布拉特提出了感知机的理论。1960年,在计算机运算能力还不强的时候,其使用基于硬件结构搭建了一个人工神经网络。

1958年夏,罗森布拉特受到美国海军的经费资助,并召开新闻发布会。《纽约时报》抓住了发布会的要点:海军透露了一种电子计算机的雏形,它将能够走路、说话、看、写、自我复制并感知到自己的存在……据预测,不久以后,感知机将能够识别出人并叫出他们的名字,立即把演讲内容翻译成另一种语言并写下来。

但是和所有先驱一样,罗森布拉特开创性的工作受到质疑。特别是当时两位科学家Marvin Minsky和Seymour Papert特地写了一本书*Perceptron*批判感知机,导致人工智能沉寂了将近20年。罗森布拉特没能渡过AI的寒冬。1971年,他在43岁生日那天,在切萨皮克湾(Chesapeake Bay)乘单桅帆船出海时溺水身亡。直到20世纪80年代BP算法的提出,再度掀起人工神经网络的研究热潮。

虽然感知机最终并没有走路或说话,它几乎不能分辨出左边和右边,但从现在来看这个设想,就能看出罗森布拉特的预见性了。2004年IEEE Frank Rosenblatt Award成立,罗森布拉特被尊称为神经网络的创立者。

读一读

诺贝尔物理学奖得主霍普菲尔德

瑞典皇家科学院 2024 年 10 月 8 日宣布,将 2024 年诺贝尔物理学奖授予约翰·霍普菲尔德(John J. Hopfield)和杰弗里·辛顿(Geoffrey E. Hinton),表彰他们在使用人工神经网络进行机器学习的基础性发现和发明。两位获奖者从 20 世纪 80 年代起就开展了与物理学相关的人工神经网络的重要工作。这是人工智能成果获得的第一项诺贝尔奖。

霍普菲尔德 1933 年 7 月 15 日在美国伊利诺伊州芝加哥出生。1954 年,获得宾夕法尼亚州斯沃斯莫尔学院物理学学士学位。1958 年,获得美国康奈尔大学物理学博士学位;同年,成为贝尔电话实验室理论物理组技术人员,正式开始了固体物理学家的职业生涯。1961—1964 年,在加州大学伯克利分校做物理学副教授。1964—1980 年,在普林斯顿大学做物理学教授。1980—1996 年,在加州理工学院化学与生物学教授。自 1997 年起,约翰·霍普菲尔德担任普林斯顿大学教授。2006 年,担任美国物理学会(APS)主席。

1968 年,约翰·霍普菲尔德获得古根海姆奖学金,此时约翰·霍普菲尔德已是一位知名的理论物理学家,也是光与固体相互作用方面的权威。在剑桥大学卡文迪什实验室获得古根海姆奖学金后返回美国后,霍普菲尔德完全改变了他的研究领域,转向物理学和生物学的交叉领域。1969 年,约翰·霍普菲尔德荣获美国物理学会奥利弗·E·巴克利凝聚态物质奖。1971 年,成为总统科学咨询委员会(PSAC)战略军事小组成员。1973 年,成为贝尔电话实验室分子生物物理学组技术人员。1974 年,霍普菲尔德对遗传学领域做出了重大贡献,证明基因表达中存在的高精度可以通过称为“动力学校对”的偶联化学反应来解释。1982 年和 1984 年,霍普菲尔德先后提出离散型 Hopfield 神经网络和连续型 Hopfield 神经网络,来解释大脑如何回忆记忆。

第9章

循环神经网络与自然语言理解

语言理解是人工智能皇冠上的明珠。如果计算机能够理解、处理自然语言,这将是计算机技术的一项重大突破。自然语言理解的研究在应用和理论两个方面都具有重大的意义。深度学习的发展促进了自然语言理解的迅猛发展。

本章首先介绍自然语言理解的概念以及发展历史,然后介绍循环神经网络和长短记忆神经网络,最后从应用角度介绍机器翻译和语音识别技术。

9.1 自然语言理解的概念与发展历史

由于自然语言具有多义性、上下文相关性、模糊性、非系统性、环境相关性等,因此,自然语言理解(natural language understanding)至今尚无一致的定义。

从微观角度,自然语言理解是指从自然语言到机器内部的一个映射。

从宏观角度,自然语言理解是指机器能够执行人类所期望的某种语言功能。这些功能主要包括如下几方面。

- ① 回答问题。计算机能正确地回答用自然语言输入的有关问题。
- ② 文摘生成。机器能产生输入文本的摘要。
- ③ 释义。机器能用不同的词语和句型来复述输入的自然语言信息。
- ④ 翻译。机器能把一种语言翻译成另外一种语言。

自然语言理解的研究历程,可以分为下列几个时期。

1. 萌芽时期

自然语言理解的研究可以追溯到20世纪40年代末和50年代初期。随着第一台计算机问世,英国的A. Donald Booth和美国的W. Weaver就开始了机器翻译方面的研究。美国、苏联等国展开的俄、英互译研究工作开启了自然语言理解研究的早期阶段。

1957年,美国语言学家Noam Chomsky(诺姆·乔姆斯基)的《句法结构》出版,书中颠覆了行为主义,认为反馈理论不能解释儿童为什么能够理解和构造他们以前没有听到的句子,而Chomsky关于语法模型的理论则能够解释这个现象,并且能够形式化。

在这一时期,M. Chomsky提出了形式语言和形式文法的概念,把自然语言和程序设计语言

置于相同的层面,用统一的数学方法来解释和定义。M. Chomsky 建立了转换生成文法,使语言学的研究进入了定量研究的阶段。Chomsky 所建立的文法体系,仍然是目前自然语言理解中文法分析所必须依赖的文法体系,但还不能处理复杂的自然语言问题。

Chomsky 的影响一直持续到 20 世纪 80 年代末,解决了语言和思维是如何联系的问题。由于 20 世纪 50 年代单纯地使用规范的文法规则,再加上当时计算机处理能力的低下,使得机器翻译工作没有取得实质性进展。

2. 以关键词匹配技术为主的时期

从 20 世纪 60 年代开始,已经产生一些自然语言理解系统,用来处理受限的自然语言子集。但这些系统大都没有真正意义上的文法分析,而主要依靠关键词匹配技术来识别输入句子的意思。1968 年,美国 MIT 的 B. Raphael 完成的语义信息检索系统 SIR,能记住用户通过英语告诉它的事实,然后对这些事实进行演绎,回答用户提出的问题。美国 MIT 的 J. Weizenbaum 设计的 ELIZA 系统,能模拟一位心理医生(机器)同一位患者(用户)的谈话。在这些系统中,事先存放了大量包含某些关键词的模式,每个模式都与一个或多个解释(又叫响应式)相对应。系统将当前输入的句子同这些模式逐个匹配,一旦匹配成功便立即得到了这个句子的解释,而不再考虑句子中那些非关键词成分对句子意思的影响。所以,基于关键词匹配的理解系统并非真正的自然语言理解系统,它既不懂文法,又不懂语义,只是一种近似匹配技术。

3. 以句法-语义分析技术为主的时期

20 世纪 70 年代后,自然语言理解的研究在句法-语义分析技术方面取得了重要进展,出现了若干有影响的自然语言理解系统。例如,1972 年美国 BBN 公司 W. Woods 负责设计的 LUNAR,是第一个允许用户用普通英语同计算机对话的人机接口系统,用于协助地质学家查找、比较和评价阿波罗 11 飞船带回来的月球标本的化学分析数据;同年,T. Winograd 设计的 SHEDLU 系统,是一个在“积木世界”中进行英语对话的自然语言理解系统,把句法、推理、上下文和背景知识灵活地结合于一体,模拟一个能够操纵桌子上一些积木玩具的机器人手臂,用户通过人机对话方式命令机器人放置那些积木块,系统通过屏幕给出回答并显示现场的相应情景。

4. 基于知识的自然语言理解发展时期

20 世纪 80 年代后,自然语言理解研究借鉴了许多人工智能和专家系统中的思想,引入了知识的表示和推理机制,使自然语言处理系统不再局限于单纯的语言句法和词法的研究,提高了系统处理的正确性,从而出现了一批商品化的自然语言人机接口和机器翻译系统。例如,美国人工智能公司(AIC)生产的英语人机接口 Intellect,美国弗雷公司生产的 Themis 人机接口。在自然语言理解研究的基础上,机器翻译走出了低谷,出现了一些具有较高水平的机器翻译系统。例如,美国的 META 系统,美国乔治敦大学的机译系统 SYSTRAN,欧共体在其基础上实现了英、法、德、西、意及葡等多语对译。

5. 基于大规模语料库的自然语言理解发展时期

由于自然语言理解中知识的数量巨大,特别是它们高度的不确定性和模糊性,要想把处理

自然语言所需的知识都用现有的知识表示方法明确表达出来是不可能的。为了处理大规模的真实文本,研究人员提出了语料库语言学(corpus linguistics)。语料库语言学认为语言学知识的真正源泉是来自于生活中大规模的资料,我们的任务是使计算机能够自动或半自动地从大规模语料库中获取处理自然语言所需的各种知识。

20世纪80年代,英国Leicester大学Leech领导的UCREL研究小组,利用已带有词类标记的语料库,经过统计分析得出了一个反映任意两个相邻标记出现频率的“概率转移矩阵”。他们设计的CLAWS系统依据这种统计信息(而不是系统内存储的知识),对LOB语料库的一百万词的语料进行词类的自动标注,准确率达96%。

6. 基于深度学习与大语言模型的自然语言理解发展时期

基于深度学习和大语言模型的自然语言理解研究近年来取得了显著进展,其核心突破体现在模型架构优化、多模态融合、领域专业化及伦理透明性提升等方面。

多模态大语言模型通过整合文本、图像和音频数据,增强了模型对跨模态信息的理解能力。推动自然语言理解进入更高维度。例如,在视觉问答(VQA)和图像描述生成任务中,多模态大语言模型能够更准确地捕捉语义关联,推动了人机交互的自然化发展。大语言模型通过更大规模的预训练数据和更高效的架构设计,显著提升了语言理解能力。稀疏注意力机制、模型蒸馏和量化等技术,能够使大语言模型在资源受限的设备上高效运行,降低计算成本,提高模型在复杂任务中的性能。

目前,自然语言理解将进一步结合机器学习、实时交互和跨语言能力,研究多语言大模型以消除多种语言翻译中的文化隔阂。虽然市场上已经出现了一些可以进行一定自然语言处理的商品软件,但要让机器像人类那样自如地运用自然语言,仍是一项长远而艰巨的任务。

9.2 语言处理过程的层次

语言虽然表示成一连串文字符号或一串声音流,但其内部是一个层次化的结构,从语言的构成中就可以清楚地看出这种层次性。文字表达的句子层次是“词素→词或词形→词组或句子”,而声音表达的句子层次是“音素→音节→音词→音句”,其中每个层次都受到语法规则的制约。因此,语言的处理过程也应当是一个层次化的过程。

许多现代语言学家把语言处理过程分为三个层次:词法分析、句法分析、语义分析。如果接收到的是语音流,那么在上述三个层次之前还应当加入一个语音分析层。对于更高层次的语言处理,在进行语义分析后,还应该进行语用分析。虽然这样划分的层次之间并非是完全隔离的,但这种层次化的划分更好地体现了语言本身的构成,并在一定程度上使得自然语言处理系统的模块化成为可能。

1. 词法分析

词法分析是从句子中切分出单词,找出词汇的各个词素,从中获得单词的语言学信息并确定单词的词义。

不同的语言对词法分析有不同的要求。例如,英语和汉语就有较大的差距。在英语等语言中,因为单词之间是以空格自然分开的,切分一个单词很容易,所以找出句子的各个词汇就很方便。但是,由于英语单词有词性、数、时态、派生及变形等变化,要找出各个词素就复杂得多,需要对词尾或词头进行分析。例如,importable 可以是 im-port-able 或 import-able,这是因为 im,port,able 这三个都是词素。词法分析可以从词素中获得许多有用的语言学信息,这些信息对于句法分析是非常有用的。例如,英语中构成词尾的词素 s 通常表示名词复数或动词第三人称单数,ly 通常是副词的后缀,而 ed 通常是动词的过去分词等。另一方面,一个词可以有许多的派生、变形。例如 work 可变化出 works,worked,working,worker,workable 等。如果将这些派生的、变形的词全放入词典,将会产生非常庞大的数据量。实际上它们的词根只有一个。自然语言理解系统中的电子词典一般只放词根,并支持词素分析,这样可以大大压缩电子词典的规模。

在汉语中,每个字就是一个词素,所以要找出各个词素是相当容易的,但要切分出各个词就非常困难,不仅需要构词的知识,还需要解决可能遇到的切分歧义,如“优秀人才学人才学”,可以是“优秀人才-学人才学”,也可以是“优秀人-才学人才学”。又如组合歧义,“把-手-放在-桌上”,可以是“把手-放在-桌上”;交叉歧义,“我们-研究所-有-东西”,可以是“我们-研究-所有-东西”。

2. 句法分析

句法分析是对句子或短语结构进行分析,以确定构成句子的各个词、短语之间的关系以及各自在句子中的作用等,将这些关系用层次结构加以表达,并对句法结构进行规范化。

在计算机科学中,形式语言是某个字母表上一些有限字串的集合,而形式文法是描述这个集合的一种方法。形式文法与自然语言中的文法相似。最常见的文法分类是乔姆斯基(N. Chomsky)在 1950 年根据形式文法中所使用的规则集提出的。他定义了下列四种形式的文法:短语结构文法,又称 0 型文法;上下文有关文法,又称 1 型文法;上下文无关文法,又称 2 型文法;正则文法,又称 3 型文法。型号愈高所受约束愈多,能表达的语言集就越小,也就是说型号越高描述能力就越弱。但由于上下文无关文法和正则文法能够高效率地实现,成为四类文法中最重要的两种文法类型。

3. 语义分析

句法分析后一般还不能理解所分析的句子,至少还需要进行语义分析。语义分析是把分析得到的句法成分与应用领域中的目标表示相关联。简单的做法就是依次使用独立的句法分析程序和语义解释程序。但这样做使得句法分析和语义分析分离,在很多情况下无法决定句子的结构。为有效地实现语义分析,并能与句法分析紧密结合,已经提出了多种语义分析方法,如语义文法和格文法。

语义文法是将文法知识和语义知识组合起来,以统一的方式定义为文法规则集。语义文法不仅可以排除无意义的句子,而且具有较高的效率,对语义没有影响的句法问题可以忽略。但是实际应用该文法时需要很多的文法规则,因此一般适用于受到严格限制的领域。

格语法是为了找出动词和跟动词处在结构关系中的名词的语义关系,同时也涉及动词或动词短语与其他各种名词短语之间的关系。也就是说,格语法的特点是允许以动词为中心构造分析结果。格语法是一种有效的语义分析方法,有助于删除句法分析的歧义性,并且易于使用。

4. 语音分析

构成单词发音的最小独立单元是音素。对于一种语言,如英语,必须将声音的不同单元识别出来并分组。在分组时,应该确保语言中的所有单词都能被区分,两个不同的单词最好由不同的音素组成。

语音分析是根据音位规则,从语言流中区分出各个独立的音素,再根据音位形态规则找出各个音节及其对应的词素或词。

词语以声波传送。语音分析系统传送声波这种模拟信号,并从中抽取诸如能量、频率等特征。然后,将这些特征映射为称作音素的单个语音单元。最后将音素序列转换成单词序列。

语音的产生是将单词映射为音素序列,然后传送给语音合成器,单词的声音通过说话者从语音合成器发出。

5. 语用分析

语用分析就是研究语言所存在的外界环境对语言使用所产生的影响,是自然语言理解中更高层次的内容。

9.3 循环神经网络

9.3.1 循环神经网络的概念

BP神经网络和卷积神经网络等前馈神经网络都是从输入层到隐含层再到输出层,所以无法处理序列数据建模问题。例如,要预测句子的下一个单词是什么,一般需要用到前面的单词,因为一个句子中前后单词并不是独立的。例如, x_{t-1}, x_t, x_{t+1} 是输入, y_{t-1}, y_t, y_{t+1} 是输出,如果输入“我是中国”,即 x_{t-1} = 我, x_t = 是, x_{t+1} = 中国,那么 y_{t-1} = 是, y_t = 中国这两个词,需要预测下一个词 y_{t+1} 最有可能是什么? 应该是“人”的概率比较大。

如果希望前面距离任意远的网络输入对之后的输出产生影响,可以使用循环神经网络。由于语言具有这样的特性,因此,RNN 通常用于与语言相关的任务,特别是语言建模。这里假设输入是当前单词 w_t 的嵌入向量,预测词 w_{t+1} ,损失是标准交叉熵损失。

循环神经网络起源于 Hopfield 神经网络。Hopfield 神经网络具有递归特性,每一个神经元的输入来自其他所有神经元的输出,它的输出又传递给其他所有的神经元,但自身没有反馈连接。

1986年,Michael I. Jordan 提出了第一个真正意义上的循环神经网络 Jordan network,实现了序列数据的回归,从而开启了循环神经网络的研究。1990年,Jeffrey I. Elman 简化了 Jordan

network 的结构,提出 Elman network,成为目前循环神经网络的主流形式。

在某种意义上,RNN 是前馈神经网络的对立面。RNN 中的输出也是输入的一部分,正是这个循环使其成为 RNN 而非前馈神经网络。就是说,RNN 是一个有向循环图,而前馈神经网络是有向非循环图。

循环神经网络(recurrent neural network,RNN)是一种对序列数据建模的神经网络,即一个序列当前的输出与前面的输出也有关,会对前面的信息进行记忆并应用于当前输出的计算中。RNN 的连接如图 9.1 所示。




图 9.1 RNN 的结构图

在图 9.1 中,每个圆圈可以看作是一个单元,而且每个单元做的事情也是一样的,因此可以折叠成左半图的形式。

RNN 整体结构就是其中一个单元网络结构重复使用的结果,所以称为循环神经网络。相比普通的神经网络,循环神经网络的不同之处在于:RNN 的隐含层之间的结点是有连接的,并且隐含层的输入不仅包括输入层的输出还包括上一时刻隐含层的输出。这使得 RNN 可以通过循环反馈连接保留前面所有时刻的信息,这赋予了 RNN 的记忆功能。这些特点使 RNN 非常适合用于对时序信号的建模。

9.3.2 循环神经网络的训练

循环神经网络的训练是一种基于时间的反向传播算法(bach propagation through time,BPTT)。BPTT 算法是针对循环层设计的训练算法,它的基本原理和 BP 算法是一样的,也包含同样的三个步骤:

- (1) 前向计算每个神经元的输出值;
- (2) 反向计算每个神经元的误差项值,它是误差函数 E 对神经元 j 的加权输入的偏导数;
- (3) 计算每个权值的梯度,用随机梯度下降算法更新权值。

假设时刻为 t 时,输入为 x_t ,隐含层状态为 h_t 。 h_t 不仅和当前时刻的输入 x_t 有关,也和上一个时刻的隐含层状态 h_{t-1} 有关。

$$z_t = Uh_{t-1} + Wx_t + b \quad (9.1)$$

$$\mathbf{h}_t = f(\mathbf{z}_t) \quad (9.2)$$

或者

$$\mathbf{h}_t = f(\mathbf{U}\mathbf{h}_{t-1} + \mathbf{W}\mathbf{x}_t + \mathbf{b}) \quad (9.3)$$

其中, $\mathbf{z}_t$ 为隐含层的输入; $f(\cdot)$ 是非线性激励函数; $\mathbf{U}$ 为状态-状态权重矩阵; $\mathbf{W}$ 为状态-输入权重矩阵; $\mathbf{b}$ 为偏置。

在一般神经网络中, 每一个网络层的参数不是共享的。而在 RNN 中, 所有层均共享同样的参数 $\mathbf{W}$ 、 $\mathbf{U}$ 、 $\mathbf{b}$, 只是输入不同, 因此大大地减少了网络中需要学习的参数。

9.3.3 循环神经网络的递归过程

从循环神经网络的结构特征可以看出, 它适合解决与时间序列相关的问题。可以将一个序列上不同时刻的数据依次传入循环神经网络的输入层, 而输出可以是对序列中下一个时刻的预测, 也可以是对当前时刻信息的处理结果。循环神经网络要求每一个时刻都有一个输入, 但是不一定每一个时刻都需要有输出。

循环神经网络可以往前看获得任意多个输入值, 其递归推导方法如式(9.4)所示, 即 RNN 的输出层 $\mathbf{y}$ 和隐含层 $\mathbf{h}$ 的计算方法:

$$\mathbf{y}_t = g(\mathbf{V}\mathbf{h}_t) \quad (9.4)$$

如果反复把式(9.3)带入到式(9.4), 得

$$\begin{aligned} \mathbf{y}_t &= g(\mathbf{V}\mathbf{h}_t) \\ &= g(\mathbf{V}f(\mathbf{W}\mathbf{x}_t + \mathbf{U}\mathbf{h}_{t-1} + \mathbf{b})) \\ &= g(\mathbf{V}f(\mathbf{W}\mathbf{x}_t + \mathbf{U}f(\mathbf{W}\mathbf{x}_{t-1} + \mathbf{U}\mathbf{h}_{t-2} + \mathbf{b}_{t-1}) + \mathbf{b})) \\ &= g(\mathbf{V}f(\mathbf{W}\mathbf{x}_t + \mathbf{U}f(\mathbf{W}\mathbf{x}_{t-1} + \mathbf{U}f(\mathbf{W}\mathbf{x}_{t-2} + \mathbf{U}\mathbf{h}_{t-3} + \mathbf{b}_{t-2}) + \mathbf{b}_{t-1}) + \mathbf{b})) \\ &= g(\mathbf{V}f(\mathbf{W}\mathbf{x}_t + \mathbf{U}f(\mathbf{W}\mathbf{x}_{t-1} + \mathbf{U}f(\mathbf{W}\mathbf{x}_{t-2} + \mathbf{U}f(\mathbf{W}\mathbf{x}_{t-3} + \cdots) + \mathbf{b}_{t-2}) + \mathbf{b}_{t-1}) + \mathbf{b})) \end{aligned} \quad (9.5)$$

从上述递归推导可以看出, RNN 的输出层 $\mathbf{y}$ 和输入系列 $\mathbf{x}_t$ 的前 t 个时刻都有关。

9.4 长短期记忆神经网络

循环神经网络的主要缺点是长期依赖问题。最有效的解决方法是进行选择性的遗忘, 同时也进行有选择的更新。1997 年, Hochreiter 和 Schmidhuber 提出的长短期记忆神经网络(long short-term memory neural network, LSTM), 是一种 RNN 特殊的类型, 使用“累加”的形式计算状态, 这种累加形式导致导数也是累加形式, 因此避免了梯度消失, 得到了广泛应用。

LSTM 的性能几乎总是优于 RNN, 但训练需要更长的时间。LSTM 的目标是通过训练 RNN 记住主要内容, 忘记其他琐碎细节, 提高 RNN 对过去事件的记忆。

所有循环神经网络都有一个重复结构的模型形式。在标准的 RNN 中, 重复的结构是一个简单的循环体, 如图 9.2 所示的体。然而 LSTM 的循环体是一个拥有四个相互关联的全连接前

馈神经网络的复制结构,如图 9.3 所示。




图 9.2 循环神经网络重复结构




图 9.3 LSTM 结构

LSTM 利用三个门(gate)操作来管理和控制神经元的状态信息。

(1) 遗忘门

LSTM 的第一步是用遗忘门(forget gate layer)确定从上一个时刻的状态中丢弃什么信息。

遗忘门是一个具有 Sigmoid 全连接的前馈神经网络,如图 9.4 所示。遗忘门的输入是 h_{t-1} 和 x_t 组成的向量,输出是向量 f_t 。向量 f_t 是由 1 和 0 组成,1 表示能够通过,0 表示不能通过。其函数式为

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \tag{9.6}$$

(2) 输入门

LSTM 的第二步用输入门(input gate layer)确定哪些输入信息要保存到神经元的状态中。

输入门是由两个前馈神经网络组成,如图 9.5 所示。第一个有 Sigmoid 层的全连接前馈神经网络,决定哪些值将被更新;第二个有 Tanh 层的全连接前馈神经网络,其输出是一个向量 C_t , C_t 向量可以被添加到当前时刻的神经元状态中;最后根据两个神经网络的结果创建一个新的神经元状态。其函数关系为

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad (9.7)$$

$$C_t = \text{Tanh}(W_c[h_{t-1}, x_t] + b_c) \quad (9.8)$$




图 9.4 LSTM 的遗忘门图




图 9.5 LSTM 的输入门

(3) 状态控制

第三步就可以更新上一时刻的状态 C_{t-1} 为当前时刻的状态 C_t 了。

通过第一步的遗忘门得到的控制向量,过滤掉一部分 C_{t-1} 信息,如图 9.6 所示的乘法操作;通过第二步的输入门根据输入向量计算新状态,通过这个新状态和 C_{t-1} 状态构建一个新的状态 C_t ,如图 9.6 所示的加法操作。其函数关系为:

$$C_t = f_t C_{t-1} + i_t \tilde{C}_t \quad (9.9)$$

(4) 输出门

最后一步就是用输出门(output gate layer)确定神经元的输出向量 h_t 。LSTM 的输出门如图 9.7 所示。




图 9.6 LSTM 状态控制图




图 9.7 LSTM 的输出门

首先通过 Sigmoid 层生成一个过滤向量;然后通过一个 Tanh 函数计算当前时刻的 C_t 状态向量,即将向量每个值的范围变换到 $[-1, 1]$ 之间。其函数关系为

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (9.10)$$

$$h_t = o_t \text{Tanh}(C_t) \quad (9.11)$$

9.5 机器翻译

9.5.1 机器翻译方法概述

人类对机器翻译(machine translation, MT)系统的研究开发已经持续了 50 多年。起初,机器翻译系统主要是基于双语字典进行直接翻译,几乎没有句法结构分析。直到 20 世纪 80 年代,一些机器翻译系统采用了间接方法。在这些方法中,源语言文本被分析转换成抽象表达形式,随后利用一些程序,通过识别词结构(词法分析)和句子结构(句法分析)解决歧义问题。其中有一种方法将抽象表达设计为一种与具体语种无关的“中间语言”,可以作为许多自然语言的中介。这样,翻译就分成两个阶段:从源语言到中间语言,从中间语言到目标语言。另一种更常用的间接方法是将源语言表达转化成为目标语言的等价表达形式。这样,翻译便分成三个阶段:分析输入文本并将它表达为抽象的源语言;将源语言转换成抽象的目标语言;最后,生成目标语言。

机器翻译系统可以分成下列几种类型:

1. 直译式机器翻译系统

直译式机器翻译系统(direct translation MT system)通过快速的分析和双语词典,将原文译出,并且重新排列译文的词汇,以符合译文的句法。直译式机器翻译系统如图 9.8 所示。




图 9.8 直译式翻译

大多数著名的大型机器翻译系统本质上都是直译式系统,如 Systran、Logos 和 Fujitsu Atlas。这些系统是高度模块化的系统,很容易被修改和扩展。例如,著名的 Systran 系统在开始设计时只能完成从俄文到英文的翻译,但现在已经可以完成很多语种之间的互译。Logos 开始只针对德语到英语的翻译,而现在可以将英语翻译成法语、德语、意大利语,以及将德语翻译成法语和意大利语。只有 Fujitsu Atlas 系统至今仍把自己局限于英日、日英的翻译。

2. 规则式机器翻译系统

规则式机器翻译系统(rule-based MT system)是先分析原文内容,产生原文的句法结构,再转换成译文的句法结构,最后再生成译文。基于规则翻译系统通过识别、标注兼类多义词的词类,对多义词意义进行排歧;对某些同类词性的多义词再按其词法规则不同消除歧义。规则式机器翻译系统如图 9.9 所示。

当前主流的机器翻译还是基于规则的机器翻译系统。

3. 中介语式机器翻译系统

中介语式机器翻译系统(inter-lingual MT system)先生成一种中介的表达方式,而非特定语言的结构,再由中介的表达式转换成译文。程序语言的编译常采取此策略。中介语式机器翻译系统如图 9.10 所示。




图 9.9 规则式翻译




图 9.10 中介语式翻译

最重要的大型机中介语式机器翻译系统是 METAL。20 世纪 80 年代初期,德国西门子公司提供了大部分资金支持开发 METAL,直到 20 世纪 80 年代末才面市。目前最有名的两个中介语式机器翻译系统是 Grenoble 的 Ariane 和欧共体资助的 Eurotra。Ariane 有望成为法国国家机器翻译系统,而 Eurotra 是非常复杂的机器翻译系统之一。20 世纪 80 年代末,日本政府出资支持开发用于亚洲语言之间互译的中间语言系统,中国、泰国、马来西亚和印度尼西亚等国的研究人员均参加了这一研究。

4. 知识库式机器翻译系统

知识库式机器翻译系统(knowledge-based MT system)是建立一个翻译需要的知识库,构成翻译专家系统。由于知识库的建立十分困难,因此目前此类研究多半有限定范围,并且使用知识获取工具,自动或半自动地大量收集相关知识充实知识库。

5. 统计式机器翻译系统

1994 年,IBM 公司的 A. Berger, P. Brown 等用统计方法和各种不同的对齐技术,给出了统计式机器翻译系统(statistics-based MT system)Candide。

源语言中任何一个句子都可能与目标语言中的某些句子相似,这些句子的相似程度可能都不相同,统计式机器翻译系统能找到最相似的句子。

6. 范例式机器翻译系统

范例式机器翻译系统(example-based MT system)是将过去的翻译结果当成范例,产生一个范例库。在翻译一段文字时,参考范例库中近似的例子,并处理差异处。

实际的机器翻译系统往往是混合式机器翻译系统(hybrid MT system),即同时采用多种翻译策略,以达到正确翻译的目标。

7. 翻译记忆

由于目前还没有有一种机器翻译产品的效果能让人满意,因此,目前广泛采用翻译记忆(translation memory, TM)技术辅助专业翻译。以欧盟为例,每天都有大量的文件需要翻译成各成员国的文字,翻译工作量极大,自1997年采用德国塔多思(TRADOS)公司的翻译记忆软件以来,欧盟的翻译工作效率大大提高。如今,欧盟、国际货币基金组织等国际组织,微软、SAP、Oracle和大众等跨国企业以及许多世界级翻译公司都将翻译记忆软件作为信息处理的基本工具。

翻译记忆是一种通过计算机软件来实现的专业翻译解决方案。与期望完全替代人工翻译的机器翻译技术不同,翻译记忆实际只是起辅助翻译的作用,也就是计算机辅助翻译(computer aided translation, CAT)。因此,翻译记忆与机器翻译有着本质的区别。

翻译记忆的基本原理是:用户利用已有的原文和译文,建立起一个或多个翻译记忆库,在翻译过程中,系统将自动搜索翻译记忆库中相同或相似的翻译资源(如句子、段落等),给出参考译文,使用户避免重复劳动,只需专注于新内容的翻译。翻译记忆库同时在后台不断学习和自动存储新的译文,变得越来越“聪明”。

由于翻译记忆实现的是原文和译文的比较和匹配,因此能够支持多语种之间的双向互译。以德国塔多思公司为例,该公司的产品基于UNICODE(统一字符编码),支持55种语言。

8. 神经机器翻译

神经机器翻译是模拟人脑的翻译过程,从海量训练数据中抽取语义信息,近年来发展非常迅速,目前已经远远超过统计机器翻译,成为机器翻译的主流技术。基于神经网络的端到端翻译方法不需要针对双语句子专门设计特征模型,而是把源语言句子的词汇送入神经网络模型,经过神经网络的运算,得到目标语言句子的翻译结果。长短期记忆神经网络(LSTM)是一种对序列数据建模的神经网络,适合处理和预测序列数据。而且,LSTM使用“累加”的形式计算状态,这种累加形式导致导数也是累加形式,避免了梯度消失,因此在神经机器翻译中得到了广泛应用。目前,神经机器翻译领域主要研究如何提升训练效率、编解码能力以及双语对照的大规模数据集。

下面介绍一种基于循环神经网络的神经机器翻译方法。

9.5.2 基于循环神经网络的机器翻译

循环神经网络是一种对序列数据建模的神经网络,成为常用的、对句子进行编码的神经网络。

例如,给定源语言句子“Economic growth has slowed down in recent years.”。如图9.11所示,循环神经网络在每个时刻,根据上一个时刻的隐含层 h_{t-1} 、当前的输入 x_t ,生成当前时刻的隐含状态 h_t ,并基于当前的隐含状态预测当前时刻的输出。

首先将句子里的第一个词“Economic”输入循环神经网络,产生第一个隐含状态 h_1 ,此时隐含状态 h_1 便包含了第一个词“Economic”的信息。下一步输入第二个词“growth”,循环神经网络




图 9.11 循环神经网络示例

络将第二个词的信息同第一个隐含状态 h_1 进行融合,产生第二个隐含状态 h_2 ,如此则第二个隐含状态 h_2 便包含了前两个词“Economic growth”的信息。用同样的方法依次将源语言句子里所有的词输入神经网络,每输入一个词都会同前一时刻的隐含状态进行融合,产生一个包含当前词信息和前边所有词信息的新的隐含状态。

当把整个句子所有的词输入进去之后,最后的隐含状态理论上包含了所有词的信息,便可以作为整个句子的语义向量表示,该语义向量称为源语言句子的上下文向量。

图 9.12 是基于源语言句子编码表示的循环神经网络翻译模型的例子。




图 9.12 循环神经网络翻译模型示例

编码器将源语言句子编码为一个源语言句子的上下文向量,解码器的任务是根据编码器生成的该上下文向量,生成目标语言句子的符号化表示。

给定源语言的上下文向量,解码器循环神经网络首先产生第一个隐含状态 s_1 ,并基于该隐含状态预测第一个目标语言词“近”,然后第一个目标语言词“近”会被作为下一个时刻的输入,连同第一个隐含状态 s_1 以及上下文向量 C_t ,来产生第二个隐含状态 s_2 ,该隐含状态 s_2 包含了目标语言句子第一个词“近”的信息和源语言句子的信息,并用来预测目标语言句子第二个词“几年”。第二个目标语言词“几年”会被再次作为输入来产生第三个隐含状态,如此循环下去,直到预测到一个句子的结束符 $\langle /S \rangle$ 为止。

9.6 语音识别

9.6.1 语音识别的概念

用语音实现人与计算机之间的交互,主要包括语音识别(speech recognition)、自然语言理解和语音合成(speech synthesis)。语音识别是完成语音到文字的转换。自然语言理解是完成文字到语义的转换。语音合成是用语音方式输出用户想要的信息。

现在已经有许多场合允许使用者用语音对计算机发命令,但是,目前还只能使用有限词汇的简单句子,因为计算机还无法接受复杂句子的语音命令。因此,需要研究基于自然语言理解的语音识别技术。

相对于机器翻译,语音识别是更加困难的问题。机器翻译系统的输入通常是印刷文本,计算机能清楚地区分单词和单词串。而语音识别系统的输入是语音,其复杂度要大得多,特别是口语有很多的不确定性。人与人交流时,往往是根据上下文提供的信息猜测对方所说的是哪一个单词,还可以根据对方使用的音调、面部表情和手势等来得到很多信息。特别是说话者会经常更正所说过的话,而且会使用不同的词来重复某些信息。显然,要使计算机像人一样识别语音是很困难的。

按照服务对象划分,针对某个用户的语音识别系统,称为特定人工作方式。针对任何人的语音识别系统,则称为非特定人工作方式。

通俗地说,特定人的语音识别是要识别说话人是谁,而非特定人语音识别是要识别说的什么话。

本节将简单介绍语音识别的基本过程,包括语音信号的采集与处理、特征参数的提取与识别等主要过程,然后着重介绍基于隐马尔可夫模型的语音识别方法。

9.6.2 语音识别的主要过程

语音识别过程包括从一段连续声波中采样,将每个采样值量化,得到声波的压缩数字化表示。采样值位于重叠的帧中,对于每一帧,抽取出一个描述频谱内容的特征向量。然后,根据语音信号的特征识别语音所代表的单词。

1. 语音信号采集

语音信号采集是语音信号处理的前提。语音通常通过话筒输入计算机。话筒将声波转换为电压信号,然后通过 A/D 装置(如声卡)进行采样,从而将连续的电压信号转换为计算机能够处理的数字信号。

目前多媒体计算机已经非常普及,声卡、音箱、话筒等已是个人计算机的基本设备。其中声卡是计算机对语音信号进行加工的重要部件,它具有对信号滤波、放大、A/D 和 D/A 转换等功能。而且,现代操作系统都附带录音软件,通过它可以驱动声卡采集语音信号并保存为语

音文件。

对于现场环境不好,或者空间受到限制,特别是对于许多专用设备,目前广泛采用基于单片机、DSP 芯片的语音信号采集与处理系统。

2. 语音信号预处理

语音信号在采集后首先要进行滤波、A/D 变换,预加重 (preemphasis) 和端点检测等预处理,然后才能进入识别、合成、增强等实际应用。

滤波的目的有两个:一是抑制输入信号中频率超出 $f_s/2$ 的所有分量(f_s 为采样频率),以防止混叠干扰;二是抑制 50 Hz 的电源工频干扰。因此,滤波器应该是一个带通滤波器。

A/D 变换是将语音模拟信号转换为数字信号。A/D 变换中要对信号进行量化,量化后的信号值与原信号值之间的差值为量化误差,又称为量化噪声。

预加重处理的目的是提升高频部分,使信号的频谱变得平坦,保持在低频到高频的整个频带中,能用同样的信噪比求频谱,便于频谱分析。

端点检测是从包含语音的一段信号中确定出语音的起点和终点。有效的端点检测不仅能减少处理时间,而且能排除无声段的噪声干扰。目前主要有两类方法:时域特征方法和频域特征方法。时域特征方法是利用语音音量和过零率进行端点检测,计算量小,但对气音会造成误判,不同的音量计算也会造成检测结果不同。频域特征方法是用声音的频谱的变异和熵的检测进行语音检测,计算量较大。

3. 语音信号的特征参数提取

人说话的频率在 10 kHz 以下。根据香农采样定理,为了使语音信号的采样数据中包含所需单词的信息,计算机的采样频率应是需要记录的语音信号中包含的最高语音频率的两倍以上。一般将信号分割成若干块,信号的每个块称为帧。为了保证可能落在帧边缘的重要信息不会丢失,应该使帧有重叠。例如,当使用 20 kHz 的采样频率时,标准的一帧为 10 ms,包含 200 个采样值。

话筒等语音输入设备可以采集到声波波形,如图 9.13 所示。虽然这些声音的波形包含了所需单词的信息,但用肉眼观察这些波形却得不到多少信息。因此,需要从采样数据中抽取那些能够帮助辨别单词的特征信息。在语音识别中,常用线性预测编码 (linear predictive coding, LPC) 技术抽取语音特征。

线性预测编码的基本思想是:语音信号采样点之间存在相关性,可用过去的若干采样点的线性组合预测当前和将来的采样点值。线性预测系数可以通过使预测信号和实际信号之间的均方误差最小来唯一确定。

语音线性预测系数作为语音信号的一种特征参数,已经广泛应用于语音处理各个领域。

声波的采样数据可以绘制成一个 x - y 平面图, x 轴表示时间, y 轴表示振幅,如图 9.13 所示。声波有两个主要特征:振幅和频率。图 9.13 所示的声波波形实际上由 3 个正弦波叠加组成,但用肉眼很难分辨。为了能够看清楚声波中包含的主要频率波形,通常将采样信号经过傅里叶变换得到相应的频谱,再从频谱中看出波形中不同音素相匹配的主控频率组成成分。

图 9.14 是图 9.13 中声波波形的频谱,清楚地显示了这段声音波形包含的正弦波的振幅和频率。可以看出,声波中主要有 3 个正弦波,它们的幅值分别是三个峰值的幅值,它们的频率分别是三个峰值对应的频率。




图 9.13 声波波形




图 9.14 声波频谱

4. 向量量化

向量量化(vector quantization, VQ)技术是 20 世纪 70 年代后期发展起来的一种数据压缩和编码技术。经过向量量化的特征向量也可以作为后面隐马尔可夫模型中的输入观察符号。

在标量量化中整个动态范围被分成若干个小区间,每个小区间有一个代表值,对于一个输入的标量信号,量化时落入小区间的值就用这个代表值代替。因为这时的信号量是一维的标量,所以称为标量量化。

向量量化的概念是用线性空间的观点,把标量改为一维的向量,对向量进行量化。和标量量化一样,向量量化是把向量空间分成若干个小区域,每个小区域寻找一个代表向量,量化时落入小区域的向量就用这个代表向量代替。

向量量化的基本原理是将若干个标量数据组成一个向量(或者是从一帧语音数据中提取的特征向量)在多维空间给予整体量化,从而可以在信息量损失较小的情况下压缩数据量。

5. 识别

当提取声音特征集合以后,就可以识别这些特征所代表的单词。本节重点关注单个单词的识别。识别系统的输入是从语音信号中提取出的特征参数,如 LPC 预测编码参数,当然,单词对应于字母序列。

9.6.3 语言识别的主要方法

语音识别所采用的方法一般有模板匹配法、随机模型法和概率语法分析法三种。这三种方法都是建立在最大似然决策贝叶斯(Bayes)判断的基础上的。

(1) 模板(template)匹配法

在训练阶段,用户将词汇表中的每一个词依次说一遍,并且将其特征向量作为模板存入模

板库。在识别阶段,将输入语音的特征向量序列,依次与模板库中的每个模板进行相似度比较,将相似度最高者作为识别结果输出。

(2) 随机模型法

在深度学习语音识别方法出现之前,随机模型法是语音识别研究的主流。其突出的代表是隐马尔可夫模型。

马尔可夫模型是俄国数学家 Markov 在 1907 年研究俄国文学家普希金作品《奥涅金》中不同音的出现规律时所提出的一个数学模型。它是研究概率随时间传递的一种方法。

如果一个过程的“将来”仅仅依赖“现在”,而不依赖“过去”,则此过程称为马尔可夫过程。时间和状态都是离散的马尔可夫过程称为马尔可夫链。

隐马尔可夫模型(hidden Markov model, HMM)是马尔可夫模型的一个拓展形式,是表示序列可能出现的一种方法。所谓的“隐”是指马尔可夫模型的状态集合观测不到。

语音信号在足够短的时间段上的信号特征近似于稳定,而总的过程可看成是依次相对稳定的某一特性过渡到另一特性。而这个相对稳定的过程,就是语音内容的一个音素单位。在分析一个大的单词库时,要计算这种特性与特性之间过渡的概率大小。例如,字母 y 跟在 ph 后面出现的概率要大于跟在 t 后面出现的概率。隐马尔可夫模型则用概率统计的方法来描述这样一种时变的过程。

(3) 概率语法分析法

这种方法是用于大长度范围的连续语音识别。语音学家通过研究不同的语音语谱图及其变化发现,虽然不同的人说同一些语音时,相应的语谱及其变化有种种差异,但是总有一些共同的特点足以使他们区别于其他语音,即语音学家提出的“区别性特征”。另一方面,人类的语言要受词法、语法、语义等约束,人在识别语音的过程中充分应用了这些约束以及对话环境的有关信息。于是,将语音识别专家提出的“区别性特征”与来自构词、句法、语义等语用约束相互结合,就可以构成一个“自底向上”或“自顶向下”的交互作用的知识系统,不同层次的知识可以用若干规则来描述。

上面三种语音识别方法都是属于统计语音识别方法。

(4) 基于深度学习的语音识别方法

目前,基于人工神经网络的语音识别方法是语音识别的主流技术和研究热点。特别是深度学习方法近年来在智能语音领域得到了广泛应用,取得了突出效果。

基于深度学习的语音识别方法是通过深度神经网络模型的非线性建模能力,建立源说话人和目标说话人之间的映射关系,实现说话人个性信息的转换。由于深度神经网络具有较强的处理高维数据的能力,所以可以直接使用原始高维的谱包络特征训练模型,能够提高转换语音的语音质量。

用于语音识别研究的比较典型的深度神经网络目前主要有:受限玻尔兹曼机、深度置信神经网络、长短时记忆递归神经网络、深度卷积神经网络等。

9.7 小 结

自然语言理解是指机器能够执行人类所期望的某种语言功能,包括回答问题、文摘生成、释义、翻译。

自然语言理解的五个层次:语音分析、词法分析、句法分析、语义分析和语用分析。

词法分析是从句子中切分出单词,找出词汇的各个词素,从中获得单词的语言学信息并确定单词的词义。

循环神经网络(RNN)是一种对序列数据建模的神经网络,非常适合于对自然语言等时序信号的建模。

长短期记忆神经网络(LSTM)是一种 RNN 特殊的类型,使用“累加”的形式计算状态,避免了梯度消失问题。LSTM 主要利用遗忘门、输入门、输出门操作来管理和控制神经元的状态信息。

机器翻译系统可以分成下列几种类型:直译式、规则式、中介语式、知识库式、统计式、范例式。

翻译记忆是用户利用已有的原文和译文,建立起一个或多个翻译记忆库,在翻译过程中,系统将自动搜索翻译记忆库中相同或相似的翻译资源(如句子、段落等),给出参考译文,使用户避免重复劳动,只需专注于新内容的翻译。翻译记忆库同时在后台不断学习和自动储存新的译文,变得越来越“聪明”。

循环神经网络是一种对序列数据建模的神经网络,成为常用的、对句子进行编码的神经网络。

语音识别包括语音信号的采集与处理、特征参数的提取与识别等。语音识别所采用的方法一般有模板匹配法、随机模型法、概率语法分析法、基于深度学习的语音识别方法。

思 考 题

- 9.1 什么是自然语言理解?
- 9.2 自然语言理解过程有哪些层次? 各层次的功能如何?
- 9.3 简述循环神经网络工作过程。
- 9.4 循环神经网络同卷积神经网络有什么区别。
- 9.5 什么是机器翻译? 有几种主要类型?
- 9.6 什么是语音识别? 有几种主要方法?

习 题

9.1 使用工具 Groundhog 和 WMT2017 的中英机器翻译评测数据集进行神经机器翻译训练,并在测试集上进行评估。

读一读

生成对抗网络之父古德费洛

伊恩·古德费洛(Ian Goodfellow, 1985—)在斯坦福大学获得计算机科学学士、硕士学位,师从吴恩达(Andrew NG)教授。博士就读于蒙特利尔大学,师从图灵奖得主 Yoshua Bengio 教授和 Aaron Courville 教授,研究机器学习,于2014年获得博士学位。2013年,古德费洛作为实习生进入谷歌。

2014年的一天晚上,古德费洛和一个刚毕业的博士生在蒙特利尔一个酒吧喝酒庆祝。一些朋友希望他能帮忙看看手头上一个棘手的项目:计算机如何自己生成图片。他们已经使用了神经网络作为生成模型来创造合理的新数据。但计算机生成的人脸图像不是模糊不清,就是缺耳少鼻。因为古德费洛朋友们提出的方案是对那些组成图片的元素进行复杂的统计分析以帮助机器自己生成图片,需要进行大量的数据运算,古德费洛告诉他们这根本行不通。古德费洛边喝啤酒边思考问题,突然有了一个想法:如果让两个神经网络相互对抗会出现什么结果呢?他的朋友对此持怀疑态度。他决定马上实现自己的想法,一直写代码到凌晨,然后进行测试。第一次运行就成功了!那天晚上他提出的方法现在叫作 GAN,即生成对抗网络。

2014年古德费洛发表著名论文“Generative Adversarial Nets”,标志着生成对抗网络(GAN)的诞生,他因此也被称为 GAN 之父。

2015年11月,古德费洛成为了谷歌大脑的高级研究员。2016年3月,他跳槽到了马斯克建立的 OpenAI 研究所。在工作了一年之后,于2017年3月重回谷歌研究院做了两年的研究科学家,2019年4月4日,古德费洛离职谷歌跳槽苹果。2022年加入谷歌 DeepMind 公司从事人工智能研究。

GAN 已经被广泛应用于图像生成、音乐生成、语音合成等领域,在机器学习领域产生了巨大的影响。2017年,古德费洛被麻省理工学院技术评论评为35位35岁以下的创新人物之一。2019年,他上榜美国《外交政策》杂志评选出的“100位全球思想家”名单。

读一读

BP 算法的杰出贡献者鲁梅尔哈特

戴维·鲁梅尔哈特(David E. Rumelhart, 1942—2011), 斯坦福大学教授, 认知心理学家, 主要从事认知神经科学和人工智能领域研究。他于 1967 年获得斯坦福大学数学心理学博士学位, 之后加入加州大学圣迭戈分校开展研究工作, 进行符号计算理论研究。20 世纪 70 年代中期转向人工神经网络研究。1985 年, 他和辛顿等人重新设计了 BP 学习算法, 在多层感知机中使用 Sigmoid 激活函数代替原来的阶跃函数, 以“人工神经网络”模仿大脑工作机制。1986 年, 他和杰弗里·辛顿(Geoffrey Hinton)和罗纳德·威廉姆斯(Ronald Williams)联名发表了具有里程碑意义的经典论文《通过误差反向传播学习表示(learning representations by back-propagating errors)》, 通过实验展示反向传递算法, 可以在神经网络的隐含层中学到对输入数据的有效表达, 实现了 Minsky 多层感知机的设想。BP 学习算法唤醒了沉睡多年的人工智能研究, 又一次掀起了神经网络高潮。

1987 年他重返斯坦福大学进行研究工作。1991 年当选美国科学院院士, 1996 年获得美国心理学会的杰出科学贡献奖。2000 年, 认知科学学会以他的名字设立了一个重要的国际奖——David E. Rumelhart 认知科学理论基础贡献奖。20 世纪 90 年代, 戴维·鲁梅尔哈特不幸患 Pick 病(一种神经性退行性疾病), 1998 年退休。2011 年去世。

第 10 章 大语言模型及其应用

大语言模型引领了人工智能生成内容 (artificial intelligence generated content, AIGC) 快速发展,使人工智能成为越来越多内容生成的源头。AIGC 在生成式人工智能模型、训练数据的基础上,可以利用大语言模型生成具有一定创意和质量的作品,涵盖文本、图像、音频、视频、代码等多个领域。

本章首先介绍大语言模型的发展与应用、大语言模型提示工程、知识蒸馏技术,然后简要介绍大语言模型的核心注意力机制和 Transformer,最后分别简要介绍生成式人工智能在图像处理、机器翻译、语音识别、视频生成等领域中的应用案例。

10.1 大语言模型的概念与发展

大语言模型 (large language model, LLM) 简称大模型 (large model), 是指在人工智能领域,特别是深度学习领域中,参数量非常大的人工神经网络模型,能够在大量的文本数据上进行训练,能够学习数据的复杂特征,可以执行多种更复杂、更抽象的任务,包括自然语言处理、文本总结、翻译、语音识别、情感分析等,以及理解和生成人类语言。

参数是神经网络中用于计算和存储信息的基本元素,它们在训练过程中不断调整以适应数据。因此,大模型最重要的特征是其参数数量的规模。大模型具有参数量大、训练数据量大、计算能力要求高、泛化能力强、应用广泛等特点。通过增加网络的深度和宽度,以及使用更多的神经元,大模型可以提供更强大的计算能力,从而更好地学习和理解数据,包括文本、图像、语音等多种类型的数据。

与传统的小模型相比,大模型更能够捕捉数据的细节及其复杂的特征,因此在处理复杂任务上有明显优势。大模型能够解决更加复杂和具有挑战性的任务,极大地提升了人工智能的应用能力,应用非常广泛。

2013 年之前提出的 CNN/RNN/LSTM 是大模型的基础。2013 年 Google 提出的高效训练向量模型 Word2Vec 非常流行,直到 2018 年 Google 基于 Transformer 架构的具有 3.4 亿个参数的预训练语言表征模型 BERT 等出现。2017 年 Google 提出的 Transformer 中引入了自注意力机制,改进了 RNN 和 LSTM 不可并行计算的缺陷。

2018年6月 OpenAI 发布 GPT-1 大模型,具有 1.1 亿个参数。2018 年 11 月 OpenAI 发布 GPT-2 大模型,具有 15 亿个参数。2019 年 6 月 10 日 OpenAI 发布 GPT-3 大模型,具有 1 750 亿个参数,并向部分合作伙伴提供了访问权限。2019 年 9 月 OpenAI 开放了 GPT-2 大模型的全部代码和数据,并发布了更高级的版本。2020 年 5 月 OpenAI 宣布推出 GPT-3 大模型的 beta 版本,该模型拥有 1 750 亿个参数。2022 年 11 月 30 日 OpenAI 通过 GPT-3.5 系列大型语音模型微调而成的全新对话式通用人工智能模型 ChatGPT 正式发布,将大模型的发展推向又一个高潮。

2023 年 3 月 15 日 OpenAI 推出了多模态大模型 GPT-4,不仅能够阅读文字,还能识别图像,并生成文本结果,现已接入 ChatGPT 向 Plus 用户开放。ChatGPT 的技术关键是使用了“人类反馈强化学习”RLHF 进行训练。它可以理解人类输入的文字,并根据文字的提问和指令,以文字的方式输出答案和反馈,从而实现借助自然语言的多轮次的人机对话。

2023 年 11 月 OpenAI 公司发布处理速度更快、费用更低的 GPT-4 Turbo 模型。2024 年 2 月 OpenAI 公司发布文生视频大模型 Sora,能够准确理解用户指令中所表达的需求,并以视频的形式进行展示。用户通过提出要求,Sora 可以创建长达 60 秒的文生视频,其中包含高度详细场景、复杂摄像机运动以及充满活力的多个角色。由 Sora 创作的视频不仅包含复杂的场景和多个角色,而且对角色的动作、瞳孔、睫毛、皮肤纹理进行了细节刻画。

2024 年 5 月 14 日,OpenAI 发布“Magic(魔法)”,包括:ChatGPT 新 UI、桌面版 GPT 以及 GPT-4o。2025 年 8 月 8 日,OpenAI 发布 GPT-5,显著降低幻觉生成,提升指令遵循精度,减少迎合性回答。

人工智能是信息世界的革命,信息技术的变革浪潮依次发生在信息量更高、信息密度更大的领域:第一阶段,文字——GPT3(2019.6);第二阶段,声音——Whisper(2020.12);第三阶段,图像——DALL-E3(2023.9);第四阶段,影像——Sora(2024.2);第五阶段,综合——GPT-4o(2024.5)、GTP-5(2025.8)。人工智能的发展符合人类信息时代的迭代发展规律。

10.2 国内外主要大模型平台

在当今人工智能领域,多模态大模型已成为研究和应用的热点。本节将介绍几个具有代表性的多模态大模型。这些多模态大模型的出现,为人工智能的应用带来了更多的可能性,同时也推动了人工智能技术的发展。

1. ChatGPT

ChatGPT 是由 OpenAI 开发的基于 GPT(generative pre-trained transformer)的聊天机器人程序,于 2022 年 11 月 30 日发布。

GPT 模型是一种采用 Transformer 结构的生成模型,通过预训练学习大量文本数据中的语言规律,然后可以根据输入的上下文生成自然的文本回复。ChatGPT 不仅能通过理解和学习人类的语言流畅地与用户对话,甚至能撰写诗、邮件、视频脚本、文案、代码,翻译,写论文等任务。

将人工智能应用于音频处理和音频生成的研究,促进了自动语音识别和原创音乐作品的发展。

2. 文心一言

文心一言是基于百度文心大模型打造的 AI 产品。文心一言生成式人工智能正蓬勃发展,在提升生活品质和工作效率方面,特别是在资料查询、文本撰写(工作总结、工作计划、发言稿、新闻稿、作文、课程大纲、教案)、翻译、出题、编程(含校对、比对)等方面具有很大作用。

文心大模型对话类产品具有广泛的适用性,用户将生成式 AI 作为办公助手、休闲娱乐和内容创作。百度文库基于文心大模型升级为一站式 AI 内容获取和创作平台,推出了智能 PPT、智能写作、思维导图、研究报告、拍图生文等上百项多模态 AI 内容创作能力。

智能体作为 AI 应用的主流形态之一,也将迎来爆发点。随着技术的迭代创新,智能体将在各行各业中发挥越来越重要的作用,成为连接用户与服务的新桥梁。文心智能体技术的突破,促进了文心大模型能力全面提升,充分释放大模型潜力,加速应用爆发,比如代码智能体、农民院士智能体、个人助手等。大模型、智能体等技术,将激发更多创新,为社会经济发展带来巨大价值。

3. 盘古

盘古是华为公司推出的大型预训练模型,具有强大的自然语言理解和生成能力。面向企业市场的分布式存储系统,旨在满足企业日益增长的存储需求。盘古系统是具有高可靠性、高性能、易管理的分布式存储系统,可为企业提供稳定、高效的存储服务,具有扩展灵活、兼容性强、数据安全的特点。

华为盘古系统能够应用于企业数据中心、云计算平台、分布式存储集群、数据仓库和分析等应用场景,助力企业应对日益增长的存储挑战。

盘古大模型采用了三层架构:L0 层包括五个基础大模型,涵盖自然语言处理、视觉、多模态、预测以及科学计算等领域;L1 层针对特定行业,提供通用或定制化的行业大模型;L2 层为特定应用场景提供细化模型服务。

包含七大应用场景:盘古 NLP 大模型用于内容生成和理解;盘古 CV 大模型应用于图像分类、分割和检测,具备模型按需抽取能力,盘古多模态大模型:结合语言与视觉信息,支持图像生成和理解等应用;盘古预测大模型基于 Transformer 架构,用于销售预测、财务异常检测等;盘古科学计算大模型解决气象、医药等领域的科学计算问题;盘古气象大模型实现秒级天气预报,精度超越传统方法;盘古药物分子大模型加速药物研发过程。

4. 通义千问

通义千问是阿里云推出的多模态大模型,能够理解和生成自然语言文本,同时还能处理图像和视频数据。通义千问是面向企业级应用的深度学习平台,为开发者提供一站式、高性能的深度学习解决方案。通义千问平台集成了阿里云在人工智能领域的深厚成果。

通义千问支持自定义模型训练,满足个性化需求,为企业提供了丰富的预训练模型(涵盖自然语言处理、计算机视觉、语音识别等多个领域)、强大的计算资源和易用的开发工具,在智能客服、图像识别、语音识别、推荐系统和文本分析等领域具有广泛的应用前景。

通义千问能够通过自然语言处理技术,实现智能客服系统的构建,处理大量客户咨

询,提供实时、精准的回答,提升客户满意度。企业可以使用通义千问平台计算机视觉功能,实现产品图片的自动分类和标签生成,提高运营效率。通义千问支持语音识别技术,可应用于企业会议记录、智能语音助手等领域。通过实时语音转文字功能,企业可以节省会议记录时间,提高工作效率。通义千问推荐系统可根据用户行为和喜好构建个性化的推荐系统,为用户提供个性化商品推荐、内容推荐等服务,提升用户体验。

5. 混元

混元是腾讯公司推出的大型预训练模型,能够进行自然语言理解和生成,同时也具备图像和视频处理能力。腾讯混元是一套面向企业级应用的混合云解决方案,帮助企业实现灵活、高效的云计算部署。腾讯混元解决方案充分考虑了企业级应用的特点,具备高度的可扩展性、稳定性和安全性。

混元平台支持多种云计算部署模式,包括公有云、私有云、混合云等,满足企业不同场景下的需求。同时,混元还支持与其他云服务和第三方服务的无缝集成,构建强大的生态系统。

混元平台结合了腾讯云丰富的产品体系和技术优势,提供一站式、跨平台的云计算服务,助力企业应对日益多样化的业务需求。混元平台可以帮助企业构建智能化的 IT 基础设施,实现大规模数据的存储、处理和分析,助力企业挖掘数据价值,实现数字化转型,支持企业构建智能应用。

6. DeepSeek

深度求索人工智能基础技术研究有限公司于 2024 年 12 月 26 日发布了开源大模型 DeepSeek-V3。DeepSeek-V3 运用了多项先进技术,大幅提升了模型的性能和训练效率,在多个基准测试中,DeepSeek-V3 在数学、代码、推理等许多方面均具有很好的性能,特别是在后训练阶段使用了强化学习技术,在仅有极少标注数据的情况下,极大地提升了模型推理能力,大幅度地降低了训练成本,不足知名大模型的二十分之一,引起国际上强烈反响。

DeepSeek 能够直接面向用户或者支持开发者,提供智能文本生成与创作、语义理解、编程与代码生成等功能,支持联网搜索与深度思考模式,同时支持文件上传,能够扫描读取文件与图片中的内容。

文本生成与创作包括:文本创作(如:文章故事诗歌等写作、营销文案、剧本或者对话设计、社交媒体内容)、摘要与改写(论文与报告的长文本摘要和简化、多语言翻译)、结构化生成(表格、列表生成、代码注释、文档撰写等)。

语义理解包括:语义分析(语义解析、评论等情感分析、客服对话与用户查询等意图识别、人名地点事件等实体提取)、文本分类(新闻分类等主题标签生成、网络垃圾内容检测)、知识推理(逻辑问题解答、因果分析)。

编程与代码生成包括:代码生成(生成代码片段、自动补全与注释生成)、代码调试(错误分析与修复建议、代码性能优化提示)、技术文档处理(API 文档生成、代码库解释与示例生成)。

还有一些大语言模型,如:讯飞星火、Kimi Chat、蓝心、智谱清言、百川大模型、豆包、天工、商汤商量、360 智脑,等等。

10.3 大语言模型提示工程

提示词对于大模型的生成结果和质量具有重要影响,合适提示词的选择被称为提示工程。一个好的提示词可以帮助模型更好地理解用户的意图,并生成更符合意图的结果。提示词是一种优化和改进大模型生成性能的重要方法。这种方法不是对大模型参数进行修改或者重新训练,而是针对特定任务,通过特殊设计的提示词引导模型生成更好的结果。

提示(prompt)在大语言模型出现前就已经存在了,是用户向计算机程序传入的一个/组指令,以引导其朝着用户的期望进行响应或行动。在大语言模型时代,提示一般指用户与大语言模型互动的文本,如问题、指令或闲聊。

大语言模型提示工程又称提示词工程(prompt engineering),是一种利用大语言模型进行自然语言处理任务的新方法,通过开发与优化提示词,从而让大模型输出预期结果的过程,可以实现如摘要、问答、翻译等多种任务。

大语言模型提示工程包括提示工程原则、自动提示生成、用例调查、基础设施、安全和最后的思考。

提示工程提示顺序、样例选择和模型校准对性能有显著影响。如何写出好的提示?提示工程的三个关键点如下:

- (1) 前提条件:明确自己的需求;
- (2) 核心工作:开发与优化提示词;
- (3) 目标:让大模型返回用户期望的结果。

为了能够提高模型输出效率,可以按照下列提示词框架编写提示词:

(1) 指令(instruction):明确描述模型需要执行的任务,指令应简洁、明确,确保模型能理解任务的目标和要求。

(2) 背景信息(context):提供给模型的上下文信息,可以帮助模型更好地理解任务和生成响应,背景知识可以包括任务的背景、目的、相关知识和其他相关信息。

(3) 输入数据(input Data):输入数据是可选的,如果模型不需要特定的输入数据,可以省略此部分内容。

(4) 输出引导(output Indicator):要求模型如何组织和呈现输出结果。

大语言模型提示工程是技巧性很强的工作,有待在运用大模型的实践中逐渐提高。

10.4 知识蒸馏技术

大语言模型开发面临一个非常重要的实际问题:在有限的算力资源下,如何以低成本快速训练大语言模型?

2006年,Bucilua等首次提出通过模型压缩技术迁移大语言模型或者用集成模型中的信息

去训练小型模型时,精度不会显著下降。2015 年,Hinton 等发表论文“Distillation the Knowledge in a Neural Network”正式提出知识蒸馏(knowledge distillation)的概念,目前已经成为一种常用的模型压缩方法。

知识蒸馏的结构如图 10.1 所示,教师模型是已经训练完成的大型模型,学生模型是小型待训练的模型。




图 10.1 知识蒸馏的结构

知识蒸馏是将教师模型中的知识“蒸馏”到学生模型中去,其本质就是在训练小型学生模型时,用大型教师模型指导,从而实现知识的传递。

对于一个分类任务,训练数据集中的标签称为 Hard label,教师模型的预测概率输出为 Soft label。Hard label 在训练集中,除了正标签以外,其他负标签都是 0。Transformer 代表用来调整 Soft label 平滑程度的超参数。

知识蒸馏的主要目标是教会学生模型如何更好地泛化新的数据。因此,知识蒸馏方法不仅能够学习到正确的分类结果,而且可以通过学习教师模型的输出结果学习到数据之间的复杂关系和不确定性,为学生模型提供了更为丰富的信息。Soft label 的概率发布熵越大,表明其包含的信息量越大,训练学生模型的效果越好。在输出结果中,每个类别基本上都分配到一定的概率,从而提供更丰富的信息。

如果学生模型能够同时参考教师模型的输出和实际标签值,就可以有效降低被教师模型的偶然错误所误导的可能性,并能够学习教师模型的泛化能力。

给定教师模型,知识蒸馏方法的一般步骤:

(1) 在温度 T 下,教师模型产生 Soft label。这些标签中包含了模型对各个类别的概率预测。

(2) 使用 Soft label 和 Hard label 同时训练学生模型。在这个过程中,学生模型不仅需要学习如何正确分类样本,还要模仿教师模型的概率输出结果。

(3) 当模型训练完成后,设置温度 T 为 1,模型在不受温度干扰的情况下进行推理。

高温蒸馏过程中的目标函数的损失值由蒸馏损失(distill loss)和学生损失(student loss)加

权得到。其中,蒸馏损失对应学生模型输出结果与教师模型输出结果之间的差异;学生损失对应学生模型在温度 T 为 1 的情况下,输出结果与真实标签之间的差异。

2025 年 2 月 6 日,李飞飞等斯坦福大学和华盛顿大学的 AI 研究团队宣布:用不到 50 美元的云计算费用训练出了一个名为 s1 的人工智能推理模型。s1 是通过蒸馏技术从谷歌的 Gemini2.0 中 Flash Thinking Experimental 模型中提炼出来的,使用 16 个英伟达 H100 GPU 训练了 26 分钟。该模型在数学和编程能力测试中表现与 OpenAI-o1 和国产大模型 DeepSeek-r1 等的推理模型相似,而以低训练成本著称的 DeepSeek-r1 (训练成本只有国际同级别大模型的 1/70) 的训练成本也需要 560 万美金。由此可见,蒸馏技术极大地降低了大语言模型的训练费用。

10.5 编码器-解码器结构

2017 年,Google 公司 Ashish Vaswani 等人提出了 Transformer,它用自注意力结构取代了循环神经网络的结构。在训练过程中,大模型将输入的单词以向量的形式传递给神经网络,然后通过网络的编码解码和自注意力机制,建立起每个单词之间联系的权重。与之前的循环神经网络相比,Transformer 最大的优点是可以并行计算,效率更高,加快了训练速度。Transformer 基于编码器-解码器(encoder-decoder)结构,编码部分由多个编码器组成,解码部分也由多个解码器组成。Transformer 在机器翻译任务上得到了当时最好的实验结果。

编码器-解码器结构最初是利用神经网络进行机器翻译的基本方法,又被称为序列到序列模型(sequence to sequence, Seq2Seq)。在机器翻译中,源语言和目标语言的长度一般并不相等,如源语言的长度为 n ,目标语言的长度为 m ,那么往往 $n \neq m$,而编码器-解码器结构则可以有效地对这类输入序列和输出序列不等长的问题进行建模。简单来说,基于 encoder-decoder 结构的模型首先利用 encoder 对源语言输入序列 x 进行编码,形成一个语义向量 c ,然后利用 decoder 对 c 进行解码,最终得到目标语言输出序列 y ,如图 10.2 所示。




图 10.2 编码器-解码器结构

编码器得到语义向量 c 的方法有很多。一种最简单的方法是直接将最后一个隐态作为语义向量:

$$c = h_n \quad (10.1)$$

也可以对最后的隐态进行一个 $\sigma(\cdot)$ 变换得到语义向量:

$$c = \sigma(h_n) \quad (10.2)$$

或对所有的隐态进行 $\sigma(\cdot)$ 变换得到语义向量:

$$c = \sigma(h_1, h_2, \dots, h_n) \quad (10.3)$$

得到语义向量 c 后,解码器常采用两种方法:一种是将语义向量 c 作为解码器的初始状态输入,如图 10.3 所示。




图 10.3 采用语义向量 c 作为初始输入的编码器-解码器结构

另一种则是将语义向量 c 作为解码器的每一步输入,如图 10.4 所示。




图 10.4 采用语义向量 c 作为每一步输入的编码器-解码器结构

可以看出,编码器-解码器结构会将任意长度的输入编码成一个固定长度的语义向量 c 。因此,如果要准确地对源语言进行翻译,则语义向量 c 应包含源语言输入序列的所有信息。但是,如果源语言输入序列比较长,这种结构可能会导致固定长度的语义向量 c 无法存储全部的语义信息,而注意力机制的提出则解决了这个问题。

10.6 注意力机制

人们在观察图像时,往往会重点关注其中的重要区域,比如会更多地关注图像中的前景,而不是背景,这就是人的视觉中的注意力机制。在阅读一个句子时,句子中各个词的关注度也是不同的,例如更加关注其中的名词、动词等。听人讲话等许多场合都是如此。这就是人类的注意力机制。

注意力机制(attention mechanism)最早由 Dzmitry Bahdanau 等人提出,最初被用于神经机器翻译任务。我们许多时候既期望网络能够看到全局,但更期望网络能够聚焦到重点信息上。比如在做自然语言处理时,句子中的一个词往往不是孤立的,而是和它上下文相关,但是上下文中不同的词的相关性是不同的,所以在处理这个词时,在看它的上下文的同时也要更加聚焦与它相关性更高的词,这就要用到常说的自注意力机制。注意力机制本质上提供了一种对输

入数据进行权重分配的方案。

注意力机制一般分为全局注意力机制、局部注意力机制和自注意力机制三种。

1. 全局注意力机制

全局注意力是指解码器端的注意力计算时要考虑编码器端输入序列中所有的序列,如图 10.5 所示。

2. 局部注意力机制

局部注意力是指解码器端的注意力计算时仅考虑编码器端输入序列中的部分序列。首先预估一个对齐位置 i ,然后在位置 i 左右的窗口范围内来取序列进行注意力计算,如图 10.6 所示。




图 10.5 全局注意力机制




图 10.6 局部注意力机制

3. 自注意力机制

自注意力是指让模型注意到整个输入中不同部分之间的相关性。自注意力机制是 Transformer 模型的核心。在下面通过介绍 Transformer 模型介绍自注意力机制。

10.7 Transformer

大模型规模庞大,例如,ChatGPT-3 有 96 层、12 288 个隐含层维度、1 750 亿个参数,帮助学习语言数据中的复杂模式。大模型参数量的增加带来了训练和推理的复杂度,需要更多的存储资源、计算资源和计算时间。因此,大模型通常需要使用高性能计算机和大规模计算集群来进行训练,也需要使用各种优化算法加速训练过程和提高模型的准确率。大模型需要通过海量数据及高质量标注语料库进行训练。大模型很难在单个 GPU 上进行预训练,需要使用 GPU 集群进行分布式训练。大模型基于 Transformer 架构进行构建,由多层神经网络架构叠加而成。

Transformer 是由 Google 大脑团队(Google Brain)于 2017 年 6 月在神经信息处理大会上提出的神经网络结构。该结构最初的设计目的是解决循环神经网络串行输入、串行编解码导致的运行速度缓慢的问题,提升机器翻译的效率。现在已经成为大模型的核心技术,奠定了大模

型预训练算法架构的基础,为通用人工智能的发展做出很大贡献。

10.7.1 Transformer 的结构

Transformer 的结构如图 10.7 所示,它由编码器和解码器两部分组成,每个部分包含若干个模块。其中,编码器负责理解输入,为每个输入构造对应的语义表示。解码器负责以自回归的方式逐个生成输出序列中的元素。




图 10.7 Transformer 的结构

Transformer 的编码器由 6 个相同的层堆叠而成,每个层包含两个子层,分别是多头自注意力层和前馈神经网络层。其中,多头自注意力是 Transformer 的核心。此外,在两个子层中,Transformer 使用残差连接(residual connection)和层归一化(layer normalization, LN)机制进行性能优化。

Transformer 的解码器也是由 6 个相同的层堆叠而成。与编码器中每层的两个子层不同的是,解码器的每层还包含第 3 个子层,第 3 个子层对编码器的输出进行多头自注意力计算。

大模型将输入的每句话中的每个单词与已经编码在模型中的单词进行相关性的计算,并把相关性又编码叠加在每个单词中,能够更好地理解和生成自然文本,并表现出一定的逻辑推理能力。

10.7.2 Transformer 中的多头自注意力机制

注意力机制可以被描述为给定一个查询(query)和一组键(key)值(value)向量对,计算这个查询和键向量之间的权重系数,然后使用这个权重系数对值向量进行加权平均,得到最终输出向量的过程。

在 Transformer 中,提出了一种可缩放的点积注意力(scaled dot-product attention),也就是自注意力。该注意力机制的输入由查询向量 Q 、维度为 d_k 的键向量 K 和维度为 d_v 的值向量 V 构成。接下来,计算查询向量 Q 和键向量 K 的点积(矩阵相乘),并除以 $\sqrt{d_k}$ 进行缩放,之后在编码器中直接跳过掩码操作,而在解码器中需要进行掩码操作,最后使用 Softmax 函数来获得值向量 V 的权重系数,再与值向量 V 进行矩阵相乘得到最终结果。自注意力机制的总体计算流程如图 10.8 所示。




图 10.8 自注意力机制整体流程

具体地,在实践中,首先将输入 X 分别通过线性变换矩阵 W_Q , W_K 和 W_V 映射成查询矩阵 Q 、键矩阵 K 和值矩阵 V ,如图 10.9 所示。




图 10.9 Transformer 的输入矩阵

Transformer 可以并行执行自注意力机制,产生多个输出值,再将这些值拼接起来进行再次投影。因此,在自注意力机制的基础上设计了多头自注意力机制 (multi-head self-attention mechanism),如图 10.10 所示。




图 10.10 多头注意力机制

多头自注意力机制是将自注意力机制中的注意力机制进行多次并行运算,每次运算都是一个不同的“头”,从而提高了模型对不同语义信息的学习能力。每个注意力头都会计算出一

组注意力权重,并用于对输入序列进行加权求和,从而生成多个新的表示向量。这些向量最终被连接在一起,形成一个更丰富和抽象的表示。

在多头自注意力机制中,每个头的参数都是独立的,因此可以学习不同的语义表示。因此,Transformer 在处理不同种类的任务时,可以通过多头自注意力机制同时学习多个方面的信息,从而提高模型的表现和泛化能力。

10.8 大语言模型的典型应用

由于图像和视频数据的取值是连续的,可直接应用梯度下降对可微的生成器和判别器进行训练,而语言生成模型中的音节、字母和单词等都是离散值,难以直接应用到基于梯度的生成对抗网络。目前,人工智能不仅广泛用于体裁比较固定的新闻写作,还能够进行诗歌写作等文学创作。

1. 写作大语言模型

在自然语言处理领域中,大模型在机器翻译、文本生成、对话系统等方面上的应用取得了显著的成果。BERT、GPT 等大模型用于文本的语义理解、情感分析、机器翻译等,能够学习语言的上下文信息和语义特征,从而提高自然语言处理的准确性和效果。在语音识别领域中,大模型可以用于语音识别、语音合成、语音转换等任务。

人工智能写作系统具有较强的语言生成能力,能够根据提示词撰写电子邮件、博客文章或其他中长篇内容,并加以提炼和润色。还有内容摘要生成能力,能够将长文章、新闻报道、研究报告、公司文档甚至客户历史记录汇总成根据输出格式定制长度的完整文本。

例如,“学习强国”中刊登了一篇《中国教育报社》上的文章“ChatGPT 与名师同写作文”。

作文题目:阅读下面的材料,根据要求写作。

冲浪是冲浪者站在冲浪板上驾驭海浪的水上运动,已被列为 2024 年巴黎奥运会的正式比赛项目。在惊涛骇浪之上翱翔,需要具备以下条件:海浪够高够大,且在冲浪者可驾驭的范围内;冲浪板尺寸合适,能被冲浪者灵活操控;冲浪者有足够的勇气,也有良好的身体素质。当今世界正经历百年未有之大变局,我国正处于实现中华民族伟大复兴的关键时期。在时代的浪潮中,我们应该如何做好一名冲浪者?

请结合材料写一篇文章,体现你的感悟与思考。要求:选准角度,确定立意,明确文体,自拟标题;不要套作,不得抄袭;不得泄露个人信息;不少于 800 字。

ChatGPT 生成文章《做好时代的冲浪者》,深圳第二外国语学校语文教师、国家“万人计划”教学名师龚志民写文章《审时而冲,量力而浪,合身择板,顺势而为》,然后由深圳市特级教师陈继英进行点评:ChatGPT 生成的文章能够从材料分解出做好时代冲浪者的“五个必备条件”,而且每段都有分论点,然后加以一一阐述,层次清晰,可以和大部分高三学生可以打个平手。而评价龚志民的文章是“令人拍案叫绝”。虽然,ChatGPT 生成的文章比人类名师的文章还有相当的差距,但写作大语言模型发展进步很快,会快速改进。

目前已经有许多写作大模型,除了 ChatGPT,百度公司的文心一言、阿里云公司的通义千问等也是功能很强的写作大模型。只要明确写作目标,让写作大模型能够了解需求,就可以生成符合需求的文章。为了得到更好的文章,可以逐步优化提问,例如修改提示词、添加详细描述等,引导大模型生成更符合预期的内容。

2. 文生图大语言模型

在图像处理领域中,大模型可以用于图像分类、目标检测、图像生成等任务。在计算机视觉领域,ResNet、InceptionV3 等大模型在图像分类、对象检测等任务上表现出色。这些大模型能够提取图像中的视觉特征,并进行准确的分类和识别。使用大模型的推荐系统,通过对用户行为数据的分析和学习,能够更好地理解用户的喜好和行为模式,对用户的兴趣和需求进行更准确的推荐。

将 GPT 生成的提示语言贴到 Midjourney 进行绘图,取得重大进展。例如用 Midjourney 生成阿房宫、四大名著里的 23 个经典人物画像等。

3. 文生视频大语言模型

2024 年 2 月 16 日 OpenAI 发布文本生成视频大模型 Sora。根据用户提出的要求,Sora 可以创建长达 60 秒的文生视频,其中包含高度详细场景、复杂摄像机运动的多角度镜头以及充满活力的多个角色,标志着人工智能在视频生成领域的动态内容创造上取得重大突破。

2024 年 5 月 14 日凌晨,OpenAI 发布“Magic(魔法)”包括:ChatGPT 新 UI、桌面版 GPT 以及 GPT-4o。Magic 具有下列特点:

(1) 全能:是一个全新的多模态大模型,o is omni model,即全能模型,可以接收文本、音频和图像的任意组合作为输入,并实时生成文本、音频和图像的任意组合输出。

(2) 快速:对音频输入最短为 232 毫秒,平均 320 毫秒,实现近乎自然的语音交互,以往产品 2 秒以上。

(3) 共情:能够分析语言确定客户的语气,进行情感分析,识别人类感情,并作出有感情的反应。

(4) 好用:可以应用于各种场所,如智能客服、在线教育、医疗咨询、智慧康养等。人工智能聊天机器人,可以回答客户询问、执行后端任务并以自然语言提供详细信息,作为集成式自助客户服务解决方案的一部分。

2024 年 9 月 13 日凌晨,OpenAI 发布“o1 系列”预览模型。o1 模型是 GPT-5 中关键的一步。GPT-4 智力水平类似于高中生,GPT-5 智力水平则是从“高中生跃升至博士”。在通用复杂推理过程中,每次回答要花更长时间思考,就像人类思考解决问题的过程一样。参加国际奥数竞赛,GPT-4o 只能拿到 13% 的分数,而 o1 可拿到 83% 的分数。特别是参加编程比赛 Codeforces,GPT-4o 只有 11%,而 o1 拿到 89% 的成绩。2024 年 12 月 20 日,OpenAI 发布推理模型 o3,在软件工程、编写代码、数学竞赛都达到了很高水平。

10.9 小 结

1. 大语言模型

大语言模型(LLM)是指在人工智能领域,特别是在深度学习领域中,参数量非常大的人工神经网络模型,能够在大量的文本数据上进行训练,能够学习到数据的复杂特征,可以执行多种更复杂、更抽象的任务。

大模型基于 Transformer 架构进行构建,由多层神经网络架构叠加而成。

大语言模型提示工程是一种利用大语言模型进行自然语言处理任务的新方法,通过开发与优化提示词,从而让大模型输出预期结果的过程,可以实现如摘要、问答、翻译等多种任务。

大语言模型提示工程包括提示工程原则、自动提示生成、用例调查、基础设施、安全和最后的思考。

知识蒸馏是将教师模型中的知识“蒸馏”到学生模型中去,其本质就是在训练小型学生模型时,用大型教师模型指导,从而实现知识的传递。

2. 编码器-解码器结构

有效地对这类输入序列和输出序列不等长的问题进行建模。

利用编码器对源语言输入序列 x 进行编码,形成一个语义向量 c ,然后利用解码器对 c 进行解码,最终得到目标语言输出序列 y 。

3. 注意力机制

一般分为全局注意力机制、局部注意力机制和自注意力机制三种。

全局注意力是指解码器端的注意力计算时要考虑编码器端输入序列中所有的序列。

局部注意力是指解码器端的注意力计算时仅考虑编码器端输入序列中的部分序列。

自注意力是指让模型注意到整个输入中不同部分之间的相关性。自注意力机制是 Transformer 模型的核心。

4. Transformer

Transformer 的结构由编码器和解码器两部分组成。

Transformer 编码器将输入序列转换成词嵌入向量(简称词向量)。在实现过程中,词向量可以随机初始化后随着网络训练得到,也可以加载预先训练好的词向量表示。

Transformer 可以并行地执行自注意力机制,产生多个输出值,再将这些值拼接起来进行再次投影。在自注意力机制的基础上设计了多头自注意力机制。

5. 生成式人工智能的应用

GAN 应用最成功的领域是计算机视觉,包括图像和视频生成,如图像翻译、图像超分辨率、图像修复、图像上色、人脸图像编辑以及视频生成等。

思考题

- 10.1 简述大语言模型的概念与特点。
- 10.2 什么是提示词工程？
- 10.3 为什么要进行知识蒸馏？
- 10.4 简述知识蒸馏的一般结构。
- 10.5 简述注意力机制的主要结构与分类。
- 10.6 简述 Transformer 的主要结构及其各部分的主要功能。
- 10.7 简述 Transformer 的输入编码机制。
- 10.8 简述 Transformer 的自注意力机制。

读一读

GPT 大模型专家苏茨克维

1985年,伊尔亚·苏茨克维(Ilya Sutskever, 1985—)出生在俄罗斯的诺夫哥罗德,父亲是工程师。2002年,17岁的苏茨克维随家人移民加拿大,就读于多伦多大学,跟随人工智能导师杰弗里·辛顿研究神经网络,从本科生到硕士生、博士生,十年如一日。2012年他和 Alex Krizhevsky、导师辛顿共同设计了卷积神经网络 AlexNet,在 ImageNet 比赛中取得了冠军。2012年博士毕业后,在斯坦福大学吴恩达(Andrew NG)教授课题组做博士后,之后和 Alex Krizhevsky、辛顿联合创办了 DNNResearch 公司,2013年,DNNResearch 公司被谷歌收购。2015年12月,苏茨克维作为联合创始人创办了 OpenAI,任首席科学家。

苏茨克维也是 AlphaGo 论文的众多作者之一。2013年,他提出的动量梯度下降法是目前深度学习模型的主流优化算法。他主导了 GPT 系列大模型的开发,在人机对话、生成式人工智能等领域取得重大突破,入选2015年“MIT 评论 35 岁以下创新人物”。2020年1月,他荣登 AI 全球最具影响力学者榜单。

第 11 章 AI 智能体与多智能体系统

随着以大语言模型为核心的人工智能技术的飞速发展, AI 智能体 (AI agent) 为人工智能的研究提供了一个通用范式, 人工智能领域的多种不同技术能够在这个范式下融合共生, 成为当前人工智能研究的热点之一。多智能不仅具备求解自身问题的能力和行为目标, 而且能够相互协作, 以达到共同的整体目标。因此, 对于复杂的大规模问题, 可以根据用户的输入选择工具、方法, 自行确定解决步骤, 最终完成用户预期目标并返回结果。

本章在介绍 AI 智能体与多智能体系统概念的基础上, 简要介绍多智能体系统中的通信、协作、协调等基本技术。

11.1 AI 智能体的概念与结构

11.1.1 AI 智能体的概念

智能体 (Agent) 技术是当前人工智能研究的热点之一。Agent 在英语中是个多义词, 国内学术界将 Agent 翻译为“主体”“智能体”“智能代理”等, 尚无统一的译法。本章将 Agent 翻译为“智能体”, 或者直接引用英文。

马文·明斯基于 1986 年提出 Agent (智能体) 的概念。早期的智能体系统依赖于简单的逻辑规则和预设的行为模式。这些系统通常用于特定场景下的自动化任务, 例如基于预设规则的智能家居控制、简单的游戏代理。这时的智能体缺乏自适应能力, 当环境发生变化时, 只能通过人工调整规则进行适应。

1977 年, Hewitt 提出的并发 Actor 模型。这个模型中包含具有自控行为、相互作用、并发执行的对象, 并被称为 Actors。他们不仅封装了内部状态, 还通过消息传递机制进行通信和并发工作。Actors 被认为是最早的 Agent。

进入 20 世纪 80 年代, 主要研究 Agent 之间的交互通信、协调合作, 强调 Agent 之间的紧密群体合作而非个体能力的自治和发挥。80 年代末, 分布式计算环境的普及推动了多 Agent 技术的发展。

随着 Agent 的能力不断加强, 能越来越多地模拟人的思维和行为, 在软硬件领域, 并行计算

和分布式处理技术的研究都取得了很大进展,使得早期研究者探索的一些 Agent 问题已经在许多新领域广泛开展,如分布式人工智能、机器人学、人工生命、分布式对象计算、人机交互、智能和适应性界面、智能搜索和筛选、信息检索、知识获取、终端用户程序设计等。

近年来,随着大数据与人工智能技术的迅速发展,大语言模型(LLM)驱动的 Agent 更多地称为 AI Agent,在中文语境下通常被称为“AI 智能体”或仍然称为“智能体”。

AI 智能体指由大模型驱动,不需要人为干预,能够自主感知环境、独立进行规划决策并自动调用工具以完成给定目标的智能程序。

AI 智能体更强调自主性和主动性,无须人类去指定每一步的操作。用户使用大模型时可以直接向 AI 智能体下达指令,无须设计合适的提示词,而由 AI 智能体自行规划解决方案并完成任务。AI 智能体未来可能会形成自己的社会,与人类和谐共存。

智能体可以看作由大脑、感知、行动三个关键部分组成:

大脑(brain):由一个大语言模型(LLM)组成,不仅存储知识和记忆,还承担信息处理和决策等功能,并可以呈现推理和规划的过程,能够很好地应对未知任务。

感知(perception):核心任务是将 Agent 的感知空间从纯文字领域扩展到包括文字、听觉和视觉模式在内的多模态领域。

行动(action):在 Agent 的构建过程中,行动模块接收大脑模块发送的行动序列,并执行与环境互动的行动。

在人工智能领域中,Agent 可以看作一个程序或者一个实体,它嵌入在环境中,通过传感器(sensor)感知环境,通过效应器(effector)自治地作用于环境并满足设计要求。Agent 与环境的交互作用如图 11.1 所示。



图 11.1 Agent 与环境的交互作用

智能体可分为物理智能体与虚拟智能体,前者如机器人,后者则包括各种软件代理。实际上,一个人可以看成是一个 Agent,眼睛、耳朵等器官如同传感器,而手、脚和嘴如同执行器。一个机器人也可以看成是一个 Agent,通过摄像头、红外传感器等传感设备感知外界环境,各种各样的马达作为执行器作用于外界环境。

一个软件 Agent,使用经过编码的二进制符号序列作为感知与动作的表示。传统的整体设计和集中控制的软件开发方法越来越显示出局限性。智能和分布式的软件系统已经成为软件系统设计的一个重要方向。综合集成分布于 Internet 的异构软件以支持社团组织完成多部门甚至多社团组织之间合作的具有空间、时间和功能分布性的复杂任务,正在成为建立新型计算环境的主要动力。

大语言模型驱动的 AI 智能体,具有如下的优势:

- (1) 语言交互:它们理解和产生语言的固有能力确保了无缝的用户交互;
- (2) 决策能力:大语言模型有能力推理和决策,使它们善于解决复杂的问题;
- (3) 灵活适配:AI 智能体的适应性确保它们可以针对不同的应用进行成型;
- (4) 协作交互:AI 智能体可以与人类或其他 AI 智能体协作,为多方面的交互铺平道路。

11.1.2 AI 智能体的特性

Agent 作为独立的智能实体应该具备以下特性。

1. 自主性

自主性是独立地作出决策,而不依赖于外部指令。一个 Agent 应该具有独立的局部于自身的知识和知识处理方法,在自身的有限计算资源和行为控制机制下,能够在没有人类和其他 Agent 的直接干预和指导的情况下持续运行,以特定的方式响应环境的要求和变化,并能够根据其内部状态和感知到的环境信息自主决定和控制自身的状态和行为。

自主性是 Agent 区别于过程、对象等其他抽象概念的一个重要特征。

2. 适应性

适应性使其根据环境变化调整行为,保持有效性。Agent 能够感知、影响环境。不只是简单被动地对环境的变化做出反应,而是可以表现出受目标驱动的自发行为。Agent 的行为是为了实现自身内在的目标,在某些情况下,Agent 能够采取主动的行为,改变周围的环境,以实现自身的目标。

3. 互动性

互动性是智能体与环境及其他智能体之间的交流与合作。如同现实世界中的生物群体一样,Agent 往往不是独立存在的,经常有很多 Agent 同时存在,形成多智能体系统,模拟社会性的群体。因此,Agent 不仅能够自主运行,同时应该具有和外部环境中其他 Agent 相互协作的能力,在遇到冲突时能够通过协商来解决问题。

4. 学习能力

学习能力是智能体能够在不断的经验积累中,优化决策过程,提高任务完成的效率。Agent 应该能够在交互过程中逐步适应环境,自主学习,自主进化。能够随着环境的变化不断扩充自身的知识和能力,提高整个系统的智能性和可靠性。

11.1.3 AI 智能体的结构

Agent 结构接受传感器的输入,然后运行 Agent 程序,并把执行的结果传送到效应器进行动作。Agent 系统的结构直接影响到系统的性能。人工智能的任务就是设计 Agent 程序,实现 Agent 从感知到动作的映射函数。这种 Agent 程序需要在某种称为结构的计算机设备上运行。简单的 Agent 结构可能只是一台计算机,复杂的 Agent 结构可能包括用在特定任务上的特殊硬件设备,如图像采集设备或者声音滤波设备等。Agent 结构可能还包括隔离纯硬件和 Agent 程

序的软件平台。

Agent、体系结构和程序之间具有如下关系：

$$\text{Agent} = \text{体系结构} + \text{程序}$$

在计算机系统中, Agent 含有独立的外部设备、输入/输出驱动装备、各种功能操作处理程序、数据结构和相应的输出。程序的核心部分是决策生成器或问题求解器, 它接收全局状态、任务和时序等信息, 指挥相应的功能操作程序模块工作, 并把内部工作状态和所要执行的重要结果送至全局数据库。Agent 的全局数据库设有存放 Agent 状态、参数和重要结果的数据库, 供总体协调使用。Agent 的运行是一个或多个进程, 并接受总体调度。各个 Agent 在多个计算机上并行运行, 其运行环境由体系结构支持。体系结构还提供共享资源、Agent 间的通信工具和 Agent 间的总体协调, 以使各个 Agent 在同一目标下并行、协调工作。

Agent 的结构表示了 Agent 内部各模块集合的组成和相互作用的关系。模块集合及其相互作用规定了 Agent 如何根据所获得的数据和它的运作策略来决定和修改 Agent 的输出。

Agent 结构需要解决以下问题：

- ① Agent 由哪些模块组成；
- ② 这些模块之间如何交互信息；
- ③ Agent 感知到的信息如何影响它的行为和内部状态；
- ④ 如何将这些模块用软件或硬件的方式组合起来形成一个有机的整体。

单个 Agent 的结构按属性可以分为：反应式体系结构 (reactive architecture)、慎思式体系结构 (deliberative architecture) 和复合式体系结构 (complex architecture)。

AI 智能体的架构如图 11.2 所示。




图 11.2 AI 智能体的架构

由图 11.2 可见, AI 智能体具有三个方面的能力：

- (1) 规划与决策能力 (planning)：将一项复杂任务分解为多个子目标与多项小任务。
- (2) 记忆能力 (memory)：能够对任务、对话中的上下文进行保持, 以确保信息的连贯性和准确性。

(3) 工具使用能力(tool):能够根据各类工具扩展自身功能,以应用于更广泛的场景。

11.1.4 反应式 Agent

反应式 Agent 是一种具备对当时处境的实时反应能力的 Agent。图 11.3 所示为反应式 Agent 的结构示意图。反应式结构又称为包孕式结构(subsumption)。

图 11.3 中,Agent 的 If-then 规则使 Agent 将感知和动作连接起来。反应式 Agent 内部预置了相关的知识,包含了行为集和约束关系。在外界刺激符合一定的条件后,直接调用预置的知识,产生相应的输出。每个 Agent 既是客户又是服务器,根据程序提出请求或做出回答。其行为以感知的外界信息为激发条件,中间不需要逻辑表示和推理。该 Agent 不制订将来行为计划,由设计者根据工作要求给出 Agent 执行的动作。




图 11.3 反应式 Agent 的结构示意图

反应式 Agent 能及时快速地响应外来信息和环境的变化,但其智能程度较低,也缺乏足够的灵活性,因此它适用于任务简单的实时环境。

11.1.5 慎思式 Agent

慎思式 Agent 是一种基于知识的系统,包括环境描述和丰富的智能行为的逻辑推理能力。慎思式 Agent 结构示意图如图 11.4 所示,Agent 接收的外部环境信息,依据内部状态进行信息融合,以产生修改当前状态的描述。然后,在知识库的支持下制定规划,再在目标指引下形成动作序列,对环境进行作用。




图 11.4 慎思式 Agent 的结构示意图