

第六章 数理统计的基本概念

主要内容

- 一 总体与样本
- 二 样本数据的整理
- 三 统计量
- 四 抽样分布

数理统计的任务是**以概率论为基础**，根据试验所得到的数据，对研究对象的客观统计规律性做出合理的推断。**从局部认识整体**是数理统计学的最大特点。

一、总体与个体

1. 总体 X ：研究对象的全体元素组成的集合。
2. 个体：总体中的每个可能观察值。

实例1 在研究2000名学生的年龄时，这些学生的年龄的全体就构成一个总体，每个学生的年龄就是个体。



一、总体与个体

3. 有限总体和无限总体

实例2 某工厂10月份生产的灯泡寿命所组成的总体中, 个体的总数就是10月份生产的灯泡数, 这是一个有限总体; 而该工厂生产的所有灯泡寿命所组成的总体是一个无限总体, 它包括以往生产和今后生产的灯泡寿命.

当有限总体包含的个体的总数很大时, 可近似地将它看成是无限总体.



一、总体与个体

4. 总体分布

实例3 在2000名大学一年级学生的年龄中, 年龄指标值为“15”, “16”, “17”, “18”, “19”, “20”的依次有9, 21, 132, 1207, 588, 43 名, 它们在总体中所占比率依次为

$$\frac{9}{2000}, \frac{21}{2000}, \frac{132}{2000}, \frac{1207}{2000}, \frac{588}{2000}, \frac{43}{2000},$$

即学生年龄的取值有一定的分布.

一般地, 我们所研究的总体, 即研究对象的某项数量指标 X , 其取值在客观上有一定的分布, X 是一个随机变量.

总体分布的定义

我们把数量指标取不同数值的比率叫做总体分布.

如实例3中, 总体就是数集 $\{15, 16, 17, 18, 19, 20\}$. 总体分布为:

年龄	15	16	17	18	19	20
比率	$\frac{9}{2000}$	$\frac{21}{2000}$	$\frac{132}{2000}$	$\frac{1207}{2000}$	$\frac{588}{2000}$	$\frac{43}{2000}$

注意：

总体：研究对象的全体组成的集合.

个体：总体中的每个可能观察值。

总体分布：总体中的不同数值含有的比率.

总体总联系着一个数量指标值 X ，而 X 是一个随机变量.

总体用 X 表示，总体分布就是 X 的分布.

X 的分布函数和数字特征称为**总体的分布函数和数字特征**.

二、样本

1. 样本的定义

样本(子样, sample): 从总体中取的一部分个体。

样本容量: 样本中所含个体的个数。

随机抽样法: 样本中的每一个个体是从总体中随机地取出来的。

随机样本: 采用随机抽样法得到的样本。

样本空间: 样本所有可能取值的集合。

样本 $(X_1, X_2, \dots, X_n)$ 样本值 $(x_1, x_2, \dots, x_n)$

2. 简单随机样本：若总体 X 的样本 $(X_1, X_2, \dots, X_n)$ 满足：

(1) X_i 与 X 服从相同的分布.

(2) $X_1, X_2, \dots, X_n$ 相互独立.

则称 $(X_1, X_2, \dots, X_n)$ 为简单随机样本.

一般,对有限总体,放回抽样所得到的样本为简单随机样本,但使用不方便,常用不放回抽样代替. 而代替的条件是

$$N / n \geq 10.$$

总体中个体总数

样本容量

3. 简单随机样本的分布函数

设 X 是具有分布函数 F 的随机变量, 若 $X_1, X_2, \dots, X_n$ 是具有同一分布函数 F 、相互独立的随机变量, 则称 $X_1, X_2, \dots, X_n$ 为从分布函数 F (或总体 F 、或总体 X) 得到的容量为 n 的简单随机样本.

它们的观察值 $x_1, x_2, \dots, x_n$ 称为样本值, 又称为 X 的 n 个独立的观察值.

则 $X_1, X_2, \dots, X_n$ 的联合分布函数为:

$$F(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F(x_i)$$

若 X 具有概率密度 f , 则 $X_1,$

$X_2, \dots, X_n$ 的联合概率密度为:

$$f(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i)$$

3. 简单随机样本的分布函数

设总体 X 的分布函数为 $F(x)$, 样本 $(X_1, X_2, \dots, X_n)$ 的分布函数

$$\begin{aligned} F(x_1, x_2, \dots, x_n) &= P\{X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n\} \\ &= P\{X_1 \leq x_1\} P\{X_2 \leq x_2\} \cdots P\{X_n \leq x_n\} = \prod_{i=1}^n F(x_i) \end{aligned}$$

连续型随机变量: $f(x_1, x_2, \dots, x_n) = f(x_1) f(x_2) \cdots f(x_n)$

离散型随机变量: $P\{X_1 = x_1, X_2 = x_2, \dots, X_n = x_n\} = \prod_{i=1}^n P\{X_i = x_i\}$

例 设某批产品共有 N 个,其中的次品数为 M , 其次品率为

$$p = M / N$$

若 p 是未知的,则可用抽样方法来估计它.

从这批产品中任取一个产品,用随机变量 X 来描述它是否是次品:

$$X = \begin{cases} 1, & \text{所取的产品是次品} \\ 0, & \text{所取的产品不是次品} \end{cases}$$

X 服从参数为 p 的0-1分布,可用如下表示方法:

$$f(x, p) = p^x (1 - p)^{1-x}, \quad x = 0, 1$$

设有放回地抽取一个容量为 n 的样本 $(X_1, X_2, \dots, X_n)$

其样本值为 $(x_1, x_2, \dots, x_n)$

样本空间为 $\{(x_1, x_2, \dots, x_n) \mid x_i = 0, 1, i = 1, 2, \dots, n\}$

$(X_1, X_2, \dots, X_n)$ 的联合分布律为

$$\begin{aligned} f_{\text{总}}(x_1, x_2, \dots, x_n) &= \prod_{i=1}^n f(x_i) \\ &= p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i} \end{aligned}$$

若抽样是无放回的,则前次抽取的结果会影响后面抽取的结果.例如

$$P(X_2 = 1 \mid X_1 = 0) = \frac{M-1}{N-1} = \frac{p - \frac{1}{N}}{1 - \frac{1}{N}} \xrightarrow{N \rightarrow \infty} p$$

$$P(X_2 = 1 \mid X_1 = 0) = \frac{M}{N-1} = \frac{p}{1 - \frac{1}{N}} \xrightarrow{N \rightarrow \infty} p$$

所以, 当样本容量 n 与总体中个体数目 N 相比很小时, 可将无放回抽样近似地看作放回抽样.

例 设总体 X 服从参数为 λ ($\lambda > 0$) 的指数分布, $(X_1, X_2, \dots, X_n)$ 是来自总体的样本, 求样本 $(X_1, X_2, \dots, X_n)$ 的概率密度.

解 总体 X 的概率密度为
$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0, \\ 0, & x \leq 0, \end{cases}$$

因为 $X_1, X_2, \dots, X_n$ 相互独立, 且与 X 有相同的分布, 所以 $(X_1, X_2, \dots, X_n)$ 的概率密度为

$$f_n(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i) = \begin{cases} \lambda^n e^{-\lambda \sum_{i=1}^n x_i}, & x_i > 0, \\ 0, & \text{其他.} \end{cases}$$

例：设 X_1, X_2, X_3 是来自柯西分布的样本，其概率密度函数为

$$p(x) = \frac{1}{\pi} \cdot \frac{1}{1+x^2}, -\infty < x < +\infty, \text{试求}(X_1, X_2, X_3)\text{的联合概率密度.}$$

解 因为 X_i 自于柯西分布，所以 X_i 的密度函数是

$$p_{X_i}(x_i) = \frac{1}{\pi} \cdot \frac{1}{1+x_i^2}, \quad -\infty < x_i < +\infty \quad (i=1, 2, 3)$$

所以 (X_1, X_2, X_3) 的联合概率密度是：

$$p_{(X_1, X_2, X_3)}(x_1, x_2, x_3) = \prod_{i=1}^3 p_{X_i}(x_i) = \frac{1}{\pi^3} \cdot \frac{1}{(1+x_1^2)(1+x_2^2)(1+x_3^2)}, x_1, x_2, x_3 \in R$$

三、小结

基本概念: 个体 总体 $\left\{ \begin{array}{l} \text{有限总体} \\ \text{无限总体} \end{array} \right.$ 随机样本

说明1 一个总体对应一个随机变量 X , 我们将不区分总体和相应的随机变量, 统称为总体 X .

说明2 在实际中遇到的总体往往是有限总体, 它对应一个离散型随机变量; 当总体中包含的个体的个数很大时, 在理论上可认为它是一个无限总体.

谢谢！

第六章 数理统计的基本概念

主要内容

- 一 总体与样本
- 二 样本数据的整理
- 三 统计量
- 四 抽样分布

总体 X 是随机变量，其概率分布是客观存在的，但往往又是未知的，要由我们来确定，常常用样本分布来作为总体分布的近似。

常用的方法有：

频数分布与频率分布（对离散型总体使用）

频率直方图（对连续型总体使用）

经验分布函数（对各种类型总体都可以使用）

1. 样本频数分布和频率分布

设有样本值 $(x_1, x_2, \dots, x_n)$, 不同数值为 $x_1^* < x_2^* < \dots < x_l^*$,

样本频数分布: 样本值中不同数值在样本中出现的次数(频数).

指标 X	x_1^*	x_2^*	$\dots$	x_l^*
频数 m_i	m_1	m_2	$\dots$	m_l

样本频率分布: 样本值中不同数值在样本中出现的频率.

指标 X	x_1^*	x_2^*	$\dots$	x_l^*
频率 m_i / n	m_1 / n	m_2 / n	$\dots$	m_l / n

2. 频率直方图

设总体 X 是连续型随机变量, 概率密度为 $f(x)$, $(x_1, x_2, \dots, x_n)$ 是来自总体 X 的样本值.

可以做频率直方图, 并由此近似得出总体 X 的概率密度曲线.

数据的简单处理

为了研究随机现象，首要的工作是收集原始数据.一般通过抽样调查或试验得到的数据往往是杂乱无章的，需要通过整理后才能显示出它们的分布状况。

数据的简单处理是以一种直观明了方式加工数据。

- 它包括两个方面——
1. 数据整理
 2. 计算样本特征数

数据整理：将数据分组——→ 计算各组频数
作频率分布表——→ 作频率直方图

- 计算样本特征数：

- (1) 反映趋势的特征数

样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$

中位数：数据按大小顺序排列后，位置居中的那个数或居中的两个数的平均数。

众数：样本中出现最多的那个数。

例 为对某小麦杂交组合 F_2 代的株高 X 进行研究，抽取容量为100的样本，测试的原始数据记录如下(单位：厘米)，试根据以上数据，画出它的频率直方图，求随机变量 X 的分布状况。

87	88	111	91	73	70	92	98	105	94
99	91	98	110	98	97	90	83	92	88
86	94	102	99	89	104	94	94	92	96
87	94	92	86	102	88	75	90	90	80
84	91	82	94	99	102	91	96	94	94
85	88	80	83	81	69	95	80	97	92
96	109	91	80	80	94	102	80	86	91
90	83	84	91	87	95	76	90	91	77
103	89	88	85	95	92	104	92	95	83
86	81	86	91	89	83	96	86	75	92

第一. 整理原始数据, 加工为分组资料, 作出频率分布表, 画直方图, 提取样本分布特征的信息. 步骤如下:

1. 找出数据中最小值 $m=69$, 最大值 $M=111$, 极差为 $M-m=42$

2. 数据分组, 根据样本容量 n 的大小, 决定分组数 k 。

一般规律	$30 \leq n \leq 40$	$5 \leq k \leq 6$
	$40 \leq n \leq 60$	$6 \leq k \leq 8$
	$60 \leq n \leq 100$	$8 \leq k \leq 10$
	$100 \leq n \leq 500$	$10 \leq k \leq 20$

数据数	40~60	100	150	200	400	600	800	1000	1500	2000	5000	10000
分组数	6~8	7~9	10~15	16	20	24	27	30	35	39	56	74

本例取 $k=9$.

一般采用等距分组（也可以不等距分组），组距等于极差除以组数略大的测量单位的整数倍。

本例测量单位为1厘米，组距为

$$\frac{M - m}{k} = \frac{111 - 69}{9} \approx 4.7 \approx 5$$

3. 确定组限和组中点值。

一般根据算式：

$$\text{各组中点值} \pm \frac{1}{2} \times \text{组距} = \text{组的上限或下限}$$

注意：组的上限与下限应比数据多一位小数。

当取 $a=67.5$ ， $b=112.5$ （ a 略小于 m ， b 略大于 M ，且 a 和 b 都比数据多一位小数），分组如下：

[67.5,72.5)	[72.5,77.5)	[77.5,82.5)
[82.5,87.5)	[87.5,92.5)	[92.5,97.5)
[97.5,102.5)	[102.5,107.5)	[107.5,112.5)

4. 将数据分组，计算出各组频数，作频数、频率分布表


组序	区间范围	频数 f_j	频率 $W_j=f_j/n$	累计频率 F_j
1	[67.5,72.5)	2	0.02	0.02
2	[72.5, 77.5)	5	0.05	0.07
3	[77.5, 82.5)	10	0.10	0.17
4	[82.5, 87.5)	18	0.18	0.35
5	[87.5, 92.5)	30	0.3	0.65
6	[92.5, 97.5)	18	0.18	0.83
7	[97.5, 102.5)	10	0.1	0.93
8	[102.5, 107.5)	4	0.04	0.97
9	[107.5, 112.5)	3	0.03	1.00

5. 作出频率直方图

以样本值为横坐标，频率/组距为纵坐标；

以分组区间为底，以 $Y_j = \frac{W_j}{X_{j+1} - X_j} = \frac{W_j}{5}$ 为高

作频率直方图



从频率直方图可看到：靠近两个极端的数据出现比较少，而中间附近的数据比较多，即中间大两头小的分布趋势，——随机变量分布状况的最粗略的信息。

在频率直方图中，每个矩形面积恰好等于样本值落在该矩形对应的分组区间内的频率，即

$$S_j = \frac{W_j}{X_{j+1} - X_j} \times (X_{j+1} - X_j) = W_j$$

频率直方图中的小矩形的面积近似地反映了样本数据落在某个区间内的可能性大小，故它可近似描述X的分布状况。

3. 经验分布函数

设 $(x_1, x_2, \dots, x_n)$ 是来自总体 X 的样本值, 定义

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{\{x_i \leq x\}}(x), \quad \text{其中 } I_{\{x_i \leq x\}}(x) = \begin{cases} 1, & x_i \leq x \\ 0, & x_i > x \end{cases}$$

称 $F_n(x)$ 为样本 $(x_1, x_2, \dots, x_n)$ 的**经验分布函数**.

满足分布函数的性质.

设 $(x_1, x_2, \dots, x_n)$ 是来自总体 X 的样本值, 定义

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{\{x_i \leq x\}}(x), \quad \text{其中 } I_{\{x_i \leq x\}}(x) = \begin{cases} 1, & x_i \leq x \\ 0, & x_i > x \end{cases},$$

将样本值由小到大排序 $x_{(1)} < x_{(2)} < \dots < x_{(l)}$,

每个不同样本值出现的频数记为: $m_1, \dots, m_l$

$$F_n(x) = \begin{cases} 0, & x < x_{(1)} \\ \frac{m_1 + \dots + m_k}{n}, & x_{(k)} \leq x < x_{(k+1)} \\ 1, & x \geq x_{(l)} \end{cases}$$

设 $(x_1, x_2, \dots, x_n)$ 是来自总体 X 的样本值, 定义

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{\{x_i \leq x\}}(x), \quad \text{其中 } I_{\{x_i \leq x\}}(x) = \begin{cases} 1, & x_i \leq x \\ 0, & x_i > x \end{cases},$$

称 $F_n(x)$ 为样本 $(x_1, x_2, \dots, x_n)$ 的**经验分布函数**.

含义: (1) $(x_1, x_2, \dots, x_n)$ 给定, $F_n(x)$ 是 x 的函数,
表示 $(x_1, x_2, \dots, x_n)$ 落入 $(-\infty, x]$ 内的概率.

(2) $F_n(x)$ 与 $(x_1, x_2, \dots, x_n)$ 有关, 是一个随机变量.

例 某食品厂生产听装饮料，现从生产线上随机抽取5听饮料，称得其净重（单位：克） 351 347 355 344 351

解： 这是一个容量为5的样本，经排序可得有序样本：

$$x_{(1)} = 344, x_{(2)} = 347, x_{(3)} = 351, x_{(4)} = 354, x_{(5)} = 355$$

其经验分布函数为 $F_n(x) = \begin{cases} 0, & x < 344 \\ 0.2, & 344 \leq x < 347 \\ 0.4, & 347 \leq x < 351 \\ 0.8, & 351 \leq x < 354 \\ 1, & x \geq 354 \end{cases}$

由**伯努里大数定律**：

只要 n 相当大， $F_n(x)$ 依概率收敛于 $F(x)$ 。

例 从织布车间抽取12匹布检查每匹布的疵点数，得样本
(1,0,0,2,1,3,2,0,1,1,2,1) 求样本频数分布和样本频率分布.

解： 将12个数从小到大排列,相同的合并, 0,0,0,1,1,1,1,1,2,2,2,3

得样本频数表(样本频数分布)

X	0	1	2	3
频数 m_i	3	5	3	1

得样本频率表(样本频率数分布)

X	0	1	2	3
频率 $\frac{m_i}{n}$	1/4	5/12	1/4	1/12

经验分布函数


设样本为 $(x_1, x_2, \dots, x_n)$, 对任意实数 x , 样本值中小于或等于 x 的个数为 $m(x)$, 则称 $F_n^*(x) = \frac{m(x)}{n}$ 为样本的经验分布函数.

$F_n^*(x)$ 同分布函数 $F(x)$ 一样具有性质:

非降、右连续、 $F_n^*(-\infty) = 0$, $F_n^*(+\infty) = 1$.


由样本频数分布得样本经验分布函数

$$F_n^*(x) = \begin{cases} 0, & x < x_1^* \\ \frac{m_1}{n}, & x_1^* \leq x < x_2^* \\ \frac{m_1 + m_2}{n}, & x_2^* \leq x < x_3^* \\ \vdots & \vdots \\ \sum_{i=1}^k m_i / n, & x_k^* \leq x < x_{k+1}^* \quad (k \leq l-1) \\ \vdots & \vdots \\ 1 & x \geq x_l^* \end{cases}$$



本例的样本经验分布函数：

$$F_n^*(x) = \begin{cases} 0, & x < 0 \\ 1/4, & 0 \leq x < 1 \\ 2/3, & 1 \leq x < 2 \\ 11/12, & 2 \leq x < 3 \\ 1 & x \geq 3 \end{cases}$$



由Chebyshev 大数定律, 对任意 $\varepsilon > 0$

$$\lim_{n \rightarrow \infty} P\left(\left|F_n^*(x) - F(x)\right| < \varepsilon\right) = 1$$

即 $F_n^*(x) \xrightarrow[n \rightarrow \infty]{p} F(x)$ 对固定 x 成立

样本经验
分布函数

依概率收敛于

总 体
分布函数

格里纹科(W. Clivenko,1933年)定理（了解）

定理（格里纹科定理） 设 $x_1, x_2, \dots, x_n$ 是取自总体分布函数为 $F(x)$ 的样本, $F_n(x)$ 是其经验分布函数，当 $n \rightarrow \infty$ 时，有

$$\lim_{n \rightarrow \infty} P \left(\sup_{x \in R} |F_n(x) - F(x)| < \varepsilon \right) = 1$$

格里纹科定理表明：当 n 相当大时，经验分布函数依概率关于 x 均匀地收敛于总体分布函数，经验分布函数 $F_n(x)$ 是总体分布函数 $F(x)$ 的一个良好的近似。

经典统计学中一切统计推断都以样本为依据，其理由就在于此。

谢谢！

第六章 数理统计的基本概念

主要内容

- 一 总体与样本
- 二 样本数据的整理
- 三 统计量
- 四 抽样分布

1. 统计量的定义

定义 设 $(X_1, X_2, \dots, X_n)$ 是来自总体 X 的样本, $T = g(X_1, X_2, \dots, X_n)$ 是关于 $(X_1, X_2, \dots, X_n)$ 的一个连续函数, 且不含有任何未知参数, 称 T 为样本 $(X_1, X_2, \dots, X_n)$ 的一个**统计量**.

设 $(x_1, x_2, \dots, x_n)$ 是样本的观察值, 则 $t = g(x_1, x_2, \dots, x_n)$ 称为统计量 $T = g(X_1, X_2, \dots, X_n)$ 的**观察值**.

例 $X \sim N(\mu, \sigma^2)$, μ, σ^2 是未知参数,

$(X_1, X_2, \dots, X_n)$ 是一样本, 则

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

是统计量, 其中 $X_i \sim N(\mu, \sigma^2)$

但 $\frac{1}{n} \sum_{i=1}^n (X_i - \mu), \quad \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2$ 不是统计量

然而, 如果 μ, σ 已知, 则又为统计量

练习： 设 X_1, X_2, X_3 是来自总体 $N(\mu, \sigma^2)$ 的一个样本, 其中 μ 为已知, σ^2 为未知, 判断下列各式哪些是统计量, 哪些不是?

$$T_1 = X_1, \quad T_2 = X_1 + X_2 e^{X_3}, \quad T_3 = \frac{1}{3}(X_1 + X_2 + X_3),$$

$$T_4 = \max(X_1, X_2, X_3), \quad T_5 = X_1 + X_2 - 2\mu, \quad \text{以上都是}$$

$$T_6 = \frac{1}{\sigma^2}(X_1^2 + X_2^2 + X_3^2). \quad \text{不是}$$

2. 常用的统计量

设 $(X_1, X_2, \dots, X_n)$ 是来自总体 X 的样本, $(x_1, x_2, \dots, x_n)$ 是观察值.

(1) 样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$

定理1 设总体 X 满足 $E(X) = \mu$ 和 $D(X) = \sigma^2$ 存在, 则

(1) $E(\bar{X}) = \mu, \quad D(\bar{X}) = \frac{\sigma^2}{n};$

(2) $\bar{X}$ 依概率收敛到 μ .

$\bar{X}$ 常用于估计总体均值, 或检验有关总体均值的假设.

(2) 样本方差

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right)$$

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad \text{样本标准差 } S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

注:在该定义中, $\sum (x_i - \bar{x})^2$ 称为**偏差平方和**, $n-1$ 称为偏差平方和的**自由度**。其含义是: 在 $\bar{x}$ 确定后, n 个偏差 $x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_n - \bar{x}$ 中, 只有 $n-1$ 个数据可以自由变动, 而第 n 个则不能自由取值, 因为 $\sum (x_i - \bar{x}) = 0$ 。

$$\text{样本方差 } S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right)$$

$$\text{样本标准差 } S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

定理2 设总体 X 满足 $E(X) = \mu$ 和 $D(X) = \sigma^2$ 存在, 则

(1) $E(S^2) = \sigma^2$;

(2) S^2 依概率收敛到 σ^2 .

S^2 常用于估计总体方差, 或检验有关总体方差的假设.

注 样本方差 S^2 与样本二阶中心矩 S_n^2 的不同

$$S^2 = \frac{n}{n-1} S_n^2, E(S_n^2) = \frac{n-1}{n} \sigma^2, E(S^2) = \sigma^2$$

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

推导: 设 $E(X) = \mu, D(X) = \sigma^2$ 则

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \mu \quad D(\bar{X}) = \frac{1}{n} \sigma^2$$

$$E(S_n^2) = EA_2 - E(\bar{X}^2) = E\left(\frac{1}{n} \sum_{i=1}^n X_i^2\right) - [D(\bar{X}) + E^2(\bar{X})] = \sigma^2 + \mu^2 - \left(\frac{1}{n} \sigma^2 + \mu^2\right) = \frac{n-1}{n} \sigma^2$$

$$E(S^2) = E\left[\frac{n}{n-1} S_n^2\right] = \frac{n}{n-1} E S_n^2 = \sigma^2$$

(3) 样本矩

样本 k 阶原点矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \quad (k=1, 2, \dots), \quad a_k = \frac{1}{n} \sum_{i=1}^n x_i^k$

样本 k 阶中心矩 $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k \quad (k=1, 2, \dots), \quad b_k = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k$

由以上定义得下述**结论**:

若总体 X 的 k 阶矩 $E(X^k)$ 记成 μ_k 存在, 则当 $n \rightarrow \infty$ 时,

$$A_k \xrightarrow{P} \mu_k, k = 1, 2, \dots.$$

证明: 因为 $X_1, X_2, \dots, X_n$ 独立且与 X 同分布,

所以 $X_1^k, X_2^k, \dots, X_n^k$ 独立且与 X^k 同分布,

故有 $E(X_1^k) = E(X_2^k) = \dots = E(X_n^k) = \mu_k$

由辛钦大数定理，知

$$\frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} \mu_k, \quad k = 1, 2, \dots;$$

由第五章“关于依概率收敛的序列的性质”知

$$g(A_1, A_2, \dots, A_k) \xrightarrow{P} g(\mu_1, \mu_2, \dots, \mu_k),$$

其中 g 是连续函数.

以上结论是下一章所要介绍的矩估计法的理论根据.

- 定理2** (1) 若总体 X 的 k 阶矩 $\alpha_k = E(X^k) (k \geq 1)$ 存在, 则 $E(A_k) = \alpha_k$;
- (2) 若总体 X 的 $2k$ 阶矩 α_{2k} 存在, 则 A_k 依概率收敛到 α_k .

样本原点矩常用于估计总体原点矩.

(4) 次序统计量

设 $(X_1, X_2, \dots, X_n)$ 是来自总体 X 的样本, $(x_1, x_2, \dots, x_n)$ 是观察值.

将 $x_1, x_2, \dots, x_n$ 按从小到大排序: $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$.

定义 $X_{(k)}$ 取值 $x_{(k)}$ ($k = 1, 2, \dots, n$),

称 $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ 为次序统计量, 且 $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$

最小次序统计量 $X_{(1)} = \min\{X_1, \dots, X_n\}$,

最大次序统计量 $X_{(n)} = \max\{X_1, \dots, X_n\}$

(5) 样本极差 $R = X_{(n)} - X_{(1)}$

(6) 样本 p 分位数

$$M_p = \begin{cases} X_{(np+1)}, & np \text{不是整数} \\ \frac{1}{2}(X_{(np)} + X_{(np+1)}), & np \text{是整数} \end{cases}$$

例 从一批机器零件毛坯中随机地抽取10件, 测得其重量为(单位: 公斤): 210, 243, 185, 240, 215, 228, 196, 235, 200, 199 求这组样本值的均值、方差、二阶原点矩与二阶中心矩.

解 令 $(x_1, x_2, \dots, x_{10}) = (210, 243, 185, 240, 215, 228, 196, 235, 200, 199)$

则 $\bar{x} = \frac{1}{10}(210 + 243 + 185 + 240 + 215 + 228 + 196 + 235 + 200 + 199) = 217.19$

$$s^2 = \frac{1}{10-1} \sum_{i=1}^{10} (x_i - \bar{x})^2 = 433.43 \quad A_2 = \frac{1}{10} \sum_{i=1}^{10} x_i^2 = 47522.5$$

$$B_2 = \frac{9}{10} s^2 = \frac{1}{10} \sum_{i=1}^{10} (x_i - \bar{x})^2 = 390.0$$

例 在总体 $N(52, 6.3^2)$ 中, 随机抽取一个容量为36的样本, 求样本均值 $\bar{X}$ 落在50.8到53.8之间的概率.

解 $\bar{X} \sim N(52, 6.3^2 / 36)$

故 $P(50.8 < \bar{X} < 53.8)$

$$= \Phi\left(\frac{53.8 - 52}{6.3 / 6}\right) - \Phi\left(\frac{50.8 - 52}{6.3 / 6}\right)$$

$$= \Phi(1.7143) - \Phi(-1.1429)$$

$$= 0.8239$$

例 设总体 X 的概率密度函数为 $f(x) = \begin{cases} |x| & |x| < 1 \\ 0 & |x| \geq 1 \end{cases}$

$(X_1, X_2, \dots, X_{50})$ 为总体的样本,求

(1) $\bar{X}$ 的数学期望与方差 (2) $E(S^2)$ (3) $P(|\bar{X}| > 0.02)$

解 (1) $E(\bar{X}) = E(X) = \int_{-1}^1 x|x|dx = 0$

$$\begin{aligned} D(\bar{X}) &= \frac{1}{50} D(X) = \frac{1}{50} E(X^2) \\ &= \frac{1}{50} 2 \int_0^1 x^2 |x| dx = \frac{1}{100} \end{aligned}$$

$$(2) \quad E(S^2) = D(X) = E(X^2) - E^2(X) = E(X^2) = 1/2.$$

$$(3) \quad \overline{X} \overset{\text{近似}}{\sim} N(0, 0.01) \quad \text{由中心极限定理}$$

$$P(|\overline{X}| > 0.02) = 1 - P(|\overline{X}| \leq 0.02)$$

$$= 2 \left(1 - \Phi \left(\frac{0.02 - 0}{0.1} \right) \right)$$

$$= 2(1 - \Phi(0.2)) = 0.8414$$

谢谢！

第六章 数理统计的基本概念

主要内容

- 一 总体与样本
- 二 样本数据的整理
- 三 统计量
- 四 抽样分布


概率分布的分位数

定义 设随机变量 X 的分布函数为 $F(x) = P\{X \leq x\}$, 对于 $0 < p < 1$, 若 $\exists x_p$, 使 $P\{X \leq x_p\} = F(x_p) = p$, 则称 x_p 为 X 的**下侧 p 分位数**.

对于 $0 < \alpha < 1$, $\exists x_\alpha$ 使 $P\{X > x_\alpha\} = 1 - F(x_\alpha) = \alpha$, 则称 x_α 为 X 的**上侧 α 分位数**. 本书用此!

概率分布的分位数


对总体 X 和给定的 α ($0 < \alpha < 1$), 若存在 x_α , 使 $P\{X \geq x_\alpha\} = \alpha$, 则称 x_α 为 X 分布的上侧 α 分位数。



若存在数 λ_1 、 λ_2 , 使

$$P\{X \geq \lambda_1\} = P\{X \leq \lambda_2\} = \frac{\alpha}{2}$$


则称 λ_1 、 λ_2 为 X 分布的双侧 α 分位数或双侧临界值。



双侧 α 分位数或双侧临界值的特例

当 X 的分布关于 y 轴对称时，若存在 $x_{\alpha/2}$ ，使 $P\{|X| \geq x_{\alpha/2}\} = \alpha$ ，
则称 $x_{\alpha/2}$ 为 X 分布的**双侧 α 分位数**或**双侧临界值**。

如图.



统计量 $f(X_1, X_2, \dots, X_n)$ 是样本 $X_1, X_2, \dots, X_n$ 的不含任何未知数的函数，它是一个随机变量。

统计量的分布称为抽样分布。

由于正态总体是最常见的总体，因此本章主要讨论正态总体下的抽样分布。

由于这些抽样分布的论证要用到较多的数学知识，故在本节中，我们主要给出有关结论，以供应用。

U 分布

正态总体样本均值的分布

设 $(X_1, X_2, \dots, X_n)$ 是来自正态总体 $N(\mu, \sigma^2)$ 的样本, 则

样本均值服从正态分布

$$(1) \quad \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right);$$

$$(2) \quad U = \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} = \frac{\frac{1}{n} \sum_{i=1}^n X_i - \mu}{\sigma / \sqrt{n}} \sim N(0, 1)$$

例：从正态总体 $N(\mu, 25)$ 中抽取容量为 16 的样本，试求样本均值 $\bar{X}$ 与总体均值 μ 之差的绝对值小于 2 的概率。

解： 因为 $E(\bar{X}) = \mu, D(\bar{X}) = 25/16$, 故有 $\bar{X} \sim N(\mu, \frac{25}{16})$.

$$P(|\bar{X} - \mu| < 2) = P\left(\frac{|\bar{X} - \mu|}{\sqrt{25/16}} < \frac{2}{\sqrt{25/16}}\right) = P(|U| < 1.6)$$

$$= \Phi(1.6) - \Phi(-1.6) = 2\Phi(1.6) - 1 = 2 \times 0.9452 - 1 = 0.8904$$

U—分布的上侧分位数

对标准正态分布变量 $U \sim N(0, 1)$ 和给定 α 的, 上侧 α 分位数是


由: $P\{U \geq u_\alpha\} = \int_{u_\alpha}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt = \alpha$ 即 $P\{U < u_\alpha\} = 1 - \alpha$; $\Phi(u_\alpha) = 1 - \alpha$
确定的点 u_α .

例如, $\alpha = 0.05$, 而

$$P\{U \geq 1.645\} = 0.05$$

所以, $u_{0.05} = 1.645$.


如图.



U—分布的双侧分位数

对标准正态分布变量 $U \sim N(0, 1)$ 和给定 α 的, 称满足条件 $P\{|U| \geq u_{\alpha/2}\} = \alpha$ 的点 $u_{\alpha/2}$ 为标准正态分布的**双侧 α 分位数**或**双侧临界值**.

如图.



$u_{\alpha/2}$ 可由 $P\{U \geq u_{\alpha/2}\} = \alpha/2$

即 $\Phi(u_{\alpha/2}) = 1 - \alpha/2$

反查标准正态分布表得到,


例如, 求 $u_{0.05/2}$,

$P\{U \geq 1.96\} = 0.05/2$

得 $u_{0.05/2} = 1.96$

例 若 $X \sim N(0,1)$, 其上侧 α 分位数 u_α 满足
 $P\{X > u_\alpha\} = \alpha$. $u_{0.05} = 1.645$, $u_{0.025} = 1.96$.

$$u_{1-\alpha} = -u_\alpha$$



在实际问题中, α 常取0.1、0.05、0.01.

常用到下面几个临界值:

$$u_{0.05} = 1.645, \quad u_{0.01} = 2.326$$

$$u_{0.05/2} = 1.96, \quad u_{0.01/2} = 2.575$$

数理统计中常用的分布除正态分布外，还有三个非常有用的连续型分布，即

χ^2 分布

t 分布

F 分布

数理统计的三大分布(都是连续型).

它们都与正态分布有密切的联系.



在本章中特别要求掌握对正态分布、 χ^2 分布、 t 分布、 F 分布的一些结论的熟练运用. 它们是后面各章的基础.

伽马函数与伽马分布

伽马函数 $\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha} e^{-x} \frac{dx}{x}$

性质: $\Gamma(\alpha + 1) = \alpha \Gamma(\alpha)$

若n为整数, $\Gamma(n + 1) = n!$

$$\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$$

$$1 = \int_0^{+\infty} \frac{1}{\Gamma(\alpha)} x^{\alpha} e^{-x} \frac{dx}{x}$$

伽马分布

$$f(x) = \frac{1}{\Gamma(\alpha)} x^{\alpha} e^{-x} \frac{1}{x}$$

则称: $X \sim \text{Gamma}(\alpha, 1)$

一般的伽马分布形式：

若 $X \sim \text{Gamma}(\alpha, 1)$ ，则 $Y = X / \lambda$ ， $\lambda > 0$ 的分布为：

$$Y \sim \text{Gamma}(\alpha, \lambda)$$

由变量变换公式 $x = \lambda y$ 及 $\frac{dx}{dy} = \lambda$

得Y 的概率密度函数为：

$$f_Y(y) = f_X(x) \left| \frac{dx}{dy} \right| = \frac{1}{\Gamma(\alpha)} (\lambda y)^\alpha e^{-\lambda y} \frac{1}{\lambda y} \lambda = \frac{1}{\Gamma(\alpha)} (\lambda y)^\alpha e^{-\lambda y} \frac{1}{y}, \quad y > 0$$

Γ 分布

如果随机变量 X 具有概率密度

$$f(x; \alpha, \lambda) = \begin{cases} \frac{(\lambda x)^\alpha}{\Gamma(\alpha)} e^{-\lambda x} \frac{1}{x}, & x > 0 \\ 0, & x \leq 0 \end{cases}, \quad \alpha > 0, \lambda > 0 \text{ 为常数}$$

则称 X 服从参数为 α, λ 的 Γ 分布. 记为

$$X \sim \Gamma(\alpha, \lambda) \text{ 或者 } X \sim \Gamma(x; \alpha, \lambda)$$

特例： 令 $\alpha=1$, 则 $\Gamma(1, \lambda)$ 的概率密度函数为 $f(y) = \lambda \exp(-\lambda y), \quad y \geq 0$

即：指数分布

性质1 若 $X \sim \Gamma(\alpha, \lambda)$, 则 $E(X) = \frac{\alpha}{\lambda}$, $D(X) = \frac{\alpha}{\lambda^2}$.

证:
$$E(X) = \frac{\lambda^\alpha}{\Gamma(\alpha)} \int_0^{+\infty} x^\alpha e^{-\lambda x} dx = \frac{\Gamma(\alpha+1)}{\lambda \Gamma(\alpha)} = \frac{\alpha}{\lambda}$$

$$E(X^2) = \frac{\lambda^\alpha}{\Gamma(\alpha)} \int_0^{+\infty} x^{\alpha+1} e^{-\lambda x} dx = \frac{\Gamma(\alpha+2)}{\lambda^2 \Gamma(\alpha)} = \frac{\alpha(\alpha+1)}{\lambda^2}$$

$$D(X) = E(X^2) - E^2(X) = \frac{\alpha(\alpha+1)}{\lambda^2} - \left(\frac{\alpha}{\lambda}\right)^2 = \frac{\alpha}{\lambda^2}$$

性质2 (可加性)

来源于第三章第4节PPT

若 $X_1 \sim \Gamma(\alpha_1, \lambda)$, $X_2 \sim \Gamma(\alpha_2, \lambda)$, 且 X_1, X_2 相互独立,
则 $X_1 + X_2 \sim \Gamma(\alpha_1 + \alpha_2, \lambda)$.

证: 设 $X = X_1$, $Y = X_2$, $Z = X + Y$

因为 Z 在 $(0, +\infty)$ 内取值, 所以当 $z \leq 0$ 时, $p_Z(z) = 0$.

当 $z > 0$ 用卷积公式, 被积函数 $p_X(z-y)p_Y(y)$ 的积分限为 $0 < y < z$, 故

$$\begin{aligned} p_Z(z) &= \frac{\lambda^{\alpha_1+\alpha_2}}{\Gamma(\alpha_1)\Gamma(\alpha_2)} \int_0^z (z-y)^{\alpha_1-1} e^{-\lambda(z-y)} \cdot y^{\alpha_2-1} e^{-\lambda y} dy \\ &= \frac{\lambda^{\alpha_1+\alpha_2} e^{-\lambda z}}{\Gamma(\alpha_1)\Gamma(\alpha_2)} \int_0^z (z-y)^{\alpha_1-1} y^{\alpha_2-1} dy \end{aligned}$$

$$= \frac{\lambda^{\alpha_1+\alpha_2} e^{-\lambda z} z^{\alpha_1-1}}{\Gamma(\alpha_1)\Gamma(\alpha_2)} \int_0^z \left(1 - \frac{y}{z}\right)^{\alpha_1-1} y^{\alpha_2-1} dy, \text{ 令 } \frac{y}{z} = t$$

$$= \frac{\lambda^{\alpha_1+\alpha_2} e^{-\lambda z} z^{\alpha_1+\alpha_2-1}}{\Gamma(\alpha_1)\Gamma(\alpha_2)} \int_0^1 (1-t)^{\alpha_1-1} t^{\alpha_2-1} dt$$

$$\beta(\alpha_1, \alpha_2) = \int_0^1 (1-t)^{\alpha_1-1} t^{\alpha_2-1} dt$$

$$\beta(\alpha_1, \alpha_2) = \frac{\Gamma(\alpha_1)\Gamma(\alpha_2)}{\Gamma(\alpha_1 + \alpha_2)}.$$

$$\therefore p_Z(z) = \begin{cases} \frac{\lambda^{\alpha_1+\alpha_2}}{\Gamma(\alpha_1 + \alpha_2)} z^{\alpha_1+\alpha_2-1} e^{-\lambda z}, & z > 0, \\ 0, & z \leq 0. \end{cases}$$

即 $Z = X_1 + X_2 \sim Ga(\alpha_1 + \alpha_2, \lambda)$

推广：

若 $X_i \sim \Gamma(\alpha_i, \lambda)$, $i = 1, 2, \dots, m$, 且 X_i 之间相互独立,
则 $X_1 + X_2 + \dots + X_m \sim \Gamma(\alpha_1 + \alpha_2 + \dots + \alpha_m, \lambda)$.

例 已知 $X \sim N(0,1)$, $Y = X^2$, 求 $f_Y(y)$

来源于第二章第3节PPT


解: 从分布函数出发

$$F_Y(y) = P(Y \leq y)$$

当 $y < 0$ 时, $F_Y(y) = 0$

当 $y > 0$ 时,

$$\begin{aligned} F_Y(y) &= P(X^2 \leq y) \\ &= P(-\sqrt{y} \leq X \leq \sqrt{y}) \\ &= F_X(\sqrt{y}) - F_X(-\sqrt{y}) \end{aligned}$$



$$F_Y(y) = \begin{cases} 0, & y < 0 \\ F_X(\sqrt{y}) - F_X(-\sqrt{y}), & y \geq 0 \end{cases}$$

故

$$f_Y(y) = \begin{cases} 0, & y < 0 \\ \frac{1}{2\sqrt{y}} (f_X(\sqrt{y}) + f_X(-\sqrt{y})), & y \geq 0 \end{cases}$$

$$f_Y(y) = \begin{cases} 0, & y < 0 \\ \frac{1}{\sqrt{2\pi} y^{1/2}} e^{-\frac{y}{2}}, & y \geq 0 \end{cases}$$

即： $Y \sim \Gamma(y; \frac{1}{2}, \frac{1}{2})$

$$f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

$$\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$$

则该概率密度可以写为：

$$f_Y(y) = \begin{cases} \frac{1}{2^{\frac{1}{2}} \Gamma(\frac{1}{2})} \left(y^{\frac{1}{2}} e^{-\frac{y}{2}} \frac{1}{y} \right), & y \geq 0 \\ 0, & y < 0 \end{cases}$$

Γ 分布的概率密度函数

$$f(x; \alpha, \lambda) = \begin{cases} \frac{(\lambda x)^\alpha}{\Gamma(\alpha)} e^{-\lambda x} \frac{1}{x}, & x > 0 \\ 0, & x \leq 0 \end{cases}, \quad \alpha > 0, \lambda > 0 \text{ 为常数}$$

令 $\alpha = \frac{1}{2}, \lambda = \frac{1}{2}$, 则上页得到的概率密度函数为 $\Gamma(y; \frac{1}{2}, \frac{1}{2})$ 分布

$$f_Y(y) = \begin{cases} \frac{1}{2^{\frac{1}{2}} \Gamma(\frac{1}{2})} \left(y^{\frac{1}{2}} e^{-\frac{y}{2}} \frac{1}{y} \right), & y \geq 0 \\ 0, & y < 0 \end{cases} \sim \Gamma(y; \frac{1}{2}, \frac{1}{2})$$

(1) χ^2 分布

定义 设总体 $X \sim N(0,1)$, $(X_1, X_2, \dots, X_n)$ 是 X 的一个样本, 则称统计量 $\chi^2 = X_1^2 + X_2^2 + \dots + X_n^2$ 服从自由度为 n 的 χ^2 分布, 记作 $\chi^2 \sim \chi^2(n)$ (书中定理6.4)

自由度是指独立随机变量的个数

$\chi^2(n)$ 分布的密度函数为

$$f(y) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} \left(y^{\frac{n}{2}-1} e^{-\frac{y}{2}} \right), & y \geq 0 \\ 0, & y < 0 \end{cases}$$

χ^2 分布

$$\chi^2(n) \text{ 分布的概率密度为 } f(y) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} y^{\frac{n}{2}-1} e^{-\frac{y}{2}}, & y > 0 \\ 0 & \text{其他.} \end{cases}$$

证明 因为 $\chi^2(1)$ 分布即为 $\Gamma\left(\frac{1}{2}, \frac{1}{2}\right)$ 分布,

又因为 $X_i \sim N(0, 1)$, 由定义 $X_i^2 \sim \chi^2(1)$, 即 $X_i^2 \sim \Gamma\left(\frac{1}{2}, \frac{1}{2}\right)$, $i = 1, 2, \dots, n$.

因为 $X_1, X_2, \dots, X_n$ 相互独立, 所以 $X_1^2, X_2^2, \dots, X_n^2$ 也相互独立,

根据 Γ 分布的可加性知 $\chi^2 = \sum_{i=1}^n X_i^2 \sim \Gamma\left(\frac{n}{2}, \frac{1}{2}\right)$.


χ^2 分布

如果随机变量 Z 具有概率密度 $\chi^2(x; n) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} e^{-\frac{x}{2}} x^{\frac{n}{2}-1}, & x > 0 \\ 0, & x \leq 0 \end{cases}$

则称 Z 服从自由度为 n 的 χ^2 分布.
记为 $Z \sim \chi^2(n)$.

当 $n = 2$ 时, $\chi^2(2) = \text{Exp}\left(\frac{1}{2}\right)$

密度函数的图形随自由度的不同而有所改变.



性质1 若 $Z \sim \chi^2(n)$, 则 $E(Z) = n$, $D(Z) = 2n$.

证明 因为 $X_i \sim N(0, 1)$, 所以 $E(X_i^2) = D(X_i) = 1$,

$$D(X_i^2) = E(X_i^4) - [E(X_i^2)]^2 = 3 - 2 = 1, \quad i = 1, 2, \dots, n.$$

$$\text{故 } E(\chi^2) = E\left(\sum_{i=1}^n X_i^2\right) = \sum_{i=1}^n E(X_i^2) = n,$$

$$D(\chi^2) = D\left(\sum_{i=1}^n X_i^2\right) = \sum_{i=1}^n D(X_i^2) = 2n.$$

性质2（可加性） 若 $X \sim \chi^2(n_1)$, $Y \sim \chi^2(n_2)$, 且 Z_1, Z_2 相互独立,
则 $Z = X + Y \sim \chi^2(n_1 + n_2)$.

证明:

由两个独立随机变量和的卷积公式, $Z=X+Y$ 的概率密度函数为


$$\begin{aligned} f(z) &= \int_{-\infty}^{+\infty} \chi^2(\mathbf{x}; n_1) \chi^2(z-x; n_2) d\mathbf{x} \\ &= \frac{1}{2^{n_1/2} \Gamma(n_1/2)} \int_0^{+\infty} x^{n_1/2} e^{-x/2} \chi^2(z-x; n_2) dx \end{aligned}$$

当 $z \leq 0$ 时 对 $x \in [0, +\infty)$, 有 $z-x \leq 0$,

故 $\chi^2(z-x, n_2) = 0$ 得 $f(z) = 0$;

$$\Gamma(s) = \int_0^{+\infty} x^{s-1} e^{-x} dx \quad (s > 0) \quad f(z) = \frac{1}{2^{n_1/2} \Gamma(n_1/2)} \int_0^{+\infty} x^{n_1/2} e^{-x/2} \chi^2(z-x; n_2) dx$$

当 $z > 0$ 时, 有效积分还需满足 $x > 0$,
 $z - x > 0$, 即 x 要同时满足 $x > 0, x < z$



$$f(z) = \frac{1}{2^{(n_1+n_2)/2} \Gamma(n_1/2) \Gamma(n_2/2)} \int_0^z x^{n_1/2-1} e^{-x/2} (z-x)^{n_2/2-1} e^{-(z-x)/2} dx$$

$$= \frac{e^{-z/2}}{2^{(n_1+n_2)/2} \Gamma(n_1/2) \Gamma(n_2/2)} \int_0^z x^{n_1/2-1} (z-x)^{n_2/2-1} dx$$

$$\stackrel{x=zt}{=} \frac{1}{2^{(n_1+n_2)/2} \Gamma(n_1/2) \Gamma(n_2/2)} z^{(n_1+n_2)/2-1} e^{-z/2} \int_0^1 t^{n_1/2-1} e^{-x/2} (1-t)^{n_2/2-1} e^{-(z-x)/2} dt$$

$$= \frac{\beta(n_1/2, n_2/2)}{2^{(n_1+n_2)/2} \Gamma(n_1/2) \Gamma(n_2/2)} z^{(n_1+n_2)/2-1} e^{-z/2}$$

$$= \frac{1}{2^{(n_1+n_2)/2} \Gamma((n_1+n_2)/2)} z^{(n_1+n_2)/2-1} e^{-z/2}$$

$$\beta(s, t) = \int_0^1 x^{s-1} (1-x)^{t-1} dx$$

$$\frac{\Gamma(s) \Gamma(t)}{\Gamma(s+t)} = \beta(s, t)$$

得

$$f(z) = \begin{cases} \frac{1}{2^{(n_1+n_2)/2} \Gamma((n_1+n_2)/2)} z^{(n_1+n_2)/2-1} e^{-z/2}, & z > 0 \\ 0, & z \leq 0 \end{cases} = \chi^2(n_1 + n_2)$$

故

$$Z = X + Y \sim \chi^2(n_1 + n_2)$$

性质2（可加性）若 $Z_1 \sim \chi^2(n_1)$, $Z_2 \sim \chi^2(n_2)$, 且 Z_1, Z_2 相互独立,
则 $Z_1 + Z_2 \sim \chi^2(n_1 + n_2)$.

证明 由 Γ 分布的可加性即可证明.

推广：若 $Z_i \sim \chi^2(n_i)$, $i = 1, 2, \dots, m$, 且 Z_i 之间相互独立,
则 $Z_1 + Z_2 + \dots + Z_m \sim \chi^2(n_1 + n_2 + \dots + n_m)$.

定理4 设 $X_1, X_2, \dots, X_n$ 独立且都服从 $N(0, 1)$, 则 $\chi^2 = \sum_{i=1}^n X_i^2 \sim \chi^2(n)$.

(定义)

性质3 设 $(X_1, X_2, \dots, X_n)$ 为取自正态总体 $X \sim N(\mu, \sigma^2)$

的样本, 则
$$\frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} \sim \chi^2(n)$$

证明 由已知, 有 $X_i \sim N(\mu, \sigma^2)$ 且 $X_1, X_2, \dots, X_n$ 相互独立,

则 $\frac{X_i - \mu}{\sigma} \sim N(0, 1)$ 且各 $\frac{X_i - \mu}{\sigma}$ 相互独立, 由定义得

$$\chi^2 = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 = \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} \sim \chi^2(n).$$

例 设总体 $X \sim N(0,1)$, $X_1, \dots, X_6$ 为总体 X 的样本,

$$Y = (X_1 + X_2 + X_3)^2 + (X_4 + X_5 + X_6)^2$$

试确定常数 c , 使 cY 服从 χ^2 分布.

解 $X_1 + X_2 + X_3 \sim N(0,3)$, $X_4 + X_5 + X_6 \sim N(0,3)$

$$\frac{1}{\sqrt{3}}(X_1 + X_2 + X_3), \frac{1}{\sqrt{3}}(X_4 + X_5 + X_6) \sim N(0,1),$$

故
$$\left[\frac{1}{\sqrt{3}}(X_1 + X_2 + X_3) \right]^2 + \left[\frac{1}{\sqrt{3}}(X_4 + X_5 + X_6) \right]^2 = \frac{1}{3}Y \sim \chi^2(2),$$

即 $c = 1/3$, cY 服从 χ^2 分布.

χ^2 分布的上 α 分位数

满足 $P\{\chi^2(n) \geq \chi_\alpha^2(n)\} = \int_{\chi_\alpha^2(n)}^{+\infty} f(y)dy = \alpha$ 的数 $\chi_\alpha^2(n)$ 为 χ^2 分布的
上 α 分位数或上侧临界值,


其几何意义见右图所示.

其中 $f(y)$ 是 χ^2 -分布的概率密度.

显然, 在自由度 n 取定以后,
 $\chi_\alpha^2(n)$ 的值只与 α 有关.

例如, 当 $n=21$, $\alpha=0.05$ 时, 由附表4(P_{312})可查得,

$$\chi_{0.05}^2(21) = 32.67 \quad \text{即} \quad P\{\chi^2(21) \geq 32.67\} = 0.05.$$



χ^2 分布的双侧 α 分位数

把满足 $P\left\{\chi^2 \leq \chi_{1-\frac{\alpha}{2}}^2(n)\right\} = P\left\{\chi^2 \geq \chi_{\frac{\alpha}{2}}^2(n)\right\} = \frac{\alpha}{2}$ 的数 $\chi_{1-\frac{\alpha}{2}}^2(n)$, $\chi_{\frac{\alpha}{2}}^2(n)$


称为 χ^2 分布的**双侧 α 分位数**或**双侧临界值**.

$\chi_{\frac{\alpha}{2}}^2(n)$ 为 χ^2 分布的上 $\frac{\alpha}{2}$ 分位数.

$\chi_{1-\frac{\alpha}{2}}^2(n)$ 为 χ^2 分布的上 $1-\frac{\alpha}{2}$ 分位数.

如：当 $n=8$, $\alpha=0.05$ 时,

$$\chi_{1-\frac{\alpha}{2}}^2(n) = \chi_{0.975}^2(8) = 2.18 \quad \chi_{\frac{\alpha}{2}}^2(n) = \chi_{0.025}^2(8) = 17.53$$



例：设 $(X_1, X_2, \dots, X_{10})$ 是来自总体 $N(0, 0.3^2)$ 的样本，求

$$P\left(\sum_{i=1}^{10} X_i^2 > 1.44\right)$$

解 将 $X_i, i = 1, 2, \dots, 10$ 标准化得 $\frac{X_i - 0}{0.3} \sim N(0, 1), i = 1, 2, \dots, 10$.

由 χ^2 分布的构造知, $\sum_{i=1}^{10} \left(\frac{X_i}{0.3}\right)^2 \sim \chi^2(10)$

因此有

$$P\left(\sum_{i=1}^{10} X_i^2 > 1.44\right) = P\left\{\sum_{i=1}^{10} \left(\frac{X_i}{0.3}\right)^2 > \frac{1.44}{0.09}\right\} = P\left\{\sum_{i=1}^{10} \left(\frac{X_i}{0.3}\right)^2 > 16\right\} = 0.1$$

(3) t 分布

定义5.4 (定理6.5) 设随机变量 $X \sim N(0, 1)$, $Y \sim \chi^2(n)$, 且 X 与 Y 相互独立, 则称统计量 $T = X / \sqrt{Y/n}$ 服从自由度为 n 的 **t分布** 或学生氏分布, 记作 $T \sim t(n)$. t 分布的概率密度函数为

$$f(t) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi}\Gamma(\frac{n}{2})} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}, \quad (-\infty < t < +\infty)$$

其形状类似标准正态分布的概率密度的图形.

当 n 较大时, t 分布近似于标准正态分布.

发现 t 分布的过程

英国统计学家戈赛特(Gosset)发现的。

1908年以前，统计学主要是研究社会统计的，所用方法多以“**中心极限定理**”为依据。K. 皮尔逊是当时统计界的权威，他认为“**正态分布是上帝赐给人们唯一正确的分布**”。

戈赛特毕业于牛津大学，1899年在一家酿酒厂担任酿酒化学技师。由于他**能获得的样本都较少（每次只有四五个）**，他发现 $t = \sqrt{n}(\bar{X} - \mu) / s$ 与传统的 $N(0,1)$ 分布不同，特别是**尾部概率相差较大**。

1908年，戈赛特在Biometrics杂志上以**笔名student**(工厂不允许工人发表论文)发表了使他名垂统计史册的论文：均值的或然误差。实际上，戈赛特的证明存在着漏洞，1922年费希尔注意到这个问题并给出了完整证明。

t 分布的发现在统计学史上有划时代的意义，打破了正态分布一统天下的局面，**开创了小样本统计推断的新纪元**。

定理6.5 设随机变量 $X \sim N(0, 1)$, $Y \sim \chi^2(n)$, 且 X 与 Y 相互独立, 则 $T = X / \sqrt{Y/n} \sim t(n)$

证明: 令 $Z = \sqrt{Y/n}$, 则 Z 的概率密度函数为

$$f_Z(z) = \begin{cases} \frac{n^{\frac{n}{2}}}{2^{\frac{n}{2}-1} \Gamma(\frac{n}{2})} \left(z^n e^{-\frac{nz^2}{2}} \frac{1}{z} \right), & z \geq 0 \\ 0, & z < 0 \end{cases}$$

于是, X 与 Z 相互独立, 且 $f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}},$

依独立随机变量商的概率密度公式， $T=X/Z$ 的概率密度为：

$$\begin{aligned}
 f_T(t) &= \int_{-\infty}^{+\infty} |z| f_X(tz) f_Z(z) dz = \frac{n^{\frac{n}{2}}}{\sqrt{\pi} 2^{\frac{n-1}{2}} \Gamma(\frac{n}{2})} \int_0^{+\infty} z^n e^{-\frac{(n+t^2)z^2}{2}} dz \\
 &= \frac{1}{\sqrt{n\pi} \Gamma(\frac{n}{2})} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}} \int_0^{+\infty} s^{\frac{n-1}{2}} e^{-s} ds \\
 &= \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi} \Gamma(\frac{n}{2})} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}} \quad (-\infty < t < +\infty)
 \end{aligned}$$

证明完毕


t 分布

若 T 的概率密度为
$$t(x; n) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}, \quad -\infty < x < \infty$$

则称 T 服从自由度为 n 的 t 分布. 记为 $T \sim t(n)$.

$t(x; n)$ 图形关于 y 轴对称, 且 n 越大, 图形越接近于 $N(0,1)$ 的概率密度曲线.

$$\lim_{n \rightarrow \infty} t(x, n) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$



当 n 较大时, t 分布近似于标准正态分布.

一般说来, 当 $n > 30$ 时, t 分布与标准正态分布 $N(0, 1)$ 就非常接近.

但对较小的 n 值, t 分布与标准正态分布之间有较大差异. 且 $P\{|T| \geq t_0\} \geq P\{|X| \geq t_0\}$, 其中 $X \sim N(0, 1)$, 即在 t 分布的尾部比在标准正态分布的尾部有着更大的概率.


t 分布的数学期望与方差 (补充)

设 $T \sim t(n)$, 则 $E(T) = 0$, $D(T) = \frac{n}{n-2} \cdot (n > 2)$

t 分布的上 α 分位数

对于给定的 α ($0 < \alpha < 1$), 称满足条件 $P\{T \geq t_{\alpha}(n)\} = \int_{t_{\alpha}(n)}^{+\infty} f(t)dt = \alpha$ 的数 $t_{\alpha}(n)$ 为 t 分布的上 α 分位数或上侧临界值,

其几何意义见图




t 分布的双侧 α 分位数

由于 t 分布的对称性，称满足条件 $P\{|T| \geq t_{\alpha/2}(n)\} = \alpha$

的数 $t_{\alpha/2}(n)$ 为 t 分布的**双侧 α 分位数**或双侧临界值

其几何意义如图所示.



在附表3 (P.310)中给出了 t 分布的临界值表.

例如, 当 $n=15$, $\alpha=0.05$ 时, 查 t 分布表得,

$$t_{0.05}(15)= 1.753 \quad t_{0.05/2}(15)= 2.131$$

其中 $t_{0.05/2}(15)$ 由 $P\{t(15)\geq t_{0.025}(15)\}=0.025$ 查得.

但当 $n>45$ 时, 如无详细表格可查, 可以用标准正态分布代替 t 分布查 $t_{\alpha}(n)$ 的值.

$$\text{即 } t_{\alpha}(n)\approx u_{\alpha}, \quad n>45.$$

一般的 t 分布临界值表中, 详列至 $n=30$, 当 $n>30$ 就用标准正态分布 $N(0, 1)$ 来近似.

例：设 $X_1, X_2, \dots, X_9$ 和 $Y_1, Y_2, \dots, Y_9$ 是来自同一总体 $N(0,9)$ 的两个独立的样本，试确定统计量 Z 的分布。

$$Z = \left(\sum_{i=1}^9 X_i \right) / \sqrt{\sum_{i=1}^9 Y_i^2}$$

解：由样本的同分布性知：

$$X_i \sim N(0,9), Y_i \sim N(0,9), i = 1, 2, \dots, 9$$

由此得：

$$\frac{1}{9} \sum_{i=1}^9 X_i \sim N(0,1) \quad \sum_{i=1}^9 \left(\frac{Y_i}{3} \right)^2 = \sum_{i=1}^9 \frac{Y_i^2}{9} \sim \chi^2(9)$$

由t分布的构造知：

$$\frac{\frac{1}{9} \sum_{i=1}^9 X_i}{\sqrt{\sum_{i=1}^9 \frac{Y_i^2}{9} / 9}} = \frac{\sum_{i=1}^9 X_i}{\sqrt{\sum_{i=1}^9 Y_i^2}} = Z \sim t(9)$$

谢谢！

第六章 数理统计的基本概念

主要内容

- 一 总体与样本
- 二 样本数据的整理
- 三 统计量
- 四 抽样分布

(4) F 分布

设随机变量 $X \sim \chi^2(n_1)$ 、 $Y \sim \chi^2(n_2)$ ，且相互独立，则称随机变量

$F = \frac{X/n_1}{Y/n_2}$ 服从第一自由度为 n_1 ，第二自由度为 n_2 的 F 分布(定理6.6)

记作 $F \sim F(n_1, n_2)$. 概率密度函数


$$f(y) = \begin{cases} Ay^{\frac{n_1}{2}-1} \left(1 + \frac{n_1}{n_2} y\right)^{-\frac{n_1+n_2}{2}}, & y \geq 0 \\ 0, & y < 0 \end{cases} \quad \text{其中} \quad A = \frac{\Gamma(\frac{n_1+n_2}{2})}{\Gamma(\frac{n_1}{2})\Gamma(\frac{n_2}{2})} \left(\frac{n_1}{n_2}\right)^{\frac{n_1}{2}},$$

F 分布

若 F 的概率密度为

$$f(x; n_1, n_2) = \begin{cases} \frac{\Gamma\left(\frac{n_1 + n_2}{2}\right)}{\Gamma\left(\frac{n_1}{2}\right)\Gamma\left(\frac{n_2}{2}\right)} \left(\frac{n_1}{n_2}\right)^{\frac{n_1}{2}} x^{\frac{n_1}{2}-1} \left(1 + \frac{n_1}{n_2}x\right)^{-\frac{n_1+n_2}{2}}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

则称 F 服从自由度为 (n_1, n_2) 的 F 分布.
记为 $F \sim F(n_1, n_2)$.



定理6.6 设 $X \sim \chi^2(n_1)$, $Y \sim \chi^2(n_2)$, 且 X, Y 独立, 则 $F = \frac{X/n_1}{Y/n_2} \sim F(n_1, n_2)$.

证明: 先求 $Z=X/Y$ 的概率密度函数, 根据独立随机变量商的分布的概率密度函数的公式:

$$\begin{aligned} f_Z(z) &= \int_{-\infty}^{+\infty} |y| f_X(zy) f_Y(y) dy = \int_0^{+\infty} y f_X(zy) f_Y(y) dy \\ &= \frac{y^{\frac{m}{2}-1}}{\Gamma(\frac{m}{2}) \cdot \Gamma(\frac{n}{2}) \cdot 2^{\frac{m+n}{2}}} \int_0^{+\infty} y^{\frac{m+n}{2}-1} e^{-\frac{y}{2}(1+z)} dy \end{aligned}$$

运用变换, $u = \frac{y}{2}(1+z)$, 可得

$$f_Z(z) = \frac{z^{\frac{m}{2}-1} (1+z)^{-\frac{m+n}{2}}}{\Gamma(\frac{m}{2}) \cdot \Gamma(\frac{n}{2})} \int_0^{+\infty} u^{\frac{m+n}{2}-1} e^{-u} du$$

最后的定积分为伽马函数 $\Gamma(\frac{m+n}{2})$, 从而

$$f_Z(z) = \frac{\Gamma(\frac{m+n}{2})}{\Gamma(\frac{m}{2}) \cdot \Gamma(\frac{n}{2})} z^{\frac{m}{2}-1} (1+z)^{-\frac{m+n}{2}}, \quad z \geq 0$$

接着，导出 $F = \frac{n}{m}Z$ 的概率密度函数。设 F 的取值为 s ，对 $s \geq 0$ 有

$$\begin{aligned} f_F(s) &= f_Z(z) \left(\frac{m}{n} s \right) \cdot \frac{m}{n} = \frac{\Gamma\left(\frac{m+n}{2}\right)}{\Gamma\left(\frac{m}{2}\right) \cdot \Gamma\left(\frac{n}{2}\right)} \left(\frac{m}{n} s \right)^{\frac{m}{2}-1} \left(1 + \frac{m}{n} s \right)^{-\frac{m+n}{2}} \cdot \frac{m}{n} \\ &= \frac{\Gamma\left(\frac{m+n}{2}\right) \left(\frac{m}{n} \right)^{\frac{m}{2}}}{\Gamma\left(\frac{m}{2}\right) \cdot \Gamma\left(\frac{n}{2}\right)} s^{\frac{m}{2}-1} \left(1 + \frac{m}{n} s \right)^{-\frac{m+n}{2}} \end{aligned}$$

证明完毕

推论 若 $F \sim F(n_1, n_2)$ ，则 $\frac{1}{F} \sim F(n_2, n_1)$.

例 设总体 $X \sim N(0,1)$, $X_1, X_2, \dots, X_n$ 为简单随机样本, 试问右边的统计量服从什么分布?

$$\frac{(\frac{n}{3}-1)\sum_{i=1}^3 X_i^2}{\sum_{i=4}^n X_i^2}$$

解 因为 $\sum_{i=1}^3 X_i^2 \sim \chi^2(3)$, $\sum_{i=4}^n X_i^2 \sim \chi^2(n-3)$,

且 $\sum_{i=1}^3 X_i^2$ 与 $\sum_{i=4}^n X_i^2$ 相互独立


所以
$$\frac{(\frac{n}{3}-1)\sum_{i=1}^3 X_i^2}{\sum_{i=4}^n X_i^2} = \frac{\sum_{i=1}^3 X_i^2 / 3}{\sum_{i=4}^n X_i^2 / (n-3)} \sim F(3, n-3).$$

F 分布的上 α 分位数

对于给定的 α ($0 < \alpha < 1$), 称满足条件 $P\{F(n_1, n_2) \geq F_\alpha(n_1, n_2)\} = \int_{F_\alpha(n_1, n_2)}^{+\infty} f(y)dy = \alpha$ 的数 $F_\alpha(n_1, n_2)$ 为 F 分布的**上 α 分位数或上侧临界值**,

其几何意义如图所示.

其中 $f(y)$ 是 F 分布的概率密度.



F 分布的上 α 分位点具有如下性质：
$$F_{1-\alpha}(n_1, n_2) = \frac{1}{F_{\alpha}(n_2, n_1)}.$$

证明: 因为 $F \sim F(n_1, n_2)$, 所以 $1-\alpha = P\{F > F_{1-\alpha}(n_1, n_2)\}$

$$= P\left\{\frac{1}{F} < \frac{1}{F_{1-\alpha}(n_1, n_2)}\right\} = 1 - P\left\{\frac{1}{F} \geq \frac{1}{F_{1-\alpha}(n_1, n_2)}\right\} = 1 - P\left\{\frac{1}{F} > \frac{1}{F_{1-\alpha}(n_1, n_2)}\right\},$$

故 $P\left\{\frac{1}{F} > \frac{1}{F_{1-\alpha}(n_1, n_2)}\right\} = \alpha$, 又因为 $\frac{1}{F} \sim F(n_2, n_1)$, 所以 $P\left\{\frac{1}{F} > F_{\alpha}(n_2, n_1)\right\} = \alpha$,

比较后得 $\frac{1}{F_{1-\alpha}(n_1, n_2)} = F_{\alpha}(n_2, n_1)$, 即 $F_{1-\alpha}(n_1, n_2) = \frac{1}{F_{\alpha}(n_2, n_1)}$

F 分布的上 α 分位数

$F_{\alpha}(n_1, n_2)$ 的值可由F 分布表查得.

附表5($P_{314} \sim P_{322}$)分别给出 $\alpha=0.1$ 、 $\alpha=0.05$ 、 $\alpha=0.01$ 等数值时F分布的上 α 分位数.

查表时应先找到相应的 α 值的表.

当时 $n_1=2, n_2=18$ 时, 有 $F_{0.01}(2, 18)= 6.01$

在附表5中所列的 α 值都比较小, 当 α 较大时, 可用下面公式

$$F_{1-\alpha}(n_1, n_2) = \frac{1}{F_{\alpha}(n_2, n_1)}$$

$$\text{例如, } F_{0.99}(18, 2) = \frac{1}{F_{0.01}(2, 18)} = \frac{1}{6.01} \approx 0.166$$


F 分布的双侧 α 分位数

称满足条件 $P\left\{F \leq F_{1-\frac{\alpha}{2}}(n_1, n_2)\right\} = P\left\{F \geq F_{\frac{\alpha}{2}}(n_1, n_2)\right\} = \frac{\alpha}{2}$


的 $F_{1-\frac{\alpha}{2}}(n_1, n_2)$, $F_{\frac{\alpha}{2}}(n_1, n_2)$ 为 F 分布的**双侧 α 分位数**
或**双侧临界值**. 见图.

$F_{\frac{\alpha}{2}}(n_1, n_2)$ 为 F 分布的上 $\frac{\alpha}{2}$ 分位数;

$F_{1-\frac{\alpha}{2}}(n_1, n_2)$ 为 F 分布的上 $1-\frac{\alpha}{2}$ 分位数;



例 若 $\chi^2 \sim \chi^2(n)$, 其上侧 α 分位数 $\chi_\alpha^2(n)$ 满足 $P\{\chi^2 > \chi_\alpha^2(n)\} = \alpha$.




例 若 $T \sim t(n)$, 其上侧 α 分位数 $t_\alpha(n)$ 满足 $P\{T > t_\alpha(n)\} = \alpha$.

$$t_{1-\alpha}(n) = -t_\alpha(n)$$

例 若 $F \sim F(n_1, n_2)$, 其上侧 α 分位数 $F_\alpha(n_1, n_2)$ 满足 $P\{F > F_\alpha(n_1, n_2)\} = \alpha$.

$$F_{1-\alpha}(n_1, n_2) = \frac{1}{F_\alpha(n_2, n_1)}$$



正态总体的抽样分布定理

一个正态总体下的统计量的抽样分布

定理7 设 $(X_1, X_2, \dots, X_n)$ 是来自正态总体 $N(\mu, \sigma^2)$ 的样本, 则

$$(1) \quad \bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right);$$

$$(2) \quad \frac{(n-1)S^2}{\sigma^2} = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 \sim \chi^2(n-1);$$

$$(3) \quad \bar{X} \text{ 与 } S^2 \text{ 相互独立.}$$

证明: $x_1, x_2, \dots, x_n$ 的联合概率密度函数为

$$\begin{aligned} f(x_1, x_2, \dots, x_n) &= (2\pi\sigma^2)^{-n/2} e^{-\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}} \\ &= (2\pi\sigma^2)^{-n/2} e^{\frac{\sum_{i=1}^n x_i^2 - 2n\bar{x}\mu + n\mu^2}{2\sigma^2}} \end{aligned}$$

记 $X = (x_1, x_2, \dots, x_n)^T$, 取一个 n 维正交矩阵 A , 其第一行元素均为 $1/\sqrt{n}$

比如：

$$A = \begin{pmatrix} \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \cdots & \frac{1}{\sqrt{n}} \\ \frac{1}{\sqrt{2 \times 1}} & -\frac{1}{\sqrt{2 \times 1}} & 0 & \cdots & 0 \\ \frac{1}{\sqrt{3 \times 2}} & \frac{1}{\sqrt{3 \times 2}} & -\frac{2}{\sqrt{3 \times 2}} & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ \frac{1}{\sqrt{n(n-1)}} & \frac{1}{\sqrt{n(n-1)}} & \frac{1}{\sqrt{n(n-1)}} & \cdots & -\frac{n-1}{\sqrt{n(n-1)}} \end{pmatrix}$$

$$\text{令 } Y = (y_1, y_2, \dots, y_n)^T = AX$$

由P96的性质3, 得 $Y = (y_1, y_2, \dots, y_n)^T$ 的各个分量相互独立, 且都服从正态分布。

上述变换的雅克比(Jacobi)行列式为1, 且有

$$\bar{x} = \frac{1}{\sqrt{n}} y_1, \quad \sum_{i=1}^n y_i^2 = Y^T Y = X^T A^T A X = \sum_{i=1}^n x_i^2$$

于是 $y_1, y_2, \dots, y_n$ 的联合概率密度函数为

$$f(y_1, y_2, \dots, y_n) = (2\pi\sigma^2)^{-n/2} e^{-\frac{\sum_{i=1}^n y_i^2 - 2ny_1\mu + n\mu^2}{2\sigma^2}}$$

即

$$f(y_1, y_2, \cdots, y_n) = (2\pi\sigma^2)^{-n/2} e^{-\frac{\sum_{i=2}^n y_i^2 + (y_1 - \sqrt{n}\mu)^2}{2\sigma^2}}$$

可见， Y 的各个分量的方差均为 σ^2 ，而均值并不完全相等。
 $y_2, \cdots, y_n$ 的均值为0， y_1 的均值为 $\sqrt{n}\mu$ 。 这就证明了结论1.

由于 $(n-1)s^2 = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - (\sqrt{n} \bar{x})^2 = \sum_{i=1}^n y_i^2 - y_1^2 = \sum_{i=2}^n y_i^2$

这就证明了结论2. 又由于 $y_2, \cdots, y_n$ 独立同分布于 $N(0, \sigma^2)$

于是 $\frac{(n-1)s^2}{\sigma^2} = \sum_{i=2}^n \left(\frac{y_i}{\sigma}\right)^2 \sim \chi^2(n-1)$ 这就证明了结论3.

定理7中(2)式的自由度为什么是 $n-1$?

从表面上看, $\sum_{i=1}^n (X_i - \bar{X})^2$ 是 n 个正态随机变量 $X_i - \bar{X}$ 的平方和, 但实际上它们不是独立的, 它们之间有一种线性约束关系:

$$\sum_{i=1}^n (X_i - \bar{X}) = \sum_{i=1}^n X_i - n\bar{X} = 0$$

这表明, 当这个 n 个正态随机变量中有 $n-1$ 个取值给定时, 剩下的一个的取值就跟着唯一确定了, 故在这 n 项平方和中只有 $n-1$ 项是独立的. 所以(2)式的自由度是 $n-1$.

设 $(X_1, X_2, \dots, X_n)$ 为来自正态总体 $X \sim N(\mu, \sigma^2)$ 的样本,则

$$\frac{(n-1)S^2}{\sigma^2} = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} \sim \chi^2(n-1)$$

与以下补充性质的结论比较:

性质 设 $(X_1, X_2, \dots, X_n)$ 为取自正态总体 $X \sim N(\mu, \sigma^2)$ 的样本,则

$$\frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} \sim \chi^2(n)$$

定理8 设 $(X_1, X_2, \dots, X_n)$ 是来自正态总体 $N(\mu, \sigma^2)$ 的样本, 则

$$T = \frac{\bar{X} - \mu}{S / \sqrt{n}} \sim t(n-1)$$

证 由于 $\bar{X}$ 与 S^2 相互独立, 且

$$U = \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1), \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

由定义6.4得

$$\frac{\frac{\bar{X} - \mu}{\sigma / \sqrt{n}}}{\sqrt{\frac{(n-1)S^2}{\sigma^2} / (n-1)}} = \frac{\bar{X} - \mu}{S / \sqrt{n}} = T \sim t(n-1)$$

例： 设 $X_1, X_2, \dots, X_{10}$ 是来自总体 $X \sim N(\mu, 4)$ 的样本, 求样本方差 S^2 大于 2.622 的概率.

解： 由于 $\frac{(10-1)S^2}{4} \sim \chi^2(9)$

$$P(S^2 > 2.622) = P\left(\frac{9}{4}S^2 > \frac{9}{4} \times 2.622\right) = P\left(\frac{9}{4}S^2 > 5.8995\right),$$

查表得 $\chi_{0.75}^2(9) = 5.899$

则有 $P(S^2 > 2.622) \approx 0.75$

正态总体的抽样分布定理

两个正态总体下的统计量的抽样分布

设总体 X 与 Y 相互独立,

$(X_1, X_2, \dots, X_{n_1})$ 是来自总体 $X \sim N(\mu_1, \sigma_1^2)$ 的一个样本:

$$\bar{X} = \frac{1}{n_1} \sum_{i=1}^{n_1} X_i, \quad S_1^2 = \frac{1}{n_1 - 1} \sum_{i=1}^{n_1} (X_i - \bar{X})^2$$

$(Y_1, Y_2, \dots, Y_{n_2})$ 是来自总体 $Y \sim N(\mu_2, \sigma_2^2)$ 的一个样本:

$$\bar{Y} = \frac{1}{n_2} \sum_{i=1}^{n_2} Y_i, \quad S_2^2 = \frac{1}{n_2 - 1} \sum_{i=1}^{n_2} (Y_i - \bar{Y})^2$$

*定理:
$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2 / n_1 + \sigma_2^2 / n_2}} \sim N(0, 1)$$

证: 由于 $\bar{X} \sim N(\mu_1, \frac{\sigma_1^2}{n_1})$ 与 $\bar{Y} \sim N(\mu_2, \frac{\sigma_2^2}{n_2})$ 独立

所以 $\bar{X} - \bar{Y} \sim N(\mu_1 - \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2})$

因此
$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2 / n_1 + \sigma_2^2 / n_2}} \sim N(0, 1)$$

定理9 设 $(X_1, X_2, \dots, X_{n_1}), (Y_1, Y_2, \dots, Y_{n_2})$ 是分别来自正态总体 $N(\mu_1, \sigma^2), N(\mu_2, \sigma^2)$ 的样本, 且两样本相互独立, 分别记两组样本的样本均值, 样本方差为 $\bar{X}, S_1^2; \bar{Y}, S_2^2$. 则有

$$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2),$$

其中
$$S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}.$$

注: 此定理只有在两个总体的方差相等时才成立.

证明: (1) 因为

$$\bar{X} \sim N\left(\mu_1, \frac{\sigma^2}{n_1}\right) \quad \bar{Y} \sim N\left(\mu_2, \frac{\sigma^2}{n_2}\right) \quad \text{所以} \quad U \stackrel{\Delta}{=} \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sigma \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim N(0, 1)$$

$$(2) \text{ 因为 } \frac{(n_1 - 1)S_1^2}{\sigma^2} \sim \chi^2(n_1 - 1) \quad \frac{(n_2 - 1)S_2^2}{\sigma^2} \sim \chi^2(n_2 - 1)$$

$$\text{所以 } V \stackrel{\Delta}{=} \frac{(n_1 - 1)S_1^2}{\sigma^2} + \frac{(n_2 - 1)S_2^2}{\sigma^2} \sim \chi^2(n_1 + n_2 - 2)$$

$$(3) \text{ 故 } T = \frac{U}{\sqrt{V / (n_1 + n_2 - 2)}} = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$$

定理10 设 $(X_1, X_2, \dots, X_{n_1}), (Y_1, Y_2, \dots, Y_{n_2})$ 是分别来自正态总体 $N(\mu_1, \sigma_1^2), N(\mu_2, \sigma_2^2)$ 的样本, 且两样本相互独立, 分别记两组样本的样本方差为 S_1^2, S_2^2 .

$$S_1^2 = \frac{1}{n_1 - 1} \sum_{i=1}^{n_1} (X_i - \bar{X})^2, \quad S_2^2 = \frac{1}{n_2 - 1} \sum_{i=1}^{n_2} (Y_i - \bar{Y})^2$$

则有
$$F = \frac{\sigma_2^2 S_1^2}{\sigma_1^2 S_2^2} \sim F(n_1 - 1, n_2 - 1).$$

特别, 当 $\sigma_X^2 = \sigma_Y^2$ 时, 有
$$F = \frac{S_1^2}{S_2^2} \sim F(n_1 - 1, n_2 - 1)$$

证： 由于 $\frac{(n_1-1)S_1^2}{\sigma_1^2} \sim \chi^2(n_1-1)$ $\frac{(n_2-1)S_2^2}{\sigma_2^2} \sim \chi^2(n_2-1)$

且相互独立

由F分布的构造知 $\frac{\frac{(n_1-1)S_1^2}{\sigma_1^2} / (n_1-1)}{\frac{(n_2-1)S_2^2}{\sigma_2^2} / (n_2-1)} \sim F(n_1, n_2)$

即 $\frac{S_1^2}{S_2^2} \cdot \frac{\sigma_2^2}{\sigma_1^2} \sim F(n_1, n_2)$

例：设总体 $X \sim N(6,1), Y \sim N(5,1)$ 有 $n_1 = n_2 = 10$ 的两个独立样本，求两个样本均值之差 $\bar{X} - \bar{Y}$ 小于 1.3 的概率。

解
$$\frac{(\bar{X} - \bar{Y}) - (6 - 5)}{\sqrt{1/10 + 1/10}} \sim N(0,1)$$

$$P(\bar{X} - \bar{Y} < 1.3) = P\left(\frac{(\bar{X} - \bar{Y}) - (6 - 5)}{\sqrt{1/10 + 1/10}} < \frac{1.3 - (6 - 5)}{\sqrt{1/10 + 1/10}}\right)$$

$$= P\left(\frac{(\bar{X} - \bar{Y}) - (6 - 5)}{\sqrt{1/10 + 1/10}} < 0.67\right) = \Phi(0.67) = 0.7486$$

例：设总体 $X \sim N(6, \sigma_1^2)$, $Y \sim N(5, \sigma_2^2)$ 有 $n_1 = n_2 = 10$ 的两个独立样本， $s_1^2 = 0.9130$, $s_2^2 = 0.9816$ ，求两个样本均值之差 $\bar{X} - \bar{Y}$ 小于 1.3 的概率。

解：
$$\frac{(\bar{X} - \bar{Y}) - (6 - 5)}{S_w \sqrt{1/10 + 1/10}} \sim t(18)$$

其中
$$S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2} = \frac{9 \times 0.9130 + 9 \times 0.9816}{18} = 0.9733^2$$

则
$$P(\bar{X} - \bar{Y} < 1.3) = P\left(\frac{(\bar{X} - \bar{Y}) - (6 - 5)}{0.9733 \sqrt{1/10 + 1/10}} < \frac{1.3 - (6 - 5)}{0.9733 \sqrt{1/10 + 1/10}}\right)$$

$$= P\left(\frac{(\bar{X} - \bar{Y}) - (6 - 5)}{0.9733 \sqrt{1/10 + 1/10}} < 0.6884\right) \quad t_{0.25}(18) = 0.6884$$

$$P(\bar{X} - \bar{Y} < 1.3) = 1 - 0.25 = 0.75$$

例： 设总体 $X \sim N(\mu, 3), Y \sim N(\mu, 5)$ 有 $n_1 = n_2 = 15$ 的两个独立样本, 求两个样本方差之比 S_1^2 / S_2^2 大于 1.272 的概率.

解 因为 $\frac{S_1^2}{S_2^2} \cdot \frac{5}{3} \sim F(9, 14)$

$$\text{所以 } P\left(\frac{S_1^2}{S_2^2} > 1.272\right) = P\left(\frac{S_1^2}{S_2^2} \cdot \frac{5}{3} > 1.272 \times \frac{5}{3}\right) = P\left(\frac{S_1^2}{S_2^2} \cdot \frac{5}{3} > 2.12\right)$$

查表得 $F_{0.1}(9, 14) = 2.12$

$$\text{因此 } P\left(\frac{S_1^2}{S_2^2} > 1.272\right) = 0.1$$

小结

常用分布的定义和性质

U—分布

正态总体样本均值的分布

设总体 $X \sim N(\mu, \sigma^2)$, $(X_1, X_2, \dots, X_n)$ 是 X 的一个样本, 则样本均值服从正态分布

$$U = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} = \frac{\frac{1}{n} \sum_{i=1}^n X_i - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

χ^2 ——分布

定义(定理5.4) 设总体 $X \sim N(0,1)$, $(X_1, X_2, \dots, X_n)$ 是 X 的一个样本, 则称统计量 $\chi^2 = X_1^2 + X_2^2 + \dots + X_n^2$ 服从自由度为 n 的 χ^2 分布, 记作 $\chi^2 \sim \chi^2(n)$

自由度是指独立随机变量的个数, $df = n$

n 个相互独立的标准正态分布之平方和服从自由度为 n 的 χ^2 分布

t—分布

定义6.4 （定理6.5） 设随机变量 $X \sim N(0, 1)$, $Y \sim \chi^2(n)$, 且 X 与 Y 相互独立, 则称统计量 $T = X / \sqrt{Y / n}$ 服从自由度为 n 的 **t分布** 或学生氏分布, 记作 $T \sim t(n)$.

$$\frac{N(0,1)}{\sqrt{\frac{\chi^2(n)}{n}}} \sim t(n)$$

t-分布的密度函数的图形相似于**标准正态分布**的密度函数. 当 n 较大时, **t分布近似于标准正态分布**.

F—分布

设随机变量 $X \sim \chi^2(n_1)$ 、 $Y \sim \chi^2(n_2)$ ，且相互独立，则称随机变量

$F = \frac{X/n_1}{Y/n_2}$ 服从第一自由度为 n_1 ，第二自由度为 n_2 的 F 分布(定理5.6)

记作 $F \sim F(n_1, n_2)$.

$$\frac{\chi^2(n_1)/n_1}{\chi^2(n_2)/n_2} \sim F(n_1, n_2)$$

例 设总体 $X \sim N(0,1)$, $X_1, X_2, \dots, X_n$ 为简单随机样本, 试问下列统计量各服从什么分布?

$$(1) \frac{X_1 - X_2}{\sqrt{X_3^2 + X_4^2}}; \quad (2) \frac{\sqrt{n-1}X_1}{\sqrt{\sum_{i=2}^n X_i^2}}; \quad (3) \frac{(\frac{n}{3}-1)\sum_{i=1}^3 X_i^2}{\sum_{i=4}^n X_i^2}.$$

解 (1) 因为 $X_i \sim N(0,1)$, $i=1, 2, \dots, n$. 所以

$$X_1 - X_2 \sim N(0, 2), \quad \frac{X_1 - X_2}{\sqrt{2}} \sim N(0,1), \quad X_3^2 + X_4^2 \sim \chi^2(2),$$

$$\text{故 } \frac{X_1 - X_2}{\sqrt{X_3^2 + X_4^2}} = \frac{(X_1 - X_2)/\sqrt{2}}{\sqrt{\frac{X_3^2 + X_4^2}{2}}} \sim t(2).$$

例 设总体 $X \sim N(0,1)$, $X_1, X_2, \dots, X_n$ 为简单随机样本, 试问下列统计量各服从什么分布?

$$(1) \frac{X_1 - X_2}{\sqrt{X_3^2 + X_4^2}}; \quad (2) \frac{\sqrt{n-1}X_1}{\sqrt{\sum_{i=2}^n X_i^2}}; \quad (3) \frac{(\frac{n}{3}-1)\sum_{i=1}^3 X_i^2}{\sum_{i=4}^n X_i^2}.$$

续解 (2) 因为 $X_1 \sim N(0,1)$, $\sum_{i=2}^n X_i^2 \sim \chi^2(n-1)$

故
$$\frac{\sqrt{n-1}X_1}{\sqrt{\sum_{i=2}^n X_i^2}} = \frac{X_1}{\sqrt{\sum_{i=2}^n X_i^2 / (n-1)}} \sim t(n-1).$$

例 设总体 $X \sim N(0,1)$, $X_1, X_2, \dots, X_n$ 为简单随机样本, 试问下列统计量各服从什么分布?

$$(1) \frac{X_1 - X_2}{\sqrt{X_3^2 + X_4^2}}; \quad (2) \frac{\sqrt{n-1}X_1}{\sqrt{\sum_{i=2}^n X_i^2}}; \quad (3) \frac{(\frac{n}{3}-1)\sum_{i=1}^3 X_i^2}{\sum_{i=4}^n X_i^2}.$$

续解 (3) 因为 $\sum_{i=1}^3 X_i^2 \sim \chi^2(3)$, $\sum_{i=4}^n X_i^2 \sim \chi^2(n-3)$,

所以

$$\frac{(\frac{n}{3}-1)\sum_{i=1}^3 X_i^2}{\sum_{i=4}^n X_i^2} = \frac{\sum_{i=1}^3 X_i^2 / 3}{\sum_{i=4}^n X_i^2 / (n-3)} \sim F(3, n-3).$$

例 若 $T \sim t(n)$, 问 T^2 服从什么分布?

解 因为 $T \sim t(n)$, 可以认为

$$T = \frac{U}{\sqrt{V/n}},$$

其中 $U \sim N(0,1)$, $V \sim \chi^2(n)$,

$$T^2 = \frac{U^2}{V/n}, \quad U^2 \sim \chi^2(1),$$

$$T^2 = \frac{U^2/1}{V/n} \sim F(1, n).$$

例 设总体 $X \sim N(\mu, 4^2)$, $X_1, X_2, \dots, X_{10}$ 是 $n=10$ 简单随机样本, S^2 为样本方差, 已知 $P\{S^2 > \alpha\} = 0.1$, 求 α .

解 因为 $n=10$, $n-1=9$, $\sigma^2=4^2$, 所以

$$\frac{9S^2}{4^2} \sim \chi^2(9).$$

$$\text{又 } P\{S^2 > \alpha\} = P\left\{\frac{9S^2}{4^2} > \frac{9\alpha}{4^2}\right\} = 0.1,$$

$$\text{所以 } \frac{9\alpha}{4^2} = \underset{\text{查表}}{\chi_{0.1}^2(9)} \approx 14.684. \quad \text{故}$$

$$\alpha \approx 14.684 \times \frac{16}{9} \approx 26.105$$

谢谢！