

第六章 数理统计的基本概念

主要内容

- 一 总体与样本
- 二 样本数据的整理
- 三 统计量
- 四 抽样分布

总体 X 是随机变量，其概率分布是客观存在的，但往往又是未知的，要由我们来确定，常常用样本分布来作为总体分布的近似。

常用的方法有：

频数分布与频率分布（对离散型总体使用）

频率直方图（对连续型总体使用）

经验分布函数（对各种类型总体都可以使用）

1. 样本频数分布和频率分布

设有样本值 $(x_1, x_2, \dots, x_n)$, 不同数值为 $x_1^* < x_2^* < \dots < x_l^*$,

样本频数分布: 样本值中不同数值在样本中出现的次数(频数).

指标 X	x_1^*	x_2^*	$\dots$	x_l^*
频数 m_i	m_1	m_2	$\dots$	m_l

样本频率分布: 样本值中不同数值在样本中出现的频率.

指标 X	x_1^*	x_2^*	$\dots$	x_l^*
频率 m_i / n	m_1 / n	m_2 / n	$\dots$	m_l / n

2. 频率直方图

设总体 X 是连续型随机变量, 概率密度为 $f(x)$, $(x_1, x_2, \dots, x_n)$ 是来自总体 X 的样本值.

可以做频率直方图, 并由此近似得出总体 X 的概率密度曲线.

数据的简单处理

为了研究随机现象，首要的工作是收集原始数据.一般通过抽样调查或试验得到的数据往往是杂乱无章的，需要通过整理后才能显示出它们的分布状况。

数据的简单处理是以一种直观明了方式加工数据。

- 它包括两个方面——
1. 数据整理
 2. 计算样本特征数

数据整理：将数据分组——→ 计算各组频数
作频率分布表——→ 作频率直方图

- 计算样本特征数：

- (1) 反映趋势的特征数

样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$

中位数：数据按大小顺序排列后，位置居中的那个数或居中的两个数的平均数。

众数：样本中出现最多的那个数。

例 为对某小麦杂交组合 F_2 代的株高 X 进行研究，抽取容量为100的样本，测试的原始数据记录如下(单位：厘米)，试根据以上数据，画出它的频率直方图，求随机变量 X 的分布状况。

87	88	111	91	73	70	92	98	105	94
99	91	98	110	98	97	90	83	92	88
86	94	102	99	89	104	94	94	92	96
87	94	92	86	102	88	75	90	90	80
84	91	82	94	99	102	91	96	94	94
85	88	80	83	81	69	95	80	97	92
96	109	91	80	80	94	102	80	86	91
90	83	84	91	87	95	76	90	91	77
103	89	88	85	95	92	104	92	95	83
86	81	86	91	89	83	96	86	75	92

第一. 整理原始数据, 加工为分组资料, 作出频率分布表, 画直方图, 提取样本分布特征的信息. 步骤如下:

1. 找出数据中最小值 $m=69$, 最大值 $M=111$, 极差为 $M-m=42$

2. 数据分组, 根据样本容量 n 的大小, 决定分组数 k 。

一般规律	$30 \leq n \leq 40$	$5 \leq k \leq 6$
	$40 \leq n \leq 60$	$6 \leq k \leq 8$
	$60 \leq n \leq 100$	$8 \leq k \leq 10$
	$100 \leq n \leq 500$	$10 \leq k \leq 20$

数据数	40~60	100	150	200	400	600	800	1000	1500	2000	5000	10000
分组数	6~8	7~9	10~15	16	20	24	27	30	35	39	56	74

本例取 $k=9$.

一般采用等距分组（也可以不等距分组），组距等于极差除以组数略大的测量单位的整数倍。

本例测量单位为1厘米，组距为

$$\frac{M - m}{k} = \frac{111 - 69}{9} \approx 4.7 \approx 5$$

3. 确定组限和组中点值。

一般根据算式：

$$\text{各组中点值} \pm \frac{1}{2} \times \text{组距} = \text{组的上限或下限}$$

注意：组的上限与下限应比数据多一位小数。

当取 $a=67.5$ ， $b=112.5$ （ a 略小于 m ， b 略大于 M ，且 a 和 b 都比数据多一位小数），分组如下：

[67.5,72.5)	[72.5,77.5)	[77.5,82.5)
[82.5,87.5)	[87.5,92.5)	[92.5,97.5)
[97.5,102.5)	[102.5,107.5)	[107.5,112.5)

4. 将数据分组，计算出各组频数，作频数、频率分布表


组序	区间范围	频数 f_j	频率 $W_j=f_j/n$	累计频率 F_j
1	[67.5,72.5)	2	0.02	0.02
2	[72.5, 77.5)	5	0.05	0.07
3	[77.5, 82.5)	10	0.10	0.17
4	[82.5, 87.5)	18	0.18	0.35
5	[87.5, 92.5)	30	0.3	0.65
6	[92.5, 97.5)	18	0.18	0.83
7	[97.5, 102.5)	10	0.1	0.93
8	[102.5, 107.5)	4	0.04	0.97
9	[107.5, 112.5)	3	0.03	1.00

5. 作出频率直方图

以样本值为横坐标，频率/组距为纵坐标；

以分组区间为底，以 $Y_j = \frac{W_j}{X_{j+1} - X_j} = \frac{W_j}{5}$ 为高

作频率直方图



从频率直方图可看到：靠近两个极端的数据出现比较少，而中间附近的数据比较多，即中间大两头小的分布趋势，——随机变量分布状况的最粗略的信息。

在频率直方图中，每个矩形面积恰好等于样本值落在该矩形对应的分组区间内的频率，即

$$S_j = \frac{W_j}{X_{j+1} - X_j} \times (X_{j+1} - X_j) = W_j$$

频率直方图中的小矩形的面积近似地反映了样本数据落在某个区间内的可能性大小，故它可近似描述X的分布状况。

3. 经验分布函数

设 $(x_1, x_2, \dots, x_n)$ 是来自总体 X 的样本值, 定义

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{\{x_i \leq x\}}(x), \quad \text{其中 } I_{\{x_i \leq x\}}(x) = \begin{cases} 1, & x_i \leq x \\ 0, & x_i > x \end{cases}$$

称 $F_n(x)$ 为样本 $(x_1, x_2, \dots, x_n)$ 的**经验分布函数**.

满足分布函数的性质.

设 $(x_1, x_2, \dots, x_n)$ 是来自总体 X 的样本值, 定义

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{\{x_i \leq x\}}(x), \quad \text{其中 } I_{\{x_i \leq x\}}(x) = \begin{cases} 1, & x_i \leq x \\ 0, & x_i > x \end{cases},$$

将样本值由小到大排序 $x_{(1)} < x_{(2)} < \dots < x_{(l)}$,

每个不同样本值出现的频数记为: $m_1, \dots, m_l$

$$F_n(x) = \begin{cases} 0, & x < x_{(1)} \\ \frac{m_1 + \dots + m_k}{n}, & x_{(k)} \leq x < x_{(k+1)} \\ 1, & x \geq x_{(l)} \end{cases}$$

设 $(x_1, x_2, \dots, x_n)$ 是来自总体 X 的样本值, 定义

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{\{x_i \leq x\}}(x), \quad \text{其中 } I_{\{x_i \leq x\}}(x) = \begin{cases} 1, & x_i \leq x \\ 0, & x_i > x \end{cases},$$

称 $F_n(x)$ 为样本 $(x_1, x_2, \dots, x_n)$ 的**经验分布函数**.

含义: (1) $(x_1, x_2, \dots, x_n)$ 给定, $F_n(x)$ 是 x 的函数,
表示 $(x_1, x_2, \dots, x_n)$ 落入 $(-\infty, x]$ 内的概率.

(2) $F_n(x)$ 与 $(x_1, x_2, \dots, x_n)$ 有关, 是一个随机变量.

例 某食品厂生产听装饮料，现从生产线上随机抽取5听饮料，称得其净重（单位：克） 351 347 355 344 351

解： 这是一个容量为5的样本，经排序可得有序样本：

$$x_{(1)} = 344, x_{(2)} = 347, x_{(3)} = 351, x_{(4)} = 354, x_{(5)} = 355$$

其经验分布函数为

$$F_n(x) = \begin{cases} 0, & x < 344 \\ 0.2, & 344 \leq x < 347 \\ 0.4, & 347 \leq x < 351 \\ 0.8, & 351 \leq x < 354 \\ 1, & x \geq 354 \end{cases}$$

由**伯努里大数定律**：

只要 n 相当大， $F_n(x)$ 依概率收敛于 $F(x)$ 。

例 从织布车间抽取12匹布检查每匹布的疵点数，得样本
(1,0,0,2,1,3,2,0,1,1,2,1) 求样本频数分布和样本频率分布。

解： 将12个数从小到大排列,相同的合并, 0,0,0,1,1,1,1,1,2,2,2,3

得样本频数表(样本频数分布)

X	0	1	2	3
频数 m_i	3	5	3	1

得样本频率表(样本频率数分布)

X	0	1	2	3
频率 $\frac{m_i}{n}$	1/4	5/12	1/4	1/12

经验分布函数


设样本为 $(x_1, x_2, \dots, x_n)$, 对任意实数 x , 样本值中小于或等于 x 的个数为 $m(x)$, 则称 $F_n^*(x) = \frac{m(x)}{n}$ 为样本的经验分布函数.

$F_n^*(x)$ 同分布函数 $F(x)$ 一样具有性质:

非降、右连续、 $F_n^*(-\infty) = 0$, $F_n^*(+\infty) = 1$.


由样本频数分布得样本经验分布函数

$$F_n^*(x) = \begin{cases} 0, & x < x_1^* \\ \frac{m_1}{n}, & x_1^* \leq x < x_2^* \\ \frac{m_1 + m_2}{n}, & x_2^* \leq x < x_3^* \\ \vdots & \vdots \\ \sum_{i=1}^k m_i / n, & x_k^* \leq x < x_{k+1}^* \quad (k \leq l-1) \\ \vdots & \vdots \\ 1 & x \geq x_l^* \end{cases}$$



本例的样本经验分布函数：

$$F_n^*(x) = \begin{cases} 0, & x < 0 \\ 1/4, & 0 \leq x < 1 \\ 2/3, & 1 \leq x < 2 \\ 11/12, & 2 \leq x < 3 \\ 1 & x \geq 3 \end{cases}$$



由Chebyshev 大数定律, 对任意 $\varepsilon > 0$

$$\lim_{n \rightarrow \infty} P\left(\left|F_n^*(x) - F(x)\right| < \varepsilon\right) = 1$$

即 $F_n^*(x) \xrightarrow[n \rightarrow \infty]{p} F(x)$ 对固定 x 成立

样本经验
分布函数

依概率收敛于

总 体
分布函数

格里纹科(W. Clivenko,1933年)定理（了解）

定理（格里纹科定理） 设 $x_1, x_2, \dots, x_n$ 是取自总体分布函数为 $F(x)$ 的样本, $F_n(x)$ 是其经验分布函数，当 $n \rightarrow \infty$ 时，有

$$\lim_{n \rightarrow \infty} P \left(\sup_{x \in R} |F_n(x) - F(x)| < \varepsilon \right) = 1$$

格里纹科定理表明：当 n 相当大时，经验分布函数依概率关于 x 均匀地收敛于总体分布函数，经验分布函数 $F_n(x)$ 是总体分布函数 $F(x)$ 的一个良好的近似。

经典统计学中一切统计推断都以样本为依据，其理由就在于此。

谢谢！