高等学校教材

概率论与数理统计

施 雨 赵小艳 李耀武 段启宏 编

高等教育出版社

高等学校教材

概率论与数理统计

施 雨 赵小艳 李耀武 段启宏 编

常州大学图书馆
藏书章

高等教育出版社·北京

内容提要

本书内容包括概率论、数理统计和随机过程三部分，共 12 章，其中第 1—5 章是概率论部分，包括随机事件与概率、随机变量及其概率分布、随机向量及其概率分布、随机变量的数字特征、大数定律与中心极限定理；第 6—10 章是数理统计部分，包括数理统计学的基本概念、参数估计、假设检验、方差分析、回归分析；第 11—12 章是随机过程部分，包括随机过程的基本知识、平稳过程。

本书配有知识点讲解视频、拓展阅读、理论探究、模拟试验、自测题、习题参考答案等教学资源，拓展课程广度，挖掘课程深度，引导读者更好地掌握课程的内容。

本书可作为理工类各专业的概率论与数理统计课程教材，也可供工程技术人员及报考理工类专业硕士研究生的人员参考。

图书在版编目(CIP)数据

概率论与数理统计／施雨等编. --北京：高等教育出版社，2021.8

ISBN 978-7-04-056214-9

Ⅰ.①概… Ⅱ.①施… Ⅲ.①概率论-高等学校-教材 ②数理统计-高等学校-教材 Ⅳ.①O21

中国版本图书馆 CIP 数据核字(2021)第 112642 号

策划编辑	杨　帆	责任编辑	杨　帆	封面设计	王　鹏	版式设计	童　丹
插图绘制	邓　超	责任校对	刁丽丽	责任印制	赵　振		

出版发行	高等教育出版社	网　址	http://www.hep.edu.cn
社　址	北京市西城区德外大街 4 号		http://www.hep.com.cn
邮政编码	100120	网上订购	http://www.hepmall.com.cn
印　刷	天津鑫丰华印务有限公司		http://www.hepmall.com
开　本	787mm×1092mm　1/16		http://www.hepmall.cn
印　张	21.25		
字　数	450 千字	版　次	2021 年 8 月第 1 版
购书热线	010-58581118	印　次	2021 年 8 月第 1 次印刷
咨询电话	400-810-0598	定　价	49.80 元

本书如有缺页、倒页、脱页等质量问题，请到所购图书销售部门联系调换

版权所有　侵权必究

物 料 号　56214-00

概率论与数理统计

施　雨　赵小艳
李耀武　段启宏

1　计算机访问http://abook.hep.com.cn/1235606，或手机扫描二维码、下载并安装Abook应用。

2　注册并登录，进入“我的课程”。

3　输入封底数字课程账号（20位密码，刮开涂层可见），或通过Abook应用扫描封底数字课程账号二维码，完成课程绑定。

4　单击“进入课程”按钮，开始本数字课程的学习。

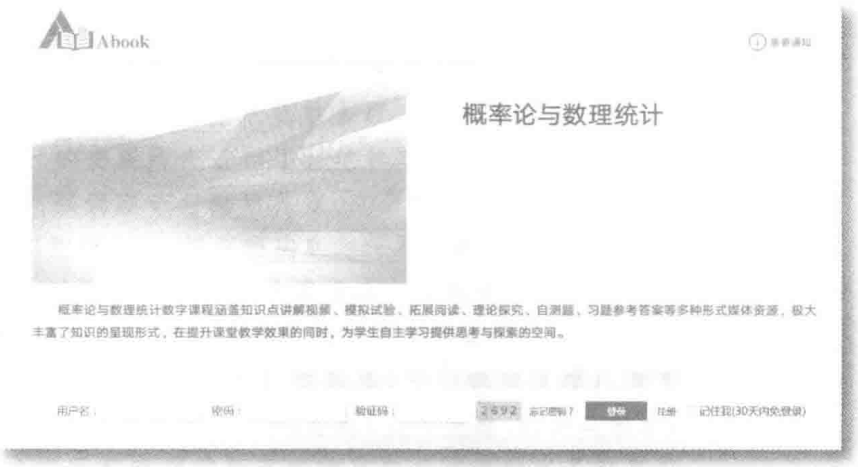

课程绑定后一年为数字课程使用有效期。受硬件限制，部分内容无法在手机端显示，请按提示通过计算机访问学习。

如有使用问题，请发邮件至abook@hep.com.cn。

http://abook.hep.com.cn/1235606

前言

概率论与数理统计是从数量上研究随机现象内在规律性的学科。随着科学技术的发展以及人们对随机现象规律性认识的需要，概率统计的思想方法已经日益渗透到自然科学和社会科学的众多领域中。概率论与数理统计已经成为高校各专业学生必修的一门数学基础课程。

近些年随着互联网的普及，涌现出大量数据，各行各业都需要从海量数据和大量随机现象中挖掘其统计规律性，以便提高生产效率或制订预案以应对突发事件。2017年国家提出新工科建设项目，要求高等教育培养具有创新创业意识、数字化思维和跨界整合能力的“新工科”人才。这些都对概率论与数理统计课程提出新的要求，与课程内容相配套的教材建设势在必行。

基于以上考虑，本教材在原有教材的基础上优化整合概率统计课程教学内容，将理论内容、应用实例与概率统计的发展历史进行了科学的融合，在编写中注重概率论与数理统计思想的逐渐渗透，强调理论与应用并重，注重理论内容与实际应用的有机融合，有利于培养读者辨识随机模型，提高解决实际问题的能力。

本教材由概率论、数理统计和随机过程三部分内容组成。概率论起源于赌博问题，17世纪50年代费马、帕斯卡、惠更斯以及一些意大利数学家都曾探讨过“合理分配赌金”问题。其后，雅科布·伯努利（大数定律）、棣莫弗（中心极限定理）、蒲丰（投针试验、几何概率）、拉普拉斯（概率的古典定义）、高斯（正态分布、最小二乘法）以及泊松（泊松分布、大数定律）等数学家也对概率论的发展与进步做出了重要贡献。不过，概率论在发展过程中也面临困难与挑战。1899年贝特朗提出如下问题：在半径为1的圆内随机地取一弦，问其弦长超过此圆内接正三角形的边长的概率是多少？对这一问题的求解有赖于“随机取弦”试验的设定，不同试验的设定下，其结果也不同。这便是所谓的“贝特朗奇论”。这个奇论说明概率的概念是以某种确定的试验为前提的，这种试验有时可由问题本身来明确规定，有时则不然。由此可见贝特朗奇论的出现是直接针对概率概念的，这使得人们对拉普拉斯给出的古典概率定义产生质疑。到了20世纪30年代，苏联数学家科尔莫戈罗夫在概率论中建立起公理化体系，奠定了这门学科坚实的理论基础，其后概率论得以蓬勃发展，成为一个从数量上研究随机现象内在规律性的数学分支。如今，概率论已渗透到自然科学和社会科学的众多领域中，并与其他学科交叉融合，是应用前景极为广阔的数学学科。

数理统计也是研究随机现象的统计规律性的一门数学学科，它以概率论为基础，研究如何合理有效地收集受到随机性影响的数据，以及如何对所获得的数据进行整理和分析，从而为随机现象选择合适的数学模型，并提供检验方法，在此基础上对随机现象的性质、特点和统计规律做出推断和预测，为决策提供依据和建议。

概率论与数理统计之间的联系非常紧密。一方面，概率论为数理统计提供了最基本的理论，在此基础上，数理统计在发展的过程中也逐步形成了自身的一套理论体系；另一方面，数理统计为概率论中的理论模型提供了应用方案或方法。

随机过程是概率论的延续和发展。如果说概率论的主要研究对象是有限维随机变量的概率分布与数字特征,那么随机过程的核心内容便是探讨无限维随机变量的概率规律。

本教材注重知识拓展,采用纸质材料与在线资源相结合的呈现模式,例如在知识点的邻近添上边注或二维码,增加模拟试验、知识点讲解视频、拓展阅读、理论探究、自测题等在线资源,补充软件求解的相关命令,添加每章内容小结,力求用通俗易懂的语言解释概率论与数理统计的思想与方法,从广度和深度上拓展教材内容,为读者自主学习提供空间,以便培养发散性思维。

本教材作为西安交通大学“十四五”规划教材重点资助项目,在编写中得到了西安交通大学教务处、数学与统计学院的大力支持,也得到了西安交通大学数学与统计学院李继成教授的大力支持,高等教育出版社杨帆编辑对本书的出版给予了热忱帮助与大力支持,提出了许多宝贵意见和建议,在此向他们表示衷心的感谢!

限于编者的水平,疏漏恐在所难免,敬请读者不吝赐教。

编　者

2021.3

目 录

1 第1章 随机事件与概率
1 1.1 随机事件
1 1.1.1 随机现象与随机试验
2 1.1.2 样本空间与随机事件
2 1.1.3 事件的关系与运算
6 1.2 概率
6 1.2.1 概率的古典定义
8 1.2.2 概率的统计定义
10 1.2.3 概率的公理化定义
11 1.2.4 概率的性质
13 1.3 条件概率 事件的相互独立性
13 1.3.1 条件概率与乘法公式
15 1.3.2 全概率公式与贝叶斯公式
17 1.3.3 事件的相互独立性
20 内容小结
22 习题1
26 自测题1
26 习题1参考答案

27 第2章 随机变量及其概率分布
27 2.1 随机变量
27 2.1.1 随机变量与分布函数
29 2.1.2 离散型随机变量
35 2.1.3 连续型随机变量
40 2.2 随机变量的函数及其概率分布
40 2.2.1 随机变量的函数的概念
41 2.2.2 离散型随机变量的函数的概率分布
43 2.2.3 连续型随机变量的函数的概率分布
45 内容小结
47 习题2
50 自测题2
50 习题2参考答案

51 第3章 随机向量及其概率分布
51 3.1 n 维随机向量
51 3.1.1 随机向量的概念
51 3.1.2 分布函数与边缘分布函数
53 3.1.3 二维离散型随机向量
56 3.1.4 二维连续型随机向量
59 3.2 条件分布
62 3.3 随机变量的相互独立性
65 3.4 随机向量的函数及其概率分布
65 3.4.1 随机向量的函数
65 3.4.2 二维离散型随机向量的函数的概率分布
67 3.4.3 二维连续型随机向量的函数的概率分布
74 内容小结
76 习题3
80 自测题3
80 习题3参考答案

81 第4章 随机变量的数字特征
81 4.1 数学期望
81 4.1.1 数学期望的定义
84 4.1.2 随机变量的函数的数学期望
85 4.1.3 数学期望的性质
86 4.2 方差
86 4.2.1 方差与标准差
87 4.2.2 方差的性质
90 4.3 协方差与相关系数 矩
90 4.3.1 协方差与相关系数
94 4.3.2 矩
95 4.3.3 协方差矩阵
96 *4.4 条件期望与条件方差
100 内容小结
102 习题4

105 自测题 4
105 习题 4 参考答案

106 第 5 章 大数定律与中心极限定理
106 5.1 随机变量的收敛性与切比雪夫不等式
106 5.1.1 依概率收敛
107 5.1.2 依分布收敛
107 5.1.3 切比雪夫不等式
108 5.2 大数定律
108 5.2.1 切比雪夫大数定律
109 5.2.2 伯努利大数定律
110 5.2.3 辛钦大数定律
111 5.3 中心极限定理
113 5.3.1 独立同分布中心极限定理
114 5.3.2 棣莫弗-拉普拉斯中心极限定理
116 *5.3.3 不同分布的中心极限定理
118 内容小结
119 习题 5
120 自测题 5
120 习题 5 参考答案

121 第 6 章 数理统计学的基本概念
121 6.1 总体与样本
121 6.1.1 总体
122 6.1.2 样本
124 6.2 样本数据的整理
124 6.2.1 样本频数分布与频率分布
125 6.2.2 频率直方图
127 6.2.3 经验分布函数
128 6.3 统计量
128 6.3.1 统计量的概念
129 6.3.2 几个常用的统计量
132 6.4 抽样分布
133 6.4.1 几种常用的重要分布
138 6.4.2 分位数
139 6.4.3 正态总体的抽样分布
141 内容小结
143 习题 6
146 自测题 6
146 习题 6 参考答案

147 第 7 章 参数估计
147 7.1 点估计
147 7.1.1 问题的提法
148 7.1.2 估计量的求法
156 7.2 估计量的评选标准
156 7.2.1 无偏性
158 7.2.2 有效性
160 7.2.3 相合性
161 7.3 区间估计
161 7.3.1 双侧区间估计
165 7.3.2 单侧区间估计
166 7.4 正态总体参数的区间估计
166 7.4.1 单个总体 $N(\mu,\sigma^2)$ 的情形
168 7.4.2 两个总体 $N(\mu_1,\sigma_1^2)$ 与 $N(\mu_2,\sigma_2^2)$ 的情形
174 内容小结
174 习题 7
177 自测题 7
177 习题 7 参考答案

178 第 8 章 假设检验
178 8.1 假设检验的基本概念
178 8.1.1 假设检验的基本原理
179 8.1.2 两类错误
180 8.1.3 假设检验的一般步骤
181 8.1.4 p 值
182 8.2 正态总体参数的假设检验
182 8.2.1 单个总体 $N(\mu,\sigma^2)$ 的情形
185 8.2.2 两个总体 $N(\mu_1,\sigma_1^2)$ 与 $N(\mu_2,\sigma_2^2)$ 的情形
188 8.3 单侧假设检验
192 8.4 非正态总体的大样本检验及小样本检验

192 8.4.1 非正态总体的大样本检验
194 8.4.2 非正态总体的小样本检验
195 8.5 成对数据的假设检验
196 8.6 分布假设检验
196 8.6.1 分布拟合检验 皮尔逊定理
196 8.6.2 χ^2 拟合检验法
201 内容小结
202 习题 8
205 自测题 8
205 习题 8 参考答案

206 第 9 章 方差分析
206 9.1 单因素方差分析
206 9.1.1 数学模型
208 9.1.2 统计分析
211 9.1.3 未知参数的估计
213 9.2 双因素方差分析
213 9.2.1 非重复试验
218 9.2.2 等重复试验
223 内容小结
224 习题 9
227 自测题 9
227 习题 9 参考答案

228 第 10 章 回归分析
228 10.1 一元线性回归
228 10.1.1 一元线性回归模型
230 10.1.2 a,b 和 σ^2 的估计
234 10.1.3 一元线性回归中的假设检验
237 10.1.4 预测
239 10.2 可线性化的一元非线性回归
242 10.3 多元线性回归
242 10.3.1 模型与参数估计
244 10.3.2 线性回归的另一种形式
249 10.3.3 线性回归的显著性检验
252 10.3.4 回归系数的假设检验
254 10.3.5 预测
255 内容小结
256 习题 10
259 自测题 10
259 习题 10 参考答案

260 第 11 章 随机过程的基本知识
260 11.1 随机过程的概念与记号
261 11.2 随机过程的概率特性
261 11.2.1 有限维分布函数族
262 11.2.2 随机过程的数字特征
264 11.2.3 两个随机过程的不相关与相互独立
265 11.3 随机过程的基本类型
265 11.3.1 按参数集与状态空间分类
265 11.3.2 按过程的性质特点分类
267 11.4 泊松过程与布朗运动
267 11.4.1 泊松过程的定义与性质
271 11.4.2 布朗运动
272 11.5 附录
274 内容小结
275 习题 11
277 自测题 11
277 习题 11 参考答案

278 第 12 章 平稳过程
278 12.1 平稳过程的概念
280 12.2 相关函数的性质
280 12.2.1 自相关函数的性质
281 12.2.2 互相关函数的性质
281 12.3 平稳过程的谱密度
281 12.3.1 相关函数的谱分解
283 12.3.2 谱密度的物理意义
286 12.3.3 谱密度与互谱密度的性质
288 12.3.4 相关函数与谱密度之间的变换
292 12.4 各态历经性
292 12.4.1 各态历经性的概念
294 12.4.2 各态历经定理

296 12.4.3 各态历经性的应用
298 12.5 附录
298 12.5.1 两个补充定理
298 12.5.2 均方微积分
301 内容小结
302 习题 12
305 自测题 12
305 习题 12 参考答案
306 附表
306 附表 1 标准正态分布表
308 附表 2 泊松分布表
310 附表 3 t 分布表
312 附表 4 χ^2 分布表
315 附表 5 F 分布表
327 参考文献

第1章 随机事件与概率

现实生活中存在大量随机现象和随机事件，它们的发生看似随机但都有一定的规律，概率论就是研究随机现象的统计规律性的学科.本章是概率论的基础，将介绍随机事件、随机试验及概率的相关性质.

1.1 随机事件

1.1.1 随机现象与随机试验

客观世界中存在着这样一类现象：在一定条件下它可能发生，也可能不发生，具有不确定性.例如，抛掷一枚硬币，其结果可能是有数字的一面（以下称为正面）朝上，也可能是另一面（以下称为反面）朝上，在每次抛掷之前，无法确定会出现何种结果.又如，从一批产品中任意抽出一件来检验，其结果可能是合格品，也可能是不合格品，事先不能肯定.在现实生活中，类似的例子还可以举出许多：如养鱼场的一万尾鱼苗能成活几许？明年的中秋节能观赏到月亮吗？下一届世界杯赛的冠军得主为谁？……这类现象称为**随机现象**.一般而言，随机现象具有以下特征：在一定的试验条件下，其试验结果不止一个；对于一次试验，可能出现这种结果，也可能出现那种结果，事先无法确定会出现何种结果.

尽管就一次试验而言，随机现象的发生与否表现出不确定性，似乎捉摸不定，然而人们经过长期的实践并深入研究之后，发现在大量重复试验或观察下，随机现象呈现出某种规律性.例如，抛掷一枚均匀硬币，一次抛掷不能断定它的哪一面朝上，但如果对同一枚硬币进行成百上千次的抛掷，将会发现，“正面朝上”与“反面朝上”的出现次数大致各占一半.从一大批产品中，任意抽取一件产品，抽到合格品或不合格品是随机的，但当重复抽取时，抽到不合格品的次数与抽取总次数之比呈现出某种稳定性.随机现象的这种内在规律性叫做**统计规律性**.概率论与数理统计是研究和揭示随机现象的统计规律性的数学学科.

随机现象的统计规律性，一般可在相同条件下，通过大量重复试验获得，这里的试验在概率统计中指的就是随机试验.那么，什么是随机试验呢？如果一个试验具备以下特征：（1）可以在相同条件下重复进行；（2）每次试验的可能结果不止一个，但事先能明确全部可能的结果；（3）进行一次试验之前不能肯定哪一个结果会出现，则称这种试验为**随机试验**，简称**试验**.以后用 E 或 $E_1, E_2, \cdots$ 来表示随机试验.例如：

E_1：抛掷一枚均匀硬币，观察正面、反面的出现情况.

E_2：投掷一颗均匀骰子，观察出现的点数.

E_3：记录车站售票处一天内售出的车票数.

E_4：从一大批元件中任意抽取一个，测试其使用寿命.

上述这些试验都是随机试验.

我们正是借助随机试验，观察和研究随机现象，进而希望找出其内在的统计规律性.

1.1.2 样本空间与随机事件

对于一个试验 E,虽然在一次试验之前不能肯定哪个结果会发生,但试验的一切可能结果是已知的,我们把 E 的所有可能的试验结果组成的集合称为 E 的**样本空间**,样本空间的元素(亦即 E 的每个可能结果)称为**样本点**.以下用 Ω 或 $\Omega_1,\Omega_2,\cdots$ 表示样本空间.例如,试验 E_1 至 E_4 的样本空间分别是:

$\Omega_1=\{\omega_0,\omega_1\}$,其中 ω_0 表示"正面朝上",ω_1 表示"反面朝上".

$\Omega_2=\{1,2,3,4,5,6\}$,其中数 i 表示"出现 i 点",$i=1,2,3,4,5,6$.

$\Omega_3=\{0,1,2,\cdots,n\}$,这里的 n 是售票处一天内准备出售的车票数.

$\Omega_4=\{\omega\mid\omega\geqslant 0\}$ 或者 $\Omega_4=[0,+\infty)$.

在随机试验中,其样本空间的子集叫做该试验的**随机事件**,简称**事件**.以后用 A,B,C,$\cdots$ 表示事件.

在试验 E_2 中,如果用 A 表示"掷出的点数为奇数",那么 A 是一个事件.由于在一次投掷中,当且仅当掷出的点数是 1,3,5 中的任何一个时才称事件 A 发生,所以我们把事件 A 表示为 $A=\{1,3,5\}$.同样地,若 B 表示事件"掷出的点数为偶数",那么 $B=\{2,4,6\}$ 也是一个事件.若 C 表示"掷出的点数为素数",那么 $C=\{2,3,5\}$,它同样是一个事件.

对于一个试验 E,它的样本空间 Ω 是由 E 的全部可能结果组成的集合,而它的一个事件 A 只是由 E 的一部分可能结果组成的集合,因而 $A\subset\Omega$.称事件 A 发生,就是当且仅当属于 A 的某一个样本点在一次试验中出现.

对于一个试验 E,在每次试验中必然发生的事件,称为**必然事件**;在每次试验中都不发生的事件,称为**不可能事件**.例如,在 E_2 中,"掷出的点数不超过 6"是必然事件,若用试验结果的集合来表示,这一事件就是 E_2 的样本空间 $\Omega_2=\{1,2,3,4,5,6\}$.而事件"掷出的点数小于 1"是不可能事件.这个事件不包含 E_2 的任何一个可能结果,故我们用空集的记号 $\varnothing$ 表示不可能事件.

一般地,对于试验 E,包含它的所有可能的试验结果的样本空间 Ω 是必然事件;不包含它的任何一个试验结果的事件 $\varnothing$ 是不可能事件.今后我们就用 Ω 表示必然事件,用 $\varnothing$ 表示不可能事件.为了运算方便,把必然事件 Ω 和不可能事件 $\varnothing$ 当作随机事件的两个极端情况.

1.1.3 事件的关系与运算

从上一段的讨论中,我们知道,对于试验 E,不可能事件是空集 $\varnothing$,必然事件是样本空间 Ω 本身,事件 A 是样本空间 Ω 的子集,于是事件间的关系和运算就可以用集合论的知识来解释.下面,在讨论两个事件之间的关系和对若干个事件进行运算时,均假定它们是同一个随机试验下的事件.

1. 事件的包含与相等

设有两个事件 A,B,若事件 A 发生必然导致事件 B 发生,则称事件 B **包含**事件 A,或者事件 A **含于**事件 B,记作 $B\supset A$,或者 $A\subset B$.用集合论的术语来表达,即 $\forall\,\omega\in A\Rightarrow\omega\in B$.

例如,在试验 E_2 中,记 $A=\{$掷出的点数为奇数$\}$,则 $A=\{1,3,5\}$.记 $B=\{$掷出的

点数不超过 5}，则 $B=\{1,2,3,4,5\}$. 显然，如果事件 A 发生，那么事件 B 必发生. 图 1.1 直观地描绘了事件 B 包含事件 A.

若事件 A,B 相互包含，即 $A\subset B$ 且 $B\subset A$，则称事件 A,B **相等**，记作 $A=B$.

例如，在试验 E_2 中，记 $A=$｛掷出 3 点或 6 点｝，$B=$｛掷出的点数为 3 的倍数｝，这两个事件表面上看起来具有不同的说法，其实表示同一事件，因而 $A=B$.

2. 事件的和

设有两事件 A,B，称｛A,B 中至少有一个发生｝的事件为 A 与 B 的**和事件**，记为 $A\cup B$. 事件 $A\cup B$ 发生意味着或者仅事件 A 发生，或者仅事件 B 发生，或者两者都发生. 用集合论的术语来表达，即 $A\cup B=\{\omega\mid \omega\in A \text{ 或 } \omega\in B\}$.

例如，在试验 E_2 中，记 $A=$｛掷出的点数为奇数｝$=\{1,3,5\}$，$B=$｛掷出的点数为 3 的倍数｝$=\{3,6\}$，那么事件 A 与事件 B 的和事件 $A\cup B=\{1,3,5,6\}$. 图 1.2 直观表示出和事件 $A\cup B$. 有时也把事件的和称为事件的并.

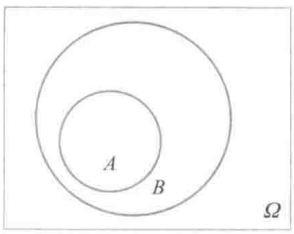

图 1.1

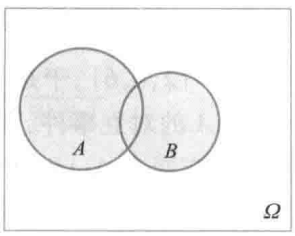

图 1.2

事件的和可以推广到多个事件的情形. 设有 n 个事件 $A_1,A_2,\cdots,A_n$，定义它们的和事件为｛$A_1,A_2,\cdots,A_n$ 中至少有一个发生｝，记为 $\bigcup\limits_{k=1}^{n}A_k$，亦即 $\bigcup\limits_{k=1}^{n}A_k=$｛$A_1,A_2,\cdots,A_n$ 中至少有一个发生｝. 类似地，可定义可数个事件的和：设有可数个事件 $A_1,A_2,\cdots,A_n,\cdots$，定义它们的和事件 $\bigcup\limits_{k=1}^{\infty}A_k$ 为

$$\bigcup_{k=1}^{\infty}A_k=\{A_1,A_2,\cdots,A_n,\cdots\text{中至少有一个发生}\}$$

3. 事件的积

设有两事件 A,B，称｛A,B 都发生｝的事件为 A 与 B 的**积事件**，记为 $A\cap B$，简记为 AB. 用集合论的术语来表达，即 $AB=\{\omega\mid \omega\in A \text{ 且 } \omega\in B\}$.

例如，在试验 E_2 中，令 $A=$｛掷出的点数为奇数｝$=\{1,3,5\}$，$B=$｛掷出的点数为素数｝$=\{2,3,5\}$，则 $AB=\{3,5\}$. 积事件 AB 可以用图 1.3 来直观表示. 有时也把事件的积称为事件的交.

类似地，可以定义有限个事件 $A_1,A_2,\cdots,A_n$ 或可数个事件 $A_1,A_2,\cdots,A_n,\cdots$ 的积事件：

$$\bigcap_{k=1}^{n}A_k=\{A_1,A_2,\cdots,A_n\text{ 都发生}\}$$

$$\bigcap_{k=1}^{\infty}A_k=\{A_1,A_2,\cdots,A_n,\cdots\text{都发生}\}$$

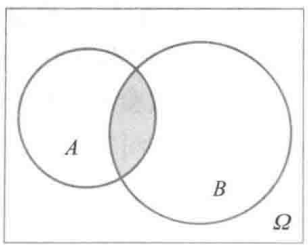

图 1.3

4. 事件的互斥和对立

设有两事件 A,B,若事件 A,B 不能同时发生,即 $AB=\varnothing$,则称 A,B 是**互斥**的,或称它们是**互不相容**的.若事件 $A_1,A_2,\cdots,A_n$ 中的任意两个都互斥,则称这些事件是两两互斥的,或称它们是**互斥事件组**.

例如,在试验 E_2 中,令 $A=\{$掷出的点数至多为 3$\}$,$B=\{$掷出的点数大于 4$\}$,由于 $A=\{1,2,3\}$,而 $B=\{5,6\}$,在组成事件 A,B 的那些试验结果中并无公共部分,故 $AB=\varnothing$,亦即事件 A,B 不会同时发生,所以 A,B 是互斥的.图 1.4 直观地表示了两事件互斥的含义.

互斥事件的一个特殊情况是对立事件.

设有事件 A,则事件

$$B=\{A\text{ 不发生}\}$$

称为 A 的**对立事件**,记为 $\overline{A}$,即 $B=\overline{A}=\{\omega \mid \omega\in\Omega \text{ 且 } \omega\notin A\}$.

例如,在试验 E_2 中,令 $A=\{$掷出的点数为奇数$\}$,$B=\{$掷出的点数为偶数$\}$,因为 $A=\{1,3,5\}$,而 $B=\{2,4,6\}$,于是 $B=\overline{A}$.此外,不难看出 $A=\overline{B}$,这说明对立事件是个相互的概念,B 是 A 的对立事件,那么 A 也是 B 的对立事件.由本例还可以发现,一方面有 $AB=\varnothing$,另一方面有 $A\cup B=\{1,2,3,4,5,6\}=\Omega$,即 B 包含的试验结果加上 A 包含的试验结果便补全了全部的试验结果,故对立事件 B 又叫做"补事件".很明显,$\overline{\overline{A}}=A$.

一般地,事件 A,B 互为对立事件,当且仅当

$$AB=\varnothing,\quad A\cup B=\Omega$$

所以,上面的两个等式亦可作为对立事件的定义.对立事件 $\overline{A}$ 的几何表示是图 1.5 中的阴影部分.

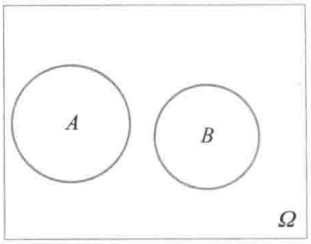

图 1.4

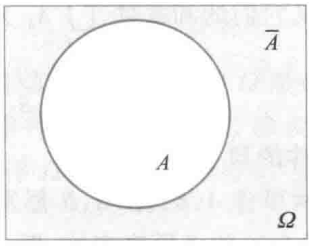

图 1.5

5. 事件的差

设有两事件 A,B,称事件$\{A$ 发生,B 不发生$\}$为事件 A 与事件 B 的**差事件**,记为 $A-B$.用集合论的术语来表达,即 $A-B=\{\omega \mid \omega\in A \text{ 且 } \omega\notin B\}$.

例如,在试验 E_2 中,令 $A=\{$掷出的点数为奇数$\}$,$B=\{$掷出的点数为素数$\}$,即 $A=\{1,3,5\}$,$B=\{2,3,5\}$,于是 $A-B=\{1\}$.

由差事件的定义可知:

$$A-B=A\overline{B} \tag{1.1.1}$$

图 1.6,图 1.7 中的阴影部分即表示 $A-B$.

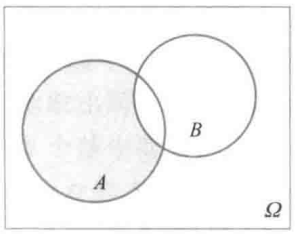

图 1.6

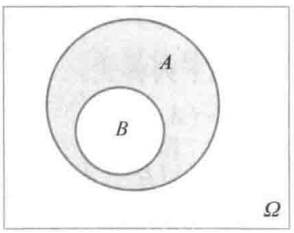

图 1.7

在进行事件的运算时,经常要用到下述定律:

设有事件 A,B,C,则有

交换律 $A\cup B=B\cup A$; $AB=BA$

结合律 $(A\cup B)\cup C=A\cup(B\cup C)$; $(AB)C=A(BC)$

分配律 $(A\cup B)C=(AC)\cup(BC)$; $(AB)\cup C=(A\cup C)(B\cup C)$

对偶律(也称为德摩根律) $\overline{A\cup B}=\overline{A}\,\overline{B}$; $\overline{AB}=\overline{A}\cup\overline{B}$

现证明对偶律:

$$\begin{aligned}\overline{A\cup B}&=\overline{\{A,B\text{ 中至少有一个发生}\}}\\&=\{A,B\text{ 都不发生}\}\\&=\{\overline{A},\overline{B}\text{ 同时发生}\}\\&=\overline{A}\,\overline{B}\end{aligned}$$

这就证明了第一个等式.利用已证明的等式不难证明第二个等式,因为

$$AB=\overline{\overline{A}\,\overline{B}}=\overline{\overline{A}\cup\overline{B}}$$

所以

$$\overline{AB}=\overline{\overline{\overline{A}\cup\overline{B}}}=\overline{A}\cup\overline{B}$$

对事件 A,B,若 $A\subset B$,则

$$A\cup B=B,\quad AB=A$$

因此,对任意事件 A,

$$A\cup\Omega=\Omega,\quad A\Omega=A,\quad A\cup\varnothing=A,\quad A\varnothing=\varnothing$$

在进行事件的运算时,优先顺序是:补运算为先,积运算其次,和、差的运算最后,若有括号,则括号内的运算优先.

例 1.1 设 A,B,C 为三个事件,试用 A,B,C 表达下列事件:

(1) $D_1=\{$三个事件中至少有两个出现$\}$;

(2) $D_2=\{$三个事件中至多有两个出现$\}$;

(3) $D_3=\{$恰有两个事件出现$\}$.

解 (1) $$D_1=AB\cup BC\cup CA$$

或

$$D_1=AB\overline{C}\cup A\overline{B}C\cup\overline{A}BC\cup ABC$$

(2) $$\begin{aligned}D_2&=\overline{ABC}\\&=\overline{A}\,\overline{B}\,\overline{C}\cup AB\overline{C}\cup A\overline{B}C\cup\overline{A}B\overline{C}\cup\overline{A}\,\overline{B}C\cup AB\overline{C}\cup A\overline{B}C\cup\overline{A}BC\end{aligned}$$

(3) $$D_3=AB\bar{C}\cup A\bar{B}C\cup\bar{A}BC$$

例 1.2 简化下列各式：

(1) $(A\cup B)-(A-B)$；

(2) $(A\cup B)(A\cup\bar{B})(\bar{A}\cup B)$.

解 (1) $$(A\cup B)-(A-B)=(A\cup B)\overline{(A-B)}=(A\cup B)\overline{A\,\bar{B}}$$

$$=(A\cup B)(\bar{A}\cup B)=A\bar{A}\cup AB\cup B\bar{A}\cup BB=B$$

(2) $$(A\cup B)(A\cup\bar{B})(\bar{A}\cup B)=A(\bar{A}\cup B)=AB$$

1.2 概率

对于随机事件，人们更关注的是其发生的可能性大小.我们用取值在区间[0,1]上的实数来度量一个随机事件发生的可能性大小，这个实数就是我们说的概率.下面介绍概率的三种定义，并给出概率的性质.

1.2.1 概率的古典定义

如果某随机试验只有有限个试验结果 $\omega_1,\omega_2,\cdots,\omega_n$，而且从该试验的条件及实施方法分析，又没有理由认为其中的某个结果要比任何其他的结果更容易发生，那么我们只能认为每个试验结果在试验中具有同等可能的出现机会，也即$\frac{1}{n}$的出现机会.一般地，若试验满足

(1) 只有有限个试验结果 $\omega_1,\omega_2,\cdots,\omega_n$；

(2) 每个试验结果在一次试验中发生的可能性相等，

则称在此试验下构建的概率模型为**古典概型**，相应地称这种试验为**古典概型试验**.

古典概型又称为**等可能概型**.因它是概率论发展初期的主要研究对象，故称之为“古典”概型.概率的古典定义正是基于古典概型.

定义 1.1 设古典概型试验的所有结果为 $\Omega=\{\omega_1,\omega_2,\cdots,\omega_n\}$.若某事件 A 恰包含 Ω 中的 m 个结果，则 A 的概率 $P(A)$ 定义为

$$P(A)=\frac{m}{n} \tag{1.2.1}$$

从古典概型的“有限性”与“等可能性”中，我们不难看出(1.2.1)式的合理性.在一次试验中，每个结果的出现机会同为$\frac{1}{n}$，现在事件 A 包含了 m 个结果，则在一次试验中，A 发生的概率应为 $m\cdot\frac{1}{n}=\frac{m}{n}$.注意到(1.2.1)式中的分子是 A 所包含的试验结果的个数 m，而分母是所有试验结果的总数，故(1.2.1)式又可以写成

$$P(A)=\frac{A\text{ 所包含的试验结果的个数}}{\text{试验结果的总数}}$$

由(1.2.1)式算得的事件 A 的概率称为**古典概率**.

计算古典概率需要排列组合方面的知识，下面我们举几个例子.

例 1.3 一袋中有 8 个大小形状相同的球，其中 5 个为黑色球，3 个为白色球.现从袋中随机地取出两个球，求取出的两球是黑色球的概率.

解 从 8 个球中取出两个，不同的取法有 C_8^2 种，所谓“随机”或“任意”地取，是指这 C_8^2 种取法有等可能性.若以 A 表示事件{取出的两球是黑色球}，那么使 A 发生的取法，或者说有利于 A 的取法有 C_5^2 种，从而

$$P(A)=\frac{C_5^2}{C_8^2}=\frac{5}{14}$$

例 1.4 一批产品共 N 件，其中次品有 M 件，今从中任取 n 件，问事件 $A=${其中恰有 $m(m\leqslant M)$ 件次品}的概率是多少？

解 在 N 件产品中取出 n 件，所有可能的取法共有 C_N^n 种，每一种取法对应一个试验结果.从 M 件次品中取 m 件，取法有 C_M^m 种，从其余 $N-M$ 件正品中取 $n-m$ 件，取法有 C_{N-M}^{n-m} 种，由乘法原理知有利于事件 A 的取法共有 $C_M^m C_{N-M}^{n-m}$ 种.故 A 的概率为

$$P(A)=\frac{C_M^m C_{N-M}^{n-m}}{C_N^n}$$

在有些实际应用中，如果试验的结果有无限多个，那么就不能按照“古典概型”来计算概率了.然而，只要试验结果仍具有等可能性，还可以用几何的方法来解决概率的计算问题.

设某试验的样本空间为有界区域 Ω，如果样本点落入 Ω 的任何子域中的机会与该子域的度量成正比，而与其位置及形状无关，那么样本点落入子域 $A(A\subset\Omega)$ 的概率 $P(A)$ 被定义为

$$P(A)=\frac{A\text{ 的度量}}{\Omega\text{ 的度量}} \tag{1.2.2}$$

其中 Ω 的度量大于 0.

上述概率模型称为**几何概型**，它也被称作“等可能概型”，因为这种概率模型同样要求具备等可能性.应用几何概型计算的概率称为**几何概率**.

例 1.5 在区间(0,1)中随机地取两个实数，求两实数之和小于$\frac{3}{2}$的概率.

解 建立如下几何概型：在区间(0,1)中随机地取两个实数 x,y，则点 (x,y) 等可能地取自正方形区域(见图 1.8)

$$\Omega=\{(x,y)\in\mathbf{R}^2\mid 0<x<1,0<y<1\}$$

设 A 为事件$\left\{\text{两实数之和小于}\frac{3}{2}\right\}$，则 A 可表示为(见图 1.8 中的阴影部分)

$$A=\left\{(x,y)\in\Omega\,\middle|\,x+y<\frac{3}{2}\right\}$$

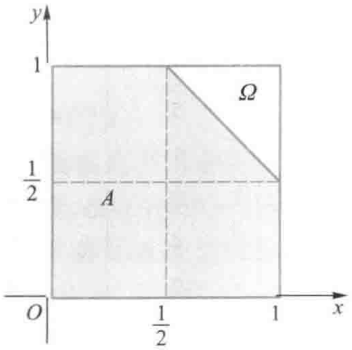

图 1.8

于是由(1.2.2)式知，

$$P(A)=\frac{A\text{ 的面积}}{\Omega\text{ 的面积}}=1-\frac{1}{2}\left(\frac{1}{2}\right)^2=\frac{7}{8}$$

扫码展阅读
贝特朗奇论

前言中贝特朗提出的问题可用几何概型来求解.

不难验证,由(1.2.1)式或(1.2.2)式定义的概率具有以下性质:

(1) $P(A)\geqslant 0$;

(2) $P(\Omega)=1$;

(3) 若事件 $A_1,A_2,\cdots,A_k$ 两两互斥,则

$$P(A_1\cup A_2\cup\cdots\cup A_k)=P(A_1)+P(A_2)+\cdots+P(A_k)$$

当试验的结果不具备等可能性时,那就既不能按古典概型也无法用几何概型来计算事件的概率了.为了解决面临的这类问题,人们从另一角度来刻画事件的概率.这就引出了下面的定义.

1.2.2 概率的统计定义

设有随机试验 E,在相同的条件下,重复进行了 n 次试验.在这 n 次试验中,事件 A 发生的次数 n_A 称为 A 发生的**频数**,比值 $\frac{n_A}{n}$ 称为 A 发生的**频率**,记为 $f_n(A)$,即 $f_n(A)=\frac{n_A}{n}$.易知事件发生的频率有以下基本性质:

(1) $f_n(A)\geqslant 0$;

(2) $f_n(\Omega)=1$;

(3) 若事件 $A_1,A_2,\cdots,A_k$ 两两互斥,则

$$f_n(A_1\cup A_2\cup\cdots\cup A_k)=f_n(A_1)+f_n(A_2)+\cdots+f_n(A_k)$$

由于频率 $f_n(A)$ 刻画了事件 A 发生的频繁程度,因而,$f_n(A)$ 越大,A 发生越频繁,这就意味着 A 在一次试验中发生的可能性也越大.这似乎提示我们可用频率来表示事件 A 在一次试验中发生的可能性的大小.是否可以这样做呢?让我们先来考察下面的例子.

例 1.6 抛掷一枚均匀硬币,以 A 表示事件{出现正面朝上},记录事件 A 发生的频数及频率,得数据如表 1.1 所示.

模拟试验:抛掷硬币分组试验

表 1.1 n 不同时 A 发生的频数和频率

试验序号	$n=5$		$n=50$		$n=500$	
	n_A	$f_n(A)$	n_A	$f_n(A)$	n_A	$f_n(A)$
1	2	0.4	22	0.44	251	0.502
2	3	0.6	25	0.50	249	0.498
3	1	0.2	21	0.42	256	0.512
4	5	1.0	25	0.50	253	0.506
5	1	0.2	24	0.48	251	0.502
6	2	0.4	21	0.42	246	0.492
7	4	0.8	18	0.36	244	0.488
8	2	0.4	24	0.48	258	0.516
9	3	0.6	27	0.54	262	0.524
10	3	0.6	31	0.62	247	0.494

从表 1.1 可以看出，当试验次数较少时，出现正面朝上的频率波动比较大，但是当试验次数增多时，正面朝上发生的频率明显地在 0.5 这个数附近波动.历史上也曾有人做过类似的试验，所得数据见表 1.2.

表 1.2 历史上不同试验者关于 A 发生的频数和频率的若干数据

试验者	n	n_A	$f_n(A)$
德摩根	2 048	1 061	0.518 1
蒲　丰	4 040	2 048	0.506 9
K.皮尔逊	12 000	6 019	0.501 6
K.皮尔逊	24 000	12 012	0.500 5

拓展阅读：蒲丰投针问题

从表 1.2 可以看出，不管什么人抛掷一枚均匀硬币，当试验次数逐渐增多时，频率 $f_n(A)$ 总是在 $0.5=\frac{1}{2}$ 附近波动，并呈现出稳定于 0.5 的倾向.频率的这种“稳定性”就是通常所说的统计规律性，它揭示了隐藏在随机现象中的必然规律性，我们用频率的稳定值来刻画事件 A 发生的可能性大小是合适的.

定义 1.2 设有随机试验 E，若当试验的重复次数 n 充分大时，事件 A 发生的频率 $f_n(A)$ 稳定地在某数 p 附近波动，则称数 p 为事件 A 的**概率**，记为

$$P(A)=p \tag{1.2.3}$$

首先，上述概率的统计定义不要求随机试验必须具备“有限性”及“等可能性”，因而它的适用范围更广.其次，它提供了估算概率的方法，即在试验的重复次数很大时，可以用事件 A 发生的频率 $f_n(A)$ 近似代替事件 A 的概率 $P(A)$.最后，它提供了一种检验理论或假说正确与否的准则.具体来说，如果我们依据某种理论或假说定出某事件 A 的概率为 p，但不知其是否与实际相符，为此，可做大量重复试验并算出 A 发生的频率 $f_n(A)$，若 $f_n(A)$ 与 p 相差很大，则认为该理论或假说可能不正确；若 $f_n(A)$ 与 p 很接近，则认为试验的结果支持了该理论或假说.我们将在第 8 章假设检验中专门讨论这一类问题.

由频率的三条基本性质可推测，作为频率稳定值的概率亦有相应的三条基本性质：

(1) $P(A)\geqslant 0$；

(2) $P(\Omega)=1$；

(3) 若事件 $A_1,A_2,\cdots,A_k$ 两两互斥，则

$$P(A_1\cup A_2\cup\cdots\cup A_k)=P(A_1)+P(A_2)+\cdots+P(A_k)$$

尽管概率的统计定义有上述种种优点，但它的不足之处也是显而易见的：首先，依定义 1.2 要确定某事件的概率，就必须进行大量重复试验，这在实际中往往难以办到.其次，即便有条件进行大量重复试验，也无法按定义 1.2 确切地指出何数为频率的稳定值.拿例 1.6 来说，如果不是基于对均匀硬币的直观认识，我们如何能认定频率是稳定于 0.5 而不是 0.502 或别的什么数呢？

概率的古典定义和统计定义存在着这样或那样的不足，这些不足不仅妨碍了概

率论自身的发展，也使人们对作为数学分支的概率论的科学性产生了怀疑.1933 年苏联数学家科尔莫戈罗夫首先提出了概率的公理化定义，从此，概率论有了坚实的理论基础并得到迅速发展.限于本教材的篇幅，在此，我们只能简单介绍概率公理化定义的一部分内容.

1.2.3 概率的公理化定义

由于并不是在 Ω 的所有子集上都能方便地定义概率，因而仅限于在满足一定条件下的集类上来研究概率及其性质，为此引进如下的事件域概念：

定义 1.3 设 $\mathscr{F}$ 是以样本空间 Ω 的一些子集为元素的集合（谓之**集类**），若它满足条件

（1）$\Omega \in \mathscr{F}$；

（2）若 $A, B \in \mathscr{F}$，则 $A-B \in \mathscr{F}$；

（3）若 $A_n \in \mathscr{F}$ $(n=1,2,\cdots)$，则 $\bigcup\limits_{n=1}^{\infty} A_n \in \mathscr{F}$，

则称 $\mathscr{F}$ 为**事件域**，称 $\mathscr{F}$ 中的元素为**事件**.

事件域 $\mathscr{F}$ 对集合间常见的那些运算如交、并、差运算是封闭的.不难验证下列集类都是事件域：$\mathscr{F}_1=\{\Omega,\varnothing\}$；$\mathscr{F}_2=\{\Omega, A, \bar{A}, \varnothing\}$，其中 $A \subset \Omega$；$\mathscr{F}_3=\{\Omega \text{ 的所有子集}\}$.

定义 1.4 设 Ω 为样本空间，$\mathscr{F}$ 为 Ω 上的事件域，$P(\cdot)$ 是一个定义在 $\mathscr{F}$ 上的集合函数，若它满足下列条件：

（1）非负性 $P(A) \geqslant 0, \forall A \in \mathscr{F}$；

（2）规范性 $P(\Omega)=1$；

（3）可列可加性 设 $A_i \in \mathscr{F}$ $(i=1,2,\cdots)$，且 $A_iA_j=\varnothing$，$\forall i \neq j$，有

$$P(A_1 \cup A_2 \cup \cdots) = P(A_1)+P(A_2)+\cdots \tag{1.2.4}$$

则称 $P(\cdot)$ 为 $\mathscr{F}$ 上的**概率测度**，对 $A \in \mathscr{F}$，称 $P(A)$ 为事件 A 的**概率**.

(1.2.4)式通常称为概率的**加法公理**.

以投掷骰子试验为例，其样本空间 $\Omega=\{1,2,3,4,5,6\}$，其中样本点 i 代表“掷出 i 点”，它表示投掷骰子试验的 6 个基本结果.取 $\mathscr{F}=\{\{1\},\cdots,\{6\},\{1,2\},\cdots,\{5,6\},\{1,2,3\},\cdots,\{4,5,6\},\cdots,\{1,2,3,4,5,6\},\varnothing\}$，$\mathscr{F}$ 中包括了 Ω 的所有子集，故 $\mathscr{F}$ 总共有 $C_6^0+C_6^1+\cdots+C_6^6=2^6=64$ 个事件，可根据骰子的具体情况给出概率 $P(\cdot)$，若骰子是均匀的正六面体，则定义 $P(\cdot)$ 为

$$P(A)=\frac{A \text{ 中所含样本点的个数}}{6}$$

其中，$A \in \mathscr{F}$.

于是，令 $A_i=\{\text{掷出的点数为 } i\}$，$i=1,2,\cdots,6$，若令 $A=\{\text{掷出的点数为奇数}\}$，则 $A=\{1,3,5\}$.由上述定义，$P(A_i)=\dfrac{1}{6}(i=1,2,3,4,5,6)$，而 $P(A)=\dfrac{3}{6}=\dfrac{1}{2}$.

若骰子不均匀，则 A_i 发生的可能性 $p_i=P(A_i)$ 各不相同，此时，先确定出 p_1，$p_2,\cdots,p_6$，再对每个事件 A，把其中所含样本点相对应的概率值加起来作为 $P(A)$.比如，若 $A=\{1,3,5\}$，则规定 $P(A)=p_1+p_3+p_5$.

1.2.4 概率的性质

概率有三条基本性质：

(1) 对任何事件 A，$P(A)\geqslant 0$；

(2) 对必然事件 Ω，$P(\Omega)=1$；

(3) 对于两两互斥的事件 $A_1,A_2,\cdots$，有

$$P(A_1\cup A_2\cup\cdots)=P(A_1)+P(A_2)+\cdots$$

由这三条基本性质出发，可推出概率有下述重要性质：

性质 1 $P(\varnothing)=0$. (1.2.5)

证 因为 $\Omega=\Omega\cup\varnothing\cup\varnothing\cup\cdots$，而 $\Omega,\varnothing,\varnothing,\cdots$ 是两两互斥的事件，由概率的基本性质(3)得

$$P(\Omega)=P(\Omega)+P(\varnothing)+P(\varnothing)+\cdots$$

由上式及基本性质(1)和(2)知 $P(\varnothing)=0$.

性质 2(概率的加法定理) 若 $A_1,A_2,\cdots,A_n$ 是两两互斥的事件，则

$$P(A_1\cup A_2\cup\cdots\cup A_n)=P(A_1)+P(A_2)+\cdots+P(A_n) \tag{1.2.6}$$

证 因为 $A_1\cup A_2\cup\cdots\cup A_n=A_1\cup A_2\cup\cdots\cup A_n\cup\varnothing\cup\cdots$，由概率的基本性质(3)及 $P(\varnothing)=0$ 知

$$\begin{aligned}P(A_1\cup A_2\cup\cdots\cup A_n)&=P(A_1)+P(A_2)+\cdots+P(A_n)+P(\varnothing)+\cdots\\&=P(A_1)+P(A_2)+\cdots+P(A_n)\end{aligned}$$

性质 3 设 A,B 是两个事件，若 $A\subset B$，则有

$$P(B-A)=P(B)-P(A) \tag{1.2.7}$$

$$P(B)\geqslant P(A) \tag{1.2.8}$$

证 由 $A\subset B$ 知 $B=A\cup(B-A)$，因为 $A(B-A)=\varnothing$，故由性质 2，得

$$P(B)=P(A)+P(B-A)$$

从而(1.2.7)式得证，再由概率的非负性知 $P(B-A)\geqslant 0$，故

$$P(B)\geqslant(A)$$

性质 4 对任一事件 A，有

$$P(\overline{A})=1-P(A) \tag{1.2.9}$$

证 因 $A\cup\overline{A}=\Omega$，$A\overline{A}=\varnothing$，由概率的加法定理知

$$1=P(\Omega)=P(A\cup\overline{A})=P(A)+P(\overline{A})$$

所以

$$P(\overline{A})=1-P(A)$$

性质 5 对任意两个事件 A,B，有

$$P(A\cup B)=P(A)+P(B)-P(AB) \tag{1.2.10}$$

证 因 $A\cup B=A\cup(B-AB)$，$A(B-AB)=\varnothing$ 及 $AB\subset B$，故由(1.2.6)及(1.2.7)式得

$$P(A\cup B)=P(A)+P(B-AB)=P(A)+P(B)-P(AB)$$

(1.2.10)式可以推广到多个事件的场合.设 $A_1,A_2,\cdots,A_n$ 是任意 n 个事件，则有

$$P(A_1\cup A_2\cup\cdots\cup A_n)=\sum_{i=1}^{n}P(A_i)-\sum_{1\leqslant i<j\leqslant n}P(A_iA_j)+\sum_{1\leqslant i<j<k\leqslant n}P(A_iA_jA_k)+\cdots+(-1)^{n+1}P(A_1A_2\cdots A_n)\quad(1.2.11)$$

(1.2.11)式可以用数学归纳法证明.

性质6 设$\{A_n,n=1,2,\cdots\}$为事件列,若$A_n\subset A_{n+1},n=1,2,\cdots$,令$A=\bigcup_{i=1}^{\infty}A_i$,则

$$P(A)=\lim_{n\to\infty}P(A_n)$$

证 令$B_1=A_1,B_n=A_n\left(\bigcup_{i=1}^{n-1}A_i\right)=A_n\overline{A}_{n-1}(n=2,3,\cdots)$.对于引入的事件列$\{B_n,n=1,2,\cdots\}$,显然,$B_iB_j=\varnothing(i\neq j,i,j=1,2,\cdots)$,并且$\bigcup_{i=1}^{\infty}A_i=\bigcup_{i=1}^{\infty}B_i$,故

$$\begin{aligned}P(A)&=P\left(\bigcup_{i=1}^{\infty}B_i\right)\\&=\sum_{i=1}^{\infty}P(B_i)\quad(\text{利用概率的可列可加性})\\&=\lim_{n\to\infty}\sum_{i=1}^{n}P(B_i)\\&=\lim_{n\to\infty}\sum_{i=1}^{n}[P(A_i)-P(A_{i-1})]\quad(\text{这里约定 }A_0=\varnothing)\\&=\lim_{n\to\infty}P(A_n)\end{aligned}$$

推论 设$\{A_n,n=1,2,\cdots\}$为事件列,若$A_n\supset A_{n+1},n=1,2,\cdots$,令$A=\bigcap_{i=1}^{\infty}A_i$,则

$$P(A)=\lim_{n\to\infty}P(A_n)$$

推论的证明留给读者.性质6及其推论统称为**概率的连续性**.

例1.7 从n双不同的手套中任取$2k(2k<n)$只,求下列事件的概率:

$$A=\{\text{恰有两只手套配成一双}\}$$

$$B=\{\text{至少有两只手套配成一双}\}$$

解 从n双手套中取$2k$只,不同的取法总数为C_{2n}^{2k}.有利于事件A的取法可分三步完成:第一步,从n双手套中取出一双作为配对的那两只手套,有C_n^1种取法;第二步,从剩下的$n-1$双手套中取出$2k-2$双手套,有C_{n-1}^{2k-2}种取法;第三步,从这不同的$2(k-1)$双手套中各选一只手套,因可取左或右,故有$2^{2(k-1)}$种取法,因此,有利于事件A的取法数为$C_n^1C_{n-1}^{2k-2}2^{2(k-1)}$,故事件$A$的概率为

$$P(A)=\frac{C_n^1C_{n-1}^{2k-2}2^{2(k-1)}}{C_{2n}^{2k}}$$

因为有利于事件$\overline{B}$的取法数为$C_n^{2k}2^{2k}$,所以事件B的概率为

$$P(B)=1-P(\overline{B})=1-\frac{C_n^{2k}2^{2k}}{C_{2n}^{2k}}$$

例1.8 在整数$1,2,\cdots,1\,000$中随机地取一个数,问取到的整数能被4整除或

者能被 6 整除的概率是多少?

解 设 $A=\{$取到的数能被 4 整除$\}$,$B=\{$取到的数能被 6 整除$\}$,则所求的概率为

$$P(A\cup B)=P(A)+P(B)-P(AB)$$

现在不同的取法总数为 $C_{1\,000}^{1}=1\,000$,有利于事件 A 的取法有 $\left[\frac{1\,000}{4}\right]=250$ 种(其中 $[a]$ 表示不超过 a 的最大整数),有利于事件 B 的取法有 $\left[\frac{1\,000}{6}\right]=166$ 种.又因为一个数能同时被 4 与 6 整除,就相当于它能被 4 与 6 的最小公倍数 12 整除,所以有利于事件 AB 的取法有 $\left[\frac{1\,000}{12}\right]=83$,故

$$P(A)=\frac{250}{1\,000},\quad P(B)=\frac{166}{1\,000},\quad P(AB)=\frac{83}{1\,000}$$

于是所求概率为

$$P(A\cup B)=\frac{250+166-83}{1\,000}=0.333$$

本例表明对于复杂的随机事件,可以通过转化为相对简单的随机事件,用概率的性质计算原概率.

1.3 条件概率 事件的相互独立性

1.3.1 条件概率与乘法公式

在实际问题中,除了要知道事件 A 的概率 $P(A)$ 外,有时还要知道"在事件 B 已经发生的条件下,事件 A 的概率",这个概率我们记为 $P(A\mid B)$.因为附加了新的条件"事件 B 已经发生",所以 $P(A\mid B)$ 一般说来与 $P(A)$ 是不同的,称 $P(A\mid B)$ 为条件概率.

例如,一盒内装有 10 个乒乓球,分别编有 1,2,…,10 号,现从盒中随机地取一个乒乓球,考虑以下事件:

$$A=\{\text{取到一个编号超过 5 的乒乓球}\}$$

$$B=\{\text{取到一个偶数号码的球}\}$$

不难算出 A 的概率为 $P(A)=\frac{5}{10}=\frac{1}{2}$.如果附加上"已知事件 B 发生",那么可能情况有五种:2,4,6,8,10,其中三种结果有利于事件 A 发生,因而在这个条件下,A 的条件概率 $P(A\mid B)=\frac{3}{5}$.另外,$P(B)=\frac{5}{10}=\frac{1}{2}$,$P(AB)=\frac{3}{10}$,$P(A\mid B)=\frac{3}{5}=\frac{\frac{3}{10}}{\frac{5}{10}}$,故有

$$P(A\mid B)=\frac{P(AB)}{P(B)}$$

由此引入条件概率的一般定义:

定义 1.5 设 A,B 为两个事件,$P(B)\neq 0$,称

$$P(A\mid B)=\frac{P(AB)}{P(B)} \tag{1.3.1}$$

为在事件 B 发生的条件下事件 A 发生的**条件概率**.

可以验证,条件概率 $P(\cdot\mid B)$ 满足概率的公理化定义,也是一种概率.可以将 $P(\cdot\mid B)$ 看成是在新的样本空间 B 下的概率定义.习题1的第26题说明条件概率 $P(\cdot\mid B)$ 满足概率的其他性质.

例 1.9 某商店供应的一种产品中,有甲厂生产的产品80件,其中有4件次品,有乙厂生产的产品40件,其中有6件次品.现从该商店供应的产品中随机地取一件,已知取出一件次品,求该产品是甲厂生产的概率.

解 令 $A=\{$取到甲厂的产品$\}$,$B=\{$取到一件次品$\}$.

方法1 先求 $P(B)$ 及 $P(AB)$.因

$$P(B)=\frac{4+6}{80+40}=\frac{1}{12},\quad P(AB)=\frac{4}{80+40}=\frac{1}{30}$$

故

$$P(A\mid B)=\frac{P(AB)}{P(B)}=\frac{\frac{1}{30}}{\frac{1}{12}}=0.4$$

方法2 若已知取出的产品为次品,则只有10种可能的结果,其中有4件次品是甲厂生产的,由等可能性可直接得到 $\frac{4}{10}$,即

$$P(A\mid B)=\frac{4}{10}=0.4$$

由条件概率的定义,即可得到下述定理:

定理 1.1(乘法公式) 若 $P(B)>0$,则

$$P(AB)=P(B)P(A\mid B) \tag{1.3.2}$$

乘法公式可以推广到 $n(n>2)$ 个事件的情形.

(1) 若 $P(AB)>0$,则

$$P(ABC)=P(A)P(B\mid A)P(C\mid AB) \tag{1.3.3}$$

(2) 对任意 n 个事件 $A_1,A_2,\cdots,A_n$,若 $P(A_1A_2\cdots A_{n-1})>0$,则

$$P(A_1A_2\cdots A_n)=P(A_1)P(A_2\mid A_1)P(A_3\mid A_1A_2)\cdots P(A_n\mid A_1A_2\cdots A_{n-1}) \tag{1.3.4}$$

例 1.10(抽签问题) n 个人以抽签方式决定谁将得到一张奥运会开幕式的入场券,n 个人依次抽签,求第 $k(1\leqslant k\leqslant n)$ 个人抽中的概率.

解 令 $A_k=\{$第 k 个人抽到入场券$\}$,$\overline{A}_k=\{$第 k 个人没有抽中$\}$,$1\leqslant k\leqslant n$.显然,$P(A_1)=\frac{1}{n}$.对于 $1<k\leqslant n$,因 $A_k\subset\overline{A}_1\overline{A}_2\cdots\overline{A}_{k-1}$,故 $A_k=\overline{A}_1\overline{A}_2\cdots\overline{A}_{k-1}A_k$.由乘法公式,得

$$\begin{aligned}P(A_k)&=P(\overline{A}_1\overline{A}_2\cdots\overline{A}_{k-1}A_k)\\&=P(\overline{A}_1)P(\overline{A}_2\mid\overline{A}_1)P(\overline{A}_3\mid\overline{A}_1\overline{A}_2)\cdots P(A_k\mid\overline{A}_1\overline{A}_2\cdots\overline{A}_{k-1})\\&=\frac{n-1}{n}\,\frac{n-2}{n-1}\,\frac{n-3}{n-2}\cdots\frac{1}{n-(k-1)}\\&=\frac{1}{n}\end{aligned}$$

亦即

$$P(A_k)=\frac{1}{n}(1\leqslant k\leqslant n)$$

本例的计算结果告诉我们：在排队依次抽签时，因中签的可能性与排位先后是没有关系的，故不必争先恐后.

1.3.2 全概率公式与贝叶斯公式

定义 1.6 设 $B_1,B_2,\cdots,B_n,\cdots$ 为可数个事件，若它们满足

(1) $B_iB_j=\varnothing(i\neq j,i,j=1,2,\cdots)$；

(2) $B_1\cup B_2\cup\cdots\cup B_n\cup\cdots=\Omega$,

则称这组事件为**互斥完备事件群**(或**互不相容完备事件组**).

注：定义 1.6 和定理 1.2 对于有限个事件 $B_1,B_2,\cdots,B_n$ 的情形亦成立.

现在考虑任一事件 A，因

$$A=A\Omega=AB_1\cup AB_2\cup\cdots\cup AB_n\cup\cdots$$

由 $B_1,B_2,\cdots,B_n,\cdots$ 两两互斥可知，$AB_1,AB_2,\cdots,AB_n,\cdots$ 亦两两互斥，再设 $P(B_i)>0$ $(i=1,2,\cdots)$，结合概率的加法公理与乘法公式，故得

$$\begin{aligned}P(A)&=P(AB_1)+P(AB_2)+\cdots+P(AB_n)+\cdots\\&=P(B_1)P(A\mid B_1)+P(B_2)P(A\mid B_2)+\cdots+P(B_n)P(A\mid B_n)+\cdots\\&=\sum_j P(B_j)P(A\mid B_j)\end{aligned}$$

这就是下面的全概率公式.

定理 1.2(全概率公式) 若事件 $B_1,B_2,\cdots,B_n,\cdots$ 构成互斥完备事件群，且 $P(B_i)>0(i=1,2,\cdots)$，则对任一事件 A，有

$$P(A)=\sum_j P(B_j)P(A\mid B_j)\tag{1.3.5}$$

由(1.3.5)式的推导过程可以看出：事件 A 的“全部”概率 $P(A)$ 被分解成许多“部分”概率 $P(AB_j)$ 之和的形式.因此，当概率 $P(B_j)$ 与 $P(A\mid B_j)$ 容易确定时，通过全概率公式可以求得复杂事件 A 的概率 $P(A)$.

运用全概率公式的关键在于恰当地找出互斥完备事件群 $B_1,B_2,\cdots,B_n,\cdots$.

例 1.11 一商店出售的某类小家电产品来自甲、乙、丙三家工厂，这三家工厂的产品比例为 1∶2∶1，且它们的产品合格率分别为 90%，85%，80%.现从该类小家电产品中随机抽取一件，问恰取到一件合格品的概率是多少?

解 令 $B_1=\{$取到一件甲厂的产品$\}$，$B_2=\{$取到一件乙厂的产品$\}$，$B_3=\{$取到一件丙厂的产品$\}$.显然，B_1,B_2,B_3 构成互斥完备事件群，又设 $A=\{$取出的产品是合格品$\}$.

由题意知 $P(B_1):P(B_2):P(B_3)=1:2:1$，故 $P(B_1)=P(B_3)=\frac{1}{4}$，$P(B_2)=\frac{1}{2}$，而 $P(A\mid B_1)=0.90$，$P(A\mid B_2)=0.85$，$P(A\mid B_3)=0.80$，因此由全概率公式可得

$$\begin{aligned}P(A)&=P(B_1)P(A\mid B_1)+P(B_2)P(A\mid B_2)+P(B_3)P(A\mid B_3)\\&=\frac{1}{4}\times0.90+\frac{1}{2}\times0.85+\frac{1}{4}\times0.80\\&=0.85\end{aligned}$$

本例的结果直观上容易理解,三家工厂的产品汇总在一起,则总的产品合格率应是各厂产品合格率的加权平均,其权与各厂产量成比例.

例 1.12 在数字通信中,信号是由数字 0 和 1 的序列所组成的.设发报台分别以概率 0.7 和 0.3 发出信号 0 和 1.由于通信系统受到随机干扰,当发出信号为 0 时,收报台未必收到信号 0,而分别以概率 0.8 与 0.2 收到信号 0 和 1;同样地,当发出信号 1 时,收报台分别以概率 0.9 和 0.1 收到信号 1 和 0.求:

(1) 收报台收到信号 1 的概率;

(2) 当收报台收到信号 1 时,发报台发出信号 1 的概率.

解 记 $A=\{$收到信号 1$\}$,$B=\{$发出信号 1$\}$.

由题意知,$P(B)=0.3$,$P(\overline{B})=0.7$,$P(A\mid B)=0.9$,$P(A\mid \overline{B})=0.2$,且 B 与 $\overline{B}$ 构成互斥完备事件群.

(1) 由全概率公式,得

$$\begin{aligned}P(A)&=P(B)P(A\mid B)+P(\overline{B})P(A\mid \overline{B})\\&=0.3\times 0.9+0.7\times 0.2=0.41\end{aligned}$$

(2) 由条件概率,得

$$\begin{aligned}P(B\mid A)&=\frac{P(AB)}{P(A)}=\frac{P(B)P(A\mid B)}{P(B)P(A\mid B)+P(\overline{B})P(A\mid \overline{B})}\\&=\frac{0.3\times 0.9}{0.41}\approx 0.66\end{aligned}$$

在例 1.12 的(2)中,用到了公式

$$P(B\mid A)=\frac{P(B)P(A\mid B)}{P(B)P(A\mid B)+P(\overline{B})P(A\mid \overline{B})} \tag{1.3.6}$$

一般地,有以下公式.

定理 1.3(贝叶斯公式) 若事件 $B_1,B_2,\cdots,B_n,\cdots$ 构成互斥完备事件群,且 $P(B_i)>0(i=1,2,\cdots)$,则对任一事件 $A(P(A)>0)$,有

$$P(B_i\mid A)=\frac{P(B_i)P(A\mid B_i)}{\sum\limits_j P(B_j)P(A\mid B_j)}\quad (i=1,2,\cdots) \tag{1.3.7}$$

拓展阅读:全概率公式和贝叶斯公式的应用:三门问题

证 由条件概率和全概率公式,有

$$\begin{aligned}P(B_i\mid A)&=\frac{P(B_iA)}{P(A)}=\frac{P(B_i)P(A\mid B_i)}{P(A)}\\&=\frac{P(B_i)P(A\mid B_i)}{\sum\limits_j P(B_j)P(A\mid B_j)}\quad (i=1,2,\cdots)\end{aligned}$$

若把事件 A 看成“结果”,把两两互斥事件 $B_1,B_2,\cdots$ 看成导致这一结果的可能的“原因”,则可以形象地把贝叶斯公式看作“由结果推测原因”:现在“结果”A 已经发生,在众多可能的“原因”中,究竟哪一个导致这一结果的可能性大?利用贝叶斯公式可以算出由某一个“原因”$B_i(i=1,2,\cdots)$ 所引起的可能性大小($P(B_i\mid A)$),如果能找到某个 B_k,使得

$$P(B_k \mid A)=\max\{P(B_1 \mid A),P(B_2 \mid A),\cdots\}$$

那么 B_k 就是导致“结果”A 的最大可能的“原因”.

例 1.13 某个地区患有一种疾病的人占 0.05%,患者对某种检测结果呈阳性的概率为 0.99,正常人对这种检测结果呈阳性的概率是 0.005,现有一个人,检测结果是阳性,问此人患有此疾病的概率是多少?

解 记 $A=\{$患有此疾病$\}$,$B=\{$检测结果呈阳性$\}$,则 $\overline{A}=\{$没有患此疾病$\}$,且 $P(A)=0.000\,5$,$P(\overline{A})=0.999\,5$,$P(B \mid A)=0.99$,$P(B \mid \overline{A})=0.005$. 由贝叶斯公式,有

$$P(A \mid B)=\frac{P(A)P(B \mid A)}{P(A)P(B \mid A)+P(\overline{A})P(B \mid \overline{A})}=\frac{0.000\,5\times 0.99}{0.000\,5\times 0.99+0.999\,5\times 0.005}\approx 0.09$$

虽然检验法可靠,但是检测结果呈阳性的人真正患有此疾病的概率并不大,只有 0.09,那么这种检测有意义吗? 我们说有. 在没有做检测的时候,这个人患有此病的概率是 0.000 5,如果做了检测,结果呈阳性,那么此人患有此疾病的概率增加到 0.09,是原来的 180 倍. 但是,即使检测结果呈阳性,也不能过早下结论说此人患有此疾病,因为这种可能性只有 0.09.

思考:读者可以用贝叶斯公式计算,如果一个人的检测结果呈阴性,则他患有此疾病的概率是多少? 并解释计算结果.

在贝叶斯公式中,通常称 $P(B_1)$,$P(B_2)$,$\cdots$ 为**先验概率**,而称 $P(B_1 \mid A)$,$P(B_2 \mid A)$,$\cdots$ 为**后验概率**. 因而,贝叶斯公式实际上是计算后验概率的公式,这是对贝叶斯公式另一层面上的解释.

拓展阅读:贝叶斯公式的启示

在实践中,先验概率代表人们依据以往经验和知识对某一随机现象的一种认识. 随着时间的推移,人们获取的信息越来越丰富,理论知识也越来越完善,对该随机现象的认识也可能发生一些变化,而后验概率就代表了人们对以往认识的一种修正(即新的认识). 因而在实践中,当获得后验概率之后,人们往往用后验概率取代先验概率,以便作为今后工作的出发点.

拓展阅读:从贝叶斯公式到贝叶斯学派

1.3.3 事件的相互独立性

设 A,B 为两个事件,一般而言 $P(A)\neq P(A \mid B)$,这表示事件 B 发生对事件 A 发生的概率有影响,只有当 $P(A)=P(A \mid B)$ 时才可以认为 B 发生与否对 A 发生的概率毫无影响,这时在概率论中就称 A,B 两事件是独立的. 由条件概率的定义

$$P(A \mid B)=\frac{P(AB)}{P(B)}$$

可知,当 $P(B)\neq 0$ 时,

$$P(A)=P(A \mid B) \text{ 等价于 } P(AB)=P(A)P(B)$$

由此就引出了下面的定义.

定义 1.7 若两事件 A,B 满足

$$P(AB)=P(A)P(B) \tag{1.3.8}$$

则称 A,B **相互独立**,简称 A,B 独立.

关于定义 1.7,有两点需要注意:(1) 概率为零的事件与任意事件相互独立;(2) 当 $P(A)P(B)\neq 0$ 时,

$$P(A)=P(A\mid B)\Leftrightarrow P(B)=P(B\mid A)\Leftrightarrow P(AB)=P(A)P(B)$$

定理 1.4 若四对事件$\{A,B\}$,$\{A,\overline{B}\}$,$\{\overline{A},B\}$,$\{\overline{A},\overline{B}\}$中有一对是相互独立的,则另外三对也是相互独立的.

证 这里仅证明"当A,B相互独立时,$\overline{A},\overline{B}$也相互独立",其余请读者自行证明.

因为A,B独立,所以$P(AB)=P(A)P(B)$,故

$$\begin{aligned}P(\overline{A}\,\overline{B})&=P(\overline{A\cup B})=1-P(A\cup B)\\&=1-[P(A)+P(B)-P(AB)]\\&=1-P(A)-P(B)+P(A)P(B)\\&=[1-P(A)][1-P(B)]\\&=P(\overline{A})P(\overline{B})\end{aligned}$$

即,$\overline{A},\overline{B}$也相互独立.

在实际问题中,并不是用(1.3.8)式来判断两事件A,B是否独立,而是从试验的具体条件以及事件的本质去判断它们不应有关联,从而是独立的,然后就可以用(1.3.8)式来计算积事件的概率了.

例 1.14 袋中有5个白球、3个红球.从中每次任取1个,有放回地连续取两次,求两次取出的球中至少有1个白球的概率.

解 令$A_i=\{$第i次取得白球$\}$$(i=1,2)$.在有放回的取球方式下,$A_1$发生与否并不影响$A_2$发生的概率,因为袋中球的总个数以及白球、红球的比例在两次取球试验中均保持一致,所以A_1,A_2相互独立,于是所求概率为

$$p=P(A_1\cup A_2)=P(A_1)+P(A_2)-P(A_1A_2)$$

因为$P(A_1)=\dfrac{5}{8}$,$P(A_2)=\dfrac{5}{8}$,由独立性,$P(A_1A_2)=P(A_1)P(A_2)$,所以

$$p=\frac{5}{8}+\frac{5}{8}-\frac{5}{8}\times\frac{5}{8}=\frac{55}{64}$$

或者,由A_1,A_2独立,知$\overline{A}_1,\overline{A}_2$独立,故

$$P(\overline{A}_1\overline{A}_2)=P(\overline{A}_1)P(\overline{A}_2)=\frac{3}{8}\times\frac{3}{8}$$

因而

$$\begin{aligned}p&=P(A_1\cup A_2)=1-P(\overline{A_1\cup A_2})=1-P(\overline{A}_1\overline{A}_2)\\&=1-\left(\frac{3}{8}\right)^2=\frac{55}{64}\end{aligned}$$

知识点讲解视频:多个事件独立性的定义

事件的独立性概念可推广到多个事件的情形:

定义 1.8 设$A_1,A_2,\cdots,A_n$是n个事件,若对任意$k(1<k\leqslant n)$,任意$1\leqslant i_1<i_2<\cdots<i_k\leqslant n$,

$$P(A_{i_1}A_{i_2}\cdots A_{i_k})=P(A_{i_1})P(A_{i_2})\cdots P(A_{i_k}) \tag{1.3.9}$$

都成立,则称事件$A_1,A_2,\cdots,A_n$相互独立.

(1.3.9)式中包含的等式总数为

$$C_n^2+C_n^3+\cdots+C_n^n=\sum_{k=0}^{n}C_n^k-C_n^1-C_n^0=2^n-n-1$$

由定义 1.8 可以看出，如果 $A_1,A_2,\cdots,A_n$ 相互独立，那么其中的任意 $k(1<k\leqslant n)$ 个事件也相互独立.特别，当 $k=2$ 时，它们之中任意两个事件都独立(称为 $A_1,A_2,\cdots,A_n$ 两两独立).但是，$A_1,A_2,\cdots,A_n$ 两两独立并不能保证 $A_1,A_2,\cdots,A_n$ 相互独立，下面的例子说明了这一点.

例 1.15 一袋装有四张形状相同的卡片，在这四张卡片上分别标有数字 110，101，011，000.从袋中任取一张卡片，以 A_i 表示事件{取到的卡片第 i 位上的数字为 1}$(i=1,2,3)$.求证：A_1,A_2,A_3 是两两独立的，但 A_1,A_2,A_3 不是相互独立事件.

证 易得

$$P(A_1)=P(A_2)=P(A_3)=\frac{2}{4}=\frac{1}{2}$$

$$P(A_1A_2)=P(A_2A_3)=P(A_3A_1)=\frac{1}{4}$$

$$P(A_1A_2A_3)=0$$

从而

$$P(A_1A_2)=P(A_1)P(A_2),\quad P(A_2A_3)=P(A_2)P(A_3),P(A_3A_1)=P(A_3)P(A_1)$$

但是

$$P(A_1A_2A_3)=0\neq\frac{1}{8}=P(A_1)P(A_2)P(A_3)$$

由此可见 A_1,A_2,A_3 是两两独立的，但它们不是相互独立的.

对于 n 个相互独立的事件，有类似定理 1.4 的结论.

定理 1.5 设 n 个事件 $A_1,A_2,\cdots,A_n$ 相互独立，则把其中任意 $m(1\leqslant m\leqslant n)$ 个事件相应地换成它们的对立事件，所得的 n 个事件仍相互独立.

例如，A_1,A_2,A_3 相互独立，则 $\overline{A}_1,A_2,A_3$ 或 $\overline{A}_1,A_2,\overline{A}_3$ 或 $\overline{A}_1,\overline{A}_2,\overline{A}_3$ 等都是相互独立的三个事件.定理 1.5 的证明可用数学归纳法来完成(对所含对立事件个数进行归纳).

例 1.16 三人同时对一个游动目标进行射击，三人击中目标的概率分别为 0.4，0.5，0.7.现在他们各自独立地打一枪，求：

(1) 该目标至少中一弹的概率；

(2) 该目标恰好中一弹的概率.

解 令 $A_i=$ {第 i 人击中目标}$(i=1,2,3)$.由题意，可知 A_1,A_2,A_3 相互独立.

(1) 若令 $A=$ {该目标至少中一弹}，则 $A=A_1\cup A_2\cup A_3$.于是

$$\begin{aligned}P(A)&=P(A_1\cup A_2\cup A_3)=1-P(\overline{A}_1\overline{A}_2\overline{A}_3)\\&=1-P(\overline{A}_1)P(\overline{A}_2)P(\overline{A}_3)\quad(\text{定理 1.5})\\&=1-0.6\times0.5\times0.3\\&=0.91\end{aligned}$$

(2) 令 $B=\{$该目标恰好中一弹$\}$,则 $B=A_1\bar{A}_2\bar{A}_3\cup\bar{A}_1A_2\bar{A}_3\cup\bar{A}_1\bar{A}_2A_3$.因为 $A_1\bar{A}_2\bar{A}_3$, $\bar{A}_1A_2\bar{A}_3$,$\bar{A}_1\bar{A}_2A_3$ 两两互斥,由概率的加法定理以及独立事件的概率乘法公式得

知识点讲解视频:随机事件互斥与相互独立的关系

$$\begin{aligned}P(B)&=P(A_1\bar{A}_2\bar{A}_3)+P(\bar{A}_1A_2\bar{A}_3)+P(\bar{A}_1\bar{A}_2A_3)\\&=P(A_1)P(\bar{A}_2)P(\bar{A}_3)+P(\bar{A}_1)P(A_2)P(\bar{A}_3)+P(\bar{A}_1)P(\bar{A}_2)P(A_3)\\&=0.4\times0.5\times0.3+0.6\times0.5\times0.3+0.6\times0.5\times0.7\\&=0.36\end{aligned}$$

应当注意,事件的相互独立与事件的互斥(互不相容)是两个不同的概念.

当事件 $A_1,A_2,\cdots,A_n$ 两两互斥时,有

$$\boxed{P(A_1\cup A_2\cup\cdots\cup A_n)=P(A_1)+P(A_2)+\cdots+P(A_n)}\qquad(1.3.10)$$

因而,事件的互斥可以简化和事件的概率计算.

而当事件 $A_1,A_2,\cdots,A_n$ 相互独立时,有

$$\boxed{P(A_1A_2\cdots A_n)=P(A_1)P(A_2)\cdots P(A_n)}\qquad(1.3.11)$$

因而,事件的相互独立可以简化积事件的概率计算.

内容小结

1. 几个基本概念

在一定条件下可能发生也可能不发生的现象称为随机现象.

若试验具备以下特征:(1) 可以在相同条件下重复进行;(2) 每次试验的可能结果不止一个,但事先能明确全部可能的结果;(3) 进行一次试验之前不能肯定哪一个结果会出现,则称这种试验为随机试验,简称试验,记为 E 或 $E_1,E_2,\cdots$.

随机试验 E 的所有可能试验结果组成的集合称为样本空间,记为 Ω,样本空间的元素称为样本点.

在随机试验中,其样本空间的子集称为随机事件,简称事件,记为 $A,B,\cdots$.在每次试验中,事件 A 发生当且仅当 A 中的一个样本点出现.

在每次试验中必然发生的事件称为必然事件,用 Ω 表示;在每次试验中都不发生的事件称为不可能事件,用 $\varnothing$ 表示.

2. 事件的关系与运算

若事件 A 发生必然导致 B 发生,则称 B 包含 A 或 A 含于 B,记作 $A\subset B$,或 $B\supset A$.特别地,若事件 A,B 相互包含,即 $A\subset B$ 且 $B\subset A$,则称 A 与 B 相等,记作 $A=B$.

称 $\{A,B$ 中至少有一个发生$\}$ 的事件为 A 与 B 的和事件,记作 $A\cup B$.

称 $\{A,B$ 都发生$\}$ 的事件为 A 与 B 的积事件,记作 $A\cap B$,简记作 AB.

若事件 A,B 不能同时发生,即 $AB=\varnothing$,则称 A 与 B 是互斥的或互不相容的.

若有事件 A,称 $\{A$ 不发生$\}$ 的事件为 A 的对立事件,记为 $\bar{A}$.A 和它的对立事件 $\bar{A}$ 满足 $A\bar{A}=\varnothing$,$A\cup\bar{A}=\Omega$,这两个等式也可以作为对立事件的定义.

称 $\{A$ 发生,B 不发生$\}$ 的事件为 A 与 B 的差事件,记为 $A-B$,且 $A-B=A\bar{B}$.

事件的运算满足以下定律：

(1) 交换律　$A\cup B=B\cup A, AB=BA$；

(2) 结合律　$(A\cup B)\cup C=A\cup(B\cup C), (AB)C=A(BC)$；

(3) 分配律　$(A\cup B)C=(AC)\cup(BC), (AB)\cup C=(A\cup C)(B\cup C)$；

(4) 对偶律(德摩根律)　$\overline{A\cup B}=\overline{A}\,\overline{B}, \overline{AB}=\overline{A}\cup\overline{B}$.

3. 概率的三种定义

(1) 古典定义

若试验满足

① 只有有限个试验结果；

② 每个试验结果在一次试验中发生的可能性相等，

则称在此试验下构建的概率模型为古典概型.

古典概型中的随机事件 A 的概率定义为

$$P(A)=\frac{A\text{ 所包含的试验结果的个数}}{\text{试验结果的总数}}$$

(2) 统计定义

将随机试验 E 在相同条件下重复进行了 n 次，事件 A 发生的次数 n_A 称为 A 发生的频数，而比值 $\frac{n_A}{n}$ 称为 A 发生的频率，记作 $f_n(A)$. 若当试验的次数 n 充分大时，事件 A 发生的频率 $f_n(A)$ 稳定地在某数 p 附近波动，则称数 p 为事件 A 发生的概率，记为 $P(A)=p$.

(3) 公理化定义

设 E 是随机试验，Ω 是它的样本空间，对由 Ω 中一些事件在满足一定条件下组成的事件域 $\mathscr{F}$ 中的每一事件 A，赋予一个实数 $P(A)$，若集合函数 $P(\cdot)$ 满足：

① 非负性　$P(A)\geqslant 0, \forall A\in\mathscr{F}$；

② 规范性　$P(\Omega)=1$；

③ 可列可加性　设 $A_i\in\mathscr{F}(i=1,2,\cdots)$，且 $A_iA_j=\varnothing, \forall i\neq j$，有 $P(A_1\cup A_2\cup\cdots)=P(A_1)+P(A_2)+\cdots$，

则称 $P(A)$ 为事件 A 的概率.

4. 概率的性质

(1) $P(\varnothing)=0$.

(2) 若 $A_1, A_2, \cdots, A_n$ 两两互斥，则

$$P(A_1\cup A_2\cup\cdots\cup A_n)=P(A_1)+P(A_2)+\cdots+P(A_n)$$

(3) 若 $A\subset B$，则 $P(B-A)=P(B)-P(A)$，且 $P(B)\geqslant P(A)$.

(4) $P(\overline{A})=1-P(A)$.

(5) $P(A\cup B)=P(A)+P(B)-P(AB)$.

(6) 设 $\{A_n, n=1,2,\cdots\}$ 为事件列，若 $A_n\subset A_{n+1}, n=1,2,\cdots$，令 $A=\bigcup\limits_{i=1}^{\infty}A_i$，则 $P(A)=\lim\limits_{n\to\infty}P(A_n)$.

5. 条件概率、事件的相互独立性

设 A,B 为两个事件，$P(B)\neq 0$，称 $\dfrac{P(AB)}{P(B)}$ 为在事件 B 发生的条件下事件 A 发生的条件概率，记作 $P(A\mid B)$.

乘法公式：设 $P(B)>0$，则 $P(AB)=P(B)P(A\mid B)$.

若 $P(AB)>0$，则 $P(ABC)=P(A)P(B\mid A)P(C\mid AB)$.

若事件 $B_1,B_2,\cdots,B_n,\cdots$ 满足

(1) $B_iB_j=\varnothing(i\neq j,i,j=1,2,\cdots)$；

(2) $B_1\cup B_2\cup\cdots\cup B_n\cup\cdots=\Omega$，

则称 $B_1,B_2,\cdots,B_n,\cdots$ 为互斥完备事件群或互不相容完备事件组.

全概率公式与贝叶斯公式：设 $B_1,B_2,\cdots,B_n,\cdots$ 为互斥完备事件群，且 $P(B_i)>0(i=1,2,\cdots)$，A 为任一事件，则

$$P(A)=\sum_j P(B_j)P(A\mid B_j)$$

若还有 $P(A)>0$，则 $P(B_i\mid A)=\dfrac{P(B_i)P(A\mid B_i)}{\sum\limits_j P(B_j)P(A\mid B_j)}(i=1,2,\cdots)$.

$P(B_i)$ 称为先验概率，而 $P(B_i\mid A)$ 称为后验概率，$i=1,2,\cdots$.

若两事件 A,B 满足 $P(AB)=P(A)P(B)$，则称 A,B 相互独立，简称 A,B 独立.

若四对事件 $\{A,B\},\{A,\overline{B}\},\{\overline{A},B\},\{\overline{A},\overline{B}\}$ 中有一对是相互独立的，则另外三对也是相互独立的.

设 $A_1,A_2,\cdots,A_n$ 是 n 个事件，若对任意 $k(1<k\leqslant n)$，任意 $1\leqslant i_1<i_2<\cdots<i_k\leqslant n$，$P(A_{i_1}A_{i_2}\cdots A_{i_k})=P(A_{i_1})P(A_{i_2})\cdots P(A_{i_k})$ 都成立，则称事件 $A_1,A_2,\cdots,A_n$ 相互独立.

设 n 个事件 $A_1,A_2,\cdots,A_n$ 相互独立，则把其中任意 $m(1\leqslant m\leqslant n)$ 个事件相应地换成它们的对立事件，所得的 n 个事件仍相互独立.

若 $A_1,A_2,\cdots,A_n$ 相互独立，则

$$P(A_1A_2\cdots A_n)=P(A_1)P(A_2)\cdots P(A_n)$$

$$P(A_1\cup A_2\cup\cdots\cup A_n)=1-P(\overline{A}_1\overline{A}_2\cdots\overline{A}_n)=1-P(\overline{A}_1)P(\overline{A}_2)\cdots P(\overline{A}_n)$$

习题 1

1. 写出下列随机试验的样本空间：

(1) 袋中有 5 个球，其中 3 个白球、2 个黑球，从袋中任取 1 个，观察其颜色；

(2) 从(1)的袋中不放回地任取两次球(每次取 1 个球)，观察其颜色；

(3) 从(1)的袋中任取 3 个球，记录取到的黑球个数；

(4) 如果把(1)的袋中的 3 个白球分别编号为 1,2,3，2 个黑球分别编号为 4 和 5，从袋中任取 1 个球，观察其号码；

(5) 生产某种产品直到有 10 件正品为止，记录生产产品的总件数；

(6) 对某工厂的产品进行检查，合格的记为正品，不合格的记为次品，如果连续查出 2 件次品就停止检查，或检查 4 件产品就停止检查，记录检查的结果；

(7) 射击用的靶子是半径为 R 的圆盘,已知每次射击均能中靶,现射击一次,记录弹着点的位置.

2. 设 A,B,C 表示三个事件,试以 A,B,C 的运算来表示下列事件:

(1) 仅 A 发生;

(2) A,B,C 中恰有一个发生;

(3) A,B,C 中至少有一个发生;

(4) A,B,C 中最多有一个发生;

(5) A,B,C 都不发生;

(6) A 不发生,B,C 中至少发生一个.

3. 从某班学生中任选一名,设 $A=\{$选出的人是男生$\}$,$B=\{$选出的人是数学爱好者$\}$,$C=\{$选出的人是班干部$\}$,试问下列运算结果分别表示什么事件?

(1) ABC; (2) $\bar{A}\bar{B}\bar{C}$;

(3) $\overline{A\cup C}$; (4) $A-(B\cup C)$.

4. 随机点 x 落在区间$[a,b]$上这一事件记作$\{x \mid a\leqslant x\leqslant b\}$.设 $\Omega=\{x \mid 0\leqslant x\leqslant 5\}$,$A=\{x \mid 1\leqslant x\leqslant 3\}$,$B=\{x \mid 2<x\leqslant 4\}$.具体写出下列各事件:

(1) $A\cup B$; (2) AB;

(3) $\bar{A}$; (4) $A-B$.

5. 化简下列各式:

(1) $AB\cup(A-B)\cup\bar{A}$;

(2) $(A\cup B)\overline{(A-B)\cup(B-A)}-B$.

6. 把一颗均匀的骰子连续投掷两次,求两次投掷中至少有一次出现 6 点且两次出现的点数之和为偶数的概率.

7. 一块表面都涂成红色的正方体被锯成 1 000 个同样大小的小正方体,将这些小正方体放入袋中均匀地搅混在一起,从袋中任取出的一个小正方体,试求该正方体两面涂有红色的概率.

8. 在长度为 L 的线段 AB 上随机地指定一点 C,求线段 AC 和 CB 中较短的线段长度大于 $\frac{L}{3}$ 的概率.

9. 两艘船都将停靠同一码头,它们可能在一昼夜的任意时刻到达.设两船停靠的时间分别为 1 h 和2 h,求有一艘船要停靠必须等待一段时间的概率.

10. 已知 $A\subset B$,$P(A)=0.2$,$P(B)=0.3$,求:

(1) $P(\bar{A})$; (2) $P(A\cup B)$; (3) $P(AB)$;

(4) $P(\bar{A}B)$; (5) $P(A-B)$.

11. 设 A,B,C 是三个事件,且 $P(A)=P(B)=P(C)=\frac{1}{4}$,$P(AB)=P(BC)=\frac{1}{8}$,$P(AC)=0$,求:

(1) A,B,C 都发生的概率;

(2) A,B,C 中至少有一个发生的概率;

(3) A,B,C 都不发生的概率.

12. 设 A,B 是两个随机事件,且 $P(A)=0.6$,$P(B)=0.7$,问:

(1) 在什么条件下 $P(AB)$取最小值? 最小值是多少?

(2) 在什么条件下 $P(AB)$取最大值? 最大值是多少?

(3) 类似(1)和(2),讨论 $P(A\cup B)$的最大、最小值情况.

13. 设 $A_1, A_2, \cdots, A_n$ 是任意 n 个事件，试利用数学归纳法证明：

$$P(A_1 \cup A_2 \cup \cdots \cup A_n) = \sum_{i=1}^{n} P(A_i) - \sum_{1 \leqslant i < j \leqslant n} P(A_i A_j) + \sum_{1 \leqslant i < j < k \leqslant n} P(A_i A_j A_k) + \cdots + (-1)^{n+1} P(A_1 A_2 \cdots A_n)$$

14. 袋中有 4 个白球、6 个红球，每次从袋中任取 1 个球，接连取两次. 试按第一次取后不放回和第一次取后放回两种情况分别求下列事件的概率：

$A = \{$取出 2 个都是白球$\}$；

$B = \{$第一次取得白球，第二次取得红球$\}$；

$C = \{$两次取得的球中恰有 1 个红球$\}$；

$D = \{$第二次取出的是白球$\}$.

15. 在分别标有号码 $1, 2, \cdots, 10$ 的 10 张卡片中任取 3 张，求：

(1) 取出的最大号码是 5 的概率；

(2) 取出的最小号码是 5 的概率；

(3) 取出的最大号码小于 5 的概率；

(4) 取出的最大号码大于 5 的概率.

16. 已知 100 件产品中有 5 件次品、95 件正品，从中任取 10 件，问取出的产品中正好有 3 件次品的概率是多少？

17. 已知 100 件产品中有 80 件一等品、15 件二等品、5 件三等品，现从中任取 10 件，求取出的产品为 7 件一等品、2 件二等品和 1 件三等品的概率.

18. 袋中有 8 个白球、5 个黑球，从袋中任取 2 个球，求：

(1) 取得的 2 个球同色的概率；

(2) 取得的 2 个球中至少有 1 个白球的概率；

(3) 取得的 2 个球中最多有 1 个白球的概率.

19. 从一副共有 52 张的扑克牌(去掉大、小王)中任取 4 张，求：

(1) 取出的 4 张是同花色的概率；

(2) 取出的 4 张是不同花色的概率；

(3) 取出的 4 张中至少有 2 张是同花色的概率；

(4) 取出的 4 张中至少有 1 张是 A 的概率.

20. 设每个人在一年的 12 个月中出生是等可能的，问 4 个人中至少有 2 个人是同月出生的概率是多少？

21. 将 3 个球随机地放入 4 个盒子中，求盒子中球的最大个数分别为 1, 2, 3 的概率.

22. 在数字 $0, 1, \cdots, 9$ 中随机地连续取出 4 个数字(无放回抽取)排成一排，求能排成一个 4 位偶数的概率.

23. 从 15 双不同的鞋子中任取 10 只，求：

(1) 取出的 10 只中恰好有两双配对的概率；

(2) 取出的 10 只中至少有两双配对的概率.

24. 已知 $P(A) = 0.7, P(B) = 0.4, P(AB) = 0.2$，求 $P(\overline{B} \mid A \cup B)$.

25. 已知 $P(A) = \dfrac{1}{4}, P(B \mid A) = \dfrac{1}{3}, P(A \mid B) = \dfrac{1}{2}$，求 $P(A \cup B)$.

26. 设 $P(B) > 0$，证明条件概率具有下列性质：

(1) 对任何事件 A，$P(A \mid B) \geqslant 0$；

(2) $P(\Omega \mid B) = 1$，$P(\varnothing \mid B) = 0$；

(3) 若 $A_1A_2=\varnothing$,则 $P(A_1\cup A_2\mid B)=P(A_1\mid B)+P(A_2\mid B)$;

(4) 若 $A_1\subset A_2$,则 $P(A_1\mid B)\leqslant P(A_2\mid B)$,并且 $P(A_2-A_1\mid B)=P(A_2\mid B)-P(A_1\mid B)$;

(5) 对任何事件 A,有 $P(\overline{A}\mid B)=1-P(A\mid B)$;

(6) 对任何事件 A_1,A_2,有 $P(A_1\cup A_2\mid B)=P(A_1\mid B)+P(A_2\mid B)-P(A_1A_2\mid B)$.

27. 设一批零件共有 100 件,其中有 7 件次品、93 件合格品.每次从中任取一件,取出的不再放回,求第三次才取到合格品的概率.

28. 设袋中有一白一黑两个球,每次从袋中任取一个球,观察其颜色后放回袋中,并再放进一个与所取球颜色相同的球,直到两种颜色的球都取到为止,求取了 n 次的概率.

29. 某射击小组共有 20 名射手,其中一级射手 4 人、二级射手 8 人、三级射手 7 人、四级射手 1 人,一、二、三、四级射手在一次射击中能中 10 环的概率分别为 0.9,0.7,0.5,0.2.现从该小组中任选一名,求他在一次射击中能中 10 环的概率.

30. 设某工厂有甲、乙、丙三个车间,它们生产同一种产品,每个车间的产量分别占该工厂总产量的 25%,35%,40%,每个车间的产品中次品率分别为 0.05,0.04,0.02.现从该厂总产品中任取一件产品,结果是次品,求取出的这个次品是由乙车间生产的概率.

31. 设某地区电信运营商 A,B,C 的用户比例为 4∶3∶2,一份对电信运营商的抽样调查数据表明用户对 A,B,C 的好评率分别为 80%,60%,70%.现从这些数据资料中任取一位用户的评价.

(1) 求该评价为好评的概率;

(2) 若该评价是好评,求该用户是运营商 B 的用户的概率.

32. 仪器中有三个元件,它们损坏的概率都是 0.2,并且损坏与否相互独立.当一个元件损坏时,仪器发生故障的概率为 0.25;当两个元件损坏时,仪器发生故障的概率为 0.6;当三个元件损坏时,仪器发生故障的概率为 0.95;当三个元件都不损坏时,仪器不发生故障.求:

(1) 仪器发生故障的概率;

(2) 仪器发生故障时恰有两个元件损坏的概率.

33. 证明:如果三个事件 A,B,C 相互独立,则 $A\cup B,AB$ 及 $A-B$ 都与 C 相互独立.

34. 证明:如果 $P(A\mid B)=P(A\mid\overline{B})$,则 A 与 B 相互独立.

35. 有 8 张形状完全相同的卡片,第 1,2,3,4 张卡片上涂有红色,第 1,2,3,5 张卡片上涂有白色,第 1,6,7,8 张卡片上涂有黑色.现从 8 张卡片中任取一张,以 A,B,C 分别表示取出的卡片上有红色、白色、黑色的事件,试验证:

$$P(ABC)=P(A)P(B)P(C)$$

但 A,B,C 不是两两独立的.

36. 设事件 A,B,C 相互独立,试证明:

(1) $\overline{A},B,C$ 相互独立;

(2) $\overline{A},\overline{B},C$ 相互独立;

(3) $\overline{A},\overline{B},\overline{C}$ 相互独立.

37. 三人独立射击同一目标,他们击中目标的概率分别是 $\frac{4}{5},\frac{2}{3},\frac{3}{4}$,试求目标被击中的概率.

38. 设有 $2n$ 个元件,每个元件的可靠性(即元件能正常工作的概率)为 $p(0<p<1)$,且各元件能否正常工作是相互独立的.若按图 1.9、图 1.10 中的方式装配成两个系统:

试求两个系统的可靠性,并比较哪个系统的可靠性大?

39. 事件 A 与 B 相互独立,两个事件中仅 A 发生的概率和仅 B 发生的概率都是 $\frac{1}{4}$,求 $P(A)$ 及 $P(B)$.

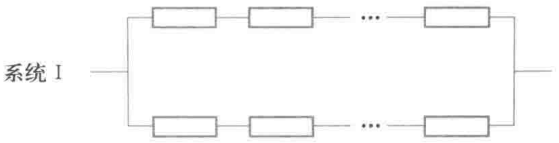

图 1.9

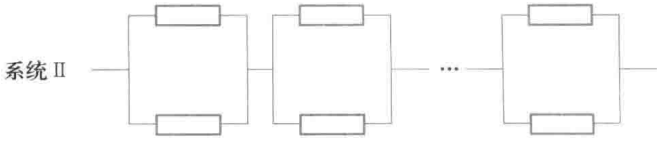

图 1.10

自测题 1

习题 1 参考答案

第2章 随机变量及其概率分布

在第1章我们讨论了随机事件与概率.为了全面地研究和描述随机现象,我们将引进概率论中的另一个重要概念——随机变量.本章将介绍有关随机变量及其概率分布的一些基本知识.

2.1 随机变量

2.1.1 随机变量与分布函数

我们讨论过不少随机试验,其中有些试验的结果就是数量,有些虽然本身不是数量,但可以用数量来表示试验的结果.

例 2.1 从一批废品率为 p 的产品中有放回地抽取 n 次,每次取一件产品,记录取到废品的次数,这一试验的所有可能结果为 $\Omega=\{0,1,2,\cdots,n\}$.如果用 X 表示取到废品的次数,那么 X 的取值依赖试验结果.当试验结果确定时,X 的取值也随之确定.比如,进行了一次这样的随机试验,试验结果 $\omega=1$,即在 n 次抽取中只有一次取到废品,那么 $X=1$.

例 2.2 抛掷一枚均匀的硬币,观察正面、反面的出现情况.这一试验的所有可能结果 $\Omega=\{H,T\}$,其中 H 表示"正面朝上",T 表示"反面朝上".如果引入变量 X,对试验的两个结果,将 X 的值分别规定为1和0,即

$$X=\begin{cases}1, & \text{当出现 } H \text{ 时},\\ 0, & \text{当出现 } T \text{ 时}\end{cases}$$

一旦试验结果确定了,X 的取值也随之确定.

从上述两例中可以看出:无论随机试验的结果本身与数量有无联系,我们都能把试验的每个结果与实数对应起来,即把试验结果数量化.由于这样的数量依赖试验结果,而对随机试验来说,在每次试验之前无法断言会出现何种结果,因而也就无法确定它会取什么值,即它的取值具有随机性,我们称这样的变量为随机变量.事实上,随机变量就是随着试验结果的不同而变化的量,因此可以说,随机变量是试验结果的函数.比如,例2.1中的 X 可写成 $X=X(\omega)=\omega$,其中 $\omega\in\{0,1,2,\cdots,n\}$,例2.2中的 X 可写成

$$X=X(\omega)=\begin{cases}1, & \omega=H,\\ 0, & \omega=T\end{cases}$$

一般地,有以下定义:

定义 2.1 设 E 为一随机试验,Ω 为其样本空间,若 $X=X(\omega)$,$\omega\in\Omega$ 为单值实函数,且对于任意实数 x,集合 $\{\omega \mid X(\omega)\leqslant x\}$ 都是随机事件,则称 X 为**随机变量**.

随机变量与普通实函数这两个概念既有相同之处又有所区别.相同之处在于它们都是从一个集合到另一个集合的映射.两者的区别主要有:首先,普通实函数的定义域是数的集合,而随机变量的定义域 Ω 未必是数的集合.根据不同随机现象而做的试验,其结果千差万别,有些可能是数的集合,有些则可能是诸如颜色的集合、气味

的集合等.其次,普通实函数无须做试验便可依据自变量的值确定函数值,而随机变量的取值在做试验之前是不确定的,只有在做了试验之后,依据所出现的结果才能确定.定义中要求对任意实数 x,$\{\omega \mid X(\omega)\leqslant x\}$ 都是事件,这说明并非任何定义在 Ω 上的函数都是随机变量,而是对这函数有一定的要求.定义中的要求无非是说,当我们把随机试验的结果数量化的时候,不能随心所欲,而是应该合乎概率公理体系的规范.今后,在不必强调 ω 时,常省去 ω,简记 $X(\omega)$ 为 X,而将 ω 的集合 $\{\omega \mid X(\omega)\leqslant x\}$ 所表示的事件简记为 $\{X\leqslant x\}$.

例 2.3 设 $A\subset\Omega$ 为一随机事件,令

$$I_A(\omega)=\begin{cases}1, & \omega\in A,\\ 0, & \omega\notin A\end{cases}$$

试证 $I_A(\omega)$ 为随机变量.

证 对任意实数 x,因

$$\{\omega \mid I_A(\omega)\leqslant x\}=\begin{cases}\varnothing, & x<0,\\ \bar{A}, & 0\leqslant x<1,\\ \Omega, & x\geqslant 1\end{cases}$$

可见对任意实数 x,$\{\omega \mid I_A(\omega)\leqslant x\}$ 都是事件,故 $I_A(\omega)$ 为随机变量.

上面的例子告诉我们:对样本空间 Ω 中的任何随机事件 A,都存在一个特殊的随机变量 $I_A(\omega)$,可用 $I_A(\omega)$ 来专门描述 A.反之,对定义在 Ω 上取值于 $\mathbf{R}$ 的随机变量 X,通过令 $\{X>a\}$,$\{b<X\leqslant c\}$,$\{X=d\}$(其中 $a,b,c,d\in\mathbf{R}$)等方式可表示许多随机事件,换言之,一般的随机变量并不能由一个随机事件所决定.这说明:随机事件与随机变量两个概念相较而言,后者更为宽泛.

思考:为什么 $\{X>a\}$,$\{b<X\leqslant c\}$,$\{X=d\}$ 都是随机事件?

在研究随机现象的理论中引入随机变量概念,其意义在于:一方面借助随机变量可以更灵活便捷地描述随机现象;另一方面也为运用微积分等近现代数学工具来研究随机现象的统计规律性奠定良好的基础.

对于随机变量 X,我们不只是看它取哪些值,更重要的是看它以多大的概率取那些值.由随机变量的定义可知,对于每一个实数 x,$\{X\leqslant x\}$ 都是一个随机事件,因而有一个确定的概率 $P\{X\leqslant x\}$ 与 x 相对应,因此,概率 $P\{X\leqslant x\}$ 是 x 的函数,这个函数在理论和应用中都很重要,为此,引入以下定义:

定义 2.2 设 X 是一随机变量,记

$$F(x)=P\{X\leqslant x\},\quad x\in\mathbf{R} \tag{2.1.1}$$

称 $F(x)$ 为 X 的**分布函数**.

有了分布函数,关于 X 的随机事件的概率都可以方便地利用分布函数 $F(x)$ 算出来,例如,$P\{a<X\leqslant b\}$,其中 $a<b$.因为 $\{a<X\leqslant b\}=\{X\leqslant b\}-\{X\leqslant a\}$,而 $a<b$,所以 $\{X\leqslant a\}\subset\{X\leqslant b\}$,故由概率的可减性,得

$$P\{a<X\leqslant b\}=P\{X\leqslant b\}-P\{X\leqslant a\}=F(b)-F(a) \tag{2.1.2}$$

可见,如果已知 X 的分布函数,就能知道 X 落在任意区间 $(a,b]$ 的概率,从这个意义上说,分布函数完整地描述了随机变量取值的概率规律.

分布函数 $F(x)$ 具有以下基本性质:

(1) $F(x)$ 是 x 的单调增函数;

(2) $F(x)$是x的右连续函数;

(3) 对任意实数x,$0\leqslant F(x)\leqslant 1$,且

$$F(-\infty)\overset{\text{def}}{=}\lim_{x\to-\infty}F(x)=0,\ F(+\infty)\overset{\text{def}}{=}\lim_{x\to+\infty}F(x)=1$$

证 (1) 当$x_2>x_1$时,因$F(x_2)-F(x_1)=P\{x_1<X\leqslant x_2\}\geqslant 0$,即$F(x_2)\geqslant F(x_1)$,故$F(x)$是$x$的单调增函数.

(2) 对任意的$x\in\mathbf{R}$及$\Delta x>0$,

$$\lim_{\Delta x\to 0^+}[F(x+\Delta x)-F(x)]=\lim_{n\to\infty}\left[F\left(x+\frac{1}{n}\right)-F(x)\right]\quad\text{(利用 }F(x)\text{的单调性)}$$

$$=\lim_{n\to\infty}P\left\{x<X\leqslant x+\frac{1}{n}\right\}=P(\varnothing)$$

$$=0\quad\text{(根据概率的连续性)}$$

即对于任意实数x,都有$F(x+0)=F(x)$,因而$F(x)$是x的右连续函数.

(3) 由概率的性质知,$0\leqslant P\{X\leqslant x\}\leqslant 1$,于是$0\leqslant F(x)=P\{X\leqslant x\}\leqslant 1$,$\forall x\in\mathbf{R}$,此外,利用$F(x)$的单调性和概率的连续性,可得

$$F(-\infty)=\lim_{x\to-\infty}F(x)=\lim_{n\to\infty}F(-n)=\lim_{n\to\infty}P\{X\leqslant -n\}=P(\varnothing)=0$$

$$F(+\infty)=\lim_{x\to+\infty}F(x)=\lim_{n\to\infty}F(n)=\lim_{n\to\infty}P\{X\leqslant n\}=P(\Omega)=1$$

需要指出:如果一个函数满足上述三条性质,那么这函数一定是某个随机变量的分布函数.因而可用这三条性质来判别一个函数是否为分布函数.

直观上,随机变量按其可能取值的特点可以分成两类:离散型随机变量和连续型随机变量,下面将分别予以讨论.

用分布函数可以表示随机变量X取任一实数x的概率,即对任一$x\in\mathbf{R}$,$P\{X=x\}=F(x)-F(x-0)$.请读者仿照性质(2)的证明方法自行推导.

2.1.2 离散型随机变量

若随机变量X的所有可能取值为有限个或者可数个,则称X为**离散型随机变量**.

现实世界中离散型随机变量的例子俯拾皆是,如公交车站的候车人数,某种商品的日销售件数,射击运动员在比赛中的命中环数等.

定义 2.3 设X为离散型随机变量,其所有可能的取值为$\{x_1,x_2,\cdots\}$,则

$$p_i=P\{X=x_i\}\ (i=1,2,\cdots)\tag{2.1.3}$$

称为随机变量X的**分布律**(或**概率函数**).

随机变量X的分布律具有以下性质:

(1) $p_i\geqslant 0$ $(i=1,2,\cdots)$;

(2) $p_1+p_2+\cdots=1$.

性质(1)是显然的.另外,由于事件$\{X=x_i\}$,$i=1,2,\cdots$构成互斥完备事件群,因而$\{X=x_1\}\cup\{X=x_2\}\cup\cdots=\Omega$,再由概率的加法公理,得

$$p_1+p_2+\cdots=1$$

上述性质(1),(2)是分布律的基本性质.反之,如果实数p_i,$i=1,2,\cdots$满足性质(1),(2),那么可以构造一个离散型随机变量,使得其分布律为p_i,$i=1,2,\cdots$.

通常,也把分布律写成

X	x_1	x_2	$\cdots$	x_n	$\cdots$
p	p_1	p_2	$\cdots$	p_n	$\cdots$

或者

$$X\sim\begin{pmatrix} x_1 & x_2 & \cdots & x_n & \cdots \\ p_1 & p_2 & \cdots & p_n & \cdots \end{pmatrix}$$

X 的分布律(2.1.3)指出了全部概率 1 在 X 的可能值的集合 $\{x_1,x_2,\cdots\}$ 上的分布情况,因而,(2.1.3)式又叫做随机变量 X 的**概率分布**.它可以形象地用图 2.1 表示,图中横轴上标出各个可能值的坐标 $x_1,x_2,\cdots$,并在每一 x_i 处画一条竖线,其高度表示事件 $\{X=x_i\}$ 的概率.显然,在这一图像表示中,各竖线高度的总和是 1.

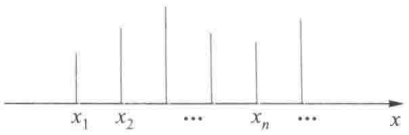

图 2.1

若已知离散型随机变量 X 的分布律 $p_i=P\{X=x_i\}$,$i=1,2,\cdots$,则可通过下式求得 X 的分布函数

$$F(x)=P\{X\leqslant x\}=\sum_{x_i\leqslant x}P\{X=x_i\}=\sum_{x_i\leqslant x}p_i$$

其中和式是对所有满足 $x_i\leqslant x$ 的 i 求和.

反之,若已知离散型随机变量 X 的分布函数 $F(x)$,欲求其分布律,可以这样做:记 $\{x_1,x_2,\cdots\}$ 为 $F(x)$ 的间断点集合,令 $p_i=F(x_i)-F(x_i-0)$,$x_i\in\{x_1,x_2,\cdots\}$,则 X 的分布律为

$$P\{X=x_i\}=p_i,\quad x_i\in\{x_1,x_2,\cdots\}$$

例 2.4 设离散型随机变量 X 的分布律为

X	0	1	2
p	0.2	0.4	0.4

求 X 的分布函数 $F(x)$.

解 由分布函数的定义知 $F(x)=P\{X\leqslant x\}$.

当 $x<0$ 时,

$$F(x)=P\{X\leqslant x\}=P(\varnothing)=0$$

当 $0\leqslant x<1$ 时,

$$F(x)=P\{X\leqslant x\}=P\{X=0\}=0.2$$

当 $1\leqslant x<2$ 时,

$$\begin{aligned}F(x)&=P\{X\leqslant x\}=P\{X=0\}+P\{X=1\}\\&=0.2+0.4=0.6\end{aligned}$$

当 $x \geqslant 2$ 时，

$$\begin{aligned} F(x) &= P\{X \leqslant x\} \\ &= P\{X=0\} + P\{X=1\} + P\{X=2\} \\ &= 0.2 + 0.4 + 0.4 = 1 \end{aligned}$$

故 X 的分布函数为

$$F(x) = \begin{cases} 0, & x<0, \\ 0.2, & 0 \leqslant x<1, \\ 0.6, & 1 \leqslant x<2, \\ 1, & x \geqslant 2 \end{cases}$$

从图 2.2 可知，$F(x)$ 的图形是一单调增的阶梯形曲线，它有三个跳跃间断点：0，1，2. 这三个值恰好是 X 的可能取值，并且 $F(x)$ 在每个跳跃间断点处的跳跃度就是 X 取该可能值的概率.

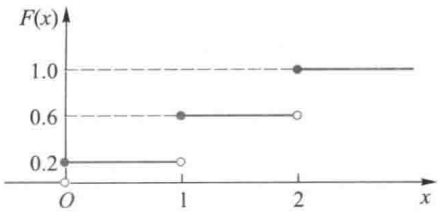

图 2.2

下面介绍几种重要的离散型随机变量及其概率分布.

单点分布 若随机变量 X 的分布律为 $P\{X=a\}=1$，则称 X **服从单点分布**，记为 $X \sim \begin{pmatrix} a \\ 1 \end{pmatrix}$.

拓展阅读：伯努利家族

两点分布 若随机变量 X 的分布律为 $P\{X=a_0\}=1-p$，$P\{X=a_1\}=p$，或者统一地表示为 $P\{X=a_i\}=p^i(1-p)^{1-i}(i=0,1)$，其中参数 $0<p<1$，则称 X **服从两点分布**.

特别，当 $a_0=0$，$a_1=1$ 时，称 X 服从 (0-1) 分布，记为 $X \sim B(1,p)$ 或

$$X \sim \begin{pmatrix} 0 & 1 \\ 1-p & p \end{pmatrix}$$

如果在一次试验中，事件 A 发生的概率为 p，不发生的概率为 $1-p$，以 X 记事件 A 在一次试验中的发生次数，那么，X 的所有可能取值为 0，1，而且 $P\{X=0\}=P(\overline{A})=1-p$，$P\{X=1\}=P(A)=p$，故 X 服从 (0-1) 分布，由此可见，(0-1) 分布正是适合描述这一类问题的概率分布.

二项分布 若随机变量 X 的分布律为 $P\{X=i\}=C_n^i p^i(1-p)^{n-i}$，$i=0,1,2,\cdots,n$，其中 $0<p<1$，则称 X **服从参数为** n,p **的二项分布**，记为 $X \sim B(n,p)$.

拓展阅读：二项分布的发展历史

二项分布来源于这样一类问题，设某事件 A 在一次试验中发生的概率为 p，现将此试验独立地重复进行 n 次①. 若以 X 表示在这 n 次试验中事件 A 发生的次数，则 X 的所有可能取值为

$$0,1,2,\cdots,n$$

为确定 X 的概率分布，考虑事件 $\{X=i\}$ $(0 \leqslant i \leqslant n)$，它可以分解为

① 若试验 E 只有两个可能结果：A，$\overline{A}$，且 $P(A)=p$，$P(\overline{A})=1-p(0<p<1)$，把 E 独立地重复进行 n 次，则称这一串独立重复试验为一个 n 重伯努利试验.

$$\{X=i\}=A_1A_2\cdots A_i\bar{A}_{i+1}\bar{A}_{i+2}\cdots\bar{A}_n\cup A_1\cdots A_{i-1}\bar{A}_iA_{i+1}\bar{A}_{i+2}\cdots\bar{A}_n\cup\cdots\cup$$
$$\bar{A}_1\bar{A}_2\cdots\bar{A}_{n-i}A_{n-i+1}\cdots A_n \tag{2.1.4}$$

这里，事件 $A_k=\{$第 k 次试验中 A 发生$\}$，$\bar{A}_k=\{$第 k 次试验中 A 不发生$\}$ $(k=1,2,\cdots,n)$. 因为“n 次独立重复试验”表达了两层含义：其一，各次试验的条件相同，即试验的重复性，这保证事件 A 的概率 p 在各次试验中保持不变；其二，在每次试验中事件 A 发生与否与其他各次试验的结果相独立，即各次试验的独立性，所以 $A_1,A_2,\cdots,A_n$ 是相互独立的，且有 $P(A_k)=p(k=1,2,\cdots,n)$. 由此可知(2.1.4)式右端每个积事件的概率皆为 $p^i(1-p)^{n-i}$，又因(2.1.4)式右端是 C_n^i 个两两互斥的积事件之和，故由概率的加法定理，得

$$P\{X=i\}=C_n^i\,p^i(1-p)^{n-i}\quad(i=0,1,2,\cdots,n) \tag{2.1.5}$$

可见 X 服从二项分布 $B(n,p)$.

记 $p_i=C_n^i\,p^i(1-p)^{n-i}(i=0,1,2,\cdots,n)$，显然 $p_i>0$，由二项式定理知

$$\sum_{i=0}^{n}p_i=\sum_{i=0}^{n}C_n^i\,p^i(1-p)^{n-i}=[p+(1-p)]^n=1$$

可见由(2.1.5)式所决定的 $p_i(i=0,1,2,\cdots,n)$ 确实为一种概率分布. 由于(2.1.5)式右端恰好是二项式$[px+(1-p)]^n$ 的展开式中 x^i 的系数，故得名二项分布.

例 2.5 某车间有 10 台机床，每台机床由于各种原因时常需要停车，设各台机床的停车或开车是相互独立的. 若每台机床在任一时刻处于停车状态的概率为 $\frac{1}{3}$，求在任一时刻车间里有 3 台机床处于停车状态的概率.

在 MATLAB 软件中，命令 binopdf(x,n,p) 计算二项分布 $B(n,p)$ 在 x 处的分布律，binocdf(x,n,p) 计算二项分布 $B(n,p)$ 在 x 处的分布函数. Excel 也提供了函数 BINOM.DIST, BINOM.DIST.RANGE 计算二项分布的分布律和分布函数.

解 令 $A=\{$任一时刻机床处于停车状态$\}$，以 X 表示任一时刻 10 台机床中处于停车状态的机床台数. 我们把任一时刻对一台机床的观察当作一次试验，试验结果只有 A 发生或 A 不发生两种可能，已知 $p=P(A)=\frac{1}{3}$. 又由题设，各机床的停车与否是相互独立的，因此，对这 10 台机床的观察相当于进行 10 次独立重复试验. 于是 $X\sim B\left(10,\frac{1}{3}\right)$，所求概率为

$$P\{X=3\}=C_{10}^3\left(\frac{1}{3}\right)^3\left(1-\frac{1}{3}\right)^7=0.260$$

例 2.6 设每次射击击中目标的概率为 0.001，现独立射击 1 000 次，求至少击中 2 次的概率.

解 若以 X 表示这 1 000 次独立射击中击中目标的次数，则 $X\sim B(1\,000,0.001)$，故所求概率为

$$P\{X\geqslant 2\}=1-P\{X<2\}=1-P\{X=0\}-P\{X=1\}$$
$$=1-0.999^{1\,000}-1\,000\times 0.001\times 0.999^{999}=0.264$$

如果把例 2.6 中的问题改为“求至少击中 20 次的概率”，那么，按上述方法计算就比较烦琐. 为此，讨论以下的近似计算法：

泊松定理 设随机变量 X_n 服从二项分布 $B(n,p_n)(n=1,2,\cdots)$，其中 p_n 与 n 有

关且满足 $\lim\limits_{n\to\infty} np_n=\lambda>0$,则

$$\lim_{n\to\infty} C_n^k p_n^k(1-p_n)^{n-k}=\frac{\lambda^k}{k!}e^{-\lambda} \quad (k=0,1,2,\cdots)$$

证 令 $np_n=\lambda_n$,则 $p_n=\dfrac{\lambda_n}{n}$,而

$$C_n^k p_n^k(1-p_n)^{n-k}=\frac{n(n-1)\cdots(n-k+1)}{k!}\left(\frac{\lambda_n}{n}\right)^k\left(1-\frac{\lambda_n}{n}\right)^n\left(1-\frac{\lambda_n}{n}\right)^{-k}$$

$$=\left(1-\frac{1}{n}\right)\left(1-\frac{2}{n}\right)\cdots\left(1-\frac{k-1}{n}\right)\frac{\lambda_n^k}{k!}\left(1-\frac{\lambda_n}{n}\right)^n\left(1-\frac{\lambda_n}{n}\right)^{-k}$$

对任意固定的 $k(0\leqslant k\leqslant n)$,当 $n\to\infty$ 时,因为

$$\left(1-\frac{1}{n}\right)\left(1-\frac{2}{n}\right)\cdots\left(1-\frac{k-1}{n}\right)\to 1,\lambda_n^k\to\lambda^k,\left(1-\frac{\lambda_n}{n}\right)^{-k}\to 1$$

及

$$\lim_{n\to\infty}\left(1-\frac{\lambda_n}{n}\right)^n=\lim_{n\to\infty}\left(1-\frac{\lambda_n}{n}\right)^{-\frac{n}{\lambda_n}(-\lambda_n)}=e^{-\lambda}$$

所以

$$\lim_{n\to\infty} C_n^k p_n^k(1-p_n)^{n-k}=\frac{\lambda^k}{k!}e^{-\lambda}$$

在应用中,当 n 较大(指 $n\geqslant 10$)且 p 较小(指 $p\leqslant 0.1$)时,有以下的泊松近似公式:

$$C_n^k p^k(1-p)^{n-k}\approx\frac{\lambda^k e^{-\lambda}}{k!} \quad (k=0,1,2,\cdots,n)$$

其中 $\lambda=np$.而关于$\dfrac{\lambda^k e^{-\lambda}}{k!}$的值,可以查书末附表 2 得到.

例 2.7(续例 2.6) 本题满足 n 较大且 p 较小的条件,又 $\lambda=1\,000\times 0.001=1$,由泊松近似公式,得

$$P\{X=0\}=C_{1\,000}^0 p^0(1-p)^{1\,000}\approx e^{-1}$$

$$P\{X=1\}=C_{1\,000}^1 p^1(1-p)^{999}\approx e^{-1}$$

因此,至少击中 2 次的概率为

$$P\{X\geqslant 2\}=1-P\{X=0\}-P\{X=1\}\approx 1-2e^{-1}=0.264$$

也可用另外一种常用的方法直接查表计算:

$$P\{X\geqslant 2\}=\sum_{k=2}^{1\,000} C_{1\,000}^k p^k(1-p)^{1\,000-k}\approx\sum_{k=2}^{1\,000}\frac{1^k e^{-1}}{k!}\approx\sum_{k=2}^{\infty}\frac{1^k e^{-1}}{k!}$$

查附表 2 得

$$\sum_{k=2}^{\infty}\frac{1^k e^{-1}}{k!}=0.264$$

故 $P\{X\geqslant 2\}\approx 0.264$.

泊松分布 若随机变量 X 的分布律为

$$P\{X=k\}=\frac{\lambda^k e^{-\lambda}}{k!},\quad k=0,1,2,\cdots \tag{2.1.6}$$

其中 $\lambda>0$ 为常数，则称 X **服从参数为 λ 的泊松分布**，记为 $X\sim P(\lambda)$.

由于 $p_k=\frac{\lambda^k e^{-\lambda}}{k!}>0$ $(k=0,1,2,\cdots)$，又由麦克劳林公式有

$$\sum_{k=0}^{\infty}p_k=\sum_{k=0}^{\infty}\frac{\lambda^k}{k!}e^{-\lambda}=e^{-\lambda}\left(1+\frac{\lambda}{1!}+\frac{\lambda^2}{2!}+\cdots+\frac{\lambda^n}{n!}+\cdots\right)=e^{-\lambda}e^{\lambda}=1$$

因而，按(2.1.6)式所决定的 $p_k(k=0,1,2,\cdots)$ 确实是一种分布律.

在 MATLAB 软件中，命令 poisspdf(x,lambda)计算泊松分布 $P(\lambda)$ 在 x 处的分布律，poisscdf(x,lambda)计算泊松分布 $P(\lambda)$ 在 x 处的分布函数. Excel 也提供了函数 POISSON.DIST 计算泊松分布的分布律和分布函数.

例 2.8 由过去的销售记录表明，某商店的某种商品每月的销售件数可以用参数 $\lambda=5$ 的泊松分布来描述，为了以 0.999 以上的把握保证不脱销，问该商店在月底至少应进多少件这种商品(假定上个月无存货)?

解 设该店每月销售这种商品 X 件，月底应进货 N 件，则当 $X\leqslant N$ 时，才不会脱销. 因为 $X\sim P(5)$，而

$$P\{X\leqslant N\}=1-P\{X>N\}=1-\sum_{k=N+1}^{\infty}\frac{5^k}{k!}e^{-5}$$

依题意，要求 $P\{X\leqslant N\}=1-\sum_{k=N+1}^{\infty}\frac{5^k}{k!}e^{-5}>0.999$，即

$$\sum_{k=N+1}^{\infty}\frac{5^k}{k!}e^{-5}<0.001$$

查附表 2 泊松分布表，得满足上述不等式的最小值 $N+1=14$，故

$$N=13$$

因而，这家商店只要在月底进 13 件这种商品，就可以有 99.9%以上的把握，保证这种商品在下个月内不会脱销.

泊松分布是概率论中重要的分布之一，它是由法国数学家泊松引入的. 一方面，泊松分布是二项分布的极限分布，在一定条件下，可用泊松分布作为二项分布的近似. 另一方面，有许多随机变量服从或近似服从泊松分布. 例如，稀有事件(故障、不幸事件、自然灾害等)在 n 次独立重复试验中出现的次数，在任给一段固定的时间间隔内来到公共设施(公共汽车站、商店、电话交换台等)要求给予服务的顾客数，放射性裂变落到某区域的质点数，显微镜下落在某区域中的血细胞或微生物的数目等都服从或近似地服从泊松分布.

几何分布 若随机变量 X 的分布律为

$$P\{X=k\}=(1-p)^{k-1}p\ (k=1,2,3,\cdots) \tag{2.1.7}$$

其中 $0<p<1$ 为常数，则称 X **服从参数为 p 的几何分布**，记为 $X\sim Ge(p)$.

在 MATLAB 软件中，命令 geopdf(x,p)计算几何分布 $Ge(p)$ 在 x 处的分布律，geocdf(x,p)计算几何分布 $Ge(p)$ 在 x 处的分布函数.

几何分布来源于如下问题：在伯努利试验的条件下，若设 X 为事件 A 首次发生时所需的试验次数，则 $\{X=k\}$ 表示第 k 次试验时 A 发生且前 $k-1$ 次试验 A 都不发生，由伯努利试验为独立重复试验的特点可知，$P\{X=k\}=(1-p)^{k-1}p$.

几何分布具有如下性质：若 $X\sim Ge(p)$，则 $P\{X=k+n\mid X>k\}=P\{X=n\}$，$k,n=1,2,3,\cdots$.

证 因

$$P\{X=k+n \mid X>k\}=\frac{P\{X=k+n, X>k\}}{P\{X>k\}}=\frac{P\{X=k+n\}}{P\{X>k\}}$$

$$P\{X=k+n\}=(1-p)^{k+n-1}p, P\{X>k\}=\sum_{i=k+1}^{\infty}(1-p)^{i-1}p=\frac{p(1-p)^k}{1-(1-p)}=(1-p)^k$$

故

$$P\{X=k+n \mid X>k\}=\frac{(1-p)^{k+n-1}p}{(1-p)^k}=(1-p)^{n-1}p=P\{X=n\}, k, n=1,2,3,\cdots$$

几何分布具有的上述性质称为“无记忆性”.可以证明:在可能取值为正整数的离散型分布中只有几何分布具有无记忆性.

2.1.3 连续型随机变量

除了离散型随机变量之外,还有一类重要的随机变量——连续型随机变量,这种随机变量 X 可以取某个区间 $[a,b]$ 或 $(-\infty,+\infty)$ 中的一切值.由于这种随机变量的所有可能值无法像离散型随机变量那样一一排列,因而也就不能用离散型随机变量的分布律来描述它的概率分布,刻画这种随机变量的概率分布的一种方法是用(2.1.1)式定义的分布函数,但在理论上和实践中更常用的方法是用所谓的“概率密度”.

定义 2.4 设 X 为随机变量,若存在非负可积函数 $f(x)$,使得对任意区间 $A\subset\mathbf{R}$,都有

$$P\{X\in A\}=\int_A f(x)\,\mathrm{d}x$$

则称 X 为**连续型随机变量**,并称 $f(x)$ 为 X 的**概率密度**①.

概率密度 $f(x)$ 具有下述性质:

(1) $f(x)\geqslant 0, -\infty<x<+\infty$;

(2) $\int_{-\infty}^{+\infty}f(x)\,\mathrm{d}x=1$;

(3) 若连续型随机变量 X 的分布函数为 $F(x)$,则对任意实数 x,有

$$F(x)=\int_{-\infty}^{x}f(t)\,\mathrm{d}t \tag{2.1.8}$$

(4) 若 $f(x)$ 在 x 点处连续,则有 $F'(x)=f(x)$②.

性质(1)是定义 2.4 自身要求的.在定义中取 $A=(-\infty,+\infty),(-\infty,x]$,就得到性质(2),(3).此外性质(2)表明:介于曲线 $y=f(x)$ 与横轴之间的全部面积等于 1.最后由(2.1.8)式结合微积分方法不难证明性质(4).

性质(1)和(2)是概率密度的基本性质.反之,若有函数 $f(x)$ 满足性质(1),(2),

---

① 因修改 $f(x)$ 在若干点处的函数值并不会影响积分 $\int_A f(x)\,\mathrm{d}x$ 的数值,故无须在意改变概率密度在若干点处的取值.

② 数学上可以证明,如果 $F(x)$ 为连续型随机变量的分布函数,那么其导数不存在的点构成的点集为至多可数集(有限集与可数集的统称).而至多可数集的“长度”是 0,因此在无限长的数轴上挖掉这个“长度”为 0 的点集,$F(x)$ 就处处可导,也就处处成立 $F'(x)=f(x)$.正是因为这个缘故,在有些教材或文献中把概率密度直接定义为分布函数的导数.

则它可以成为某个连续型随机变量的概率密度.

性质(3)与(4)刻画了连续型随机变量的分布函数与概率密度之间的关系,如图 2.3 所示.

由性质(4)可知,在 $f(x)$ 的连续点 x 处,有

$$f(x)=\lim_{\Delta x\to 0^+}\frac{F(x+\Delta x)-F(x)}{\Delta x}=\lim_{\Delta x\to 0^+}\frac{P\{x<X\leqslant x+\Delta x\}}{\Delta x}$$

从 $f(x)$ 的上述等式中发现,它与物理学中的线密度的定义式相类似,这便是 $f(x)$ 被称作概率密度的来由.

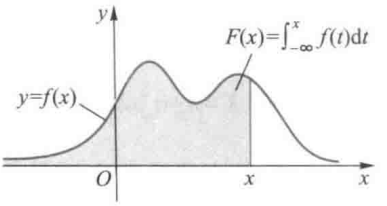

图 2.3

由高等数学的知识结合(2.1.8)式可知:**连续型随机变量的分布函数 $F(x)$ 必为连续函数.**

连续型随机变量 X 具有下列特性:X 取任意实数的概率都等于零,即,对于任意实数 x,有

$$P\{X=x\}=0$$

事实上,设 X 的分布函数为 $F(x)$,对任意 $\Delta x>0$,由

$$\{X=x\}\subset\{x-\Delta x<X\leqslant x\}$$

得

$$0\leqslant P\{X=x\}\leqslant P\{x-\Delta x<X\leqslant x\}=F(x)-F(x-\Delta x)$$

因为 X 为连续型随机变量,其分布函数 $F(x)$ 是连续函数,所以,在上述不等式两端,令 $\Delta x\to 0^+$,即得证.

由连续型随机变量的上述特性可知

$$P\{a<X<b\}=P\{a\leqslant X<b\}=P\{a<X\leqslant b\}$$
$$=P\{a\leqslant X\leqslant b\}=\int_a^b f(x)\,\mathrm{d}x$$

即只要区间端点 a,b 确定,则 X 落入区间 (a,b),$[a,b)$,$(a,b]$,$[a,b]$ 的概率是相同的,都等于 $\int_a^b f(x)\,\mathrm{d}x$.

当 x 为 X 的某个可能值时,事件 $\{X=x\}$ 并非不可能事件,但有 $P\{X=x\}=0$.这一事实说明:若事件 $A=\varnothing$,则 $P(A)=0$;反之,若事件 A 的概率 $P(A)=0$,则 A 未必是不可能事件.

下面介绍几种重要的连续型随机变量.

拓展阅读:正态分布的发展历史

正态分布 若连续型随机变量 X 的概率密度为

$$f(x)=\frac{1}{\sqrt{2\pi}\sigma}\mathrm{e}^{-\frac{(x-\mu)^2}{2\sigma^2}}\quad(-\infty<x<+\infty)\tag{2.1.9}$$

其中 $\mu,\sigma(\sigma>0)$ 为常数,则称 X **服从参数为 μ,σ 的正态分布**,记为 $X\sim N(\mu,\sigma^2)$.习惯上,称服从正态分布的随机变量为**正态变量**.

可以验证(2.1.9)式中的 $f(x)$ 确实满足概率密度的两条基本性质(性质(1),(2)).事实上,显然 $f(x)\geqslant 0(-\infty<x<+\infty)$,为证明 $\int_{-\infty}^{+\infty}f(x)\,\mathrm{d}x=1$,作变量代换 $t=\frac{x-\mu}{\sigma}$,即转化为证明等式

$$I=\int_{-\infty}^{+\infty}\mathrm{e}^{-\frac{t^2}{2}}\mathrm{d}t=\sqrt{2\pi} \tag{2.1.10}$$

为此，考虑下面的积分

$$I^2=\int_{-\infty}^{+\infty}\mathrm{e}^{-\frac{t^2}{2}}\mathrm{d}t\int_{-\infty}^{+\infty}\mathrm{e}^{-\frac{s^2}{2}}\mathrm{d}s=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}\mathrm{e}^{\frac{-(s^2+t^2)}{2}}\mathrm{d}s\mathrm{d}t$$

化成极坐标 $s=\rho\cos\varphi, t=\rho\sin\varphi$，得

$$I^2=\int_0^{2\pi}\mathrm{d}\varphi\int_0^{+\infty}\mathrm{e}^{-\frac{\rho^2}{2}}\rho\mathrm{d}\rho=2\pi$$

因为 $I\geqslant 0$，所以 $I=\sqrt{2\pi}$，即(2.1.10)式得证.

当 $\mu=3$，σ 取不同数值时，相应的 $f(x)$ 的图形如图 2.4(a)所示.

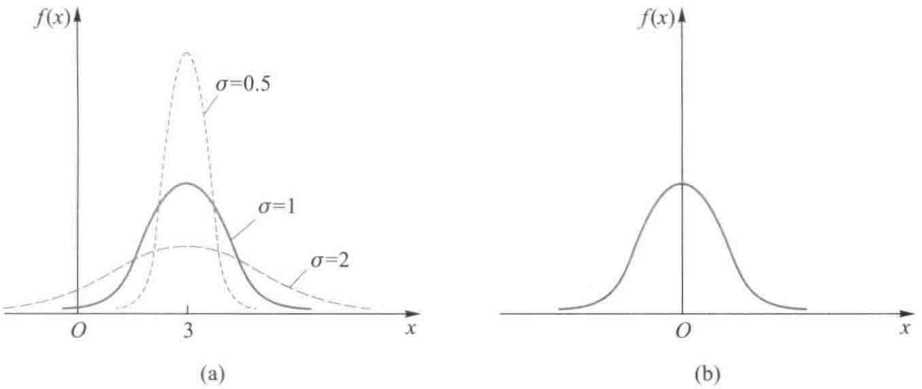

图 2.4

正态分布概率密度曲线的这种“中间高，两头低”的特点反映了在正常状态下一般事物所遵循的客观规律.例如一大群人的身高，特别高大者和殊为矮小者占少数，而处中间状态者居多.各种职业的人的收入、大批同类产品检验时的误差等亦如此，它们都不同程度地符合正态分布.因此，正态分布无论在理论上还是在实际应用中都占有十分重要的地位.

当 $\mu=0$，$\sigma=1$ 时称 X 服从**标准正态分布**，其概率密度(见图 2.4(b))、分布函数分别用专用符号 $\varphi(x)$，$\Phi(x)$ 表示，即有

$$\varphi(x)=\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-\frac{x^2}{2}}\quad(-\infty<x<+\infty) \tag{2.1.11}$$

$$\Phi(x)=\int_{-\infty}^{x}\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-\frac{t^2}{2}}\mathrm{d}t \tag{2.1.12}$$

对于标准正态分布的分布函数 $\Phi(x)$，有恒等式

$$\Phi(-x)=1-\Phi(x) \tag{2.1.13}$$

成立.(2.1.13)式的证明留给读者.

标准正态分布的分布函数 $\Phi(x)$ 在正态分布的概率计算中起着重要作用，人们已编制了 $\Phi(x)$ 的函数值表，可供查用(见附表 1).利用 $\Phi(x)$ 可进行任何正态分布的概率计算.这是因为

命题 若随机变量 $X\sim N(\mu,\sigma^2)$，则 $Z=\dfrac{X-\mu}{\sigma}\sim N(0,1)$.

证 因为 Z 的分布函数为

$$P\{Z\leqslant x\}=P\left\{\frac{X-\mu}{\sigma}\leqslant x\right\}=P\{X\leqslant\mu+\sigma x\}$$

$$=\frac{1}{\sqrt{2\pi}\sigma}\int_{-\infty}^{\mu+\sigma x}\mathrm{e}^{-\frac{(t-\mu)^2}{2\sigma^2}}\mathrm{d}t$$

令 $s=\dfrac{t-\mu}{\sigma}$,则

$$P\{Z\leqslant x\}=\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{x}\mathrm{e}^{-\frac{s^2}{2}}\mathrm{d}s=\Phi(x)$$

由此可见

$$Z\sim N(0,1)$$

例 2.9 设随机变量 $X\sim N(1.4,4)$,求:

(1) $P\{1<X\leqslant 1.6\}$;

(2) $P\{|X-1.4|>2\}$;

(3) $P\{X>1.8\}$.

解 因为 $\dfrac{X-1.4}{2}\sim N(0,1)$,所以

(1) $P\{1<X\leqslant 1.6\}=P\left\{\dfrac{1-1.4}{2}<\dfrac{X-1.4}{2}\leqslant\dfrac{1.6-1.4}{2}\right\}$

$$=\Phi\left(\frac{1.6-1.4}{2}\right)-\Phi\left(\frac{1-1.4}{2}\right)$$

$$=\Phi(0.1)-\Phi(-0.2)$$

$$=\Phi(0.1)-[1-\Phi(0.2)]$$

$$=0.539\ 8-(1-0.579\ 3)=0.119\ 1$$

(2) $P\{|X-1.4|>2\}=P\left\{\dfrac{|X-1.4|}{2}>1\right\}$

$$=1-P\left\{\left|\frac{X-1.4}{2}\right|\leqslant 1\right\}$$

$$=1-[\Phi(1)-\Phi(-1)]$$

$$=2-2\Phi(1)=2(1-0.841\ 3)=0.317\ 4$$

(3) $P\{X>1.8\}=1-P\{X\leqslant 1.8\}$

$$=1-P\left\{\frac{X-1.4}{2}\leqslant\frac{1.8-1.4}{2}\right\}$$

$$=1-\Phi(0.2)=0.420\ 7$$

在 MATLAB 软件中,命令 normpdf(x,MU,SIGMA)计算正态分布 $N(\mu,\sigma)$ 在 x 处的概率密度,normcdf(x,MU,SIGMA)计算正态分布 $N(\mu,\sigma)$ 在 x 处的分布函数. Excel 也提供了函数 NORM.DIST 计算正态分布的概率密度和分布函数,Gauss(x)计算标准正态分布在 x 处的分布函数值减去 0.5.

例 2.10 公共汽车车门(单位:cm)的高度是按成年男子与车门顶碰头的概率在 0.01 以下来设计的,设成年男子身高 X(单位:cm)服从正态分布 $N(170,6^2)$,试确定车门的高度.

解 设车门的高度为 h,依题意应有

$$P\{X>h\}=1-P\{X\leqslant h\}<0.01$$

即

$$P\{X\leqslant h\}>0.99$$

因为 $X\sim N(170,6^2)$，所以 $\dfrac{X-170}{6}\sim N(0,1)$，从而

$$P\{X\leqslant h\}=P\left\{\frac{X-170}{6}\leqslant\frac{h-170}{6}\right\}=\Phi\left(\frac{h-170}{6}\right)$$

查标准正态分布表，得

$$\Phi(2.33)=0.990\ 1>0.99$$

所以取 $\dfrac{h-170}{6}=2.33$，即 $h\approx184$，故车门的设计高度至少应为 184 cm 方可保证成年男子与车门顶碰头的概率在 0.01 以下.

均匀分布 若随机变量 X 具有概率密度

$$f(x)=\begin{cases}\dfrac{1}{b-a}, & a\leqslant x\leqslant b,\\ 0, & x<a\ 或\ x>b\end{cases}\tag{2.1.14}$$

则称 X **在区间**$[a,b]$**上服从均匀分布**，记为 $X\sim U(a,b)$，其中 a,b 为常数，$-\infty<a<b<+\infty$.

在 MATLAB 软件中，命令 unifpdf(x,a,b) 计算均匀分布 $U(a,b)$ 在 x 处的概率密度，unifcdf(x,a,b) 计算均匀分布 $U(a,b)$ 在 x 处的分布函数.

分布的“均匀”性是指 X 具有下述意义的等可能性，即它落在 $[a,b]$ 内任意等长度的子区间内的概率是相同的. 事实上，对于任一长度为 Δl 的子区间 $[c,c+\Delta l]$，$a\leqslant c<c+\Delta l\leqslant b$，

$$\begin{aligned}P\{c\leqslant X\leqslant c+\Delta l\}&=\int_c^{c+\Delta l}f(x)\,\mathrm{d}x\\&=\int_c^{c+\Delta l}\frac{1}{b-a}\mathrm{d}x\\&=\frac{\Delta l}{b-a}\end{aligned}$$

均匀分布的概率密度 $f(x)$ 的图形如图 2.5 所示.

如果随机变量 $X\sim U(a,b)$，那么 X 的分布函数

$$F(x)=\int_{-\infty}^{x}f(t)\,\mathrm{d}t=\begin{cases}0, & x<a,\\ \displaystyle\int_a^x\frac{1}{b-a}\mathrm{d}t=\frac{x-a}{b-a}, & a\leqslant x<b,\\ \displaystyle\int_a^b\frac{1}{b-a}\mathrm{d}t=1, & x\geqslant b\end{cases}$$

其图形如图 2.6 所示.

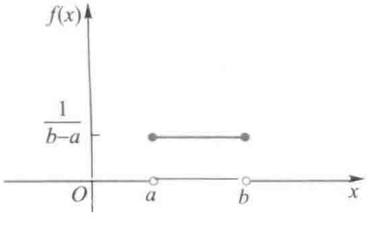

图 2.5

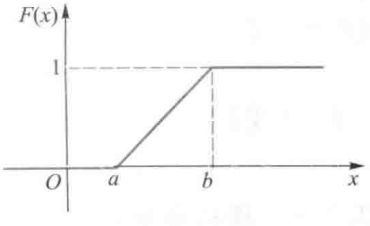

图 2.6

在实际问题中，如定点计算的舍入误差、计算机产生的随机数、正弦波的随机相位等通常都服从均匀分布.在理论研究中，尤其是在分布的模拟研究中也常用到均匀分布(参见例2.16).

指数分布 若随机变量 X 具有概率密度

$$f(x)=\begin{cases}\lambda e^{-\lambda x}, & x\geqslant 0,\\ 0, & x<0\end{cases}$$

其中常数 $\lambda>0$，则称 X **服从参数为 λ 的指数分布**，记为 $X\sim Exp(\lambda)$.此时概率密度 $f(x)$ 的图形如图2.7所示.

在MATLAB软件中，命令 exppdf(x, lambda) 计算指数分布 $Exp(\lambda)$ 在 x 处的概率密度.expcdf(x, lambda) 计算指数分布 $Exp(\lambda)$ 在 x 处的分布函数，Excel也提供了函数 EXPON.DIST 计算指数分布的概率密度和分布函数.

如果随机变量 $X\sim Exp(\lambda)$，那么 X 的分布函数 $F(x)$ 为

$$F(x)=\int_{-\infty}^{x}f(t)\,dt=\begin{cases}1-e^{-\lambda x}, & x\geqslant 0,\\ 0, & x<0\end{cases}$$

此时，对任意的 $x\geqslant 0$，有

$$P\{X>x\}=1-F(x)=e^{-\lambda x}.$$

指数分布的分布函数图形如图2.8所示.

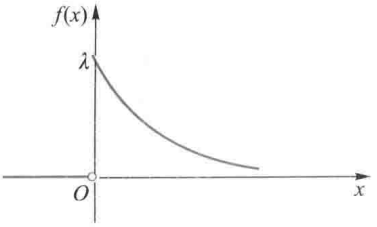

图2.7

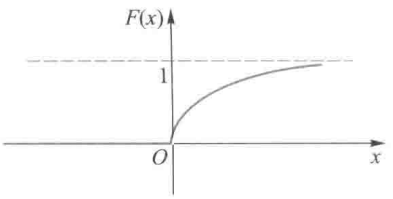

图2.8

指数分布具有如下性质：若 $X\sim Exp(\lambda)$，则对任意的 $s>0,t>0$，有

$$P\{X>s+t\mid X>s\}=P\{X>t\}$$

证 $$P\{X>s+t\mid X>s\}=\frac{P\{X>s+t,X>s\}}{P\{X>s\}}=\frac{P\{X>s+t\}}{P\{X>s\}}$$

$$=\frac{e^{-\lambda(s+t)}}{e^{-\lambda s}}=e^{-\lambda t}=P\{X>t\}$$

拓展阅读：既非离散型也非连续型随机变量举例

指数分布的上述性质称为**无记忆性**，也有人把它比喻为“永远年轻”，意思是若以 X 表示某人的寿命，则在已知其寿命超过 s 岁的条件下还能多活 t 年的概率与其出生时能活过 t 年的概率是相同的.

在连续型分布中唯有指数分布具有无记忆性.

指数分布最常见的一个应用场合是寿命分布，如电子元件的寿命、电话通话时间、随机服务系统的服务时间等常常都可看作是近似服从指数分布的.

2.2 随机变量的函数及其概率分布

2.2.1 随机变量的函数的概念

在数学理论上经常会对变量作变换，当一个随机变量变换成另一个随机变量

时，如何由原来随机变量的概率分布来确定新随机变量的概率分布？在实际应用中也会遇到这样的问题：某些随机变量本身的概率分布很难获得（如滚珠体积的测量值），但是与它们有关的另一些随机变量（如滚珠直径的测量值），其分布往往容易获得.因此，需要研究相关随机变量之间的关系，并用已知随机变量的分布来求出与之有关的另一个随机变量的分布.

定义 2.5 记随机变量 X 的一切可能值集合为 D，设 $g(x)$ 是定义在 D 上的单值实函数[①]，若对于 X 的每一个可能值 $x \in D$，随机变量 Y 相应地取值 $y=g(x)$，则称 Y **为 X 的函数**，记为 $Y=g(X)$.

根据上述定义，如果 X 为随机变量，那么对一个普通的函数（映射）$g: D \to \mathbf{R}$，就能保证 $g(X)$ 仍为随机变量.

下面来研究随机变量函数的概率分布，就离散型与连续型两种情形分别展开讨论.

2.2.2 离散型随机变量的函数的概率分布

当已知离散型随机变量 X 的分布律时，要确定 $Y=g(X)$ 的分布律是比较容易的.

离散型随机变量的函数一定是离散型随机变量，只需求其分布律即可.

例 2.11 设离散型随机变量 X 的分布律为

X	-1	$-\frac{1}{2}$	0	$\frac{1}{2}$	1
p	$\frac{1}{8}$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{8}$	$\frac{1}{4}$

求：(1) 随机变量 $Y=2X$ 的分布律；(2) 随机变量 $Y=4X^2$ 的分布律.

解 (1) 因为 $Y=2X$ 的可能取值为 $-2,-1,0,1,2$，且有

$$P\{Y=-2\}=P\{X=-1\}=\frac{1}{8}$$

$$P\{Y=-1\}=P\left\{X=-\frac{1}{2}\right\}=\frac{1}{4}$$

$$P\{Y=0\}=P\{X=0\}=\frac{1}{4}$$

$$P\{Y=1\}=P\left\{X=\frac{1}{2}\right\}=\frac{1}{8}$$

$$P\{Y=2\}=P\{X=1\}=\frac{1}{4}$$

所以 Y 的分布律为

Y	-2	-1	0	1	2
p	$\frac{1}{8}$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{8}$	$\frac{1}{4}$

① 假定该函数是连续函数或单调函数或分段单调函数.

(2) 因为 $Y=4X^2$ 的可能取值为 0,1,4,且有

$$P\{Y=0\}=P\{X=0\}=\frac{1}{4}$$

$$P\{Y=1\}=P\left\{\left\{X=-\frac{1}{2}\right\}\cup\left\{X=\frac{1}{2}\right\}\right\}=P\left\{X=-\frac{1}{2}\right\}+P\left\{X=\frac{1}{2}\right\}=\frac{1}{4}+\frac{1}{8}=\frac{3}{8}$$

$$P\{Y=4\}=P\{\{X=-1\}\cup\{X=1\}\}=P\{X=-1\}+P\{X=1\}=\frac{1}{8}+\frac{1}{4}=\frac{3}{8}$$

故 $Y=4X^2$ 的分布律为

Y	0	1	4
p	$\frac{1}{4}$	$\frac{3}{8}$	$\frac{3}{8}$

一般情况下,确定 $Y=g(X)$ 的分布律的方法在原则上与上例是一样的:把 $Y=g(X)$ 可能取的不同值找出来,再把与 Y 的某个可能值对应的所有 X 值的概率相加,即得 Y 取这个值的概率.

例 2.12 设离散型随机变量 X 的分布律为

X	1	2	…	n	…
p	$\frac{1}{2}$	$\left(\frac{1}{2}\right)^2$	…	$\left(\frac{1}{2}\right)^n$	…

求随机变量 $Y=\cos\left(\frac{\pi}{2}X\right)$ 的分布律.

解 因为

$$\cos\left(\frac{n\pi}{2}\right)=\begin{cases}-1, & n=2(2k-1),\\ 0, & n=2k-1,\\ 1, & n=2(2k),\end{cases}\qquad k=1,2,\cdots$$

所以 $Y=\cos\left(\frac{\pi}{2}X\right)$ 的可能取值为 $-1,0,1$.

由于 X 取值 $2,6,10,\cdots$ 都使对应的 Y 取 -1,根据上述方法得

$$P\{Y=-1\}=\left(\frac{1}{2}\right)^2+\left(\frac{1}{2}\right)^6+\left(\frac{1}{2}\right)^{10}+\cdots=\frac{1}{4\left(1-\frac{1}{16}\right)}=\frac{4}{15}$$

同理可得

$$P\{Y=0\}=\frac{1}{2}+\left(\frac{1}{2}\right)^3+\left(\frac{1}{2}\right)^5+\cdots=\frac{1}{2\left(1-\frac{1}{4}\right)}=\frac{2}{3}$$

$$P\{Y=1\}=\left(\frac{1}{2}\right)^4+\left(\frac{1}{2}\right)^8+\left(\frac{1}{2}\right)^{12}+\cdots=\frac{1}{16\left(1-\frac{1}{16}\right)}=\frac{1}{15}$$

故 Y 的分布律为

Y	-1	0	1
p	$\frac{4}{15}$	$\frac{2}{3}$	$\frac{1}{15}$

2.2.3 连续型随机变量的函数的概率分布

在应用中,更常见的是连续型随机变量的函数.设 X 为连续型随机变量,已知 $f_X(x)$ 为其概率密度.对于随机变量 $Y=g(X)$,应当如何确定 Y 的概率密度 $f_Y(y)$ 呢?先看一个简单例子.

连续型随机变量的函数可能是离散型随机变量(见习题2第30、31题),也可能是连续型随机变量(例2.13).

例 2.13 设连续型随机变量 X 具有概率密度 $f_X(x)$,求随机变量 $Y=kX+b$(其中 k,b 为常数且 $k\neq 0$)的概率密度 $f_Y(y)$.

解 因对任意区间 $A=[c,d]\subset\{y\mid y=kx+b,x\in\mathbf{R}\}$,当 $k>0$ 时,有

$$P\{Y\in A\}=P\left\{\frac{c-b}{k}\leqslant X\leqslant\frac{d-b}{k}\right\}=\int_{\frac{c-b}{k}}^{\frac{d-b}{k}}f_X(x)\,\mathrm{d}x=\int_c^d f_X\left(\frac{t-b}{k}\right)\frac{1}{k}\mathrm{d}t$$

因 $f_X\left(\frac{y-b}{k}\right)\frac{1}{k}$ 为非负可积函数,故由概率密度的定义可知

$$f_Y(y)=f_X\left(\frac{y-b}{k}\right)\frac{1}{k}$$

当 $k<0$ 时,有

$$\begin{aligned}P\{Y\in A\}&=P\left\{\frac{d-b}{k}\leqslant X\leqslant\frac{c-b}{k}\right\}=\int_{\frac{d-b}{k}}^{\frac{c-b}{k}}f_X(x)\,\mathrm{d}x=\int_d^c f_X\left(\frac{t-b}{k}\right)\frac{1}{k}\mathrm{d}t\\&=\int_c^d f_X\left(\frac{t-b}{k}\right)\left(-\frac{1}{k}\right)\mathrm{d}t\end{aligned}$$

因 $k<0$,得 $-\frac{1}{k}>0$,即积分号下的被积函数仍是非负可积的,故

$$f_Y(y)=f_X\left(\frac{y-b}{k}\right)\left(-\frac{1}{k}\right)$$

综上所述,Y 的概率密度为

$$f_Y(y)=f_X\left(\frac{y-b}{k}\right)\frac{1}{|k|}(k\neq 0)$$

由上例可知,若随机变量 $X\sim N(\mu,\sigma^2)$,则 $Y=kX+b\sim N(k\mu+b,k^2\sigma^2)(k\neq 0)$,即正态随机变量的线性函数仍然服从正态分布.

一般地,有以下定理:

定理 2.1 设随机变量 X 具有概率密度 $f_X(x)$,若 $g(x)$ 为 $(-\infty,+\infty)$(即实数域 $\mathbf{R}$)上的可导函数,并且,恒有 $g'(x)>0$(或恒有 $g'(x)<0$).记 $h(y)$ 为 $g(x)$ 的反函数,则 $Y=g(X)$ 是连续型随机变量,其概率密度为

$$f_Y(y)=\begin{cases}f_X(h(y))\,|h'(y)|, & y\in g(\mathbf{R}),\\0, & \text{其他}\end{cases}\tag{2.2.1}$$

其中 $g(\mathbf{R})=\{g(x)\mid x\in(-\infty,+\infty)\}$ 为 $g(x)$ 的值域.

定理 2.1 的证明可参照例 2.13 的解题方法来进行(留给读者作为练习).

如果 $f_X(x)$ 在区间 $[a,b]$ 以外恒为零,那么定理 2.1 中的条件可改为:在 $[a,b]$ 上恒有 $g'(x)>0$(或恒有 $g'(x)<0$).定理的结论依然成立,但要把 $g(\mathbf{R})$ 换成 $g([a,b])$,这里 $g([a,b])=\{g(x)\mid x\in[a,b]\}$.

例 2.14 设随机变量 $X\sim N(\mu,\sigma^2)$,令 $Y=e^X$,求 Y 的概率密度 $f_Y(y)$.

解 因 e^x 满足定理 2.1 中的条件,当 $y>0$ 时,$y=e^x$ 的反函数为 $x=\ln y$,所以由定理 2.1 可知

$$f_Y(y)=\begin{cases}\dfrac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(\ln y-\mu)^2}{2\sigma^2}}\left|\dfrac{1}{y}\right|, & y>0,\\ 0, & y\leqslant 0\end{cases}$$

$$=\begin{cases}\dfrac{1}{\sqrt{2\pi}y\sigma}e^{-\frac{(\ln y-\mu)^2}{2\sigma^2}}, & y>0,\\ 0, & y\leqslant 0\end{cases}$$

通常,称具有上述概率密度的随机变量 Y 服从**对数正态分布**,对数正态分布在工程技术、生物学、医学等领域有广泛的应用.

如果 $g(x)$ 不是单调函数,那么情况就较为复杂.下面我们通过一个例题来介绍解决这类问题的基本思想.

例 2.15 设随机变量 $X\sim N(0,1)$,求 $Y=X^2$ 的概率密度.

解 因 x^2 在 $(-\infty,+\infty)$ 上不是单调函数,故不能用定理 2.1.注意到 $Y=X^2$ 总取非负值,因此,当 $y<0$ 时,可得 Y 的分布函数

$$F_Y(y)=P\{Y\leqslant y\}=P\{X^2\leqslant y\}=P(\varnothing)=0$$

当 $y\geqslant 0$ 时,

$$F_Y(y)=P\{Y\leqslant y\}=P\{X^2\leqslant y\}=P\{-\sqrt{y}\leqslant X\leqslant\sqrt{y}\}$$

$$=\int_{-\sqrt{y}}^{\sqrt{y}}f_X(x)\,dx=\frac{1}{\sqrt{2\pi}}\int_{-\sqrt{y}}^{\sqrt{y}}e^{-\frac{x^2}{2}}dx$$

因而,在 $y\neq 0$ 处,$F_Y(y)$ 为可导函数,其导数为

$$F_Y'(y)=\begin{cases}f_X(\sqrt{y})\dfrac{1}{2\sqrt{y}}-f_X(-\sqrt{y})\left(-\dfrac{1}{2\sqrt{y}}\right), & y>0,\\ 0, & y<0\end{cases}$$

$$=\begin{cases}\dfrac{1}{\sqrt{2\pi}}y^{-\frac{1}{2}}e^{-\frac{y}{2}}, & y>0,\\ 0, & y<0\end{cases}$$

令

$$f_Y(y)=\begin{cases}\dfrac{1}{\sqrt{2\pi}}y^{-\frac{1}{2}}e^{-\frac{y}{2}}, & y>0,\\ 0, & y\leqslant 0\end{cases}$$

不难验证上述 $f_Y(y)$ 与 $F_Y(y)$ 满足关系式 $F_Y(y)=\int_{-\infty}^{y}f_Y(t)\,dt$,因而,$f_Y(y)$ 即为所求.

一般地,求 $Y=g(X)$ 的概率密度的步骤是:(1) 求出 Y 的分布函数 $F_Y(y)$;(2) 求 $F_Y(y)$ 的导函数 $F_Y'(y)$;(3) 令 $f_Y(y)=F_Y'(y)$,并在 $F_Y(y)$ 的不可导点处规定 $f_Y(y)$ 的函数值为零.于是,$f_Y(y)$ 就是 Y 的概率密度.

例 2.16 若随机变量 X 的分布函数 $F(x)$ 为连续函数且严格单调增,证明:$Y=F(X)$ 是服从均匀分布 $U(0,1)$ 的随机变量.

证 由定义 2.5 知 $Y=F(X)$ 为随机变量,下面考察 Y 的分布函数 $F_Y(y)$.

当 $y<0$ 时,因 $F(x)\geqslant 0$,故

$$F_Y(y)=P\{Y\leqslant y\}=P\{F(X)\leqslant y\}=0$$

当 $0\leqslant y<1$ 时,因 $F(x)$ 为严格单调增函数,其必有反函数 $F^{-1}(y)$,故

$$F_Y(y)=P\{Y\leqslant y\}=P\{F(X)\leqslant y\}=P\{X\leqslant F^{-1}(y)\}=F(F^{-1}(y))=y$$

当 $y\geqslant 1$ 时,因 $F(x)\leqslant 1$,故

$$F_Y(y)=P\{Y\leqslant y\}=P\{F(X)\leqslant y\}=1$$

亦即

$$F_Y(y)=\begin{cases}0, & y<0,\\ y, & 0\leqslant y<1,\\ 1, & y\geqslant 1\end{cases}$$

这正是均匀分布 $U(0,1)$ 的分布函数,因而 $Y\sim U(0,1)$.

根据例 2.16 的结论,我们可用服从均匀分布 $U(0,1)$ 的随机数 u 来生成分布函数为 $F(x)$ 的随机数 x,做法是:令 $x=F^{-1}(u)$.

例如随机变量 $X\sim Exp(\lambda)$,指数分布 $Exp(\lambda)$ 的分布函数 $F(x)=1-e^{-\lambda x}(x\geqslant 0)$ 为严格单调增函数,存在反函数 $F^{-1}(u)=-\dfrac{\ln(1-u)}{\lambda}$.如果 u 是服从均匀分布 $U(0,1)$ 的随机数(可以很方便地用计算机甚至计算器生成),令 $x=F^{-1}(u)=-\dfrac{\ln(1-u)}{\lambda}$,那么 x 便是参数为 λ 的指数分布的随机数.

在 MATLAB 软件提供了一些命令生成服从常见分布的随机数,如 unifrnd(a,b) 表示产生服从均匀分布 $U(a,b)$ 的随机数.rand(m,n) 表示产生服从均匀分布 $U(0,1)$ 上的 $m\times n$ 随机数矩阵,normrnd(MU,SIGMA) 表示产生服从正态分布 $N(\mu,\sigma^2)$ 的随机数等.应用例 2.16 的结论,可以生成分布函数为 $F(x)$ 的随机数 x.

内容小结

1. 随机变量及分布函数

设 E 为一随机试验,Ω 为它的样本空间,若 $X=X(\omega)$,$\omega\in\Omega$ 为单值实函数,且对于任意实数 x,集合 $\{\omega\mid X(\omega)\leqslant x\}$ 都是随机事件,则称 X 为随机变量.

设 X 是一随机变量,称

$$F(x)=P\{X\leqslant x\},\ -\infty<x<+\infty$$

为随机变量 X 的分布函数.X 落入任何区间的概率都可用分布函数表示.

分布函数具有下列基本性质:

(1) $F(x)$ 是 x 的单调增函数,即 $x_1<x_2$ 时,有 $F(x_1)\leqslant F(x_2)$;

(2) $F(x)$ 是 x 的右连续函数;

(3) 对任意实数 x,$0\leqslant F(x)\leqslant 1$,且 $F(-\infty)=\lim\limits_{x\to-\infty}F(x)=0$,$F(+\infty)=\lim\limits_{x\to+\infty}F(x)=1$.

如果一个函数满足上述三条性质,那么这个函数一定是某个随机变量的分布函数,因此可用这三条性质判别一个函数是否是分布函数.

2. 离散型随机变量及其分布律

若随机变量 X 的所有可能取值为有限个或可数个,则称 X 为离散型随机变量.

设 X 为离散型随机变量,其所有可能取值为 $x_k(k=1,2,\cdots)$,则

$$p_k=P\{X=x_k\}\ (k=1,2,\cdots)$$

称为 X 的分布律(或概率函数).

分布律具有性质:(1) $p_k\geqslant 0(k=1,2,\cdots)$;(2) $\sum\limits_{k=1}^{\infty}p_k=1$.

这两个性质也可以用来验证 $p_k(k=1,2,\cdots)$ 是不是某离散型随机变量的分布律.

给定离散型随机变量的分布律,其分布函数为

$$F(x)=\sum_{x_k\leqslant x}P\{X=x_k\}=\sum_{x_k\leqslant x}p_k$$

常见的几种离散型随机变量及其分布律:

(1) 单点分布 $\begin{pmatrix}a\\1\end{pmatrix}$:$P\{X=a\}=1$.

(2) (0-1)分布 $B(1,p)$:$P\{X=k\}=p^k(1-p)^{1-k}(k=0,1)$.

(3) 二项分布 $B(n,p)$:$P\{X=k\}=C_n^k p^k(1-p)^{n-k}(k=0,1,2,\cdots,n)$.

(4) 泊松分布 $P(\lambda)$:$P\{X=k\}=\dfrac{\lambda^k}{k!}e^{-\lambda}(k=0,1,2,\cdots),\lambda>0$.

(5) 几何分布 $Ge(p)$:$P\{X=k\}=(1-p)^{k-1}p(k=1,2,3,\cdots)$.

3. 连续型随机变量及其分布

设 X 为随机变量,若存在非负可积函数 $f(x)$,使得对任意区间 $A\subset\mathbf{R}$,都有

$$P\{X\in A\}=\int_A f(x)\,dx$$

则称 X 为连续型随机变量,并称 $f(x)$ 为 X 的概率密度.

概率密度具有基本性质:(1) $f(x)\geqslant 0,-\infty<x<+\infty$;(2) $\int_{-\infty}^{+\infty}f(x)\,dx=1$.

这两条基本性质也用来验证函数 $f(x)$ 是不是某个连续型随机变量的概率密度.

连续型随机变量的分布函数 $F(x)=\int_{-\infty}^{x}f(t)\,dt$ 是连续函数.

连续型随机变量取任何实数的概率都是零.

常见的几种连续型随机变量及其概率密度:

(1) 正态分布 $N(\mu,\sigma^2)$:$f(x)=\dfrac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}},-\infty<x<+\infty$.

标准正态分布 $N(0,1)$:$\varphi(x)=\dfrac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}},-\infty<x<+\infty$,其分布函数 $\Phi(x)$ 满足 $\Phi(-x)=1-\Phi(x)$,$\Phi(0)=0.5$.

若随机变量 $X\sim N(\mu,\sigma^2)$,则 $\dfrac{X-\mu}{\sigma}\sim N(0,1)$.

(2) 均匀分布 $U(a,b)(a<b)$:$f(x)=\begin{cases}\dfrac{1}{b-a}, & a\leqslant x\leqslant b,\\ 0, & \text{其他},\end{cases}$ 分布函数 $F(x)=\begin{cases}0, & x<a,\\ \dfrac{x-a}{b-a}, & a\leqslant x<b,\\ 1, & x\geqslant b.\end{cases}$

(3) 指数分布 $Exp(\lambda)$:$f(x)=\begin{cases}\lambda e^{-\lambda x}, & x\geqslant 0,\\ 0, & x<0,\end{cases}$ 分布函数 $F(x)=\begin{cases}1-e^{-\lambda x}, & x\geqslant 0,\\ 0, & x<0.\end{cases}$

若 $X\sim Exp(\lambda)$,则对任意的 $s>0,t>0$,$P\{X>s+t\mid X>s\}=P\{X>t\}$.

4. 随机变量的函数及其概率分布

设 X 为随机变量,$g(x)$ 是单值实函数(假定该函数是连续函数或单调函数或分段单调函数),则 $Y=g(X)$ 仍为随机变量.

若 X 为离散型随机变量,则 $Y=g(X)$ 也是离散型随机变量,求其分布律.

若 X 为连续型随机变量,则 $Y=g(X)$ 的取值可能离散也可能连续.如果 Y 是离散型随机变量,求其分布律.如果 Y 不是离散型随机变量,那么求其分布函数.若 Y 是连续型随机变量,则还可以求其概率密度.

设随机变量 X 具有概率密度 $f_X(x)$,若 $g(x)$ 为 $(-\infty,+\infty)$(即实数域 $\mathbf{R}$)上的可导函数,并且,恒有 $g'(x)>0$(或恒有 $g'(x)<0$).记 $h(y)$ 为 $g(x)$ 的反函数,则 $Y=g(X)$ 是连续型随机变量,其概率密度为

$$f_Y(y)=\begin{cases}f_X(h(y))\mid h'(y)\mid, & y\in g(\mathbf{R}),\\ 0, & \text{其他}\end{cases}$$

其中 $g(\mathbf{R})=\{g(x)\mid x\in(-\infty,+\infty)\}$ 为 $g(x)$ 的值域.

特别地,若随机变量 $X\sim N(\mu,\sigma^2)$,则 $Y=kX+b\sim N(k\mu+b,k^2\sigma^2)$,其中 $k\neq 0$.

习题 2

1. 袋中有 6 个分别标着数字 $-1,-1,1,1,1,3$ 的球.现从袋中任取一个球,设随机变量 X 表示取到的球上标着的数字.求:

(1) X 的分布函数;

(2) $P\{X\leqslant 0\}$,$P\{-1<X\leqslant 2\}$ 及 $P\{-1\leqslant X\leqslant 2\}$.

2. 射击用的靶子是半径为 R 的圆盘,已知每次射击均能击中靶,且击中靶上任一个以靶心为圆心的小圆盘上的概率与该小圆盘的面积成正比.设随机变量 X 表示弹着点与圆心的距离,试求 X 的分布函数.

3. 设 $F_1(x)$,$F_2(x)$ 为两个分布函数.

(1) $F_1(x)+F_2(x)$ 是不是分布函数?

(2) 若 $a_1>0,a_2>0$ 均为常数且 $a_1+a_2=1$,证明 $a_1F_1(x)+a_2F_2(x)$ 为分布函数;

(3) 证明 $F_1(x)F_2(x)$ 为分布函数.

4. 设随机变量 X 的分布函数为

$$F(x)=A+B\arctan x\ (-\infty<x<+\infty)$$

求:

(1) 常数 A 及 B;

(2) 随机变量 X 落在区间 $(-1,1]$ 内的概率.

5.（1）设离散型随机变量 X 的分布律为

$$P\{X=k\}=\frac{a}{k!}(k=0,1,2,\cdots)$$

试确定常数 a；

（2）设离散型随机变量 X 的分布律为

$$P\{X=k\}=\frac{a}{k(k+1)}\ (k=1,2,\cdots,N)$$

试确定常数 a.

6. 设离散型随机变量 X 的分布函数为

$$F(x)=\begin{cases}0, & x<-1,\\ 0.125, & -1\leqslant x<0,\\ 0.625, & 0\leqslant x<0.5,\\ 0.875, & 0.5\leqslant x<1,\\ 1, & x\geqslant 1\end{cases}$$

试写出 X 的分布律.

7. 一箱产品中有 8 件正品、2 件次品，使用时从箱中任取一件，如果每次取出的次品不再放回箱中，求在取到正品以前已取出的次品数 X 的分布律及分布函数.

8. 设袋中有 15 个球，其中只有 3 个是白色的.每次从袋中任取一个球，接连取 5 次.设 X 表示 5 次中取到白球的次数，试按下述两种情况求随机变量 X 的分布律：

（1）每次取后不放回；

（2）每次取后放回.

9. 设事件 A 在每次试验中发生的概率为 0.3，当 A 发生不少于 3 次时，指示灯发出信号.求：

（1）进行了 5 次独立试验，指示灯发出信号的概率；

（2）进行了 7 次独立试验，指示灯发出信号的概率.

10. 某射手在每次射击中能击中目标的概率为 0.8，现连续射击：

（1）直至第一次击中目标为止；

（2）直至第 $r(r\geqslant 1)$ 次击中目标为止，

求射击次数 X 的分布律.

11. 某电话交换台每分钟的呼唤次数服从参数为 4 的泊松分布.求：

（1）每分钟恰有 6 次呼唤的概率；

（2）每分钟呼唤次数为 5 至 10 的概率.

12. 某复杂系统由 500 个相互独立起作用的部件组成，在整个运行期间，每个部件损坏的概率为 0.005.求在整个运行期间最多有 5 个部件损坏的概率.

13. 设 X 服从二项分布，其分布律为

$$P\{X=k\}=C_n^k p^k q^{n-k}(k=0,1,2,\cdots,n)$$

其中 $0<p<1$，$q=1-p$.

（1）k 取何值时，$P\{X=k\}$ 最大？

（2）p 为何值时，$P\{X=k\}=P\{X=n-k\}(k=0,1,2,\cdots,n)$？

14.（1）设 X 服从参数为 $\lambda(\lambda>0)$ 的泊松分布，其分布律为

$$P\{X=k\}=\frac{\lambda^k}{k!}e^{-\lambda}(k=0,1,2,\cdots)$$

当 k 取何值时，$P\{X=k\}$ 最大？

（2）在第 11 题中，最可能的呼唤次数是多少？

15. 甲、乙两选手轮流投篮，直至有一个投中为止，若甲每次投篮命中的概率为 0.7，乙每次投篮命中的概率为 0.8. 如果甲首先投篮，求：

（1）两人投篮总次数 X 的分布律；

（2）甲投篮次数 X 的分布律；

（3）乙投篮次数 X 的分布律.

16. 连续型随机变量 X 的概率密度为

$$f(x)=Ae^{-|x|}(-\infty<x<+\infty)$$

求：

（1）常数 A；

（2）X 落在区间 $(-1,2)$ 内的概率；

（3）X 的分布函数.

17. 设随机变量 X 的概率密度为

$$f(x)=\begin{cases}\dfrac{A}{\sqrt{1-x^2}}, & |x|<1,\\ 0, & |x|\geqslant 1\end{cases}$$

求：

（1）常数 A；

（2）X 落在区间 $\left[-\dfrac{1}{2},\dfrac{1}{2}\right]$ 上的概率；

（3）X 的分布函数.

18.（1）求第 4 题中随机变量 X 的概率密度；

（2）设随机变量 X 的分布函数为

$$F(x)=\begin{cases}0, & x<1,\\ \ln x, & 1\leqslant x<e,\\ 1, & x\geqslant e\end{cases}$$

求 X 的概率密度.

19. 设随机变量 X 服从正态分布 $N(\mu,\sigma^2)$，$F(x)$ 为其分布函数. 试证明：对任何实数 x，有 $F(x)=1-F(2\mu-x)$，从而有 $F(\mu)=0.5$；而且，当 X 服从标准正态分布时，有 $\Phi(x)=1-\Phi(-x)$，$\Phi(0)=0.5$.

20. 设随机变量 X 服从正态分布 $N(-2,9)$，求：

（1）$P\{X>-1\}$；　　（2）$P\{-5\leqslant X\leqslant 3\}$；

（3）$P\{0<X<5\}$；　　（4）$P\{|X|>1\}$；

（5）$P\{|X+2|<4\}$；　　（6）满足 $P\{|X-a|<a\}=0.01$ 的常数 a.

21. 设随机变量 X 在区间 $[0,5]$ 上服从均匀分布，求关于实变量 t 的二次方程 $t^2+2(X-3)t+X^2=0$ 有实根的概率.

22. 已知某种类型的电子元件的使用寿命 X（单位：h）服从参数为 0.001 的指数分布，一台仪器中装有 3 只此类型的元件，其中任一只损坏仪器便不能正常工作，且每只元件是否损坏是相互独立的，求仪器的使用寿命在 1 000 h～1 500 h 的概率.

23. 设随机变量 X 的概率密度为 $f(x)=\begin{cases}2x, & 0<x<1,\\ 0, & \text{其他},\end{cases}$ 以 Y 表示对 X 进行三次独立观察中 $\left\{X\leqslant\dfrac{1}{2}\right\}$ 出现的次数，求：

（1）Y 的分布律；（2）$P\{Y=2\}$.

24. 设离散型随机变量 X 的分布律为

X	-2	-1	0	1	2	3
p	$\frac{1}{15}$	$\frac{1}{10}$	$\frac{1}{6}$	$\frac{1}{3}$	$\frac{3}{10}$	$\frac{1}{30}$

求下列随机变量的分布律：

(1) $Y_1=2^X$；　　(2) $Y_2=|1-2X|$；

(3) $Y_3=1-X^2$；　　(4) $Y_4=\cos\frac{\pi X}{4}$.

25. 把一枚均匀硬币随机地抛掷五次，求正面向上次数与反面向上次数之积的分布律.

26. 设随机变量 X 服从参数为 $\lambda(\lambda>0)$ 的指数分布，求下列随机变量的概率密度：

(1) $Y_1=X^3$；　　(2) $Y_2=e^{-\lambda X}$.

27. 设随机变量 X 在区间 $\left(-\frac{\pi}{2},\frac{\pi}{2}\right)$ 内服从均匀分布，求下列随机变量的概率密度：

(1) $Y_1=\tan X$；　　(2) $Y_2=\cos X$.

28. 设随机变量 X 服从正态分布 $N(\mu,\sigma^2)$，求随机变量 $Y=|X-\mu|$ 的概率密度.

29. 在半径为 R、中心在坐标原点的圆周上任取一点（即该点的极角为在 $[-\pi,\pi]$ 上服从均匀分布的随机变量），求：

(1) 该点的纵坐标的概率密度；

(2) 连接该点与点 $(R,0)$ 所成的弦的长度 l 的概率密度.

30. 设随机变量 $X\sim U(0,2)$，令 $Y=\min\{X,1\}=\begin{cases}X, & X<1,\\ 1, & X\geqslant 1,\end{cases}$ 求 Y 的分布函数 $F_Y(y)$.

31. 设 X 服从参数为 λ 的指数分布，令 $Y=[X]+1$，其中 $[x]$ 为不超过 x 的最大整数，求 Y 的分布.

自测题 2

习题 2 参考答案

第3章 随机向量及其概率分布

在上一章，我们讨论了随机变量及其概率分布.本章将介绍随机向量，联合分布与边缘分布，反映随机变量之间相依性的条件分布，随机变量的独立性，随机向量的函数及其概率分布等内容.

3.1 n 维随机向量

3.1.1 随机向量的概念

在实际问题中，有些试验的结果需要同时用两个或两个以上的随机变量来描述.例如，热带风暴中心的位置需要用经度与纬度来描述.又如，在制定我国的服装标准时，需对人体的多个部位进行测量，上身长、臂长、胸围、下肢长、腰围、臀围等都要考察.这类例子可以举出很多.对于同一个试验结果的各个随机变量之间，一般有某种联系，因而需要把它们作为一个整体来研究.

定义 3.1 设 Ω 是随机试验 E 的样本空间，ω 为样本点，而 $X_1(\omega), X_2(\omega), \cdots, X_n(\omega)$ 是定义在 Ω 上的 n 个随机变量，则 n 维向量 $(X_1(\omega), X_2(\omega), \cdots, X_n(\omega))$ 称为 **n 维随机向量**或 **n 维随机变量**.

在上述定义中有三点需要注意：

(1) 随机向量 $(X_1(\omega), X_2(\omega), \cdots, X_n(\omega))$ 中的每一个分量 $X_i(\omega)$ $(1 \leqslant i \leqslant n)$ 是一维随机变量.

(2) 实际上，随机向量 $(X_1(\omega), X_2(\omega), \cdots, X_n(\omega))$ 是从样本空间 Ω 到 n 维欧氏空间 $\mathbf{R}^n$ 的一个映射：$\omega \in \Omega \mapsto (X_1(\omega), X_2(\omega), \cdots, X_n(\omega)) \in \mathbf{R}^n$.

(3) 随机向量的所有分量中包含的 ω 是同一个 ω.举例来说，如果某个样本空间 $\Omega = \{\omega_1, \omega_2\}$，$X(\omega) = \begin{cases} 1, \omega = \omega_1, \\ 0, \omega = \omega_2, \end{cases}$ $Y(\omega) = \begin{cases} 0, \omega = \omega_1, \\ 1, \omega = \omega_2 \end{cases}$ 是定义在 Ω 上的两个随机变量，那么随机向量 $(X(\omega), Y(\omega))$ 把样本空间 Ω 映射成平面上的两个点 $(1,0)$，$(0,1)$，而不是四个点.

今后在不必强调样本点 ω 时，常把 $(X_1(\omega), X_2(\omega), \cdots, X_n(\omega))$ 简记为 $(X_1, X_2, \cdots, X_n)$.

因为 $n(n \geqslant 3)$ 维随机向量和二维随机向量的研究方法及所得结论无实质的差别，所以为简单起见，本教材主要讨论二维随机向量，有关内容都可以类推到 $n(n \geqslant 3)$ 维的情形，不同之处本教材也会特别说明.

3.1.2 分布函数与边缘分布函数

定义 3.2 设 (X, Y) 是二维随机向量，对任意实数 x, y，二元函数

$$F(x, y) = P\{X \leqslant x, Y \leqslant y\} \tag{3.1.1}$$

称为二维随机向量 (X, Y) 的分布函数，或 X 与 Y 的联合分布函数.

这里，

$$\{X\leqslant x,Y\leqslant y\}=\{\omega\mid X(\omega)\leqslant x,Y(\omega)\leqslant y\},$$

因此，分布函数 $F(x,y)$ 是事件 $\{X\leqslant x\}$ 与 $\{Y\leqslant y\}$ 同时发生的概率.

若把二维随机向量 (X,Y) 看作是平面上的随机点的坐标，则分布函数 $F(x,y)$ 在 (x,y) 处的函数值，就是随机点 (X,Y) 落入以点 (x,y) 为顶点而位于该点左下方的无穷矩形域内（如图 3.1 所示的阴影部分）的概率.

由上述几何解释并借助图 3.2，不难算出事件 $\{x_1<X\leqslant x_2,y_1<Y\leqslant y_2\}$ 的概率

$$P\{x_1<X\leqslant x_2,y_1<Y\leqslant y_2\}=F(x_2,y_2)-F(x_2,y_1)-F(x_1,y_2)+F(x_1,y_1) \tag{3.1.2}$$

性质(2)—(4)是分布函数 $F(x,y)$ 的基本性质. 反之，如果一个二元函数 $F(x,y)$ 满足性质(2)—(4)，那么它一定是某二维随机向量 (X,Y) 的分布函数.

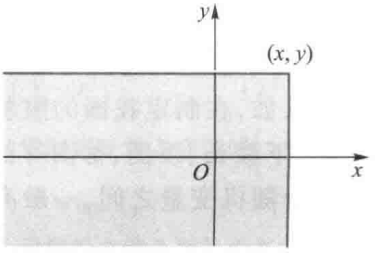

图 3.1

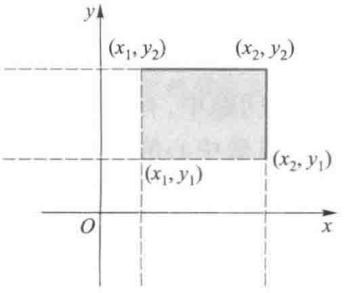

图 3.2

分布函数 $F(x,y)$ 具有以下性质：

(1) $F(x,y)$ 对每个变量是单调增函数，即当 $x_1<x_2$ 时，$F(x_1,y)\leqslant F(x_2,y)$；当 $y_1<y_2$ 时，$F(x,y_1)\leqslant F(x,y_2)$.

(2) $F(x,y)$ 对每个变量是右连续的，即 $F(x+0,y)=F(x,y)$，$F(x,y+0)=F(x,y)$.

(3) $F(-\infty,y)=F(x,-\infty)=F(-\infty,-\infty)=0$，$F(+\infty,+\infty)=1$.

(4) 对任意两点 (x_1,y_1)，(x_2,y_2)，若 $x_1\leqslant x_2,y_1\leqslant y_2$，则

$$F(x_2,y_2)-F(x_2,y_1)-F(x_1,y_2)+F(x_1,y_1)\geqslant 0$$

性质(1)—(3)可仿照一维随机变量情形给予证明. 对于性质(4)，因为不等式左边就是 $P\{x_1<X\leqslant x_2,y_1<Y\leqslant y_2\}$，所以结论显然成立.

注意：$F_X(x)$ 是随机变量 X 的分布函数，对随机变量 Y 没有限制，那么 Y 应取 $(-\infty,+\infty)$ 中的任意实数.

若给定二维随机向量 (X,Y) 的分布函数 $F(x,y)$，则它的两个分量 X,Y 的分布函数 $F_X(x)$，$F_Y(y)$ 与分布函数 $F(x,y)$ 之间必然存在联系. 事实上，

$$F_X(x)=P\{X\leqslant x\}=P\{X\leqslant x,Y<+\infty\}=\lim_{y\to+\infty}P\{X\leqslant x,Y\leqslant y\}$$
$$=\lim_{y\to+\infty}F(x,y)=F(x,+\infty)$$

即

$$F_X(x)=F(x,+\infty) \tag{3.1.3}$$

称 $F_X(x)$ 为二维随机向量 (X,Y) 关于 X 的**边缘分布函数**.

同理可得

$$F_Y(y)=F(+\infty,y) \tag{3.1.4}$$

称 $F_Y(y)$ 为二维随机向量 (X,Y) 关于 Y 的**边缘分布函数**.

由上面的讨论可知，边缘分布函数 $F_X(x)$，$F_Y(y)$ 完全由分布函数 $F(x,y)$ 唯一确定，但反过来并不一定成立（参见后面的例 3.1）.

值得说明的是，对于三维及以上随机向量，除了定义一维边缘分布函数，还可以定义 k 维边缘分布函数 $(1<k<n)$. 如对于三维随机向量 (X,Y,Z)，除了有 3 个一维随

机变量 X,Y,Z 对应的边缘分布函数 $F_X(x),F_Y(y),F_Z(z)$ 外，若子向量 (X,Y)，(Y,Z)，(X,Z)（这里不改变分量的原有顺序）分别有分布函数 $F_{X,Y}(x,y)$，$F_{Y,Z}(y,z),F_{X,Z}(x,z)$，则称 $F_{X,Y}(x,y),F_{Y,Z}(y,z),F_{X,Z}(x,z)$ 是三维随机向量 (X,Y,Z) 的 3 个二维边缘分布函数，称 $F_X(x),F_Y(y),F_Z(z)$ 是三维随机向量 (X,Y,Z) 的 3 个一维边缘分布函数. 而且，

$$F_{X,Y}(x,y)=F(x,y,+\infty),F_{Y,Z}(y,z)=F(+\infty,y,z),F_{X,Z}(x,z)=F(x,+\infty,z)$$

$$F_X(x)=F(x,+\infty,+\infty),F_Y(y)=F(+\infty,y,+\infty),F_Z(z)=F(+\infty,+\infty,z)$$

与随机变量类似，二维随机向量主要有离散型与连续型两类.

3.1.3 二维离散型随机向量

定义 3.3 若二维随机向量 (X,Y) 的所有可能取的值是有限对或可数对 (x_i,y_j) $(i,j=1,2,\cdots)$，则称 (X,Y) 是**二维离散型随机向量**，并称 $P\{X=x_i,Y=y_j\}=p_{ij}(i,j=1,2,\cdots)$ 为二维离散型随机向量 (X,Y) 的**分布律**或 X 与 Y 的联合分布律.

由 p_{ij} 的定义结合概率的性质可知，它应满足：

(1) $0\leqslant p_{ij}\leqslant 1 \quad (i,j=1,2,\cdots)$； (3.1.5)

(2) $\sum\limits_{i=1}^{\infty}\sum\limits_{j=1}^{\infty}p_{ij}=1.$ (3.1.6)

二维离散型随机向量 (X,Y) 的分布律也可用下述形式的表格给出（表 3.1）.

表 3.1 (X,Y) 的分布律

p_{ij}		Y					$p_{i\cdot}$
		y_1	y_2	$\cdots$	y_m	$\cdots$	
X	x_1	p_{11}	p_{12}	$\cdots$	p_{1m}	$\cdots$	$p_{1\cdot}$
	x_2	p_{21}	p_{22}	$\cdots$	p_{2m}	$\cdots$	$p_{2\cdot}$
	$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$
	x_n	p_{n1}	p_{n2}	$\cdots$	p_{nm}	$\cdots$	$p_{n\cdot}$
	$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$
$p_{\cdot j}$		$p_{\cdot 1}$	$p_{\cdot 2}$	$\cdots$	$p_{\cdot m}$	$\cdots$	1

二维离散型随机向量的分布律满足性质(1)、(2)，反过来，若有 $p_{ij},i,j=1,2,\cdots$ 满足性质(1)、(2)，则它可以成为某二维离散型随机向量的分布律.

若已知二维离散型随机向量 (X,Y) 的分布律 $P\{X=x_i,Y=y_j\}=p_{ij}(i,j=1,2,\cdots)$，则 (X,Y) 的分布函数可按下式确定

$$F(x,y)=\sum_{x_i\leqslant x}\sum_{y_j\leqslant y}p_{ij} \tag{3.1.7}$$

其中和式是对所有满足 $x_i\leqslant x,y_j\leqslant y$ 的下标 i,j 求和.

思考：一维离散型随机变量的分布函数是阶梯形曲线，二维离散型随机变量的分布函数的图形是什么形状呢？

从 (X,Y) 的分布律出发，还可以求出它的两个分量 X,Y 的分布律.

$$\begin{aligned}P\{X=x_i\}&=P\{X=x_i,Y<+\infty\}\\&=P\{X=x_i,Y=y_1\}+P\{X=x_i,Y=y_2\}+\cdots\\&=\sum_{j=1}^{\infty}P\{X=x_i,Y=y_j\}\\&=\sum_{j=1}^{\infty}p_{ij}\quad(i=1,2,\cdots)\end{aligned}$$

同理

$$P\{Y=y_j\}=\sum_{i=1}^{\infty}p_{ij}\quad(j=1,2,\cdots)$$

若记

$$p_{i\cdot}=P\{X=x_i\}=\sum_{j=1}^{\infty}p_{ij}\quad(i=1,2,\cdots)\tag{3.1.8}$$

$$p_{\cdot j}=P\{Y=y_j\}=\sum_{i=1}^{\infty}p_{ij}\quad(j=1,2,\cdots)\tag{3.1.9}$$

则称 $p_{i\cdot}(i=1,2,\cdots)$ 和 $p_{\cdot j}(j=1,2,\cdots)$ 为 (X,Y) 关于 X 和关于 Y 的**边缘分布律**.因此,由 (X,Y) 的分布律可以唯一地确定 X 和 Y 的分布律 $p_{i\cdot}(i=1,2,\cdots)$ 和 $p_{\cdot j}(j=1,2,\cdots)$.但是,反之未必成立.

例 3.1 一袋中有 6 个大小相同的球,其中 2 个为红色,4 个为白色.每次从袋中任取一球,共取两次.定义随机变量 X,Y 如下:

$$X=\begin{cases}0, & \text{第一次取出红色球},\\ 1, & \text{第一次取出白色球}\end{cases}$$

$$Y=\begin{cases}0, & \text{第二次取出红色球},\\ 1, & \text{第二次取出白色球}\end{cases}$$

考虑两种取球方式:(1) 有放回取球;(2) 不放回取球.试就以上两种取球方式分别写出二维随机向量 (X,Y) 的分布律以及关于 X、关于 Y 的边缘分布律.

解 (1) 由事件的独立性,可得 (X,Y) 的分布律为

$$P\{X=0,Y=0\}=P\{X=0\}\times P\{Y=0\}=\frac{2}{6}\times\frac{2}{6}=\frac{1}{9}$$

$$P\{X=0,Y=1\}=P\{X=0\}\times P\{Y=1\}=\frac{2}{6}\times\frac{4}{6}=\frac{2}{9}$$

$$P\{X=1,Y=0\}=P\{X=1\}\times P\{Y=0\}=\frac{4}{6}\times\frac{2}{6}=\frac{2}{9}$$

$$P\{X=1,Y=1\}=P\{X=1\}\times P\{Y=1\}=\frac{4}{6}\times\frac{4}{6}=\frac{4}{9}$$

关于 X 的边缘分布律为

$$\begin{aligned}P\{X=0\}&=P\{X=0,Y=0\}+P\{X=0,Y=1\}\\&=\frac{1}{9}+\frac{2}{9}=\frac{1}{3}\end{aligned}$$

$$\begin{aligned}P\{X=1\}&=P\{X=1,Y=0\}+P\{X=1,Y=1\}\\&=\frac{2}{9}+\frac{4}{9}=\frac{2}{3}\end{aligned}$$

类似地可得关于 Y 的边缘分布律

$$P\{Y=0\}=\frac{1}{3}$$

$$P\{Y=1\}=\frac{2}{3}$$

(X,Y)的分布律以及关于 X、关于 Y 的边缘分布律如表 3.2 所示.

表 3.2 (X,Y)的分布律

p_{ij}		Y		$p_{i\cdot}$
		0	1	
X	0	$\frac{1}{9}$	$\frac{2}{9}$	$\frac{1}{3}$
	1	$\frac{2}{9}$	$\frac{4}{9}$	$\frac{2}{3}$
$p_{\cdot j}$		$\frac{1}{3}$	$\frac{2}{3}$	1

(2) 利用概率的乘法公式及条件概率的定义,可得二维随机向量(X,Y)的分布律

$$P\{X=0,Y=0\}=P\{X=0\}\times P\{Y=0\mid X=0\}=\frac{2}{6}\times\frac{1}{5}=\frac{1}{15}$$

$$P\{X=0,Y=1\}=P\{X=0\}\times P\{Y=1\mid X=0\}=\frac{2}{6}\times\frac{4}{5}=\frac{4}{15}$$

$$P\{X=1,Y=0\}=P\{X=1\}\times P\{Y=0\mid X=1\}=\frac{4}{6}\times\frac{2}{5}=\frac{4}{15}$$

$$P\{X=1,Y=1\}=P\{X=1\}\times P\{Y=1\mid X=1\}=\frac{4}{6}\times\frac{3}{5}=\frac{2}{5}$$

同(1)类似,把(X,Y)的分布律以及关于 X、关于 Y 的分布律如表 3.3 所示.

表 3.3 (X,Y)的分布律

p_{ij}		Y		$p_{i\cdot}$
		0	1	
X	0	$\frac{1}{15}$	$\frac{4}{15}$	$\frac{1}{3}$
	1	$\frac{4}{15}$	$\frac{2}{5}$	$\frac{2}{3}$
$p_{\cdot j}$		$\frac{1}{3}$	$\frac{2}{3}$	1

以上两表的中央部分是(X,Y)的分布律,表的边缘部分是关于 X 与 Y 的边缘分布律,它们由(X,Y)的分布律的同一行或同一列相加而得.因它们处于表的"边缘"位置,故称之为"边缘分布律".以上两表中的边缘分布是相同的,但(X,Y)的分布律是不同的.这说明(X,Y)的分布律不能由边缘分布律唯一地确定.

例 3.1 的结果表明,两种取球方式下,两次取到同一颜色球的概率是一样的.特别地,不放回取球下的结论再次验证了中签概率与抽签顺序无关.

3.1.4 二维连续型随机向量

定义 3.4 设(X,Y)是二维随机向量,若存在一个非负可积函数$f(x,y)$($-\infty<x<+\infty$,$-\infty<y<+\infty$),使对任意区域$A\subset\mathbf{R}^2$,都有

$$P\{(X,Y)\in A\}=\iint_A f(x,y)\,\mathrm{d}x\mathrm{d}y$$

则称(X,Y)为二维连续型随机向量,称$f(x,y)$为(X,Y)的概率密度,或X与Y的联合概率密度.

概率密度具有以下性质:

(1) $f(x,y)\geqslant 0,\forall(x,y)\in\mathbf{R}^2$;

(2) $\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}f(x,y)\,\mathrm{d}x\mathrm{d}y=1$;

(3) 设二维连续型随机向量(X,Y)的分布函数为$F(x,y)$,则对任意实数x,y,都有

$$F(x,y)=\int_{-\infty}^{x}\int_{-\infty}^{y}f(u,v)\,\mathrm{d}u\mathrm{d}v \tag{3.1.10}$$

(4) 若$f(x,y)$在点(x,y)的某邻域内连续,则

$$\frac{\partial^2 F(x,y)}{\partial x\partial y}=f(x,y)$$

在这里,性质(1),(2)是概率密度的基本性质.我们不加证明地指出:任何一个二元可积函数$g(x,y)$,若它满足性质(1),(2),则它可以成为某二维连续型随机向量的概率密度.

当给定二维连续型随机向量(X,Y)的概率密度$f(x,y)$,那么两个分量X和Y的概率密度$f_X(x)$,$f_Y(y)$也就随之确定.因为对任意区间$[a,b]\subset\mathbf{R}$,

$$P\{X\in[a,b]\}=P\{X\in[a,b],-\infty<Y<+\infty\}=\int_a^b\left[\int_{-\infty}^{+\infty}f(u,v)\,\mathrm{d}v\right]\mathrm{d}u$$

其中$\int_{-\infty}^{+\infty}f(x,y)\,\mathrm{d}y$为$x$的非负可积函数,所以$X$是一维连续型随机变量,且其概率密度为

$$f_X(x)=\int_{-\infty}^{+\infty}f(x,y)\,\mathrm{d}y \tag{3.1.11}$$

同理,Y也是一维连续型随机变量,其概率密度为

$$f_Y(y)=\int_{-\infty}^{+\infty}f(x,y)\,\mathrm{d}x \tag{3.1.12}$$

$f_X(x)$,$f_Y(y)$分别称为(X,Y)关于X、关于Y的边缘概率密度.

二维正态分布 若二维随机向量(X,Y)的概率密度为

$$f(x,y)=\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left\{\frac{-1}{2(1-\rho^2)}\left[\frac{(x-\mu_1)^2}{\sigma_1^2}-2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2}+\frac{(y-\mu_2)^2}{\sigma_2^2}\right]\right\}$$
$$(-\infty<x<+\infty,-\infty<y<+\infty) \tag{3.1.13}$$

其中$\mu_1,\mu_2,\sigma_1,\sigma_2,\rho$都是常数,且$\sigma_1>0,\sigma_2>0$,$|\rho|<1$,则称$(X,Y)$**服从二维正态分布**,记为$(X,Y)\sim N(\mu_1,\mu_2;\sigma_1^2,\sigma_2^2;\rho)$,并称$(X,Y)$为二维正态随机向量.

可以证明，由(3.1.13)式给出的 $f(x,y)$ 满足概率密度的两条基本性质.首先，

$$f(x,y)>0 \quad (-\infty<x<+\infty,-\infty<y<+\infty)$$

其次，若令

$$f_1(x)=\int_{-\infty}^{+\infty} f(x,y)\,\mathrm{d}y$$

$$u=\frac{x-\mu_1}{\sigma_1},\quad v=\frac{y-\mu_2}{\sigma_2}$$

则

$$f_1(x)=\frac{1}{\sqrt{2\pi}\sigma_1}\exp\left\{-\frac{u^2}{2}\right\}\int_{-\infty}^{+\infty}\frac{1}{\sqrt{2\pi}\sqrt{1-\rho^2}}\exp\left\{-\frac{(v-\rho u)^2}{2(1-\rho^2)}\right\}\mathrm{d}v$$

作变量代换 $t=\dfrac{v-\rho u}{\sqrt{1-\rho^2}}$，并利用恒等式

$$\int_{-\infty}^{+\infty}\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-\frac{t^2}{2}}\mathrm{d}t\equiv 1$$

得

$$f_1(x)=\frac{1}{\sqrt{2\pi}\sigma_1}\exp\left\{-\frac{u^2}{2}\right\}=\frac{1}{\sqrt{2\pi}\sigma_1}\mathrm{e}^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}}\quad(-\infty<x<+\infty)$$

于是

$$\begin{aligned}\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}f(x,y)\,\mathrm{d}x\mathrm{d}y&=\int_{-\infty}^{+\infty}f_1(x)\,\mathrm{d}x\\&=\int_{-\infty}^{+\infty}\frac{1}{\sqrt{2\pi}\sigma_1}\mathrm{e}^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}}\mathrm{d}x\\&=1\end{aligned}$$

由此可知，由(3.1.13)式所定义的 $f(x,y)$ 确实是概率密度.此外，从上面验证过程中，顺便得到了二维正态随机向量 (X,Y) 关于 X 的边缘概率密度

$$f_X(x)=f_1(x)=\frac{1}{\sqrt{2\pi}\sigma_1}\mathrm{e}^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}}\quad(-\infty<x<+\infty)\tag{3.1.14}$$

同理可得 (X,Y) 关于 Y 的边缘概率密度

$$f_Y(y)=\frac{1}{\sqrt{2\pi}\sigma_2}\mathrm{e}^{-\frac{(y-\mu_2)^2}{2\sigma_2^2}}\quad(-\infty<y<+\infty)\tag{3.1.15}$$

在这里，我们可得出两个结论：(1) 当 (X,Y) 服从二维正态分布 $N(\mu_1,\mu_2;\sigma_1^2,\sigma_2^2;\rho)$ 时，它的每个分量为一维正态变量，其中 $X\sim N(\mu_1,\sigma_1^2)$，$Y\sim N(\mu_2,\sigma_2^2)$.(2) 当 ρ 取不同数值时，(X,Y) 服从不同的二维正态分布 $N(\mu_1,\mu_2;\sigma_1^2,\sigma_2^2;\rho)$，但它的两个边缘概率密度却不变，这说明已知每个分量 X,Y 的边缘概率密度未必能唯一地确定随机向量 (X,Y) 的概率密度.

正态曲面 $z=f(x,y)$ 的图形如图 3.3 所示，其特点是“中间高，四周低”.

二维均匀分布 设 (X,Y) 为二维随机向量，G 是平面上的一个有界区域，其面积为 $A(A>0)$，又设

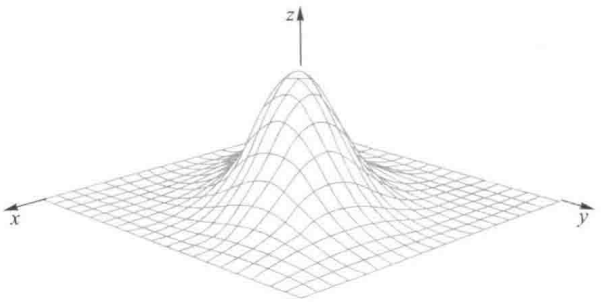

图 3.3

$$f(x,y)=\begin{cases}\dfrac{1}{A}, & \text{当}(x,y)\in G,\\ 0, & \text{当}(x,y)\notin G\end{cases} \tag{3.1.16}$$

若(X,Y)的概率密度为(3.1.16)式所定义的函数$f(x,y)$,则称二维随机向量(X,Y)在G上服从**二维均匀分布**.

容易验证由(3.1.16)式定义的$f(x,y)$满足概率密度的两条基本性质.

平面上的几何概型问题可以用服从二维均匀分布的随机向量(X,Y)来建模求解.

例 3.2 设平面区域G由曲线$y=\dfrac{1}{x}$及直线$y=0,x=1,x=\mathrm{e}^2$所围成,二维随机向量(X,Y)在G上服从均匀分布,试求:

(1) (X,Y)的概率密度;

(2) 关于X和Y的边缘概率密度;

(3) $P\left\{XY>\dfrac{1}{3}\right\}$.

解 (1) 平面区域G(如图3.4)的面积

$$S_G=\iint\limits_G \mathrm{d}x\mathrm{d}y=\int_1^{\mathrm{e}^2}\mathrm{d}x\int_0^{\frac{1}{x}}\mathrm{d}y=\int_1^{\mathrm{e}^2}\frac{1}{x}\mathrm{d}x=2$$

因此,(X,Y)的概率密度为

$$f(x,y)=\begin{cases}\dfrac{1}{2}, & 1\leqslant x\leqslant \mathrm{e}^2,0\leqslant y\leqslant\dfrac{1}{x},\\ 0, & \text{其他}\end{cases}$$

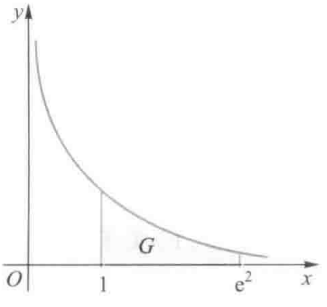

图 3.4

(2) 关于X的边缘概率密度为

$$f_X(x)=\int_{-\infty}^{+\infty}f(x,y)\,\mathrm{d}y=\begin{cases}\displaystyle\int_0^{\frac{1}{x}}\frac{1}{2}\mathrm{d}y=\frac{1}{2x}, & 1\leqslant x\leqslant \mathrm{e}^2,\\ 0, & \text{其他}\end{cases}$$

关于Y的边缘概率密度为

$$f_Y(y)=\int_{-\infty}^{+\infty}f(x,y)\,\mathrm{d}x=\begin{cases}\displaystyle\int_1^{\mathrm{e}^2}\frac{1}{2}\mathrm{d}x=\frac{\mathrm{e}^2-1}{2}, & 0\leqslant y<\mathrm{e}^{-2},\\ \displaystyle\int_1^{\frac{1}{y}}\frac{1}{2}\mathrm{d}x=\frac{1}{2}\left(\frac{1}{y}-1\right), & \mathrm{e}^{-2}\leqslant y\leqslant 1,\\ 0, & \text{其他}\end{cases}$$

(3) $$P\left\{XY>\frac{1}{3}\right\}=\iint\limits_{xy>\frac{1}{3}} f(x,y)\,\mathrm{d}x\mathrm{d}y=\int_1^{e^2}\mathrm{d}x\int_{\frac{1}{3x}}^{\frac{1}{x}}\frac{1}{2}\mathrm{d}y=\frac{2}{3}.$$

3.2 条件分布

当同时研究多个随机变量时,变量间的相互影响、相互依赖关系是一个值得关注的问题.人们可以从不同的角度来研究这个问题(例如在统计中用回归分析或相关分析的方法来研究它).本节讨论条件分布概念.设$(X_1,X_2,\cdots,X_n)$为n维随机向量,在已知其中一部分分量的值的条件下,问其余分量的条件概率分布是什么?

以下仅就$n=2$的情形展开讨论,相应的结论以及定义可以方便地推广到$n(n>2)$维随机向量的场合.

设(X,Y)为二维离散型随机向量,其分布律为

$$P\{X=x_i,Y=y_j\}=p_{ij}\quad(i,j=1,2,\cdots)\tag{3.2.1}$$

(X,Y)关于X和关于Y的边缘分布律分别为

$$P\{X=x_i\}=p_{i\cdot}=\sum_{j=1}^{\infty}p_{ij}\quad(i=1,2,\cdots)\tag{3.2.2}$$

$$P\{Y=y_j\}=p_{\cdot j}=\sum_{i=1}^{\infty}p_{ij}\quad(j=1,2,\cdots)\tag{3.2.3}$$

当$P\{Y=y_j\}>0$时,利用条件概率的计算公式,可知

$$P(X=x_i\mid Y=y_j\}=\frac{P\{X=x_i,Y=y_j\}}{P\{Y=y_j\}}=\frac{p_{ij}}{p_{\cdot j}}\quad(i=1,2,\cdots)$$

不难验证,上述这组条件概率(注意:这里j是固定的,i取遍$1,2,\cdots$)符合分布律的两条基本性质:

(1) $P\{X=x_i\mid Y=y_j\}\geqslant 0\quad(i=1,2,\cdots)$;

(2) $\sum\limits_{i=1}^{\infty}P\{X=x_i\mid Y=y_j\}=1.$

由此引入以下定义:

定义 3.5 设(X,Y)是二维离散型随机向量,其分布律以及(X,Y)关于X和关于Y的边缘分布律分别由(3.2.1),(3.2.2)和(3.2.3)式给出,对于固定的j,若$P\{Y=y_j\}>0$,则称

$$P\{X=x_i\mid Y=y_j\}=\frac{p_{ij}}{p_{\cdot j}}\quad(i=1,2,\cdots)\tag{3.2.4}$$

为在$Y=y_j$的条件下随机变量X的**条件分布律**.

离散型随机变量的条件分布律的定义比较直观,用第1章条件概率的定义就可以得到.

类似地,对于固定的i,若$P\{X=x_i\}>0$,则称

$$P\{Y=y_j\mid X=x_i\}=\frac{p_{ij}}{p_{i\cdot}}\quad(j=1,2,\cdots)\tag{3.2.5}$$

为在$X=x_i$的条件下随机变量Y的**条件分布律**.

例 3.3 在上节例3.1中,求在$X=0$的条件下,Y的条件分布律.

解 (1) 有放回取球:

$$P\{Y=0 \mid X=0\}=\frac{P\{X=0,Y=0\}}{P\{X=0\}}=\frac{\frac{1}{9}}{\frac{1}{3}}=\frac{1}{3}$$

$$P\{Y=1 \mid X=0\}=\frac{P\{X=0,Y=1\}}{P\{X=0\}}=\frac{\frac{2}{9}}{\frac{1}{3}}=\frac{2}{3}$$

(2) 不放回取球:

$$P\{Y=0 \mid X=0\}=\frac{P\{X=0,Y=0\}}{P\{X=0\}}=\frac{\frac{1}{15}}{\frac{1}{3}}=\frac{1}{5}$$

$$P\{Y=1 \mid X=0\}=\frac{P\{X=0,Y=1\}}{P\{X=0\}}=\frac{\frac{4}{15}}{\frac{1}{3}}=\frac{4}{5}$$

对比本例的两组答案,可以发现:对于有放回取球,在 $X=0$ 的条件下,Y 的条件分布律与 Y 的无条件分布律$\left(\text{亦即 } P\{Y=0\}=\frac{1}{3}, P\{Y=1\}=\frac{2}{3}\right)$相同.这表明条件$X=0$对 Y 的分布律没有产生任何影响(把条件换成 $X=1$,上述结论依然成立).但对于不放回取球方式,在同样条件下,Y 的条件分布律不同于 Y 的无条件分布律.不仅如此,在 $X=0, X=1$ 的条件下,相应的 Y 的条件分布律也各不相同(留给读者验证).这说明在不放回取球方式下,Y 的条件分布律与条件 $X=0$(或 $X=1$)是息息相关的.

由条件分布律就可以得到条件分布函数:给定条件 $Y=y_j(P\{Y=y_j\}>0)$,X 的条件分布函数为

$$\begin{aligned} F_{X|Y}(x \mid y_j) &= P\{X \leqslant x \mid Y=y_j\} \\ &= \sum_{x_i \leqslant x} P\{X=x_i \mid Y=y_j\} = \sum_{x_i \leqslant x} \frac{p_{ij}}{p_{\cdot j}} \end{aligned} \tag{3.2.6}$$

类似地,给定条件 $X=x_i(P\{X=x_i\}>0)$,Y 的条件分布函数为

$$\begin{aligned} F_{Y|X}(y \mid x_i) &= P\{Y \leqslant y \mid X=x_i\} \\ &= \sum_{y_j \leqslant y} P\{Y=y_j \mid X=x_i\} = \sum_{y_j \leqslant y} \frac{p_{ij}}{p_{i\cdot}} \end{aligned} \tag{3.2.7}$$

设(X,Y)为二维连续型随机向量,其概率密度为$f(x,y)$,(X,Y)关于 Y 的边缘概率密度为$f_Y(y)$.

此时由于对任意实数 y 有 $P\{Y=y\}=0$,因而直接由条件概率公式去计算 $P\{a \leqslant X \leqslant b \mid Y=y\}$ 是行不通的.为此,通过极限手段,把概率 $P\{a \leqslant X \leqslant b \mid Y=y\}$ 定义为(其中假定:对 $\forall \varepsilon>0, P\{y-\varepsilon<Y \leqslant y+\varepsilon\}>0$,$[a,b]$为任意区间)

$$P\{a \leqslant X \leqslant b \mid Y=y\} = \lim_{\varepsilon \to 0^+} P\{a \leqslant X \leqslant b \mid y-\varepsilon<Y \leqslant y+\varepsilon\}$$

$$= \lim_{\varepsilon \to 0^+} \frac{P\{a \leqslant X \leqslant b, y-\varepsilon < Y \leqslant y+\varepsilon\}}{P\{y-\varepsilon < Y \leqslant y+\varepsilon\}}$$

$$= \lim_{\varepsilon \to 0^+} \frac{\int_a^b \int_{y-\varepsilon}^{y+\varepsilon} f(u,v)\,\mathrm{d}v\mathrm{d}u}{\int_{-\infty}^{+\infty} \int_{y-\varepsilon}^{y+\varepsilon} f(u,v)\,\mathrm{d}v\mathrm{d}u}$$

若 $f(x,y)$ 在点 (x,y) 处连续，则上式的右端的极限值为

$$\frac{\int_a^b f(u,y)\,\mathrm{d}u}{\int_{-\infty}^{+\infty} f(u,y)\,\mathrm{d}u} = \int_a^b \frac{f(u,y)}{f_Y(y)}\mathrm{d}u$$

亦即

$$P\{a \leqslant X \leqslant b \mid Y = y\} = \int_a^b \frac{f(u,y)}{f_Y(y)}\mathrm{d}u$$

注意到上式右端积分号下的被积函数是非负可积函数，再把该式与连续型随机变量的概率密度的定义做比较，便引出如下定义：

定义 3.6 设 (X,Y) 为二维连续型随机向量，其概率密度为 $f(x,y)$，(X,Y) 关于 Y 的边缘概率密度为 $f_Y(y)$. 若对于固定的 y，$f_Y(y)>0$，则称

$$f_{X|Y}(x \mid y) = \frac{f(x,y)}{f_Y(y)} \tag{3.2.8}$$

为在 $Y=y$ 的条件下 X 的条件概率密度；而称

$$F_{X|Y}(x \mid y) = \int_{-\infty}^{x} f_{X|Y}(u \mid y)\,\mathrm{d}u \tag{3.2.9}$$

为在 $Y=y$ 的条件下 X 的条件分布函数.

类似地，当 $f_X(x)>0$ 时，可定义在 $X=x$ 的条件下 Y 的条件概率密度为

$$f_{Y|X}(y \mid x) = \frac{f(x,y)}{f_X(x)} \tag{3.2.10}$$

而将

$$F_{Y|X}(y \mid x) = \int_{-\infty}^{y} f_{Y|X}(v \mid x)\,\mathrm{d}v \tag{3.2.11}$$

称为在 $X=x$ 的条件下 Y 的条件分布函数.

例 3.4 设二维随机变量 (X,Y) 在单位圆域上服从二维均匀分布，即有概率密度

$$f(x,y) = \begin{cases} \dfrac{1}{\pi}, & \text{当 } x^2+y^2<1, \\ 0, & \text{其他} \end{cases}$$

求条件概率密度 $f_{X|Y}(x \mid y)$.

解 由 (X,Y) 的概率密度可得关于 Y 的边缘概率密度

$$f_Y(y) = \int_{-\infty}^{+\infty} f(x,y)\,\mathrm{d}x = \begin{cases} \displaystyle\int_{-\sqrt{1-y^2}}^{\sqrt{1-y^2}} \frac{1}{\pi}\mathrm{d}x = \frac{2}{\pi}\sqrt{1-y^2}, & |y|<1, \\ 0, & \text{其他} \end{cases}$$

故当给定 $Y=y(|y|<1)$ 时，X 的条件概率密度为

本例说明二维均匀分布的边缘分布不一定是均匀分布，但是其条件分布是均匀分布.请读者思考，为什么？

$$f_{X|Y}(x|y)=\frac{f(x,y)}{f_Y(y)}=\begin{cases}\dfrac{1/\pi}{(2/\pi)\sqrt{1-y^2}}=\dfrac{1}{2\sqrt{1-y^2}}, & |x|<\sqrt{1-y^2},\\ 0, & \text{其他}\end{cases}$$

这表明：当给定条件 $Y=y(|y|<1)$ 时，X 的条件分布为区间 $(-\sqrt{1-y^2},\sqrt{1-y^2})$ 上的均匀分布.

例 3.5 设数 X 在区间 $(0,1)$ 内随机地取值，当观察到 $X=x(0<x<1)$ 时，数 Y 在区间 $(x,1)$ 内随机地取值，求 Y 的概率密度 $f_Y(y)$.

解 由题意知，X 具有概率密度

$$f_X(x)=\begin{cases}1, & 0<x<1,\\ 0, & \text{其他}\end{cases}$$

又知，当给定条件 $X=x(0<x<1)$ 时，Y 的条件分布为区间 $(x,1)$ 上的均匀分布，即

$$f_{Y|X}(y|x)=\begin{cases}\dfrac{1}{1-x}, & x<y<1,\\ 0, & \text{其他}\end{cases}$$

其中 x 固定，$0<x<1$.

由(3.2.10)式得

$$f(x,y)=f_{Y|X}(y|x)f_X(x)=\begin{cases}\dfrac{1}{1-x}, & 0<x<1,x<y<1,\\ 0, & \text{其他}\end{cases}$$

故

$$f_Y(y)=\int_{-\infty}^{+\infty}f(x,y)\,\mathrm{d}x=\begin{cases}\displaystyle\int_0^y\frac{1}{1-x}\mathrm{d}x=-\ln(1-y), & 0<y<1,\\ 0, & \text{其他}\end{cases}$$

在本题的求解中，用到了一个重要的关系式

$$f(x,y)=f_X(x)f_{Y|X}(y|x)=f_Y(y)f_{X|Y}(x|y) \tag{3.2.12}$$

它与概率的乘法公式 $(P(AB)=P(A)P(B|A)=P(B)P(A|B))$ 类似.

3.3 随机变量的相互独立性

随机变量的相互独立性是概率论与数理统计中的一个很重要的概念，它是由随机事件的相互独立性引申而来的.我们知道，两个事件 A,B 是相互独立的当且仅当它们满足条件

$$P(AB)=P(A)P(B)$$

由此，可引出随机变量的相互独立性.

随机变量 X 与 Y 相互独立的本质是 X 与 Y 各自取值是互不影响的.

定义 3.7 设 (X,Y) 是二维随机向量，$F(x,y)$ 及 $F_X(x),F_Y(y)$ 分别是 (X,Y) 的分布函数及边缘分布函数，若对任意实数 x,y 恒有

$$P\{X\leqslant x,Y\leqslant y\}=P\{X\leqslant x\}P\{Y\leqslant y\} \tag{3.3.1}$$

即

$$F(x,y)=F_X(x)F_Y(y) \tag{3.3.2}$$

则称随机变量 X 与 Y 是**相互独立的**.

当 (X,Y) 是二维离散型随机向量时,X 与 Y 相互独立的条件(3.3.2)式等价于:对 (X,Y) 的所有可能取值 (x_i,y_j) $(i,j=1,2,\cdots)$ 都有

$$P\{X=x_i,Y=y_j\}=P\{X=x_i\}P\{Y=y_j\} \quad (i,j=1,2,\cdots) \tag{3.3.3}$$

当 (X,Y) 是二维连续型随机向量时,设 $f(x,y)$ 及 $f_X(x)$,$f_Y(y)$ 分别是 (X,Y) 的概率密度及边缘概率密度,则 X 与 Y 相互独立的条件(3.3.2)式等价于:

$$f(x,y)=f_X(x)f_Y(y) \tag{3.3.4}$$

几乎处处成立①.

理论探究:二维随机变量相互独立的等价条件的证明

在利用定义验证随机变量的独立性时,用(3.3.3)式或(3.3.4)式要比用(3.3.2)式方便些.

例 3.6 问 3.1 节例 3.1 中的 X 与 Y 是否相互独立?

答 在采用有放回取球时,因为

$$P\{X=i,Y=j\}=P\{X=i\}P\{Y=j\} \quad (i,j=0,1)$$

所以,X 与 Y 是相互独立的.

在采用不放回取球时,因为

$$P\{X=0,Y=0\}=\frac{1}{15}\neq P\{X=0\}P\{Y=0\}=\frac{1}{9}$$

所以,此时的 X 与 Y 不相互独立.

例 3.7 设二维随机向量 $(X,Y)\sim N(\mu_1,\mu_2;\sigma_1^2,\sigma_2^2;\rho)$,试证:$X$ 与 Y 相互独立的充要条件是 $\rho=0$.

证 由(3.1.14)式和(3.1.15)式知,(X,Y) 的两个边缘概率密度的乘积为

$$f_X(x)f_Y(y)=\frac{1}{2\pi\sigma_1\sigma_2}\exp\left\{\frac{-1}{2}\left[\frac{(x-\mu_1)^2}{\sigma_1^2}+\frac{(y-\mu_2)^2}{\sigma_2^2}\right]\right\} \tag{3.3.5}$$

先证充分性.设 $\rho=0$,把 $\rho=0$ 代入到 (X,Y) 的概率密度 $f(x,y)$(即(3.1.13)式)中,因为对一切实数 x,y 都有

$$\begin{aligned}f(x,y)&=\frac{1}{2\pi\sigma_1\sigma_2}\exp\left\{\frac{-1}{2}\left[\frac{(x-\mu_1)^2}{\sigma_1^2}+\frac{(y-\mu_2)^2}{\sigma_2^2}\right]\right\}\\&\equiv f_X(x)f_Y(y)\end{aligned}$$

故 X 与 Y 相互独立.

再证必要性.设 X 与 Y 相互独立,由于 $f(x,y)$,$f_X(x)$ 及 $f_Y(y)$ 都是连续函数,故对一切实数 x,y,都有

$$f(x,y)=f_X(x)f_Y(y) \tag{3.3.6}$$

在(3.3.6)式中令 $x=\mu_1,y=\mu_2$,由(3.1.13)式及(3.3.5)式得

$$\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}=\frac{1}{2\pi\sigma_1\sigma_2}$$

从而 $\rho=0$.

① "几乎处处成立"的含义是:在平面上挖去一个"面积"为零的点集之后,处处成立.

在实际问题中,随机变量的相互独立性通常不是用数学定义验证出来的,而是从变量产生的实际背景判断的.如果它们之间无任何影响或者影响很弱,可以认为(或者近似地认为)它们是相互独立的,然后再运用随机变量相互独立的性质以及与独立性有关的定理,计算有关的概率或解决相应的实际问题或建立新的数学模型.

相互独立的概念可以推广到 $n(n>2)$ 个随机变量的场合.设 n 维随机向量 $(X_1, X_2, \cdots, X_n)$ 的分布函数为

$$F(x_1, x_2, \cdots, x_n) = P\{X_1 \leqslant x_1, X_2 \leqslant x_2, \cdots X_n \leqslant x_n\}$$

若对任意实数 $x_1, x_2, \cdots, x_n$,都有

$$F(x_1, x_2, \cdots, x_n) = F_{X_1}(x_1) F_{X_2}(x_2) \cdots F_{X_n}(x_n) \tag{3.3.7}$$

则称随机变量 $X_1, X_2, \cdots, X_n$ 是相互独立的.

对于 n 维离散型随机向量和 n 维连续型随机向量,也相应地有类似于(3.3.3)式和(3.3.4)式的相互独立的等价条件,这里就不再罗列.

相互独立的概念还可以做进一步的推广.设 $X_1, X_2, \cdots, X_n, \cdots$ 为一串随机变量(或称为随机变量序列),若对任意正整数 $n>1$,都有 $X_1, X_2, \cdots, X_n$ 相互独立,则称随机变量序列 $X_1, X_2, \cdots, X_n, \cdots$ 是相互独立的.

设 m 维随机向量 $(X_1, X_2, \cdots, X_m)$ 的分布函数为 $F_1(x_1, x_2, \cdots, x_m)$,$n$ 维随机向量 $(Y_1, Y_2, \cdots, Y_n)$ 的分布函数为 $F_2(y_1, y_2, \cdots, y_n)$,$m+n$ 维随机向量 $(X_1, X_2, \cdots, X_m, Y_1, Y_2, \cdots, Y_n)$ 的分布函数为 $F(x_1, x_2, \cdots, x_m, y_1, y_2, \cdots, y_n)$.若对任意实数 $x_1, x_2, \cdots, x_m, y_1, y_2, \cdots, y_n$,都有

$$F(x_1, x_2, \cdots, x_m, y_1, y_2, \cdots, y_n) = F_1(x_1, x_2, \cdots, x_m) F_2(y_1, y_2, \cdots, y_n) \tag{3.3.8}$$

则称 $(X_1, X_2, \cdots, X_m)$ 与 $(Y_1, Y_2, \cdots, Y_n)$ 是相互独立的.

思考:为什么有这个结论?

随机向量 $(X_1, X_2, \cdots, X_m)$ 与 $(Y_1, Y_2, \cdots, Y_n)$ 之间的相互独立性蕴含:若从 $(X_1, X_2, \cdots, X_m)$ 中任选 i 个 $(1 \leqslant i \leqslant m)$ 变量 $(X_{m_1}, X_{m_2}, \cdots, X_{m_i})$,其中下标 $1 \leqslant m_1 < m_2 < \cdots < m_i \leqslant m$,从 $(Y_1, Y_2, \cdots, Y_n)$ 中任选 j 个 $(1 \leqslant j \leqslant n)$ 变量 $(Y_{n_1}, Y_{n_2}, \cdots, Y_{n_j})$,其中下标 $1 \leqslant n_1 < n_2 < \cdots < n_j \leqslant n$,则 $(X_{m_1}, X_{m_2}, \cdots, X_{m_i})$ 与 $(Y_{n_1}, Y_{n_2}, \cdots, Y_{n_j})$ 相互独立.反之,结论也成立.

下面,介绍两个有关独立性的重要定理.

定理 3.1 设 $(X_1, X_2, \cdots, X_m)$ 与 $(Y_1, Y_2, \cdots, Y_n)$ 相互独立,若 $h(x_1, x_2, \cdots, x_m)$,$g(y_1, y_2, \cdots, y_n)$ 是连续函数,则 $h(X_1, X_2, \cdots, X_m)$ 与 $g(Y_1, Y_2, \cdots, Y_n)$ 也相互独立.

定理 3.2 若随机变量 $X_1, X_2, \cdots, X_n$ 相互独立,把它们分为不相交的 k 组,每组中的所有变量由一个连续函数复合而生成一个新的随机变量,则这 k 个随机变量仍相互独立.

例如,X_1, X_2, X_3, X_4, X_5 相互独立,而 $Y_1 = \arctan(X_1 + X_3)$,$Y_2 = (\sin X_2) e^{X_5^2}$,$Y_3 = |X_4|$,因为 X_1, X_2, X_3, X_4, X_5 相互独立,所以把它分成不重合的三组:X_1, X_3;X_2, X_5;X_4,这三组变量之间亦无任何相依关系,而 Y_1, Y_2, Y_3 分别与这三组变量对应,因此 Y_1, Y_2, Y_3 应是相互独立的.

定理 3.1,3.2 的证明因超出本书的范围,此处从略.

3.4 随机向量的函数及其概率分布

3.4.1 随机向量的函数

在上一章的2.2节中我们讨论了随机变量的函数及其概率分布.而对有些应用问题来说,需要将高维的随机数据进行压缩或降维,这就引出如下概念:

定义 3.8 设$(X_1,X_2,\cdots,X_n)$是n维随机向量,$D\subset\mathbf{R}^n$是$(X_1,X_2,\cdots,X_n)$的所有可能值集合,

(1) 若$g(x_1,x_2,\cdots,x_n)$为定义在D上的n元函数,Y为随机变量,当$(X_1,X_2,\cdots,X_n)$取得可能值$(x_1,x_2,\cdots,x_n)\in D$时,$Y$相应地取值$g(x_1,x_2,\cdots,x_n)$,则称$Y$为随机向量$(X_1,X_2,\cdots,X_n)$的函数,记作$Y=g(X_1,X_2,\cdots,X_n)$.

(2) 若$g(x_1,x_2,\cdots,x_n)(j=1,2,\cdots,k)$为定义在$D$上的$n$元函数,$Y_j(j=1,2\cdots,k)$为随机变量,其中正整数$k\leqslant n$,当$(X_1,X_2,\cdots,X_n)$取得可能值$(x_1,x_2,\cdots,x_n)\in D$时,$Y_j$相应地取值$g_j(x_1,x_2,\cdots,x_n)(j=1,2\cdots,k)$,则称$(Y_1,Y_2,\cdots,Y_k)$为随机向量$(X_1,X_2,\cdots,X_n)$的向量值函数,记作

$$(Y_1,Y_2,\cdots,Y_k)=(g_1(X_1,X_2,\cdots,X_n),g_2(X_1,X_2,\cdots,X_n),\cdots,g_k(X_1,X_2,\cdots,X_n))$$

在上述定义中,若把n维随机向量$(X_1,X_2,\cdots,X_n)$映射成一维随机变量$Y=g(X_1,X_2,\cdots,X_n)$,则相当于把n维数据压缩成一维数据.

若把n维随机向量$(X_1,X_2,\cdots,X_n)$映射成k维随机向量

$$(Y_1,Y_2,\cdots,Y_k)=(g_1(X_1,X_2,\cdots,X_n),g_2(X_1,X_2,\cdots,X_n),\cdots,g_k(X_1,X_2,\cdots,X_n))$$

其中$k<n$,则相当于对高维数据进行降维.

下面我们来研究随机向量的函数的概率分布,为简明起见,将只考虑二维随机向量并就离散型与连续型两种情形分别予以讨论.

3.4.2 二维离散型随机向量的函数的概率分布

确定离散型随机向量的函数的概率分布是比较简单的.总的思路是设法将新随机变量(或随机向量)所表示的事件转化为老随机向量所表示的等价事件.请看下面的例题.

例 3.8 设二维离散型随机向量(X,Y)的分布律为

(X,Y)	$(-1,0)$	$(-1,1)$	$(-1,2)$	$(2,0)$	$(2,1)$	$(2,2)$
p	0.2	0.3	0.1	0.1	0.1	0.2

求$\max\{X,Y\}$,$\min\{X,Y\}$,$X+Y$,XY的分布律.

解 因$\max\{X,Y\}$把随机向量(X,Y)的6个可能值点映射为0,1,2,且

$$P\{\max\{X,Y\}=0\}=P\{(X,Y)=(-1,0)\}=0.2$$

$$P\{\max\{X,Y\}=1\}=P\{(X,Y)=(-1,1)\}=0.3$$

$$P\{\max\{X,Y\}=2\}$$

$$=P\{\{(X,Y)=(-1,2)\}\cup\{(X,Y)=(2,0)\}\cup\{(X,Y)=(2,1)\}\cup\{(X,Y)=(2,2)\}\}$$
$$=0.1+0.1+0.1+0.2=0.5$$

或简单地

$$P\{\max\{X,Y\}=2\}=1-P\{\max\{X,Y\}=0\}-P\{\max\{X,Y\}=1\}=1-0.2-0.3=0.5$$

故 $\max\{X,Y\}$ 的分布律为

$\max\{X,Y\}$	0	1	2
p	0.2	0.3	0.5

类似地，$\min\{X,Y\}$ 的分布律为

$\min\{X,Y\}$	−1	0	1	2
p	0.6	0.1	0.1	0.2

$X+Y$ 的分布律为

$X+Y$	−1	0	1	2	3	4
p	0.2	0.3	0.1	0.1	0.1	0.2

XY 的分布律为

XY	−2	−1	0	2	4
p	0.1	0.3	0.3	0.1	0.2

该结论称为泊松分布的可加性.

例 3.9 设随机变量 $X\sim P(\lambda_1)$，$Y\sim P(\lambda_2)$，且 X 与 Y 相互独立，求 $Z=X+Y$ 的分布律.

解 $Z=X+Y$ 的取值为所有非负整数 $0,1,2,\cdots$，事件 $\{Z=k\}$ 是一组互斥事件 $\{X=i,Y=k-i\}$，$i=0,1,\cdots,k$ 的并.因此，对 $k=0,1,2,\cdots$，

$$P\{Z=k\}=\sum_{i=0}^{k}P\{X=i,Y=k-i\}=\sum_{i=0}^{k}P\{X=i\}P\{Y=k-i\}$$
$$=\sum_{i=0}^{k}\frac{\lambda_1^i}{i!}e^{-\lambda_1}\frac{\lambda_2^{k-i}}{(k-i)!}e^{-\lambda_2}=e^{-(\lambda_1+\lambda_2)}\sum_{i=0}^{k}\frac{1}{i!\,(k-i)!}\lambda_1^i\lambda_2^{k-i}=\frac{(\lambda_1+\lambda_2)^k}{k!}e^{-(\lambda_1+\lambda_2)}$$

即 $Z=X+Y$ 服从参数为 $\lambda_1+\lambda_2$ 的泊松分布.

上面结论可以推广到有限个相互独立泊松分布之和的情形.事实上，若随机变量 $X_1,X_2,\cdots,X_n$ 相互独立，且 $X_i\sim P(\lambda_i)$，$i=1,2,\cdots,n$，则 $X_1+X_2+\cdots+X_n\sim P(\lambda_1+\lambda_2+\cdots+\lambda_n)$.

例 3.10 设二维离散型随机向量 (X,Y) 的分布律为

(X,Y)	(1,−1)	(1,0)	(1,1)	(2,−1)	(2,0)	(2,1)
p	0.3	0.1	0.1	0.1	0.1	0.3

求随机向量(Y^2,XY)的分布律.

解 因(Y^2,XY)把随机向量(X,Y)的6个可能值点映射为$(0,0),(1,-2),(1,-1),(1,1),(1,2)$,且

$$P\{(Y^2,XY)=(0,0)\}=P\{\{(X,Y)=(1,0)\}\cup\{(X,Y)=(2,0)\}\}=0.1+0.1=0.2$$

$$P\{(Y^2,XY)=(1,-2)\}=P\{(X,Y)=(2,-1)\}=0.1$$

$$P\{(Y^2,XY)=(1,-1)\}=P\{(X,Y)=(1,-1)\}=0.3$$

$$P\{(Y^2,XY)=(1,1)\}=P\{(X,Y)=(1,1)\}=0.1$$

$$P\{(Y^2,XY)=(1,2)\}=P\{(X,Y)=(2,1)\}=0.3$$

故(Y^2,XY)的分布律为

(Y^2,XY)	$(0,0)$	$(1,-2)$	$(1,-1)$	$(1,1)$	$(1,2)$
p	0.2	0.1	0.3	0.1	0.3

3.4.3 二维连续型随机向量的函数的概率分布

设二维连续型随机向量(X,Y)的概率密度为$f(x,y)$,$(U,V)=(g_1(X,Y),g_2(X,Y))$为$(X,Y)$的向量值函数,如何由$(X,Y)$的概率密度$f(x,y)$来确定$(U,V)$的分布?下面我们做一简要分析.

记$\mathscr{A}=\{(x,y)\in\mathbf{R}^2\mid f(x,y)>0\}$.假定$U=g_1(X,Y)$,$V=g_2(X,Y)$是$(X,Y)$到$(U,V)$的一一对应变换,因而存在逆变换$X=h_1(U,V)$,$Y=h_2(U,V)$,又假定$g_1,g_2$存在连续的一阶偏导数,此时,逆变换的函数$h_1,h_2$也存在连续的一阶偏导数,并且在一一对应变换的假定下,雅可比行列式$J=\dfrac{\partial(x,y)}{\partial(u,v)}=\begin{vmatrix}\dfrac{\partial h_1}{\partial u} & \dfrac{\partial h_1}{\partial v}\\ \dfrac{\partial h_2}{\partial u} & \dfrac{\partial h_2}{\partial v}\end{vmatrix}$不恒等于0.

令$\mathscr{B}=\{(u,v)\in\mathbf{R}^2\mid u=g_1(x,y),v=g_2(x,y),(x,y)\in\mathscr{A}\}$,它表示向量值函数$(u,v)=(g_1(x,y),g_2(x,y))$的值域.对$\forall B\subset\mathscr{B}$,必有唯一的$A\subset\mathscr{A}$与之对应,于是事件$\{(U,V)\in B\}$与事件$\{(X,Y)\in A\}$为等价事件,从而

$$P\{(U,V)\in B\}=P\{(X,Y)\in A\}=\iint_A f(x,y)\,\mathrm{d}x\mathrm{d}y$$

对上述二重积分作变量代换:令$u=g_1(x,y)$,$v=g_2(x,y)$,则有

$$\iint_A f(x,y)\,\mathrm{d}x\mathrm{d}y=\iint_B f(h_1(u,v),h_2(u,v))\mid J\mid \mathrm{d}u\mathrm{d}v$$

即

$$P\{(U,V)\in B\}=\iint_B f(h_1(u,v),h_2(u,v))\mid J\mid \mathrm{d}u\mathrm{d}v$$

由连续型随机向量的概念便知(U,V)仍为连续型随机向量,且其概率密度为

$$f_{U,V}(u,v)=f(h_1(u,v),h_2(u,v))\mid J\mid$$

由以上分析可引出下面的定理.

定理3.3 设二维连续型随机向量(X,Y)的概率密度为$f(x,y)$,若$U=g_1(X,Y)$,$V=$

$g_2(X,Y)$是(X,Y)到(U,V)的一一对应变换，即存在逆变换$X=h_1(U,V)$，$Y=h_2(U,V)$，并且g_1,g_2,h_1,h_2都存在连续的一阶偏导数，则(U,V)仍为连续型随机向量，且其概率密度为

$$f_{U,V}(u,v)=\begin{cases}f(h_1(u,v),h_2(u,v))\,|J|, & (u,v)\in\mathscr{B},\\ 0, & \text{其他}\end{cases} \tag{3.4.1}$$

定理3.3的结论类似于第2章的定理2.1，是定理2.1在多维随机向量下的推广.

其中$\mathscr{B}$为向量值函数$(u,v)=(g_1(x,y),g_2(x,y))$的值域.

例3.11 设随机变量X与Y相互独立且都服从正态分布$N(0,\sigma^2)$，令$U=X+Y$，$V=X-Y$，问：(1) U与V分别服从什么分布？(2) U与V是否相互独立？

解 (1) 由独立性知，(X,Y)的概率密度为

$$f(x,y)=f_X(x)f_Y(y)=\frac{1}{2\pi\sigma^2}e^{-\frac{x^2+y^2}{2\sigma^2}},\quad -\infty<x,y<+\infty$$

因$(U,V)=(X+Y,X-Y)$存在唯一的逆变换$(X,Y)=\left(\frac{U+V}{2},\frac{U-V}{2}\right)$，且正、逆变换中的所有函数都存在连续的一阶偏导数，又雅可比行列式

$$J=\frac{\partial(x,y)}{\partial(u,v)}=\begin{vmatrix}\frac{1}{2} & \frac{1}{2}\\ \frac{1}{2} & -\frac{1}{2}\end{vmatrix}=-\frac{1}{2}$$

故由定理3.3知，

$$f_{U,V}(u,v)=f\left(\frac{u+v}{2},\frac{u-v}{2}\right)\cdot\left|-\frac{1}{2}\right|=\frac{1}{4\pi\sigma^2}e^{-\frac{u^2+v^2}{4\sigma^2}},\quad -\infty<u,v<+\infty$$

对比二维正态分布的定义式(3.1.13)，可知$(U,V)\sim N(0,0;2\sigma^2,2\sigma^2;0)$，于是$U\sim N(0,2\sigma^2)$，$V\sim N(0,2\sigma^2)$.

(2) 由(1)知$(U,V)\sim N(0,0;2\sigma^2,2\sigma^2;0)$且$\rho=0$，依例3.7的结论便知$U$与$V$相互独立.

有时，我们只需求二维连续型随机向量(X,Y)的一个函数$g(X,Y)$的概率密度. 下面就几种常见问题来探讨求解方法.

1. $X+Y$的概率密度

已知二维连续型随机向量(X,Y)的概率密度为$f(x,y)$，设$U=X+Y$，为求U的概率密度，补一个函数

$$V=Y \tag{3.4.2}$$

这样便构成(X,Y)到(U,V)的一一对应变换：$\begin{cases}U=X+Y,\\ V=Y,\end{cases}$逆变换为$\begin{cases}X=U-V,\\ Y=V,\end{cases}$雅可比行列式$J=\frac{\partial(x,y)}{\partial(u,v)}=\begin{vmatrix}1 & -1\\ 0 & 1\end{vmatrix}=1$，由定理3.3知，

$$f_{U,V}(u,v)=f(u-v,v)\cdot|1|=f(u-v,v)$$

于是

$$f_U(u)=\int_{-\infty}^{+\infty}f_{U,V}(u,v)\,dv=\int_{-\infty}^{+\infty}f(u-v,v)\,dv$$

若补的函数((3.4.2)式)换成 $V=X$,则类似可得

$$f_U(u)=\int_{-\infty}^{+\infty} f(v,u-v)\,\mathrm{d}v$$

综上,便得求 $X+Y$ 的概率密度的如下公式:

$$f_{X+Y}(t)=\int_{-\infty}^{+\infty} f(x,t-x)\,\mathrm{d}x=\int_{-\infty}^{+\infty} f(t-y,y)\,\mathrm{d}y \tag{3.4.3}$$

特别地,当 X 与 Y 相互独立时,$f(x,y)=f_X(x)f_Y(y)$,其中 $f_X(x)$,$f_Y(y)$ 为 (X,Y) 关于 X,关于 Y 的边缘概率密度,于是 $X+Y$ 的概率密度为

$$f_{X+Y}(t)=\int_{-\infty}^{+\infty} f_X(x)f_Y(t-x)\,\mathrm{d}x=\int_{-\infty}^{+\infty} f_X(t-y)f_Y(y)\,\mathrm{d}y \tag{3.4.4}$$

(3.4.4)式称为独立变量之和的**密度卷积公式**.

例 3.12 设随机变量 X 与 Y 相互独立,且都服从均匀分布 $U(0,1)$,求 $X+Y$ 的概率密度.

解 (解法一)由卷积公式(3.4.4),得

$$f_{X+Y}(t)=\int_{-\infty}^{+\infty} f_X(x)f_Y(t-x)\,\mathrm{d}x=\int_0^1 f_Y(t-x)\,\mathrm{d}x$$

因被积函数 $f_Y(t-x)=\begin{cases}1, & 0\leqslant t-x\leqslant 1,\\ 0, & \text{其他},\end{cases}$ 又积分变量 x 在区间 $[0,1]$ 上进行无限累加,故只需讨论区间 $[t-1,t]$ 与区间 $[0,1]$ 的相交情况.当 $t<0$ 或 $t>2$ 时,两区间相交为空集,相应的积分为 0;当 $0\leqslant t<1$ 时,两区间的交集为 $[0,t]$,积分 $\int_0^1 f_Y(t-x)\,\mathrm{d}x=\int_0^t 1\,\mathrm{d}x=t$;当 $1\leqslant t<2$ 时,两区间的交集为 $[t-1,1]$,积分 $\int_0^1 f_Y(t-x)\,\mathrm{d}x=\int_{t-1}^1 1\,\mathrm{d}x=2-t$;综上

$$f_{X+Y}(t)=\begin{cases}t, & 0\leqslant t<1,\\ 2-t, & 1\leqslant t<2,\\ 0, & \text{其他}\end{cases}$$

(解法二)先求 $X+Y$ 的分布函数:

$$F_{X+Y}(t)=P\{X+Y\leqslant t\}=\iint\limits_{x+y\leqslant t} f(x,y)\,\mathrm{d}x\mathrm{d}y$$

因被积函数 $f(x,y)=f_X(x)f_Y(y)=\begin{cases}1, & 0\leqslant x\leqslant 1,0\leqslant y\leqslant 1,\\ 0, & \text{其他},\end{cases}$ 而积分域为 $\{(x,y)\in\mathbf{R}^2\mid x+y\leqslant t\}$,故需对集合 $\{(x,y)\in\mathbf{R}^2\mid x+y\leqslant t\}$ 与 $\{(x,y)\in\mathbf{R}^2\mid 0\leqslant x\leqslant 1,0\leqslant y\leqslant 1\}$ 的相交情况进行讨论.

当 $t<0$ 时,两集相交为空集(如图 3.5(a)所示),重积分

$$\iint\limits_{x+y\leqslant t} f(x,y)\,\mathrm{d}x\mathrm{d}y=0$$

当 $0\leqslant t<1$ 时,两集相交为图 3.5(b)中的重叠阴影部分,重积分

$$\iint\limits_{x+y\leqslant t} f(x,y)\,\mathrm{d}x\mathrm{d}y=\int_0^t \mathrm{d}x\int_0^{t-x}\mathrm{d}y=\frac{t^2}{2}$$

当 $1\leqslant t<2$ 时,两集相交为图 3.5(c)中的重叠阴影部分,重积分

$$\iint\limits_{x+y\leqslant t} f(x,y)\,\mathrm{d}x\mathrm{d}y=\int_0^{t-1}\mathrm{d}x\int_0^1\mathrm{d}y+\int_{t-1}^1\mathrm{d}x\int_0^{t-x}\mathrm{d}y=-\frac{t^2}{2}+2t-1$$

当 $t\geqslant 2$ 时，两集相交为图 3.5(d)中的重叠阴影部分，重积分

$$\iint\limits_{x+y\leqslant t} f(x,y)\,\mathrm{d}x\mathrm{d}y=\int_0^1\mathrm{d}x\int_0^1\mathrm{d}y=1.$$

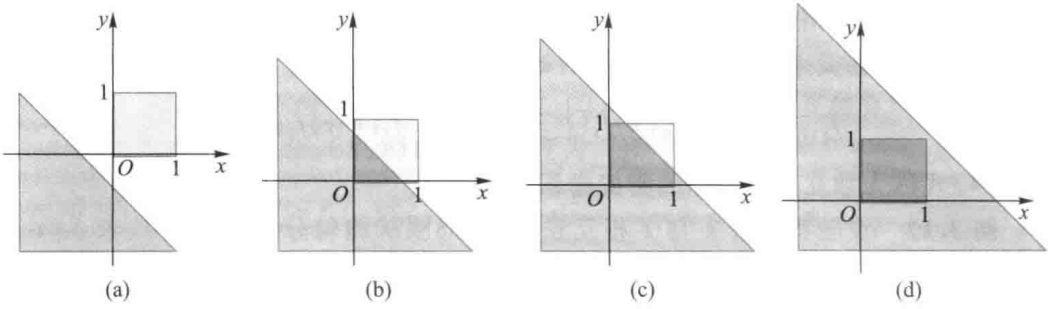

图 3.5

综上，

$$F_{X+Y}(t)=P\{X+Y\leqslant t\}=\iint\limits_{x+y\leqslant t} f(x,y)\,\mathrm{d}x\mathrm{d}y=\begin{cases}0, & t<0,\\ \dfrac{t^2}{2}, & 0\leqslant t<1,\\ -\dfrac{t^2}{2}+2t-1, & 1\leqslant t<2,\\ 1, & t\geqslant 2\end{cases}$$

因此

$$f_{X+Y}(t)=F'_{X+Y}(t)=\begin{cases}t, & 0<t<1,\\ 2-t, & 1<t<2,\\ 0, & \text{其他}\end{cases}$$

例 3.13 设随机变量 $X\sim N(\mu_1,\sigma_1^2)$，$Y\sim N(\mu_2,\sigma_2^2)$，且 X 与 Y 相互独立，求 $X+Y$ 的概率密度.

解 由(3.4.4)式对 $-\infty<z<+\infty$，有

$$f_{X+Y}(z)=\frac{1}{2\pi\sigma_1\sigma_2}\int_{-\infty}^{+\infty}\mathrm{e}^{-\frac{[(z-y)-\mu_1]^2}{2\sigma_1^2}}\mathrm{e}^{-\frac{(y-\mu_2)^2}{2\sigma_2^2}}\mathrm{d}y$$

因为

$$\frac{[(z-y)-\mu_1]^2}{\sigma_1^2}+\frac{(y-\mu_2)^2}{\sigma_2^2}=y^2\left(\frac{1}{\sigma_1^2}+\frac{1}{\sigma_2^2}\right)-2y\left[\frac{(z-\mu_1)}{\sigma_1^2}+\frac{\mu_2}{\sigma_2^2}\right]+\frac{(z-\mu_1)^2}{\sigma_1^2}+\frac{\mu_2^2}{\sigma_2^2}$$

令

$$A=\frac{1}{\sigma_1^2}+\frac{1}{\sigma_2^2},\quad B=\frac{z-\mu_1}{\sigma_1^2}+\frac{\mu_2}{\sigma_2^2},\quad C=\frac{(z-\mu_1)^2}{\sigma_1^2}+\frac{\mu_2^2}{\sigma_2^2}$$

所以

$$\frac{[(z-y)-\mu_1]^2}{\sigma_1^2}+\frac{(y-\mu_2)^2}{\sigma_2^2}=Ay^2-2By+C$$

$$=A\left(y-\frac{B}{A}\right)^2+\frac{AC-B^2}{A}$$

于是

$$f_{X+Y}(z)=\frac{1}{2\pi\sigma_1\sigma_2}\mathrm{e}^{-\frac{AC-B^2}{2A}}\int_{-\infty}^{+\infty}\mathrm{e}^{-\frac{A}{2}\left(y-\frac{B}{A}\right)^2}\mathrm{d}y$$

作变量代换 $t=\sqrt{A}\left(y-\frac{B}{A}\right)$，并注意到

$$\int_{-\infty}^{+\infty}\mathrm{e}^{-\frac{t^2}{2}}\mathrm{d}t=\sqrt{2\pi}$$

以及

$$\mathrm{e}^{-\frac{AC-B^2}{2A}}=\mathrm{e}^{-\frac{[z-(\mu_1+\mu_2)]^2}{2(\sigma_1^2+\sigma_2^2)}}$$

最后，得

$$f_{X+Y}(z)=\frac{1}{2\pi\sigma_1\sigma_2}\mathrm{e}^{-\frac{[z-(\mu_1+\mu_2)]^2}{2(\sigma_1^2+\sigma_2^2)}}\frac{\sqrt{2\pi}}{\sqrt{A}}$$

$$=\frac{1}{\sqrt{2\pi}\sqrt{\sigma_1^2+\sigma_2^2}}\mathrm{e}^{-\frac{[z-(\mu_1+\mu_2)]^2}{2(\sigma_1^2+\sigma_2^2)}}$$

由此可知，$X+Y\sim N(\mu_1+\mu_2,\sigma_1^2+\sigma_2^2)$.

例 3.13 的结论可以推广到 n 个相互独立正态随机变量之和的情形.

若 $X_k\sim N(\mu_k,\sigma_k^2)\ (k=1,2,\cdots,n)$，并且它们相互独立，则

$$X_1+X_2+\cdots+X_n\sim N(\mu_1+\mu_2+\cdots+\mu_n,\sigma_1^2+\sigma_2^2+\cdots+\sigma_n^2)$$

更一般地，可以证明 n **个相互独立的正态随机变量的线性组合仍然是正态随机变量**.

该结论称为正态分布的可加性.请读者思考：若 $(X,Y)\sim N(\mu_1,\mu_2;\sigma_1^2,\sigma_2^2;\rho)$，则 $X+Y$ 服从什么分布?

2. $\frac{X}{Y}$ 的概率密度

设二维连续型随机向量 (X,Y) 的概率密度为 $f(x,y)$，又设 $U=\frac{X}{Y}(Y\neq 0)$，为求 U 的概率密度，补一个函数 $V=Y$，这样便构成 (X,Y) 到 (U,V) 的一一对应变换：

$\begin{cases}U=\frac{X}{Y},\\V=Y,\end{cases}$ 逆变换为 $\begin{cases}X=UV,\\Y=V,\end{cases}$ 雅可比行列式

$$J=\begin{vmatrix}\frac{\partial x}{\partial u} & \frac{\partial x}{\partial v}\\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v}\end{vmatrix}=\begin{vmatrix}v & u\\0 & 1\end{vmatrix}=v$$

由定理 3.3 知，$f_{U,V}(u,v)=f(uv,v)\,|J|=f(uv,v)\,|v|$，于是

$$f_U(u)=\int_{-\infty}^{+\infty}f_{U,V}(u,v)\,\mathrm{d}v=\int_{-\infty}^{+\infty}f(uv,v)\,|v|\,\mathrm{d}v$$

由此便得$\frac{X}{Y}$的概率密度的计算公式

$$f_{X/Y}(t)=\int_{-\infty}^{+\infty}|y|f(yt,y)\mathrm{d}y \tag{3.4.5}$$

特别,当X与Y相互独立时,$\frac{X}{Y}$的概率密度为

$$f_{X/Y}(t)=\int_{-\infty}^{+\infty}|y|f_X(yt)f_Y(y)\mathrm{d}y \tag{3.4.6}$$

其中$f_X(x)$、$f_Y(y)$分别为(X,Y)关于X、关于Y的边缘概率密度.

例 3.14 设$X\sim N(0,1)$,$Y\sim N(0,1)$,且X与Y相互独立,求$T=\frac{X}{\sqrt{Y^2}}$的概率密度.

解 根据例2.15,$U=Y^2$的概率密度为

$$f_U(u)=\begin{cases}\frac{1}{\sqrt{2\pi}}u^{-\frac{1}{2}}\mathrm{e}^{-\frac{u}{2}}, & u>0,\\ 0, & u\leqslant 0\end{cases}$$

令$V=\sqrt{U}$,由定理2.1可得V的概率密度

$$f_V(v)=\begin{cases}\frac{2}{\sqrt{2\pi}}\mathrm{e}^{-\frac{v^2}{2}}, & v>0,\\ 0, & v\leqslant 0\end{cases}$$

于是

$$f_T(t)=\int_{-\infty}^{+\infty}|v|f_X(vt)f_V(v)\mathrm{d}v=\int_0^{+\infty}v\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-\frac{(vt)^2}{2}}\frac{2}{\sqrt{2\pi}}\mathrm{e}^{-\frac{v^2}{2}}\mathrm{d}v$$

$$=\frac{1}{\pi}\int_0^{+\infty}v\mathrm{e}^{-\frac{(1+t^2)v^2}{2}}\mathrm{d}v=\frac{1}{\pi(1+t^2)}(-\infty<t<+\infty)$$

具有上述概率密度的概率分布称为标准柯西分布.

若随机变量X具有概率密度$f(x)=\frac{\lambda}{\pi[\lambda^2+(x-\theta)^2]}(-\infty<x<+\infty)$,则称$X$服从参数为$\theta,\lambda$的**柯西分布**,记作$X\sim C(\theta,\lambda)$,其中参数$-\infty<\theta<+\infty$,$\lambda>0$.当$\theta=0,\lambda=1$时,称$C(0,1)$为标准柯西分布.

3. $\max\{X,Y\}$,$\min\{X,Y\}$**的分布**

如果随机变量X与Y相互独立,它们的分布函数分别为$F_X(x)$和$F_Y(y)$,设$M=\max\{X,Y\}$,$N=\min\{X,Y\}$,下面来寻求M,N的概率分布.

对任意实数z,有$\{\max\{X,Y\}\leqslant z\}=\{X\leqslant z,Y\leqslant z\}$,由$X$与$Y$相互独立,可知

$$F_M(z)=P\{M\leqslant z\}=P\{\max\{X,Y\}\leqslant z\}$$
$$=P\{X\leqslant z,Y\leqslant z\}=P\{X\leqslant z\}P\{Y\leqslant z\}=F_X(z)F_Y(z)$$

类似地,由$\{\min\{X,Y\}>z\}=\{X>z,Y>z\}$及$X$与$Y$的相互独立性,可得

$$F_N(z)=P\{N\leqslant z\}=P\{\min\{X,Y\}\leqslant z\}$$
$$=1-P\{\min\{X,Y\}>z\}=1-P\{X>z,Y>z\}$$
$$=1-P\{X>z\}P\{Y>z\}=1-[1-F_X(z)][1-F_Y(z)]$$

上述结果不难推广到$n(n>2)$个相互独立的随机变量的场合.

若$X_1,X_2,\cdots,X_n$是n个相互独立的随机变量,$F_{X_k}(x_k)$为$X_k(k=1,2,\cdots,n)$的分布函数,设$M=\max\{X_1,X_2,\cdots,X_n\}$,$N=\min\{X_1,X_2,\cdots,X_n,\}$,则

$$F_M(z)=F_{X_1}(z)F_{X_2}(z)\cdots F_{X_n}(z) \tag{3.4.7}$$

$$F_N(z)=1-[1-F_{X_1}(z)][1-F_{X_2}(z)]\cdots[1-F_{X_n}(z)] \tag{3.4.8}$$

其中 $F_M(z)$,$F_N(z)$ 分别为 M,N 的分布函数.

(3.4.7)式与(3.4.8)式适用于任何类型的随机变量.当 $X_1,X_2,\cdots,X_n$ 是 n 个相互独立的连续型随机变量时,在一般情况下,想通过对(3.4.7)式与(3.4.8)式两端求导来获得 M,N 的概率密度却并不方便,这是因为要对 n 个函数的乘积求导.不过在一些特殊情况下,还是可以很容易地求得 M,N 的概率密度的.例如,若 $X_1,X_2,\cdots,X_n$ 是 n 个相互独立且服从同一分布的随机变量且 $X_1\sim U(0,1)$,已知均匀分布 $U(0,1)$ 的分布函数为

$$F(x)=\begin{cases}0, & x<0,\\ x, & 0\leqslant x<1,\\ 1, & x\geqslant 1\end{cases}$$

又有服从同一分布的这一条件,则

$$f_M(z)=F_M'(z)=(F^n(x))'=nF^{n-1}(x)f(x)=\begin{cases}nx^{n-1}, & 0<x<1,\\ 0, & \text{其他}\end{cases} \tag{3.4.9}$$

同理可得

$$f_N(z)=\begin{cases}n(1-x)^{n-1}, & 0<x<1,\\ 0, & \text{其他}\end{cases} \tag{3.4.10}$$

前面讨论的主要是二维离散型随机向量或二维连续型随机向量函数的概率分布问题,对于一个离散型随机变量和一个连续型随机变量的函数的概率分布,需要用全概率公式计算其分布函数.下面通过一个例子说明.

例 3.15 设随机变量 X 与 Y 相互独立,且 X 服从(0-1)分布:$P\{X=0\}=P\{X=1\}=\dfrac{1}{2}$,$Y$ 服从参数为 λ 的指数分布,求 $Z=X+Y$ 的概率分布.

解 先求 $Z=X+Y$ 的分布函数 $F_Z(z)=P\{Z\leqslant z\}=P\{X+Y\leqslant z\}$.利用全概率公式的思想以及 X 与 Y 相互独立的这一条件,有

$$\begin{aligned}F_Z(z)&=P\{X+Y\leqslant z\}=P\{X=0,X+Y\leqslant z\}+P\{X=1,X+Y\leqslant z\}\\&=P\{X=0,Y\leqslant z\}+P\{X=1,Y\leqslant z-1\}\\&=P\{X=0\}P\{Y\leqslant z\}+P\{X=1\}P\{Y\leqslant z-1\}\\&=\frac{1}{2}F_Y(z)+\frac{1}{2}F_Y(z-1)\end{aligned}$$

知识点讲解视频:离散型随机变量与连续型随机变量之和的概率分布

因 $Y\sim Exp(\lambda)$,故 Y 的分布函数 $F_Y(y)=\begin{cases}1-e^{-\lambda y}, & y\geqslant 0,\\ 0, & y<0,\end{cases}$ 于是

$$F_Z(z)=\begin{cases}1-\dfrac{1}{2}(e^{-\lambda z}+e^{-\lambda(z-1)}), & z\geqslant 1,\\ \dfrac{1}{2}(1-e^{-\lambda z}), & 0\leqslant z<1,\\ 0, & z<0\end{cases}$$

显然 $F_Z(z)$ 为连续函数且在点 $z=0$ 与 $z=1$ 之外处处可导,其导函数为

$$F'_Z(z)=\begin{cases}\dfrac{1}{2}\lambda(e^{-\lambda z}+e^{-\lambda(z-1)}), & z>1,\\ \dfrac{1}{2}\lambda e^{-\lambda z}, & 0<z<1,\\ 0, & z<0\end{cases}$$

令

$$f_Z(z)=\begin{cases}\dfrac{1}{2}\lambda(e^{-\lambda z}+e^{-\lambda(z-1)}), & z>1,\\ \dfrac{1}{2}\lambda e^{-\lambda z}, & 0<z<1,\\ 0, & z<0\end{cases}$$

$f_Z(z)$即为 Z 的概率密度.

内容小结

1. 二维随机向量及其概率分布

设 $X_1,X_2,\cdots,X_n$ 是定义在样本空间 Ω 上的 n 个随机变量,则$(X_1,X_2,\cdots,X_n)$称为 n 维随机向量或 n 维随机变量.

设(X,Y)是二维随机向量,对任意实数 x,y,二元函数

$$F(x,y)=P\{X\leqslant x,Y\leqslant y\},-\infty<x,y<+\infty$$

称为二维随机向量(X,Y)的分布函数,或 X 与 Y 的联合分布函数.

分布函数 $F(x,y)$具有性质:

(1) $F(x,y)$对每个变量是单调增函数,即当 $x_1<x_2$ 时,$F(x_1,y)\leqslant F(x_2,y)$;当 $y_1<y_2$ 时,$F(x,y_1)\leqslant F(x,y_2)$.

(2) $F(x,y)$对每个变量是右连续的函数,即 $F(x+0,y)=F(x,y)$,$F(x,y+0)=F(x,y)$.

(3) $0\leqslant F(x,y)\leqslant 1$,且 $F(-\infty,y)=0$,$F(x,-\infty)=0$,$F(-\infty,-\infty)=0$,$F(+\infty,+\infty)=1$.

(4) 对任意两点(x_1,y_1),(x_2,y_2),若 $x_1\leqslant x_2,y_1\leqslant y_2$,则 $F(x_2,y_2)-F(x_2,y_1)-F(x_1,y_2)+F(x_1,y_1)\geqslant 0$.

以上四条性质可以验证一个二元函数是否是某二维随机向量的分布函数.

(X,Y)关于 X,Y 的边缘分布函数分别为 $F_X(x)=P\{X\leqslant x\}=F(x,+\infty)$,$F_Y(y)=F(+\infty,y)$.

对二维离散型随机向量(X,Y),定义它的分布律

$$P\{X=x_i,Y=y_j\}=p_{ij}\quad(i,j=1,2,\cdots)$$

且分布律满足性质:(1) $p_{ij}\geqslant 0(i,j=1,2,\cdots)$;(2) $\sum\limits_{i=1}^{\infty}\sum\limits_{j=1}^{\infty}p_{ij}=1$.

此时,(X,Y)关于 X,Y 的边缘分布律分别为

$$p_{i\cdot}=P\{X=x_i\}=\sum_{j=1}^{\infty}p_{ij}(i=1,2,\cdots),\quad p_{\cdot j}=P\{Y=y_j\}=\sum_{i=1}^{\infty}p_{ij}(j=1,2,\cdots)$$

(X,Y)的分布律能唯一确定关于X,Y的边缘分布律,反之则不成立.

设(X,Y)是二维随机向量,若存在一个非负可积函数$f(x,y)$($-\infty<x<+\infty$,$-\infty<y<+\infty$),使得对任意区域$A\subset\mathbf{R}^2$,都有

$$P\{(X,Y)\in A\}=\iint_A f(x,y)\,\mathrm{d}x\mathrm{d}y$$

则(X,Y)称为二维连续型随机向量,称$f(x,y)$为(X,Y)的概率密度.

概率密度具有性质:(1) $f(x,y)\geqslant 0,-\infty<x,y<+\infty$;(2) $\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}f(x,y)\,\mathrm{d}x\mathrm{d}y=1$.

二维连续型随机向量(X,Y)的分布函数为

$$F(x,y)=\int_{-\infty}^{x}\int_{-\infty}^{y}f(u,v)\,\mathrm{d}u\mathrm{d}v$$

此时,X,Y分别是一维连续型随机变量,关于它们的边缘概率密度分别为

$$f_X(x)=\int_{-\infty}^{+\infty}f(x,y)\,\mathrm{d}y,\quad f_Y(y)=\int_{-\infty}^{+\infty}f(x,y)\,\mathrm{d}x$$

若二维随机向量(X,Y)的概率密度为

$$f(x,y)=\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\mathrm{e}^{-\frac{1}{2(1-\rho^2)}\left[\frac{(x-\mu_1)^2}{\sigma_1^2}-2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2}+\frac{(y-\mu_2)^2}{\sigma_2^2}\right]},\quad -\infty<x<+\infty,-\infty<y<+\infty$$

其中$\mu_1,\mu_2,\sigma_1,\sigma_2,\rho$都是常数,且$\sigma_1>0,\sigma_2>0,-1<\rho<1$,则称$(X,Y)$服从二维正态分布,记为$(X,Y)\sim N(\mu_1,\mu_2;\sigma_1^2,\sigma_2^2;\rho)$.

若二维随机向量(X,Y)的概率密度为$f(x,y)=\begin{cases}\dfrac{1}{A}, & (x,y)\in G,\\ 0, & \text{其他},\end{cases}$则称$(X,Y)$在$G$上服从二维均匀分布,其中$A(A>0)$为有界区域$G$的面积.

2. 条件分布

若(X,Y)是二维离散型随机向量,其分布律为

$$p_{ij}=P\{X=x_i,Y=y_j\}\ (i,j=1,2,\cdots)$$

若(X,Y)关于Y的边缘分布律$p_{\cdot j}=P\{Y=y_j\}>0$,称$P\{X=x_i\mid Y=y_j\}=\dfrac{p_{ij}}{p_{\cdot j}}$($i=1,2,\cdots$)为在$Y=y_j$条件下$X$的条件分布律.

若(X,Y)关于X的边缘分布律$p_{i\cdot}=P\{X=x_i\}>0$,称$P\{Y=y_j\mid X=x_i\}=\dfrac{p_{ij}}{p_{i\cdot}}$($j=1,2,\cdots$)为在$X=x_i$条件下$Y$的条件分布律.

若(X,Y)是二维连续型随机向量,其概率密度为$f(x,y)$,(X,Y)关于X,Y的边缘概率密度为$f_X(x)$,$f_Y(y)$,若对于固定的y,$f_Y(y)>0$,称$f_{X|Y}(x\mid y)=\dfrac{f(x,y)}{f_Y(y)}$为在$Y=y$条件下$X$的条件概率密度,称$F_{X|Y}(x\mid y)=\int_{-\infty}^{x}f_{X|Y}(u\mid y)\,\mathrm{d}u$为在$Y=y$条件下$X$的条件分布函数.

若对于固定的x,$f_X(x)>0$,称$f_{Y|X}(y\mid x)=\dfrac{f(x,y)}{f_X(x)}$为在$X=x$条件下$Y$的条件概率

密度，称$F_{Y|X}(y\mid x)=\int_{-\infty}^{y} f_{Y|X}(v\mid x)\,\mathrm{d}v$为在$X=x$条件下$Y$的条件分布函数.

3. 随机变量的相互独立性

设二维随机向量(X,Y)的分布函数与边缘分布函数分别为$F(x,y),F_X(x),F_Y(y)$，若对任何实数x,y，都有$F(x,y)=F_X(x)F_Y(y)$，则称随机变量X与Y是相互独立的.

若(X,Y)是二维离散型随机向量，则X与Y相互独立等价于$p_{ij}=p_{i\cdot}p_{\cdot j}(i,j=1,2,\cdots)$.

若(X,Y)是二维连续型随机向量，则X与Y相互独立等价于对任意实数x,y，$f(x,y)=f_X(x)f_Y(y)$几乎处处成立.

设$(X_1,X_2,\cdots,X_m)$与$(Y_1,Y_2,\cdots,Y_n)$相互独立，h,g为连续函数，则$h(X_1,X_2,\cdots,X_m)$与$g(Y_1,Y_2,\cdots,Y_n)$也相互独立.

4. 随机向量的函数及其概率分布

若(X,Y)是二维离散型随机向量，其分布律为$p_{ij}=P\{X=x_i,Y=y_j\}\ (i,j=1,2,\cdots)$，则$Z=X+Y$的分布律为$P\{Z=z_k\}=\sum_j P\{X=z_k-y_j,Y=y_j\}$.

若$X\sim P(\lambda_1)$，$Y\sim P(\lambda_2)$，且X,Y相互独立，则$Z=X+Y\sim P(\lambda_1+\lambda_2)$.

设二维连续型随机向量(X,Y)的概率密度为$f(x,y)$，若$U=g_1(X,Y)$，$V=g_2(X,Y)$是(X,Y)到(U,V)的一一对应变换，即存在逆变换$X=h_1(U,V)$，$Y=h_2(U,V)$，且g_1,g_2,h_1,h_2都存在连续的一阶偏导数，则(U,V)仍为连续型随机向量，且其概率密度为

$$f_{U,V}(u,v)=\begin{cases} f(h_1(u,v),h_2(u,v))\,|J|, & (u,v)\in\mathscr{B},\\ 0, & \text{其他}\end{cases}$$

其中$\mathscr{B}$为向量值函数$(u,v)=(g_1(x,y),g_2(x,y))$的值域，$J=\dfrac{\partial(x,y)}{\partial(u,v)}$.

若(X,Y)是二维连续型随机向量，其概率密度为$f(x,y)$，则$Z=X+Y$的概率密度为$f_z(z)=\int_{-\infty}^{+\infty} f(x,z-x)\,\mathrm{d}x$，$Z=\dfrac{X}{Y}$的概率密度为$f_z(z)=\int_{-\infty}^{+\infty}|y|f(yz,y)\,\mathrm{d}y$.

若$X\sim N(\mu_1,\sigma_1^2)$，$Y\sim N(\mu_2,\sigma_2^2)$，且相互独立，则$Z=X+Y\sim N(\mu_1+\mu_2,\sigma_1^2+\sigma_2^2)$.

若X,Y的分布函数分别为$F_X(x),F_Y(y)$，且相互独立，则$M=\max\{X,Y\}$的分布函数为$F_M(z)=F_X(z)F_Y(z)$，$N=\min\{X,Y\}$的分布函数为$F_N(z)=1-[1-F_X(z)][1-F_Y(z)]$.

习题3

1. 已知二元函数

$$F(x,y)=\begin{cases}1, & x+y\geqslant 0,\\ 0, & x+y<0\end{cases}$$

问$F(x,y)$是不是某二维随机向量的分布函数？

2. 设二维随机向量(X,Y)的分布函数为$F(x,y)$，试用$F(x,y)$表示下列概率：

(1) $P\{X\leqslant a\}$；　　(2) $P\{Y>b\}$；

(3) $P\{X>a,Y>b\}$；　　(4) $P\{a<X\leqslant b,Y\leqslant c\}$.

3. 设二维随机向量(X,Y)的分布函数为

$$F(x,y)=A\left(B+\arctan\frac{x}{2}\right)\left(C+\arctan\frac{y}{3}\right)$$

求：

(1) 常数 A,B,C；

(2) $P\{0<X\leqslant 2,0<Y\leqslant 3\}$；

(3) $P\{X>2,Y>3\}$；

(4) 关于 X,Y 的边缘分布函数.

4. 袋中有三个分别标着数字 1,2,2 的球，从袋中随机地摸两次球(每次仅摸一球)，用 X,Y 分别记第一次和第二次摸到的球上标着的数字.试按下述两种情况求 (X,Y) 的分布律及分布函数：

(1) 不放回摸球；　　(2) 有放回摸球.

5. 将一枚均匀硬币连续抛掷三次，以 X 表示在三次抛掷中出现正面的次数，以 Y 表示三次中出现正面次数与出现反面次数之差的绝对值，试求二维随机向量 (X,Y) 的分布律及边缘分布律.

6. 对第 3 题中的二维随机向量 (X,Y)，求其概率密度及边缘概率密度.

7. 设二维连续型随机向量 (X,Y) 的概率密度为

$$f(x,y)=\begin{cases}Ae^{-3x-4y}, & x>0,y>0,\\ 0, & \text{其他}\end{cases}$$

求：

(1) 常数 A；

(2) (X,Y) 的分布函数；

(3) 关于 X,Y 的边缘概率密度.

8. 设 G 是由直线 $y=x,y=3,x=1$ 所围成的三角形区域，二维随机向量 (X,Y) 在 G 上服从二维均匀分布.求：

(1) (X,Y) 的概率密度；

(2) $P\{Y-X\leqslant 1\}$；

(3) 关于 X,Y 的边缘概率密度.

9. 设随机向量 (X,Y) 服从二维正态分布，其概率密度为

$$f(x,y)=\frac{1}{4\pi^2}e^{-\frac{(x-1)^2+(y-2)^2}{4\pi}}$$

求：

(1) $P\{2X\leqslant Y\}$；

(2) 随机点 (X,Y) 落在区域 $G=\{(x,y)\mid \pi\leqslant (x-1)^2+(y-2)^2\leqslant 4\pi\}$ 的概率.

10. 设二维随机向量 (X,Y) 的概率密度为

$$f(x,y)=\begin{cases}Cx^2y, & x^2\leqslant y\leqslant 1,\\ 0, & \text{其他}\end{cases}$$

(1) 确定常数 C；

(2) 求概率 $P\{|X|\leqslant Y\}$；

(3) 求关于 X,Y 的边缘概率密度.

11. 对第 5 题，求给定 Y 时 X 的条件分布律.

12. (1) 对第 8 题，求条件概率密度；

(2) 对第 10 题，求条件概率密度；

(3) 对第 10 题，求 $P\left\{X\leqslant\frac{1}{4}\mid Y=\frac{1}{4}\right\}$ 及 $P\left\{Y>\frac{1}{2}\mid X=0\right\}$.

13. 设某医院一天中出生的婴儿个数 X 服从参数为 λ 的泊松分布，Y 是其中的男婴个数.假设每出生一个婴儿，其是男婴的概率为 $\frac{1}{2}$，试求：

(1) (X,Y)的分布律;

(2) Y的分布律;

(3) 给定Y时X的条件分布律.

14. 设随机变量$X\sim U[0,1]$,当$X=x(0<x\leqslant 1)$时,Y服从参数为x的指数分布,试求:

(1) (X,Y)的概率密度;

(2) Y的概率密度;

(3) 给定Y时X的条件概率密度.

15. 设随机变量X服从两点分布:

$$P\{X=1\}=\frac{1}{3},\quad P\{X=2\}=\frac{2}{3}.$$

当$X=x$时,Y服从参数为x的指数分布,试求:

(1) Y的概率密度;

(2) 给定Y时,X的条件分布律.

16. 已知二维随机向量(X,Y)的分布律为

X	Y		
	-1	0	1
1	$\frac{1}{6}$	$\frac{1}{9}$	$\frac{1}{18}$
2	$\frac{1}{3}$	a	b

问a,b为何值时,X与Y相互独立?

17. 设X与Y相互独立,且分布律分别为

X	-1	$-\frac{1}{2}$	0
p	$\frac{1}{2}$	$\frac{1}{3}$	$\frac{1}{6}$

Y	0	2	5	6
p	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{2}{5}$	$\frac{1}{10}$

求二维随机向量(X,Y)的分布律.

18. 设二维随机向量(X,Y)具有下述概率密度,判断X与Y是否独立?

(1) $f(x,y)=\begin{cases}x^2+\dfrac{xy}{3}, & 0\leqslant x\leqslant 1,0\leqslant y\leqslant 2,\\ 0, & \text{其他};\end{cases}$

(2) $f(x,y)=\begin{cases}6x^2y, & 0<x<1,0<y<1,\\ 0, & \text{其他};\end{cases}$

(3) $f(x,y)=\begin{cases}\dfrac{3}{2}x, & 0<x<1,-x<y<x,\\ 0, & \text{其他};\end{cases}$

(4) $f(x,y)=\begin{cases}\dfrac{1}{2}e^{-y}, & 0<x<2,y>0,\\ 0, & \text{其他}.\end{cases}$

19. 设三维连续型随机向量(X,Y,Z)的概率密度为

$$f(x,y,z)=\frac{A}{(1+x^2)(4+y^2)(9+z^2)}$$

(1) 确定常数 A;

(2) 判断 X,Y,Z 是否相互独立.

20. 设三维随机向量(X,Y,Z)的概率密度为

$$f(x,y,z)=\begin{cases}\frac{1}{8}(1-xyz), & -1\leqslant x,y,z\leqslant 1,\\ 0, & \text{其他}\end{cases}$$

试证明 X,Y,Z 两两独立,但不相互独立.

21. 设随机变量 X,Y 相互独立,都服从(0-1)分布 $B\left(1,\frac{1}{2}\right)$.

(1) 求 $X+Y$ 的分布律;

(2) 求 $2X$ 的分布律,并与(1)的结果比较;

(3) 求 XY 的分布律;

(4) 求 X^2 的分布律,并与(3)的结果比较.

22. 设随机变量 X,Y 相互独立,并且分别服从参数为 λ_1,λ_2 的指数分布,求 $Z=X+Y$ 的概率密度.

23. 某种商品一周的需求量是一个随机变量,其概率密度为

$$f(x)=\begin{cases}xe^{-x}, & x>0,\\ 0, & x\leqslant 0\end{cases}$$

设各周的需求量是相互独立的.试求两周及三周的需求量的概率密度.

24. 设随机变量 X,Y 相互独立,都在区间$[0,a]$$(a>0)$上服从均匀分布.求:

(1) $X-Y$ 的概率密度;

(2) $|X-Y|$ 的概率密度.

25. 设二维随机向量(X,Y)具有概率密度

$$f(x,y)=\begin{cases}\frac{1}{4}(1+xy), & |x|\leqslant 1,|y|\leqslant 1,\\ 0, & \text{其他}\end{cases}$$

求 $Z=X+Y$ 的概率密度.

26. 设二维随机向量(X,Y)在矩形域$\{(x,y)\mid 0\leqslant x\leqslant a,0\leqslant y\leqslant b\}$上服从均匀分布,求随机变量 $Z=\frac{X}{Y}$的概率密度.

27. 向一目标射击,目标中心为坐标原点,已知命中点的横坐标 X 和纵坐标 Y 相互独立,且均服从正态分布 $N(0,\sigma^2)$.令 $\rho=\sqrt{X^2+Y^2}$,$\theta=\arctan\frac{Y}{X}$.

(1) 求(ρ,θ)的概率密度;

(2) 判断 ρ 与 θ 是否相互独立.

28. 设随机变量 X,Y 相互独立,X 在区间$[0,5]$上服从均匀分布,Y 服从参数为 5 的指数分布,引入随机变量

$$Z=\begin{cases}1, & X\leqslant Y,\\ 0, & X>Y\end{cases}$$

求:(1) $X+Y$ 的概率密度;

(2) Z 的分布律.

29. 设随机变量 X,Y 相互独立,都在区间$[a,b]$上服从均匀分布,求:

(1) $Z_1=\max\{X,Y\}$ 的概率密度;

(2) $Z_2=\min\{X,Y\}$ 的概率密度;

(3) (Z_1,Z_2) 的概率密度;

(4) $R=Z_1-Z_2$ 的概率密度.

30. 证明:第25题中的 X,Y 不相互独立,但 X^2 与 Y^2 相互独立.

31. 设 (X,Y) 的分布律为

X	Y			
	0	1	2	3
0	0	0.05	0.08	0.12
1	0.01	0.09	0.12	0.15
2	0.02	0.11	0.13	0.12

(1) 求 $Z=X+Y$ 的分布律;

(2) 求 $U=\max\{X,Y\}$ 的分布律;

(3) 求 $V=\min\{X,Y\}$ 的分布律.

32. 设随机变量 X,Y 相互独立,并且分别服从参数为 λ_1,λ_2 的泊松分布.令 $Z=X+Y$,求给定 Z 时 X 的条件分布律.

33. 设 X 与 Y 相互独立,都服从几何分布 $Ge(p)$,其中 $0<p<1$ 试求:

(1) $Z=X+Y$ 的分布律;

(2) 给定 Z 时 X 的条件分布律;

(3) $W=\max\{X,Y\}$ 的分布律;

(4) $V=\min\{X,Y\}$ 的分布律.

34. 设随机变量 X 与 Y 相互独立,X 服从参数为 $\frac{1}{2}$ 的指数分布,Y 服从分布 $B(1,0.4)$,令 $Z=X+Y$,求 Z 的分布函数.

35. 设二维随机向量 (X,Y) 在矩形域 $G=\{(x,y)\mid 0\leqslant x\leqslant 2,0\leqslant y\leqslant 1\}$ 上服从均匀分布,试求边长为 X 和 Y 的矩形面积 S 的概率密度 $f(s)$.

自测题3

习题3参考答案

第4章 随机变量的数字特征

在第2,3章中,我们讨论了随机变量与随机向量的概率分布(分布律或概率密度或分布函数),概率分布描述了该变量取值的统计规律的全貌.而随机变量的数字特征则是一些由它的概率分布所决定的常数,这些常数能够反映随机变量某些方面的重要特征,故称之为随机变量的数字特征,它们在理论和应用上都具有重要的意义.本章介绍随机变量的常用数字特征:数学期望、方差、协方差和相关系数等.

4.1 数学期望

4.1.1 数学期望的定义

先看一个例子.

例4.1 某车间生产一种自行车配件.每天质检员都从一大批这种配件中随机地取出n个来检验.以X表示查出的次品件数.如果检查了N天,查出次品为$0,1,2,\cdots,n$个的天数分别为$m_0,m_1,\cdots,m_n$($m_0+m_1+\cdots+m_n=N$),那么N天中查出的次品总数为$\sum\limits_{k=0}^{n}km_k$,于是平均每天查出

$$\frac{1}{N}\sum_{k=0}^{n}km_k=\sum_{k=0}^{n}k\frac{m_k}{N}$$

个次品.记$p_k=P\{X=k\}$($k=0,1,2,\cdots,n$),由于$\frac{m_k}{N}$是N次试验中出现k个次品的频率,当N充分大时,频率$\frac{m_k}{N}$将接近于X取k值的概率,即$\frac{m_k}{N}\approx p_k$(在下一章,我们将指出频率与相应的概率之间的关系).因此

$$\sum_{k=0}^{n}k\frac{m_k}{N}\approx\sum_{k=0}^{n}kp_k$$

上式表明:当试验次数很大时,随机变量X的观测值的算术平均值$\sum\limits_{k=0}^{n}k\frac{m_k}{N}$将接近于$\sum\limits_{k=0}^{n}kp_k$.由于数$\sum\limits_{k=0}^{n}kp_k$不依赖于试验的次数$N$,也不受这$N$次试验是由何人做的影响,因此它是随机变量$X$的某种客观属性,称$\sum\limits_{k=0}^{n}kp_k$为随机变量$X$的**数学期望**或**理论均值**.

拓展阅读:数学期望概念的产生:分赌金问题

下面来介绍数学期望的定义.

定义4.1 设离散型随机变量X的分布律为$P\{X=x_i\}=p_i,i=1,2,\cdots$.若级数$\sum\limits_{i=1}^{\infty}x_ip_i$绝对收敛,则称$\sum\limits_{i=1}^{\infty}x_ip_i$为随机变量$X$的**数学期望**,简称期望,又称为均值,记

作 $E(X)$[①]，即

$$E(X)=\sum_{i=1}^{\infty}x_ip_i \tag{4.1.1}$$

(4.1.1)式的右端是无穷级数.数学期望应与 X 的取值 $x_1,x_2,\cdots,x_n,\cdots$ 的排列次序无关，为此，要求 $\sum_{i=1}^{\infty}x_ip_i$ 无论以何种方式重排各项的求和顺序都能收敛到同一数值，但这是有条件的.根据级数理论，如果 $\sum_{i=1}^{\infty}x_ip_i$ 是绝对收敛的，那么就可满足上述要求.

对于连续型随机变量，可以用积分代替求和，从而得到相应的数学期望定义.

定义 4.2 设连续型随机变量 X 的概率密度为 $f(x)$，若积分 $\int_{-\infty}^{+\infty}xf(x)\mathrm{d}x$ 绝对收敛，则称 $\int_{-\infty}^{+\infty}xf(x)\mathrm{d}x$ 为随机变量 X 的数学期望，记为 $E(X)$，即

$$E(X)=\int_{-\infty}^{+\infty}xf(x)\mathrm{d}x \tag{4.1.2}$$

数学期望 $E(X)$ 是由随机变量 X 的概率分布所确定的，因此当 X 服从某一分布时，也把 $E(X)$ 称为该分布的数学期望.

例 4.2 设 $X\sim B(n,p)$，求 $E(X)$.

解 由(4.1.1)式

$$\begin{aligned}E(X)&=\sum_{i=0}^{n}i\mathrm{C}_n^ip^i(1-p)^{n-i}=\sum_{i=1}^{n}i\mathrm{C}_n^ip^i(1-p)^{n-i}\\&=np\sum_{i=1}^{n}\mathrm{C}_{n-1}^{i-1}p^{i-1}(1-p)^{n-i}\\&=np\sum_{k=0}^{n-1}\mathrm{C}_{n-1}^{k}p^{k}(1-p)^{n-1-k}\\&=np[p+(1-p)]^{n-1}\\&=np\end{aligned}$$

二项分布的数学期望为 np 的意思是：具有概率 p 的事件 A 在 n 次独立重复试验中平均发生 np 次.例如，抛掷一枚均匀硬币，记 $A=\{$掷出正面$\}$，于是 $p=P(A)=\frac{1}{2}$.若抛掷 100 次这枚硬币，那么，可以“期望”出现 $100\times\frac{1}{2}=50$ 次正面.

例 4.3 设 X 服从参数为 λ 的泊松分布 $P(\lambda)$，求 $E(X)$.

解 因为

$$\begin{aligned}\sum_{k=0}^{\infty}k\frac{\lambda^k}{k!}\mathrm{e}^{-\lambda}&=\sum_{k=1}^{\infty}k\frac{\lambda^k}{k!}\mathrm{e}^{-\lambda}=\sum_{k=1}^{\infty}\frac{\lambda^k}{(k-1)!}\mathrm{e}^{-\lambda}\\&=\lambda\mathrm{e}^{-\lambda}\sum_{k=1}^{\infty}\frac{\lambda^{k-1}}{(k-1)!}=\lambda\mathrm{e}^{-\lambda}\mathrm{e}^{\lambda}\\&=\lambda<+\infty\end{aligned}$$

① 在有些表达式中，为简化记号，$E(X)$ 也可直接写成 EX.

所以 X 的数学期望是存在的，且有 $E(X)=\lambda$. 这表明泊松分布中的参数 λ 恰为 X 的数学期望.

例 4.4 设 $X\sim N(\mu,\sigma^2)$，求 $E(X)$.

解 因为 $f(x)=\dfrac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}}(-\infty<x<+\infty)$，不难看出

$$\int_{-\infty}^{+\infty}|x|f(x)\,dx<+\infty$$

所以 $E(X)$ 存在[①]，且有

$$E(X)=\int_{-\infty}^{+\infty}x\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}}dx$$

令 $\dfrac{x-\mu}{\sigma}=t$，则 $x=\mu+\sigma t$，$dx=\sigma dt$，于是

$$E(X)=\mu\int_{-\infty}^{+\infty}\frac{1}{\sqrt{2\pi}}e^{-\frac{t^2}{2}}dt+\sigma\int_{-\infty}^{+\infty}\frac{t}{\sqrt{2\pi}}e^{-\frac{t^2}{2}}dt$$

$$=\mu\times1+\sigma\times0=\mu$$

由此可见，正态分布 $N(\mu,\sigma^2)$ 的参数 μ 正好是它的数学期望.

例 4.5 设 X 在区间 $[a,b]$ 上服从均匀分布 $U[a,b]$，求 $E(X)$.

解 因为 X 的概率密度为

$$f(x)=\begin{cases}\dfrac{1}{b-a}, & a\leqslant x\leqslant b,\\ 0, & \text{其他}\end{cases}$$

所以

$$E(X)=\int_{-\infty}^{+\infty}xf(x)\,dx=\int_a^b x\frac{1}{b-a}dx=\frac{a+b}{2}$$

即数学期望是区间的中点.

为加深对数学期望的理解，把它与力学中的质心概念作一类比. 设 X 为离散型随机变量，X 的可能取值为 $x_1,x_2,\cdots,x_n,\cdots$，其分布律为 $p_k=P\{X=x_k\}(k=1,2,\cdots)$，现在把 x_k 看作质点系中第 k 个质点所在位置的横坐标，p_k 看作第 k 个质点的“质量”，那么

$$x_C=\frac{\sum\limits_{k=1}^{\infty}x_kp_k}{\sum\limits_{k=1}^{\infty}p_k}$$

表示质点系的质心横坐标，因为现在的质点系的总“质量” $\sum\limits_{k=1}^{\infty}p_k=1$，所以 $x_C=\sum\limits_{k=1}^{\infty}x_kp_k$. 既然质心是质点系质量分布的中心，所以同样可以认为数学期望（理论均值）是概率分布的中心. 对连续型随机变量的情形，亦可作类似的对比. 现在，就不难

并不是所有随机变量的数学期望都存在（如习题 4 第 7 题）.

① 以后求 $E(X)$ 时，除特别声明外，均认为 $E(X)$ 已存在.

理解例4.4、例4.5中的计算结果了.

4.1.2 随机变量的函数的数学期望

对一维随机变量的函数,有以下定理:

定理4.1 (1) 设离散型随机变量 X 的分布律为 $P\{X=x_i\}=p_i, i=1,2,\cdots$,若 $g(x)$ 为连续函数,且 $\sum\limits_{i=1}^{\infty} g(x_i)p_i$ 绝对收敛,则

$$E[g(X)]=\sum_{i=1}^{\infty} g(x_i)p_i \tag{4.1.3}$$

(2) 设连续型随机变量 X 的概率密度为 $f(x)$,若 $g(x)$ 为连续函数,且 $\int_{-\infty}^{+\infty} g(x)\cdot f(x)\mathrm{d}x$ 绝对收敛,则

$$E[g(X)]=\int_{-\infty}^{+\infty} g(x)f(x)\mathrm{d}x \tag{4.1.4}$$

直觉上,要计算随机变量 $Y=g(X)$ 的数学期望,应当先由 X 的概率分布求出 Y 的概率分布,再按随机变量数学期望的定义,计算 $E(Y)$.这种想法当然没有错,不过定理4.1告诉我们还有更简便的方法来计算 $E(Y)$:可省去求 Y 的概率分布这一环节,直接由(4.1.3)式或(4.1.4)式便可计算 Y 的数学期望.

定理4.1的证明从略.

例4.6 设风速 V 为连续型随机变量,且在区间 $[0,a]$ $(a>0)$ 上服从均匀分布,又设飞机机翼受到的压力 W 是风速 V 的函数 $W=kV^2$ $(k>0)$,求 $E(W)$.

解

$$E(W)=\int_{-\infty}^{+\infty} kv^2 f(v)\mathrm{d}v=\int_0^a \frac{kv^2}{a}\mathrm{d}v=\frac{ka^2}{3}$$

例4.7 设随机变量 $X\sim N(\mu,\sigma^2)$,又设随机变量 $Y=\mathrm{e}^X$,求 $E(Y)$.

解 因为

$$\int_{-\infty}^{+\infty} \mathrm{e}^x f(x)\mathrm{d}x=\int_{-\infty}^{+\infty} \mathrm{e}^x \frac{1}{\sqrt{2\pi}\sigma}\mathrm{e}^{-\frac{(x-\mu)^2}{2\sigma^2}}\mathrm{d}x$$

令 $\dfrac{x-\mu}{\sigma}=t$,则 $x=\mu+\sigma t$, $\mathrm{d}x=\sigma\mathrm{d}t$,所以

$$\int_{-\infty}^{+\infty} \mathrm{e}^x f(x)\mathrm{d}x=\int_{-\infty}^{+\infty} \mathrm{e}^{\mu+\sigma t}\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-\frac{t^2}{2}}\mathrm{d}t=\mathrm{e}^{\mu+\frac{\sigma^2}{2}}\int_{-\infty}^{+\infty}\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-\frac{(t-\sigma)^2}{2}}\mathrm{d}t=\mathrm{e}^{\mu+\frac{\sigma^2}{2}}$$

故 $E(Y)=\mathrm{e}^{\mu+\frac{\sigma^2}{2}}$.

对二维随机向量的函数,有类似定理4.1的结论.

定理4.2 (1) 设二维离散型随机向量 (X,Y) 的分布律为 $P\{X=x_i,Y=y_j\}=p_{ij}$, $i,j=1,2,\cdots$,若 $g(x,y)$ 为二元连续函数,且 $\sum\limits_{j=1}^{\infty}\sum\limits_{i=1}^{\infty} g(x_i,y_j)p_{ij}$ 绝对收敛,则

$$E[g(X,Y)]=\sum_{j=1}^{\infty}\sum_{i=1}^{\infty} g(x_i,y_j)p_{ij} \tag{4.1.5}$$

(2) 设二维连续型随机向量(X,Y)的概率密度为$f(x,y)$,若$g(x,y)$为二元连续函数,且$\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty} g(x,y)f(x,y)\,\mathrm{d}x\mathrm{d}y$绝对收敛,则

$$E[g(X,Y)]=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty} g(x,y)f(x,y)\,\mathrm{d}x\mathrm{d}y \tag{4.1.6}$$

特别,若$E(X)$存在,取$g(x,y)=x$,当(X,Y)为离散型随机向量时,则有

$$E(X)=\sum_{j=1}^{\infty}\sum_{i=1}^{\infty} x_i p_{ij}=\sum_{i=1}^{+\infty} x_i p_i. \tag{4.1.7}$$

当(X,Y)为连续型随机向量时,则有

$$E(X)=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty} xf(x,y)\,\mathrm{d}x\mathrm{d}y=\int_{-\infty}^{+\infty} xf_X(x)\,\mathrm{d}x \tag{4.1.8}$$

例 4.8 设(X,Y)在半圆域$D=\{(x,y)\mid x^2+y^2\leqslant 1,y\geqslant 0\}$上服从均匀分布,求$X$,$Y$以及$X^2Y$的数学期望.

解 因为(X,Y)的概率密度为

$$f(x,y)=\begin{cases}\dfrac{2}{\pi}, & x^2+y^2\leqslant 1,y\geqslant 0,\\ 0, & \text{其他}\end{cases}$$

所以

$$E(X)=\iint_D x\,\frac{2}{\pi}\mathrm{d}x\mathrm{d}y=\frac{2}{\pi}\int_{-1}^{1}x\,\mathrm{d}x\int_0^{\sqrt{1-x^2}}\mathrm{d}y=0$$

$$E(Y)=\iint_D y\,\frac{2}{\pi}\mathrm{d}x\mathrm{d}y=\frac{2}{\pi}\int_{-1}^{1}\mathrm{d}x\int_0^{\sqrt{1-x^2}}y\,\mathrm{d}y=\frac{4}{3\pi}$$

$$E(X^2Y)=\iint_D x^2y\,\frac{2}{\pi}\mathrm{d}x\mathrm{d}y=\frac{2}{\pi}\int_{-1}^{1}x^2\,\mathrm{d}x\int_0^{\sqrt{1-x^2}}y\,\mathrm{d}y=\frac{4}{15\pi}$$

4.1.3 数学期望的性质

本段约定:C,C_k等代表常数;X,X_k,Y等代表随机变量,并且所涉及的各随机变量的数学期望都是存在的.

数学期望具有如下性质:

(1) $E(C)=C$; (4.1.9)

(2) $E(CX)=CE(X)$; (4.1.10)

(3) $E(X+Y)=E(X)+E(Y)$; (4.1.11)

(4) 若X与Y相互独立,则

$$E(XY)=E(X)E(Y) \tag{4.1.12}$$

证 性质(1)和(2)的证明比较简单,留给读者去完成,下面仅就二维连续型随机向量(X,Y)来证明性质(3)和(4).设$f(x,y)$,$f_X(x)$与$f_Y(y)$分别为(X,Y)的概率密度以及关于X与Y的边缘概率密度.因为

$$\begin{aligned}E(X+Y)&=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}(x+y)f(x,y)\,\mathrm{d}x\mathrm{d}y\\&=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}xf(x,y)\,\mathrm{d}x\mathrm{d}y+\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}yf(x,y)\,\mathrm{d}x\mathrm{d}y\end{aligned}$$

$$=E(X)+E(Y)\text{（由(4.1.8)式知）}$$

故(4.1.11)式得证.

因 X 与 Y 相互独立，即有 $f(x,y)=f_X(x)f_Y(y)$，于是

$$E(XY)=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}xyf(x,y)\,\mathrm{d}x\mathrm{d}y=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}xyf_X(x)f_Y(y)\,\mathrm{d}x\mathrm{d}y$$

$$=\int_{-\infty}^{+\infty}xf_X(x)\,\mathrm{d}x\int_{-\infty}^{+\infty}yf_Y(y)\,\mathrm{d}y=E(X)E(Y)$$

故(4.1.12)式得证.

当(X,Y)为二维离散型随机向量时，用类似的方法可以证明性质(3)和(4).

把性质(2)与性质(3)结合起来，则有

$$E(C_1X+C_2Y)=C_1E(X)+C_2E(Y) \tag{4.1.13}$$

一般地，数学期望具有如下的线性性质：

$$E\Big[\sum_{k=1}^{n}C_kX_k\Big]=\sum_{k=1}^{n}C_kE(X_k) \tag{4.1.14}$$

性质(4)还可以推广到 $n(n>2)$ 个相互独立的随机变量，即若 $X_1,X_2,\cdots,X_n$ 是 n 个相互独立的随机变量，则

$$E(X_1X_2\cdots X_n)=E(X_1)E(X_2)\cdots E(X_n) \tag{4.1.15}$$

拓展阅读：数学期望的应用：检测问题

例 4.9 设随机变量 $X\sim B(n,p)$，试由数学期望的性质求 $E(X)$.

解 在前面的例4.2中，我们用定义4.1，直接算出 $E(X)$，这里，介绍一种更简便的方法.注意到 X 为在 n 次独立重复试验中某事件 A 发生的次数，并且在每次试验中 A 发生的概率为 p.现引入下列随机变量：

$$X_k=\begin{cases}1, & \text{第 } k \text{ 次试验时事件 } A \text{ 发生},\\ 0, & \text{第 } k \text{ 次试验时事件 } A \text{ 不发生}\end{cases}$$

其中 $k=1,2,\cdots,n$.由试验的独立性可知 $X_1,X_2,\cdots,X_n$ 是相互独立的，且有

$$X=X_1+X_2+\cdots+X_n$$

因

$$P\{X_k=1\}=P(A)=p,\quad P\{X_k=0\}=P(\overline{A})=1-p(k=1,2,\cdots,n)$$

故

$$E(X_k)=1\times p+0\times(1-p)=p(k=1,2,\cdots,n)$$

最后由(4.1.14)式，得

$$E(X)=E(X_1)+E(X_2)+\cdots+E(X_n)=np$$

4.2 方差

4.2.1 方差与标准差

先看一个例子.

例 4.10 设甲、乙两名射击运动员在一次射击比赛中打出的环数分别为 X,Y，并有如下的分布律：

$$X\sim\begin{pmatrix}10 & 9 & 8 & 7\\ 0.4 & 0.3 & 0.2 & 0.1\end{pmatrix},\quad Y\sim\begin{pmatrix}10 & 9 & 8\\ 0.25 & 0.5 & 0.25\end{pmatrix}$$

经计算可知,甲、乙两人打出的平均环数相同($E(X)=9, E(Y)=9$),但比较两人打出环数的分布律可以发现,乙比甲在比赛中波动更小,表现更为稳定,从这个意义上讲,乙优于甲,然而,这一点从两人射击环数的期望值上是看不来的.因此有必要引入一个能描述随机变量 X 对期望 $E(X)$ 的分散程度的量.

采用 $E\{[X-E(X)]^2\}$ 来度量 X 对其期望 $E(X)$ 的分散程度.这个量就叫做 X 的方差("平均平方偏差").

定义 4.3 设 X 为随机变量,若 $E\{[X-E(X)]^2\}$ 存在,则称

$$D(X)=E\{[X-E(X)]^2\} \tag{4.2.1}$$

为 X 的方差[①],称 $\sqrt{D(X)}$ 为 X 的标准差,记为 $\sigma(X)$,即 $\sigma(X)=\sqrt{D(X)}$.

由于 $\sigma(X)$ 的量纲与 X 的量纲相同,因而,在工程技术领域中常用标准差 $\sigma(X)$.

记 $\mu=E(X)$,因为

$$[X-E(X)]^2=(X-\mu)^2=X^2-2\mu X+\mu^2$$

根据数学期望的性质,有

$$E\{[X-E(X)]^2\}=E(X^2)-2\mu E(X)+\mu^2=E(X^2)-\mu^2$$

所以

$$D(X)=E(X^2)-[E(X)]^2 \tag{4.2.2}$$

在许多场合,用(4.2.2)式计算方差要比用(4.2.1)式方便.

例 4.11 设 X 服从单点分布,$P\{X=C\}=1$,求 $D(X)$.

解 因为 $E(X)=C\times 1=C$, $E(X^2)=C^2\times 1=C^2$,所以

$$D(X)=E(X^2)-[E(X)]^2=C^2-C^2=0$$

知识点讲解视频:马尔可夫不等式的证明及应用

4.2.2 方差的性质

在讨论方差的性质之前,我们先来介绍一个重要的不等式.

定理 4.3(马尔可夫不等式) 设 X 为随机变量,若 $E(|X|^r)<+\infty$,其中 $r>0$ 为实数,则对任意正数 ε,有

$$P\{|X|\geqslant\varepsilon\}\leqslant\frac{E(|X|^r)}{\varepsilon^r} \tag{4.2.3}$$

证 以下仅就 X 为连续型随机变量的情形加以证明,并设 X 的概率密度为 $f(x)$.

$$P\{|X|\geqslant\varepsilon\}=\int_{|x|\geqslant\varepsilon}f(x)\,\mathrm{d}x\leqslant\int_{|x|\geqslant\varepsilon}\frac{|x|^r}{\varepsilon^r}f(x)\,\mathrm{d}x\quad\left(\text{因为在积分域上,恒有 }1\leqslant\frac{|x|^r}{\varepsilon^r}\right)$$

$$\leqslant\frac{1}{\varepsilon^r}\int_{-\infty}^{+\infty}|x|^r f(x)\,\mathrm{d}x=\frac{E(|X|^r)}{\varepsilon^r}$$

方差具有下列性质:

若 X, Y 为随机变量,a 为常数,并假定所涉及的随机变量的方差均存在,则

① 方差也可记为 $\mathrm{Var}(X)$ 或 $\sigma^2(X)$,在有些表达式中,为简化记号,$D(X)$ 也可以直接写成 DX.

(1) $D(a)=0$; (4.2.4)

(2) $D(aX)=a^2D(X)$; (4.2.5)

(3) 若 X 与 Y 相互独立,则 $D(X\pm Y)=D(X)+D(Y)$; (4.2.6)

(4) $D(X)=0$ 的充要条件是 $P\{X=E(X)\}=1$.

证 性质(1),(2)的证明比较简单,留给读者做练习,下面证明性质(3),(4).

先来证明性质(3).由于

$$[(X\pm Y)-E(X\pm Y)]^2=[X-E(X)]^2\pm 2[X-E(X)][Y-E(Y)]+[Y-E(Y)]^2$$

在上式两端取期望运算并由期望的性质,得

$$\begin{aligned}&E\{[(X\pm Y)-E(X\pm Y)]^2\}\\&=E\{[X-E(X)]^2\}\pm 2E\{[X-E(X)][Y-E(Y)]\}+E\{[Y-E(Y)]^2\}\end{aligned} \tag{4.2.7}$$

因 X 与 Y 相互独立,故 $X-E(X)$ 与 $Y-E(Y)$ 也相互独立,从而

$$E\{[X-E(X)][Y-E(Y)]\}=E[X-E(X)]E[Y-E(Y)]=0$$

于是

$$D(X\pm Y)=E\{[(X\pm Y)-E(X\pm Y)]^2\}=E\{[X-E(X)]^2\}+E\{[Y-E(Y)]^2\}=D(X)+D(Y)$$

性质(3)得证.

再来证明性质(4).根据例 4.11,只需证明必要性("⇒"),设 $D(X)=0$,在马尔可夫不等式中,取 $r=2$,并以 $X-E(X)$ 代替 X,则对任意 $\varepsilon>0$,都有

$$P\{|X-E(X)|\geqslant\varepsilon\}\leqslant\frac{D(X)}{\varepsilon^2}=0$$

因为 $\{|X-E(X)|\neq 0\}=\bigcup\limits_{n=1}^{\infty}\left\{|X-E(X)|\geqslant\frac{1}{n}\right\}$,且 $\left\{|X-E(X)|\geqslant\frac{1}{n}\right\}\subset\left\{|X-E(X)|\geqslant\frac{1}{n+1}\right\}(n=1,2,\cdots)$,由概率的连续性以及 $P\left\{|X-E(X)|\geqslant\frac{1}{n}\right\}=0$,$n=1,2,\cdots$,可得

$$P\{|X-E(X)|\neq 0\}=\lim_{n\to\infty}P\left\{|X-E(X)|\geqslant\frac{1}{n}\right\}=0$$

所以

$$P\{|X-E(X)|=0\}=1-P\{|X-E(X)|\neq 0\}=1$$

把性质(2)与性质(3)结合起来,运用数学归纳法可以推证如下更一般的结果:

(5) 若 $X_1,X_2,\cdots,X_n$ 是相互独立的随机变量,则

$$D\left(\sum_{i=1}^{n}C_iX_i\right)=\sum_{i=1}^{n}C_i^2D(X_i) \tag{4.2.8}$$

将复杂随机变量写成一些简单随机变量之和,进而求其数学期望和方差是常用的一种计算技巧(参见习题4第16题)

例 4.12 设随机变量 $X\sim B(n,p)$,求 $D(X)$.

解 用例 4.9 中的方法,把 X 表示为

$$X=X_1+X_2+\cdots+X_n$$

其中 $X_1,X_2,\cdots,X_n$ 相互独立且都服从(0-1)分布.而

$$D(X_k)=E(X_k^2)-[E(X_k)]^2=1^2\times p+0^2\times(1-p)-p^2=p(1-p),\quad k=1,2,\cdots,n$$

由方差的性质(5),得

$$D(X)=D(X_1)+D(X_2)+\cdots+D(X_n)=np(1-p)$$

例 4.13 设随机变量 X 服从参数为 λ 的泊松分布,求 $D(X)$.

解 已知 X 的分布律为 $P\{X=i\}=\dfrac{\lambda^i e^{-\lambda}}{i!}(i=0,1,2,\cdots)$,又知 $E(X)=\lambda$.为求 $D(X)$,先算 $E(X^2)$.因

$$\begin{aligned}\sum_{i=0}^{\infty} i^2\frac{\lambda^i e^{-\lambda}}{i!}&=\sum_{i=1}^{\infty} i^2\frac{\lambda^i e^{-\lambda}}{i!}=\lambda\sum_{i=1}^{\infty} i\frac{\lambda^{i-1}e^{-\lambda}}{(i-1)!}\\&=\lambda\sum_{k=0}^{\infty}(k+1)\frac{\lambda^k e^{-\lambda}}{k!}=\lambda\left(\sum_{k=0}^{\infty} k\frac{\lambda^k e^{-\lambda}}{k!}+\sum_{k=0}^{\infty}\frac{\lambda^k e^{-\lambda}}{k!}\right)\\&=\lambda(\lambda+1)\end{aligned}$$

故 $E(X^2)=\sum\limits_{i=0}^{\infty} i^2\dfrac{\lambda^i e^{-\lambda}}{i!}=\lambda(\lambda+1)$,从而

$$D(X)=E(X^2)-[E(X)]^2=\lambda(\lambda+1)-\lambda^2=\lambda$$

计算结果表明:泊松分布的数学期望与其方差相同,都等于参数 λ.

例 4.14 设随机变量 $X\sim N(\mu,\sigma^2)$,求 $D(X)$.

解 已知 X 的概率密度为

$$f(x)=\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}},\quad -\infty<x<+\infty$$

又知 $E(X)=\mu$.取 $g(x)=(x-\mu)^2$,因为

$$\int_{-\infty}^{+\infty} g(x)f(x)\,dx=\int_{-\infty}^{+\infty}(x-\mu)^2\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}}dx$$

令 $t=\dfrac{x-\mu}{\sigma}$,由分部积分法得

$$\int_{-\infty}^{+\infty}(x-\mu)^2\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}}dx=\sigma^2$$

所以 $D(X)=E[g(X)]=\sigma^2$.

上述结果表明:正态分布 $N(\mu,\sigma^2)$ 中的第二个参数 σ^2 是其方差.

例 4.15 设 X 在区间 $[a,b]$ 上服从均匀分布,求 $D(X)$.

解 已知 X 的概率密度为

$$f(x)=\begin{cases}\dfrac{1}{b-a}, & a\leqslant x\leqslant b,\\ 0, & \text{其他}\end{cases}$$

又知 $E(X)=\dfrac{a+b}{2}$,而 $\int_{-\infty}^{+\infty}x^2f(x)\,dx=\int_a^b\dfrac{x^2}{b-a}dx=\dfrac{b^2+ab+a^2}{3}$,即 $E(X^2)=\dfrac{b^2+ab+a^2}{3}$,于是

$$D(X)=E(X^2)-[E(X)]^2=\frac{(b-a)^2}{12}$$

我们把常用的离散型、连续型分布的数学期望与方差汇总成表 4.1,表 4.2,以备读者查用.

MATLAB 提供了一些形如"分布+stat"的函数用来计算分布的数学期望和方差.如 binostat(n,p)计算二项分布的期望和方差,poisstat(lambda)计算泊松分布的期望和方差,normstat 计算正态分布的期望和方差,expstat 计算指数分布的期望和方差等.

表 4.1 常用的离散型分布的数学期望与方差

离散型分布	分布律	数学期望	方差
(0—1)分布 $B(1,p)$	$p^k(1-p)^{1-k}, k=0,1$	p	$p(1-p)$
二项分布 $B(n,p)$	$C_n^k p^k (1-p)^{n-k}, k=0,1,\cdots,n$	np	$np(1-p)$
泊松分布 $P(\lambda)$	$\frac{\lambda^k}{k!}e^{-\lambda}, k=0,1,2,\cdots$	λ	λ
几何分布 $Ge(p)$	$p(1-p)^{k-1}, k=1,2,\cdots$	$\frac{1}{p}$	$\frac{1-p}{p^2}$

表 4.2 常用的连续型分布的数学期望与方差

连续型分布	概率密度	数学期望	方差
正态分布 $N(\mu,\sigma^2)$	$\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}}, -\infty<x<+\infty$	μ	σ^2
均匀分布 $U(a,b)$	$\begin{cases}\frac{1}{b-a}, & a\leqslant x\leqslant b,\\ 0, & x<a \text{ 或 } x>b\end{cases}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
指数分布 $Exp(\lambda)$	$\begin{cases}\lambda e^{-\lambda x}, & x\geqslant 0,\\ 0, & x<0\end{cases}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$

4.3 协方差与相关系数 矩

4.3.1 协方差与相关系数

对于多维随机向量$(X_1,X_2,\cdots,X_n)$,它的每个分量 $X_i(1\leqslant i\leqslant n)$是一维随机变量,因而,可以讨论 X_i 的数学期望和方差.除此之外,人们还常常希望了解反映分量之间相互关系的数字特征.本段将针对二维随机向量(X,Y)来讨论有关这方面的问题.

定义 4.4 设(X,Y)为二维随机向量,若 $E\{[X-E(X)][Y-E(Y)]\}$存在,则称 $E\{[X-E(X)][Y-E(Y)]\}$为 X 与 Y 的协方差,记为 $\mathrm{Cov}(X,Y)$,即

$$\mathrm{Cov}(X,Y)=E\{[X-E(X)][Y-E(Y)]\} \tag{4.3.1}$$

由上述定义可知,$\mathrm{Cov}(X,X)=E\{[X-E(X)]^2\}=D(X)$.既然,$X-E(X)$与 $X-E(X)$之积的数学期望称为方差,现在把其中的一个 $X-E(X)$换成 $Y-E(Y)$,由于其形式与方差类似,又是 X 与 Y 协同参与的结果,故称之为"协方差".

把(4.3.1)式的右端方括号中的各项乘开,再利用数学期望的性质,可得到一个较实用的计算 $\mathrm{Cov}(X,Y)$的公式

$$\mathrm{Cov}(X,Y)=E(XY)-E(X)E(Y) \tag{4.3.2}$$

协方差具有下列性质：

若 X_1,X_2,X,Y 为随机变量，a,b 为常数，并假定所涉及的协方差均存在，则

(1) $\mathrm{Cov}(a,X)=0$； (4.3.3)

(2) $\mathrm{Cov}(X,Y)=\mathrm{Cov}(Y,X)$； (4.3.4)

(3) $\mathrm{Cov}(aX,bY)=ab\mathrm{Cov}(X,Y)$； (4.3.5)

(4) $\mathrm{Cov}(X_1+X_2,Y)=\mathrm{Cov}(X_1,Y)+\mathrm{Cov}(X_2,Y)$； (4.3.6)

(5) 若 X 与 Y 相互独立，则

$$\mathrm{Cov}(X,Y)=0 \tag{4.3.7}$$

(6) 若 $E(X^2),E(Y^2)$ 存在，则

$$[E(XY)]^2\leqslant E(X^2)E(Y^2) \tag{4.3.8}$$

特别地，有

$$[\mathrm{Cov}(X,Y)]^2\leqslant D(X)D(Y) \tag{4.3.9}$$

证 根据协方差的定义以及(4.3.2)式，容易证明协方差性质(1)—(4).下面来证明性质(5)，因 X 与 Y 相互独立，故由期望的性质，得

$$\mathrm{Cov}(X,Y)=E(XY)-E(X)E(Y)=E(X)E(Y)-E(X)E(Y)=0$$

性质(5)得证.

为证性质(6)，考虑如下实变量 t 的函数

$$q(t)=E[(tX+Y)^2]=t^2E(X^2)+2tE(XY)+E(Y^2)$$

对任意实数 t，因为随机变量 $(tX+Y)^2$ 的可能值是非负的，所以其理论均值亦是非负的，即对一切 t，有 $q(t)\geqslant 0$.因此，一元二次方程 $q(t)=0$ 的判别式应满足条件

$$4[E(XY)]^2-4E(X^2)E(Y^2)\leqslant 0$$

此即

$$[E(XY)]^2\leqslant E(X^2)E(Y^2)$$

最后令 $U=X-E(X)$，$V=Y-E(Y)$，由已知条件知 $E(U^2),E(V^2)$ 存在，对 U,V 应用不等式(4.3.8)，即得不等式(4.3.9).

通常，不等式(4.3.9)称为**柯西-施瓦茨不等式**.

利用协方差的记号，可把(4.2.7)式改写成

$$D(X\pm Y)=D(X)\pm 2\mathrm{Cov}(X,Y)+D(Y) \tag{4.3.10}$$

从方差性质(3)的证明过程可知，无论 X 与 Y 是否相互独立，(4.3.10)式都成立.于是，当 X 与 Y 相互独立时，由协方差性质(5)知 $\mathrm{Cov}(X,Y)=0$，从而(4.2.6)式成立.

定义 4.5 若 $D(X)>0,D(Y)>0$，则称 $\dfrac{\mathrm{Cov}(X,Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$ 为 X 与 Y 的**相关系数**，记为 $\rho(X,Y)$，即

$$\rho(X,Y)\overset{\mathrm{def}}{=\!=}\frac{\mathrm{Cov}(X,Y)}{\sqrt{D(X)}\sqrt{D(Y)}} \tag{4.3.11}$$

相关系数具有下列性质：

(1) 若 X 与 Y 相互独立，则 $\rho(X,Y)=0$；

(2) $|\rho(X,Y)|\leqslant 1$；

(3) $|\rho(X,Y)|=1$ 的充要条件是:存在常数 a,b,使得 $P\{Y=a+bX\}=1$.

证 由相关系数的定义以及协方差的性质(5),(6),容易证明相关系数的性质(1),(2).下面我们来证明性质(3).首先,$|\rho(X,Y)|=1$ 等价于 $[\mathrm{Cov}(X,Y)]^2=D(X)D(Y)$.考虑如下的一元二次方程

$$t^2D(X)+2t\mathrm{Cov}(X,Y)+D(Y)=0 \tag{4.3.12}$$

对方程(4.3.12)而言,条件 $[\mathrm{Cov}(X,Y)]^2=D(X)D(Y)$ 等价于上述方程只有重根 $t=t_0$,即

$$t_0^2D(X)+2t_0\mathrm{Cov}(X,Y)+D(Y)=0$$

而上式又等价于

$$E\{[t_0(X-E(X))+(Y-E(Y))]^2\}=0 \tag{4.3.13}$$

注意到 $E[t_0(X-E(X))+(Y-E(Y))]=0$,故(4.3.13)式等价于

$$D[t_0(X-E(X))+(Y-E(Y))]=0$$

根据方差的性质(4),$D[t_0(X-E(X))+(Y-E(Y))]=0$ 的充要条件是 $P\{t_0(X-E(X))+(Y-E(Y))=0\}=1$,亦即

$$P\{Y=t_0E(X)+E(Y)-t_0X\}=1$$

取 $a=t_0E(X)+E(Y)$,$b=-t_0$,这就证明了"$|\rho(X,Y)|=1$ 的充要条件是:存在常数 a,b,使得 $P\{Y=a+bX\}=1$."

可以证明,若随机变量 X 与 Y 的方差存在,且都大于零,则下列四个命题等价:
(1) X 与 Y 不相关;
(2) $\mathrm{Cov}(X,Y)=0$;
(3) $E(XY)=E(X)\cdot E(Y)$;
(4) $D(X\pm Y)=D(X)+D(Y)$.(参见习题4第27题).

从 $\rho(X,Y)$ 的性质中我们看到,一般而言,$\rho(X,Y)$ 的绝对值是介于0与1之间的常数.当 $|\rho(X,Y)|=1$ 时,X 与 Y 之间几乎必然地存在着某种线性关系.因而,当 $|\rho(X,Y)|$ 接近于1时,我们说 X 与 Y 之间的线性相关程度较强;当 $|\rho(X,Y)|$ 接近于0时,则说 X 与 Y 之间的线性相关程度较弱.特别,当 $\rho(X,Y)=0$ 时,称 X 与 Y **不线性相关**(简称 X 与 Y 不相关).因此,相关系数 $\rho(X,Y)$ 是一个反映随机变量 X 与 Y 之间线性相关程度的量.

定义 4.6 若 $\rho(X,Y)=0$,则称 X 与 Y **不相关**.

因为 $\rho(X,Y)=0$ 等价于 $\mathrm{Cov}(X,Y)=0$,所以,当协方差 $\mathrm{Cov}(X,Y)=0$ 时,同样称 X 与 Y 不相关.

通过比较(4.3.10)式与(4.2.6)式,不难看出,当 X 与 Y 不相关时,就有(4.2.6)式成立,因此,方差性质(3)成立的条件可由"若 X 与 Y 相互独立"改为"若 X 与 Y 不相关".事实上,这是用较弱的条件取代较强的条件(参见下面的例4.16).因而,其结论更具一般性.

相关系数的性质(1)表明:若 X 与 Y 相互独立,则 X 与 Y 不相关.那么,其逆命题如何呢?即,若 X 与 Y 不相关,能否得出 X 与 Y 相互独立的结论?

例 4.16 设二维连续型随机向量 (X,Y) 具有概率密度

$$f(x,y)=\begin{cases}\dfrac{1}{\pi}, & x^2+y^2\leqslant 1,\\ 0, & \text{其他}\end{cases}$$

试证:X 与 Y 是不相关的,但 X 与 Y 并不相互独立.

证 由(3.1.11)式和(3.1.12)式知

$$f_X(x)=\begin{cases}\dfrac{2}{\pi}\sqrt{1-x^2}, & |x|\leqslant 1,\\ 0, & |x|>1,\end{cases}\quad f_Y(y)=\begin{cases}\dfrac{2}{\pi}\sqrt{1-y^2}, & |y|\leqslant 1,\\ 0, & |y|>1\end{cases}$$

因此

$$E(X)=\int_{-1}^{1}x\frac{2}{\pi}\sqrt{1-x^2}\,\mathrm{d}x=0$$

同理

$$E(Y)=0$$

又因

$$\mathrm{Cov}(X,Y)=E(XY)-E(X)E(Y)=\iint\limits_{x^2+y^2\leqslant 1}\frac{xy}{\pi}\mathrm{d}x\mathrm{d}y=0$$

这表明 X 与 Y 不相关.但因为在集合 $D=\{(x,y)\mid |x|>1,|y|>1,x^2+y^2>1\}$ 上,有

$$f(x,y)\equiv 0\neq f_X(x)f_Y(y)=\frac{4}{\pi^2}\sqrt{1-x^2}\sqrt{1-y^2}$$

而点集 D 的面积不为零,所以 X 与 Y 不是相互独立的.

例 4.17 设随机变量 X 在区间 $[-\theta,\theta]$ 上服从均匀分布,其中常数 $\theta>0$.若 $Y=\cos X$,求 $\rho(X,Y)$.

解 因为 $E(X)=0$,所以

$$\begin{aligned}\mathrm{Cov}(X,Y)&=E(XY)-E(X)E(Y)\\&=E(X\cos X)=\int_{-\theta}^{\theta}x\cos x\frac{1}{2\theta}\mathrm{d}x=0\end{aligned}$$

故有 $\rho(X,Y)=0$.

由上例可知:X 与 Y 是不相关的,但它们之间却可以存在着非线性关系($Y=\cos X$).这就表明相关系数仅仅是一个反映 X 与 Y 之间线性关系密切程度的量而已.

例 4.18 设二维随机向量 $(X,Y)\sim N(\mu_1,\mu_2;\sigma_1^2,\sigma_2^2;\rho)$,求 $\rho(X,Y)$.

解 由已知条件以及(3.1.14)式、(3.1.15)式知,$X\sim N(\mu_1,\sigma_1^2)$,$Y\sim N(\mu_2,\sigma_2^2)$,从而有 $E(X)=\mu_1$,$D(X)=\sigma_1^2$;$E(Y)=\mu_2$,$D(Y)=\sigma_2^2$.由协方差的定义以及二维正态分布的概率密度 $f(x,y)$ 的表达式((3.1.13)式),得

$$\begin{aligned}\mathrm{Cov}(X,Y)=&\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}(x-\mu_1)(y-\mu_2)\cdot\\&\exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x-\mu_1)^2}{\sigma_1^2}-2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2}+\frac{(y-\mu_2)^2}{\sigma_2^2}\right]\right\}\mathrm{d}x\mathrm{d}y\end{aligned}$$

因为

$$\frac{(x-\mu_1)^2}{\sigma_1^2}-2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2}+\frac{(y-\mu_2)^2}{\sigma_2^2}=\left[\frac{x-\mu_1}{\sigma_1}-\frac{\rho(y-\mu_2)}{\sigma_2}\right]^2+\left(\sqrt{1-\rho^2}\frac{y-\mu_2}{\sigma_2}\right)^2$$

令 $u=\dfrac{1}{\sqrt{1-\rho^2}}\left[\dfrac{x-\mu_1}{\sigma_1}-\dfrac{\rho(y-\mu_2)}{\sigma_2}\right]$,$v=\dfrac{y-\mu_2}{\sigma_2}$,所以

$$\mathrm{Cov}(X,Y)=\frac{1}{2\pi}\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}\sigma_1\sigma_2(\rho v+\sqrt{1-\rho^2}u)v\exp\left\{-\frac{u^2+v^2}{2}\right\}\mathrm{d}u\mathrm{d}v$$

又因

$$\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}uv\exp\left\{-\frac{u^2+v^2}{2}\right\}\mathrm{d}x\mathrm{d}y=\int_{-\infty}^{+\infty}u\mathrm{e}^{-\frac{u^2}{2}}\mathrm{d}u\int_{-\infty}^{+\infty}v\mathrm{e}^{-\frac{v^2}{2}}\mathrm{d}v=0$$

$$\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}v^2\exp\left\{-\frac{u^2+v^2}{2}\right\}\mathrm{d}x\mathrm{d}y=\int_{-\infty}^{+\infty}\mathrm{e}^{-\frac{u^2}{2}}\mathrm{d}u\int_{-\infty}^{+\infty}v^2\mathrm{e}^{-\frac{v^2}{2}}\mathrm{d}v=2\pi$$

因此 $\mathrm{Cov}(X,Y)=\rho\sigma_1\sigma_2$，故得

$$\rho(X,Y)=\frac{\mathrm{Cov}(X,Y)}{\sqrt{D(X)}\sqrt{D(Y)}}=\rho$$

由此可见，二维正态分布 $N(\mu_1,\mu_2;\sigma_1^2,\sigma_2^2;\rho)$ 中的第五个参数 ρ 恰巧是 X 与 Y 的相关系数.

通过第3章例3.7的讨论，我们知道：若二维随机向量 $(X,Y)\sim N(\mu_1,\mu_2;\sigma_1^2,\sigma_2^2;\rho)$，则 X 与 Y 相互独立的充要条件是 $\rho=0$. 现在，又有 $\rho(X,Y)=\rho$，因此，我们得到如下重要结论：若 $(X,Y)\sim N(\mu_1,\mu_2;\sigma_1^2,\sigma_2^2;\rho)$，则 X 与 Y 相互独立的充要条件是 X 与 Y 不相关.

4.3.2 矩

定义 4.7 设 X 为随机变量，n 为非负整数. 若

$$\alpha_n=E(X^n) \tag{4.3.14}$$

存在，则称它为 X 的 n 阶原点矩，简称为 n 阶矩. 若

$$\mu_n=E[(X-E(X))^n],n>1 \tag{4.3.15}$$

存在，则称它为 X 的 n 阶中心矩.

由上述定义可见，数学期望 $E(X)$ 是 X 的一阶原点矩，方差 $D(X)$ 是 X 的二阶中心矩.

因为

$$\mu_n=E[(X-E(X))^n]=E\left[\sum_{k=0}^{n}\mathrm{C}_n^kX^k(-E(X))^{n-k}\right]$$

$$=\sum_{k=0}^{n}\mathrm{C}_n^kE(X^k)(-E(X))^{n-k}=\sum_{k=0}^{n}\mathrm{C}_n^k\alpha_k(-\alpha_1)^{n-k}(\alpha_0=1)$$

所以，若能求得 X 的前 n 阶原点矩，则它的 n 阶中心矩可由上式确定. 特别地，当 $n=2$ 时，有 $\mu_2=\alpha_2-\alpha_1^2$，此即(4.2.2)式：$D(X)=E(X^2)-[E(X)]^2$.

定义 4.8 设 (X,Y) 为二维随机向量，k,l 为非负整数. 若

$$\alpha_{kl}=E(X^kY^l) \tag{4.3.16}$$

存在，则称它为 (X,Y) 的 $k+l$ 阶混合原点矩. 若

$$\mu_{kl}=E[(X-E(X))^k(Y-E(Y))^l] \tag{4.3.17}$$

存在，则称它为 (X,Y) 的 $k+l$ 阶混合中心矩.

根据上述定义，X 与 Y 的协方差可表示为 $\mathrm{Cov}(X,Y)=\mu_{11}$，相关系数可表示为

$$\rho(X,Y)=\frac{\mu_{11}}{\sqrt{\mu_{20}}\sqrt{\mu_{02}}}$$

4.3.3 协方差矩阵

设 n 维随机向量 $(X_1,X_2,\cdots,X_n)$ 的二阶混合中心矩

$$v_{ij}=\mathrm{Cov}(X_i,X_j)\quad (i,j=1,2,\cdots,n)$$

都存在,则称矩阵

$$\boldsymbol{V}=\begin{pmatrix} v_{11} & v_{12} & \cdots & v_{1n} \\ v_{21} & v_{22} & \cdots & v_{2n} \\ \vdots & \vdots & & \vdots \\ v_{n1} & v_{n2} & \cdots & v_{nn} \end{pmatrix}$$

为 n 维随机向量 $(X_1,X_2,\cdots,X_n)$ 的**协方差矩阵**.

由于 $v_{ij}=v_{ji}(i\neq j,i,j=1,2,\cdots,n)$,因此协方差矩阵 $\boldsymbol{V}$ 是对称矩阵.此外,$v_{ii}=D(X_i)(i=1,2,\cdots,n)$,即 $\boldsymbol{V}$ 的主对角线上的元素 v_{ii} 恰为 $(X_1,X_2,\cdots,X_n)$ 的分量 X_i 的方差.

有了协方差矩阵,就可以来讨论将二维正态分布推广到 n 维正态分布的问题.为此,先要把二维正态分布的概率密度定义式((3.1.13)式)改写成另一种含矩阵运算的形式.

设二维随机向量 (X_1,X_2) 服从二维正态分布,引入下面的行矩阵

$$\boldsymbol{X}=(X_1,X_2),\boldsymbol{x}=(x_1,x_2),\boldsymbol{a}=(\mu_1,\mu_2)=(E(X_1),E(X_2))=E(\boldsymbol{X})^{①}$$

由于 (X_1,X_2) 的协方差矩阵为

$$\boldsymbol{V}=\begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$$

它的行列式 $|\boldsymbol{V}|=\sigma_1^2\sigma_2^2(1-\rho^2)\neq 0$,因此 $\boldsymbol{V}$ 的逆矩阵为

$$\boldsymbol{V}^{-1}=\frac{1}{|\boldsymbol{V}|}\begin{pmatrix} \sigma_2^2 & -\rho\sigma_1\sigma_2 \\ -\rho\sigma_1\sigma_2 & \sigma_1^2 \end{pmatrix}$$

由矩阵的乘法运算,得

$$(\boldsymbol{x}-\boldsymbol{a})\boldsymbol{V}^{-1}(\boldsymbol{x}-\boldsymbol{a})^{\mathrm{T}}=\frac{1}{1-\rho^2}\left[\frac{(x_1-\mu_1)^2}{\sigma_1^2}-2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2}+\frac{(x_2-\mu_2)^2}{\sigma_2^2}\right] \tag{4.3.18}$$

把(4.3.18)式代入到(3.1.13)式中,则 (X_1,X_2) 的概率密度可写成

$$f(x_1,x_2)=\frac{1}{(2\pi)^{2/2}|\boldsymbol{V}|^{1/2}}\exp\left\{-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{a})\boldsymbol{V}^{-1}(\boldsymbol{x}-\boldsymbol{a})^{\mathrm{T}}\right\} \tag{4.3.19}$$

所以,二维随机向量 (X_1,X_2) 服从二维正态分布也可以记作 $\boldsymbol{X}\sim N(\boldsymbol{a},\boldsymbol{V})$.

利用(4.3.19)式,可以很方便地把正态分布概念推广到 n 维随机向量的场合中去.设 $(X_1,X_2,\cdots,X_n)$ 为 n 维随机向量,引入下面的行矩阵

$$\boldsymbol{X}=(X_1,X_2,\cdots,X_n),\quad \boldsymbol{x}=(x_1,x_2,\cdots,x_n),$$

---

① 若 $(X_1,X_2,\cdots,X_n)$ 为 n 维随机向量,则规定 $E(X_1,X_2,\cdots,X_n)=(E(X_1),E(X_2),\cdots,E(X_n))$.

$$\boldsymbol{a}=(\mu_1,\mu_2,\cdots,\mu_n)=(E(X_1),E(X_2),\cdots,E(X_n))=E(\boldsymbol{X})$$

若 $\boldsymbol{X}$ 的概率密度为

$$f(x_1,x_2,\cdots,x_n)=\frac{1}{(2\pi)^{n/2}|\boldsymbol{V}|^{1/2}}\exp\left\{-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{a})\boldsymbol{V}^{-1}(\boldsymbol{x}-\boldsymbol{a})^{\mathrm{T}}\right\} \tag{4.3.20}$$

其中 $\boldsymbol{V}$ 是 $\boldsymbol{X}$ 的协方差矩阵，则称 $\boldsymbol{X}=(X_1,X_2,\cdots,X_n)$ 服从 n 维正态分布，记做 $\boldsymbol{X}\sim N(\boldsymbol{a},\boldsymbol{V})$，并称 $(X_1,X_2,\cdots,X_n)$（或 $\boldsymbol{X}$）为 n 维正态向量.

正态向量具有以下重要性质（证明从略）：

（1）随机向量 $(X_1,X_2,\cdots,X_n)$ 服从 n 维正态分布的充要条件是 $X_1,X_2,\cdots,X_n$ 的任意线性组合 $\sum\limits_{k=1}^{n}l_kX_k$ 服从一维正态分布，这里 $l_1,l_2,\cdots,l_n$ 是任意取定的一组不全为零的实数.

（2）设 $\boldsymbol{X}=(X_1,X_2,\cdots,X_n)$ 为 n 维正态向量（即 $\boldsymbol{X}\sim N(\boldsymbol{a},\boldsymbol{V})$，其中 $\boldsymbol{a}=E(\boldsymbol{X})=[E(X_1),E(X_2),\cdots,E(X_n)]$，$\boldsymbol{V}=E[(\boldsymbol{X}-E(\boldsymbol{X}))^{\mathrm{T}}(\boldsymbol{X}-E(\boldsymbol{X}))]$①），则由 $\boldsymbol{X}$ 的 $m(m<n)$ 个分量所构成的 m 维随机向量 $\tilde{\boldsymbol{X}}=(X_{i_1},X_{i_2},\cdots,X_{i_m})$ $(1\leqslant i_1<i_2<\cdots<i_m\leqslant n)$ 是 m 维正态向量，且其数学期望为

$$\tilde{\boldsymbol{a}}=(\mu_{i_1},\mu_{i_2},\cdots,\mu_{i_m})=(E(X_{i_1}),E(X_{i_2}),\cdots,E(X_{i_m}))$$

协方差矩阵为

$$\tilde{V}=\begin{pmatrix}\mathrm{Cov}(X_{i_1},X_{i_1}) & \mathrm{Cov}(X_{i_1},X_{i_2}) & \cdots & \mathrm{Cov}(X_{i_1},X_{i_m})\\ \mathrm{Cov}(X_{i_2},X_{i_1}) & \mathrm{Cov}(X_{i_2},X_{i_2}) & \cdots & \mathrm{Cov}(X_{i_2},X_{i_m})\\ \vdots & \vdots & & \vdots\\ \mathrm{Cov}(X_{i_m},X_{i_1}) & \mathrm{Cov}(X_{i_m},X_{i_2}) & \cdots & \mathrm{Cov}(X_{i_m},X_{i_m})\end{pmatrix}$$

特别当 $m=1$ 时，有 $X_j\sim N(\mu_j,D(X_j))$ $(1\leqslant j\leqslant n)$，即 n 维正态向量 $\boldsymbol{X}$ 的每个分量 X_j 均为一维正态变量.

（3）若 $\boldsymbol{X}=(X_1,X_2,\cdots,X_n)$ 服从 n 维正态分布 $N(\boldsymbol{a},\boldsymbol{V})$，$\boldsymbol{C}$ 为 $m\times n$ 矩阵，其中元素 $C_{ij}(i=1,2,\cdots,m;j=1,2,\cdots,n)$ 均为常数且 $\boldsymbol{C}$ 的秩为 m，则 m 维随机向量 $\boldsymbol{Y}^{\mathrm{T}}=\boldsymbol{C}\boldsymbol{X}^{\mathrm{T}}$ 服从 m 维正态分布 $N(\boldsymbol{C}\boldsymbol{a}^{\mathrm{T}},\boldsymbol{C}^{\mathrm{T}}\boldsymbol{V}\boldsymbol{C})$.

此性质说明正态随机向量经过线性变换之后仍为正态随机向量.特别当 $m=1$ 时，有下面的结论.

（4）若 $\boldsymbol{X}=(X_1,X_2,\cdots,X_n)$ 服从 n 维正态分布 $N(\boldsymbol{a},\boldsymbol{V})$，$l_1,l_2,\cdots,l_n$ 是一组不全为零的常数，则 $Y=\sum\limits_{i=1}^{n}l_iX_i$ 服从一维正态分布 $N\left(\sum\limits_{i=1}^{n}l_i\mu_i,\ \sum\limits_{j=1}^{n}\sum\limits_{k=1}^{n}l_jl_k\mathrm{Cov}(X_j,X_k)\right)$.

（5）设 $\boldsymbol{X}=(X_1,X_2,\cdots,X_n)$ 是 n 维正态向量，则随机变量 $X_1,X_2,\cdots,X_n$ 相互独立的充要条件是它们两两不相关.

*4.4 条件期望与条件方差

利用条件分布并仿照数学期望与方差的定义方式，我们引入条件期望与条件方

① 一般地，若矩阵 $\boldsymbol{X}=(X_{ij})_{n\times m}$ 中的每一个元 X_{ij} 为随机变量，则规定 $E(\boldsymbol{X})=(E(X_{ij}))_{n\times m}$.

差的定义.

设 X,Y 为随机变量,在 $Y=y$ 条件下,X 的**条件期望**定义为

$$E(X\mid Y=y)=\begin{cases}\sum\limits_i x_iP\{X=x_i\mid Y=y\}, & X,Y\text{是离散型的},\\ \int_{-\infty}^{+\infty} xf_{X|Y}(x\mid y)\,\mathrm{d}x, & X,Y\text{是连续型的}\end{cases}\tag{4.4.1}$$

X 的**条件方差**定义为

$$\begin{aligned}D(X\mid Y=y)&\overset{\text{def}}{=\!=}E\{[X-E(X\mid Y=y)]^2\mid Y=y\}\\&=\begin{cases}\sum\limits_i [x_i-E(X\mid Y=y)]^2P\{X=x_i\mid Y=y\}, & X,Y\text{是离散型的},\\ \int_{-\infty}^{+\infty}[x-E(X\mid Y=y)]^2f_{X\mid Y}(x\mid y)\,\mathrm{d}x, & X,Y\text{是连续型的}\end{cases}\end{aligned}\tag{4.4.2}$$

这里,$P\{X=x_i\mid Y=y\}=\dfrac{P\{X=x_i,Y=y\}}{P\{Y=y\}}$是在 $Y=y$ 条件下 X 的条件分布律;$f_{X|Y}(x\mid y)=\dfrac{f(x,y)}{f_Y(y)}$是在 $Y=y$ 条件下 X 的条件概率密度.并且假定:定义式右端的无穷级数或反常积分为绝对收敛的.

例 4.19 设二维随机向量(X,Y)有概率密度

$$f(x,y)=\begin{cases}\dfrac{5}{4}\mathrm{e}^{-\frac{x}{2}}, & 0<5y<x<+\infty,\\ 0, & \text{其他}\end{cases}$$

试求:$E(X\mid Y=y)$与 $D(X\mid Y=y)$,这里,$0<y<+\infty$.

解 首先,由 $f_Y(y)=\int_{-\infty}^{+\infty}f(x,y)\,\mathrm{d}x$,求得$(X,Y)$关于 Y 的边缘概率密度

$$f_Y(y)=\begin{cases}\dfrac{5}{2}\mathrm{e}^{-\frac{5y}{2}}, & 0<y<+\infty,\\ 0, & \text{其他}\end{cases}$$

其次,由 $f_{X|Y}(x\mid y)=\dfrac{f(x,y)}{f_Y(y)}$,求得在 $Y=y$ 条件下 X 的条件概率密度

$$f_{X|Y}(x\mid y)=\begin{cases}\dfrac{1}{2}\mathrm{e}^{-\frac{x-5y}{2}}, & 5y<x<+\infty,\\ 0, & \text{其他}\end{cases}$$

其中,参数 $y>0$.因而

$$\begin{aligned}E(X\mid Y=y)&=\int_{-\infty}^{+\infty}xf_{X|Y}(x\mid y)\,\mathrm{d}x\\&=\int_{5y}^{+\infty}\frac{x}{2}\mathrm{e}^{-\frac{x-5y}{2}}\mathrm{d}x\\&=5y+2\end{aligned}$$

又因

$$E(X^2 \mid Y=y)=\int_{-\infty}^{+\infty} x^2 f_{X|Y}(x \mid y)\,\mathrm{d}x$$
$$=\int_{5y}^{+\infty} \frac{x^2}{2}\mathrm{e}^{-\frac{x-5y}{2}}\mathrm{d}x$$
$$=(5y)^2+4(5y+2)$$

故

$$D(X \mid Y=y)=E(X^2 \mid Y=y)-[E(X \mid Y=y)]^2$$
$$=(5y)^2+4(5y+2)-(5y+2)^2$$
$$=4$$

注意到 $E(X \mid Y=y)$ 是 y 的函数，我们定义 $E(X \mid Y)$ 为随机变量 Y 的函数，其对应法则为：当 $Y=y$ 时，取值 $E(X \mid Y=y)$. 对随机变量 $E(X \mid Y)$，有如下的重要结论：

全期望公式 $E(X)=E[E(X \mid Y)]$

$$=\begin{cases}\sum\limits_j E(X \mid Y=y_j)P\{Y=y_j\}, & X,Y \text{ 是离散型的},\\ \int_{-\infty}^{+\infty} E(X \mid Y=y)f_Y(y)\,\mathrm{d}y, & X,Y \text{ 是连续型的}\end{cases} \tag{4.4.3}$$

以下仅就连续型随机变量来验证这一公式的正确性.

$$\int_{-\infty}^{+\infty} E(X \mid Y=y)f_Y(y)\,\mathrm{d}y=\int_{-\infty}^{+\infty}\left[\int_{-\infty}^{+\infty} x f_{X|Y}(x \mid y)\,\mathrm{d}x\right]f_Y(y)\,\mathrm{d}y$$
$$=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty} x f_{X|Y}(x \mid y)f_Y(y)\,\mathrm{d}x\mathrm{d}y$$
$$=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty} x f(x,y)\,\mathrm{d}x\mathrm{d}y \quad (\text{根据}(3.2.12)\text{式})$$
$$=E(X) \quad (\text{根据}(4.1.8)\text{式})$$

全期望公式是全概率公式的推广. 事实上，记 $I_A(\omega)$ 为事件 A 的示性函数，即

$$I_A(\omega)=\begin{cases}1, & \omega \in A,\\ 0, & \omega \in \bar{A}\end{cases}$$

易知 $E(I_A)=P(A)$，$E(I_A \mid Y=y)=P(A \mid Y=y)$，由(4.4.3)式

$$P(A)=\begin{cases}\sum\limits_j P(A \mid Y=y_j)P\{Y=y_j\}, & X,Y \text{ 是离散型的},\\ \int_{-\infty}^{+\infty} P(A \mid Y=y)f_Y(y)\,\mathrm{d}y, & X,Y \text{ 是连续型的}\end{cases} \tag{4.4.4}$$

例 4.20 一矿工被困在矿井中，要到达安全地带，有三条通道可选择. 他从第一条通道出去要走 2 个小时可到达安全地带，从第二条通道出去要走 3 个小时又返回原处，从第三条通道出去要走 4 个小时也返回原处. 设任一时刻都等可能地选中其中一条通道. 试问这位矿工到达安全地带平均要花多长时间.

解 设 X 表示这位矿工到达安全地带所需时间，Y 表示他选定的通道，由全期望公式

$$E(X)=E[E(X \mid Y)]$$
$$=E(X \mid Y=1)P(Y=1)+E(X \mid Y=2)P(Y=2)+$$
$$E(X \mid Y=3)P(Y=3)$$

$$=\frac{1}{3}[2+(3+E(X))+(4+E(X))]$$

故得,$E(X)=9$.

例 4.21 黄金周到某旅游景区的游客数是随机变量 N(N 的可能值为正整数).X_i 是第 i 位游客在进入景区后所花费的钱数,假定 $X_1,X_2,\cdots$ 是独立同分布的随机变量列,且与 N 相互独立,那么,黄金周期间,该旅游景区一周的平均收入为

$$\begin{aligned}
E\Big(\sum_{i=1}^{N}X_i\Big)&=E\Big[E\Big(\sum_{i=1}^{N}X_i\mid N\Big)\Big]\\
&=\sum_{n=1}^{\infty}E\Big(\sum_{i=1}^{N}X_i\mid N=n\Big)P\{N=n\}\\
&=\sum_{n=1}^{\infty}E\Big(\sum_{i=1}^{n}X_i\mid N=n\Big)P\{N=n\}\\
&=\sum_{n=1}^{\infty}E\Big(\sum_{i=1}^{n}X_i\Big)P\{N=n\}\quad\Big(\text{因}\sum_{i=1}^{n}X_i\text{与}N\text{独立}\Big)\\
&=\sum_{n=1}^{\infty}nE(X_1)P\{N=n\}\quad(\text{因}X_1,X_2,\cdots\text{独立同分布})\\
&=\Big[\sum_{n=1}^{\infty}nP\{N=n\}\Big]E(X_1)\\
&=E(N)E(X_1)
\end{aligned}$$

如同定义 $E(X\mid Y)$那样,把 $D(X\mid Y)$定义为随机变量 Y 的函数:当 $Y=y$ 时,它的取值为 $D(X\mid Y=y)$.关于随机变量 $D(X\mid Y)$,我们介绍一个与之有关的公式.

全方差公式 $D(X)=E[D(X\mid Y)]+D[E(X\mid Y)]$ (4.4.5)

以下仅就 X,Y 为连续型随机变量来验证这一公式的正确性.因为

$$\begin{aligned}
E[D(X\mid Y)]&=\int_{-\infty}^{+\infty}D(X\mid Y=y)f_Y(y)\,\mathrm{d}y\\
&=\int_{-\infty}^{+\infty}\{E(X^2\mid Y=y)-[E(X\mid Y=y)]^2\}f_Y(y)\,\mathrm{d}y\\
&=E[E(X^2\mid Y)]-E\{[E(X\mid Y)]^2\}\\
&=E(X^2)-E\{[E(X\mid Y)]^2\}\quad(\text{第一项用全期望公式})
\end{aligned}$$

又

$$\begin{aligned}
D[E(X\mid Y)]&=E\{[E(X\mid Y)]^2\}-\{E[E(X\mid Y)]\}^2\\
&=E\{[E(X\mid Y)]^2\}-[E(X)]^2\quad(\text{第二项用全期望公式})
\end{aligned}$$

所以

$$E[D(X\mid Y)]+D[E(X\mid Y)]=E(X^2)-[E(X)]^2=D(X)$$

全方差公式说明,当有另一个随机变量 Y 对 X 起作用时,X 的方差可以分解为两部分:一部分是 Y 对 X 的系统影响部分 $E(X\mid Y)$ 的方差,另一部分是条件方差 $D(X\mid Y)$的平均.

内容小结

1. 数学期望

若 X 是离散型随机变量，其分布律为 $P\{X=x_k\}=p_k(k=1,2,\cdots)$，若级数 $\sum\limits_{k=1}^{\infty}x_kp_k$ 绝对收敛，则称 $\sum\limits_{k=1}^{\infty}x_kp_k$ 为随机变量 X 的数学期望，记作 $E(X)$.

若 X 是连续型随机变量，其概率密度为 $f(x)$，若积分 $\int_{-\infty}^{+\infty}xf(x)\mathrm{d}x$ 绝对收敛，则称 $\int_{-\infty}^{+\infty}xf(x)\mathrm{d}x$ 为 X 的数学期望，记作 $E(X)$.

设 $g(x)$ 是连续函数，(1) 若 X 的分布律为 $P\{X=x_k\}=p_k(k=1,2,\cdots)$，且 $\sum\limits_{k=1}^{\infty}g(x_k)p_k$ 绝对收敛，则 $E[g(X)]=\sum\limits_{k=1}^{\infty}g(x_k)p_k$；(2) 若 X 的概率密度为 $f(x)$，且 $\int_{-\infty}^{+\infty}g(x)f(x)\mathrm{d}x$ 绝对收敛，则 $E[g(X)]=\int_{-\infty}^{+\infty}g(x)f(x)\mathrm{d}x$.

若 $g(x,y)$ 是二元连续函数，(1) 若 (X,Y) 的分布律为 $P\{X=x_i,Y=y_j\}=P_{ij}(i,j=1,2,\cdots)$，且 $\sum\limits_{j=1}^{\infty}\sum\limits_{i=1}^{\infty}g(x_i,y_j)p_{ij}$ 绝对收敛，则 $E[g(X,Y)]=\sum\limits_{j=1}^{\infty}\sum\limits_{i=1}^{\infty}g(x_i,y_j)p_{ij}$；(2) 若 (X,Y) 的概率密度为 $f(x,y)$，且 $\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}g(x,y)f(x,y)\mathrm{d}x\mathrm{d}y$ 绝对收敛，则 $E[g(X,Y)]=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}g(x,y)f(x,y)\mathrm{d}x\mathrm{d}y$.

数学期望具有性质：(1) $E(C)=C$(C 为常数)；(2) k 为常数时，$E(kX)=kE(X)$；(3) $E(X\pm Y)=E(X)\pm E(Y)$；(4) 若 X 与 Y 相互独立，则 $E(XY)=E(X)E(Y)$.

2. 方差

对随机变量 X，若 $E\{[X-E(X)]^2\}$ 存在，则称 $E\{[X-E(X)]^2\}$ 为 X 的方差，记作 $\mathrm{Var}(X)$ 或 $D(X)$，$\sqrt{D(X)}$ 称为随机变量 X 的标准差或均方差.

方差具有性质：(1) $D(a)=0$(a 为常数)；(2) a 为常数时，$D(aX)=a^2D(X)$；(3) 若 X 与 Y 相互独立，则 $D(X\pm Y)=D(X)+D(Y)$；(4) $D(X)=0$ 的充要条件是 $P\{X=E(X)\}=1$.

马尔可夫不等式：设 X 为随机变量，若 $E(|X|^r)<+\infty$，其中 $r>0$ 为实数，则对任意正数 ε，有

$$P\{|X|\geqslant\varepsilon\}\leqslant\frac{E(|X|^r)}{\varepsilon^r}$$

常见随机变量的数学期望和方差：

(1) (0—1)分布：$E(X)=p$，$D(X)=p(1-p)$.

(2) 二项分布 $B(n,p)$：$E(X)=np$，$D(X)=np(1-p)$.

(3) 泊松分布 $P(\lambda)$：$E(X)=\lambda$，$D(X)=\lambda$.

(4) 几何分布 $Ge(p)$：$E(X)=\dfrac{1}{p}$，$D(X)=\dfrac{1-p}{p^2}$.

(5) 正态分布 $N(\mu,\sigma^2)$：$E(X)=\mu$，$D(X)=\sigma^2$.

(6) 均匀分布 $U(a,b)$：$E(X)=\dfrac{a+b}{2}$，$D(X)=\dfrac{(b-a)^2}{12}$.

(7) 指数分布 $Exp(\lambda)$：$E(X)=\dfrac{1}{\lambda}$，$D(X)=\dfrac{1}{\lambda^2}$.

3. 协方差、相关系数和矩

对二维随机向量(X,Y)，称 $E\{[X-E(X)][Y-E(Y)]\}$ 为随机变量 X 与 Y 的协方差，记作 $\mathrm{Cov}(X,Y)$.

协方差具有性质(a,b 为常数)：

(1) $\mathrm{Cov}(X,a)=0$；

(2) $\mathrm{Cov}(X,Y)=\mathrm{Cov}(Y,X)$；

(3) $\mathrm{Cov}(aX,bY)=ab\mathrm{Cov}(X,Y)$；

(4) $\mathrm{Cov}(X_1+X_2,Y)=\mathrm{Cov}(X_1,Y)+\mathrm{Cov}(X_2,Y)$；

(5) 若 X 与 Y 相互独立，则 $\mathrm{Cov}(X,Y)=0$；

(6) 若 $E(X^2)$，$E(Y^2)$存在，则$[E(XY)]^2\leqslant E(X^2)E(Y^2)$；特别地，有

$$[\mathrm{Cov}(X,Y)]^2\leqslant D(X)D(Y)$$

(7) $D(X\pm Y)=D(X)+D(Y)\pm 2\mathrm{Cov}(X,Y)$.

称 $\rho(X,Y)=\dfrac{\mathrm{Cov}(X,Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$为随机变量 X 与 Y 的相关系数.

当 $\rho(X,Y)=0$ 时，称 X 与 Y 不相关.

设 X,Y 是随机变量，k,l 为非负整数，称 $E(X^k)$ 为 X 的 k 阶原点矩，称 $E\{[X-E(X)]^k\}$ 为X 的 k 阶中心矩($k>1$)，称 $E(X^kY^l)$为 X,Y 的 $k+l$ 阶混合原点矩，称 $E\{[X-E(X)]^k[Y-E(Y)]^l\}$ 为 X,Y 的 $k+l$ 阶混合中心矩.

4. 协方差矩阵

设 n 维随机变量$(X_1,X_2,\cdots,X_n)$的二阶混合中心矩

$$v_{ij}=\mathrm{Cov}(X_i,X_j)=E[(X_i-E(X_i))(X_j-E(X_j))]\ (i,j=1,2,\cdots,n)$$

都存在，则矩阵 $\boldsymbol{V}=\begin{pmatrix} v_{11} & v_{12} & \cdots & v_{1n} \\ v_{21} & v_{22} & \cdots & v_{2n} \\ \vdots & \vdots & & \vdots \\ v_{n1} & v_{n2} & \cdots & v_{nn} \end{pmatrix}$ 称为$(X_1,X_2,\cdots,X_n)$的**协方差矩阵**.

n 维正态分布具有以下重要性质：

(1) $(X_1,X_2,\cdots,X_n)$为 n 维正态向量的充要条件是 $X_1,X_2,\cdots,X_n$ 的任意线性组合 $l_1X_1+l_2X_2+\cdots+l_nX_n$ 服从一维正态分布，其中 $l_1,l_2,\cdots,l_n$ 不全为 0.

(2) 由 n 维正态向量$(X_1,X_2,\cdots,X_n)$的其中 m 个分量按照相对位置不变组成的随机向量是 m 维正态向量.特别地，n 维正态向量$(X_1,X_2,\cdots,X_n)$的每一个分量 $X_i(i=1,2,\cdots,n)$都是一维正态变量.

(3) 若 $X=(X_1,X_2,\cdots,X_n)$ 服从 n 维正态分布 $N(\boldsymbol{a},\boldsymbol{V})$，$\boldsymbol{C}=(c_{ij})_{m\times n}$ 且 $\boldsymbol{C}$ 的秩为 m，则 $\boldsymbol{Y}^{\mathrm{T}}=\boldsymbol{C}\boldsymbol{X}^{\mathrm{T}}$ 服从 m 维正态分布 $N(\boldsymbol{C}\boldsymbol{a}^{\mathrm{T}},\boldsymbol{C}^{\mathrm{T}}\boldsymbol{V}\boldsymbol{C})$.

(4) 设 $(X_1,X_2,\cdots,X_n)$ 是 n 维正态向量，则 $X_1,X_2,\cdots,X_n$ 相互独立的充要条件是它们两两不相关.

5. 条件期望和条件方差

设 X,Y 为随机变量，在 $Y=y$ 条件下，X 的条件期望为

$$E(X\mid Y=y)=\begin{cases}\sum\limits_i x_iP\{X=x_i\mid Y=y\}, & X,Y\text{是离散型的},\\ \int_{-\infty}^{+\infty}xf_{X|Y}(x\mid y)\,\mathrm{d}x, & X,Y\text{是连续型的}\end{cases}$$

X 的条件方差为

$$D(X\mid Y=y)=\begin{cases}\sum\limits_i [x_i-E(X\mid Y=y)]^2P\{X=x_i\mid Y=y\}, & X,Y\text{是离散型的},\\ \int_{-\infty}^{+\infty}[x-E(X\mid Y=y)]^2f_{X|Y}(x\mid y)\,\mathrm{d}x, & X,Y\text{是连续型的}\end{cases}$$

全期望公式：

$$E(X)=E[E(X\mid Y)]=\begin{cases}\sum\limits_j E(X\mid Y=y_j)P\{Y=y_j\}, & X,Y\text{是离散型的},\\ \int_{-\infty}^{+\infty}E(X\mid Y=y)f_Y(y)\,\mathrm{d}y, & X,Y\text{是连续型的}\end{cases}$$

全方差公式：

$$D(X)=E[D(X\mid Y)]+D[E(X\mid Y)]$$

习题 4

1. 一箱产品中有 12 件正品，3 件次品. 现从该箱中任取 5 件产品，以 X 表示取出的 5 件产品中的次品数，求 X 的数学期望 $E(X)$.

2. 设随机变量 X 服从几何分布 $Ge(p)$ $(0<p<1)$，求 X 的数学期望 $E(X)$.

3. 设随机变量 X 服从参数为 $\lambda(\lambda>0)$ 的指数分布，求 X 的数学期望 $E(X)$.

4. 设随机变量 X 的概率密度为

$$f(x)=\frac{1}{2}\mathrm{e}^{-|x|}\quad(-\infty<x<+\infty)$$

求 $E(X)$.

5. 船只横向摇摆的振幅 X 是一个随机变量，设 X 服从瑞利分布，其概率密度为

$$f(x)=\begin{cases}\dfrac{x}{\sigma^2}\mathrm{e}^{-\frac{x^2}{2\sigma^2}}, & x>0,\\ 0, & x\leqslant 0\end{cases}$$

其中 $\sigma(\sigma>0)$ 为常数，求平均振幅 $E(X)$.

6. 设随机变量 X 的分布函数为

$$F(x)=\begin{cases}1-\dfrac{a^3}{x^3}, & x\geqslant a,\\ 0, & x<a\end{cases}$$

其中 $a(a>0)$ 为常数，求 $E(X)$.

7. 设随机变量 X 服从柯西分布,其概率密度为

$$f(x) = \frac{1}{\pi(1+x^2)} \quad (-\infty < x < +\infty)$$

试验证 X 的数学期望不存在.

8. 设随机变量 X 在区间$[0,2\pi]$上服从均匀分布,求 $Y=\sin X$ 的数学期望.

9. 设随机变量 X 服从正态分布 $N(\mu,\sigma^2)$,

(1) 求 $Y=|X-E(X)|$ 的数学期望;

(2) 求 $Y=e^{\frac{\mu^2-2\mu X}{2\sigma^2}}$ 的数学期望.

10. 分子运动的速率 X 服从麦克斯韦分布,其概率密度为

$$f(x) = \begin{cases} \dfrac{4x^2}{a^3\cdot\sqrt{\pi}} e^{-\frac{x^2}{a^2}}, & x>0, \\ 0, & x\leqslant 0 \end{cases}$$

其中 $a(a>0)$是常数,设分子的质量为 m,求分子的平均动能.

11. 一工厂生产的某种设备的使用寿命 X(单位:年)服从指数分布,其概率密度为

$$f(x) = \begin{cases} \dfrac{1}{4}e^{-\frac{x}{4}}, & x>0, \\ 0, & x\leqslant 0 \end{cases}$$

工厂规定,出售的设备若在售出一年之内损坏可予以调换.若工厂售出一台设备获利 100 元,调换一台设备厂方需花费 300 元,试求厂方出售一台设备净获利的数学期望.

12. 二维随机向量(X,Y)的分布律为

X	Y		
	1	2	3
−1	a	0.1	0
0	0.1	0	b
1	0.1	0.1	c

(1) 求 a,b,c 使 $E(X)=0,E(Y)=2$;

(2) 设 $Z=(X-Y)^2$,求 $E(Z)$;

(3) 设 $Z=X^2Y$,求 $E(Z)$.

13. 设(X,Y)的概率密度为

$$f(x,y) = \begin{cases} \dfrac{1}{3}(x+y), & 0\leqslant x\leqslant 2, 0\leqslant y\leqslant 1, \\ 0, & \text{其他} \end{cases}$$

求 $E(X),E(Y),E(XY),E(X^2+Y^2)$.

14. 在长度为 a 的线段上任取两点 A 及 B,试求线段 AB 的长度的数学期望.

15. 在半径为 R 的圆内任取一点 A,求 A 到圆心距离的数学期望.

16. 将 n 只球(编号 $1,2,\cdots,n$)随机地放进 n 个盒子(编号 $1,2,\cdots,n$)中去,一个盒子装一只球.若一只球装入与球同号的盒子中,称为一个配对,记 X 为总的配对数,求 $E(X)$.

17. 设 X 在区间$[0,2]$上服从均匀分布,Y 服从参数为 2 的指数分布,

(1) 求 $E(X+Y)$及 $E(X^2-2Y+1)$;

(2) 若 X 与 Y 相互独立,求 $E(XY)$.

18. 求第 1 至 6 题中所描述的随机变量 X 的方差 $D(X)$.

19. 求第8题中所描述的随机变量 Y 的方差.

20. 求第14题中线段 AB 长度的方差.

21. 求第15题中 A 到圆心距离的方差.

22. 设 (X,Y) 的概率密度为

$$f(x,y)=\begin{cases}1, & |y|\leqslant x,0\leqslant x\leqslant 1,\\ 0, & \text{其他}\end{cases}$$

求 $D(X)$ 及 $D(Y)$.

23. 设随机变量 X 与 Y 相互独立,方差存在,证明:

$$D(XY)=D(X)D(Y)+[E(X)]^2D(Y)+D(X)[E(Y)]^2$$

成立,并由此可得 $D(XY)\geqslant D(X)D(Y)$.

24. 设随机变量 X 与 Y 相互独立,且 $E(X)=E(Y)=0,D(X)=D(Y)=\sigma^2$,求 $E(X-Y)^2$.

25. 设二维随机向量 (X,Y) 的分布律为

X	Y				
	-2	-1	0	1	2
0	0.2	0	0.2	0	0.2
1	0	0.2	0	0.2	0

求 $\mathrm{Cov}(X,Y)$ 及 $\rho(X,Y)$.

26. 设二维随机向量 (X,Y) 的概率密度为

$$f(x,y)=\begin{cases}2-x-y, & 0<x<1,0<y<1,\\ 0, & \text{其他}\end{cases}$$

求 $\mathrm{Cov}(X,Y)$,$\rho(X,Y)$ 及 $D(2X-Y+1)$.

27. 证明:当随机变量 X,Y 的方差存在,且 $D(X)>0,D(Y)>0$ 时,下列命题是等价的:

(1) X 与 Y 不相关;

(2) $\mathrm{Cov}(X,Y)=0$;

(3) $E(XY)=E(X)E(Y)$;

(4) $D(X\pm Y)=D(X)+D(Y)$.

28. 设随机变量 X_1 与 X_2 相互独立,方差存在,且 $E(X_1)=E(X_2)=0$,试证明随机变量 $Y_1=X_1-X_2$ 与 $Y_2=X_1X_2$ 不相关.

29. 已知三个随机变量 X,Y,Z 有 $E(X)=E(Y)=1,E(Z)=-1,E(X^2)=E(Y^2)=E(Z^2)=2$,$\rho(X,Y)=0,\rho(X,Z)=\frac{1}{2},\rho(Y,Z)=-\frac{1}{2}$,求:

(1) 随机变量 $W=X+Y+Z$ 的数学期望 $E(W)$ 及方差 $D(W)$;

(2) $\mathrm{Cov}(2X+Y,3Z+X)$.

30. 设二维随机向量 (X,Y) 的分布律为

X	Y		
	-1	0	1
-1	0	0.25	0
0	0.25	0	0.25
1	0	0.25	0

证明：X 与 Y 不相关，而 X 与 Y 不相互独立.

31. 证明：第 22 题中的 X 与 Y 不相关，而 X 与 Y 不相互独立.

32. 已知对二维随机向量 (X,Y) 有 $E(X)=0, E(Y)=1, E(X^2)=1, E(XY)=-1, \rho(X,Y)=-\frac{1}{2}$，求 $D(X-Y)$.

33. 求第 16 题所描述的随机变量 X 的方差.

34. (1) 设 X 与 Y 分别服从(0—1)分布，即 $P\{X=0\}=1-p_1, P\{X=1\}=p_1, 0<p_1<1, P\{Y=0\}=1-p_2, P\{Y=1\}=p_2, 0<p_2<1$. 试证：$X$ 与 Y 相互独立等价于 X 与 Y 不相关.

(2) 若随机变量 X 与 Y 分别服从两点分布：$P\{X=a_1\}=1-p_1, P\{X=a_2\}=p_1, 0<p_1<1$；$P\{Y=b_1\}=1-p_2, P\{Y=b_2\}=p_2, 0<p_2<1$，其中 a_1, a_2, b_1, b_2 为任意常数，且 $a_1 \neq a_2, b_1 \neq b_2$. 试证：$X$ 与 Y 相互独立等价于 X 与 Y 不相关.

*35. 设二维随机向量 $(X,Y) \sim N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2; \rho)$，求 $E(Y \mid X=x)$ 和 $D(Y \mid X=x)$.

*36. 设 $X_1, X_2, \cdots$ 是一列相互独立的随机变量，且都服从均匀分布 $U(a,b)$，随机变量 N 服从参数为 λ 的泊松分布，且与 $\{X_i, i \geqslant 1\}$ 相互独立，令 $Y=\sum_{i=1}^{N} X_i$，试求 $E(Y)$ 和 $D(Y)$.

自测题 4

习题 4 参考答案

第5章 大数定律与中心极限定理

大数定律是研究随机现象在大量重复试验中呈现某种稳定性的一组定理的统称.中心极限定理是探讨在什么条件下独立随机变量之和的极限分布为正态分布的理论.本章首先引入随机变量序列的两种收敛性及一个重要的不等式,其后介绍大数定律与中心极限定理.

理论探究:随机变量序列两种收敛性的解释

5.1 随机变量的收敛性与切比雪夫不等式

学过微积分的读者都了解数列的收敛性概念,那么对随机变量序列的收敛性又当如何定义呢?由于随机变量序列$\{X_n, n=1,2,\cdots\}$除了下标n从1变化至无穷外,每个X_n都含有样本点ω,这使得对X_n定义的收敛性与数列的收敛性有很大的不同.下面就来介绍随机变量序列两种常用的收敛性:依概率收敛和依分布收敛.

5.1.1 依概率收敛

定义 5.1 设$\{X_n, n=1,2,\cdots\}$是随机变量序列,X也是一个随机变量,若对任意$\varepsilon>0$,有

$$\lim_{n\to\infty} P\{|X_n - X| \geqslant \varepsilon\} = 0 \tag{5.1.1}$$

则称随机变量序列$\{X_n\}$依概率收敛于X,记作$(p)\lim_{n\to\infty} X_n = X$或者$X_n \xrightarrow{P} X$.

依概率收敛表明,随机变量X_n对X的绝对偏差不小于任一给定正数的概率随着n增大而越来越接近于零.

由概率的性质(1.2.9)式,(5.1.1)式也等价于

$$\lim_{n\to\infty} P\{|X_n - X| < \varepsilon\} = 1 \tag{5.1.2}$$

特别地,当随机变量X为单点分布,即$P\{X=a\}=1$,则称序列$\{X_n\}$依概率收敛于a,即$X_n \xrightarrow{P} a$.

依概率收敛于常数的随机变量序列有一条重要性质:

若$(p)\lim_{n\to\infty} X_n = a$,$(p)\lim_{n\to\infty} Y_n = b$,又$g(x,y)$在点$(a,b)$处连续,则

$$(p)\lim_{n\to\infty} g(X_n, Y_n) = g(a,b)$$

证明从略.

易知:

$$(p)\lim_{n\to\infty}(X_n \pm Y_n) = a \pm b,\quad (p)\lim_{n\to\infty} X_n Y_n = ab,\quad (p)\lim_{n\to\infty}\frac{X_n}{Y_n} = \frac{a}{b}(Y_n \neq 0, b \neq 0)$$

一般地,依概率收敛的随机变量序列也具有四则运算性质.

例 5.1 设随机变量X_n服从柯西分布$C\left(0,\frac{1}{n}\right)$,其概率密度为

$$f_n(x) = \frac{n}{\pi(1+n^2x^2)},\quad -\infty < x < +\infty$$

试证:随机变量序列$\{X_n\}$依概率收敛于0,即$(p)\lim\limits_{n\to\infty}X_n=0$.

证 由依概率收敛的定义,对任意$\varepsilon>0$,

$$P\{|X_n-0|<\varepsilon\}=P\{|X_n|<\varepsilon\}=\int_{-\varepsilon}^{\varepsilon}\frac{n}{\pi(1+n^2x^2)}\mathrm{d}x=\frac{2}{\pi}\arctan n\varepsilon$$

则$\lim\limits_{n\to\infty}P\{|X_n-0|<\varepsilon\}=\lim\limits_{n\to\infty}\frac{2}{\pi}\arctan n\varepsilon=1$,因此$X_n$依概率收敛于0.

5.1.2 依分布收敛

定义5.2 设$\{X_n,n=1,2,\cdots\}$为随机变量序列,其对应的分布函数序列为$\{F_n(x),n=1,2,\cdots\}$,X是另一随机变量,其分布函数为$F(x)$.若对$F(x)$的每个连续点x,有

$$\lim_{n\to\infty}F_n(x)=F(x) \tag{5.1.3}$$

则称随机变量序列$\{X_n\}$依分布收敛于X,记作$X_n\xrightarrow{d}X$,或称分布函数序列$\{F_n(x),n=1,2,\cdots\}$弱收敛于$F(x)$,记为$F_n(x)\xrightarrow{w}F(x)$.

理论探究:随机变量序列的其他收敛性及关系

5.1.3 切比雪夫不等式

若随机变量X存在数学期望$E(X)$和方差$D(X)$,则对任意正数ε,有

$$P\{|X-E(X)|\geqslant\varepsilon\}\leqslant\frac{D(X)}{\varepsilon^2} \tag{5.1.4}$$

或等价地有

$$P\{|X-E(X)|<\varepsilon\}\geqslant1-\frac{D(X)}{\varepsilon^2} \tag{5.1.5}$$

上述不等式就称为**切比雪夫不等式**.

证 在马尔可夫不等式(4.2.3)式中,以$X-E(X)$取代X并令正实数$r=2$,则对任意正数ε,有

$$P\{|X-E(X)|\geqslant\varepsilon\}\leqslant\frac{E\{[X-E(X)]^2\}}{\varepsilon^2}=\frac{D(X)}{\varepsilon^2}$$

成立.

由不等式(5.1.5)不难看出,$D(X)$越小,随机变量X取值于开区间$(E(X)-\varepsilon,E(X)+\varepsilon)$中的概率就越大.这说明方差是一个反映随机变量的概率分布对其分布中心——$E(X)$的集中程度的数量指标.

在随机变量X的分布未知的情况下,利用切比雪夫不等式可以估算概率$P\{|X-E(X)|<\varepsilon\}$的下界.

例5.2 设随机变量X的数学期望$E(X)=10$,方差$D(X)=0.04$,估计$P\{9.4<X<10.4\}$的下界.

解

$$\begin{aligned}P\{9.4<X<10.4\}&=P\{-0.6<X-10<0.4\}\\&\geqslant P\{|X-10|<0.4\}\end{aligned}$$

$$\geqslant 1-\frac{D(X)}{0.4^2}=0.75$$

因此，概率 $P\{9.4<X<10.4\}$ 不会小于 0.75.

若随机变量 X 服从正态分布 $N(10,0.04)$，则实际概率

$$P\{9.4<X<10.4\}=P\left\{\frac{-0.6}{0.2}<\frac{X-10}{0.2}<\frac{0.4}{0.2}\right\}=\Phi(2)-\Phi(-3)=0.9759$$

由上式可知，虽然切比雪夫不等式可以估计概率的下界，但通常情况下，由它所得概率的下界与实际概率相差较大.切比雪夫不等式作为一种理论工具，通常被用于证明某些定理，尤其是可用来证明下面的大数定律.

5.2 大数定律

在大量重复试验中，事件发生的频率稳定于它发生的概率.对某个随机变量 X（在统计学中常常代表一个总体）进行大量重复观测，所得大批观测值的算术平均值稳定于随机变量 X 的数学期望.由于这类稳定性是在对随机现象进行大量重复试验的条件下呈现出来的，因此，反映这方面规律的定理统称为大数定律.

5.2.1 切比雪夫大数定律

定理 5.1（切比雪夫大数定律） 设 $\{X_n,n=1,2,\cdots\}$ 是相互独立的随机变量序列，且分别存在数学期望 $E(X_k)$ 和方差 $D(X_k)$ $(k=1,2,\cdots)$.若存在常数 C，使得 $D(X_k)\leqslant C(k=1,2,\cdots)$，则对任意 $\varepsilon>0$，有

$$\lim_{n\to\infty}P\left\{\left|\frac{1}{n}\sum_{k=1}^{n}X_k-\frac{1}{n}\sum_{k=1}^{n}E(X_k)\right|<\varepsilon\right\}=1 \tag{5.2.1}$$

证 因 $\{X_n,n=1,2,\cdots\}$ 两两不相关，故

$$D\left(\frac{1}{n}\sum_{k=1}^{n}X_k\right)=\frac{1}{n^2}\sum_{k=1}^{n}D(X_k)\leqslant\frac{C}{n}$$

令 $Y_n=\dfrac{1}{n}\sum\limits_{k=1}^{n}X_k$，则由切比雪夫不等式可得下面的不等式

$$1\geqslant P\{|Y_n-E(Y_n)|<\varepsilon\}\geqslant 1-\frac{D(Y_n)}{\varepsilon^2}\geqslant 1-\frac{C}{n\varepsilon^2}$$

令 $n\to\infty$，由数列极限的夹逼法则知

$$\lim_{n\to\infty}P\{|Y_n-E(Y_n)|<\varepsilon\}=1$$

注意到 $E(Y_n)=E\left(\dfrac{1}{n}\sum\limits_{k=1}^{n}X_k\right)=\dfrac{1}{n}\sum\limits_{k=1}^{n}E(X_k)$，把 Y_n 和 $E(Y_n)$ 的表达式代入到上式中去，即证明了定理 5.1.

定理 5.1 和定理 5.2 中的条件“$\{X_n,n=1,2,\cdots\}$ 相互独立”可以减弱为“$\{X_n,n=1,2,\cdots\}$ 两两不相关”.

下面给一个应用更广泛的结论.

定理 5.2 设 $\{X_n,n=1,2,\cdots\}$ 是相互独立的随机变量序列，且存在相同的数学期望 $E(X_k)=\mu$ 与方差 $D(X_k)=\sigma^2(k=1,2,\cdots)$，则对任意 $\varepsilon>0$，有

$$\lim_{n\to\infty} P\left\{\left|\frac{1}{n}\sum_{k=1}^{n} X_k - \mu\right| < \varepsilon\right\} = 1$$

定理 5.2 是定理 5.1 的特殊情形,因此证明略去.

定理 5.2 表明,当 n 很大时,事件 $\left\{\left|\frac{1}{n}\sum_{k=1}^{n} X_k - \mu\right| < \varepsilon\right\}$ 的概率接近于 1.一般地,我们称概率接近于 1 的事件为大概率事件,而称概率接近于 0 的事件为小概率事件.人们在大量实践中发现:大概率事件在一次试验中几乎肯定要发生,而小概率事件在一次试验中几乎不可能发生.这一规律称为"实际推断原理",它对于我们在实际工作中处理概率接近于 1 或者 0 的事件具有一定的指导意义.例如,设 X 是一个概率分布未知的随机变量,我们无法由定义算出 $E(X)$,为了估算 $E(X)$,对 X 做一次 n 重观测试验,记 X_k 为第 k 个试验的结果($k=1,2,\cdots,n$),由于这一连串独立重复观测只是设想要做而尚未实施,所以 X_k($k=1,2,\cdots,n$)是随机变量,并且 $X_1,X_2,\cdots,X_n$ 是相互独立的,每一个随机变量 X_k($k=1,2,\cdots,n$)的概率分布都与 X 的概率分布一致.因此,$E(X_k)=E(X)$,$D(X_k)=D(X)$($k=1,2,\cdots,n$)(假定 $E(X)$,$D(X)$ 都存在).根据推论,对任意给定的一个比较小的正数 ε,当 n 充分大时,事件 $\left\{\left|\frac{1}{n}\sum_{k=1}^{n} X_k - E(X)\right| < \varepsilon\right\}$ 为大概率事件,因此,对一次 n 重观测试验的结果:$x_1,x_2,\cdots,x_n$,由实际推断原理知,几乎可以肯定有 $\left|\frac{x_1+x_2+\cdots+x_n}{n} - E(X)\right| < \varepsilon$,故 $E(X) \approx \frac{1}{n}\sum_{k=1}^{n} x_k$. 这种估算 $E(X)$ 的方法称为数学期望的统计估计.

定理 5.2 不仅是数学期望的统计估计的理论依据,而且在概率理论中还具有一定的概率意义.

有了 5.1 节随机变量序列的依概率收敛的概念,定理 5.2 表明:若随机变量序列 $\{X_n, n=1,2,\cdots\}$ 相互独立,且具有相同的数学期望与方差:$E(X_k)=\mu$,$D(X_k)=\sigma^2$($k=1,2,\cdots$),则随机变量序列 $Y_n=\frac{1}{n}\sum_{k=1}^{n} X_k$ 依概率收敛于 μ,即 $(p)\lim_{n\to\infty} Y_n=\mu$.

例 5.3 设 $X_1,X_2,\cdots,X_n,\cdots$ 是相互独立的随机变量序列,对每个固定的 n,X_n 的分布律为 $P\{X_n=\sqrt{n}\}=\frac{1}{2n}$,$P\{X_n=-\sqrt{n}\}=\frac{1}{2n}$,$P\{X_n=0\}=1-\frac{1}{n}$,试问 $\{X_n\}$ 是否满足大数定律?

解 $\{X_n\}$ 是相互独立随机变量序列,且

$$E(X_n)=0, D(X_n)=1$$

由定理 5.2 可知 $\{X_n\}$ 满足切比雪夫大数定律,且 $\frac{1}{n}\sum_{k=1}^{n} X_k \xrightarrow{P} 0$.

5.2.2 伯努利大数定律

定理 5.3(伯努利大数定律) 设 n_A 是 n 次独立重复试验中事件 A 发生的次数,p 是事件 A 在每次试验发生的概率,则对于任意正数 ε,有

$$\lim_{n\to\infty} P\left\{\left|\frac{n_A}{n}-p\right|<\varepsilon\right\}=1$$

或

$$\lim_{n\to\infty} P\left\{\left|\frac{n_A}{n}-p\right|\geqslant\varepsilon\right\}=0$$

即$\frac{n_A}{n}\xrightarrow{P}P$.

证 引入随机变量

$$X_k=\begin{cases}1, & \text{第 } k \text{ 次试验中 } A \text{ 发生},\\ 0, & \text{第 } k \text{ 次试验中 } A \text{ 不发生},\end{cases}\quad (k=1,2,\cdots)$$

显然

$$n_A=X_1+X_2+\cdots+X_n$$

因为 X_k 只依赖第 k 次试验的结果，又假设各次试验是独立的，所以 $X_1,X_2,\cdots,X_n,\cdots$ 是相互独立的.另外，因为 X_k 服从(0—1)分布，所以 $E(X_k)=p,D(X_k)=p(1-p)(k=1,2,\cdots)$.根据定理 5.2，得

$$\lim_{n\to\infty} P\left\{\left|\frac{1}{n}\sum_{k=1}^{n}X_k-p\right|<\varepsilon\right\}=1$$

即

$$\lim_{n\to\infty} P\left\{\left|\frac{n_A}{n}-p\right|<\varepsilon\right\}=1$$

拓展阅读：雅科布·伯努利与他的《猜度术》

伯努利大数定律是概率论历史上最早出现的大数定律，是由瑞士数学家雅科布·伯努利在他的遗著《猜度术》中首次提出的.读者也可用切比雪夫不等式证明该大数定律.

伯努利大数定律表明事件 A 发生的频率$\frac{n_A}{n}$依概率收敛于事件 A 发生的概率 p.该定理以严格的数学表达式明确了频率的稳定性，这就是当 n 很大时，事件发生的频率与概率有较大偏差的可能性很小，由实际推断原理，在实际应用中，当试验次数很大时，便可以用事件发生的频率来近似地代替事件的概率.例如要估计某种疾病在某个地区的发病率，可以从该地区中随机抽取 n 个人进行检测，统计患有此病的频率，当 n 很大时，可近似用此频率作为发病率的估计值，而且我们还可以给出在一定范围内发病率的估计区间(参见第 7 章的区间估计).

拓展阅读：大数定律的发展历史

5.2.3 辛钦大数定律

定理 5.4(辛钦大数定律) 设$\{X_n,n=1,2,\cdots\}$是独立同分布的随机变量序列，且 $E(X_k)=\mu(k=1,2,\cdots)$存在，则对任意 $\varepsilon>0$，有

$$\lim_{n\to\infty} P\left\{\left|\frac{1}{n}\sum_{k=1}^{n}X_k-\mu\right|<\varepsilon\right\}=1$$

即 $\frac{1}{n}\sum_{k=1}^{n}X_k\xrightarrow{P}\mu$.

辛钦大数定律表明，若随机变量序列是独立同分布的，即使对它们的方差一无

所知,它们的算术平均值仍然依概率收敛于它们的数学期望.

辛钦大数定律是苏联数学家辛钦于1929年提出的,相较于切比雪夫大数定律对方差的苛刻要求,它以"同分布"作为补偿,取消了对方差的要求.

辛钦大数定律的证明需要用到概率论的其他知识,超出本书范围,这里从略.

例 5.4 $\{X_n, n=1,2,\cdots\}$ 是独立同分布的随机变量序列,且每个 X_n 都服从参数为 λ 的泊松分布($\lambda>0$),试问当 $n\to\infty$ 时,$Y_n=\dfrac{1}{n}\sum\limits_{k=1}^{n}X_k^2$ 依概率收敛于何值?

解 由于 $X_1^2, X_2^2, \cdots, X_n^2, \cdots$ 是独立同分布的随机变量,且 $E(X_k^2)=[E(X_k)]^2+D(X_k)=\lambda^2+\lambda$,对 $\{X_n^2, n=1,2,\cdots\}$ 应用辛钦大数定律可知,当 $n\to\infty$ 时,$Y_n=\dfrac{1}{n}\sum\limits_{k=1}^{n}X_k^2$ 依概率收敛于 $E(Y_n)=E(X_k^2)=\lambda^2+\lambda$.

5.3 中心极限定理

在实际应用中,如果某个随机变量是由许多偶然因素叠加而成的,那么它的概率分布往往服从(或近似服从)正态分布,本节的中心极限定理将从理论上解释这一现象.先看两个例子.

例 5.5 设 $\{X_n, n=1,2,\cdots\}$ 是独立同分布的随机变量序列,服从(0—1)分布 $B(1,p)$,则部分和 $\sum\limits_{k=1}^{n}X_k$ 服从二项分布 $B(n,p)$.分别取 $p=0.3$ 和 $p=0.6$,绘制二项分布 $B(n,p)$ 在不同 n 下的概率分布折线图(见图5.1),其中横坐标表示随机变量 $\sum\limits_{k=1}^{n}X_k$ 的取值,纵坐标表示取对应值的概率.可以看出,对于不同的 p,随着 n 的不断增加,概率分布折线图越来越接近正态分布的概率密度曲线.

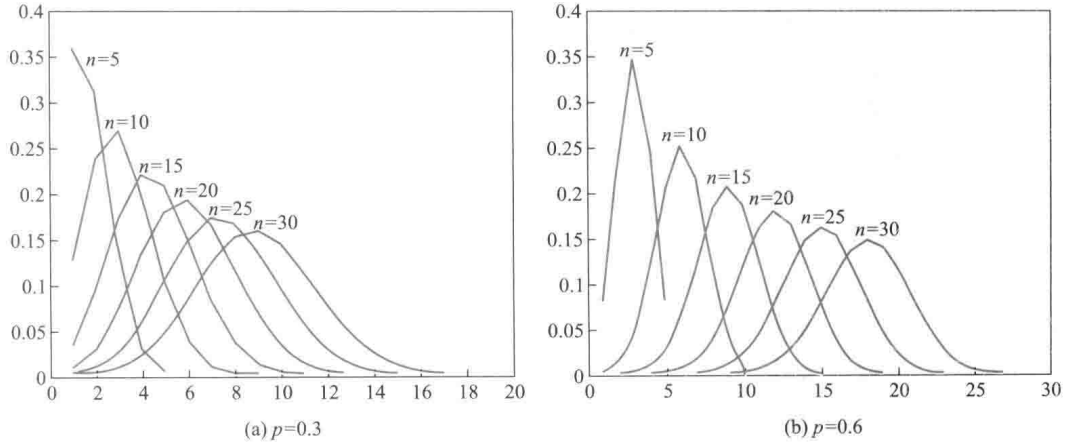

图 5.1

例 5.6 对一物件独立地做 n 次测量,每次的测量误差 $X_k, k=1,2,\cdots,n$ 服从[0,1]上的均匀分布,考虑这些误差之和 $\sum\limits_{k=1}^{n}X_k$ 的分布.由第3章概率密度卷积公式,可

得 $Y_2=X_1+X_2$，$Y_3=X_1+X_2+X_3$ 的概率密度分别为

$$f_2(z)=\begin{cases} z, & 0<z<1, \\ 2-z, & 1\leqslant z<2, \\ 0, & \text{其他}, \end{cases} \qquad f_3(z)=\begin{cases} \dfrac{z^2}{2}, & 0<z<1, \\ -z^2+3z-\dfrac{3}{2}, & 1\leqslant z<2, \\ \dfrac{(3-z)^2}{2}, & 2\leqslant z<3, \\ 0 & \text{其他}, \end{cases}$$

绘制它们的概率密度曲线，并与正态分布概率密度曲线做比较，如图 5.2，图 5.3 所示.

图 5.2 中的实线表示 Y_2 的概率密度 $f_2(z)$ 的曲线，虚线表示正态分布 $N\left(1,\dfrac{1}{6}\right)$ 的概率密度曲线（这是由于 $E(Y_2)=1$，$D(Y_2)=\dfrac{1}{6}$）. 图 5.3 中的实线表示 $f_3(z)$ 的曲线，虚线表示正态分布 $N\left(\dfrac{3}{2},\dfrac{1}{4}\right)$ 的概率密度曲线. 由图 5.2，图 5.3 可知，即使对于很小的 $n(n=2,3)$，正态分布的概率密度曲线与随机变量之和的概率密度曲线之间相差依然较小.

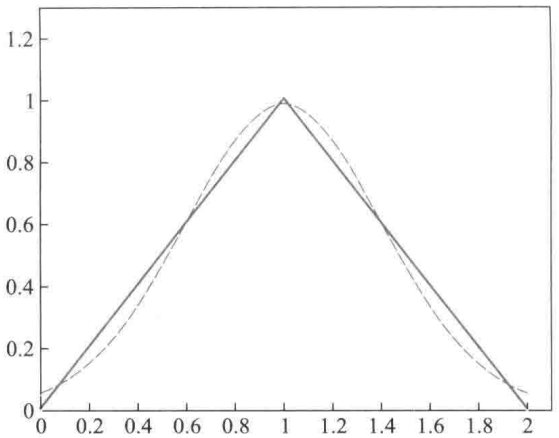

图 5.2

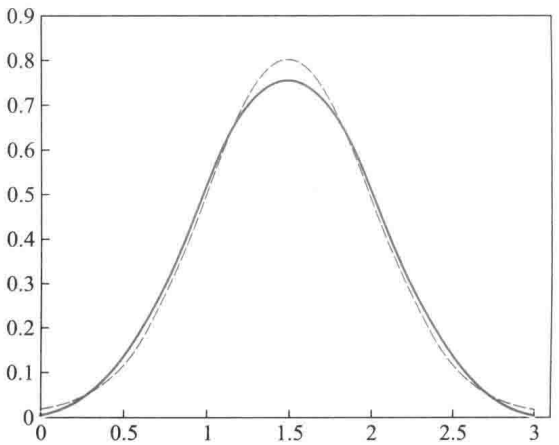

图 5.3

以上两个例子表明多个独立同分布的随机变量之和的分布将随着 n 的增加逐渐逼近于正态分布,这就是下面的中心极限定理.中心极限定理本质上是研究在何种条件下独立随机变量之和的极限分布为正态分布的一系列命题的统称.本节将介绍三个常用的中心极限定理.

5.3.1 独立同分布中心极限定理

定理 5.5 设 $\{X_n, n=1,2,\cdots\}$ 是独立同分布的随机变量序列,且有有限的数学期望和方差:$E(X_k)=\mu, D(X_k)=\sigma^2\neq 0 (k=1,2,\cdots)$,则随机变量

$$Y_n=\frac{\sum\limits_{k=1}^{n}X_k-E\left(\sum\limits_{k=1}^{n}X_k\right)}{\sqrt{D\left(\sum\limits_{k=1}^{n}X_k\right)}}=\frac{\sum\limits_{k=1}^{n}X_k-n\mu}{\sqrt{n}\sigma}$$

的分布函数 $F_n(x)$ 对于任意实数 x,都有

$$\lim_{n\to\infty}F_n(x)=\lim_{n\to\infty}P\left\{\frac{\sum\limits_{k=1}^{n}X_k-n\mu}{\sqrt{n}\sigma}\leqslant x\right\}=\int_{-\infty}^{x}\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-\frac{t^2}{2}}\mathrm{d}t \tag{5.3.1}$$

由于定理的证明要用到较多的数学知识,故从略.由定理 5.5 可知,当 n 很大时,Y_n 近似地服从标准正态分布 $N(0,1)$.因此,当 n 很大时,$\sum\limits_{k=1}^{n}X_k=\sqrt{n}\sigma Y_n+n\mu$ 近似地服从正态分布 $N(n\mu,n\sigma^2)$.若令 $\overline{X}=\frac{1}{n}\sum\limits_{k=1}^{n}X_k$,则当 n 很大时,$\overline{X}$ 近似地服从正态分布 $N\left(\mu,\frac{\sigma^2}{n}\right)$.由此可见,在独立同分布的场合,无论 $X_1,X_2,\cdots,X_n$ 本身的分布函数为何,它们的算术平均数 $\overline{X}$ 在 n 很大时总是近似地服从正态分布.这一结论具有重要的理论及应用价值.

例 5.7 计算机在进行加法时,对每个加数取整,即取最接近于它的整数,设所有的取整误差是相互独立的,且它们都在 $(-0.5,0.5)$ 上服从均匀分布.

(1) 若取 1 200 个数相加,问误差总和的绝对值超过 20 的概率是多少?

(2) 最多可有几个数相加使得误差总和的绝对值小于 10 的概率不小于 0.90?

解 设每个数的取整误差为 $X_k(k=1,2,\cdots,1\ 200)$,则

$$f_{X_k}(x)=\begin{cases}1, & -0.5<x<0.5,\\ 0, & \text{其他}\end{cases}$$

因此,$E(X_k)=0, D(X_k)=\frac{1}{12}(k=1,2,\cdots,1\ 200)$.

(1) 令 $X=\sum\limits_{k=1}^{1\ 200}X_k$,则由题意及定理 5.4,有

$$\begin{aligned}P\{|X|>20\}&=1-P\{-20\leqslant X\leqslant 20\}\\&=1-P\left\{\frac{-20-0}{\sqrt{1\ 200}\sqrt{1/12}}\leqslant\frac{X-0}{\sqrt{1\ 200}\sqrt{1/12}}\leqslant\frac{20-0}{\sqrt{1\ 200}\sqrt{1/12}}\right\}\end{aligned}$$

$$\approx 1-[\Phi(2)-\Phi(-2)]$$
$$=2[1-\Phi(2)]=0.0456$$

(2) 设加数的个数为 n,由题意,要求 n,使得

$$P\left\{\left|\sum_{k=1}^{n}X_k\right|<10\right\}\geqslant 0.90$$

由定理 5.5,有

$$P\left\{\left|\sum_{k=1}^{n}X_k\right|<10\right\}=P\left\{\left|\frac{\sum_{k=1}^{n}X_k}{\sqrt{n/12}}\right|<\frac{10}{\sqrt{n/12}}\right\}\approx 2\Phi\left(\frac{10}{\sqrt{n/12}}\right)-1$$

所以,有不等式

$$2\Phi\left(\frac{10}{\sqrt{n/12}}\right)-1\geqslant 0.90$$

即

$$\Phi\left(\frac{10}{\sqrt{n/12}}\right)\geqslant 0.95$$

通过查附表 1,得 $10\sqrt{\frac{12}{n}}\geqslant 1.65$,故 $n\leqslant 440.77$.因此,最多可有 440 个数相加可使得误差总和的绝对值小于 10 的概率不小于 0.90.

5.3.2 棣莫弗-拉普拉斯中心极限定理

拓展阅读:中心极限定理的发展历史

定理 5.6 设随机变量 $\eta_n(n=1,2,\cdots)$ 服从参数为 $n,p(0<p<1)$ 的二项分布,则对于任意区间 $(a,b]$,恒有

$$\lim_{n\to\infty}P\left\{a<\frac{\eta_n-np}{\sqrt{np(1-p)}}\leqslant b\right\}=\int_a^b\frac{1}{\sqrt{2\pi}}e^{-\frac{t^2}{2}}dt \tag{5.3.2}$$

证 将 η_n 分解为 n 个相互独立且服从(0—1)分布的随机变量 $X_1,X_2,\cdots,X_n$ 之和,即 $\eta_n=X_1+X_2+\cdots+X_n$,其中 $X_k(k=1,2,\cdots,n)$ 的分布律为 $P\{X_k=x\}=p^x(1-p)^{1-x}$ $(x=0,1)$.由于

$$E(X_k)=p,D(X_k)=p(1-p)(k=1,2,\cdots)$$

故由定理 5.5,有

$$\lim_{n\to\infty}P\left\{\frac{\eta_n-np}{\sqrt{np(1-p)}}\leqslant x\right\}=\lim_{n\to\infty}P\left\{\frac{\sum_{k=1}^{n}X_k-np}{\sqrt{np(1-p)}}\leqslant x\right\}=\int_{-\infty}^{x}\frac{1}{\sqrt{2\pi}}e^{-\frac{t^2}{2}}dt$$

于是,对任意区间 $(a,b]$,有

$$\lim_{n\to\infty}P\left\{a<\frac{\eta_n-np}{\sqrt{np(1-p)}}\leqslant b\right\}=\int_a^b\frac{1}{\sqrt{2\pi}}e^{-\frac{t^2}{2}}dt$$

定理 5.6 表明,二项分布的极限分布是正态分布.一般而言,当 n 很大时,二项分布的概率计算是非常麻烦的.若 n 较小,则可以用二项分布的分布律计算概率.若 n

较大，p 较小且 np 适中，则可以利用泊松近似公式（见第 2 章 2.1 节的泊松定理）来近似计算概率.但当 np 也较大时，用上述公式近似计算出的结果，其精度稍差.此时，我们可以利用下面的近似公式来计算二项分布的概率：

$$\begin{aligned}\sum_{k=n_1}^{n_2} C_n^k p^k (1-p)^{n-k} &= P\{n_1 \leqslant \eta_n \leqslant n_2\} \\ &= P\left\{\frac{n_1 - np}{\sqrt{np(1-p)}} \leqslant \frac{\eta_n - np}{\sqrt{np(1-p)}} \leqslant \frac{n_2 - np}{\sqrt{np(1-p)}}\right\} \\ &\approx \Phi\left(\frac{n_2 - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{n_1 - np}{\sqrt{np(1-p)}}\right) \qquad (5.3.3)\end{aligned}$$

例 5.8　设随机变量 $X \sim B(100, 0.8)$，求 $P\{80 \leqslant X \leqslant 100\}$.

解　因 $n=100, p=0.8, np=80$，故不能用泊松近似公式近似计算概率 $P\{80 \leqslant X \leqslant 100\}$.由(5.3.3)式

$$\begin{aligned}P\{80 \leqslant X \leqslant 100\} &\approx \Phi\left(\frac{100-80}{\sqrt{100 \times 0.8 \times 0.2}}\right) - \Phi\left(\frac{80-80}{\sqrt{100 \times 0.8 \times 0.2}}\right) \\ &= \Phi(5) - \Phi(0) = 1 - \frac{1}{2} = \frac{1}{2}\end{aligned}$$

例 5.9　(1) 一复杂系统由 100 个相互独立起作用的部件所组成，在整个运行期间每个部件损坏的概率为 0.10.为了使整个系统起作用，至少必须有 85 个部件正常工作，求整个系统起作用的概率.

(2) 一复杂系统由 n 个相互独立起作用的部件所组成.每个部件的可靠性（即部件正常工作的概率）为 0.90，且必须至少有 80%的部件正常工作才能使整个系统工作，问 n 至少为多大才能使系统的可靠性不低于 0.95.

解　(1) 在任一时刻，对每个部件考察其是否正常工作即相当于进行了一次伯努利试验，由于各个部件是否正常工作是相互独立的，因此，对这 100 个部件的逐一考察可看成是 100 重伯努利试验.若设 X 为某时刻正常工作的部件个数，则 $X \sim B(100, 0.90)$，现要求 $P\{85 \leqslant X \leqslant 100\}$.利用(5.3.3)式，有

$$\begin{aligned}P\{85 \leqslant X \leqslant 100\} &\approx \Phi\left(\frac{100-90}{\sqrt{100 \times 0.9 \times 0.1}}\right) - \Phi\left(\frac{85-90}{\sqrt{100 \times 0.9 \times 0.1}}\right) \\ &= \Phi\left(\frac{10}{3}\right) - \Phi\left(-\frac{5}{3}\right) = 0.952\,0\end{aligned}$$

(2) 设 n 为系统所需的部件总数，X 为某时刻正常工作的部件个数，则 $X \sim B(n, 0.90)$，根据题意，要求使不等式 $P\{0.8n \leqslant X \leqslant n\} \geqslant 0.95$ 成立的最小的 n.

同样由(5.3.3)式，有

$$\begin{aligned}P\{0.8n \leqslant X \leqslant n\} &\approx \Phi\left(\frac{\sqrt{n}}{3}\right) - \Phi\left(-\frac{\sqrt{n}}{3}\right) \\ &= 2\Phi\left(\frac{\sqrt{n}}{3}\right) - 1\end{aligned}$$

令 $2\Phi\left(\frac{\sqrt{n}}{3}\right) - 1 \geqslant 0.95$，即 $\Phi\left(\frac{\sqrt{n}}{3}\right) \geqslant 0.975$，查附表 1 得 $\frac{\sqrt{n}}{3} \geqslant 1.96$，故 $n \geqslant 34.574\,4$，取

$n=35$,所以至少需要35个部件才能使整个系统的可靠性不低于0.95.

例5.10 某车间有200台机床,在工作时间内由于各种原因会停工,各机床开工与否相互独立.已知机床的开工率为0.6,而每台开工的机床需电功率达到5 kW.应至少供应该车间多少电功率,才能以99.9%的概率保证此车间正常工作?

解 设某时刻正常工作的机床数为X,则$X\sim B(200,0.6)$,$E(X)=120$,$D(X)=48$.设某时刻车间需要的电功率为x,则有$P\{0\leqslant 5X\leqslant x\}\geqslant 0.999$.而

$$P\{0\leqslant 5X\leqslant x\}=P\left\{\frac{0-120}{\sqrt{48}}\leqslant\frac{X-120}{\sqrt{48}}\leqslant\frac{x/5-120}{\sqrt{48}}\right\}$$

$$\approx\Phi\left(\frac{x/5-120}{\sqrt{48}}\right)-\Phi\left(\frac{0-120}{\sqrt{48}}\right)=\Phi\left(\frac{x/5-120}{\sqrt{48}}\right)\geqslant 0.999$$

所以$\dfrac{x/5-120}{\sqrt{48}}\geqslant 3.1$,解得$x\geqslant 707.387\ 2$.因此应至少供应该车间708 kW电功率,才能以99.9%的概率保证车间正常工作.

例5.11 试分别用切比雪夫不等式和中心极限定理求一枚均匀硬币需要抛掷多少次,才能使得正面出现的频率在0.4与0.6之间的概率至少为0.9?

解 用X表示抛掷一枚均匀硬币n次正面出现的次数,则$X\sim B(n,0.5)$,$E(X)=\dfrac{n}{2}$,$D(X)=\dfrac{n}{4}$,则正面出现的频率为$\dfrac{X}{n}$,且$E\left(\dfrac{X}{n}\right)=\dfrac{1}{2}$,$D\left(\dfrac{X}{n}\right)=\dfrac{1}{4n}$.

(1) 由切比雪夫不等式(5.1.5)式,

$$P\left\{0.4\leqslant\frac{X}{n}\leqslant 0.6\right\}=P\left\{\left|\frac{X}{n}-0.5\right|\leqslant 0.1\right\}\geqslant 1-\frac{1}{0.1^2}D\left(\frac{X}{n}\right)=1-\frac{25}{n}$$

令$1-\dfrac{25}{n}\geqslant 0.9$,解得$n\geqslant 250$,即至少要抛掷250次硬币才能使得正面出现的频率在0.4与0.6之间的概率至少为0.9.

(2) 由(5.3.3)式,

$$P\left\{0.4\leqslant\frac{X}{n}\leqslant 0.6\right\}=P\left\{\left|\frac{\frac{X}{n}-0.5}{\sqrt{\frac{1}{4n}}}\right|\leqslant\frac{0.1}{\sqrt{\frac{1}{4n}}}\right\}\approx 2\Phi(0.2\sqrt{n})-1\geqslant 0.9$$

由$0.2\sqrt{n}\geqslant 1.65$,解得$n\geqslant 68.062\ 5$.因此至少要抛掷69次硬币才能使得正面出现的频率在0.4与0.6之间的概率至少为0.9.

比较这两个结果,可以看出,用切比雪夫不等式近似计算比用中心极限定理近似计算所得结果更"粗糙"一些,这是因为切比雪夫不等式给出的是概率的下界,而中心极限定理得到的是概率的近似值.

*5.3.3 不同分布的中心极限定理

定理5.7(林德伯格中心极限定理) 设随机变量序列$\{X_n,n=1,2,\cdots\}$相互独立,它们的概率密度分别为$f_{X_1}(x)$,$f_{X_2}(x)$,$\cdots$,且具有有限的数学期望和方差

$E(X_k)=\mu_k, D(X_k)=\sigma_k^2 \quad (k=1,2,\cdots)$，令 $B_n^2=\sum_{k=1}^{n}\sigma_k^2$，$Y_n=\dfrac{\sum_{k=1}^{n}X_k-\sum_{k=1}^{n}\mu_k}{B_n}$. 若对任意正数 τ，有

$$\lim_{n\to\infty}\frac{1}{B_n^2}\sum_{k=1}^{n}\int_{|x-\mu_k|>\tau B_n}(x-\mu_k)^2 f_{X_k}(x)\,\mathrm{d}x=0$$

则对任意实数 x，随机变量 Y_n 的分布函数 $F_n(x)$ 满足

$$\lim_{n\to\infty}F_n(x)=\lim_{n\to\infty}P\left\{\frac{\sum_{k=1}^{n}X_k-\sum_{k=1}^{n}\mu_k}{B_n}\leqslant x\right\}=\int_{-\infty}^{x}\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-\frac{t^2}{2}}\mathrm{d}t$$

证明从略. 我们来分析一下定理 5.7 中的条件（通常称之为林德伯格条件）的概率意义. 令

$$A_k=\{|X_k-\mu_k|>\tau B_n\} \quad (k=1,2,\cdots,n)$$

于是

$$P\{\max_{1\leqslant k\leqslant n}|X_k-\mu_k|>\tau B_n\}=P\Big(\bigcup_{k=1}^{n}A_k\Big)\leqslant\sum_{k=1}^{n}P(A_k)$$

由于 $P(A_k)=P\{|X_k-\mu_k|>\tau B_n\} \quad (k=1,2,\cdots,n)$，由马尔可夫不等式可得

$$P(A_k)\leqslant\frac{1}{\tau^2B_n^2}\int_{|x-\mu_k|>\tau B_n}(x-\mu_k)^2 f_{X_k}(x)\,\mathrm{d}x \quad (k=1,2,\cdots,n)$$

故有

$$P\{\max_{1\leqslant k\leqslant n}|X_k-\mu_k|>\tau B_n\}\leqslant\frac{1}{\tau^2B_n^2}\sum_{k=1}^{n}\int_{|x-\mu_k|>\tau B_n}(x-\mu_k)^2 f_{X_k}(x)\,\mathrm{d}x$$

由此可见，林德伯格条件保证：对任意给定的正数 τ，有

$$\lim_{n\to\infty}P\left\{\max_{1\leqslant k\leqslant n}\left|\frac{X_k-\mu_k}{B_n}\right|>\tau\right\}=0$$

上式表示：当 n 充分大时，$Y_n=\sum_{k=1}^{n}\dfrac{X_k-\mu_k}{B_n}$ 中的每一加项 $\dfrac{X_k-\mu_k}{B_n}$ 都要“均匀的小”. 因而定理 5.7 表明：若某个随机变量是由大量相互独立且均匀小的随机变量相加而成的，那么它的概率分布将近似于正态分布. 在客观世界中所遇到的许多随机变量，往往服从或者近似服从正态分布. 例如，考量射击命中点与靶心距离的偏差，由于这种偏差是大量微小的偶然因素所造成的微小误差的总和，这些因素如瞄准误差、测量误差、子弹制造过程方面（如外形、质量等）的误差以及射击时武器的振动、气象因素（如风速、风向、能见度、温度等）的作用……所有这些不同因素所引起的微小误差是相互独立的，并且它们当中每一个对总和只产生不大的影响，因此，这种偏差服从正态分布. 又如成年人的身高是大量的先天性和后天性的因素影响的总结果，因而一般认为身高近似地服从正态分布.

内容小结

1. 大数定律

切比雪夫不等式：设随机变量 X 存在数学期望 $E(X)$ 和方差 $D(X)$，则对于任意 $\varepsilon>0$，有

$$P\{|X-E(X)|\geqslant\varepsilon\}\leqslant\frac{D(X)}{\varepsilon^2}$$

切比雪夫大数定律：设 $\{X_n,n=1,2,\cdots\}$ 是相互独立的随机变量序列，且分别存在数学期望 $E(X_k)$ 和方差 $D(X_k)(k=1,2,\cdots)$，若存在常数 C，使得 $D(X_k)\leqslant C(k=1,2,\cdots)$，则对任意的 $\varepsilon>0$，有

$$\lim_{n\to\infty}P\left\{\left|\frac{1}{n}\sum_{k=1}^{n}X_k-\frac{1}{n}\sum_{k=1}^{n}E(X_k)\right|<\varepsilon\right\}=1$$

设 $\{X_n,n=1,2,\cdots\}$ 是相互独立的随机变量序列，且存在相同的数学期望 $E(X_k)=\mu$ 与方差 $D(X_k)=\sigma^2(k=1,2,\cdots)$，则对任意的 $\varepsilon>0$，有

$$\lim_{n\to\infty}P\left\{\left|\frac{1}{n}\sum_{k=1}^{n}X_k-\mu\right|<\varepsilon\right\}=1$$

伯努利大数定律：设 n_A 是 n 次独立重复试验中事件 A 发生的次数，p 是事件 A 在每次试验发生的概率，则对于任意 $\varepsilon>0$，有

$$\lim_{n\to\infty}P\left\{\left|\frac{n_A}{n}-p\right|<\varepsilon\right\}=1$$

或

$$\lim_{n\to\infty}P\left\{\left|\frac{n_A}{n}-p\right|\geqslant\varepsilon\right\}=0$$

辛钦大数定律：设 $\{X_n,n=1,2,\cdots\}$ 是独立同分布的随机变量序列，且 $E(X_k)=\mu(k=1,2,\cdots)$ 存在，则对任意 $\varepsilon>0$，有

$$\lim_{n\to\infty}P\left\{\left|\frac{1}{n}\sum_{k=1}^{n}X_k-\mu\right|<\varepsilon\right\}=1$$

2. 中心极限定理

独立同分布中心极限定理：设 $\{X_n,n=1,2,\cdots\}$ 是独立同分布的随机变量序列，且有有限的数学期望和方差：$E(X_k)=\mu,D(X_k)=\sigma^2\neq0(k=1,2,\cdots)$，则随机变量

$$Y_n=\frac{\sum_{k=1}^{n}X_k-E\left(\sum_{k=1}^{n}X_k\right)}{\sqrt{D\left(\sum_{k=1}^{n}X_k\right)}}=\frac{\sum_{k=1}^{n}X_k-n\mu}{\sqrt{n}\sigma}$$

的分布函数 $F_n(x)$ 对于任意实数 x，都有

$$\lim_{n\to\infty}F_n(x)=\lim_{n\to\infty}P\left\{\frac{\sum_{k=1}^{n}X_k-n\mu}{\sqrt{n}\sigma}\leqslant x\right\}=\int_{-\infty}^{x}\frac{1}{\sqrt{2\pi}}e^{-\frac{t^2}{2}}dt$$

棣莫弗-拉普拉斯中心极限定理：设随机变量 $\eta_n(n=1,2,\cdots)$ 服从参数为 $n,p(0<p<1)$ 的二项分布，则对于任意区间 $(a,b]$，恒有

$$\lim_{n\to\infty} P\left\{a < \frac{\eta_n - np}{\sqrt{np(1-p)}} \leqslant b\right\} = \int_a^b \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$

习题 5

1. 设随机变量 X 的分布未知，但已知 $E(X)=\mu, D(X)=\sigma^2$，试用切比雪夫不等式估计 X 落在区间 $(\mu-3\sigma,\mu+3\sigma)$ 内的概率下界.

2. 设随机变量 X 的分布未知，但已知其标准差为 0.3，试用切比雪夫不等式求满足 $P\{E(X)-\varepsilon<X<E(X)+\varepsilon\}\geqslant 0.9$ 的最小 ε.

3. 设随机变量 X 服从参数为 4 的泊松分布，$Y\sim N(4,4)$，且 $\rho(X,Y)=0.5$，试根据切比雪夫不等式估计概率 $P\{|X-Y|\leqslant 4\}$.

4. 设 $X_1,X_2,\cdots,X_n,\cdots$ 是一列相互独立的随机变量，对每一个固定的 n，X_n 的概率分布律为

X_n	-2^n	0	2^n
p	$2^{-(2n+1)}$	$1-2^{-2n}$	$2^{-(2n+1)}$

试证：对任意正数 ε，有

$$\lim_{n\to\infty} P\left\{\left|\frac{1}{n}\sum_{k=1}^{n} X_k\right| < \varepsilon\right\} = 1$$

5. 证明泊松大数定律：如果事件 A 在第 k 次试验中发生的概率等于 $p_k(k=1,2,\cdots,n,\cdots)$ 且各次试验是独立进行的，m 表示在 n 次试验中事件 A 发生的次数，则对任意正数 ε，有

$$\lim_{n\to\infty} P\left\{\left|\frac{m}{n} - \frac{1}{n}\sum_{k=1}^{n} p_k\right| < \varepsilon\right\} = 1$$

6. 随机变量 $X_1,X_2,\cdots,X_n,\cdots$ 相互独立，且都服从正态分布 $N(\mu,\sigma^2)$，记 $\overline{X}_n = \frac{1}{n}\sum_{k=1}^{n} X_k$，试证：$(p)\lim_{n\to\infty}\overline{X}_n = \mu$.

7. 设 X 是一随机变量，$X_1,X_2,\cdots$ 是一列随机变量，试证明：如果 $\lim_{n\to\infty} E(X_n-X)^2=0$，则 $(p)\lim_{n\to\infty} X_n = X$.

8. 设 $X_k(k=1,2,\cdots,80)$ 是相互独立的随机变量且都服从参数为 $\lambda=0.03$ 的泊松分布，记 $Z=\sum_{k=1}^{80} X_k$，试用中心极限定理近似计算 $P\{Z\geqslant 3\}$.

9. 某射手打靶，得 10 分的概率为 0.5，得 9 分的概率为 0.3，得 8 分的概率为 0.1，得 7 分的概率为 0.05，得 6 分的概率为 0.05.现独立地射击 100 次，求总得分在 900 分至 930 分之间的概率.

10. 某种电子元件的使用寿命(单位：h)服从指数分布，其平均寿命为 150 h.在一台昼夜连续工作的设备中使用了一件这种电子元件，使用过程中，当这种元件损坏时，立即换一件新的.问一年(365 天)中最少要预备多少件这种元件，才能保证够用的概率不小于 0.95.

11. 设 $X_1,X_2,\cdots,X_n$ 是独立同分布的随机变量，已知数学期望为 μ，方差为 $\sigma^2>0$，但分布函数未知，求 $\overline{X} = \frac{1}{n}\sum_{k=1}^{n} X_k$ 的渐近分布(即当 n 充分大时，$\overline{X}$ 的分布函数的近似表达式).

12. 在一家人寿保险公司里有 5 000 个同一年龄的人参加人寿保险，每人每年付 12 元保险费，在一年内每个人死亡的概率为 0.001，死亡时，其家属可从保险公司领取 2 000 元.问：

(1) 保险公司一年中获利不少于 20 000 元的概率是多少?

(2) 保险公司亏本的概率是多少?

13. 某单位设置有一电话总机,共有 200 架电话分机.设每个电话分机有 5%的时间要使用外线通话,假定每个分机是否使用外线是相互独立的,问总机要备多少条外线才能以 90%的概率保证每个分机要使用外线时不必等候?

14. 独立重复地抛掷一枚均匀硬币 10 000 次,每次观察出现正面还是反面,用中心极限定理估算:在 99%的把握之下,能够保证正面出现的频率与概率的误差的绝对值控制在什么范围之内?

自测题 5

习题 5 参考答案

第6章 数理统计学的基本概念

前面五章介绍了概率论的基本概念与基本方法.在概率论中,随机变量及其概率分布完整地描述了随机现象的统计规律性.概率论中的所有计算、推理及演绎结果都建立在随机变量的概率分布已知的基础上.然而实际问题往往并非如此.例如,某工厂有一批产品要出厂,作为检验员如何判断该批产品是否可以出厂?我们经常假定测量误差服从正态分布 $N(0,\sigma^2)$,那么误差的方差 σ^2 等于多少?我们的这个假定是否合理呢?这些问题都属于数理统计学的研究范畴.概率论的基本内容为数理统计学建立了必要的数学基础.

数理统计学是一门应用性很强的学科,它研究怎样有效地收集、分析和整理数据,并对所研究的问题做出统计推断.经过多年的研究和发展,数理统计学已经深入到很多学科中.可以说,凡是有大量数据出现的地方,都需要用到数理统计学的思想和方法.

统计推断的主要问题有两类:第一类是由数据推断已知概率分布中的未知参数的取值问题,这类问题称为参数估计问题;第二类是判断某个说法或结论是否成立的问题,这类问题称为假设检验问题.我们将分别在第7章和第8章详细介绍.

本章主要介绍总体、样本、统计量等基本概念,以及一些常见的抽样分布.

6.1 总体与样本

6.1.1 总体

在数理统计中,研究对象的全体所构成的集合称为**总体**.构成总体的每个元素称为**个体**.含有有限个个体的总体称为**有限总体**,否则称为**无限总体**.例如某大学所有一年级学生构成总体,每个一年级学生是个体.

在一个具体的数理统计问题中,我们往往关心的是总体的某项(或某些)数量指标.因此,当我们说总体的时候,既可以是研究对象,也可以是研究对象的某项(或某些)数量指标值构成的集合.

如果用 X 表示总体的某项(或某些)数量指标,则总体是一些可重复的指标 X 构成的集合.总体中,指标 X 的各种不同值有的出现的机会大,有的出现的机会小,客观上有一定的比率.从概率论的角度看,可以用一个概率分布去描述和归纳这种规律.数量指标 X 取不同值的比率称作**总体分布**.由于数量指标 X 的取值随着个体的不同而变化,它可以看成是服从总体分布的一维随机变量(或多维随机向量).

例 6.1 为考察某大学2 000名一年级学生的性别指标,所有一年级学生的性别构成总体.如果用0表示女生,1表示男生,那么

$$\text{总体}=\{2\,000\text{个}0\text{或}1\text{组成的一组数}\}$$

如果该总体中有600名女生,那么性别指标 X 是只取0或1的一维随机变量,总体分布为 $B(1,0.7)$.

例 6.2 如果我们考察上例2 000名学生的年龄和体重指标,那么2 000名学生

的年龄和体重指标构成总体.该总体的指标是二维随机向量,客观上有一个总体分布.

例 6.3 在研究一批产品的使用寿命时,所有产品的使用寿命值构成总体.而寿命指标 X 是一维随机变量,客观上有一个总体分布与之对应,应用实践中人们往往认为 X 服从某个指数分布.

由于总体由总体分布刻画,因此以后我们将总体、总体的数量指标及总体分布等同起来,都用随机变量 X 表示,简称总体 X.有时也根据总体分布的类型来称呼总体.例如若总体分布是正态分布 $N(\mu,\sigma^2)$,则可称为"正态总体"或"总体 $N(\mu,\sigma^2)$".

若总体是离散型随机变量,则称为离散型总体;若总体是连续型随机变量,则称为连续型总体.若该总体考虑的是一维数量指标,则称为一维总体;若总体考虑的是二维数量指标,则称为二维总体.二维及二维以上总体统称为多维总体.本书主要讨论一维总体.

6.1.2 样本

从总体中取得一部分个体,这一部分个体称为**样本**或**子样**.样本中所含个体的个数称为**样本容量**.取得样本的过程称为**抽样**.抽样过程所采取的方法称为**抽样法**.在数理统计中,采用的抽样法是**随机抽样法**,即样本中的每一个个体是从总体中随机地取出来的.采用随机抽样法得到的样本称为**随机样本**.

从总体 X 中随机地抽取 n 个个体,按抽到的先后顺序分别记为 $X_1,X_2,\cdots,X_n$,则它们就是一个容量为 n 的随机样本,记为$(X_1,X_2,\cdots,X_n)$,并且称它是来自总体 X 的样本.由于采用的是随机抽样,因此,每个 $X_i(i=1,2,\cdots,n)$ 都是随机变量,而样本$(X_1,X_2,\cdots,X_n)$是一个 n 维随机向量.

样本$(X_1,X_2,\cdots,X_n)$是 n 维随机向量,这是针对进行一次具体抽样前而言.进行一次具体抽样后得到的是一组具体的实数$(x_1,x_2,\cdots,x_n)$,它是样本$(X_1,X_2,\cdots,X_n)$的一个观测值,称为**样本值**.为方便起见,有时候把样本和样本值统称为样本.

例 6.4 某轧钢厂生产了一批直径为 85 mm 的钢材,为了研究这批钢材的抗拉强度(单位:N/mm^2),从中随机地抽取了 76 个样品进行拉伸试验,测出数据如下:

41.0	37.0	33.0	44.2	30.5	27.0	45.0	28.5
31.2	33.5	38.5	41.5	43.0	45.5	42.5	39.0
38.8	35.5	32.5	29.6	32.6	34.5	37.5	39.5
42.8	45.1	42.8	45.8	39.8	37.2	33.8	31.2
29.0	35.2	37.8	41.2	43.8	48.0	43.6	41.8
36.6	34.8	31.0	32.0	33.5	37.4	40.8	44.7
40.2	41.3	38.8	34.1	31.8	34.6	38.3	41.3
30.0	35.2	37.5	40.5	38.1	37.3	37.1	41.5
29.5	29.1	27.5	34.8	36.5	44.2	40.0	44.5
40.6	36.2	35.8	31.5				

在此例中,这批直径为 85 mm 的钢材的抗拉强度的值的全体就是总体,每根钢材的抗拉强度的值就是个体,总体的数量指标就是每根钢材的抗拉强度 X,它是一个随机变量,这 76 个数据就是容量为 76 的样本$(X_1,X_2,\cdots,X_{76})$的一个样本观测值$(x_1,x_2,\cdots,x_{76})$.

我们抽取样本的目的是为了对总体分布进行各种分析、推断,因而要求抽取的样本能很好地反映总体的特性,这就必须对随机抽样的方法提出一定的要求,通常提出下面两点最有实用价值的要求:

(1) 样本的每个分量 $X_i(i=1,2,\cdots,n)$必须与总体 X 具有相同的分布;

(2) 样本的各分量 $X_1,X_2,\cdots,X_n$ 是相互独立的.

凡具有上述两个性质的样本称为**简单随机样本**.获得简单随机样本的抽样方法称为**简单随机抽样**.在本书中,如果不做特殊声明,所说的样本都是指简单随机样本.

对于简单随机样本$(X_1,X_2,\cdots,X_n)$,其概率分布可以由总体 X 的分布完全决定.设总体 X 的分布函数为 $F(x)$,则样本$(X_1,X_2,\cdots,X_n)$的分布函数为

$$\begin{aligned}P\{X_1\leqslant x_1,X_2\leqslant x_2,\cdots,X_n\leqslant x_n\}&=\prod_{i=1}^{n}P\{X_i\leqslant x_i\}\\&=\prod_{i=1}^{n}F(x_i)\end{aligned}$$

特别地,如果总体 X 是连续型随机变量,具有概率密度 $f(x)$,则样本$(X_1,X_2,\cdots,X_n)$有概率密度

$$f(x_1)f(x_2)\cdots f(x_n)=\prod_{i=1}^{n}f(x_i)$$

如果总体 X 是离散型随机变量,具有分布律

$$P\{X=a_i\}=p_i\quad(i=1,2,\cdots)$$

则样本$(X_1,X_2,\cdots,X_n)$有分布律

$$P\{X_1=x_1,X_2=x_2,\cdots,X_n=x_n\}=\prod_{i=1}^{n}P\{X_i=x_i\}=\prod_{i=1}^{n}P\{X=x_i\}$$

其中 $x_1,x_2,\cdots,x_n$ 都在集合$\{a_1,a_2,\cdots\}$中取值.

例 6.5 设总体 X 服从参数为 $\lambda(\lambda>0)$的指数分布,$(X_1,X_2,\cdots,X_n)$是来自总体 X 的样本,求样本$(X_1,X_2,\cdots,X_n)$的概率密度.

解 总体 X 的概率密度为

$$f(x)=\begin{cases}\lambda e^{-\lambda x}, & x\geqslant 0,\\ 0, & x<0\end{cases}$$

因为 $X_1,X_2,\cdots,X_n$ 相互独立,且都与 X 有相同的分布,所以$(X_1,X_2,\cdots,X_n)$的概率密度为

$$\begin{aligned}f_n(x_1,x_2,\cdots,x_n)&=\prod_{i=1}^{n}f(x_i)\\&=\begin{cases}\lambda^n e^{-\lambda\sum\limits_{i=1}^{n}x_i}, & x_1,x_2,\cdots,x_n\geqslant 0,\\ 0, & \text{其他}\end{cases}\end{aligned}$$

例 6.6 设总体 X 服从(0—1)分布 $B(1,p)$,其中 $0<p<1$,$(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的样本,求样本 $(X_1,X_2,\cdots,X_n)$ 的分布律.

解 总体 X 的分布律为

$$P\{X=i\}=p^i q^{1-i} \quad (i=0,1)$$

其中 $q=1-p$.因为 $X_1,X_2,\cdots,X_n$ 相互独立且与 X 有相同的分布,所以 $(X_1,X_2,\cdots,X_n)$ 的分布律为

$$\begin{aligned} P\{X_1=x_1,X_2=x_2,\cdots,X_n=x_n\} &= P\{X_1=x_1\}P\{X_2=x_2\}\cdots P\{X_n=x_n\} \\ &= p^{\sum\limits_{i=1}^{n}x_i} q^{n-\sum\limits_{i=1}^{n}x_i} \end{aligned}$$

其中 $x_1,x_2,\cdots,x_n$ 在集合 $\{0,1\}$ 中取值.

在实际中,也会碰到样本不是简单随机样本的情况,但有时根据具体问题,可以将其近似地看成是简单随机样本.例如,在有限总体情形,设总体中含有 N 个个体,要从中抽取一个容量为 n 的样本.如果采用有放回抽样,所得样本 $(X_1,X_2,\cdots,X_n)$ 是一个简单随机样本.如果采用不放回抽样,所得样本 $(X_1,X_2,\cdots,X_n)$ 不是一个简单随机样本,但当 N 与 n 相比很大(一般 $N/n\geqslant 10$)时,可近似地看成是简单随机样本.对于无限总体情形,无论是采用有放回抽样还是不放回抽样,所得样本都可认为是简单随机样本.

6.2 样本数据的整理

总体 X 在客观上有总体分布(分布函数 $F(x)$、概率密度 $f(x)$ 或分布律 $P(x)$).在实际问题中,总体分布往往是未知的,要求我们来确定.由于时间、人力、物力、财力等因素的限制,我们不能对总体的每一个个体进行观测,所以,要精确地确定总体分布是很困难的,甚至是不可能的.在实际应用中,我们常常通过对样本数据的整理来对总体分布进行近似.下面介绍整理样本数据的三种形式:样本频数分布与频率分布、频率直方图、经验分布函数.

6.2.1 样本频数分布与频率分布

设有样本值 $(x_1,x_2,\cdots,x_n)$,**样本频数分布**是指样本值中不同数值在样本值中出现的频数(即次数),**样本频率分布**是指样本值中不同数值在样本值中出现的频率(即频数除以样本容量).为确定计,设样本值中不同的数值为 $x_1^*,x_2^*,\cdots,x_l^*$,相应的频数为 $m_1,m_2,\cdots,m_l$,其中 $x_1^*<x_2^*<\cdots<x_l^*$ 且 $\sum\limits_{i=1}^{l} m_i=n$,则样本频数分布可由表 6.1 表示.

表 6.1 样本频数分布表

指标 X	x_1^*	x_2^*	$\cdots$	x_l^*
频数 m_i	m_1	m_2	$\cdots$	m_l

样本频率分布可由表 6.2 表示.

表 6.2 样本频率分布表

指标 X	x_1^*	x_2^*	…	x_l^*
频率$\frac{m_i}{n}$	$\frac{m_1}{n}$	$\frac{m_2}{n}$	…	$\frac{m_l}{n}$

例 6.7 从例 6.2 中的总体中随机地选出 15 名学生,调查其年龄,得样本值(18,18,17,19,18,19,16,17,18,20,18,19,19,18,17),则样本频数分布为

年龄 X	16	17	18	19	20
频率 m_i	1	3	6	4	1

样本频率分布为

年龄 X	16	17	18	19	20
频率$\frac{m_i}{n}$	$\frac{1}{15}$	$\frac{3}{15}$	$\frac{6}{15}$	$\frac{4}{15}$	$\frac{1}{15}$

如果总体 X 是离散型随机变量,那么 $x_i^*(i=1,2,\cdots,l)$ 都是 X 的可能取值,事件 $\{X=x_i^*\}$ 的概率为 $P\{X=x_i^*\}=p_i$,由伯努利大数定律,当 n 很大时,事件 $\{X=x_i^*\}$ 的频率 $\frac{m_i}{n}$ 应接近于概率 p_i.因此,当 n 很大时,我们可以用样本频率分布作为总体分布律的近似.如果总体 X 是连续型随机变量,那么,事件 $\{X=x_i^*\}$ 的概率都是零,这时,考察样本频率分布意义不大,需要考察样本的频率直方图.

6.2.2 频率直方图

设总体 X 是一个连续型随机变量,具有概率密度 $f(x)$,$(x_1,x_2,\cdots,x_n)$ 是来自总体 X 的一个样本值.下面介绍如何作频率直方图,并由此近似得出总体 X 的概率密度曲线 $y=f(x)$.我们结合例 6.4 来说明此方法.

(1) **整理数据**:先把样本值 $x_1,x_2,\cdots,x_n$ 按从小到大的顺序排列得

$$x_{(1)}\leqslant x_{(2)}\leqslant\cdots\leqslant x_{(n)}$$

这样排列后,不仅可以看出其最大值 $x_{(n)}$ 与最小值 $x_{(1)}$,还可以看出大部分值是在哪一个范围内.在本例中,$n=76$,$x_{(1)}=27.0$,$x_{(76)}=48.0$,且大部分值集中在区间(30,45)内.

MATLAB 软件提供了命令 hist(x,n) 绘制直角坐标系下样本值 x 的频率直方图,n 是直方图的区间数,默认为 10.Excel 也提供了多种直方图可选.

(2) **分组**:在(1)的基础上,我们在包含 $[x_{(1)},x_{(n)}]$ 的区间 $[a,b]$ 中插入一些分点 $a=t_0<t_1<\cdots<t_{l-1}<t_l=b$ 把 $[a,b]$ 分成 l 个小区间 $[t_0,t_1],(t_1,t_2],\cdots,(t_{l-1},t_l]$,每个小区间的长度 $d_i=t_i-t_{i-1}(i=1,2,\cdots,l)$ 称为**组距**,区间的中点称为**组中值**,小区间的个数 l 称为**组数**.一般采用等分,即各组的组距相等,此时,$d_i=\frac{b-a}{l}(i=1,2,\cdots,l)$.组数 l 的大小根据样本容量 n 的大小而定:一般说来,$n>100$ 时,l 可取为 10 至 20;n 为

模拟试验：频率直方图

50左右时，取 l 为5或6为宜.但要注意这样的一个划分原则：要使每个区间 $(t_{i-1},t_i]$ $(i=1,2,\cdots,l)$ 内都有样本观测值 $x_i(i=1,2,\cdots,n)$ 落入其中.在本例中，取 $a=27$，$b=48$，$l=7$，且采用等分，即 $d_i=\dfrac{48-27}{7}=3$，$t_i=27+3i(i=1,2,\cdots,7)$.

(3) **列分组频率分布表**：以 m_i 表示观测值落入 $(t_{i-1},t_i]$ 中的个数，即这个区间或这组的频数，$f_i=\dfrac{m_i}{n}$ 称为**这组的频率**.记 $y_i=\dfrac{f_i}{d_i}$，将分组整理的数据列成表.本例的分组频率分布表如表6.3所示.

表6.3 分组频率分布表

分组	组中值	频数 m_i	频率 f_i	y_i
[27,30]	28.5	8	0.105	0.035
(30,33]	31.5	10	0.132	0.044
(33,36]	34.5	12	0.158	0.053
(36,39]	37.5	17	0.224	0.075
(39,42]	40.5	14	0.184	0.061
(42,45]	43.5	11	0.145	0.048
(45,48]	46.5	4	0.053	0.018

(4) **作频率直方图**：在 xOy 坐标平面上，分别以 x 轴上各区间 $(t_{i-1},t_i]$ 为底，以 $y_i=f_i/d_i$ 为高画一排竖着的矩形，即得频率直方图.本例的频率直方图如图6.1所示.

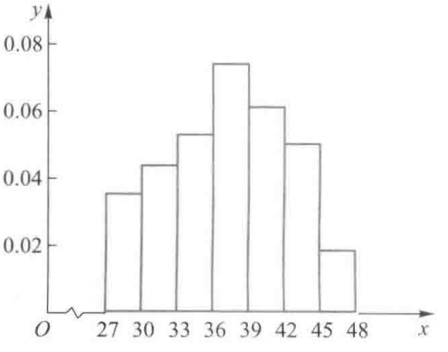

图6.1

根据大数定律，当 n 相当大时，频率 f_i 可以近似地表示总体 X 落入区间 $(t_{i-1},t_i]$ 内的概率 p_i，即

$$f_i \approx p_i = \int_{t_{i-1}}^{t_i} f(x)\,\mathrm{d}x = f(\xi_i)\,d_i,\ \xi_i \in (t_{i-1},t_i] \tag{6.2.1}$$

又

$$f_i = y_i d_i$$

所以

$$y_i \approx f(\xi_i),\quad \xi_i \in (t_{i-1},t_i] \tag{6.2.2}$$

由(6.2.1)式，可以用频率直方图估计概率.例如，在此例中为估计钢材的抗拉强度 X 在35与44之间的概率，利用频率直方图可得

$$P\{35\leqslant X\leqslant 44\}\approx\frac{1}{3}\times 0.158+0.224+0.184+\frac{2}{3}\times 0.145=0.557$$

(5) **作概率密度曲线**:把频率直方图中各矩形上边的中点联结起来得到一条折线,由(6.2.2)式,当 n 及 l 充分大时,这条折线近似于 X 的概率密度曲线 $y=f(x)$.因此,我们可以粗略地给出一条修匀(光滑)曲线作为 X 的概率密度曲线 $y=f(x)$ 的估计(即近似).如果样本容量越大(即 n 越大),分组越细(即 l 越大),那么提供的概率密度曲线越准确.本例中由频率直方图提供的概率密度曲线如图 6.2 所示.

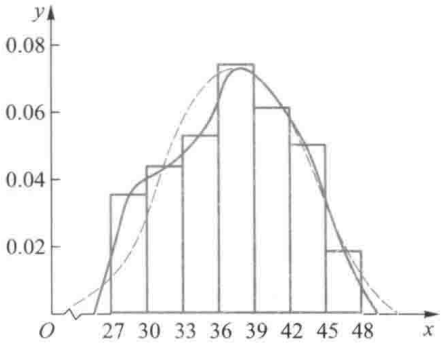

图 6.2

从图 6.2 看,这条曲线很像正态分布的概率密度曲线,这时,我们不禁要问,这批钢材的抗拉强度是否服从正态分布呢?关于这个问题我们将在第 8 章中讨论.

6.2.3 经验分布函数

前两段介绍的样本频率分布和样本的频率直方图,都可以用来估计总体的分布.这种估计方法虽然方便,但是都有局限性,即它们分别只适用于总体 X 为离散型和连续型的随机变量的情形.下面我们介绍一种更为普遍的估计总体分布的方法,即经验分布函数法,它不论总体为离散型或连续型随机变量都可以应用.

设有样本值 $(x_1,x_2,\cdots,x_n)$.作函数

$$F_n(x)=\frac{1}{n}\sum_{i=1}^{n}I_{[x_i\leqslant x]}(x) \tag{6.2.3}$$

这里 $I_A(\cdot)$ 表示集合 A 的示性函数,$I_A(x)=\begin{cases}1, & x\in A,\\ 0, & x\notin A.\end{cases}$ 显然,由(6.2.3)式定义的函数具有如下性质:

(1) $F_n(x)$ 是 x 的单调增函数;

(2) $F_n(x)$ 是 x 的右连续函数;

(3) $F_n(-\infty)=0,F_n(+\infty)=1$.

因此,$F_n(x)$ 是一个分布函数,称它为**样本值** $(x_1,x_2,\cdots,x_n)$ **的经验分布函数**,简称**经验分布函数**.

如果样本值是以频数分布表表 6.1 给出,那么经验分布函数 $F_n(x)$ 可具体表达为

$$F_n(x)=\begin{cases}0, & x<x_1^*,\\ \dfrac{m_1+m_2+\cdots+m_i}{n}, & x_i^*\leqslant x<x_{i+1}^*,(i=1,2,\cdots,l-1)\\ 1, & x\geqslant x_l^*\end{cases}$$

其图形如图 6.3 所示.显然 $F_n(x)$ 是一个阶梯形函数,在每个 x_i^* 处有一个跃度为 $\dfrac{m_i}{n}$ 的跳跃.

MATLAB 软件提供了命令[F,x]=ecdf(y)计算样本 y 的经验分布函数,命令 stairs(F,x)绘制经验分布函数曲线.

例 6.8 对于例 6.7 中的样本值，其经验分布函数为

$$F_{15}(x)=\begin{cases}0, & x<16,\\ \dfrac{1}{15}, & 16\leqslant x<17,\\ \dfrac{4}{15}, & 17\leqslant x<18,\\ \dfrac{10}{15}, & 18\leqslant x<19,\\ \dfrac{14}{15}, & 19\leqslant x<20,\\ 1, & x\geqslant 20\end{cases}$$

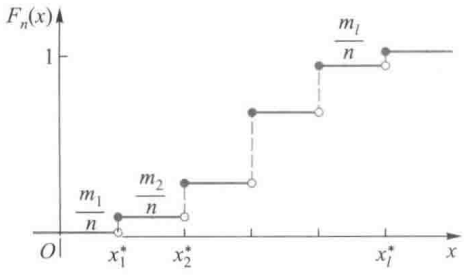

图 6.3

其图像如图 6.4 所示.

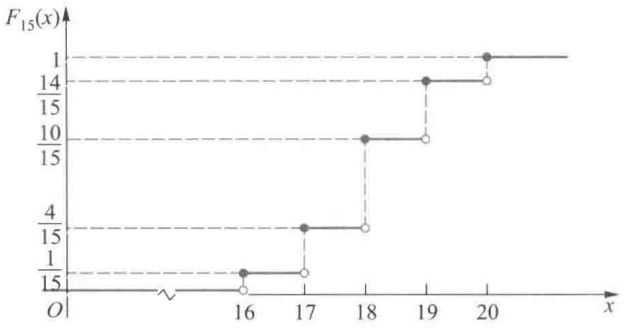

图 6.4

我们来分析经验分布函数 $F_n(x)$ 的含义：由 $F_n(x)$ 的定义可见，当样本值 $(x_1,x_2,\cdots,x_n)$ 给定时，$F_n(x)$ 是 x 的函数，对任何实数 x，$F_n(x)$ 表示 $x_1,x_2,\cdots,x_n$ 落入区间 $(-\infty,x]$ 内的频率.另一方面，对于样本 $(X_1,X_2,\cdots,X_n)$ 的不同观测值将得到不同的经验分布函数 $F_n(x)$，所以，经验分布函数不仅与样本容量有关，而且与得到的样本值 $(x_1,x_2,\cdots,x_n)$ 有关.因为在一次试验中得到样本值 $(x_1,x_2,\cdots,x_n)$ 是随机的，所以，对于每个固定的 x 值，$F_n(x)$ 又是样本 $(X_1,X_2,\cdots,X_n)$ 的函数，是一个随机变量.由大数定律，对于每个固定的 x 值，当 $n\to\infty$ 时，$F_n(x)$ 依概率收敛到 $F(x)=P\{X\leqslant x\}$（具体证明见例 7.24）.因此，当 n 很大时，可以用 $F_n(x)$ 作为分布函数 $F(x)$ 的估计.

6.3 统计量

6.3.1 统计量的概念

样本是我们推断总体分布的依据.利用样本进行统计推断时，第一步的工作是要把样本中所包含的我们关心的事物的信息集中起来，针对不同的问题构造出样本的适当函数，这种函数在统计学中称为统计量.

定义 6.1 设 $(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的一个样本，$T=g(X_1,X_2,\cdots,X_n)$ 为 $(X_1,X_2,\cdots,X_n)$ 的一个实值函数，且 g 中不包含任何未知参数，则称 T 为样本

$(X_1,X_2,\cdots,X_n)$的一个**统计量**.若$(x_1,x_2,\cdots,x_n)$是样本$(X_1,X_2,\cdots,X_n)$的一个观测值,则$t=g(x_1,x_2,\cdots,x_n)$称为统计量T的一个**观测值**.

例如,设(X_1,X_2,X_3)是来自总体$N(\mu,\sigma^2)$的一个样本,其中μ已知,σ^2未知,则$T_1=X_1,T_2=X_1+X_2e^{X_3},T_3=\frac{1}{3}(X_1+X_2+X_3),T_4=\max\{X_1,X_2,X_3\},T_5=X_1+X_2-2\mu$都是统计量,而$T_6=\frac{1}{\sigma^2}(X_1^2+X_2^2+X_3^2)$不是统计量.

下面介绍几个在实际中常用的统计量.

6.3.2 几个常用的统计量

设$(X_1,X_2,\cdots,X_n)$是来自总体X的样本,$(x_1,x_2,\cdots,x_n)$是这一样本的观测值.

1. 样本均值

统计量

$$\bar{X}=\frac{1}{n}\sum_{i=1}^{n}X_i=\frac{1}{n}(X_1+X_2+\cdots+X_n) \tag{6.3.1}$$

称为**样本均值**,其观测值记为

$$\bar{x}=\frac{1}{n}\sum_{i=1}^{n}x_i$$

定理 6.1 设总体X的均值(即数学期望)$E(X)=\mu$和方差$D(X)=\sigma^2$存在,则

(1) $E(\bar{X})=\mu,\quad D(\bar{X})=\frac{\sigma^2}{n}$;

(2) $(p)\lim\limits_{n\to\infty}\bar{X}=\mu$.

MATLAB 提供了命令 mean(X)计算样本 X 的样本均值.Excel 提供了函数 AVERAGE 计算样本均值.

证 (1) 因为$X_1,X_2,\cdots,X_n$都与X有相同的分布,所以,$E(X_i)=\mu,D(X_i)=\sigma^2(i=1,2,\cdots,n)$.又因为$X_1,X_2,\cdots,X_n$相互独立,所以

$$E(\bar{X})=\frac{1}{n}\sum_{i=1}^{n}E(X_i)=\mu$$

$$D(\bar{X})=\frac{1}{n^2}\sum_{i=1}^{n}D(X_i)=\frac{\sigma^2}{n}$$

(2) 由辛钦大数定律知成立.

此定理表明,随着样本容量n的逐渐增大,样本均值$\bar{X}$以越来越大的概率落在总体均值μ的邻近,因此,样本均值常用于估计总体均值,或检验有关总体均值的假设.

2. 样本方差和样本标准差

统计量

$$S^2=\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^2 \tag{6.3.2}$$

称为**样本方差**,其观测值记为

$$s^2=\frac{1}{n-1}\sum_{i=1}^{n}(x_i-\bar{x})^2$$

统计量

$$S=\sqrt{S^2}=\sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^2} \tag{6.3.3}$$

称为**样本标准差**,其观测值记为

$$s=\sqrt{s^2}=\sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i-\bar{x})^2}$$

这里 $\bar{X}$ 为样本均值.样本方差和样本标准差都是反映样本值分散程度的量.

容易验证

$$\sum_{i=1}^{n}(X_i-\bar{X})^2=\sum_{i=1}^{n}X_i^2-n\bar{X}^2 \tag{6.3.4}$$

因此,由(6.3.2)和(6.3.3)式定义的样本方差和样本标准差,通常采用下面的形式:

$$S^2=\frac{1}{n-1}\left(\sum_{i=1}^{n}X_i^2-n\bar{X}^2\right) \tag{6.3.2}'$$

$$S=\sqrt{\frac{1}{n-1}\left(\sum_{i=1}^{n}X_i^2-n\bar{X}^2\right)} \tag{6.3.3}'$$

MATLAB 提供了命令 var(X)计算样本 X 的样本方差,std(X)计算样本 X 的样本标准差.Excel 提供了函数 VAR.S 计算样本方差.

定理 6.2 设总体 X 的均值 $E(X)=\mu$ 和方差 $D(X)=\sigma^2$ 存在,则

(1) $E(S^2)=\sigma^2$;

(2) $(p)\lim\limits_{n\to\infty}S^2=\sigma^2$.

证 (1) 由定理 6.1 知,$E(\bar{X})=\mu$,$D(\bar{X})=\dfrac{\sigma^2}{n}$,

$$E(\bar{X}^2)=D(\bar{X})+[E(\bar{X})]^2=\frac{\sigma^2}{n}+\mu^2$$

因为 $X_1,X_2,\cdots,X_n$ 相互独立,且都与 X 同分布,所以,$X_1^2,X_2^2,\cdots,X_n^2$ 相互独立,且都与 X^2 同分布,从而

$$E(X_i^2)=E(X^2)=\sigma^2+\mu^2 \quad (i=1,2,\cdots,n)$$

故由(6.3.2)′式,有

$$\begin{aligned}E(S^2)&=\frac{1}{n-1}\left[\sum_{i=1}^{n}E(X_i^2)-nE(\bar{X}^2)\right]\\&=\frac{1}{n-1}\left[n(\sigma^2+\mu^2)-n\left(\frac{\sigma^2}{n}+\mu^2\right)\right]\\&=\sigma^2\end{aligned}$$

(2) 对 $X_1^2,X_2^2,\cdots,X_n^2$ 应用辛钦大数定律,有

$$(p)\lim_{n\to\infty}\frac{1}{n}\sum_{i=1}^{n}X_i^2=E(X^2)=\sigma^2+\mu^2$$

由定理 6.1 知,

$$(p)\lim_{n\to\infty}\bar{X}=\mu$$

故由 5.1 节中依概率收敛序列的性质知

$$(p)\lim_{n\to\infty}S^2=(p)\lim_{n\to\infty}\frac{n}{n-1}\left(\frac{1}{n}\sum_{i=1}^{n}X_i^2-\bar{X}^2\right)=\sigma^2$$

此定理表明,随着样本容量 n 的逐渐增大,样本方差 S^2 以越来越大的概率落在总体方差 σ^2 的邻近.因此,样本方差 S^2 常用于估计总体方差,或检验有关总体方差的假设.此外,此定理的结论(1)也是(6.3.2)式中除以 $n-1$ 而不是 n 的原因.

3. 样本矩

统计量

$$A_k=\frac{1}{n}\sum_{i=1}^{n}X_i^k\quad(k=1,2,\cdots)\tag{6.3.5}$$

称为**样本 k 阶原点矩**,简称**样本 k 阶矩**,其观测值记为

$$a_k=\frac{1}{n}\sum_{i=1}^{n}x_i^k\quad(k=1,2,\cdots)$$

统计量

$$B_k=\frac{1}{n}\sum_{i=1}^{n}(X_i-\bar{X})^k\quad(k=1,2,\cdots)\tag{6.3.6}$$

称为**样本 k 阶中心矩**,其观测值记为

$$b_k=\frac{1}{n}\sum_{i=1}^{n}(x_i-\bar{x})^k\quad(k=1,2,\cdots)$$

显然,

$$A_1=\bar{X},B_1=0,B_2=\frac{1}{n}\sum_{i=1}^{n}(X_i-\bar{X})^2=\frac{n-1}{n}S^2$$

$$B_k=\sum_{j=0}^{k}(-1)^{k-j}C_k^jA_jA_1^{k-j}(k=1,2,\cdots)$$

这里约定 $A_0=1$.

定理 6.3 (1) 如果总体 X 的 k 阶原点矩 $\alpha_k=E(X^k)(k=1,2,\cdots)$ 存在,则

$$E(A_k)=\alpha_k$$

(2) $(p)\lim_{n\to\infty}A_k=\alpha_k$.

证 (1) 因为 $X_1,X_2,\cdots,X_n$ 都与 X 有相同的分布,所以

$$E(X_i^k)=E(X^k)=\alpha_k\quad(i=1,2,\cdots,n)$$

故

$$E(A_k)=\frac{1}{n}\sum_{i=1}^{n}E(X_i^k)=\alpha_k$$

(2) 因为 $X_1,X_2,\cdots,X_n$ 相互独立且都与 X 同分布,所以,$X_1^k,X_2^k,\cdots,X_n^k$ 相互独立且都与 X^k 同分布.故对 $X_1^k,X_2^k,\cdots,X_n^k$ 应用辛钦大数定律,立即可得定理结论.

此定理表明,当样本容量 n 逐渐增大时,样本原点矩以越来越大的概率落在总体原点矩的邻近.因此,样本原点矩常用于估计总体原点矩.

4. 顺序统计量

设 $(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的样本,$(x_1,x_2,\cdots,x_n)$ 是这一样本的一个观测

值.将观测值 $x_1,x_2,\cdots,x_n$ 由小到大排列为

$$x_{(1)}\leqslant x_{(2)}\leqslant\cdots\leqslant x_{(n)}$$

MATLAB 提供了命令 min(X) 计算样本 X 的最小值，max(X) 计算样本 X 的最大值，median(X) 计算样本 X 的中位数，pretile(X,p) 计算样本 X 的 $\frac{p}{100}$ 分位数（$0<p<100$）. Excel 也提供了函数 MIN, MAX, MEDIAN 分别计算样本最小值、最大值和样本中值等.

定义统计量 $X_{(k)}$ 取值为 $x_{(k)}$，$k=1,2,\cdots,n$. 由此得到 n 个统计量 $X_{(1)},X_{(2)},\cdots,X_{(n)}$，且它们满足 $X_{(1)}\leqslant X_{(2)}\leqslant\cdots\leqslant X_{(n)}$，称 $X_{(1)},X_{(2)},\cdots,X_{(n)}$ 为该样本的**顺序统计量**或**次序统计量**.

$X_{(1)}=\min\{X_1,X_2,\cdots,X_n\}$ 的观测值 $x_{(1)}$ 是样本观测值中最小的一个，称为**最小顺序统计量**. $X_{(n)}=\max\{X_1,X_2,\cdots,X_n\}$ 的观测值 $x_{(n)}$ 是样本观测值中最大的一个，称为**最大顺序统计量**.

样本的最小、最大顺序统计量反映样本值的取值范围，在某些关于灾害性现象和材料试验结果的统计分析中有重要作用，如一定时期内一条河的最大流量、地震的最大震级、材料的断裂强度等. 数理统计中有一个叫做极值统计分析的分支就专门处理这类问题.

5. 样本极差

统计量

$$R=X_{(n)}-X_{(1)}$$

称为**样本极差**，其观测值记为 $r=x_{(n)}-x_{(1)}$.

样本极差是反映样本值分散程度的量.

6. 样本 p 分位数

对于 $0<p<1$，统计量

$$M_p=\begin{cases}X_{([np+1])}, & np\text{ 不是整数},\\ \dfrac{1}{2}(X_{(np)}+X_{(np+1)}), & np\text{ 是整数}\end{cases}$$

称为**样本 p 分位数**，其观测值记为 $m_p=\begin{cases}x_{([np+1])}, & np\text{ 不是整数},\\ \dfrac{1}{2}(x_{(np)}+x_{(np+1)}), & np\text{ 是整数},\end{cases}$ 这里 $[a]$ 为不超过 a 的最大整数.

当 $p=\dfrac{1}{2}$ 时，样本 p 分位数称做**样本中位数**. 样本 p 分位数是反映样本值位置特征的量，它在推断总体分布的分位数时有重要作用.

理论探究：顺序统计量的概率分布

6.4 抽样分布

样本是随机变量，统计量是样本的已知函数，也是随机变量，因而有其概率分布. 统计量的概率分布称为**抽样分布**. 当总体的分布已知时，可以按照 3.4 节中介绍的方法确定统计量的抽样分布. 正态分布在数理统计中处于特别显著的位置，这是因为在许多领域的统计研究中所遇到的总体大都服从正态分布或近似服从正态分布. 另外，当总体服从正态分布时，许多重要的统计量的抽样分布已经得出. 因此，本节将主要讨论正态总体的抽样分布. 这些分布都与下面介绍的三大分布（χ^2 分布、t 分布、F 分布）有密切关系.

6.4.1 几种常用的重要分布

1. Γ 分布

定义 6.2 如果随机变量 X 具有概率密度

$$f(x;\alpha,\lambda)=\begin{cases}\dfrac{\lambda^{\alpha}}{\Gamma(\alpha)}x^{\alpha-1}\mathrm{e}^{-\lambda x}, & x>0,\\ 0, & x\leqslant 0\end{cases} \tag{6.4.1}$$

其中 $\alpha>0,\lambda>0$ 为常数，则称 X 服从参数为 α,λ 的 Γ 分布，记为 $X\sim\Gamma(\alpha,\lambda)$.

图 6.5 给出了 α,λ 取不同值时的 Γ 分布的概率密度曲线.

当 $\alpha=1$ 时，Γ 分布是参数为 λ 的指数分布.

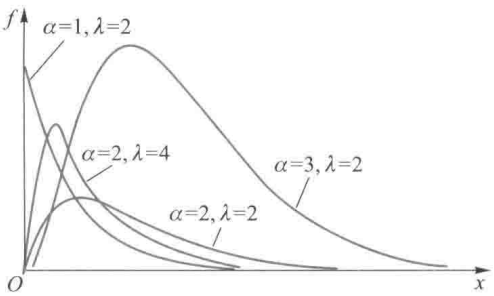

图 6.5

Γ 函数的定义及性质：

Γ 函数定义为 $\Gamma(\alpha)=\int_0^{+\infty}x^{\alpha-1}\mathrm{e}^{-x}\mathrm{d}x$,

Γ 函数具有性质：$\Gamma(\alpha+1)=\alpha\Gamma(\alpha)$, $\Gamma\left(\frac{1}{2}\right)=\sqrt{\pi}$.

特别地，当 n 为正整数时，$\Gamma(n+1)=n!$.

Γ 分布具有如下性质：

性质 1 如果随机变量 $X\sim\Gamma(\alpha,\lambda)$，那么 $E(X)=\dfrac{\alpha}{\lambda}$, $D(X)=\dfrac{\alpha}{\lambda^2}$.

证 由 Γ 函数的性质得

$$E(X)=\frac{\lambda^{\alpha}}{\Gamma(\alpha)}\int_0^{+\infty}x^{\alpha}\mathrm{e}^{-\lambda x}\mathrm{d}x=\frac{\Gamma(\alpha+1)}{\lambda\Gamma(\alpha)}=\frac{\alpha}{\lambda}$$

又因为

$$E(X^2)=\frac{\lambda^{\alpha}}{\Gamma(\alpha)}\int_0^{+\infty}x^{\alpha+1}\mathrm{e}^{-\lambda x}\mathrm{d}x=\frac{\Gamma(\alpha+2)}{\lambda^2\Gamma(\alpha)}=\frac{\alpha(\alpha+1)}{\lambda^2}$$

所以

$$D(X)=E(X^2)-[E(X)]^2=\frac{\alpha(\alpha+1)}{\lambda^2}-\left(\frac{\alpha}{\lambda}\right)^2=\frac{\alpha}{\lambda^2}$$

MATLAB 软件中，命令 gampdf(x,a,b)计算 $\Gamma(a,b)$ 分布在 x 处的概率密度值，gamcdf(x,a,b)计算 $\Gamma(a,b)$ 分布在 x 处的分布函数值.Excel 提供了函数 GAMMA.DIST 计算 $\Gamma(\alpha,\beta)$ 分布的概率密度和分布函数.

性质 2 如果随机变量 $X_1\sim\Gamma(\alpha_1,\lambda)$, $X_2\sim\Gamma(\alpha_2,\lambda)$，且 X_1 与 X_2 相互独立，则

$$X_1+X_2\sim\Gamma(\alpha_1+\alpha_2,\lambda)$$

证 由两个独立随机变量和的卷积公式，X_1+X_2 的概率密度为

$$f(z)=\int_{-\infty}^{+\infty}f_{X_1}(x;\alpha_1,\lambda)f_{X_2}(z-x;\alpha_2,\lambda)\mathrm{d}x$$

$$=\frac{\lambda^{\alpha_1}}{\Gamma(\alpha_1)}\int_0^{+\infty}x^{\alpha_1-1}\mathrm{e}^{-\lambda x}f_{X_2}(z-x;\alpha_2,\lambda)\mathrm{d}x$$

其中

$$f_{X_2}(z-x;\alpha_2,\lambda)=\begin{cases}\dfrac{\lambda^{\alpha_2}}{\Gamma(\alpha_2)}(z-x)^{\alpha_2-1}e^{-\lambda(z-x)}, & x<z,\\ 0, & x\geqslant z\end{cases}$$

所以，当 $z\leqslant 0$ 时，$f(z)=0$；当 $z>0$ 时，

$$\begin{aligned}f(z)&=\frac{\lambda^{\alpha_1+\alpha_2}}{\Gamma(\alpha_1)\Gamma(\alpha_2)}\int_0^z x^{\alpha_1-1}e^{-\lambda x}(z-x)^{\alpha_2-1}e^{-\lambda(z-x)}\,dx\\&=\frac{\lambda^{\alpha_1+\alpha_2}e^{-\lambda z}}{\Gamma(\alpha_1)\Gamma(\alpha_2)}\int_0^z x^{\alpha_1-1}(z-x)^{\alpha_2-1}\,dx\\&=\frac{\lambda^{\alpha_1+\alpha_2}z^{\alpha_1+\alpha_2-1}e^{-\lambda z}}{\Gamma(\alpha_1)\Gamma(\alpha_2)}\int_0^1 t^{\alpha_1-1}(1-t)^{\alpha_2-1}\,dt\\&=\frac{B(\alpha_1,\alpha_2)\lambda^{\alpha_1+\alpha_2}}{\Gamma(\alpha_1)\Gamma(\alpha_2)}z^{\alpha_1+\alpha_2-1}e^{-\lambda z}\\&=\frac{\lambda^{\alpha_1+\alpha_2}}{\Gamma(\alpha_1+\alpha_2)}z^{\alpha_1+\alpha_2-1}e^{-\lambda z}\end{aligned}$$

B函数的定义及性质：
B函数定义为 $B(p,q)=\int_0^1 x^{p-1}\cdot(1-x)^{q-1}dx\ (p>0,q>0)$.
B函数具有性质
(1) $B(p,q)=B(q,p)$；
(2) $B(p,q)=\dfrac{\Gamma(p)\Gamma(q)}{\Gamma(p+q)}$；
(3) $B(p+1,q)=\dfrac{p}{p+q}B(p,q)$.

与(6.4.1)式比较，知 $X_1+X_2\sim\Gamma(\alpha_1+\alpha_2,\lambda)$.

此性质的结论，由数学归纳法可以推广到多个随机变量情形：设随机变量 $X_1,X_2,\cdots,X_m$ 相互独立，且 $X_i\sim\Gamma(\alpha_i,\lambda)\ (i=1,2,\cdots,m)$，则

$$\sum_{i=1}^{m}X_i\sim\Gamma(\alpha_1+\alpha_2+\cdots+\alpha_m,\lambda)$$

2. χ^2 分布（卡方分布）

在 Γ 分布中取 $\alpha=\dfrac{n}{2},\lambda=\dfrac{1}{2}$，$\Gamma$ 分布就是自由度为 n 的 χ^2 分布.

定义 6.3 如果随机变量 Z 具有概率密度

$$\chi^2(x;n)=\begin{cases}\dfrac{1}{2^{\frac{n}{2}}\Gamma\left(\dfrac{n}{2}\right)}x^{\frac{n}{2}-1}e^{-\frac{x}{2}}, & x>0,\\ 0, & x\leqslant 0\end{cases}\tag{6.4.2}$$

则称 Z **服从自由度为 n 的 χ^2 分布**，记为 $Z\sim\chi^2(n)$，随机变量 Z 称为 χ^2 变量.

图 6.6 给出了当 $n=1,4,10,20$ 时的 χ^2 分布的概率密度曲线.

拓展阅读：χ^2 分布的发展历史

当 $n=2$ 时，χ^2 分布是参数为 $\dfrac{1}{2}$ 的指数分布.

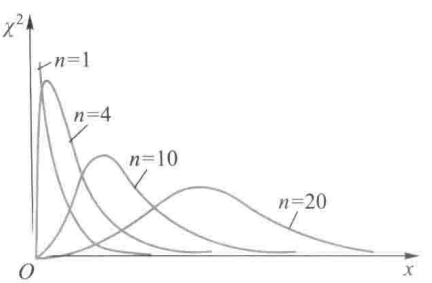

图 6.6

由 Γ 分布的性质知 χ^2 分布有如下性质：

性质 1 若随机变量 $Z\sim\chi^2(n)$，则 $E(Z)=n,D(Z)=2n$.

性质 2（可加性） 若随机变量 $Z_1,Z_2,\cdots,Z_m$ 相互独立，且 $Z_i\sim\chi^2(n_i)\ (i=1,2,\cdots,m)$，则

$$\sum_{i=1}^{m} Z_i \sim \chi^2(n_1 + n_2 + \cdots + n_m).$$

MATLAB 软件中，命令 chi2pdf(x,n) 计算 $\chi^2(n)$ 分布在 x 处的概率密度值，chi2cdf(x,n) 计算 $\chi^2(n)$ 分布在 x 处的分布函数值. Excel 提供了函数 CHISQ.DIST 计算 $\chi^2(n)$ 分布的概率密度和分布函数.

定理 6.4 设随机变量 $X_1, X_2, \cdots, X_n$ 相互独立，且都服从标准正态分布 $N(0,1)$，则随机变量 $\chi^2 = \sum_{i=1}^{n} X_i^2$ 服从自由度为 n 的 χ^2 分布，即 $\chi^2 \sim \chi^2(n)$.

证 若 $X \sim N(0,1)$，则由例 2.15 可知 X^2 的概率密度为

$$f(y) = \begin{cases} \dfrac{1}{\sqrt{2\pi y}} e^{-\frac{y}{2}}, & y>0, \\ 0, & y \leqslant 0 \end{cases}$$

与(6.4.2)式比较，知 $X^2 \sim \chi^2(1)$. 因为 $X_1, X_2, \cdots, X_n$ 相互独立且都服从 $N(0,1)$ 分布，所以 $X_1^2, X_2^2, \cdots, X_n^2$ 相互独立且都服从 $\chi^2(1)$ 分布，由 χ^2 分布的可加性知 $\sum_{i=1}^{n} X_i^2 \sim \chi^2(n)$.

有些教材也用定理 6.4 作为 χ^2 分布的定义，进而导出其概率密度(6.4.2)式.

3. t 分布

定义 6.4 如果随机变量 T 具有概率密度

$$t(x;n) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\,\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}} \quad (-\infty < x < +\infty) \tag{6.4.3}$$

则称 T **服从自由度为 n 的 t 分布**，记为 $T \sim t(n)$.

t 分布又称为**学生氏(Student)分布**.

由(6.4.3)式可见，t 分布的概率密度 $t(x;n)$ 关于 $x=0$ 对称，并且当 $|x| \to +\infty$ 时单调下降趋于 0，还可以证明对任意实数 x，有 $\lim\limits_{n\to\infty} t(x;n) = \dfrac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$，即当自由度 $n \to \infty$ 时，自由度为 n 的 t 分布收敛于标准正态分布 $N(0,1)$. 一般来说，当 $n>30$ 时，t 分布与标准正态分布就非常接近了，但对较小的 n 值，t 分布与标准正态分布之间有较大的差异，且有

$$P\{|T| \geqslant t_0\} \geqslant P\{|X| \geqslant t_0\}$$

其中 $X \sim N(0,1)$.

拓展阅读：t 分布的发展历史

容易验证，当 $n=1$ 时，t 分布就是柯西分布. 柯西分布是不存在任何阶矩的，一般地，当 $n>1$ 时，t 分布只存在阶数 $k<n$ 的矩.

图 6.7 中给出了当 $n=1,2,5$ 时，$t(x;n)$ 的图形与 $n=\infty$（即标准正态分布概率密度）的图形.

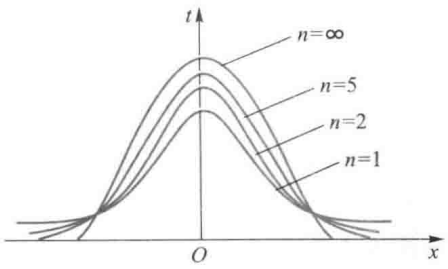

图 6.7

MATLAB 软件中，命令 tpdf(x,n) 计算 $t(n)$ 分布在 x 处的概率密度，tcdf(x,n) 计算 $t(n)$ 分布在 x 处的分布函数. Excel 提供了函数 T.DIST 计算 $t(n)$ 分布的概率密度和分布函数.

定理 6.5 设随机变量 $X \sim N(0,1)$，$Y \sim \chi^2(n)$，且 X 与 Y 相互独立，则

$$T = \frac{X}{\sqrt{Y/n}} \sim t(n)$$

证 令 $Z = \sqrt{Y/n}$，由 Y 的概率密度(6.4.2)式及 2.2 节中随机变量函数的概率密度公式易求出 Z 的概率密度为

$$f_2(y)=\begin{cases}\dfrac{n^{\frac{n}{2}}}{2^{\frac{n}{2}-1}\Gamma\left(\dfrac{n}{2}\right)}y^{n-1}\mathrm{e}^{-\frac{ny^2}{2}}, & y>0,\\ 0, & y\leqslant 0\end{cases}$$

于是，X 与 Z 相互独立，且概率密度分别为 $f_1(x)=\dfrac{1}{\sqrt{2\pi}}\mathrm{e}^{-\frac{x^2}{2}}$ 和 $f_2(y)$，依独立随机变量商的概率密度公式，$T=\dfrac{X}{Z}$ 的概率密度为

$$\begin{aligned}g(t)&=\int_{-\infty}^{+\infty}|y|f_1(ty)f_2(y)\mathrm{d}y\\&=\frac{n^{\frac{n}{2}}}{\sqrt{\pi}2^{\frac{n-1}{2}}\Gamma\left(\dfrac{n}{2}\right)}\int_0^{+\infty}y^n\mathrm{e}^{-\frac{(n+t^2)y^2}{2}}\mathrm{d}y\\&=\frac{1}{\sqrt{n\pi}\Gamma\left(\dfrac{n}{2}\right)}\left(1+\frac{t^2}{n}\right)^{-\frac{n+1}{2}}\int_0^{+\infty}s^{\frac{n-1}{2}}\mathrm{e}^{-s}\mathrm{d}s\\&=\frac{\Gamma\left(\dfrac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\dfrac{n}{2}\right)}\left(1+\frac{t^2}{n}\right)^{-\frac{n+1}{2}}\qquad(-\infty<t<+\infty)\end{aligned}$$

与(6.4.3)式比较，知 $T\sim t(n)$.

4. F 分布

拓展阅读：F 分布的发展历史

定义 6.5 若随机变量 F 具有概率密度

$$f(x;n_1,n_2)=\begin{cases}\dfrac{\Gamma\left(\dfrac{n_1+n_2}{2}\right)}{\Gamma\left(\dfrac{n_1}{2}\right)\Gamma\left(\dfrac{n_2}{2}\right)}\left(\dfrac{n_1}{n_2}\right)\left(\dfrac{n_1}{n_2}x\right)^{\frac{n_1}{2}-1}\left(1+\dfrac{n_1}{n_2}x\right)^{-\frac{n_1+n_2}{2}}, & x>0,\\ 0, & x\leqslant 0\end{cases}\tag{6.4.4}$$

则称 F 服从自由度为 (n_1,n_2) 的 F 分布，记为 $F\sim F(n_1,n_2)$.

MATLAB 软件中，命令 fpdf(x, n1, n2)计算 $F(n_1,n_2)$ 分布在 x 处的概率密度，fcdf(x, n1, n2)计算 $F(n_1,n_2)$ 分布在 x 处的分布函数.Excel 提供了函数 F.DIST 计算 $F(n_1,n_2)$ 分布的概率密度和分布函数.

图 6.8 给出了几条不同自由度的 F 分布的概率密度曲线.

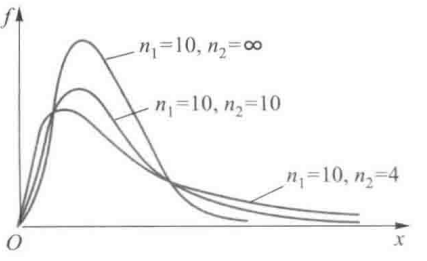

图 6.8

定理 6.6 设随机变量 $X\sim\chi^2(n_1)$，$Y\sim\chi^2(n_2)$，且 X 与 Y 相互独立，则

$$F=\frac{X/n_1}{Y/n_2}\sim F(n_1,n_2)$$

证 由(6.4.2)式及随机变量函数的概率密度公式，易得 X/n_1 的概率密度为

$$f_1(x)=\begin{cases}\dfrac{n_1^{\frac{n_1}{2}}}{2^{\frac{n_1}{2}}\Gamma\left(\dfrac{n_1}{2}\right)}x^{\frac{n_1}{2}-1}\mathrm{e}^{-\frac{n_1}{2}x}, & x>0,\\ 0, & x\leqslant 0\end{cases}$$

Y/n_2 的概率密度为

$$f_2(y)=\begin{cases}\dfrac{n_2^{\frac{n_2}{2}}}{2^{\frac{n_2}{2}}\Gamma\left(\dfrac{n_2}{2}\right)}y^{\frac{n_2}{2}-1}\mathrm{e}^{-\frac{n_2}{2}y}, & y>0,\\ 0, & y\leqslant 0\end{cases}$$

又 X/n_1 与 Y/n_2 相互独立，由独立随机变量商的概率密度公式，F 的概率密度为

$$\begin{aligned}g(x)&=\int_{-\infty}^{+\infty}|y|f_1(xy)f_2(y)\mathrm{d}y\\&=\frac{n_2^{\frac{n_2}{2}}}{2^{\frac{n_2}{2}}\Gamma\left(\dfrac{n_2}{2}\right)}\int_0^{+\infty}y^{\frac{n_2}{2}}\mathrm{e}^{-\frac{n_2}{2}y}f_1(xy)\mathrm{d}y\end{aligned}$$

其中，

$$f_1(xy)=\begin{cases}\dfrac{n_1^{\frac{n_1}{2}}}{2^{\frac{n_1}{2}}\Gamma\left(\dfrac{n_1}{2}\right)}(xy)^{\frac{n_1}{2}-1}\mathrm{e}^{-\frac{n_1xy}{2}}, & xy>0,\\ 0, & xy\leqslant 0\end{cases}$$

所以，当 $x\leqslant 0$ 时，$g(x)=0$；当 $x>0$ 时，

$$\begin{aligned}g(x)&=\frac{n_1^{\frac{n_1}{2}}n_2^{\frac{n_2}{2}}x^{\frac{n_1}{2}-1}}{2^{\frac{n_1+n_2}{2}}\Gamma\left(\dfrac{n_1}{2}\right)\Gamma\left(\dfrac{n_2}{2}\right)}\int_0^{+\infty}y^{\frac{n_1+n_2}{2}-1}\mathrm{e}^{-\frac{(n_2+n_1x)y}{2}}\mathrm{d}y\\&=\frac{n_1^{\frac{n_1}{2}}n_2^{\frac{n_2}{2}}x^{\frac{n_1}{2}-1}}{2^{\frac{n_1+n_2}{2}}\Gamma\left(\dfrac{n_1}{2}\right)\Gamma\left(\dfrac{n_2}{2}\right)}\left(\frac{2}{n_2+n_1x}\right)^{\frac{n_1+n_2}{2}}\int_0^{+\infty}s^{\frac{n_1+n_2}{2}-1}\mathrm{e}^{-s}\mathrm{d}s\\&=\frac{\Gamma\left(\dfrac{n_1+n_2}{2}\right)}{\Gamma\left(\dfrac{n_1}{2}\right)\Gamma\left(\dfrac{n_2}{2}\right)}\left(\frac{n_1}{n_2}\right)^{\frac{n_1}{2}}x^{\frac{n_1}{2}-1}\left(1+\frac{n_1}{n_2}x\right)^{-\frac{n_1+n_2}{2}}\\&=\frac{\Gamma\left(\dfrac{n_1+n_2}{2}\right)}{\Gamma\left(\dfrac{n_1}{2}\right)\Gamma\left(\dfrac{n_2}{2}\right)}\left(\frac{n_1}{n_2}\right)\left(\frac{n_1}{n_2}x\right)^{\frac{n_1}{2}-1}\left(1+\frac{n_1}{n_2}x\right)^{-\frac{n_1+n_2}{2}}\end{aligned}$$

与(6.4.4)式比较,知 $F\sim F(n_1,n_2)$.

推论 如果 $F\sim F(n_1,n_2)$,则 $\dfrac{1}{F}\sim F(n_2,n_1)$.

6.4.2 分位数

数理统计中经常要用到某个概率分布的分位数作为临界值.下面介绍概率分布的分位数概念.

定义 6.6 设随机变量 X 的分布函数为 $F(x)=P\{X\leqslant x\}$,对于 $0<p<1$,若 x_p 使

$$P\{X\leqslant x_p\}=F(x_p)=p$$

则称 x_p 为分布 $F(x)$(或随机变量 X)的**下侧 p 分位数**;对于 $0<\alpha<1$,若 x_α 使

$$P\{X>x_\alpha\}=1-F(x_\alpha)=\alpha$$

则称 x_α 为分布 $F(x)$(或随机变量 X)的**上侧 α 分位数**.

由定义可见,上侧 α 分位数就是下侧 $1-\alpha$ 分位数;下侧 p 分位数就是上侧 $1-p$ 分位数.

例 6.9 设 $X\sim N(0,1)$,标准正态分布 $N(0,1)$ 的上侧 α 分位数是满足

$$P\{X>u_\alpha\}=\frac{1}{\sqrt{2\pi}}\int_{u_\alpha}^{+\infty}\mathrm{e}^{-\frac{x^2}{2}}\mathrm{d}x=\alpha$$

的 u_α 如图 6.9 所示.本书中专门用 u_α 表示 $N(0,1)$ 分布的上侧 α 分位数,其值可查附表 1,如 $u_{0.05}=1.65$,$u_{0.025}=1.96$,等等.由于标准正态分布的对称性,显然有 $u_{1-\alpha}=-u_\alpha$.

MATLAB 软件提供了命令 norminv(p,mu,sigma)计算正态分布的上侧 p 分位数,chi2inv(p,n)计算 $\chi^2(n)$ 分布的上侧 p 分位数,tinv(p,n)计算 $t(n)$ 分布的上侧 p 分位数,finv(p,n1,n2)计算 $F(n_1,n_2)$ 分布的上侧 p 分位数.Excel 提供了函数 NORM.S.INV,CHISQ.INV.RT,T.INV.2T,F.INV.RT 分别计算标准正态分布、χ^2 分布、t 分布、F 分布的上侧分数位.

例 6.10 设 $T\sim t(n)$,$t(n)$ 分布的上侧 α 分位数是满足

$$P\{T>t_\alpha(n)\}=\int_{t_\alpha(n)}^{+\infty}t(x;n)\mathrm{d}x=\alpha$$

的 $t_\alpha(n)$,如图 6.10 所示.本书中用 $t_\alpha(n)$ 表示 $t(n)$ 分布的上侧 α 分位数,其值可查附表 3,如 $t_{0.05}(10)=1.812\,5$,$t_{0.025}(15)=2.131\,5$.由 t 分布的对称性有 $t_{1-\alpha}(n)=-t_\alpha(n)$.

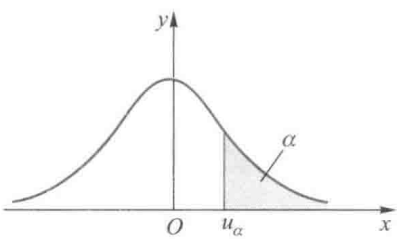

图 6.9

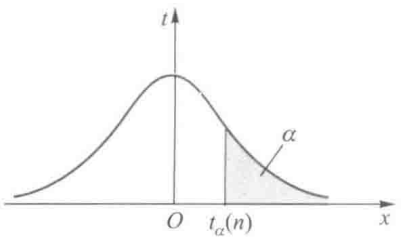

图 6.10

例 6.11 设 $Z\sim\chi^2(n)$,$\chi^2(n)$ 分布的上侧 α 分位数是满足

$$P\{Z>\chi_\alpha^2(n)\}=\int_{\chi_\alpha^2(n)}^{+\infty}\chi^2(x;n)\mathrm{d}x=\alpha$$

的 $\chi_\alpha^2(n)$,如图 6.11 所示.本书中用 $\chi_\alpha^2(n)$ 表示 $\chi^2(n)$ 分布的上侧 α 分位数,其值可查附表 4,如 $\chi_{0.025}^2(8)=17.535$,$\chi_{0.975}^2(10)=3.247$.

例 6.12 $F(n_1,n_2)$ 分布的上侧 α 分位数,本书记为 $F_\alpha(n_1,n_2)$,应满足

$$\int_{F_\alpha(n_1,n_2)}^{+\infty} f(x;n_1,n_2)\,\mathrm{d}x=\alpha$$

如图 6.12 所示，其值可查附表 5，如 $F_{0.025}(7,8)=4.53$，$F_{0.05}(10,16)=2.49$. 由定理 6.6 的推论可知，

$$F_\alpha(n_1,n_2)=\frac{1}{F_{1-\alpha}(n_2,n_1)}$$

例如，查表得 $F_{0.05}(10,16)=2.49$，那么 $F_{0.95}(16,10)=\dfrac{1}{2.49}=0.401\ 6$.

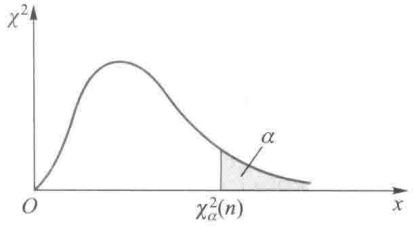

图 6.11

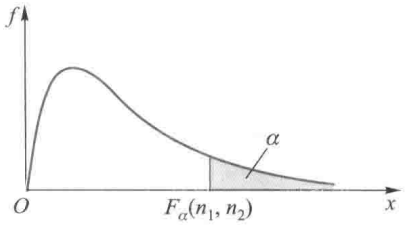

图 6.12

6.4.3 正态总体的抽样分布

下面介绍总体为正态分布时的几个重要的抽样分布定理，它们在以后各章中都有重要的作用.

定理 6.7 设 $(X_1,X_2,\cdots,X_n)$ 是来自正态总体 $N(\mu,\sigma^2)$ 的样本，$\bar{X}$ 为样本均值，S^2 为样本方差，则

(1) $\bar{X}\sim N\left(\mu,\dfrac{\sigma^2}{n}\right)$；

(2) $\dfrac{n-1}{\sigma^2}S^2=\dfrac{1}{\sigma^2}\sum\limits_{i=1}^{n}(X_i-\bar{X})^2\sim\chi^2(n-1)$；

(3) $\bar{X}$ 与 S^2 相互独立.

理论探究：定理 6.7 的证明

定理 6.8 设 $(X_1,X_2,\cdots,X_n)$ 是来自正态总体 $N(\mu,\sigma^2)$ 的样本，$\bar{X}$ 为样本均值，S^2 为样本方差，则

$$T=\frac{\sqrt{n}(\bar{X}-\mu)}{S}\sim t(n-1)$$

证 由定理 6.7 知 $\dfrac{\sqrt{n}(\bar{X}-\mu)}{\sigma}\sim N(0,1)$，$\dfrac{(n-1)S^2}{\sigma^2}\sim\chi^2(n-1)$，且 $\dfrac{\sqrt{n}(\bar{X}-\mu)}{\sigma}$ 与 $\dfrac{(n-1)S^2}{\sigma^2}$ 相互独立，再由定理 6.5 知

$$T=\frac{\sqrt{n}(\bar{X}-\mu)}{S}=\frac{\sqrt{n}(\bar{X}-\mu)}{\sigma}\Big/\sqrt{\frac{(n-1)S^2}{\sigma^2}/(n-1)}\sim t(n-1)$$

定理 6.9 设 $(X_1,X_2,\cdots,X_{n_1})$，$(Y_1,Y_2,\cdots,Y_{n_2})$ 是分别来自总体 $N(\mu_1,\sigma^2)$，

$N(\mu_2,\sigma^2)$的样本，且两样本相互独立，$\bar{X}=\frac{1}{n_1}\sum_{i=1}^{n_1}X_i$，$\bar{Y}=\frac{1}{n_2}\sum_{i=1}^{n_2}Y_i$，$S_{1n_1}^2=\frac{1}{n_1-1}\sum_{i=1}^{n_1}(X_i-\bar{X})^2$，$S_{2n_2}^2=\frac{1}{n_2-1}\sum_{i=1}^{n_2}(Y_i-\bar{Y})^2$，则有

$$T=\frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{S_W\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}}\sim t(n_1+n_2-2)$$

其中

$$S_W^2=\frac{(n_1-1)S_{1n_1}^2+(n_2-1)S_{2n_2}^2}{n_1+n_2-2}$$

证　由定理条件及定理6.7的结论(1)知，$\bar{X}-\bar{Y}\sim N\left(\mu_1-\mu_2,\left(\frac{1}{n_1}+\frac{1}{n_2}\right)\sigma^2\right)$，即

$$U=\frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{\sigma\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}}\sim N(0,1)$$

再由定理条件、定理6.7的结论(2)及χ^2分布的性质2知

$$V=\frac{(n_1-1)S_{1n_1}^2+(n_2-1)S_{2n_2}^2}{\sigma^2}\sim\chi^2(n_1+n_2-2)$$

且由定理3.1及定理6.7的结论(3)知U与V相互独立，从而由定理6.5知

$$T=\frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{S_W\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}}=\frac{U}{\sqrt{V/(n_1+n_2-2)}}\sim t(n_1+n_2-2)$$

要特别注意：此定理中两个正态总体的方差相同.

定理6.10　设$(X_1,X_2,\cdots,X_{n_1})$，$(Y_1,Y_2,\cdots,Y_{n_2})$是分别来自总体$N(\mu_1,\sigma_1^2)$，$N(\mu_2,\sigma_2^2)$的样本，且两样本相互独立，$S_{1n_1}^2$和$S_{2n_2}^2$如定理6.9定义，则

$$F=\frac{\sigma_2^2S_{1n_1}^2}{\sigma_1^2S_{2n_2}^2}\sim F(n_1-1,n_2-1)$$

证　由定理条件及定理6.7知$\frac{(n_1-1)S_{1n_1}^2}{\sigma_1^2}$和$\frac{(n_2-1)S_{2n_2}^2}{\sigma_2^2}$相互独立，且

$$\frac{(n_1-1)S_{1n_1}^2}{\sigma_1^2}\sim\chi^2(n_1-1),\quad\frac{(n_2-1)S_{2n_2}^2}{\sigma_2^2}\sim\chi^2(n_2-1)$$

从而由定理6.6知

$$F=\frac{\dfrac{(n_1-1)S_{1n_1}^2}{\sigma_1^2}\Big/(n_1-1)}{\dfrac{(n_2-1)S_{2n_2}^2}{\sigma_2^2}\Big/(n_2-1)}\sim F(n_1-1,n_2-1)$$

即

$$F=\frac{\sigma_2^2S_{1n_1}^2}{\sigma_1^2S_{2n_2}^2}\sim F(n_1-1,n_2-1)$$

定理 6.7 至定理 6.10 非常重要,它们是后面各章的理论基础,应予以重视.特别是定理 6.7 要能够熟练掌握.

内容小结

1. 总体与样本

将研究对象的全体或研究对象的某项(或某些)数量指标的全体所构成的集合称为总体,而总体中的每个元素称为个体.

从总体中取得的一部分个体称为样本或子样.

样本中所含个体的数量称为样本容量.

取得样本的过程称为抽样,抽样过程所采取的方法称为抽样法.

若样本中的个体是从总体中随机抽取出来的,则这样得到的样本称为随机样本.

若样本$(X_1,X_2,\cdots,X_n)$满足:(1) 每个 X_i 与总体 X 具有相同的分布;(2) X_1, $X_2,\cdots,X_n$ 相互独立,则称$(X_1,X_2,\cdots,X_n)$为简单随机样本.称$(x_1,x_2,\cdots,x_n)$为样本$(X_1,X_2,\cdots,X_n)$的一个观测值。

若总体 X 的分布函数为 $F(x)$,则样本$(X_1,X_2,\cdots,X_n)$的分布函数为

$$F(x_1,x_2,\cdots,x_n)=\prod_{i=1}^{n}F(x_i)$$

若总体 X 是连续型随机变量,概率密度为$f(x)$,则样本$(X_1,X_2,\cdots,X_n)$的概率密度为

$$f(x_1,x_2,\cdots,x_n)=\prod_{i=1}^{n}f(x_i)$$

若总体 X 是离散型随机变量,分布律为 $P\{X=x_i\}=p_i(i=1,2,\cdots)$,则样本$(X_1$, $X_2,\cdots,X_n)$的分布律为

$$P\{X_1=x_1,X_2=x_2,\cdots,X_n=x_n\}=\prod_{i=1}^{n}P\{X=x_i\}$$

2. 常用的统计量

设$(X_1,X_2,\cdots,X_n)$是来自总体的一个样本,统计量 $\overline{X}=\dfrac{1}{n}\sum\limits_{i=1}^{n}X_i$ 称为样本均值,

$S^2=\dfrac{1}{n-1}\sum\limits_{i=1}^{n}(X_i-\overline{X})^2$ 称为样本方差,$S=\sqrt{S^2}$ 称为样本标准差,$A_k=\dfrac{1}{n}\sum\limits_{i=1}^{n}X_i^k(k=1,$

2,…) 称为样本 k 阶原点矩,$B_k=\frac{1}{n}\sum_{i=1}^{n}(X_i-\bar{X})^k(k=1,2,\cdots)$ 称为样本 k 阶中心矩.

若总体 X 的均值 $E(X)=\mu$ 和方差 $D(X)=\sigma^2$ 都存在,则(1) $E(\bar{X})=\mu$,$D(\bar{X})=\frac{\sigma^2}{n}$;(2) $(p)\lim\limits_{n\to\infty}\bar{X}=\mu$;(3) $E(S^2)=\sigma^2$;(4) $(p)\lim\limits_{n\to\infty}S^2=\sigma^2$.

若总体 X 的 k 阶原点矩 $\alpha_k=E(X^k)$ $(k=1,2,\cdots)$ 存在,则(1) $E(A_k)=\alpha_k$;(2) $(p)\lim\limits_{n\to\infty}A_k=\alpha_k$.

设 $(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的样本,将其样本值 $(x_1,x_2,\cdots,x_n)$ 按从小到大的顺序排列为 $x_{(1)}\leqslant x_{(2)}\leqslant\cdots\leqslant x_{(n)}$,定义 $X_{(i)}$ 的取值为 $x_{(i)}(i=1,2,\cdots,n)$,则 $X_{(1)}$,$X_{(2)}$,…,$X_{(n)}$ 称为样本 $(X_1,X_2,\cdots,X_n)$ 的顺序统计量或次序统计量,$X_{(1)}$ 与 $X_{(n)}$ 分别称为最小顺序统计量与最大顺序统计量.

3. Γ 分布、χ^2 分布、t 分布、F 分布及抽样分布定理

(1) 常用的重要分布

如果随机变量 X 具有概率密度

$$f(x;\alpha,\lambda)=\begin{cases}\dfrac{\lambda^{\alpha}}{\Gamma(\alpha)}x^{\alpha-1}e^{-\lambda x}, & x>0,\\ 0, & x\leqslant 0\end{cases}$$

其中常数 $\alpha>0,\lambda>0$,则称 X 服从参数为 α,λ 的 Γ 分布,记为 $X\sim\Gamma(\alpha,\lambda)$.

若 $X\sim\Gamma(\alpha,\lambda)$,则 $E(X)=\frac{\alpha}{\lambda}$,$D(X)=\frac{\alpha}{\lambda^2}$.

若 $X\sim\Gamma(\alpha_1,\lambda)$,$Y\sim\Gamma(\alpha_2,\lambda)$,且 X 与 Y 相互独立,则 $X+Y\sim\Gamma(\alpha_1+\alpha_2,\lambda)$.

设随机变量 $X_1,X_2,\cdots,X_n$ 相互独立且都服从 $N(0,1)$,则随机变量 $\chi^2=X_1^2+X_2^2+\cdots+X_n^2$ 服从自由度为 n 的 χ^2 分布,记作 $\chi^2\sim\chi^2(n)$.

若 $X\sim\chi^2(n)$,则 $E(X)=n$,$D(X)=2n$.

设随机变量 $X\sim N(0,1)$,$Y\sim\chi^2(n)$,且 X 与 Y 相互独立,则随机变量 $T=\frac{X}{\sqrt{Y/n}}$ 服从自由度为 n 的 t 分布,记作 $T\sim t(n)$.

设随机变量 $X\sim\chi^2(n_1)$,$Y\sim\chi^2(n_2)$,且 X 与 Y 相互独立,则随机变量 $F=\frac{X/n_1}{Y/n_2}$ 服从自由度为 (n_1,n_2) 的 F 分布,记作 $F\sim F(n_1,n_2)$.

若随机变量 $X\sim F(n_1,n_2)$,则 $\frac{1}{X}\sim F(n_2,n_1)$.

(2) 分位数

设随机变量 X 的分布函数为 $F(x)$,对于 $\alpha(0<\alpha<1)$,若 x_α 使 $P\{X>x_\alpha\}=1-F(x_\alpha)=\alpha$,称 x_α 为 X 的上侧 α 分位数.u_α 表示 $N(0,1)$ 分布的上侧 α 分位数,$\chi^2_\alpha(n)$ 表示 $\chi^2(n)$ 分布的上侧 α 分位数,$t_\alpha(n)$ 表示 $t(n)$ 分布的上侧 α 分位数,$F_\alpha(n_1,n_2)$ 表示 $F(n_1,n_2)$ 分布的上侧 α 分位数,且 $u_{1-\alpha}=-u_\alpha$,$t_{1-\alpha}(n)=-t_\alpha(n)$,$F_\alpha(n_1,n_2)=\frac{1}{F_{1-\alpha}(n_2,n_1)}$.

(3) 正态总体的抽样分布

设$(X_1,X_2,\cdots,X_n)$是来自总体$N(\mu,\sigma^2)$的样本,$\bar{X}$与S^2分别为样本均值与样本方差,则

① $\bar{X}\sim N\left(\mu,\dfrac{\sigma^2}{n}\right)$;② $\dfrac{(n-1)S^2}{\sigma^2}\sim\chi^2(n-1)$;③ $\bar{X}$与S^2相互独立.

设$(X_1,X_2,\cdots,X_n)$是来自总体$N(\mu,\sigma^2)$的样本,$\bar{X}$与S^2分别为样本均值与样本方差,则

$$\frac{\bar{X}-\mu}{S/\sqrt{n}}\sim t(n-1)$$

设$(X_1,X_2,\cdots,X_{n_1})$和$(Y_1,Y_2,\cdots,Y_{n_2})$是分别来自总体$N(\mu_1,\sigma^2)$和$N(\mu_2,\sigma^2)$的样本,且两样本相互独立,

$$\bar{X}=\frac{1}{n_1}\sum_{i=1}^{n_1}X_i,\bar{Y}=\frac{1}{n_2}\sum_{i=1}^{n_2}Y_i,S_{1n_1}^2=\frac{1}{n_1-1}\sum_{i=1}^{n_1}(X_i-\bar{X})^2,S_{2n_2}^2=\frac{1}{n_2-1}\sum_{i=1}^{n_2}(Y_i-\bar{Y})^2$$

则

$$T=\frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{S_W\sqrt{\dfrac{1}{n_1}+\dfrac{1}{n_2}}}\sim t(n_1+n_2-2)$$

其中$S_W^2=\dfrac{(n_1-1)S_{1n_1}^2+(n_2-1)S_{2n_2}^2}{n_1+n_2-2}$.

设$(X_1,X_2,\cdots,X_{n_1})$和$(Y_1,Y_2,\cdots,Y_{n_2})$是分别来自总体$N(\mu_1,\sigma_1^2)$和$N(\mu_2,\sigma_2^2)$的样本,且两样本相互独立,$S_{1n_1}^2=\dfrac{1}{n_1-1}\sum_{i=1}^{n_1}(X_i-\bar{X})^2,S_{2n_2}^2=\dfrac{1}{n_2-1}\sum_{i=1}^{n_2}(Y_i-\bar{Y})^2$,则

$$F=\frac{\dfrac{S_{1n_1}^2}{\sigma_1^2}}{\dfrac{S_{2n_2}^2}{\sigma_2^2}}=\frac{\sigma_2^2S_{1n_1}^2}{\sigma_1^2S_{2n_2}^2}\sim F(n_1-1,n_2-1)$$

习题 6

1. 设总体X服从正态分布$N(\mu,\sigma^2)$,$(X_1,X_2,\cdots,X_n)$是来自X的样本,试写出$(X_1,X_2,\cdots,X_n)$的概率密度.

2. 设总体X在区间$[a,b]$上服从均匀分布,$(X_1,X_2,\cdots,X_n)$是来自X的样本,试写出$(X_1,X_2,\cdots,X_n)$的概率密度.

3. 设总体X具有概率密度

$$f(x)=\begin{cases}6x(1-x), & 0<x<1,\\ 0, & \text{其他}\end{cases}$$

(X_1,X_2,X_3)是来自X的样本,试写出(X_1,X_2,X_3)的概率密度.

4. 设总体X服从参数为$\lambda(\lambda>0)$的泊松分布,$(X_1,X_2,\cdots,X_n)$是来自X的样本,试写出$(X_1,$

$X_2,\cdots,X_n$)的分布律.

5. 为了研究玻璃产品在集装箱运输过程中的损坏情况,现随机抽取20个集装箱检查其产品损坏的件数,记录结果为1,1,1,1,2,0,0,1,3,1,0,0,2,4,0,3,1,4,0,2.试写出样本频率分布,再写出经验分布函数并画出其图像.

6. 下面是100个学生身高(单位:cm)的测量情况,试作出学生身高的样本频率直方图,并用直方图估计学生身高在160与175之间的概率.

身高	[154,158]	(158,162]	(162,166]	(166,170]	(170,174]	(174,178]	(178,182]
学生数	10	14	26	28	12	8	2

7. 设从总体X抽得一个容量为10的样本,其值为2.4,4.5,2.0,1.0,1.5,3.4,6.6,5.0,3.5,4.0,试计算样本均值、样本方差、样本标准差、样本二阶中心矩及样本二阶原点矩.

8. (1) 从总体X中抽取容量为n的样本,其观测值的频数分布为

x_i^*	x_1^*	x_2^*	$\cdots$	x_l^*
m_i	m_1	m_2	$\cdots$	m_l

($m_1+m_2+\cdots+m_l=n$),试写出计算样本均值$\bar{X}$和样本方差S^2的公式;

(2) 从总体X中抽取一个样本,其观测值的频数分布为

x_i^*	1	3	6	26
m_i	8	40	10	2

求样本均值、样本方差及样本标准差.

9. 样本均值和样本方差的简化计算如下:设来自总体X的样本($X_1,X_2,\cdots,X_n$)的样本均值和样本方差分别为$\bar{X}$和S_X^2,作变换$Y_i=\dfrac{X_i-a}{c}$,得样本($Y_1,Y_2,\cdots,Y_n$),它的样本均值和样本方差记为$\bar{Y}$和S_Y^2.

(1) 试证:$\bar{X}=a+c\bar{Y}$,$S_X^2=c^2S_Y^2$;

(2) 如果总体X的均值$E(X)=\mu$和方差$D(X)=\sigma^2$存在,试求$E(\bar{Y})$和$E(S_Y^2)$.

10. 从总体$X\sim N(9,9)$中分别抽取容量为50的两组样本,求两组样本均值之差的绝对值小于0.6的概率.

11. ($X_1,X_2,\cdots,X_n$)是来自总体X的样本,设总体X的分布分别为(1) 二项分布$B(m,p)$;(2) 参数为λ的泊松分布$P(\lambda)$;(3) 区间$[a,b]$上的均匀分布;(4) 参数为λ的指数分布;(5) 正态分布$N(\mu,\sigma^2)$,试求$E(\bar{X})$,$D(\bar{X})$,$E(S^2)$.

12. 设$\bar{X}_n$和S_n^2为样本($X_1,X_2,\cdots,X_n$)的样本均值和样本方差,增加一次抽样得X_{n+1},记样本($X_1,X_2,\cdots,X_n,X_{n+1}$)的样本均值和样本方差为$\bar{X}_{n+1}$和$S_{n+1}^2$,求证:

(1) $\sum\limits_{i=1}^{n}(X_i-a)^2=\sum\limits_{i=1}^{n}(X_i-\bar{X}_n)^2+n(\bar{X}_n-a)^2$对任何常数$a$都成立;

(2) $\bar{X}_{n+1}=\bar{X}_n+\dfrac{1}{n+1}(X_{n+1}-\bar{X}_n)$,$S_{n+1}^2=\dfrac{n-1}{n}S_n^2+\dfrac{1}{n+1}(X_{n+1}-\bar{X}_n)^2$.

13. 样本($X_1,X_2,\cdots,X_n$)的样本均值和样本方差分别记为$\bar{X}_n$和S_X^2,样本($Y_1,Y_2,\cdots,Y_m$)的样本均值和样本方差分别记为$\bar{Y}_m$和S_Y^2,现将两个样本合并在一起,以$\bar{Z}_{n+m}$和S_Z^2记合并后样本的样

本均值和样本方差，试证：

$$\bar{Z}_{n+m}=\frac{n\bar{X}_n+m\bar{Y}_m}{n+m}$$

$$S_Z^2=\frac{(n-1)S_X^2+(m-1)S_Y^2}{n+m-1}+\frac{nm}{(n+m)(n+m-1)}(\bar{X}_n-\bar{Y}_m)^2$$

14. 若从总体中抽取容量为 13 的样本值：-2.1，3.2，0，-0.1，1.2，-4，2.22，2.01，1.2，-0.1，3.21，-2.1，0.试写出这个样本值的顺序统计量、样本$\frac{2}{3}$分位数及样本极差.

15. 设总体 X 服从参数为 $\lambda(\lambda>0)$ 的泊松分布，$(X_1,X_2,\cdots,X_n)$ 是来自该总体的样本，试求样本均值 $\bar{X}$ 的分布律.

16. 设总体 X 服从参数为 α,λ 的 Γ 分布，$(X_1,X_2,\cdots,X_n)$ 是来自此总体的样本，试求样本均值 $\bar{X}$ 的概率密度.

17. 设 $(X_1,X_2,\cdots,X_n)$ 是来自正态总体 $N(\mu,\sigma^2)$ 的样本，求 $Y=\frac{1}{\sigma^2}\sum\limits_{i=1}^{n}(X_i-\mu)^2$ 的概率分布.

18. 设 $(X_1,X_2,\cdots,X_n)$ 是来自标准正态总体 $N(0,1)$ 的样本，求统计量 $Y=\frac{1}{m}\left(\sum\limits_{i=1}^{m}X_i\right)^2+\frac{1}{n-m}\left(\sum\limits_{i=m+1}^{n}X_i\right)^2$ 的抽样分布.

19. 设 $(X_1,X_2,\cdots,X_{10})$ 是来自正态总体 $N(\mu,\sigma^2)$ 的样本，S^2 是样本方差，求(1) $P\left\{0.3<\frac{S^2}{\sigma^2}<2.114\right\}$；(2) $D(S^2)$.

20. 设 $(X_1,X_2,\cdots,X_n)$ 是来自正态总体 $N(0,\sigma^2)$ 的样本，求统计量(1) $Y_1=\frac{1}{n}\left(\sum\limits_{i=1}^{n}X_i\right)^2$；(2) $Y_2=\frac{1}{n}\sum\limits_{i=1}^{n}X_i^2$ 的概率密度.

21. 已知随机变量 $X\sim t(n)$，求证 $X^2\sim F(1,n)$.

22. 设 $(X_1,X_2,\cdots,X_n,X_{n+1},\cdots,X_{n+m})$ 是来自正态总体 $N(0,\sigma^2)$ 的样本，试求下列统计量的概率分布：

(1) $Y_1=\dfrac{\sqrt{m}\sum\limits_{i=1}^{n}X_i}{\sqrt{n}\sqrt{\sum\limits_{i=n+1}^{n+m}X_i^2}}$；(2) $Y_2=\dfrac{m\sum\limits_{i=1}^{n}X_i^2}{n\sum\limits_{i=n+1}^{n+m}X_i^2}$.

23. 设 $(X_1,X_2,\cdots,X_n,X_{n+1})$ 是来自正态总体 $N(\mu,\sigma^2)$ 的样本，$\bar{X}=\frac{1}{n}\sum\limits_{i=1}^{n}X_i$，$S^2=\frac{1}{n-1}\sum\limits_{i=1}^{n}(X_i-\bar{X})^2$，试求统计量

$$Y=\frac{X_{n+1}-\bar{X}}{S}\sqrt{\frac{n}{n+1}}$$

的抽样分布.

24. 设 $(X_1,X_2,\cdots,X_{n_1})$ 和 $(Y_1,Y_2,\cdots,Y_{n_2})$ 是分别来自总体 $N(\mu_1,\sigma_1^2)$ 和 $N(\mu_2,\sigma_2^2)$ 的两个独立样本，试证明

$$F=\frac{n_2\sigma_2^2\sum\limits_{i=1}^{n_1}(X_i-\mu_1)^2}{n_1\sigma_1^2\sum\limits_{i=1}^{n_2}(Y_i-\mu_2)^2}$$

服从自由度为(n_1,n_2)的 F 分布.

25. 设总体 X 服从参数为 λ 的指数分布,$(X_1,X_2,\cdots,X_n)$是来自总体 X 的样本,试证明 $Y=2\lambda\sum_{i=1}^{n}X_i$ 服从自由度为 $2n$ 的χ^2 分布.

26. 设(X_1,X_2)是来自总体 $X\sim N(0,\sigma^2)$的样本,求统计量 $Y=\left(\frac{X_1+X_2}{X_1-X_2}\right)^2$ 的概率分布.

27. 设$(X_1,X_2,\cdots,X_n)$为来自总体 $U(0,1)$的样本,试证明 $Y=-2\sum_{i=1}^{n}\ln(X_i)$ 服从自由度为 $2n$ 的χ^2 分布.

自测题 6

习题 6 参考答案

第7章 参数估计

在实际应用中，经常会遇到这样的问题：已知总体的分布（或近似分布）的类型，但其中可能含有某些未知参数，如何由样本数据来推断总体的这些未知参数.这类问题就称为参数估计问题.

参数估计是数理统计中重要的基本问题之一.所谓参数既指总体分布中所含的未知参数，也包括当总体分布的类型未知时，总体一些数字特征如均值、方差等（此时这些数字特征也都是未知的）；所谓参数估计是指由样本数据来推断总体的上述未知参数.在讨论参数估计问题时，一般把参数的可容许变动的范围称为**参数空间**，并以 Θ 记之.

本章主要介绍点估计量的求法、点估计量优良性的评判标准以及总体均值和方差的区间估计等内容.

7.1 点估计

7.1.1 问题的提法

先看一个例子.

例 7.1 纺织厂细纱机上的断头次数 X 是一个随机变量，假定它服从参数为 $\lambda(\lambda>0)$ 的泊松分布，参数 λ 未知.现在检查了 150 只纱锭在某一时间间隔内断头的次数，得数据如下：

断头次数 k	0	1	2	3	4	5	6
断头 k 次的纱锭数 n_k	45	60	32	9	2	1	1

试估计参数 λ.

解 由于总体 X 服从参数为 λ 的泊松分布，故有 $\lambda=E(X)$，由定理 6.1 知，当 n 很大时，样本均值 $\overline{X}$ 以很大的概率落在 λ 的邻近.因而，自然想到用样本均值 $\overline{x}$ 作为总体均值 λ 的估计值.由已知数据计算得 $n=\sum_{k=0}^{6} n_k = 150$，

$$\begin{aligned}\overline{x} &= \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{1}{150}\sum_{k=0}^{6} kn_k \\ &= \frac{1}{150}(0\times 45+1\times 60+2\times 32+3\times 9+4\times 2+5\times 1+6\times 1) \\ &= 1.133\end{aligned}$$

所以，λ 的估计值为 1.133.

在例 7.1 的求解过程中，我们先确定了一个统计量 $\overline{X}$，再由抽样后得到的样本值计算出统计量 $\overline{X}$ 的观测值 $\overline{x}$，把 $\overline{x}$ 作为参数 λ 的估计值.这种估计称为**点估计**.

一般地，参数点估计问题的提法如下：设总体 X 的分布函数是 $F(x;\theta_1,\theta_2,\cdots,$

$\theta_l)$，其中 $\theta_1,\theta_2,\cdots,\theta_l$ 是待估计的未知参数，$(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的样本，$(x_1,x_2,\cdots,x_n)$ 是相应的样本值，点估计问题就是要构造 l 个适当的统计量 $\hat{\theta}_i(X_1,X_2,\cdots,X_n)(i=1,2,\cdots,l)$，分别用观测值 $\hat{\theta}_i(x_1,x_2,\cdots,x_n)$ 作为未知参数 θ_i 的估计值. 以后，我们把作为估计用的统计量 $\hat{\theta}_i(X_1,X_2,\cdots,X_n)$ 称为**估计量**，它的观测值 $\hat{\theta}_i(x_1,x_2,\cdots,x_n)$ 称为**估计值**，在不致混淆的情况下统称估计量和估计值为**估计**，并都简记为 $\hat{\theta}_i$.

由于估计量是样本的函数，是随机变量，因此，对于不同的样本值得到的参数估计值往往是不相同的. 在点估计问题中，关键是求估计量. 下面介绍估计量的求法.

矩估计法是英国统计学家卡尔·皮尔逊在19世纪末20世纪初首次提出的. 矩估计法的主要思想是用样本矩替换对应的总体矩这里的矩可以是原点矩、中心矩，还可以是矩的函数.

7.1.2 估计量的求法

点估计量的求法有许多种，下面主要介绍常用的两种方法：矩估计法和最大似然估计法.

1. 矩估计法

设总体 X 的分布中含有 l 个待估计的未知参数 $\theta_1,\theta_2,\cdots,\theta_l$，求出 X 的 l 个原点矩，要求它们都是 $\theta_1,\theta_2,\cdots,\theta_l$ 的函数. 不妨设总体 X 的前 l 阶原点矩 $\alpha_k=E(X^k)(k=1,2,\cdots,l)$ 存在，且都是 $\theta_1,\theta_2,\cdots,\theta_l$ 的函数，即

$$\alpha_k=\alpha_k(\theta_1,\theta_2,\cdots,\theta_l)\quad(k=1,2,\cdots,l)$$

把上面各式中的总体原点矩用相应的样本原点矩代替，未知参数用其估计量代入得

$$\alpha_k(\hat{\theta}_1,\hat{\theta}_2,\cdots,\hat{\theta}_l)=A_k\quad(k=1,2,\cdots,l)\tag{7.1.1}$$

解此方程组可得 $\hat{\theta}_1,\hat{\theta}_2,\cdots,\hat{\theta}_l$，并将它们分别作为 $\theta_1,\theta_2,\cdots,\theta_l$ 的估计量. 这种求估计量的方法称为**矩估计法**，简称**矩法**. 用矩估计法求得的估计量称为**矩估计量**.

矩估计法的理论依据是大数定律，由定理6.3知，当 n 充分大时，样本矩 A_k 以很大的概率落在总体矩 α_k 的邻近，因而可用 A_k 作为 α_k 的矩估计量.

例7.2 设总体 X 在 $[0,\theta]$ 上服从均匀分布，其中 $\theta(\theta>0)$ 未知，$(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的样本，求 θ 的矩估计量.

解 因为 $\alpha_1=E(X)=\dfrac{\theta}{2}$，所以，由矩估计法，令

$$\frac{\hat{\theta}}{2}=A_1=\overline{X}$$

解之，得 θ 的矩估计量为 $\hat{\theta}=2\overline{X}$.

例7.3 设总体 X 具有概率密度

$$f(x)=\begin{cases}\lambda e^{-\lambda(x-\theta)}, & x>\theta,\\ 0, & x\leqslant\theta\end{cases}$$

其中 $\lambda(\lambda>0)$，θ 都是未知参数. $(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的样本，求 θ,λ 的矩估计量.

解 因为

$$\alpha_1=E(X)=\int_{\theta}^{+\infty}x\lambda e^{-\lambda(x-\theta)}dx=\theta+\frac{1}{\lambda}$$

$$\alpha_2 = E(X^2) = \int_{\theta}^{+\infty} x^2 \lambda e^{-\lambda(x-\theta)} dx = \left(\theta + \frac{1}{\lambda}\right)^2 + \frac{1}{\lambda^2}$$

所以,由矩估计法,令

$$\begin{cases} \hat{\alpha}_1 = A_1, \\ \hat{\alpha}_2 = A_2 \end{cases}$$

即

$$\begin{cases} \hat{\theta} + \dfrac{1}{\hat{\lambda}} = \overline{X}, \\ \left(\hat{\theta} + \dfrac{1}{\hat{\lambda}}\right)^2 + \dfrac{1}{\hat{\lambda}^2} = \dfrac{1}{n}\sum\limits_{i=1}^{n} X_i^2 \end{cases}$$

解之,得 θ,λ 的矩估计量分别为

$$\hat{\theta} = \overline{X} - \sqrt{B_2} = \overline{X} - \sqrt{\frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^2}$$

$$\hat{\lambda} = B_2^{-\frac{1}{2}} = \left[\frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^2\right]^{-\frac{1}{2}}$$

例 7.4 设总体 X 服从几何分布 $Ge(p)$,其中 $p(0<p<1)$ 为未知参数,$(X_1, X_2, \cdots, X_n)$ 为来自总体 X 的样本,求 p 的矩估计量.

解 因为

$$\alpha_1 = E(X) = \sum_{k=1}^{\infty} kp(1-p)^{k-1} = \frac{1}{p}$$

所以,由矩估计法,令

$$\frac{1}{\hat{p}} = \overline{X}$$

得 p 的矩估计量 $\hat{p} = \dfrac{1}{\overline{X}}$.

例 7.5 设总体 X 的二阶矩存在,$(X_1, X_2, \cdots, X_n)$ 是来自总体 X 的样本,求总体 X 的均值 μ 和方差 σ^2 的矩估计量.

例 7.5 的结果表明:无论总体服从什么分布,总体均值 μ 的矩估计量都是样本均值 $\overline{X}$,总体方差 σ^2 的矩估计量都是样本二阶中心矩 B_2.

解 因为 $\alpha_1 = \mu, \alpha_2 = \sigma^2 + \mu^2$,所以由矩估计法得方程组

$$\begin{cases} \hat{\mu} = A_1 = \overline{X}, \\ \hat{\mu}^2 + \hat{\sigma}^2 = A_2 = \dfrac{1}{n}\sum\limits_{i=1}^{n} X_i^2 \end{cases}$$

解之,得 μ 和 σ^2 的矩估计量为

$$\hat{\mu} = \overline{X}$$

$$\hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n} X_i^2 - (\overline{X})^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^2 = B_2$$

例 7.6 设 $X \sim N(\mu, \sigma^2)$,μ, σ 是未知参数,$(X_1, X_2, \cdots, X_n)$ 是来自 X 的样本,求 μ, σ 的矩估计量.

解 因为 μ,σ^2 分别为总体 X 的均值和方差，所以，由例 7.5 的结论可知 μ,σ 的矩估计分别为 $\hat{\mu}=\overline{X},\hat{\sigma}=\sqrt{B_2}$.

例 7.7 设总体 X 服从参数为 $\lambda(\lambda>0)$ 的泊松分布，$(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的样本，试求 λ 的矩估计量.

解 我们已经知道 $E(X)=\lambda$，所以，由例 7.5 的结论可知，λ 的矩估计量为 $\hat{\lambda}=\overline{X}$.

例 7.8 设总体 X 具有概率密度

$$f(x)=\begin{cases}\dfrac{2}{\Gamma\left(\dfrac{\theta}{2}\right)}x^{\theta-1}\mathrm{e}^{-x^2}, & x>0,\\ 0, & x\leqslant 0\end{cases}$$

其中 $\theta>0$ 是未知参数，$(X_1,X_2,\cdots,X_n)$ 是来自此总体的样本，试求 θ 的矩估计量.

解 因为

$$\begin{aligned}\alpha_1=E(X)&=\frac{2}{\Gamma\left(\dfrac{\theta}{2}\right)}\int_0^{+\infty}x^{\theta}\mathrm{e}^{-x^2}\mathrm{d}x\\&=\frac{1}{\Gamma\left(\dfrac{\theta}{2}\right)}\int_0^{+\infty}y^{\frac{\theta-1}{2}}\mathrm{e}^{-y}\mathrm{d}y\\&=\frac{\Gamma\left(\dfrac{\theta+1}{2}\right)}{\Gamma\left(\dfrac{\theta}{2}\right)}\end{aligned}$$

所以，由矩估计法，令

$$\frac{\Gamma\left(\dfrac{\hat{\theta}+1}{2}\right)}{\Gamma\left(\dfrac{\hat{\theta}}{2}\right)}=\overline{X}$$

此方程的解 $\hat{\theta}$ 就是 θ 的矩估计量.但此处得不出简单的解析表达式，而只能对具体的样本值用数值方法得出估计值.

矩估计法不必知道总体的分布，直接用样本矩代替对应的总体矩，进而求得总体中未知参数的估计.这种估计方法的优点是简单直接，在一定条件下所求得的参数矩估计会随着样本容量的无限趋大而收敛于参数真值.由于矩估计法只是利用了总体的局部特征而没有充分利用总体分布的信息，因而所得的估计在体现总体分布特征的性质方面力有不逮.

2. 最大似然估计法

统计中的频率学派认为，如果在一次试验中事件 A 发生，那么 A 发生的概率取大值要比取小值合理.同样地，一次随机抽样抽到了样本值 $(x_1,x_2,\cdots,x_n)$，现要由此样本数据估计参数相当于要推断样本值 $(x_1,x_2,\cdots,x_n)$ 来自哪个分布亦即哪个总体（因为不同的参数对应不同的总体分布也就是不同的总体）.基于上述朴素思想，若

存在某一分布，使得在此分布下抽中$(x_1,x_2,\cdots,x_n)$的概率最大，则认为$(x_1,x_2,\cdots,x_n)$来自这一分布.下面举例子来说明这种统计思想.

例 7.9 设有两枚外形完全一样的硬币，一枚是均匀的，另一枚不均匀.用 p 表示抛掷一枚硬币出现正面朝上的概率.已知对均匀硬币，$p=\frac{1}{2}$.对不均匀硬币，$p=\frac{2}{3}$.现从这两枚硬币中随机选一枚，连续抛掷 3 次，结果其中有 2 次出现正面朝上，试问这枚硬币是哪一枚比较合理?

解 用随机变量 X 表示抛掷硬币 3 次其中出现正面朝上的次数，则 $X\sim B(3,p)$，据题意参数 p 的取值范围是$\left\{\frac{1}{2},\frac{2}{3}\right\}$.两个不同的参数值对应两个不同的总体：一个对应一枚均匀硬币，另一个对应一枚不均匀硬币.现从这两枚硬币中随机选一枚，用 B 表示事件{连续抛掷 3 次硬币，其中有 2 次正面朝上}.要从事件 B 的发生推断这枚硬币属于哪一种硬币，也就是要推断这组样本数据更有可能来自哪个总体.

注：读者也可以讨论当正面朝上次数是 0，3 时，参数 p 的取值.

当 $p=\frac{1}{2}$时，$P(B)=C_3^2\frac{1}{2^3}=0.375$，而当 $p=\frac{2}{3}$时，$p(B)=C_3^2\left(\frac{2}{3}\right)^2\left(\frac{1}{3}\right)^1=0.444\ 4$.显然 $0.375<0.444\ 4$，说明抛掷一枚不均匀硬币会使得 B 发生的可能性更大，故认为这枚硬币更像是不均匀的那枚，亦即推断 $p=\frac{2}{3}$.

若用 C 表示事件{将抽中的硬币连续抛掷 3 次，其中有 2 次反面朝上}，此时 $C_3^2\frac{1}{2^3}=0.375>C_3^2\left(\frac{1}{3}\right)^2\frac{2}{3}=0.222\ 2$，即抛掷一枚均匀硬币使得事件 C 发生的可能性更大，则就认为这枚硬币更像是均匀硬币，换言之推断 $p=\frac{1}{2}$.

拓展阅读：最大似然估计法的发展历史

以上例子解释了最大似然估计法的原理及求解方法：利用已知的样本信息，反推最具有可能(或最大概率)导致这些样本结果出现的参数取值！下面具体给出最大似然估计法.

定义 7.1 如果总体 X 是离散型或连续型随机变量，其分布律为

$$P\{X=x\}=p(x;\theta_1,\theta_2,\cdots,\theta_l)$$

或概率密度为

$$f(x;\theta_1,\theta_2,\cdots,\theta_l)$$

其中 $\theta_1,\theta_2,\cdots,\theta_l$ 为未知参数，在参数空间 Θ 内取值，变量 x 在随机变量 X 的可能取值范围内取值.设$(X_1,X_2,\cdots,X_n)$是来自总体 X 的样本，则$(X_1,X_2,\cdots,X_n)$的分布律为

$$\begin{aligned}L(x_1,x_2,\cdots,x_n;\theta_1,\theta_2,\cdots,\theta_l)&=P\{X_1=x_1,X_2=x_2,\cdots,X_n=x_n\}\\&=\prod_{i=1}^{n}p(x_i;\theta_1,\theta_2,\cdots,\theta_l)\end{aligned}\tag{7.1.2}$$

或概率密度为

$$L(x_1,x_2,\cdots,x_n;\theta_1,\theta_2,\cdots,\theta_l)=\prod_{i=1}^{n}f(x_i;\theta_1,\theta_2,\cdots,\theta_l)\tag{7.1.2}'$$

当固定$(x_1,x_2,\cdots,x_n)$，把 $L(x_1,x_2,\cdots,x_n;\theta_1,\theta_2,\cdots\theta_l)$看成是 $\theta_1,\theta_2,\cdots,\theta_l$ 的定

义于 Θ 上的函数时，它称为参数 $\theta_1,\theta_2,\cdots,\theta_l$ 的**似然函数**，并简记为 $L(\theta_1,\theta_2,\cdots,\theta_l)$，即 $L(\theta_1,\theta_2,\cdots,\theta_l)=L(x_1,x_2,\cdots,x_n;\theta_1,\theta_2,\cdots,\theta_l)$. 似然函数的对数 $\ln L(\theta_1,\theta_2,\cdots,\theta_l)$ 称为**对数似然函数**.

最大似然估计法就是当得到样本值 $(x_1,x_2,\cdots,x_n)$ 时，选取使似然函数 $L(\theta_1,\theta_2,\cdots,\theta_l)$ 取得最大值的 $\hat{\theta}_1,\hat{\theta}_2,\cdots,\hat{\theta}_l$ 分别作为未知参数 $\theta_1,\theta_2,\cdots,\theta_l$ 的估计值，即取 $\hat{\theta}_1,\hat{\theta}_2,\cdots,\hat{\theta}_l$ 使

$$L(x_1,x_2,\cdots,x_n;\hat{\theta}_1,\hat{\theta}_2,\cdots,\hat{\theta}_l)=\max_{(\theta_1,\theta_2,\cdots,\theta_l)\in\Theta}L(x_1,x_2,\cdots,x_n;\theta_1,\theta_2,\cdots,\theta_l) \tag{7.1.3}$$

或简单地写成

$$L(\hat{\theta}_1,\hat{\theta}_2,\cdots,\hat{\theta}_l)=\max_{(\theta_1,\theta_2,\cdots,\theta_l)\in\Theta}L(\theta_1,\theta_2,\cdots,\theta_l) \tag{7.1.3}'$$

这样得到的 $\hat{\theta}_1,\hat{\theta}_2,\cdots,\hat{\theta}_l$ 与样本值 $(x_1,x_2,\cdots,x_n)$ 有关，记为 $\hat{\theta}_i=\hat{\theta}_i(x_1,x_2,\cdots,x_n)$，并称为参数 $\theta_i(i=1,2,\cdots,l)$ 的**最大似然估计值**，而相应的统计量 $\hat{\theta}_i(X_1,X_2,\cdots,X_n)(i=1,2,\cdots,l)$ 称为参数 θ_i 的**最大似然估计量**.

最大似然估计法把参数 $\theta_1,\theta_2,\cdots,\theta_l$ 的估计问题转化为似然函数 $L(\theta_1,\theta_2,\cdots,\theta_l)$ 的极值问题. 由于 $\ln x$ 是 x 的单调上升函数，因而 $\ln L(\theta_1,\theta_2,\cdots,\theta_l)$ 与 $L(\theta_1,\theta_2,\cdots,\theta_l)$ 有相同的最大值点. 因此，最大似然估计 $\hat{\theta}_1,\hat{\theta}_2,\cdots,\hat{\theta}_l$ 可以等价地定义为

$$\ln L(\hat{\theta}_1,\hat{\theta}_2,\cdots,\hat{\theta}_l)=\max_{(\theta_1,\theta_2,\cdots,\theta_l)\in\Theta}\ln L(\theta_1,\theta_2,\cdots,\theta_l) \tag{7.1.4}$$

很多情形下，似然函数 $L(\theta_1,\theta_2,\cdots,\theta_l)$ 和对数似然函数 $\ln L(\theta_1,\theta_2,\cdots,\theta_l)$ 关于 $\theta_1,\theta_2,\cdots,\theta_l$ 的偏导数存在，这时 $\hat{\theta}_1,\hat{\theta}_2,\cdots,\hat{\theta}_l$ 常可以从方程组

$$\frac{\partial L(\theta_1,\theta_2,\cdots,\theta_l)}{\partial\theta_j}=0\quad(j=1,2,\cdots,l) \tag{7.1.5}$$

或方程组

$$\frac{\partial\ln L(\theta_1,\theta_2,\cdots,\theta_l)}{\partial\theta_j}=0\quad(j=1,2,\cdots,l) \tag{7.1.5}'$$

解得. 上述两个方程组分别称为**似然方程**和**对数似然方程**.

MATLAB 软件提供了命令 [phat,pci]=mle('dist',data,alpha) 计算不同分布中参数的最大似然估计和区间估计，其中 dist 可取为 binomial, normal, poisson, uniform, geometric, exponential 等.
也可以用“分布+fit”计算分布中参数的最大似然估计和置信区间. 如 normfit(x) 计算正态分布中参数的最大似然估计和区间估计，binofit 计算二项分布中参数的最大似然估计和区间估计等.

例 7.10 设 X 服从参数为 $\lambda(\lambda>0)$ 的泊松分布，$(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的一个样本，试求参数 λ 的最大似然估计量.

解 由于 X 的概率分布为

$$P\{X=x\}=\frac{\lambda^x}{x!}e^{-\lambda}\quad(x=0,1,2,\cdots)$$

故 λ 的似然函数为

$$L(\lambda)=\prod_{i=1}^{n}\left(\frac{\lambda^{x_i}}{x_i!}e^{-\lambda}\right)=e^{-n\lambda}\frac{\lambda^{\sum_{i=1}^{n}x_i}}{\prod_{i=1}^{n}(x_i!)}$$

对数似然函数为

$$\ln L(\lambda)=-n\lambda+\ln \lambda \sum_{i=1}^{n} x_i-\sum_{i=1}^{n} \ln(x_i!)$$

令

$$\frac{\mathrm{d}\ln L(\lambda)}{\mathrm{d}\lambda}=-n+\frac{1}{\lambda}\sum_{i=1}^{n} x_i=0$$

$\hat{\lambda}=\frac{1}{n}\sum_{i=1}^{n} x_i=\bar{x}$，又因为$\frac{\mathrm{d}^2\ln L(\lambda)}{\mathrm{d}\lambda^2}=-\frac{n\bar{x}}{\lambda^2}<0$，所以 $\ln L(\lambda)$ 在 $\hat{\lambda}=\bar{x}$ 处取得最大值，故 λ 的最大似然估计值为

$$\hat{\lambda}=\frac{1}{n}\sum_{i=1}^{n} x_i=\bar{x}$$

由此得 λ 的最大似然估计量为

$$\hat{\lambda}=\frac{1}{n}\sum_{i=1}^{n} X_i=\bar{X}$$

这一估计量与矩估计量是相同的.

例 7.11　设 $X\sim N(\mu,\sigma^2)$，其中参数 μ,σ^2 未知，试求 μ,σ^2 的最大似然估计量.

解　设 $(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的一个样本，参数 μ,σ^2 的似然函数为

$$L(\mu,\sigma^2)=\prod_{i=1}^{n}\frac{1}{\sqrt{2\pi\sigma^2}}\mathrm{e}^{-\frac{(x_i-\mu)^2}{2\sigma^2}}$$

$$=(2\pi\sigma^2)^{-\frac{n}{2}}\mathrm{e}^{-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2}$$

对数似然函数为

$$\ln L(\mu,\sigma^2)=-\frac{n}{2}\ln(2\pi)-\frac{n}{2}\ln \sigma^2-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2$$

令

$$\begin{cases}\dfrac{\partial\ln L(\mu,\sigma^2)}{\partial\mu}=\dfrac{1}{\sigma^2}\displaystyle\sum_{i=1}^{n}(x_i-\mu)=0,\\[2ex] \dfrac{\partial\ln L(\mu,\sigma^2)}{\partial\sigma^2}=-\dfrac{n}{2\sigma^2}+\dfrac{1}{2\sigma^4}\displaystyle\sum_{i=1}^{n}(x_i-\mu)^2=0\end{cases}$$

解之，得

$$\hat{\mu}=\frac{1}{n}\sum_{i=1}^{n} x_i=\bar{x}$$

$$\hat{\sigma^2}=\frac{1}{n}\sum_{i=1}^{n}(x_i-\bar{x})^2=b_2$$

利用二阶导数容易说明 $\ln L(\mu,\sigma^2)$ 在 $(\hat{\mu},\hat{\sigma^2})$ 处取得最大值.

由此得 μ,σ^2 的最大似然估计量为

$$\hat{\mu}=\bar{X}$$

$$\hat{\sigma^2}=B_2$$

这说明正态分布中参数 μ,σ^2 的最大似然估计量分别为样本均值 $\bar{X}$ 和样本二阶中心矩 B_2，恰好与矩法得到的结果是相同的.

本例说明，有时似然函数不连续，或者对未知参数不可导，这时不能使用求解似然方程或者对数似然方程的方法.此时需用定义式(7.1.3)求解参数.

例 7.12 设总体 X 在 $[0,\theta]$ 上服从均匀分布，参数 $\theta(\theta>0)$ 未知，$(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的一个样本，试求参数 θ 的最大似然估计量.

解 由于 X 的概率密度为

$$f(x,\theta)=\begin{cases}\dfrac{1}{\theta}, & 0\leqslant x\leqslant\theta,\\ 0, & \text{其他}\end{cases}$$

所以，样本 $(X_1,X_2,\cdots,X_n)$ 的联合概率密度为

$$\prod_{i=1}^{n}f(x_i;\theta)=\begin{cases}\dfrac{1}{\theta^n}, & 0\leqslant x_1,x_2,\cdots,x_n\leqslant\theta,\\ 0, & \text{其他}\end{cases}$$

即 θ 的似然函数(将 θ 看作变量，$x_1,x_2,\cdots,x_n$ 为已知)为

$$L(\theta)=\begin{cases}\dfrac{1}{\theta^n}, & \theta\geqslant\max\{x_1,x_2,\cdots,x_n\},\\ 0, & \text{其他}\end{cases}$$

容易看出当 $\theta=\max\{x_1,x_2,\cdots,x_n\}$ 时，$L(\theta)$ 取得最大值，故 θ 的最大似然估计量为

$$\hat{\theta}=\max\{X_1,X_2,\cdots,X_n\}$$

比较此例与例 7.2 知，用矩估计法和最大似然估计法所求的估计量不同.

例 7.13 设总体 X 服从柯西分布 $C(\theta,1)$，即具有概率密度

$$f(x;\theta)=\frac{1}{\pi[1+(x-\theta)^2]}\quad(-\infty<x<+\infty)$$

θ 为未知参数，$(X_1,X_2,\cdots,X_n)$ 是来自 X 的样本，求 θ 的最大似然估计量.

解 θ 的似然函数为

$$L(\theta)=\prod_{i=1}^{n}\frac{1}{\pi[1+(x_i-\theta)^2]}=\pi^{-n}\prod_{i=1}^{n}[1+(x_i-\theta)^2]^{-1}$$

对数似然函数为

$$\ln L(\theta)=-n\ln\pi-\sum_{i=1}^{n}\ln[1+(x_i-\theta)^2]$$

对数似然方程为

$$\sum_{i=1}^{n}\frac{x_i-\theta}{1+(x_i-\theta)^2}=0$$

这方程的解 $\hat{\theta}$ 不能用简单的解析式表达，只能求得数值解.

到此为止，我们介绍了参数点估计的两种常用方法：矩估计法和最大似然估计法.这两种方法各有特点，矩估计法可以不知道总体的分布类型，它的理论基础是大数定律，所以，一般要求样本容量 n 比较大，矩估计法只能估计与矩有关的参数；而最大似然估计法则必须知道总体分布的类型，它可以估计除与矩有关以外的更复杂的参数，由于最大似然估计法充分利用了总体分布类型的信息，因而它有许多优良性质.

3. 特殊方法

在参数估计中，求估计量时除了用某些一般性方法（如矩估计法，最大似然估计法等）外，有时针对不同的问题也可采用一些特殊的方法.这些方法多数是出于某种直观考虑，当然也不排除有理论分析.下面通过两个例子来说明.

例 7.14　设总体 X 具有对称分布，参数 θ 为其对称中心，$(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的样本，则可用样本中位数 $M_{\frac{1}{2}}$ 作为 θ 的估计量，即 $\hat{\theta}=M_{\frac{1}{2}}$.

如正态分布 $N(\mu,\sigma^2)$ 是对称分布，μ 是其对称中心，因此，可用样本中位数 $M_{\frac{1}{2}}$ 估计 μ，即 $\hat{\mu}=M_{\frac{1}{2}}$.

又如 $[0,\theta]$ 上的均匀分布是对称分布，其对称中心为 $\frac{\theta}{2}$，可用样本中位数 $M_{\frac{1}{2}}$ 估计，从而得 $\hat{\theta}=2M_{\frac{1}{2}}$.

特别，如例 7.13 中的柯西分布 $C(\theta,1)$，前已看到，用最大似然估计法估计 θ，似然方程不好解，而此分布数学期望又不存在，因此又不能用矩估计法估计 θ，但注意到此分布关于 θ 对称，故可用样本中位数估计 θ，即 $\hat{\theta}=M_{\frac{1}{2}}$.

例 7.15　设总体 X 的方差存在，$\sigma=\sqrt{D(X)}$ 是其标准差，$(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的样本，$R=X_{(n)}-X_{(1)}$ 是样本极差，则可通过 R 来构造 σ 的估计量.

这种方法的直观想法有两个方面：一方面是由于 σ 反映总体取值的分散程度，R 反映样本值的分散程度，所以，可以考虑通过 R 估计 σ；另一方面，虽然样本标准差 S 也反映样本值的分散程度，且比样本极差 R 更能充分利用样本提供的信息，但是 R 比 S 的计算要简单得多，所以，在精度要求不太高的情况下，可以考虑通过 R 估计 σ.

特别地，对于正态总体 $N(\mu,\sigma^2)$，有估计式

$$\hat{\sigma}=C_nR \tag{7.1.6}$$

其中比例系数按表 7.1 取值.

表 7.1　比例系数 C_n 的值

n	2	3	4	5	6	7	8	9	10
C_n	0.886 2	0.590 8	0.485 7	0.429 9	0.394 6	0.369 8	0.351 2	0.336 7	0.324 9

当 $n\leqslant 10$ 时，采用(7.1.6)式估计效果比较好.当 $n>10$ 时，这个估计效果迅速下降，这时，可把样本中数据随机地分为 k 个小组，每组只有少数几个数据，对第 i 组求出极差 R_i，用 R_i 作为(7.1.6)式中的 R 求出 $\hat{\sigma}_i=C_{n_i}R_i$，这里 n_i 是第 i 组数据的个数，然后取 $\hat{\sigma}_i(i=1,2,\cdots,k)$ 的平均值作为 σ 的估计，即 $\hat{\sigma}=\frac{1}{k}\sum_{i=1}^{k}\hat{\sigma}_i=\frac{1}{k}\sum_{i=1}^{k}C_{n_i}R_i$. 一般分组时，可等分为 k 组.

例如，从维尼纶厂 20 天正常生产中，随机地抽样得 20 个纤度（表示纤维粗细程度的一个量）数值，等分成四组，每组 5 个数据，如表 7.2 所示.

表 7.2 纤度分组数据

组号	数值					极差 r_i
	x_1	x_2	x_3	x_4	x_5	
1	1.36	1.49	1.43	1.41	1.37	0.13
2	1.40	1.32	1.42	1.47	1.39	0.15
3	1.41	1.36	1.40	1.34	1.42	0.08
4	1.42	1.45	1.35	1.42	1.39	0.10

从经验知,正常生产中纤度服从正态分布 $N(\mu,\sigma^2)$.现在要估计 σ,用样本极差估计有

$$\hat{\sigma}=\frac{1}{4}\sum_{i=1}^{4}C_5 r_i=C_5\bar{r}$$

$$=0.429\ 9\times\frac{1}{4}(0.13+0.15+0.08+0.10)=0.049$$

若用样本标准差 S 估计,则有

$$\hat{\sigma}=s=0.043$$

可见两种估计法所得估计值很接近.

7.2 估计量的评选标准

对于总体的同一个参数 θ,可以用不同的方法构造出不同的估计量.例如,从上节的例 7.2 和例 7.12 看到,对同一个未知参数 θ 的矩估计量是 $2\bar{X}$,最大似然估计量是 $\max\{X_1,X_2,\cdots,X_n\}$.很显然,对一个未知参数,原则上任何统计量都可作为它的估计量.这就产生了一个问题:对同一个参数究竟采用哪一个估计量好呢?要比较好坏,就涉及用什么标准来评价的问题.下面介绍几个常用的标准.

7.2.1 无偏性

估计量是随机变量,对于不同的样本值就会得到不同的估计值.这样,我们要确定一个估计量的好坏,不能仅仅依据某次抽样的结果来衡量,而必须由多次抽样的结果来衡量.一个自然而基本的衡量标准是要求估计量无系统偏差,也就是说,尽管在一次抽样中得到的估计值不一定恰好等于待估计的参数真值,但在大量重复抽样(样本容量相同)时,所得到的估计值平均起来应与待估计的参数真值相同,这就是所谓的无偏性的要求.这个直观上的要求,用概率语言描述就是下面的定义.

定义 7.2 设 $(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的一个样本,θ 是包含在 X 的分布中的未知参数,θ 的取值范围为 Θ,$\hat{\theta}=\hat{\theta}(X_1,X_2,\cdots,X_n)$ 是 θ 的一个估计量.若对任意 $\theta\in\Theta$ 有

$$E(\hat{\theta})=\theta \tag{7.2.1}$$

则称 $\hat{\theta}$ 是 θ 的一个**无偏估计量**.

一个估计量如果不是无偏的就称它是**有偏估计量**,并且称 $E(\hat{\theta})-\theta$ 为估计量 $\hat{\theta}$ 的**偏差**或简称为**偏**.

若 $E(\hat{\theta})-\theta\neq 0$,但当样本容量 $n\to\infty$ 时,有

$$\lim_{n\to\infty}[E(\hat{\theta})-\theta]=0 \tag{7.2.2}$$

则称 $\hat{\theta}$ 为 θ 的**渐近无偏估计量**.

例 7.16 设 $(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的样本.无论 X 服从什么分布,都有

(1) 若总体均值 $E(X)=\mu$ 存在,则样本均值 $\bar{X}$ 是总体均值 μ 的无偏估计量;

(2) 若总体方差 $D(X)=\sigma^2$ 存在,则样本方差 S^2 是总体方差 σ^2 的无偏估计量;

(3) 若总体 k 阶矩 $E(X^k)=\alpha_k(k=1,2,\cdots)$ 存在,则 k 阶样本原点矩 $A_k=\dfrac{1}{n}\sum\limits_{i=1}^{n}X_i^k$ 是 k 阶总体原点矩 α_k 的无偏估计量.

此例中的结论可以分别由定理 6.1—6.3 得到.

例 7.17 设总体 X 在 $[0,\theta]$ 上服从均匀分布,参数 $\theta>0$,$(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的样本.试证 $2\bar{X}$ 和 $\dfrac{n+1}{n}\max\{X_1,X_2,\cdots,X_n\}$ 都是 θ 的无偏估计量.

证 因为 $E(2\bar{X})=2E(\bar{X})=2E(X)=2\times\dfrac{\theta}{2}=\theta$,所以 $2\bar{X}$ 是 θ 的无偏估计量.由(3.4.7)式可知 $X_{(n)}=\max\{X_1,X_2,\cdots,X_n\}$ 的概率密度为

$$f(x)=\begin{cases}\dfrac{nx^{n-1}}{\theta^n}, & 0\leqslant x\leqslant\theta,\\ 0, & \text{其他}\end{cases}$$

所以

$$E(X_{(n)})=\int_0^{\theta}\frac{nx^n}{\theta^n}\mathrm{d}x=\frac{n}{n+1}\theta$$

从而得 $E\left(\dfrac{n+1}{n}X_{(n)}\right)=\theta$,故 $\dfrac{n+1}{n}\max\{X_1,X_2,\cdots,X_n\}$ 亦是 θ 的无偏估计量.

例 7.18 设总体 X 的均值 $E(X)=\mu$,方差 $D(X)=\sigma^2$ 都存在,且 $\sigma^2>0$,$(X_1,X_2,\cdots,X_n)$ 是来自 X 的样本.试证明 $\bar{X}^2$ 是 μ^2 的渐近无偏估计量,$B_2=\dfrac{1}{n}\sum\limits_{i=1}^{n}(X_i-\bar{X})^2$ 是 σ^2 的渐近无偏估计量.

证 因为 $E(\bar{X}^2)=D(\bar{X})+[E(\bar{X})]^2=\dfrac{\sigma^2}{n}+\mu^2$,所以,$\bar{X}^2$ 是 μ^2 的有偏估计量,其偏为 $E(\bar{X}^2)-\mu^2=\dfrac{\sigma^2}{n}$,当 $n\to\infty$ 时,$\dfrac{\sigma^2}{n}\to 0$,因此 $\bar{X}^2$ 是 μ^2 的渐近无偏估计量.由例 7.16 知样本方差 S^2 是 σ^2 的无偏估计量,而 $B_2=\dfrac{n-1}{n}S^2$,所以,$E(B_2)=\dfrac{n-1}{n}E(S^2)=\dfrac{n-1}{n}\sigma^2$,即

B_2 是 σ^2 的有偏估计量，其偏为 $E(B_2)-\sigma^2=-\dfrac{\sigma^2}{n}$，故 B_2 是 σ^2 的渐近无偏估计量.

例 7.19 设 $(X_1,X_2,\cdots,X_n)$ 是来自正态总体 $N(\mu,\sigma^2)$ 的样本，试求 σ 的无偏估计量.

解 由定理 6.7 知，$\dfrac{n-1}{\sigma^2}S^2\sim\chi^2(n-1)$，因此

$$E\left(\frac{\sqrt{n-1}S}{\sigma}\right)=\int_0^{+\infty}\sqrt{x}\,\frac{1}{2^{\frac{n-1}{2}}\Gamma\left(\frac{n-1}{2}\right)}\mathrm{e}^{-\frac{x}{2}}x^{\frac{n-1}{2}-1}\mathrm{d}x$$

$$=\frac{1}{2^{\frac{n-1}{2}}\Gamma\left(\frac{n-1}{2}\right)}\int_0^{+\infty}x^{\frac{n}{2}-1}\mathrm{e}^{-\frac{x}{2}}\mathrm{d}x$$

$$=\frac{\sqrt{2}\Gamma\left(\frac{n}{2}\right)}{\Gamma\left(\frac{n-1}{2}\right)}\qquad(\text{利用}\chi^2(n)\text{的概率密度})$$

从而得

$$E(S)=\sqrt{\frac{2}{n-1}}\frac{\Gamma\left(\frac{n}{2}\right)}{\Gamma\left(\frac{n-1}{2}\right)}\sigma$$

故，S 不是 σ 的无偏估计，而 $\sqrt{\dfrac{n-1}{2}}\dfrac{\Gamma\left(\dfrac{n-1}{2}\right)}{\Gamma\left(\dfrac{n}{2}\right)}S$ 是 σ 的无偏估计量.

该例子表明，若 $\hat{\theta}$ 是 θ 的无偏估计量，一般情况下，$g(\hat{\theta})$ 不是 $g(\theta)$ 的无偏估计量，除非 $g(\cdot)$ 是线性函数. 这也就是说无偏估计量不具有不变性. 读者可以用斯特林公式证明：S 是 σ 的渐近无偏估计量.

7.2.2 有效性

在很多情况下，无偏估计量不是唯一的，那么就存在着一个从中挑选的问题. 自然，衡量一个参数的两个无偏估计量何者更好的标准，应该看它们谁的取值更集中，即方差更小，这就是下面的有效性概念.

定义 7.3 设 $(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的样本，θ 是 X 的分布中包含的待估参数，$\hat{\theta}=\hat{\theta}(X_1,X_2,\cdots,X_n)$ 和 $\hat{\theta}^*=\hat{\theta}^*(X_1,X_2,\cdots,X_n)$ 都是 θ 的无偏估计量，若

$$D(\hat{\theta})\leqslant D(\hat{\theta}^*)\text{，即 }E[(\hat{\theta}-\theta)^2]\leqslant E[(\hat{\theta}^*-\theta)^2]\tag{7.2.3}$$

则称 $\hat{\theta}$ 较 $\hat{\theta}^*$ **有效**.

例 7.20（续例 7.17） 在例 7.17 中证明了估计量 $\hat{\theta}_1=2\overline{X}$ 和 $\hat{\theta}_2=\dfrac{n+1}{n}\max\{X_1,X_2,\cdots,X_n\}$ 都是 θ 的无偏估计量. 现证明当 $n\geqslant 2$ 时，$\hat{\theta}_2$ 比 $\hat{\theta}_1$ 有效.

证 因为

$$D(\hat{\theta}_1)=4D(\bar{X})=\frac{4}{n}D(X)=\frac{\theta^2}{3n}$$

$$D(\hat{\theta}_2)=D\left(\frac{n+1}{n}X_{(n)}\right)=\left(\frac{n+1}{n}\right)^2D(X_{(n)})$$

而

$$E(X_{(n)})=\frac{n}{n+1}\theta$$

$$E(X_{(n)}^2)=\int_0^\theta\frac{nx^{n+1}}{\theta^n}\mathrm{d}x=\frac{n}{n+2}\theta^2$$

$$D(X_{(n)})=E(X_{(n)}^2)-[E(X_{(n)})]^2=\frac{n}{(n+2)(n+1)^2}\theta^2$$

所以

$$D(\hat{\theta}_2)=\frac{\theta^2}{n(n+2)}$$

又 $n\geqslant 2$,所以 $D(\hat{\theta}_2)<D(\hat{\theta}_1)$,故 $\hat{\theta}_2$ 比 $\hat{\theta}_1$ 有效.

例 7.21 设总体 X 的均值 $E(X)=\mu$ 和方差 $D(X)=\sigma^2$ 存在,$(X_1,X_2,\cdots,X_n)$ 是来自 X 的样本,试证样本均值 $\bar{X}$ 在 μ 的所有线性无偏估计量中是最有效的(所谓线性估计是指估计量是样本的线性函数).

证 由例 7.16 知 $\bar{X}$ 是 μ 的无偏估计量,且 $D(\bar{X})=\frac{\sigma^2}{n}$.设 $X^*=\sum\limits_{i=1}^{n}a_iX_i$ 是 μ 的任一个线性无偏估计量,那么

$$\mu=E(X^*)=\sum_{i=1}^{n}a_iE(X_i)=\mu\sum_{i=1}^{n}a_i$$

所以

$$\sum_{i=1}^{n}a_i=1$$

又

$$D(X^*)=\sum_{i=1}^{n}a_i^2D(X_i)=\sigma^2\sum_{i=1}^{n}a_i^2$$

由柯西-施瓦茨不等式,有

$$\sum_{i=1}^{n}a_i^2\geqslant\frac{1}{n}\left(\sum_{i=1}^{n}|a_i|\right)^2\geqslant\frac{1}{n}\left(\sum_{i=1}^{n}a_i\right)^2=\frac{1}{n}$$

因此

$$D(X^*)\geqslant\frac{\sigma^2}{n}=D(\bar{X})$$

故 $\bar{X}$ 在 μ 的线性无偏估计量中是方差最小的,即最有效的.

从有效性的定义 7.3 可知,要比较 θ 的两个无偏估计量谁更有效,就是看谁的方差更小.按照这个标准,很自然地要问:在 θ 的所有无偏估计量(要求二阶矩存在)中,是否有一个估计量,它的方差最小?如果这样的估计量存在,那么在有效性标准下,

这样的估计量应当最好，我们称这样的估计量为 θ 的**最小方差无偏估计(量)**.判断一个参数的最小方差无偏估计是否存在，以及求最小方差无偏估计要用到数理统计较深的理论，本书不做介绍.例 7.21 证明了样本均值 $\bar{X}$ 在总体均值 μ 的所有线性无偏估计量中是方差最小的.我们称它为 μ 的**最小方差线性无偏估计(量)**.

7.2.3 相合性

前面介绍的无偏性和有效性，都是在样本容量 n 固定的情况下讨论的.我们自然还希望当样本容量 n 无限增大时，估计量能在某种意义下越来越接近被估计的参数的真值，这就是所谓的相合性要求.下面我们介绍相合性的概念.

从统计角度看，相合性是对估计量的最基本要求，它要求当样本容量无限增加时，用估计量估计参数可以达到任意小的精度.试想一下，如果一个参数的估计量没有相合性，也就是说无论样本容量 n 取多大，估计量都不能任意接近参数真值，这样的估计量可用吗?

定义 7.4 设 $\hat{\theta}=\hat{\theta}(X_1,X_2,\cdots,X_n)$ 是参数 θ 的估计量，如果当 $n\to\infty$ 时，$\hat{\theta}$ 依概率收敛于 θ，即对任意 $\varepsilon>0$，有

$$\lim_{n\to\infty}P\{|\hat{\theta}-\theta|<\varepsilon\}=1 \tag{7.2.4}$$

则称 $\hat{\theta}$ 为 θ 的**相合估计(量)**或**一致估计(量)**，并记 $(p)\lim\limits_{n\to\infty}\hat{\theta}=\theta$ 或 $\hat{\theta}\xrightarrow{P}\theta(n\to\infty)$.

如果，当 $n\to\infty$ 时，$\hat{\theta}$ 均方收敛于 θ，即

$$\lim_{n\to\infty}E[(\hat{\theta}-\theta)^2]=0 \tag{7.2.5}$$

则称 $\hat{\theta}$ 为 θ 的**均方相合估计(量)**，并记 $(\text{m. s.})\lim\limits_{n\to\infty}\hat{\theta}=\theta$ 或 $\hat{\theta}\xrightarrow{L^2}\theta(n\to\infty)$.

例 7.22 设总体 X 的 $2m$ 阶矩存在，$(X_1,X_2,\cdots,X_n)$ 是来自该总体的样本，试证明样本 k 阶原点矩 A_k 作为总体 k 阶原点矩 $\alpha_k(1\leqslant k\leqslant m)$ 的估计量，既是相合估计量，又是均方相合估计量.

证 由定理 6.3 知，A_k 是 α_k 的相合估计量.因为 X 的 $2m$ 阶矩存在，所以，$D(X^k)$ 存在，且

$$E(A_k)=\frac{1}{n}\sum_{i=1}^{n}E(X_i^k)=E(X^k)=\alpha_k$$

$$D(A_k)=\frac{1}{n^2}\sum_{i=1}^{n}D(X_i^k)=\frac{1}{n}D(X^k)$$

$$\lim_{n\to\infty}E[(A_k-\alpha_k)^2]=\lim_{n\to\infty}D(A_k)=\lim_{n\to\infty}\frac{D(X^k)}{n}=0$$

因此，A_k 是 α_k 的均方相合估计量.

可以证明：常见的矩估计量都具有相合性.

作为此例的一个特例：当总体 X 的方差存在时，样本均值 $\bar{X}$ 是总体均值 $E(X)$ 的相合估计量及均方相合估计量.

关于相合估计量，我们指出如下事实(读者可自己证明)：

(1) 若 $\hat{\theta}$ 是 θ 的相合估计量，常数列 $\{a_n\}$ 和 $\{b_n\}$ 满足 $\lim\limits_{n\to\infty}a_n=a$，$\lim\limits_{n\to\infty}b_n=b$，则 $a_n\hat{\theta}+b_n$ 是 $a\theta+b$ 的相合估计量；

(2) 若 $\hat{\theta}$ 是 θ 的相合估计量，函数 $g(t)$ 在 θ 处连续，则 $g(\hat{\theta})$ 是 $g(\theta)$ 的相合估计量；

理论探究：相合但不均方相合的估计量

(3) 如果 $\hat{\theta}_1,\hat{\theta}_2,\cdots,\hat{\theta}_k$ 分别是 $\theta_1,\theta_2,\cdots,\theta_k$ 的相合估计量，函数 $g(t_1,t_2,\cdots,t_k)$ 在 $(\theta_1,\theta_2,\cdots,\theta_k)$ 处连续，则 $g(\hat{\theta}_1,\hat{\theta}_2,\cdots,\hat{\theta}_k)$ 是 $g(\theta_1,\theta_2,\cdots,\theta_k)$ 的相合估计量；

(4) 如果 $\hat{\theta}$ 是 θ 的均方相合估计量，则 $\hat{\theta}$ 也是 θ 的相合估计量，反之不真.

例 7.23 如果总体 X 的四阶矩存在，则样本方差 S^2 和样本二阶中心矩 B_2 都是总体方差 σ^2 的相合估计量，S 和 $\sqrt{B_2}$ 都是总体标准差 σ 的相合估计量.

证 由定理 6.2 知 S^2 是 σ^2 的相合估计量，由例 7.22 的结论知 B_2 也是 σ^2 的相合估计量. 又因为 $g(t)=\sqrt{t}$ 在 $t>0$ 是连续的，所以，由上述事实(2)，S 和 $\sqrt{B_2}$ 都是 σ 的相合估计量.

在结束本节之前我们证明下列重要事实.

例 7.24 设总体 X 的分布函数为 $F(x)$，$(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的样本，$F_n(x)=\dfrac{1}{n}\sum\limits_{i=1}^{n}I_{\{X_i\leqslant x\}}(x)$ 是经验分布函数，试证明：对任意固定的 x，

(1) $F_n(x)$ 是 $F(x)$ 的无偏估计量；

(2) $F_n(x)$ 是 $F(x)$ 的相合估计量；

(3) $F_n(x)$ 是 $F(x)$ 的均方相合估计量.

证 令 $Y=I_{\{X\leqslant x\}}(x)$，$Y_i=I_{\{X_i\leqslant x\}}(x)$，$i=1,2,\cdots,n$，则 $Y_1,Y_2,\cdots,Y_n$ 相互独立，且都与 Y 有相同的分布

$$P\{Y=0\}=1-F(x),\quad P\{Y=1\}=F(x),$$

所以，$Y_1,Y_2,\cdots,Y_n$ 可看成是来自总体 Y 的样本，而

$$E(Y)=F(x),D(Y)=F(x)[1-F(x)]$$

$$F_n(x)=\frac{1}{n}\sum_{i=1}^{n}Y_i=\overline{Y}$$

故，由例 7.16 和例 7.22 的结论可得本例的全部结论.

此例说明经验分布函数是总体分布函数的很好的估计.

7.3 区间估计

7.3.1 双侧区间估计

前两节我们讨论了参数的点估计. 在那里，我们先确定了一个估计量 $\hat{\theta}(X_1,X_2,\cdots,X_n)$，当抽样得到样本值 $(x_1,x_2,\cdots,x_n)$ 后，用数值 $\hat{\theta}(x_1,x_2,\cdots,x_n)$ 作为参数 θ 的估计值. 在实际中，我们有时需要由样本值给出未知参数 θ 的一个估计范围，并且知道这个范围包含参数 θ 真值的可信程度，这种范围往往表现为一个区间，即所谓的**置信区间**，这种形式的估计称为**区间估计**.

定义 7.5 设 $(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的一个样本，θ 是包含在总体分布中的一个未知参数，对于给定值 $\alpha(0<\alpha<1)$，若统计量 $\hat{\theta}_1(X_1,X_2,\cdots,X_n)$ 和 $\hat{\theta}_2(X_1,X_2,\cdots,X_n)$ 满足

区间估计理论是美国统计学家奈曼在1934年的一篇论文中首次提出的.奈曼在概率论公理化体系下建立了严格的区间估计理论.区间估计不仅给出了参数的可能取值范围,而且考虑了可能出现的误差,是一种很常用的参数估计方法.

$$P\{\hat{\theta}_1(X_1,X_2,\cdots,X_n)<\theta<\hat{\theta}_2(X_1,X_2,\cdots,X_n)\}=1-\alpha \tag{7.3.1}$$

则称随机区间$(\hat{\theta}_1,\hat{\theta}_2)$为参数$\theta$的置信度为$1-\alpha$的**双侧置信区间**,$\hat{\theta}_1$和$\hat{\theta}_2$分别称为**置信下限**和**置信上限**,$1-\alpha$称为**置信度**.

注意:被估计的参数θ虽然未知,但它是一个常数,没有随机性,而区间$(\hat{\theta}_1,\hat{\theta}_2)$则是随机的,因此(7.3.1)式的本质是随机区间$(\hat{\theta}_1,\hat{\theta}_2)$以$1-\alpha$的概率包含着参数$\theta$的真值,而不能说参数$\theta$以$1-\alpha$的概率落入随机区间$(\hat{\theta}_1,\hat{\theta}_2)$.

给(7.3.1)式以频率解释如下:若重复抽样多次(各次的样本容量都是n),每次抽样得到的样本值都对应一个确定的区间$(\hat{\theta}_1,\hat{\theta}_2)$,每个这样的区间要么包含$\theta$的真值,要么不包含$\theta$的真值.按伯努利大数定律,当抽样次数充分大时,在这些区间中包含θ真值的频率接近于置信度(即概率)$1-\alpha$,即在这些区间中大约有$100(1-\alpha)\%$个区间包含θ真值,$100\alpha\%$个区间不包含θ真值.例如,若$\alpha=0.05$,重复抽样100次,得到的100个区间中大约有95个包含θ真值.

一般可以从点估计量出发来构造置信区间.下面通过例子来说明此方法.

例7.25 设总体X在$[0,\theta]$上服从均匀分布,$\theta>0$未知,$(X_1,X_2,\cdots,X_n)$是来自总体X的样本,给定α,求θ的置信度为$1-\alpha$的置信区间.

记$X_{(n)}=\max\{X_1,X_2,\cdots,X_n\}$,由例7.17知$\dfrac{n+1}{n}X_{(n)}$是$\theta$的无偏估计量,我们设想$\theta$的置信区间能通过$X_{(n)}$表示出来.$X_{(n)}$具有概率密度

$$f(x)=\begin{cases}\dfrac{nx^{n-1}}{\theta^n}, & 0\leqslant x\leqslant\theta,\\ 0, & \text{其他}\end{cases}$$

容易求得包含待估参数θ的随机变量$Z=X_{(n)}/\theta$的概率密度为

$$g(z)=\begin{cases}nz^{n-1}, & 0\leqslant z\leqslant 1,\\ 0, & \text{其他}\end{cases} \tag{7.3.2}$$

这分布不含有任何未知参数.于是,对给定的α,可找到常数$a,b(0<a<b\leqslant 1)$满足条件

$$P\left\{a<\frac{X_{(n)}}{\theta}<b\right\}=1-\alpha \tag{7.3.3}$$

即

$$1-\alpha=\int_a^b nz^{n-1}\mathrm{d}z=b^n-a^n \tag{7.3.4}$$

将(7.3.3)式改写成

$$P\left\{\frac{X_{(n)}}{b}<\theta<\frac{X_{(n)}}{a}\right\}=1-\alpha$$

于是$\left(\dfrac{X_{(n)}}{b},\dfrac{X_{(n)}}{a}\right)$就是$\theta$的置信度为$1-\alpha$的置信区间.

注意:置信度为$1-\alpha$的置信区间并不是唯一的,一则满足(7.3.3)式的a,b有很

多;二则也可以设想不从 $X_{(n)}$ 出发而从别的统计量出发构造 θ 的置信度为 $1-\alpha$ 的置信区间.这样就产生了在许多具有同一置信度的置信区间中应该选择哪一个(即最好)的问题.评价一个置信区间的优劣有两个要素,一是其**置信度**,即它包含待估参数真值的概率 $1-\alpha$ 有多大,当然越接近 1 越好;二是其**精度**,衡量精度的一个明显指标是它的长度(当置信区间长度 $\hat{\theta}_2-\hat{\theta}_1$ 为随机变量时则用它的平均长度,即 $E(\hat{\theta}_2-\hat{\theta}_1)$)越小越好.在样本容量固定的情况下,这二者是矛盾的.若把置信度提得极高,则置信区间的长度就会很大,如果大得过分了,那么区间估计就失去了意义;反之,如果把区间限制得很小,那么置信度 $1-\alpha$ 就会变小,置信区间不包含待估参数的概率就会增大.为了解决这一对矛盾,在区间估计问题中,一般采用这样的办法:事先给定置信度 $1-\alpha$,以保证有一定的可信度,在这个前提下,尽量选择精度更高(即长度更短)的置信区间.

在上面的例子中,不难证明,满足(7.3.3)式的置信区间 $\left(\dfrac{X_{(n)}}{b},\dfrac{X_{(n)}}{a}\right)$ 中长度最短的区间是

$$(X_{(n)},\alpha^{-\frac{1}{n}}X_{(n)}) \tag{7.3.5}$$

其平均长度为

$$L_n=E(\alpha^{-\frac{1}{n}}X_{(n)}-X_{(n)})=(\alpha^{-\frac{1}{n}}-1)\frac{n}{n+1}\theta$$

且当 $n\to\infty$ 时 $L_n\to 0$.这表明:在给定置信度 $1-\alpha$ 的前提下,要提高区间估计的精度,就需要增加样本容量 n.这个结论对于一般的区间估计也是适用的.

通过例 7.25 可以看到,求未知参数 θ 的双侧置信区间的具体做法如下:

经常从未知参数的点估计量(如最大似然估计量)出发寻找枢轴量.

(1) 寻求一个样本 $(X_1,X_2,\cdots,X_n)$ 的函数 $Z=Z(X_1,X_2,\cdots X_n,\theta)$,它包含待估计的参数 θ,但不含其他任何未知参数,求出 Z 的分布,并且此分布不依赖于任何未知参数,当然也不依赖于待估参数 θ.一般称具有这种性质的 Z 为枢轴量.在例 7.25 中 $Z=X_{(n)}/\theta$ 就是一个枢轴量.

(2) 对于给定的置信度 $1-\alpha$,定出两个常数 k_1,k_2 使 $P\{k_1<Z<k_2\}=1-\alpha$.

(3) 把不等式 $k_1<Z<k_2$ 改写成 $\hat{\theta}_1<\theta<\hat{\theta}_2$ 的形状,其中 $\hat{\theta}_1=\hat{\theta}_1(X_1,X_2,\cdots,X_n)$,$\hat{\theta}_2=\hat{\theta}_2(X_1,X_2,\cdots,X_n)$ 都是统计量,那么 $(\hat{\theta}_1,\hat{\theta}_2)$ 就是 θ 的一个置信度为 $1-\alpha$ 的置信区间.

(4) 根据一次具体抽样所得的样本值 $(x_1,x_2,\cdots,x_n)$ 计算出(3)中的统计量 $\hat{\theta}_1$,$\hat{\theta}_2$ 的观测值 $\hat{\theta}_1=\hat{\theta}_1(x_1,x_2,\cdots,x_n)$,$\hat{\theta}_2=\hat{\theta}_2(x_1,x_2,\cdots,x_n)$,就得到一个具体的区间 $(\hat{\theta}_1,\hat{\theta}_2)$.这个区间已不是随机区间了,但我们仍称它为置信度为 $1-\alpha$ 的置信区间.

例 7.26　设某工件的长度 X 服从正态分布 $N(\mu,16)$,今抽 9 件测量其长度,得数据如下(单位:mm):142,138,150,165,156,148,132,135,160.试求参数 μ 的置信度为 0.95 的置信区间.

解　因为 $\bar{X}$ 是 μ 的无偏估计量,由定理 6.7 知,$U=\dfrac{\bar{X}-\mu}{\sigma/\sqrt{n}}\sim N(0,1)$,所以 U 可以

用来作为枢轴量.

对于概率密度图形是单峰且关于纵轴对称的情况，如标准正态分布、t 分布，易证取 k_1 和 k_2 关于原点对称时，能使置信区间的平均长度最短.

对于给定的 $1-\alpha=0.95$，即 $\alpha=0.05$，找 k_1,k_2 使得

$$P\{k_1<U<k_2\}=1-\alpha$$

这样的 k_1,k_2 有许多，实用上常取 $k_1=-u_{\alpha/2},k_2=u_{\alpha/2}$，则有

$$P\{-u_{\alpha/2}<U<u_{\alpha/2}\}=1-\alpha$$

即

$$P\left\{\bar{X}-\frac{\sigma}{\sqrt{n}}u_{\alpha/2}<\mu<\bar{X}+\frac{\sigma}{\sqrt{n}}u_{\alpha/2}\right\}=1-\alpha$$

于是得 μ 的置信度为 $1-\alpha$ 的置信区间

$$\left(\bar{X}-\frac{\sigma}{\sqrt{n}}u_{\alpha/2},\bar{X}+\frac{\sigma}{\sqrt{n}}u_{\alpha/2}\right)$$

本例中，$n=9,\sigma=4,\alpha=0.05,u_{0.025}=1.96,\bar{x}=147.333$，从而，$\mu$ 的置信度为 0.95 的置信区间是(144.720,149.946).

上述两列中所依据的分布(7.3.2)式和 $N(0,1)$ 都是确切的分布，因此，作出的置信区间，其置信度也是确切的.有时，确切的分布无法找到或过于复杂不便应用，可以考虑使用其近似分布，一般当样本容量较大时可使用其极限分布，但这时所得到的置信区间，其置信度也是近似的.这样得到的置信区间称为大样本置信区间.

例 7.27 设总体 X 服从(0-1)分布 $B(1,p)$，$0<p<1$ 是未知参数，$(X_1,X_2,\cdots,X_n)$ 是来自该总体的一个样本，试求 p 的置信度为 $1-\alpha$ 的置信区间.

解 已知 $E(X)=p,D(X)=p(1-p)$，记

$$U=\frac{\sum_{i=1}^{n}X_i-np}{\sqrt{np(1-p)}}=\frac{\sqrt{n}(\bar{X}-p)}{\sqrt{p(1-p)}}$$

则 U 的分布仍与 p 有关，所以，直接按上述两例的方法来处理是行不通的.但由中心极限定理，当 n 充分大时，U 近似地服从 $N(0,1)$ 分布，因此，当 n 充分大时近似地有

$$P\{|U|<u_{\alpha/2}\}\approx 1-\alpha$$

即

$$P\left\{-u_{\alpha/2}<\frac{\sqrt{n}(\bar{X}-p)}{\sqrt{p(1-p)}}<u_{\alpha/2}\right\}\approx 1-\alpha$$

而不等式

$$-u_{\alpha/2}<\frac{\sqrt{n}(\bar{X}-p)}{\sqrt{p(1-p)}}<u_{\alpha/2}$$

等价于不等式

$$ap^2-bp+c<0$$

此处 $a=n+u_{\alpha/2}^2,b=2n\bar{X}+u_{\alpha/2}^2,c=n\bar{X}^2$，解此不等式得

$$\hat{p}_1<p<\hat{p}_2$$

这里 $\hat{p}_1=\frac{1}{2a}(b-\sqrt{b^2-4ac})$，$\hat{p}_2=\frac{1}{2a}(b+\sqrt{b^2-4ac})$，于是$(\hat{p}_1,\hat{p}_2)$可作为 p 的置信区间，其置信度近似地为 $1-\alpha$.

7.3.2 单侧区间估计

上面的讨论中，对于未知参数 θ，我们定出两个统计量 $\hat{\theta}_1,\hat{\theta}_2$，得到 θ 的双侧置信区间$(\hat{\theta}_1,\hat{\theta}_2)$.在有些实际问题中，人们关心的只是 θ 在一个方向的界限.例如，对于设备、元件的寿命来说，我们常常关心的是平均寿命 θ 的“下界”是多少？在考虑产品的废品率时，我们关心它的“上界”是多少？等等.这也是一种区间估计.若用 $\overline{\theta}$ 作为 θ 的上界估计，则等于说估计 θ 在区间$(-\infty,\overline{\theta})$内；同样，若用 $\underline{\theta}$ 作为 θ 的下界估计，则等于说估计 θ 在区间$(\underline{\theta},+\infty)$内.这就引出了单侧区间估计的概念.

定义 7.6 设$(X_1,X_2,\cdots,X_n)$是来自总体 X 的一个样本，θ 是包含在 X 分布中的一个未知参数，对于给定值 $\alpha(0<\alpha<1)$，若统计量 $\underline{\theta}=\underline{\theta}(X_1,X_2,\cdots,X_n)$满足

$$P\{\underline{\theta}(X_1,X_2,\cdots,X_n)<\theta\}=1-\alpha$$

则称随机区间$(\underline{\theta},+\infty)$是 θ 的置信度为 $1-\alpha$ 的**单侧置信区间**，$\underline{\theta}$ 称为 θ 的置信度为 $1-\alpha$ 的**单侧置信下限**或**置信下界**；又若统计量 $\overline{\theta}=\overline{\theta}(X_1,X_2,\cdots,X_n)$满足

$$P\{\theta<\overline{\theta}(X_1,X_2,\cdots,X_n)\}=1-\alpha$$

则称随机区间$(-\infty,\overline{\theta})$是 θ 的置信度为 $1-\alpha$ 的**单侧置信区间**，$\overline{\theta}$ 称为 θ 的置信度为 $1-\alpha$ 的**单侧置信上限**或**置信上界**.

对于单侧区间估计问题的讨论，完全平行于双侧区间估计问题的讨论，只是应该注意：对于精度的标准不能像双侧区间那样，用置信区间的长度来刻画.此时，对于给定的置信度 $1-\alpha$，选择置信下界 $\underline{\theta}$ 时，应该使 $E(\underline{\theta})$越大越好；选择置信上界 $\overline{\theta}$ 时，应该使 $E(\overline{\theta})$越小越好.

例 7.28（续例 7.25） 分别求 θ 的置信度为 $1-\alpha$ 的置信下界和置信上界.

解 对于给定的 α，找 $0<c\leqslant 1$ 使

$$P\{X_{(n)}/\theta<c\}=1-\alpha$$

即

$$1-\alpha=\int_0^c nz^{n-1}\mathrm{d}z=c^n$$

从而得 $c=\sqrt[n]{1-\alpha}$，因此

$$P\{(1-\alpha)^{-\frac{1}{n}}X_{(n)}<\theta\}=1-\alpha$$

于是 θ 的置信度为 $1-\alpha$ 的置信下界为

$$\underline{\theta}=(1-\alpha)^{-\frac{1}{n}}X_{(n)}$$

对于给定的 α，找 $0<d<1$ 使

$$P\{X_{(n)}/\theta>d\}=1-\alpha$$

即

$$1-\alpha=\int_d^1 nz^{n-1}\mathrm{d}z=1-d^n$$

从而得 $d=\alpha^{\frac{1}{n}}$，所以

$$P\{\theta<\alpha^{-\frac{1}{n}}X_{(n)}\}=1-\alpha$$

于是 θ 的置信度为 $1-\alpha$ 的置信上界为

$$\overline{\theta}=\alpha^{-\frac{1}{n}}X_{(n)}$$

若取 $\alpha=0.05$，$n=15$，$x_{(15)}=2.5$，则分别得到 θ 的置信度为 0.95 的置信下界 $\underline{\theta}=2.509$ 和置信上界 $\overline{\theta}=3.053$.

7.4 正态总体参数的区间估计

正态分布是实际应用中碰到最多的分布之一.本节利用上节介绍的区间估计方法，寻求正态总体参数的置信区间.我们只求双侧置信区间，相应的单侧置信区间可类似得到，由读者自己完成.

7.4.1 单个总体 $N(\mu,\sigma^2)$ 的情形

以下讨论中，总假设已给定置信度 $1-\alpha$，并设 $(X_1,X_2,\cdots,X_n)$ 为来自总体 $N(\mu,\sigma^2)$ 的样本，$\overline{X}$，S^2 分别是样本均值和样本方差.

1. 均值 μ 的置信区间

分别就方差 σ^2 已知和未知来讨论.

(1) 方差 σ^2 已知.由例 7.26 知

$$U=\frac{\sqrt{n}(\overline{X}-\mu)}{\sigma}\sim N(0,1) \tag{7.4.1}$$

因此取 U 作为枢轴量.由标准正态分布表可查得 $u_{\alpha/2}$，使

$$P\{|U|<u_{\alpha/2}\}=1-\alpha$$

即

$$P\left\{\overline{X}-\frac{\sigma}{\sqrt{n}}u_{\alpha/2}<\mu<\overline{X}+\frac{\sigma}{\sqrt{n}}u_{\alpha/2}\right\}=1-\alpha$$

于是得 μ 的置信度为 $1-\alpha$ 的双侧置信区间

$$\left(\overline{X}-\frac{\sigma}{\sqrt{n}}u_{\alpha/2},\overline{X}+\frac{\sigma}{\sqrt{n}}u_{\alpha/2}\right) \tag{7.4.2}$$

例 7.29 包糖机某日开工包了 12 包糖，称得重量(单位：g)分别为 506，500，495，488，504，486，505，513，521，520，512，485.假设重量服从正态分布，且标准差为 $\sigma=10$.试由此数据求糖包的平均重量 μ 的置信度为 $1-\alpha$ 置信区间(分别取 $\alpha=0.10$ 和 $\alpha=0.05$).

解 $\sigma=10$，$n=12$，经计算得 $\overline{x}=502.92$，

当取 $\alpha=0.10$ 时，查标准正态分布表得 $u_{0.05}=1.65$，从而

$$\bar{x}-\frac{\sigma}{\sqrt{n}}u_{\alpha/2}=502.92-\frac{10}{\sqrt{12}}\times 1.65=498.16$$

$$\bar{x}+\frac{\sigma}{\sqrt{n}}u_{\alpha/2}=502.92+\frac{10}{\sqrt{12}}\times 1.65=507.68$$

即,μ 的置信度为 90%的置信区间为(498.16,507.68).

当取 $\alpha=0.05$ 时,查标准正态分布表得 $u_{0.025}=1.96$,同理可求得 μ 的置信度为 0.95 的置信区间为(497.26,508.58).

从此例看到,当置信度 $1-\alpha$ 较大时,置信区间也较大;当置信度 $1-\alpha$ 较小时,置信区间也较小.

(2) 方差 σ^2 未知.实际中经常遇到的是方差 σ^2 未知的情况.此时,不能使用(7.4.2)式给出的区间,因其中含有未知参数 σ.由于 S^2 是 σ^2 的无偏估计量,一个很自然的想法是利用 S 代替(7.4.1)式中的 σ,由定理 6.8 知

$$T=\frac{\sqrt{n}(\bar{X}-\mu)}{S}\sim t(n-1) \tag{7.4.3}$$

因此取 T 作为枢轴量.由 t 分布表可查得 $t_{\alpha/2}(n-1)$,使

$$P\{|T|<t_{\alpha/2}(n-1)\}=1-\alpha$$

即

$$P\left\{\bar{X}-\frac{S}{\sqrt{n}}t_{\alpha/2}(n-1)<\mu<\bar{X}+\frac{S}{\sqrt{n}}t_{\alpha/2}(n-1)\right\}=1-\alpha$$

于是得 μ 的置信度为 $1-\alpha$ 的置信区间

$$\left(\bar{X}-\frac{S}{\sqrt{n}}t_{\alpha/2}(n-1),\bar{X}+\frac{S}{\sqrt{n}}t_{\alpha/2}(n-1)\right) \tag{7.4.4}$$

例 7.30 某电子产品的某一质量指标 X 服从正态分布 $N(\mu,\sigma^2)$.从某日生产的产品中随机抽取 15 个产品,测得其质量指标值为 3.0,2.7,2.9,2.8,3.1,2.6,2.5,2.8,2.4,2.9,2.7,2.6,3.2,3.0,2.8.试求该日产品质量指标的总体均值 μ 的置信度为 0.95 的置信区间.

解 此时 σ 未知,$n=15$,经计算得 $\bar{x}=2.8$,$s=0.22$,而 $\alpha=0.05$,查 $t(n-1)$ 分布表可得 $t_{0.025}(14)=2.1448$,从而

$$\frac{S}{\sqrt{n}}t_{\alpha/2}(n-1)=\frac{0.22}{\sqrt{15}}\times 2.1448=0.12$$

即得 μ 的置信度为 0.95 的置信区间为(2.68,2.92).

2. 方差 σ^2 的置信区间

我们只讨论 μ 未知的情形,μ 已知的情形由读者自己讨论.由定理 6.7 知

$$\chi^2=\frac{1}{\sigma^2}\sum_{i=1}^{n}(X_i-\bar{X})^2=\frac{(n-1)S^2}{\sigma^2}\sim\chi^2(n-1) \tag{7.4.5}$$

因此取 χ^2 作为枢轴量.选取常数 a,b,且 $0<a<b$ 使

$$P\{a<\chi^2<b\}=1-\alpha$$

这样的 a,b 有许多,一般习惯上取 a,b 满足

若枢轴量 Z 的概率密度图形是单峰但不对称的,如 χ^2 分布、F 分布,则要选择 a,b 使置信区间的平均长度最短比较困难.为了处理方便,一般习惯上按"等尾概率"取 a,b,即 $P\{Z\leqslant a\}=P\{Z\geqslant b\}=\frac{\alpha}{2}$.这样得到的置信区间称为等尾置信区间.

$$P\{\chi^2 \leqslant a\} = P\{\chi^2 \geqslant b\} = \frac{\alpha}{2}$$

查 χ^2 分布表可得

$$a = \chi^2_{1-\alpha/2}(n-1), \quad b = \chi^2_{\alpha/2}(n-1)$$

于是得

$$P\{\chi^2_{1-\alpha/2}(n-1) < \chi^2 < \chi^2_{\alpha/2}(n-1)\} = 1-\alpha$$

即

$$P\left\{\frac{(n-1)S^2}{\chi^2_{\alpha/2}(n-1)} < \sigma^2 < \frac{(n-1)S^2}{\chi^2_{1-\alpha/2}(n-1)}\right\} = 1-\alpha$$

从而得 σ^2 的置信度为 $1-\alpha$ 的置信区间为

$$\left(\frac{(n-1)S^2}{\chi^2_{\alpha/2}(n-1)}, \frac{(n-1)S^2}{\chi^2_{1-\alpha/2}(n-1)}\right) \tag{7.4.6}$$

由此也可得到标准差 σ 的置信度为 $1-\alpha$ 的置信区间

$$\left(S\sqrt{\frac{n-1}{\chi^2_{\alpha/2}(n-1)}}, S\sqrt{\frac{n-1}{\chi^2_{1-\alpha/2}(n-1)}}\right) \tag{7.4.7}$$

在具体计算时，因为 $(n-1)S^2 = \sum_{i=1}^{n}(X_i - \bar{X})^2$，所以(7.4.6)式和(7.4.7)式可直接写成

$$\left(\frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{\chi^2_{\alpha/2}(n-1)}, \frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{\chi^2_{1-\alpha/2}(n-1)}\right) \tag{7.4.6}'$$

和

$$\left(\sqrt{\frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{\chi^2_{\alpha/2}(n-1)}}, \sqrt{\frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{\chi^2_{1-\alpha/2}(n-1)}}\right) \tag{7.4.7}'$$

例 7.31(续例 7.30) 试求例 7.30 中该日产品质量指标的总体方差 σ^2 和总体标准差 σ 的置信度为 0.95 的置信区间.

解 $n=15, \alpha=0.05, \bar{x}=2.8, \sum_{i=1}^{15}(x_i - \bar{x})^2 = 0.7$，查 χ^2 分布表可得 $\chi^2_{0.025}(14) = 26.119$，$\chi^2_{0.975}(14) = 5.629$. 由(7.4.6)′式计算得 σ^2 的置信度为 0.95 的置信区间为(0.03,0.12)，由(7.4.7)′式计算得 σ 的置信度为 0.95 的置信区间为(0.17,0.35).

7.4.2 两个总体 $N(\mu_1, \sigma_1^2)$ 与 $N(\mu_2, \sigma_2^2)$ 的情形

在实际中常遇到下面的问题：已知产品的某一质量指标服从正态分布，但由于原料、设备条件、操作人员不同，或工艺过程的改变等因素，引起总体均值、总体方差有所改变，我们需要知道这些变化有多大.这就需要考虑两个正态总体均值差或方差比的估计问题.

在以下讨论中，设已给定置信度 $1-\alpha$，并设 $(X_1, X_2, \cdots, X_{n_1})$ 是来自第一个总体 $N(\mu_1, \sigma_1^2)$ 的样本，$(Y_1, Y_2, \cdots, Y_{n_2})$ 是来自第二个总体 $N(\mu_2, \sigma_2^2)$ 的样本，并且两个样

本相互独立.记 $\bar{X},\bar{Y}$ 分别为相应的样本均值,$S_{1n_1}^2,S_{2n_2}^2$ 分别为相应的样本方差.

1. 两总体均值差 $\mu_1-\mu_2$ 的置信区间

这里只讨论方差 σ_1^2 和 σ_2^2 未知的情形,σ_1^2 和 σ_2^2 已知的情形由读者自己讨论.

(1) σ_1^2 和 σ_2^2 未知,但 $\sigma_1^2=\sigma_2^2$.

在这种情况下,记 $\sigma_1^2=\sigma_2^2=\sigma^2$,由定理 6.9 知

$$T=\frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{S_W\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}}\sim t(n_1+n_2-2) \tag{7.4.8}$$

其中

$$S_W=\sqrt{\frac{(n_1-1)S_{1n_1}^2+(n_2-1)S_{2n_2}^2}{n_1+n_2-2}}$$

因此取 T 作为枢轴量.仿照(7.4.4)式的推导过程可得 $\mu_1-\mu_2$ 的一个置信度为 $1-\alpha$ 的置信区间

$$\left((\bar{X}-\bar{Y})-t_{\alpha/2}(n_1+n_2-2)S_W\sqrt{\frac{1}{n_1}+\frac{1}{n_2}},\right.$$
$$\left.(\bar{X}-\bar{Y})+t_{\alpha/2}(n_1+n_2-2)S_W\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}\right) \tag{7.4.9}$$

例 7.32 为提高某一化学生产过程的得率,试图采用一种新的催化剂.为慎重起见,在实验工厂先进行试验,设采用原来的催化剂进行 $n_1=8$ 次试验,测到得率的平均值 $\bar{x}=91.73$,样本方差 $s_{1n_1}^2=3.89$;又采用新的催化剂进行 $n_2=8$ 次试验,测到得率的平均值 $\bar{y}=93.75$,样本方差 $s_{2n_2}^2=4.02$.假定采用两种催化剂的得率都可认为服从正态分布,且方差相等,试求两种催化剂平均得率之差 $\mu_1-\mu_2$ 的置信度为 0.95 的置信区间.

解 $\alpha=0.05,n_1=n_2=8,\bar{x}=91.73,\bar{y}=93.75,s_{1n_1}^2=3.89,s_{2n_2}^2=4.02$,又 $n_1+n_2-2=14$.查 t 分布表得 $t_{0.025}(14)=2.1448$,计算得

$$s_w^2=\frac{(n_1-1)s_{1n_1}^2+(n_2-1)s_{2n_2}^2}{n_1+n_2-2}=\frac{7\times3.89+7\times4.02}{14}=3.96$$

$$(\bar{x}-\bar{y})\pm t_{0.025}(14)s_w\sqrt{\frac{1}{8}+\frac{1}{8}}=-2.02\pm2.13$$

因此,$\mu_1-\mu_2$ 的置信度为 0.95 的置信区间为(-4.15,0.11).

(2) σ_1^2 和 σ_2^2 未知,且 $\sigma_1^2\neq\sigma_2^2$.

在这种情形下,推不出(7.4.8)式,因此(7.4.9)式不能用.但是,可以证明:当 n_1,n_2 充分大时,

$$U=\frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{\sqrt{\frac{S_{1n_1}^2}{n_1}+\frac{S_{2n_2}^2}{n_2}}}\overset{\text{近似}}{\sim}N(0,1) \tag{7.4.10}$$

这里“$\overset{近似}{\sim}$”表示“近似服从”.对给定的 α,查标准正态分布表得 $u_{\alpha/2}$,使

$$P\{|U|<u_{\alpha/2}\}\approx 1-\alpha$$

即

$$P\left\{-u_{\alpha/2}<\frac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{\sqrt{\frac{1}{n_1}S_{1n_1}^2+\frac{1}{n}S_{2n_2}^2}}<u_{\alpha/2}\right\}\approx 1-\alpha$$

改写成

$$P\left\{(\bar{X}-\bar{Y})-u_{\alpha/2}\sqrt{\frac{1}{n_1}S_{1n_1}^2+\frac{1}{n_2}S_{2n_2}^2}<\mu_1-\mu_2\right.$$

$$\left.<(\bar{X}-\bar{Y})+u_{\alpha/2}\sqrt{\frac{1}{n_1}S_{1n_1}^2+\frac{1}{n_2}S_{2n_2}^2}\right\}\approx 1-\alpha$$

于是得 $\mu_1-\mu_2$ 的置信度近似为 $1-\alpha$ 的置信区间为

$$\left((\bar{X}-\bar{Y})-u_{\alpha/2}\sqrt{\frac{1}{n_1}S_{1n_1}^2+\frac{1}{n_2}S_{2n_2}^2},(\bar{X}-\bar{Y})+u_{\alpha/2}\sqrt{\frac{1}{n_1}S_{1n_1}^2+\frac{1}{n_2}S_{2n_2}^2}\right)\tag{7.4.11}$$

注:即使对任意两个总体(不假定服从正态分布),只要它们具有有限的非零方差,其均值分别为 μ_1 和 μ_2,则当 n_1,n_2 充分大时也有(7.4.10)式成立,因此(7.4.11)式适用于任何总体.

例 7.33 为了比较两种枪弹的枪口速度(单位:m/s),在相同条件下进行速度测定.算得样本平均值和样本标准差如下:

枪弹甲:$n_1=110,\bar{x}=2\ 805,s_{1n_1}=120.41$

枪弹乙:$n_2=100,\bar{y}=2\ 680,s_{2n_2}=105.00$

试求两种枪弹的枪口平均速度之差 $\mu_1-\mu_2$ 的置信度为 0.95 的置信区间.

解 此题中 n_1,n_2 都很大,可采用(7.4.11)式为置信区间.$\alpha=0.05$,查标准正态分布表得 $u_{0.025}=1.96$,从而

$$(\bar{x}-\bar{y})\pm u_{\alpha/2}\sqrt{\frac{1}{n_1}s_{1n_1}^2+\frac{1}{n_2}s_{2n_2}^2}=(2\ 805-2\ 680)\pm 1.96\sqrt{\frac{(120.41)^2}{110}+\frac{(105.00)^2}{100}}$$

$$=125\pm 30.49$$

所以,$\mu_1-\mu_2$ 的置信度为 0.95 的置信区间为(94.51,155.49).

2. 两个总体方差比 σ_1^2/σ_2^2 的置信区间

这里只讨论均值 μ_1,μ_2 未知的情形,μ_1,μ_2 已知的情形由读者自己讨论.由定理 6.10 知

$$F=\frac{\sigma_2^2S_{1n_1}^2}{\sigma_1^2S_{2n_2}^2}\sim F(n_1-1,n_2-1)\tag{7.4.12}$$

因此取 F 作为枢轴量.选取 λ_1,λ_2,且 $0<\lambda_1<\lambda_2$ 使

$$P\{\lambda_1<F<\lambda_2\}=1-\alpha$$

这样的 λ_1,λ_2 有很多.习惯上取 λ_1,λ_2 满足

$$P\{F\leqslant\lambda_1\}=P\{F\geqslant\lambda_2\}=\frac{\alpha}{2}$$

即寻找等尾置信区间.由 F 分布表可查得

$$\lambda_1=F_{1-\alpha/2}(n_1-1,n_2-1),\quad \lambda_2=F_{\alpha/2}(n_1-1,n_2-1)$$

于是得

$$P\{F_{1-\alpha/2}(n_1-1,n_2-1)<F<F_{\alpha/2}(n_1-1,n_2-1)\}=1-\alpha$$

即

$$P\left\{F_{1-\alpha/2}(n_1-1,n_2-1)<\frac{\sigma_2^2S_{1n_1}^2}{\sigma_1^2S_{2n_2}^2}<F_{\alpha/2}(n_1-1,n_2-1)\right\}=1-\alpha$$

改写成

$$P\left\{\frac{S_{1n_1}^2}{S_{2n_2}^2F_{\alpha/2}(n_1-1,n_2-1)}<\frac{\sigma_1^2}{\sigma_2^2}<\frac{S_{1n_1}^2}{S_{2n_2}^2F_{1-\alpha/2}(n_1-1,n_2-1)}\right\}=1-\alpha$$

从而得 σ_1^2/σ_2^2 的一个置信度为 $1-\alpha$ 的置信区间为

$$\left(\frac{S_{1n_1}^2}{S_{2n_2}^2F_{\alpha/2}(n_1-1,n_2-1)},\frac{S_{1n_1}^2}{S_{2n_2}^2F_{1-\alpha/2}(n_1-1,n_2-1)}\right)\tag{7.4.13}$$

还可得 σ_1/σ_2 的一个置信度为 $1-\alpha$ 的置信区间为

$$\left(\frac{S_{1n_1}}{S_{2n_2}\sqrt{F_{\alpha/2}(n_1-1,n_2-1)}},\frac{S_{1n_1}}{S_{2n_2}\sqrt{F_{1-\alpha/2}(n_1-1,n_2-1)}}\right)\tag{7.4.14}$$

例 7.34 某橡胶配方中,原用氧化锌 5 g,现减为 1 g.分别对两种配方作一批试验,测得橡胶伸长率如下:

氧化锌 5 g	540	533	525	520	545	531	541	529	534	
氧化锌 1 g	565	577	580	575	556	542	560	532	570	561

假定两种配方的伸长率都服从正态分布,求两总体标准差之比 σ_1/σ_2 的置信区间(取 $\alpha=0.05$).

解

$$n_1=9,s_{1n_1}=\sqrt{\frac{1}{n_1-1}\sum_{i=1}^{n_1}(x_i-\bar{x})^2}=7.99$$

$$n_2=10,s_{2n_2}=\sqrt{\frac{1}{n_2-1}\sum_{i=1}^{n_2}(y_i-\bar{y})^2}=15.39$$

对 $\alpha=0.05$,查 F 分布表得 $F_{0.025}(8,9)=4.10$,$F_{0.025}(9,8)=4.36$,故有

$$\frac{s_{1n_1}}{s_{2n_2}\sqrt{F_{\alpha/2}(n_1-1,n_2-1)}}=\frac{7.99}{15.39\sqrt{4.10}}=0.26$$

$$\frac{s_{1n_1}}{s_{2n_2}\sqrt{F_{1-\alpha/2}(n_1-1,n_2-1)}}=\frac{7.99\sqrt{4.36}}{15.39}=1.08$$

从而由(7.4.14)式得 σ_1/σ_2 的置信度为 0.95 的置信区间为(0.26,1.08).

正态分布参数的区间估计小结于表 7.3 及表 7.4 中.

表 7.3 正态分布参数的置信区间

待估参数	条件	所用枢轴量及分布	置信区间
均值 μ	方差 σ^2 已知	$U=\dfrac{\sqrt{n}(\bar{X}-\mu)}{\sigma}\sim N(0,1)$	$\left(\bar{X}-\dfrac{\sigma}{\sqrt{n}}u_{\alpha/2},\bar{X}+\dfrac{\sigma}{\sqrt{n}}u_{\alpha/2}\right)$
均值 μ	方差 σ^2 未知	$T=\dfrac{\sqrt{n}(\bar{X}-\mu)}{S}\sim t(n-1)$	$\left(\bar{X}-\dfrac{S}{\sqrt{n}}t_{\alpha/2}(n-1),\bar{X}+\dfrac{S}{\sqrt{n}}t_{\alpha/2}(n-1)\right)$
方差 σ^2	均值 μ 未知	$\chi^2=\dfrac{(n-1)}{\sigma^2}S^2\sim\chi^2(n-1)$	$\left(\dfrac{(n-1)S^2}{\chi^2_{\alpha/2}(n-1)},\dfrac{(n-1)S^2}{\chi^2_{1-\alpha/2}(n-1)}\right)$
均值差 $\mu_1-\mu_2$	方差 σ_1^2,σ_2^2 未知，但 $\sigma_1^2=\sigma_2^2$	$T=\dfrac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{S_W\sqrt{\dfrac{1}{n_1}+\dfrac{1}{n_2}}}\sim t(n_1+n_2-2)$	$\left((\bar{X}-\bar{Y})-t_{\alpha/2}(n_1+n_2-2)S_W\sqrt{\dfrac{1}{n_1}+\dfrac{1}{n_2}},\ (\bar{X}-\bar{Y})+t_{\alpha/2}(n_1+n_2-2)S_W\sqrt{\dfrac{1}{n_1}+\dfrac{1}{n_2}}\right)$
均值差 $\mu_1-\mu_2$	方差 σ_1^2,σ_2^2 未知，且 $\sigma_1^2\neq\sigma_2^2$，大样本	$U=\dfrac{(\bar{X}-\bar{Y})-(\mu_1-\mu_2)}{\sqrt{\dfrac{1}{n_1}S^2_{1n_1}+\dfrac{1}{n_2}S^2_{2n_2}}}\overset{\text{近似}}{\sim}N(0,1)$	$\left((\bar{X}-\bar{Y})-u_{\alpha/2}\sqrt{\dfrac{1}{n_1}S^2_{1n_1}+\dfrac{1}{n_2}S^2_{2n_2}},\ (\bar{X}-\bar{Y})+u_{\alpha/2}\sqrt{\dfrac{1}{n_1}S^2_{1n_1}+\dfrac{1}{n_2}S^2_{2n_2}}\right)$
方差比 σ_1^2/σ_2^2	均值 μ_1,μ_2 未知	$F=\dfrac{\sigma_2^2S^2_{1n_1}}{\sigma_1^2S^2_{2n_2}}\sim F(n_1-1,n_2-1)$	$\left(\dfrac{S^2_{1n_1}}{S^2_{2n_2}F_{\alpha/2}(n_1-1,n_2-1)},\dfrac{S^2_{1n_1}}{S^2_{2n_2}F_{1-\alpha/2}(n_1-1,n_2-1)}\right)$

表 7.4　正态分布参数的置信上、下限

待估参数	条件	置信上限	置信下限
均值 μ	方差 σ^2 已知	$\bar{X}+\frac{\sigma}{\sqrt{n}}u_{\alpha}$	$\bar{X}-\frac{\sigma}{\sqrt{n}}u_{\alpha}$
均值 μ	方差 σ^2 未知	$\bar{X}+\frac{S}{\sqrt{n}}t_{\alpha}(n-1)$	$\bar{X}-\frac{S}{\sqrt{n}}t_{\alpha}(n-1)$
方差 σ^2	均值 μ 未知	$\frac{(n-1)S^2}{\chi^2_{1-\alpha}(n-1)}$	$\frac{(n-1)S^2}{\chi^2_{\alpha}(n-1)}$
均值差 $\mu_1-\mu_2$	方差 σ_1^2,σ_2^2 未知，但 $\sigma_1^2=\sigma_2^2$	$\bar{X}-\bar{Y}+t_{\alpha}(n_1+n_2-2)S_W\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}$	$\bar{X}-\bar{Y}-t_{\alpha}(n_1+n_2-2)S_W\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}$
均值差 $\mu_1-\mu_2$	方差 σ_1^2,σ_2^2 未知，且 $\sigma_1^2\neq\sigma_2^2$，大样本	$\bar{X}-\bar{Y}+u_{\alpha}\sqrt{\frac{1}{n_1}S^2_{1n_1}+\frac{1}{n_2}S^2_{2n_2}}$	$\bar{X}-\bar{Y}-u_{\alpha}\sqrt{\frac{1}{n_1}S^2_{1n_1}+\frac{1}{n_2}S^2_{2n_2}}$
方差比 σ_1^2/σ_2^2	均值 μ_1,μ_2 未知	$\frac{S^2_{1n_1}}{S^2_{2n_2}F_{1-\alpha}(n_1-1,n_2-1)}$	$\frac{S^2_{1n_1}}{S^2_{2n_2}F_{\alpha}(n_1-1,n_2-1)}$

内容小结

已知总体 X 的分布函数为 $F(x;\theta)$，θ 是未知参数，$(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的样本.构造统计量 $\hat{\theta}(X_1,X_2,\cdots,X_n)$，其观测值 $\hat{\theta}(x_1,x_2,\cdots,x_n)$ 作为 θ 的估计值，称 $\hat{\theta}(X_1,X_2,\cdots,X_n)$ 为 θ 的估计量.

用样本的原点矩代替总体的原点矩，求出未知参数的估计的方法称为矩估计法，简称矩法，用矩法求出未知参数的估计量称为矩估计量.

选取使得样本出现的概率最大的值为参数的估计值，这种估计方法称为最大似然估计法，相应的估计量称为最大似然估计量.

设 $\hat{\theta}=\hat{\theta}(X_1,X_2,\cdots,X_n)$ 是参数 θ 的估计量，若 $E(\hat{\theta})=\theta$，则称 $\hat{\theta}$ 为 θ 的无偏估计量，否则称 $\hat{\theta}$ 为 θ 的有偏估计量，并称 $E(\hat{\theta})-\theta$ 为估计量 $\hat{\theta}$ 的偏差或者偏.若 $E(\hat{\theta})\neq\theta$，但 $\lim\limits_{n\to\infty}[E(\hat{\theta})-\theta]=0$，称 $\hat{\theta}$ 为 θ 的渐近无偏估计量.

若 $\hat{\theta}_1,\hat{\theta}_2$ 均为参数 θ 的无偏估计量，$D(\hat{\theta}_1)\leqslant D(\hat{\theta}_2)$，则称 $\hat{\theta}_1$ 较 $\hat{\theta}_2$ 有效.

设 $\hat{\theta}=\hat{\theta}(X_1,X_2,\cdots,X_n)$ 为参数 θ 的估计量，若对任意的 $\varepsilon>0$，有 $\lim\limits_{n\to\infty}P\{|\hat{\theta}-\theta|<\varepsilon\}=1$，则称 $\hat{\theta}$ 为 θ 的相合估计量或一致估计量.若 $\lim\limits_{n\to\infty}E[(\hat{\theta}-\theta)^2]=0$，称 $\hat{\theta}$ 为 θ 的均方相合估计量.

设总体分布中含有一个未知参数 θ，$(X_1,X_2,\cdots,X_n)$ 为来自总体的样本，对给定的 $\alpha(0<\alpha<1)$，若统计量 $\underline{\theta}(X_1,X_2,\cdots,X_n)$ 和 $\overline{\theta}(X_1,X_2,\cdots,X_n)$ 满足

$$P\{\underline{\theta}<\theta<\overline{\theta}\}=1-\alpha$$

则称区间 $(\underline{\theta},\overline{\theta})$ 为 θ 的置信度为 $1-\alpha$ 的双侧置信区间，而 $\underline{\theta}$，$\overline{\theta}$ 分别为置信下限、置信上限.

设 $(X_1,X_2,\cdots,X_n)$ 是总体 X 的样本，$\underline{\theta}=\underline{\theta}(X_1,X_2,\cdots,X_n)$ 和 $\overline{\theta}=\overline{\theta}(X_1,X_2,\cdots,X_n)$ 都是统计量.若对给定的 $\alpha(0<\alpha<1)$，有 $P\{\theta>\underline{\theta}\}=1-\alpha$ 或 $P\{\theta<\overline{\theta}\}=1-\alpha$，则区间 $(\underline{\theta},+\infty)$ 或 $(-\infty,\overline{\theta})$ 称为 θ 的置信度为 $1-\alpha$ 的单侧置信区间，而 $\underline{\theta}$ 是 θ 的单侧置信下限，$\overline{\theta}$ 是 θ 的单侧置信上限.

习题7

1. 设 $(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的样本，试求下列总体 X 的概率分布中未知参数的矩估计量：

(1) 总体 X 服从参数为 λ 的指数分布，其中 $\lambda>0$ 未知；

(2) 总体 X 具有概率密度

$$f(x)=\begin{cases}\theta x^{\theta-1}, & 0<x<1,\\ 0, & \text{其他}\end{cases}$$

其中 $\theta>0$ 未知；

（3）总体 X 具有概率密度

$$f(x)=\begin{cases}\dfrac{\beta^k}{(k-1)!}x^{k-1}\mathrm{e}^{-\beta x}, & x>0,\\ 0, & x\leqslant 0\end{cases}$$

其中 k 是已知正整数，β 未知；

（4）总体 X 具有概率密度

$$f(x)=\begin{cases}\dfrac{1}{\theta}\mathrm{e}^{-\frac{x-a}{\theta}}, & x\geqslant a,\\ 0, & x<a\end{cases}$$

其中 $\theta>0,\theta,a$ 是未知参数；

（5）总体 X 服从二项分布 $B(m,p)$，其中 m 已知，$0<p<1$，p 为未知参数；

2. 试求 1 题中各未知参数的最大似然估计量.

3. 总体 X 服从几何分布 $Ge(p)$，其中 $0<p<1$，p 为未知参数.$(X_1,X_2,\cdots,X_n)$ 是来自该总体的样本，试求 p 的最大似然估计量.

4. 随机地取 8 只活塞环，测得它们的直径为（单位：mm）：74.001，74.005，74.003，74.001，74.000，73.998，74.006，74.002.试求总体均值 μ 及方差 σ^2 的矩估计值，并求样本方差 s^2.

5. 设总体 X 在 $[a,b]$ 上服从均匀分布，现从该总体中抽得容量为 6 的样本，11.3，10.6，11.7，12.2，10.3，11.1.试求参数 a,b 的矩估计值及最大似然估计值.

6. 设总体 X 的概率密度为

$$f(x;\alpha,\beta)=\begin{cases}\beta\alpha^{\beta}x^{-\beta-1}, & x>\alpha,\\ 0, & x\leqslant\alpha\end{cases}$$

其中 $\alpha>0,\beta>1$ 为未知参数，$X_1,X_2,\cdots,X_n$ 为来自总体 X 的一个样本.

（1）当 $\alpha=1$ 时，求 β 的矩估计量；

（2）当 $\beta=2$ 时，求 α 的最大似然估计量.

7. 设总体 X 的分布律为

X	-1	0	1	2
概率	θ	$\theta/2$	$\theta/2$	$1-2\theta$

其中 $0<\theta<\dfrac{1}{2}$ 是未知参数.现从该总体中抽取样本容量为 16 的样本，对应样本值为

样本值	-1	0	1	2
频数	3	2	5	6

求 θ 的矩估计值和最大似然估计值.

8. 设总体 X 的均值 $E(X)=\mu$ 及方差 $D(X)=\sigma^2$ 存在，(X_1,X_2,X_3) 为来自总体 X 的样本，试验证下面三个估计量

$$\hat{\mu}_1=\frac{1}{3}X_1+\frac{1}{3}X_2+\frac{1}{3}X_3$$

$$\hat{\mu}_2=\frac{1}{5}X_1+\frac{2}{5}X_2+\frac{2}{5}X_3$$

$$\hat{\mu}_3=\frac{1}{6}X_1+\frac{1}{3}X_2+\frac{1}{2}X_3$$

都是 μ 的无偏估计量，并判断 $\hat{\mu}_1,\hat{\mu}_2,\hat{\mu}_3$ 作为 μ 的估计量，哪一个最有效.

9. 设 $(X_1,X_2,\cdots,X_n)$ 是来自总体 $N(\mu,\sigma^2)$ 的样本，试选择适当的常数 C，使 $C\sum_{i=1}^{n-1}(X_{i+1}-X_i)^2$ 为 σ^2 的无偏估计量.

10. 设总体 X 服从参数为 λ 的泊松分布 $P(\lambda)$，$(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的样本，试验证：对任何值 $\alpha\in[0,1]$，$\alpha\bar{X}+(1-\alpha)S^2$ 都是 λ 的无偏估计量.

11. 设总体 X 服从两点分布 $B(1,p)$ $(0<p<1)$.

(1) 若 X_1 是来自 X 的样本，试证：p^2 不存在无偏估计量.

(2) 若 $(X_1,X_2,\cdots,X_n)$ $(n\geqslant 2)$ 是来自 X 的样本，试求 p^2 的一个无偏估计量.

12. 设总体 X 在 $[0,\theta]$ 上服从均匀分布，$(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的样本，试证 $2\bar{X}$ 和 $X_{(n)}$ 都是 θ 的相合估计量和均方相合估计量.

13. 设 $(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的样本，θ 是 X 的分布中包含的未知参数，$\hat{\theta}=\hat{\theta}(X_1,X_2,\cdots,X_n)$ 是 θ 的一个渐近无偏估计量，且 $\lim\limits_{n\to\infty}D(\hat{\theta})=0$，试证明：$\hat{\theta}$ 是 θ 的相合估计量和均方相合估计量.

14. 设某种元件的寿命服从参数为 $\lambda>0$ 的指数分布，抽其 12 只进行寿命试验，试验结果为(单位：h)：

20	640	1 750	50	1 110	1 660
640	2 410	890	970	1 520	750

试求：

(1) 参数 λ 和元件的平均寿命 μ 的置信度为 0.9 的置信区间；

(2) 元件平均寿命 μ 的置信度为 0.9 的置信下限及置信上限.

15. 在 105 次射击中，有 60 次命中目标，试求命中率的置信度为 0.95 的置信区间.

16. 设总体 X 服从泊松分布.参数 $\lambda>0$ 未知，$(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的样本，试在 n 充分大的条件下，求参数 λ 的置信度近似为 $1-\alpha$ 的置信区间.

17. 对于方差 σ^2 已知的正态总体来说，问需要取容量 n 为多大的样本，才能使总体均值 μ 的置信度为 $1-\alpha$ 的置信区间长度不大于 L?

18. 某车间生产的螺杆直径服从正态分布 $N(\mu,\sigma^2)$，今随机地从中抽取 5 支测得直径为(单位：mm)

22.3	21.5	20.0	21.8	21.4

(1) 当 $\sigma=0.3$ 时，求 μ 的置信度为 0.95 的置信区间；

(2) 当 σ 未知时，求 μ 的置信度为 0.95 的置信区间；

(3) 当 σ 未知时，求 μ 的置信度为 0.95 的置信上限和置信下限.

19. 为了了解一台测量长度的仪器的精度，对一根长为 30 mm 的标准金属棒进行 6 次重复测量，测得结果如下(单位：mm)

30.1	29.9	29.8	30.3	30.2	29.6

假定测量值服从正态分布 $N(\mu,\sigma^2)$，

(1) 若仪器无系统偏差，即 $\mu=30$，求 σ^2 的置信度为 0.95 的置信区间；

(2) 若 μ 未知，求 σ^2 的置信度为 0.95 的置信区间.

20. 冷拔铜丝的折断力服从正态分布，从一批铜丝中任取 10 根试验折断力，得数据为：573，572，568，577，570，572，596，584，582，570，求标准差 σ 的置信度为 0.95 的置信区间和置信下限.

21. 设总体 $X\sim N(0,\sigma^2)$，$x_1,x_2,\cdots,x_{10}$ 为来自总体 X 的一组样本的观测值，样本方差 $s^2=2$. 分别求 σ^2 和 $D\left(\frac{X^2}{\sigma^3}\right)$ 的置信度为 0.95 的置信区间.

22. 设 $(X_1,X_2,\cdots,X_{n_1})$ 和 $(Y_1,Y_2,\cdots,Y_{n_2})$ 是分别来自正态总体 $N(\mu_1,\sigma_1^2)$ 和 $N(\mu_2,\sigma_2^2)$ 的独立样本，在 σ_1^2 和 σ_2^2 都已知的情形下，求两总体均值差 $\mu_1-\mu_2$ 的置信度为 $1-\alpha$ 的置信区间、置信上限和置信下限.

23. 随机地从甲批导线中抽取 4 根，从乙批导线中抽取 5 根，测得其电阻（单位：Ω）为：

甲批导线：0.143　0.142　0.143　0.137

乙批导线：0.140　0.142　0.136　0.138　0.140

设测试数据分别服从正态分布 $N(\mu_1,\sigma^2)$ 和 $N(\mu_2,\sigma^2)$，试求 $\mu_1-\mu_2$ 的置信度为 0.95 的置信区间.

24. 从某地区随机地选取男、女各 100 名，以估计男、女平均身高之差，测量并计算得男子身高的样本均值为 1.71 m，样本标准差为 0.035 m，女子身高的样本均值为 1.67 m，样本标准差为 0.038 m，试求男、女身高平均值之差的置信度为 0.95 的置信区间.

25. 设 $(X_1,X_2,\cdots,X_{n_1})$ 和 $(Y_1,Y_2,\cdots,Y_{n_2})$ 是分别来自正态总体 $N(\mu_1,\sigma_1^2)$ 和 $N(\mu_2,\sigma_2^2)$ 的独立样本，在 μ_1 和 μ_2 都已知的情形，求方差比 σ_1^2/σ_2^2 的置信度为 $1-\alpha$ 的置信区间、置信下限和置信上限.

26. 设两位化验员 A 和 B 独立地用相同的方法对某种聚合物含氯量各做 10 次测定，其测定值的样本方差分别为 $s_A^2=0.541\ 9$，$s_B^2=0.606\ 5$，设 σ_A^2 和 σ_B^2 分别为 A 和 B 所测定的测定值总体的方差，总体均服从正态分布，求方差比 σ_A^2/σ_B^2 的置信度为 0.95 的置信区间、置信下限和置信上限.

27. 设 $X_1,X_2,\cdots,X_n$ 和 $Y_1,Y_2,\cdots,Y_n$ 分别是来自于正态总体 $N(\mu_1,25)$ 和 $N(\mu_2,25)$ 的两个独立简单样本，为使 $\mu_1-\mu_2$ 的置信度为 0.9 的置信区间长度不超过 2，问样本容量 n 应取多大？

自测题 7

习题 7 参考答案

第8章 假设检验

经常碰到以下问题：如何检验一批产品是否合格？经常假设学生成绩服从正态分布，这个假设是否合理？对某生产线改进新工艺，这个改进是否有效？如何判断？同一单位中的男女职员是否同工同酬等.为了解决这一类问题，我们需要抽取样本，通过计算对所提的问题给予肯定或否定的回答，这就是本章要讲的假设检验.假设检验是数理统计学中另一类重要的统计推断问题.

拓展阅读：从女士品茶说起——假设检验的原理与发展

8.1 假设检验的基本概念

假设检验是指对总体提出某项假设，然后利用从总体中抽样所得的样本值来检验所提的假设是否正确.检验的结果：若认为该假设正确，则称**接受**该假设；否则，称**拒绝**该假设.实际中，对总体所提的假设一般有两类：一类是对总体分布中的某个未知参数或总体的某个数字特征提出假设.例如，假设总体 X 的均值 $E(X)$ 为已知数 μ_0.又如，已知总体 X 服从指数分布，假设总体分布中的参数 λ 为已知数 λ_0.这类假设称为**参数假设**.用样本值检验这类假设称为**参数假设检验**或简称**参数检验**.另一类是对总体分布提出假设.例如，假设总体 X 服从正态分布.又如，假设总体 X 的分布函数为已知分布函数 $F_0(x)$.这类假设称为**分布假设**.用样本值检验这类假设称为**分布假设检验**.

8.1.1 假设检验的基本原理

如何利用样本值对一个具体的假设进行检验，一般借助于直观分析和理论分析相结合的做法，其基本原理就是人们在实际问题中经常采用的所谓**实际推断原理**："一个小概率事件在一次试验中几乎是不可能发生的".下面我们结合具体例子来说明在假设检验中如何运用这一基本原理.

例 8.1 某洗衣粉厂用自动包装机包装洗衣粉，每袋标准重量为 500 g.长期实践表明，袋装重量（单位：g）服从正态分布，且标准差 σ 为 2 g 比较稳定.某日，为了检验包装机是否正常，在装好的袋中随机地抽取 7 袋，称得净重为 501.8，502.4，499，500.3，504.5，498.2，505.6，问机器是否正常？

经计算，X 的观测值 $\bar{x}=501.685\,7$，与总体均值 500 之间有差异.如何看待这个差异？这个差异是机器不正常引起的，还是由偶然性引起的呢？我们用一个量来界定.对于正数 $\delta>0$，若 $|\bar{x}-\mu|<\delta$，则认为是随机性差异，若 $|\bar{x}-\mu|\geqslant\delta$，则认为不是随机性差异.而这个数 δ 的选取需要用到概率论的知识.

在这个问题中，按题意袋装重量 X 是一个正态总体 $N(\mu,\sigma^2)$，由于标准差比较稳定，我们可认为 $\sigma^2=4$ 已知，因此要看机器是否正常，就是要看每袋平均重量是否为 500 g.为此，我们提出假设每袋平均重量是 500 g，用 H_0 表示此项假设，

$$\text{假设 } H_0:\mu=500$$

现在用抽得的样本值检验假设 H_0 是否成立.若检验的结果是接受假设 H_0，则认为机器正常；若检验的结果是拒绝假设 H_0，则认为机器不正常.

要用样本判断假设 H_0 是否成立，首先要构造一个适用于检验假设 H_0 的统计量，称为**检验统计量**.由于现在要检验的假设涉及总体的均值 μ，自然想到可借助样本均值 $\bar{X}$ 这一统计量，对此，我们构造统计量

$$U=\frac{\bar{X}-500}{\frac{2}{\sqrt{7}}}=\frac{\sqrt{7}(\bar{X}-500)}{2}$$

从直观上分析，我们知道 $\bar{X}$ 是 μ 的无偏估计量，$\bar{X}$ 的观测值 $\bar{x}$ 的大小在一定程度上反映了 μ 的大小，因此，若假设 H_0 为真，则统计量 U 的观测值的绝对值 $|u|$ 应在 $E(U)=0$ 附近，一般 $|u|$ 不应太大.若过分地大，则我们就怀疑假设 H_0 的正确性而拒绝 H_0.基于这样的想法，我们可适当选定一个常数 k，得检验法：在一次抽样后，如果 $|u|\geqslant k$，就拒绝 H_0；反之，如果 $|u|<k$，就接受 H_0.在本例中，如果取 $k=1.96$，因为 $u=2.23$，$|u|>1.96$，所以拒绝 H_0，即认为机器不正常.

从理论上分析，当假设 H_0 为真时，总体 X 服从正态分布 $N(500,4)$，因而 U 服从标准正态分布 $N(0,1)$，由标准正态分布表可知 $P\{|U|\geqslant 1.96\}=0.05$，这表明事件 $\{|U|\geqslant 1.96\}$ 是一个小概率事件，在一次抽样中发生的概率仅有 0.05，根据实际推断原理，事件 $\{|U|\geqslant 1.96\}$ 在一次抽样中不大可能发生.如果在一次抽样中，所得样本值使 $|u|\geqslant 1.96$，说明在一次抽样中事件 $\{|U|\geqslant 1.96\}$ 竟然发生了，这与实际推断原理相矛盾，这就使我们对最初的假设 H_0 表示怀疑而拒绝 H_0；相反，如果抽到的样本值使 $|u|<1.96$，说明在一次抽样中小概率事件 $\{|U|\geqslant 1.96\}$ 没有发生，这与实际推断原理是一致的，在这种情况下没有理由拒绝原来的假设 H_0，而应该接受 H_0.这样就得检验法：在一次抽样后，如果 $|u|\geqslant 1.96$，则拒绝 H_0；如果 $|u|<1.96$，则接受 H_0.这与上面的直观分析是一致的.

从上面的理论分析可见，要给出检验假设 H_0 的一个检验法，主要是在 H_0 成立的前提下，作出一个适当的小概率事件，例如上面把概率为 0.05 的事件 $\{|U|\geqslant 1.96\}$ 作为小概率事件，然后按实际推断原理，在一次具体的抽样后，如果这个小概率事件发生了，就拒绝 H_0，如果这个小概率事件没有发生，就接受 H_0.那么，概率小到什么程度的事件才算是小概率事件呢？通常是根据实际问题事先给定一个值 α（一般给定 α 为 0.05，0.01，0.1 等值），当事件的概率不超过 α 时，就认为是一个小概率事件.显然，α 值给的越小，小概率事件在一次抽样中越不容易发生，也就越不容易拒绝假设 H_0，因此，α 越小，拒绝假设 H_0 就越有说服力，或者说样本值提供了不利于假设 H_0 的显著证据.

需要指出，假设检验的方法是建立在实际推断原理的基础上的，但是仅利用它是不够的，还应该与直观一致.例如在上面的例子中，当 H_0 成立时，由标准正态分布表可知 $P\{|U|\leqslant 0.06\}=0.05$，此式表明，$H_0$ 成立时，$\{|U|\leqslant 0.06\}$ 是一个小概率事件，如果对此小概率事件运用实际推断原理，获得如下检验法：在一次抽样后，若 $|u|\leqslant 0.06$，则拒绝假设 H_0，即认为机器不正常；若 $|u|>0.06$，则接受 H_0，即认为机器正常.显然，这与上面的直观分析相矛盾，所以，此种检验法是不可取的.

8.1.2 两类错误

在检验假设 H_0 时，如果得到检验法：当所采用的检验统计量的观测值落在集合 W 时，拒绝 H_0，当检验统计量的观测值落在集合 $\bar{W}$ 时，接受 H_0，则称 W 和 $\bar{W}$ 分别为 H_0 的**拒绝域**和**接受域**.显然 W 和 $\bar{W}$ 是两个不相交的集合，并且 W 和 $\bar{W}$ 的并集就是检验统计量的所有可能取值的集合.拒绝域和接受域的分界点称为**临界值**.例如，在例 8.1 中，拒绝域为 $W=\{u\mid |u|\geqslant 1.96\}$，接受域为 $\bar{W}=\{u\mid |u|<1.96\}$，临界值为

$k_1=-1.96$ 和 $k_2=1.96$. W 可简记为 $|u|\geqslant 1.96$.

由于检验假设 H_0 时，是根据一次抽样后所得的样本值求得的检验统计量的观测值，看它是否落在拒绝域 W 中而作出拒绝或接受 H_0 的决定，而样本带有随机性，因此，可能会发生所做决定与真实情况不符而产生错误.错误有两类：一类是 H_0 为真但被拒绝了，称这类错误为**第Ⅰ类错误**；另一类是 H_0 不真但被接受了，称这类错误为**第Ⅱ类错误**.

犯第Ⅰ类错误的概率记为 $P\{\text{拒绝 } H_0 \mid H_0 \text{ 为真}\}=\alpha$，前面我们看到了，$\alpha$ 的大小反映了我们拒绝 H_0 的说服力，所以称 α 为检验的**显著性水平**，简称为**水平**，它是根据实际问题事先给定的，用来控制犯第Ⅰ类错误的.例 8.1 中给定了水平为 $\alpha=0.05$. 犯第Ⅱ类错误的概率记为 $P\{\text{接受 } H_0 \mid H_0 \text{ 不真}\}=\beta$，这个概率的计算通常是很复杂的，我们不做过多的探讨.

是否犯某一类错误，犯错误的可能性（即概率）大小取决于参数的真值和所用的检验方法及所得到的样本值.参数的真值是未知的，样本的取值是随机的，我们所能做的只是适当地选择检验法，使少犯某一类错误.实际中，我们不可能要求一个检验方法永远不会出错，但可以要求尽可能使犯错误的概率小一些.为此，在确定检验法时，我们应尽可能使犯两类错误的概率都较小.但是，由进一步讨论可知，一般说来，当样本容量固定时，若减少犯某一类错误的概率，则犯另一类错误的概率往往增大.若要使犯两类错误的概率都减小除非增加样本容量.在固定样本容量的情况下，我们通常是控制犯第Ⅰ类错误的概率，使它不超过某个给定的值 α，这种对犯第Ⅰ类错误的概率加以控制而不考虑犯第Ⅱ类错误的检验问题，称为**显著性检验**问题.若一个检验法犯第Ⅰ类错误的概率不超过 α，即 $P\{\text{拒绝 } H_0 \mid H_0 \text{ 为真}\}\leqslant\alpha$，则称这个检验法为**显著性水平为 α 的检验法**.

显然，对同一个检验问题可以构造出许多不同的检验法，那么如何评价这些不同的检验法呢？什么是最好的检验法呢？通常是这样理解的：对给定的水平 α，首先要求检验法是水平 α 的检验法，再在所有水平为 α 的检验法中，选取犯第Ⅱ类错误的概率 β 最小的检验法为最好的检验法.关于评价检验法的标准，以及在某一标准下求最好的检验法等问题是假设检验理论中比较深刻的问题，超出了本书的范围.

8.1.3 假设检验的一般步骤

在假设检验问题中，我们把要检验的假设 H_0 称为**原假设**或**零假设**.把原假设的对立面称为**对立假设**或**备择假设**，记为 H_1.如例 8.1 中原假设为 $H_0:\mu=500$，对立假设为 $H_1:\mu\neq 500$.这样，我们通常把例 8.1 的检验问题叙述成：在显著性水平 α 下检验假设

$$H_0:\mu=500,\quad H_1:\mu\neq 500$$

也常说成“在显著性水平 α 下，针对 H_1 检验 H_0”.

通常对于一个需要用假设检验方法处理的实用问题，首先要明确问题的性质，明确基本前提是什么？它包括分布类型是否已知，若类型已知则分布中包含哪些未知参数，等等.基本前提是考虑问题的出发点，必须先肯定下来.在明确了基本前提之后，假设检验一般可按如下步骤进行：

(1) 充分考虑和利用已知的背景知识提出原假设 H_0 及备择假设 H_1.

(2) 确定检验统计量 Z,并在 H_0 成立的前提下导出 Z 的概率分布,要求 Z 的分布不依赖于任何未知参数.

(3) 确定拒绝域.即依据直观分析先确定拒绝域的形式,然后根据给定的水平 α 和 Z 的分布,由 $P\{\text{拒绝 } H_0 \mid H_0 \text{ 为真}\}=\alpha$ 确定拒绝域的临界值,从而确定拒绝域.

(4) 作一次具体的抽样,根据得到的样本值和上面确定的拒绝域对 H_0 作出拒绝或接受的判断.

拓展阅读:原假设与备择假设的选取问题

在结束之前,作几点说明:

(1) 在假设检验中,"接受 H_0"和"拒绝 H_0"这种用语,只是反映当事者在所面对的样本值证据之下,对假设 H_0 所采取的一种态度、倾向性,以至某种必须或自愿采取的行动,而不是在逻辑上"证明"了该假设正确或不正确.

(2) 在显著性假设检验问题中,由于我们控制的是犯第 Ⅰ 类错误的概率,因此,原假设 H_0 与备择假设 H_1 的地位不是对等的,它们不能随意交换.实际问题中如何确定 H_0 和 H_1 是很重要的.一般情况下,H_0 要取那个在实践中应该受到保护的论断,这个论断不应轻易受到否定,若要否定它,则必须有足够的理由.

(3) 参数的假设检验与区间估计有着密切联系.请读者注意总结它们的联系与区别.

8.1.4 p 值

前面的假设检验是先定出拒绝域和接受域的临界值,确定拒绝域,然后判断检验统计量的观测值是否落入拒绝域中,判断拒绝或接受原假设.这个检验法也称为临界值检验法.然而在很多统计软件中,假设检验的结果通常以 p 值的方式输出.下面以例 8.1 来解释 p 值的含义.

选取检验统计量 $U=\dfrac{\sqrt{n}(\bar{X}-\mu_0)}{\sigma_0}$,且在 H_0 为真时,$U\sim N(0,1)$.由样本可得检验统计量的观测值为 $u=2.23$,此时 $p=P\{|U|\geqslant 2.23\}=2[1-\Phi(2.23)]=0.025\,8$.此时,也可以给出判断准则:

若检验水平 $\alpha\geqslant 0.025\,8$,则 $u_{\alpha/2}\leqslant |u|=2.23$,此时检验统计量的观测值落入拒绝域中,因此拒绝原假设.

若检验水平 $\alpha<0.025\,8$,则 $u_{\alpha/2}>|u|=2.23$,此时检验统计量的观测值没有落入拒绝域中,没有理由拒绝原假设,应接受原假设.

由此判断准则,可以看到,上面计算的概率 0.025 8 是拒绝原假设的最小的显著性水平,将此概率定义为 p 值.

定义 8.1 在假设检验中,利用样本值做出的拒绝原假设的最小显著性水平称为 p 值.

p 值的检验准则为:

若 p 值不大于检验水平 α,则拒绝原假设;

若 p 值大于检验水平 α,则接受原假设.

比较临界值检验法和 p 值检验法,可以发现它们是等价的.

想一想，用临界值检验法如何解释这一结论？

还有一点需要强调，如果只是改变检验水平 α，那么检验结果是否变化呢？用 p 值检验法，很容易看出，若在较小的检验水平下拒绝原假设，则在较大的检验水平下也拒绝原假设；反之，若在较大的检验水平下接受原假设，则在较小的检验水平下也接受原假设.其他情况不一定，需要具体问题具体分析.

8.2 正态总体参数的假设检验

在实际问题中，常常有理由假定总体服从正态分布.本节介绍正态总体参数的假设检验.检验时，若检验统计量服从正态分布，则称为 **u 检验法**；若检验统计量服从 χ^2 分布、t 分布或 F 分布，分别称为 **χ^2 检验法**、**t 检验法**或 **F 检验法**.

8.2.1 单个总体 $N(\mu,\sigma^2)$ 的情形

以下讨论中，总假定已给定显著性水平 α，并设 $(X_1,X_2,\cdots,X_n)$ 是来自总体 $N(\mu,\sigma^2)$ 的样本，$\bar{X}$ 和 S^2 分别是样本均值和样本方差.

1. 总体均值 μ 的检验

今欲检验假设

$$H_0:\mu=\mu_0,\quad H_1:\mu\neq\mu_0 \tag{8.2.1}$$

这里 μ_0 是一个已知数.下面分方差 σ^2 已知和未知两种情况讨论.

(1) 方差 σ^2 已知(为 σ_0^2)——u 检验法

这个问题在例 8.1 中已讨论过.由定理 6.7 知，当 H_0 为真时，

$$U=\frac{\sqrt{n}(\bar{X}-\mu_0)}{\sigma_0}\sim N(0,1) \tag{8.2.2}$$

所以，我们选取 $U=\dfrac{\sqrt{n}(\bar{X}-\mu_0)}{\sigma_0}$ 作为检验统计量.因为 $\bar{X}$ 是 μ 的无偏估计量，所以，当 H_0 为真时，$|u|$ 不应太大，当 H_1 成立时，$|u|$ 有偏大的趋势，故拒绝域形式为

$$|u|=\left|\frac{\sqrt{n}(\bar{x}-\mu_0)}{\sigma_0}\right|\geqslant k\quad (k\text{ 待定})$$

对给定的显著性水平 α，查标准正态分布表得 $k=u_{\alpha/2}$，使

$$P\{|U|\geqslant u_{\alpha/2}\}=\alpha$$

即得拒绝域为

$$|u|=\left|\frac{\sqrt{n}(\bar{x}-\mu_0)}{\sigma_0}\right|\geqslant u_{\alpha/2} \tag{8.2.3}$$

由一次抽样后所得样本值 $(x_1,x_2,\cdots,x_n)$ 计算出 U 的观测值 u，若 $|u|\geqslant u_{\alpha/2}$，则拒绝原假设 H_0，即认为总体均值与 μ_0 有显著差异，若 $|u|<u_{\alpha/2}$，则接受 H_0，即认为总体均值与 μ_0 无显著差异.

为求此检验法的 p 值，由于拒绝域为 $|u|\geqslant k$，因此

$$p=\min_k P\{|U|\geqslant k\mid H_0\text{ 为真}\}=\min_k 2[1-\Phi(k)]=2[1-\Phi(|u|)]$$

例 8.2 某切割机在正常工作时,切割每段金属棒的平均长度为 10.5 cm,标准差是 0.15 cm.今从一批产品中随机地抽取 15 段进行测量,其结果如下(单位:cm):

10.4 10.6 10.1 10.4 10.5 10.3 10.3 10.2

10.9 10.6 10.8 10.5 10.7 10.2 10.7

假定切割的长度服从正态分布,且标准差没有变化,试问该机工作是否正常($\alpha=0.05$)?

解 依题意,总体 X 服从正态分布 $N(\mu,\sigma_0^2)$,$\sigma_0=0.15$,要检验假设

$$H_0:\mu=10.5,\quad H_1:\mu\neq 10.5$$

现在,$n=15$,$\bar{x}=10.48$,$u=\sqrt{15}(10.48-10.5)/0.15=-0.516$,$\alpha=0.05$,查表得 $u_{0.025}=1.96$,由于 $|u|=0.516<1.96$,所以,接受 H_0,即认为该机工作正常.

此例的 p 值为 $p=P\{|U|\geqslant 0.516\}=0.603>0.05$,因此接受 H_0.

(2) 方差 σ 未知——t 检验法

现在,由于 σ^2 未知,因此 u 检验法不能使用.由定理 6.8 知,当 H_0 为真时,

$$T=\frac{\sqrt{n}(\bar{X}-\mu_0)}{S}\sim t(n-1) \tag{8.2.4}$$

因此,我们选取 $T=\dfrac{\sqrt{n}(\bar{X}-\mu_0)}{S}$ 作为检验统计量.因为 S^2 是 σ^2 的无偏估计量,$\bar{X}$ 是 μ 的无偏估计量,所以,当 H_0 为真时,$|t|$ 不应太大,当 H_1 为真时,$|t|$ 有偏大的趋势,故拒绝域形式为

$$|t|=\left|\frac{\sqrt{n}(\bar{x}-\mu_0)}{s}\right|\geqslant k\quad (k\text{ 待定})$$

对给定的显著性水平 α,查 t 分布表得 $k=t_{\alpha/2}(n-1)$,使

$$P\{|T|\geqslant t_{\alpha/2}(n-1)\}=\alpha$$

即得拒绝域为

$$|t|=\left|\frac{\sqrt{n}(\bar{x}-\mu_0)}{s}\right|\geqslant t_{\alpha/2}(n-1) \tag{8.2.5}$$

由一次具体抽样后所得样本值 $(x_1,x_2,\cdots,x_n)$ 计算出 T 的观测值 t,若 $|t|\geqslant t_{\alpha/2}(n-1)$,则拒绝 H_0,否则接受 H_0.

此检验法的 p 值为 $p=P\{|T|\geqslant|t|\}$,其中 t 是统计量 T 的观测值,$T\sim t(n-1)$.

例 8.3 为了检验一架天平是否准确,现把一个质量为 1 000 g 的物体在这架天平上重复称量 9 次,其称量结果如下(单位:g):

1 001 1 005 1 004 1 000 1 002 999 1 005 1 006 1 003

假定称量质量服从正态分布,试问该架天平是否准确.

解 依题意,总体 X 服从正态分布 $N(\mu,\sigma^2)$,μ,σ^2 均未知,要检验假设

$$H_0:\mu=1\,000,\quad H_1:\mu\neq 1\,000$$

现在,$n=9$,$\bar{x}=1\,002.778$,$s=2.438\,1$,$t=\sqrt{n}(\bar{x}-1\,000)/s=3.418\,2$,自由度为 $n-1=8$,

MATLAB 软件提供了命令 [h, p] = ztest(x, m, sigma, alpha, tail) 计算总体方差已知时单个正态总体的均值 μ 的检验.若 $h=0$,则表示在显著性水平 α 下,不能拒绝原假设.若 $h=1$,则表示在显著性水平 α 下,可以拒绝原假设.p 是检验的 p 值.tail = 0 表示双侧假设检验,tail = 1 或 -1 表示单侧假设检验.

MATLAB 软件提供了命令 h = ttest(x, mu0, alpha, tail) 计算总体方差未知时单个正态总体均值的检验.Excel 提供函数 T. TEST,通过选取参数进行不同的 t 检验.

对于给定的 $\alpha=0.05$，查 t 分布表得 $t_{0.025}(8)=2.306\ 0$，由于 $|t|=3.418\ 2>2.306\ 0$，因此，拒绝原假设 H_0，即认为该天平不准确.

该例的 p 值为 $p=P\{|T|>|t|\}=P\{|T|>3.418\ 2\}=2P\{T>3.418\ 2\}=0.009\ 1<\alpha=0.05$，因此拒绝原假设 H_0.

2. 总体方差 σ^2 的检验——χ^2 检验法

今欲检验假设

$$H_0:\sigma^2=\sigma_0^2,\quad H_1:\sigma^2\neq\sigma_0^2 \tag{8.2.6}$$

这里 σ_0^2 为已知数.我们仅讨论 μ 未知的情形，μ 已知的情形由读者自己讨论.由定理6.7知，当 H_0 为真时，

$$\chi^2=\frac{(n-1)S^2}{\sigma_0^2}=\frac{1}{\sigma_0^2}\sum_{i=1}^{n}(X_i-\bar{X})^2\sim\chi^2(n-1) \tag{8.2.7}$$

所以，我们选取 $\chi^2=\dfrac{(n-1)S^2}{\sigma_0^2}$ 作为检验统计量.因为 S^2 是 σ^2 的无偏估计量，所以，当 H_0 为真时，s^2 应在 σ_0^2 附近；当 H_1 为真时，χ^2 有偏小或偏大的趋势.因此，拒绝域形式为

$$\chi^2=\frac{(n-1)s^2}{\sigma_0^2}\leqslant k_1\ 或\ \chi^2=\frac{(n-1)s^2}{\sigma_0^2}\geqslant k_2$$

此处 k_1,k_2 对给定的 α，应由下式确定

$$P\{\chi^2\leqslant k_1\ 或\ \chi^2\geqslant k_2\}=\alpha$$

满足此式的 k_1,k_2 有许多，一般习惯上取 k_1,k_2 满足

$$P\{\chi^2\leqslant k_1\}=P\{\chi^2\geqslant k_2\}=\frac{\alpha}{2}$$

查 χ^2 分布表得

$$k_1=\chi^2_{1-\alpha/2}(n-1),\quad k_2=\chi^2_{\alpha/2}(n-1)$$

即得拒绝域为

$$\chi^2=\frac{(n-1)s^2}{\sigma_0^2}\leqslant\chi^2_{1-\alpha/2}(n-1)\ 或\ \chi^2=\frac{(n-1)s^2}{\sigma_0^2}\geqslant\chi^2_{\alpha/2}(n-1) \tag{8.2.8}$$

由一次具体抽样后所得的样本值 $(x_1,x_2,\cdots,x_n)$ 可计算出统计量 χ^2 的观测值.若 $\chi^2\leqslant\chi^2_{1-\alpha/2}(n-1)$ 或 $\chi^2\geqslant\chi^2_{\alpha/2}(n-1)$，则拒绝 H_0，即认为总体方差与 σ_0^2 有显著差异；若 $\chi^2_{1-\alpha/2}(n-1)<\chi^2<\chi^2_{\alpha/2}(n-1)$，则接受 H_0，即认为总体方差与 σ_0^2 无显著差异.

MATLAB软件提供了命令 h = vartest(x, var0, alpha, tail) 计算总体均值未知时单个正态总体方差的检验.Excel提供函数CHISQ.TEST进行卡方检验.

此检验法的 p 值

$$\begin{aligned}p&=\min_{k_1,k_2}P\{\{\chi^2\leqslant k_1\}\cup\{\chi^2\geqslant k_2\}\mid\sigma^2=\sigma_0^2\}\\&=\min_{k_1,k_2}\{P\{\chi^2\leqslant k_1\mid\sigma^2=\sigma_0^2\}+P\{\chi^2\geqslant k_2\mid\sigma^2=\sigma_0^2\}\}\\&=2\min\{P\{\chi^2\leqslant\chi_0^2\},P\{\chi^2\geqslant\chi_0^2\}\}\end{aligned}$$

其中 χ_0^2 是检验统计量 χ^2 的观测值，$\chi^2\sim\chi^2(n-1)$.

例8.4(续例8.2) 如果只假定切割的长度服从正态分布，问该机切割的金属棒长度的标准差有无显著变化($\alpha=0.05$)？

解 依题意，总体 X 服从正态分布 $N(\mu,\sigma^2)$，μ,σ^2 均未知，要检验假设

$$H_0:\sigma=0.15,\quad H_1:\sigma\neq 0.15$$

此假设等价于假设

$$H_0:\sigma^2=0.022\ 5,\quad H_1:\sigma^2\neq 0.022\ 5$$

现在，$n=15$，$\bar{x}=10.48$，$s^2=0.056$，$\chi^2=\dfrac{(n-1)s^2}{\sigma_0^2}=\dfrac{14\times 0.056}{0.022\ 5}=34.844$，对 $\alpha=0.05$，查 χ^2 分布表得 $\chi^2_{0.975}(14)=5.629$，$\chi^2_{0.025}(14)=26.119$，由于 $\chi^2=34.844>26.119$，所以，拒绝 H_0，即认为该机切割的金属棒长度的标准差有显著变化.

此例的 p 值为 $p=2\min\{P\{\chi^2\leqslant 34.844\},P\{\chi^2\geqslant 34.844\}\}=2P\{\chi^2\geqslant 34.844\}=0.003\ 1<\alpha=0.05$，因此拒绝原假设 H_0.

8.2.2 两个总体 $N(\mu_1,\sigma_1^2)$ 与 $N(\mu_2,\sigma_2^2)$ 的情形

在以下讨论中，总假定已给定显著性水平 α，并设 $(X_1,X_2,\cdots,X_{n_1})$ 是来自总体 $N(\mu_1,\sigma_1^2)$ 的样本，$(Y_1,Y_2,\cdots,Y_{n_2})$ 是来自总体 $N(\mu_2,\sigma_2^2)$ 的样本，并且两个样本相互独立，记 $\bar{X}$，$\bar{Y}$ 分别为相应的样本均值，$S_{1n_1}^2$，$S_{2n_2}^2$ 分别为相应的样本方差.

1. 两总体均值差 $\mu_1-\mu_2$ 的检验——t 检验法

今欲检验假设

$$H_0:\mu_1-\mu_2=c,\quad H_1:\mu_1-\mu_2\neq c \tag{8.2.9}$$

这里 c 为已知数.我们仅讨论 σ_1^2 和 σ_2^2 未知且相等的情形，记 $\sigma_1^2=\sigma_2^2=\sigma^2$，由定理 6.9 知，当 H_0 为真时，

$$T=\frac{(\bar{X}-\bar{Y})-c}{S_W\sqrt{\dfrac{1}{n_1}+\dfrac{1}{n_2}}}\sim t(n_1+n_2-2) \tag{8.2.10}$$

其中 $S_W^2=\dfrac{(n_1-1)S_{1n_1}^2+(n_2-1)S_{2n_2}^2}{n_1+n_2-2}$.因为 $S_{1n_1}^2$ 和 $S_{2n_2}^2$ 都是 σ^2 的无偏估计量，所以 S_W^2 也是 σ^2 的无偏估计量.由于 $\bar{X}$ 是 μ_1 的无偏估计量，$\bar{Y}$ 是 μ_2 的无偏估计量，因此 $\bar{X}-\bar{Y}$ 是 $\mu_1-\mu_2$ 的无偏估计量.故当 H_0 为真时，$|t|$ 不应太大，当 H_1 为真时，$|t|$ 有偏大的趋势，因此，拒绝域形式为

$$|t|=\left|\frac{(\bar{x}-\bar{y})-c}{s_w\sqrt{\dfrac{1}{n_1}+\dfrac{1}{n_2}}}\right|\geqslant k\quad (k\text{ 待定})$$

对给定的显著性水平 α，查 t 分布表得 $k=t_{\alpha/2}(n_1+n_2-2)$ 使

$$P\{|T|\geqslant t_{\alpha/2}(n_1+n_2-2)\}=\alpha$$

即得拒绝域为

$$|t|=\left|\frac{(\bar{x}-\bar{y})-c}{s_w\sqrt{\dfrac{1}{n_1}+\dfrac{1}{n_2}}}\right|\geqslant t_{\alpha/2}(n_1+n_2-2) \tag{8.2.11}$$

由一次具体抽样后所得的样本值 $(x_1,x_2,\cdots,x_{n_1})$ 和 $(y_1,y_2,\cdots,y_{n_2})$ 计算出 T 的

观测值 t,若 $|t| \geqslant t_{\alpha/2}(n_1+n_2-2)$,则拒绝 H_0,否则接受 H_0.

此检验法的 p 值为 $p=P\{|T| \geqslant |t|\}$,其中 t 是统计量 T 的观测值,

$$T \sim t(n_1+n_2-2)$$

当两个正态总体的方差均已知时,我们可用 u 检验法来检验假设(8.2.9);当两个总体方差未知且不相等时,我们可用后面 8.4 节介绍的大样本方法来检验假设(8.2.9).这些由读者自己讨论.

关于均值差的假设检验,常见的是 $c=0$ 的情况,此时,假设(8.2.9)等价于假设

$$H_0:\mu_1=\mu_2, \quad H_1:\mu_1 \neq \mu_2$$

MATLAB 软件提供了命令 h = ttest2(X, Y, alpha, tail) 计算总体方差未知但相等时两正态总体样本均值差是否相等的检验.

例 8.5 有甲、乙两台机床加工同样产品,从这两台机床加工的产品中随机地抽取若干件,测得产品直径(单位:mm)为

机床甲 20.5 19.8 19.7 20.4 20.1 20.0 19.0 19.9

机床乙 19.7 20.8 20.5 19.8 19.4 20.6 19.2

试比较甲、乙两台机床加工的产品直径有无显著差异($\alpha=0.05$)?假定两台机床加工的产品直径都服从正态分布,且总体方差相等.

解 依题意,两总体 X 和 Y 分别服从正态分布 $N(\mu_1,\sigma^2)$,$N(\mu_2,\sigma^2)$,而 μ_1,μ_2,σ^2 均未知,要检验假设

$$H_0:\mu_1=\mu_2, \quad H_1:\mu_1 \neq \mu_2$$

计算可得

$$n_1=8, \quad \bar{x}=19.925, \quad s_{1n_1}^2=0.216$$

$$n_2=7, \quad \bar{y}=20.000, \quad s_{2n_2}^2=0.397$$

因而

$$s_w=\sqrt{\frac{(n_1-1)s_{1n_1}^2+(n_2-1)s_{2n_2}^2}{n_1+n_2-2}}=0.547$$

$$t=\frac{\bar{x}-\bar{y}}{s_w\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}}=-0.265$$

对给定的 $\alpha=0.05$,查自由度为 $n_1+n_2-2=13$ 的 t 分布表得 $t_{0.025}(13)=2.160\,4$,由于 $|t|=0.265<2.160\,4$,因此,接受 H_0,即认为甲、乙两台机床加工的产品直径没有显著差异.

此例的 p 值为 $p=P\{|T| \geqslant |t|\}=P\{|T| \geqslant 0.265\}=0.204\,8>\alpha=0.05$,因此接受原假设 H_0.

2. 两总体方差比的检验——F 检验法

今欲检验假设

$$H_0:\frac{\sigma_1^2}{\sigma_2^2}=c, \quad H_1:\frac{\sigma_1^2}{\sigma_2^2} \neq c \tag{8.2.12}$$

这里 $c>0$ 为已知数.我们只讨论 μ_1,μ_2 未知的情形,μ_1,μ_2 已知的情形由读者自己讨论.由定理 6.10 知,当 H_0 成立时,

$$F=\frac{S_{1n_1}^2}{cS_{2n_2}^2}\sim F(n_1-1,n_2-1) \tag{8.2.13}$$

所以，我们选取 $F=\dfrac{S_{1n_1}^2}{cS_{2n_2}^2}$ 作为检验统计量.因为 $S_{1n_1}^2$ 是 σ_1^2 的无偏估计量，$S_{2n_2}^2$ 是 σ_2^2 的无偏估计量，所以，当 H_0 为真时，F 的取值应集中在 1 的附近，当 H_1 为真时，F 的取值有偏小或偏大的趋势，故拒绝域有形式

$$F\leqslant k_1 \text{ 或 } F\geqslant k_2 \quad (k_1,k_2 \text{ 待定})$$

对给定的水平 α，求 k_1,k_2 使

$$P\{F\leqslant k_1 \text{ 或 } F\geqslant k_2\}=\alpha$$

满足上式的 k_1,k_2 有许多，一般习惯上取 k_1,k_2 使

$$P\{F\leqslant k_1\}=P\{F\geqslant k_2\}=\frac{\alpha}{2}$$

查 F 分布表得

$$k_1=F_{1-\alpha/2}(n_1-1,n_2-1),\quad k_2=F_{\alpha/2}(n_1-1,n_2-1)$$

即得拒绝域为

$$F=\frac{s_{1n_1}^2}{cs_{2n_2}^2}\leqslant F_{1-\alpha/2}(n_1-1,n_2-1)$$

或

$$F=\frac{s_{1n_1}^2}{cs_{2n_2}^2}\geqslant F_{\alpha/2}(n_1-1,n_2-1) \tag{8.2.14}$$

由一次具体抽样后所得的样本值 $(x_1,x_2,\cdots,x_{n_1})$ 和 $(y_1,y_2,\cdots,y_{n_2})$ 计算出 F 的观测值，若 $F\leqslant F_{1-\alpha/2}(n_1-1,n_2-1)$ 或 $F\geqslant F_{\alpha/2}(n_1-1,n_2-1)$，则拒绝 H_0，若 $F_{1-\alpha/2}(n_1-1,n_2-1)<F<F_{\alpha/2}(n_1-1,n_2-1)$，则接受 H_0.

此检验法的 p 值为 $p=2\min\{P\{F\leqslant F_0\},P\{F\geqslant F_0\}\}$，其中 F_0 是检验统计量 F 的观测值，$F\sim F(n_1-1,n_2-1)$.

关于两总体方差比的检验，常见的是 $c=1$ 的情况，此时，假设(8.2.12)等价于假设

$$H_0:\sigma_1^2=\sigma_2^2,\quad H_1:\sigma_1^2\neq\sigma_2^2$$

MATLAB 软件提供了命令 h = vartest2 (X, Y, alpha, tail) 计算总体均值未知时，两正态总体方差是否相等的检验. Excel 提供函数 F.TEST 进行 F 检验.

例 8.6(续例 8.5)　假定两台机床加工的产品直径都服从正态分布，试比较甲、乙两台机床加工的产品直径的精度有无显著差异(取 $\alpha=0.05$).

解　依题意，两总体 X 和 Y 分别服从正态分布 $N(\mu_1,\sigma_1^2)$，$N(\mu_2,\sigma_2^2)$，而 $\mu_1,\mu_2,\sigma_1^2,\sigma_2^2$ 未知，要检验假设

$$H_0:\sigma_1^2=\sigma_2^2,\quad H_1:\sigma_1^2\neq\sigma_2^2$$

经计算得

$$n_1=8,\quad \bar{x}=19.925,\quad s_{1n_1}^2=0.216$$

$$n_2=7,\quad \bar{y}=20.000,\quad s_{2n_2}^2=0.397$$

因而

$$F=\frac{s_{1n_1}^2}{s_{2n_2}^2}=\frac{0.216}{0.397}=0.544$$

对给定的 $\alpha=0.05$，查 F 分布表得 $F_{0.025}(7,6)=5.70$，$F_{0.025}(6,7)=5.12$，于是

$$F_{0.975}(7,6)=\frac{1}{F_{0.025}(6,7)}=\frac{1}{5.12}=0.195$$

易见 $F_{0.975}(7,6)<F<F_{0.025}(7,6)$，故接受 H_0，即认为两台机床加工的产品直径的精度无显著差异.

此例检验的 p 值为 $p=2\min\{P\{F\leqslant 0.544\},P\{F\geqslant 0.544\}\}=0.444\ 0$. 因为 $p=0.444\ 0>\alpha=0.05$，所以，接受原假设 H_0.

8.3 单侧假设检验

上节中我们检验的假设有：

$$H_0:\mu=\mu_0,\qquad H_1:\mu\neq\mu_0$$

$$H_0:\sigma^2=\sigma_0^2,\qquad H_1:\sigma^2\neq\sigma_0^2$$

$$H_0:\mu_1-\mu_2=c,\qquad H_1:\mu_1-\mu_2\neq c$$

$$H_0:\frac{\sigma_1^2}{\sigma_2^2}=c,\qquad H_1:\frac{\sigma_1^2}{\sigma_2^2}\neq c$$

这些假设有一个共同的特点就是每一对假设中的备择假设 H_1 的参数区域都在原假设 H_0 的参数区域的两边，或者从上节的结果可知，它们的拒绝域在其接受域的两边. 这样的假设称为**双侧假设**或**双边假设**.

在实际问题中，有时需要检验形如

$$H_0:\mu=\mu_0,\qquad H_1:\mu>\mu_0 \tag{8.3.1}$$

$$H_0:\mu=\mu_0,\qquad H_1:\mu<\mu_0 \tag{8.3.2}$$

$$H_0:\mu\leqslant\mu_0,\qquad H_1:\mu>\mu_0 \tag{8.3.3}$$

$$H_0:\mu\geqslant\mu_0,\qquad H_1:\mu<\mu_0 \tag{8.3.4}$$

的假设，它们的每一对假设中，备择假设 H_1 的参数域都在原假设 H_0 的参数域的一边. 这样的假设称为**单侧假设**或**单边假设**. 对上节的四个双侧假设都相应地有形如(8.3.1)—(8.3.4)的四种单侧假设.

单侧假设检验方法导出的步骤类似于双侧假设检验，主要是在第(1)步中确定拒绝域的形式时要依据备择假设 H_1 来做. 下面通过几个例子介绍单侧假设检验方法.

例 8.7 设 $(X_1,X_2,\cdots,X_n)$ 是来自正态总体 $N(\mu,\sigma^2)$ 的样本，μ,σ^2 未知，要检验假设

$$H_0:\mu=\mu_0,\quad H_1:\mu>\mu_0$$

这里 μ_0 是已知数.

这样的假设意味着均值 μ 不会小于 μ_0，我们仍取

$$T=\frac{\sqrt{n}(\bar{X}-\mu_0)}{S}$$

作为检验统计量.因为 $\bar{X}$ 是 μ 的无偏估计量,S^2 是 σ^2 的无偏估计量,所以,当 H_0 为真时,t 不应太大,当 H_1 为真时,t 有偏大的趋势,因此,拒绝域的形式应为

$$t=\frac{\sqrt{n}(\bar{x}-\mu_0)}{s}\geqslant k \quad (k\text{ 待定})$$

因为 H_0 为真时,$T\sim t(n-1)$,所以,对给定的水平 α,查 t 分布表得 $k=t_\alpha(n-1)$,使

$$P\{T\geqslant t_\alpha(n-1)\}=\alpha$$

于是得拒绝域为

$$t=\frac{\sqrt{n}(\bar{x}-\mu_0)}{s}\geqslant t_\alpha(n-1) \tag{8.3.5}$$

由单侧假设检验的讨论可以看出,拒绝域是由备择假设 H_1 确定的.因此作假设检验时,只写出原假设 H_0 是不够的,还应写出备择假设 H_1.

此检验法的 p 值为 $p=p\{T\geqslant t\}$,其中 t 是统计量 T 的观测值,$T\sim t(n-1)$.

类似地,若在例 8.7 中要检验假设

$$H_0:\mu=\mu_0,\quad H_1:\mu<\mu_0$$

这里 μ_0 为已知数,则意味着 μ 不会大于 μ_0,其拒绝域形式应为

$$t=\frac{\sqrt{n}(\bar{x}-\mu_0)}{s}\leqslant k \quad (k\text{ 待定})$$

查 t 分布表可得 $k=-t_\alpha(n-1)$,使

$$P\{T\leqslant -t_\alpha(n-1)\}=\alpha$$

故拒绝域为

$$t=\frac{\sqrt{n}(\bar{x}-\mu_0)}{s}\leqslant -t_\alpha(n-1) \tag{8.3.6}$$

此检验法的 p 值为 $p=P\{T\leqslant t\}$,其中 t 是统计量 T 的观测值,$T\sim t(n-1)$.

例 8.8 设 $(X_1,X_2,\cdots,X_n)$ 是来自正态总体 $N(\mu,\sigma^2)$ 的样本,μ,σ^2 未知,要检验假设

$$H_0:\mu\leqslant\mu_0,\quad H_1:\mu>\mu_0$$

这里 μ_0 为已知数.

这种情形在实际中更多见.我们仍取

$$T=\frac{\sqrt{n}(\bar{X}-\mu_0)}{S}$$

作为检验统计量.因为 $\bar{X}$ 是 μ 的无偏估计量,S^2 是 σ^2 的无偏估计量,所以,当 H_0 为真时,t 应偏小,当 H_1 为真时,t 应偏大.因此,拒绝域形式应为

$$t=\frac{\sqrt{n}(\bar{x}-\mu_0)}{s}\geqslant k \quad (k\text{ 待定})$$

因为在 $\mu=\mu_0$ 的前提下,$T\sim t(n-1)$,所以,对给定的 α,查 t 分布表得 $t_\alpha(n-1)$,使

$$P_{\mu_0}\{T\geqslant t_\alpha(n-1)\}=\alpha$$

这里 P_{μ_0} 表示在参数 μ 取 μ_0 时事件 $\{\cdot\}$ 的概率(以下同).我们就取 $k=t_\alpha(n-1)$,从

而得假设(8.3.3)的拒绝域:

$$t=\frac{\sqrt{n}(\bar{x}-\mu_0)}{s}\geqslant t_\alpha(n-1) \tag{8.3.7}$$

可以证明:用(8.3.7)式作为假设(8.3.3)的拒绝域,犯第Ⅰ类错误的概率不会超过给定的检验水平 α.事实上任取 $\mu_1<\mu_0$,若总体均值 μ 的真值为 μ_1,则由定理6.8知

$$\frac{\sqrt{n}(\bar{X}-\mu_1)}{S}\sim t(n-1) \tag{8.3.8}$$

因为 $\mu_1<\mu_0$,所以,$\sqrt{n}(\mu_1-\mu_0)/S<0$,从而 $t_\alpha(n-1)-\sqrt{n}(\mu_1-\mu_0)/S>t_\alpha(n-1)$,由分布函数的单调性,有

$$\begin{aligned}P_{\mu_1}\{T\geqslant t_\alpha(n-1)\}&=P_{\mu_1}\left\{\frac{\sqrt{n}(\bar{X}-\mu_0)}{S}\geqslant t_\alpha(n-1)\right\}\\&=P_{\mu_1}\left\{\frac{\sqrt{n}(\bar{X}-\mu_1)}{S}\geqslant t_\alpha(n-1)-\frac{\sqrt{n}(\mu_1-\mu_0)}{S}\right\}\\&\leqslant P_{\mu_1}\left\{\frac{\sqrt{n}(\bar{X}-\mu_1)}{S}\geqslant t_\alpha(n-1)\right\}\\&=\alpha\quad(\text{利用了}(8.3.8)\text{式})\end{aligned}$$

即

$$P\{\text{拒绝 } H_0 \mid H_0 \text{ 为真}\}\leqslant\alpha$$

注意:尽管假设(8.3.1)与(8.3.3)中原假设 H_0 的形式不同,实际意义也不一样,但对于相同的检验水平 α,它们的拒绝域(8.3.5)式和(8.3.7)式有相同的形式,因此遇到形如(8.3.3)的检验问题,可以按(8.3.1)的来讨论.对于正态总体参数的单边假设检验问题都有类似的结果.

类似地,若在例8.8中要检验假设(8.3.4),可得拒绝域为(8.3.6)式.

假设(8.3.3)与(8.3.1)有相同形式的 p 值 $p=P\{T\geqslant t_0\}$,其中 $T\sim t(n-1)$,t_0 是检验统计量的观测值.同理,假设(8.3.4)与(8.3.2)有相同形式的 p 值 $p=P\{T\leqslant t_0\}$,T,t_0 同上解释.

例8.9 国家规定某种药品的杂质含量不得超过0.1 mg/g.药监局对某药厂送检的该种药品进行了10次抽样检测,测得数据如下:

0.089 0.11 0.12 0.097 0.087 5 0.07 0.124 0.094 0.097 0.13

设检测值服从正态分布,试问在检验水平 $\alpha=0.05$ 下,该药品杂质含量是否合格?

在本例中,如果互换原假设和备择假设,即 $H_0:\mu\leqslant\mu_0=0.1$,$H_1:\mu>\mu_0$,那么检验结果又会如何?如何看待这个问题?

解 设用 X 表示检测值,则 $X\sim N(\mu,\sigma^2)$,μ,σ^2 未知.本着对药品质量严格标准的原则,提出如下假设

$$H_0:\mu\geqslant\mu_0=0.1,\quad H_1:\mu<\mu_0$$

由于 σ^2 未知,故选取检验统计量 $T=\dfrac{\sqrt{n}(\bar{X}-\mu_0)}{S}$,拒绝域为 $t\leqslant-t_\alpha(n-1)$.$n=10$,

$\bar{x}=0.1019, s=0.0188, t=0.3116 \geqslant -t_{\alpha}(9)=-1.8331$，因此接受原假设，即认为该批药品不合格.可以计算其 p 值为 $p=P\{T \leqslant 0.3116\}=0.6188>0.05$，因此接受原假设.

最后，我们将正态总体参数的检验法汇总于表 8.1 中，以便查用.

拓展阅读：互换原假设与备择假设检验结果相反的例子

表 8.1 正态分布参数的检验法

H_0	H_1	条件	检验统计量及分布	拒绝域
$\mu=\mu_0$	$\mu\neq\mu_0$	方差 σ_0^2 已知	$U=\dfrac{\sqrt{n}(\bar{X}-\mu_0)}{\sigma_0}\sim N(0,1)$	$\left\lvert\dfrac{\sqrt{n}(\bar{x}-\mu_0)}{\sigma_0}\right\rvert \geqslant u_{\alpha/2}$
$\mu\leqslant\mu_0$（或 $\mu=\mu_0$）	$\mu>\mu_0$			$\dfrac{\sqrt{n}(\bar{x}-\mu_0)}{\sigma_0}\geqslant u_{\alpha}$
$\mu\geqslant\mu_0$（或 $\mu=\mu_0$）	$\mu<\mu_0$			$\dfrac{\sqrt{n}(\bar{x}-\mu_0)}{\sigma_0}\leqslant -u_{\alpha}$
$\mu=\mu_0$	$\mu\neq\mu_0$	方差 σ^2 未知	$T=\dfrac{\sqrt{n}(\bar{X}-\mu_0)}{S}\sim t(n-1)$	$\left\lvert\dfrac{\sqrt{n}(\bar{x}-\mu_0)}{s}\right\rvert \geqslant t_{\alpha/2}(n-1)$
$\mu\leqslant\mu_0$（或 $\mu=\mu_0$）	$\mu>\mu_0$			$\dfrac{\sqrt{n}(\bar{x}-\mu_0)}{s}\geqslant t_{\alpha}(n-1)$
$\mu\geqslant\mu_0$（或 $\mu=\mu_0$）	$\mu<\mu_0$			$\dfrac{\sqrt{n}(\bar{x}-\mu_0)}{s}\leqslant -t_{\alpha}(n-1)$
$\sigma^2=\sigma_0^2$	$\sigma^2\neq\sigma_0^2$	均值 μ 未知	$\chi^2=\dfrac{(n-1)S^2}{\sigma_0^2}\sim\chi^2(n-1)$	$\dfrac{(n-1)s^2}{\sigma_0^2}\leqslant\chi^2_{1-\alpha/2}(n-1)$ 或 $\dfrac{(n-1)s^2}{\sigma_0^2}\geqslant\chi^2_{\alpha/2}(n-1)$
$\sigma^2\leqslant\sigma_0^2$（或 $\sigma^2=\sigma_0^2$）	$\sigma^2>\sigma_0^2$			$\dfrac{(n-1)s^2}{\sigma_0^2}\geqslant\chi^2_{\alpha}(n-1)$
$\sigma^2\geqslant\sigma_0^2$（或 $\sigma^2=\sigma_0^2$）	$\sigma^2<\sigma_0^2$			$\dfrac{(n-1)s^2}{\sigma_0^2}\leqslant\chi^2_{1-\alpha}(n-1)$
$\mu_1-\mu_2=c$	$\mu_1-\mu_2\neq c$	方差 σ_1^2，σ_2^2 未知，但 $\sigma_1^2=\sigma_2^2$	$T=\dfrac{(\bar{X}-\bar{Y})-c}{S_W\sqrt{\dfrac{1}{n_1}+\dfrac{1}{n_2}}}\sim t(n_1+n_2-2)$，其中 $S_W^2=[(n_1-1)S_{1n_1}^2+(n_2-1)S_{2n_2}^2]/(n_1+n_2-2)$	$\left\lvert\dfrac{(\bar{x}-\bar{y})-c}{s_w\sqrt{\dfrac{1}{n_1}+\dfrac{1}{n_2}}}\right\rvert \geqslant t_{\alpha/2}(n_1+n_2-2)$
$\mu_1-\mu_2\leqslant c$（或 $\mu_1-\mu_2=c$）	$\mu_1-\mu_2>c$			$\dfrac{(\bar{x}-\bar{y})-c}{s_w\sqrt{\dfrac{1}{n_1}+\dfrac{1}{n_2}}}\geqslant t_{\alpha}(n_1+n_2-2)$
$\mu_1-\mu_2\geqslant c$（或 $\mu_1-\mu_2=c$）	$\mu_1-\mu_2<c$			$\dfrac{(\bar{x}-\bar{y})-c}{s_w\sqrt{\dfrac{1}{n_1}+\dfrac{1}{n_2}}}\leqslant -t_{\alpha}(n_1+n_2-2)$

续表

H_0	H_1	条件	检验统计量及分布	拒绝域
$\frac{\sigma_1^2}{\sigma_2^2}=c$	$\frac{\sigma_1^2}{\sigma_2^2}\neq c$	均值 μ_1，μ_2 均未知	$F=\frac{S_{1n_1}^2}{cS_{2n_2}^2}\sim F(n_1-1,n_2-1)$	$\frac{s_{1n_1}^2}{cs_{2n_2}^2}\leqslant F_{1-\alpha/2}(n_1-1,n_2-1)$ 或 $\frac{s_{1n_1}^2}{cs_{2n_2}^2}\geqslant F_{\alpha/2}(n_1-1,n_2-1)$
$\sigma_1^2/\sigma_2^2\leqslant c$（或 $\sigma_1^2/\sigma_2^2=c$）	$\frac{\sigma_1^2}{\sigma_2^2}>c$			$\frac{s_{1n_1}^2}{cs_{2n_2}^2}\geqslant F_{\alpha}(n_1-1,n_2-1)$
$\sigma_1^2/\sigma_2^2\geqslant c$（或 $\sigma_1^2/\sigma_2^2=c$）	$\frac{\sigma_1^2}{\sigma_2^2}<c$			$\frac{s_{1n_1}^2}{cs_{2n_2}^2}\leqslant F_{1-\alpha}(n_1-1,n_2-1)$

8.4 非正态总体的大样本检验及小样本检验

8.4.1 非正态总体的大样本检验

在8.1.3介绍的假设检验四个步骤中，重要的也是困难的是在第(2)步中求检验统计量 Z 的分布.有时 Z 的确切分布难于找到或过于复杂不便应用.遇到这种情况，可以考虑使用 Z 的近似分布.一般在样本容量比较大时，采用 Z 的渐近分布.这时，由给定的显著性水平 α 得到的检验法，其显著性水平近似为 α，而不是确切为 α.下面通过几个例子来介绍.

例 8.10 设总体 X 的分布是任意的，其均值 $E(X)=\mu$ 和方差 $D(X)=\sigma_0^2$ 存在，且 $\sigma_0^2>0$ 已知.$(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的样本，n 比较大，要检验假设

$$H_0:\mu=\mu_0,\quad H_1:\mu\neq\mu_0\quad(\mu_0\text{ 为已知数})$$

解 采用

$$U=\frac{\sqrt{n}(\bar{X}-\mu_0)}{\sigma_0}$$

为检验统计量.因为 $\bar{X}$ 是 μ 的无偏估计量，所以，当 H_0 为真时，$|u|$ 应偏小，当 H_1 为真时，$|u|$ 应偏大，因此拒绝域形式应为

$$|u|=\left|\frac{\sqrt{n}(\bar{x}-\mu_0)}{\sigma_0}\right|\geqslant k\quad(k\text{ 待定})$$

要由给定的显著性水平 α 确定 k，就要在 H_0 为真的条件下求得 U 的分布.因为总体 X 的分布形式未知，所以无法求出 U 的确切分布.但是，由中心极限定理可知，当 H_0 为真且 n 很大时，U 近似地服从标准正态分布 $N(0,1)$.因此，当 n 很大时，对给定的 α，查标准正态分布表得 $u_{\alpha/2}$，使

$$P\{|u|\geqslant u_{\alpha/2}\}\approx\alpha$$

即得到拒绝域

$$|u|=\left|\frac{\sqrt{n}(\bar{x}-\mu_0)}{\sigma_0}\right|\geqslant u_{\alpha/2}$$

由一次具体抽样后所得的样本值$(x_1,x_2,\cdots,x_n)$计算出 U 的观测值 u,若 $|u|\geqslant u_{\alpha/2}$,则拒绝 H_0,否则接受 H_0.

此大样本检验法的 p 值为 $p=P\{|U|\geqslant|u|\}\approx P\{|Z|\geqslant|u|\}$,其中 $Z\sim N(0,1)$.u 是检验统计量 U 的观测值.

例 **8.11** 设有两个总体 X 和 Y,它们的分布是任意的,而均值和方差都存在,且 $E(X)=\mu_1,E(Y)=\mu_2,D(X)=\sigma_1^2>0,D(Y)=\sigma_2^2>0$ 均未知.$(X_1,X_2,\cdots,X_{n_1})$是来自总体 X 的样本,$(Y_1,Y_2,\cdots,Y_{n_2})$是来自总体 Y 的样本,且两样本独立,n_1,n_2 都比较大,要检验假设

$$H_0:\mu_1-\mu_2=c,\quad H_1:\mu_1-\mu_2\neq c$$

这里 c 是已知数.

解 记 $\bar{X},\bar{Y}$ 分别为相应的样本均值,$S_{1n_1}^2$ 和 $S_{2n_2}^2$ 分别为相应的样本方差.我们采用

$$U=\frac{(\bar{X}-\bar{Y})-c}{\sqrt{\frac{1}{n_1}S_{1n_1}^2+\frac{1}{n_2}S_{2n_2}^2}}$$

作为检验统计量.因为 $\bar{X},\bar{Y},S_{1n_1}^2,S_{2n_2}^2$ 分别是 $\mu_1,\mu_2,\sigma_1^2,\sigma_2^2$ 的无偏估计量,所以,当 H_0 为真时,$|u|$ 应偏小,当 H_1 为真时,$|u|$ 应偏大,故拒绝域形式应为

$$|u|=\left|\frac{(\bar{x}-\bar{y})-c}{\sqrt{\frac{1}{n_1}s_{1n_1}^2+\frac{1}{n_2}s_{2n_2}^2}}\right|\geqslant k\quad(k\text{ 待定})$$

要由给定的显著性水平 α 确定 k,就要在 H_0 为真的条件下求得 U 的分布.在 7.4.2 小节中,我们已知道,当 H_0 为真且 n_1,n_2 都充分大时,U 近似服从标准正态分布 $N(0,1)$.对给定的 α,查标准正态分布表得 $u_{\alpha/2}$,使

$$P\{|U|\geqslant u_{\alpha/2}\}\approx\alpha$$

于是得拒绝域为

$$|u|=\left|\frac{(\bar{x}-\bar{y})-c}{\sqrt{\frac{1}{n_1}s_{1n_1}^2+\frac{1}{n_2}s_{2n_2}^2}}\right|\geqslant u_{\alpha/2}$$

由一次具体抽样后所得的样本值$(x_1,x_2,\cdots,x_{n_1})$和$(y_1,y_2,\cdots,y_{n_2})$计算出 U 的观测值 u,若 $|u|\geqslant u_{\alpha/2}$,则拒绝 H_0,否则接受 H_0.

此大样本检验法的 p 值为 $p=P\{|U|\geqslant|u|\}\approx P\{|Z|\geqslant|u|\}$,其中 $Z\sim N(0,1)$,u 是检验统计量 U 的观测值.

例 **8.12** 某厂有一大批产品需要出厂,其次品率 p 未知,按规定标准,次品率 p 不超过某个已知数 p_0 方可出厂.今在其中任意选取 n 件产品进行检验,发现有次品

m 件,问这批产品能否出厂? 假定 n 比较大.

解 依题意,总体 X 的分布是(0—1)分布 $B(1,p)$,即

$$P\{X=1\}=p,\quad P\{X=0\}=1-p$$

要检验假设

$$H_0:p\leqslant p_0,\quad H_1:p>p_0$$

因为要检验的参数是总体均值 $E(X)=p$,所以,自然想到利用样本均值 $\bar{X}=\frac{m}{n}$ 来检验,对此,我们取检验统计量为

$$U=\frac{\bar{X}-p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}=\frac{m-np_0}{\sqrt{np_0(1-p_0)}}$$

因为 $\bar{X}$ 是 p 的无偏估计量,所以,当 H_0 为真时,u 应偏小,当 H_1 为真时,u 应偏大,故拒绝域的形式应为

$$u=\frac{m-np_0}{\sqrt{np_0(1-p_0)}}\geqslant k\quad (k\text{ 待定})$$

对给定的显著性水平 α,要确定临界值 k,需要在 $p=p_0$ 的前提下导出 U 的分布.此分布虽然容易导出,但不便应用.由中心极限定理知,当 n 很大时,U 近似地服从标准正态分布 $N(0,1)$,查标准正态分布表得 $k=u_\alpha$ 使

$$P\{U\geqslant u_\alpha\}\approx\alpha$$

于是得拒绝域

$$u=\frac{m-np_0}{\sqrt{np_0(1-p_0)}}\geqslant u_\alpha$$

或写成

$$m\geqslant np_0+u_\alpha\sqrt{np_0(1-p_0)}$$

即当 $m<np_0+u_\alpha\sqrt{np_0(1-p_0)}$ 时方可出厂.

此大样本检验法的 p 值为 $p=P\{|U|\geqslant|u|\}\approx P\{|Z|\geqslant|u|\}$,其中 $Z\sim N(0,1)$.u 是检验统计量 U 的观测值.

8.4.2 非正态总体的小样本检验

假设检验中,我们通常讨论的是正态总体的假设检验问题,如果不是正态总体,但当样本容量很大时,还可以考虑用大样本检验.然而,对一些非正态总体且样本容量比较小时,用大样本检验会出现一些误差.下面通过例子介绍非正态总体参数的小样本假设检验问题.

例 8.13 某厂家声称他们生产的电子元件平均寿命不低于 2 000 h,现随机抽取 10 个这种电子元件,测得其寿命(单位:h)为:717,1 996,2 532,4 213,1 574,5 437,925,3 654,6 273,2 150,在检验水平 $\alpha=0.05$ 下能否相信厂家的说法?

解 设电子元件的寿命 $X\sim Exp(\lambda)$,λ 未知,则要检验

$$H_0:\frac{1}{\lambda}\geqslant\frac{1}{\lambda_0}=2\ 000,\quad H_1:\frac{1}{\lambda}<\frac{1}{\lambda_0}\quad 或\quad H_0:\lambda\leqslant\lambda_0=\frac{1}{2\ 000},\quad H_1:\lambda>\lambda_0$$

因为检验的是总体的期望,因此从样本均值出发构造统计量.由于 $2n\lambda\overline{X}=2\lambda\sum_{i=1}^{n}X_i\sim\chi^2(2n)$(参见习题 6 第 25 题),因此选取检验统计量为 $\chi^2=2n\lambda_0\overline{X}$,且当 $\lambda=\lambda_0$ 时,$\chi^2\sim\chi^2(2n)$,拒绝域为 $\chi^2\leqslant\chi^2_{1-\alpha}(2n)$.计算得,$\chi^2=29.471>\chi^2_{0.95}(20)=10.851$,故接受原假设,即认为电子元件的平均寿命超过 2 000 h.

此检验的 p 值为 $p=P\{\chi^2\leqslant 29.471\}=0.921\ 1>0.05$,因此接受原假设.

8.5 成对数据的假设检验

前面对两个正态总体的均值或方差的假设检验中,我们要求两个总体相互独立,所抽样本也相互独立.然而,实际应用中这样的要求可能不满足.比如为了检测某种药品的效果,我们测试 n 个人服药前后的数据.每一个人服药前后两个数据并不相互独立,而且由于每个人体质差异,将这些人服药前的 n 个数据看做来自同一个正态总体是不合理的.如果样本是来自同一总体的不同观测,它们成对出现,那么称这样的数据为成对数据.应用中,会经常出现成对数据的假设检验问题,如在相同条件下比较两种产品和两个仪器的差异等.对这类问题,经常转化成单个正态总体的假设检验问题.

注:将成对数据做差可以消除数据间非处理因素之间的差别,比如在检测药品的效果时,样本 $Z_1,Z_2,\cdots,Z_n$ 就消除了不同人的体质差异,只考虑药品的效果.

设有 n 对相互独立的样本 $(X_1,Y_1),(X_2,Y_2),\cdots,(X_n,Y_n)$,令 $Z_i=Y_i-X_i,i=1,2,\cdots,n$,则 $Z_1,Z_2,\cdots,Z_n$ 相互独立.设 $Z_1,Z_2,\cdots,Z_n$ 是来自正态总体 $N(\mu,\sigma^2)$ 的样本,可以检验

(1) $H_0:\mu=\mu_0,\quad H_1:\mu\neq\mu_0$;

(2) $H_0:\mu\leqslant\mu_0,\quad H_1:\mu>\mu_0$;

(3) $H_0:\mu\geqslant\mu_0,\quad H_1:\mu<\mu_0$.

例 8.14 某培训班声称经过培训,学员掷实心球的成绩能够提高 1 米以上.为检验他们的说法是否符合实际,随机选出 9 人,记录他们培训前和培训后的成绩如下(单位:m):

注:读者也可以试用两个相互独立的正态总体在方差未知但相等时的均值差的 t 检验法来做,检验结果如何?怎么解释这一结果?

培训前成绩 x_i	9.63	7.61	6.28	8.32	5.40	5.82	6.89	8.17	5.78
培训后成绩 y_i	10.24	8.75	7.05	8.91	6.51	6.58	8.02	9.08	6.32
差值 y_i-x_i	0.61	1.14	0.77	0.59	1.11	0.76	1.13	0.91	0.54

设差值数据来自正态总体,在检验水平 0.05 下,是否可以认为该培训班的说法是对的?

解 设差值数据来自正态总体 $Z\sim N(\mu,\sigma^2)$,则要求检验 $H_0:\mu\geqslant 1,H_1:\mu<1$.选取检验统计量 $T=\dfrac{\overline{Z}-1}{S_Z/\sqrt{9}}$,在 $\mu=1$ 时,$T\sim t(8)$,该检验的拒绝域为 $t\leqslant -t_{0.05}(8)$.

计算得 $\overline{z}=0.84,s_z=0.242,t=-1.98<-t_{0.05}(8)=-1.859\ 5$,故拒绝原假设,即认

为培训后平均成绩提高不到 1 m.

可以计算此检验的 p 值为 $p=P\{T\leqslant -1.98\}=0.041\ 5<0.05$,因此拒绝原假设.

8.6 分布假设检验

8.6.1 分布拟合检验 皮尔逊定理

前面各节中,我们着重介绍了参数假设检验.在那里,对样本容量比较小的情形要求总体是正态分布.但在许多实际问题中,往往对总体的分布形式一无所知,我们手中所掌握的只是对总体的一些由观测得到的数据资料(即样本值),我们希望能据此判断出这个总体的分布是什么分布或属于什么类型.通常的办法是:先按照某种理由确定一个分布或一个分布类型,这可以是按某种理论的分析,也可以是按以往的经验,或者是通过作样本的频率直方图或经验分布函数大致看出等,然后再利用假设检验方法来判断总体的分布是不是这个分布或属不属于这个分布类型.这种假设检验问题可以提为:设$(X_1,X_2,\cdots,X_n)$是来自总体 X 的样本,要根据此样本检验假设

$$H_0:X \text{ 的分布函数为 } F(x),\quad H_1:X \text{ 的分布函数不是 } F(x)$$

这里 $F(x)$是一个已知的分布函数或函数形式已知,但包含有未知参数的分布函数.$F(x)$常称为**理论分布函数**.此假设检验问题也可以等价的提为:如果用理论分布 $F(x)$函数去拟合样本$(X_1,X_2,\cdots,X_n)$,那么拟合的优良程度如何? 因此,通常称这类假设检验为**分布拟合检验**.分布拟合检验的方法有几种,本节仅介绍其中常用的一种——χ^2 **检验法**.为此,我们先介绍一个重要定理.

定理 8.1 设一个随机试验的 r 个结果 $A_1,A_2,\cdots,A_r$ 构成互斥完备事件群,在一次试验中它们发生的概率分别为 $p_1,p_2,\cdots,p_r$,其中 $p_i>0(i=1,2,\cdots,r)$,且 $\sum\limits_{i=1}^{r}p_i=1$,以 m_i 表示在 n 次独立重复试验中 A_i 发生的次数,那么,当 $n\to\infty$ 时,随机变量

$$\chi^2=\sum_{i=1}^{r}\frac{(m_i-np_i)^2}{np_i}$$

的分布收敛于自由度为 $r-1$ 的 χ^2 分布.

这个定理通常称为**皮尔逊定理**.它的证明超出了本书范围,故从略.

8.6.2 χ^2 拟合检验法

1. 理论分布完全已知的情形

设$(X_1,X_2,\cdots,X_n)$是来自总体 X 的样本,$F(x)$是一个完全已知的分布函数,今要利用此样本检验假设

$$H_0:X \text{ 的分布函数为 } F(x),\quad H_1:X \text{ 的分布函数不是 } F(x)$$

χ^2 拟合检验法的基本思想与步骤:

(1) 把总体 X 的一切可能值的集合 Ω 划分成有限个,比如 r 个互不相交的子集

$$\Omega_1,\Omega_2,\cdots,\Omega_r \tag{8.6.1}$$

记 $A_i=\{X\in\Omega_i\}(i=1,2,\cdots,r)$,则 $A_1,A_2,\cdots,A_r$ 构成互斥完备事件群.

(2) 在原假设 H_0 为真的前提下,计算事件 A_i 的概率

$$P(A_i)=p_i \quad (i=1,2,\cdots,r)$$

显然 $\sum_{i=1}^{r} p_i = 1$,不妨设 $p_i>0$(否则可适当改变划分(8.6.1)),从而可得,在对总体 X 的 n 次独立观察中,事件 A_i 发生的理论频数为 $np_i(i=1,2,\cdots,r)$,即

事件	A_1	A_2	$\cdots$	A_r
理论频数	np_1	np_2	$\cdots$	np_r

(3) 统计出样本值$(x_1,x_2,\cdots,x_n)$中落入 Ω_i 的频数,即事件 A_i 发生的实际频数 $m_i(i=1,2,\cdots,r)$,即

事件	A_1	A_2	$\cdots$	A_r
实际频数	m_1	m_2	$\cdots$	m_r

(4) 考虑统计量

$$\chi^2 = \sum_{i=1}^{r} \frac{(m_i - np_i)^2}{np_i}$$

χ^2 是样本的实际频数 m_i 对理论频数 np_i 偏差 m_i-np_i 的加权平方和,它的值的大小刻画理论分布函数 $F(x)$ 与样本值$(x_1,x_2,\cdots,x_n)$的拟合程度,其值越小,说明 $F(x)$ 与$(x_1,x_2,\cdots,x_n)$拟合得越好,其值越大,说明 $F(x)$ 与$(x_1,x_2,\cdots,x_n)$的偏离程度越大,因此,χ^2 可以作为检验统计量,拒绝域具有形式

$$\chi^2 \geqslant k \quad (k \text{ 待定})$$

对给定的显著性水平 α,要确定 k 使:当 H_0 为真时

$$P\{\chi^2 \geqslant k\} = \alpha$$

就需要确定统计量χ^2 在 H_0 为真的前提下的概率分布.一般来说,要确定χ^2 的精确分布是困难的.但是,由皮尔逊定理,当 H_0 为真且 n 充分大时,χ^2 近似地服从自由度为 $r-1$ 的χ^2 分布,所以,对给定的 α,查χ^2 分布表得$\chi^2_\alpha(r-1)$,使

$$P\{\chi^2 \geqslant \chi^2_\alpha(r-1)\} \approx \alpha$$

于是得拒绝域

$$\chi^2 = \sum_{i=1}^{r} \frac{(m_i - np_i)^2}{np_i} \geqslant \chi^2_\alpha(r-1)$$

此检验法的 p 值为 $p=P\{\chi^2 \geqslant \chi_0^2\} \approx P\{Z \geqslant \chi_0^2\}$,其中 χ_0^2 是检验统计量χ^2 的观测值,$Z \sim \chi^2(r-1)$.

运用χ^2 拟合检验法检验总体分布时,首先要求样本容量比较大,通常取 $n \geqslant 50$;其次,划分时要求各组的理论频数 $np_i \geqslant 5$.另外,在分布拟合检验时,备择假设 H_1 可以不必写出来.

例 8.15 把一颗骰子重复抛掷了 300 次,结果如下:

MATLAB 软件提供了命令 H = chi2gof(x)计算分布的χ^2 拟合检验.

出现的点数	1	2	3	4	5	6
出现的频数	40	70	48	60	52	30

试检验这颗骰子的六个面是否匀称(取 $\alpha=0.05$).

解 设 X 表示抛掷这颗骰子一次所出现的点数,它有 6 个可能值,即 X 的一切可能值的集合为 $\Omega=\{1,2,3,4,5,6\}$,我们提出原假设

$$H_0:\text{这颗骰子六个面是匀称的}$$

或等价于假设

$$H_0:P\{X=i\}=\frac{1}{6}\quad(i=1,2,\cdots,6)$$

因为 X 的取值只有 6 个(有限个),所以,我们取 $\Omega_i=\{i\}$ $(i=1,2,\cdots,6)$,那么,事件 $A_i=\{X\in\Omega_i\}=\{X=i\}$ $(i=1,2,\cdots,6)$ 构成互斥完备事件群.在 H_0 为真的前提下,A_i 的概率 $p_i=P(A_i)=\frac{1}{6}(i=1,2,\cdots,6)$.计算

$$\begin{aligned}\chi^2&=\sum_{i=1}^{6}\frac{(m_i-np_i)^2}{np_i}\\&=\frac{\left(40-300\times\frac{1}{6}\right)^2}{300\times\frac{1}{6}}+\frac{\left(70-300\times\frac{1}{6}\right)^2}{300\times\frac{1}{6}}+\frac{\left(48-300\times\frac{1}{6}\right)^2}{300\times\frac{1}{6}}+\\&\quad\frac{\left(60-300\times\frac{1}{6}\right)^2}{300\times\frac{1}{6}}+\frac{\left(52-300\times\frac{1}{6}\right)^2}{300\times\frac{1}{6}}+\frac{\left(30-300\times\frac{1}{6}\right)^2}{300\times\frac{1}{6}}\\&=20.16\end{aligned}$$

自由度为 $r-1=5$,对给定的 $\alpha=0.05$,查 χ^2 分布表得 $\chi^2_{0.05}(5)=11.071$,易见 $\chi^2=20.16>11.07$,所以,拒绝 H_0,即认为这颗骰子六个面不是匀称的.

此例的 p 值为 $p=P\{\chi^2\geqslant 20.16\}\approx P\{Z\geqslant 20.16\}=0.001\ 2$,其中 $Z\sim\chi^2(5)$,因为 $p=0.001\ 2<\alpha=0.05$,所以,拒绝原假设 H_0.

例 8.16 某厂生产一种电子产品,以往生产的产品寿命(单位:h)服从指数分布,平均寿命为 954,现从新生产的一批产品中抽取 50 个样品,通过寿命试验,测得其寿命为

910	1 220	1 280	20	2 330	900	860	1 450	1 220	550
160	2 020	1 590	1 730	490	1 620	560	530	500	240
1 280	60	190	290	740	1 160	220	910	40	1 410
3 650	3 410	70	510	1 270	610	310	220	370	60
1 750	890	790	1 280	570	760	50	1 530	1 860	1 280

问这批产品的寿命分布有无显著变化(取 $\alpha=0.05$)?

解 设 X 表示这批产品的寿命,我们提出原假设

$$H_0: X \text{ 具有概率密度 } f(x)=\begin{cases}\dfrac{1}{954}e^{-\frac{x}{954}}, & x>0,\\ 0, & x\leqslant 0\end{cases}$$

把 X 可能取值集合$(0,+\infty)$分为 5 个区间,分别计算各组的理论频数 np_i 和实际频数 m_i.计算结果列表 8.2 中.

表 8.2 50 个样品的分组数据表

组号 i	1	2	3	4	5
分组	(0,110]	(110,790]	(790,1 470]	(1 470,2 150]	(2 150,+∞)
p_i	0.108 9	0.454 2	0.222 7	0.109 2	0.105 0
np_i	5.445	22.711	11.134	5.459	5.251
m_i	6	19	15	7	3
m_i-np_i	0.555	−3.711	3.866	1.541	−2.251
$\dfrac{(m_i-np_i)^2}{np_i}$	0.056 5	0.606 3	1.342 0	0.435 0	0.964 7

由表 8.2 最后一行计算得

$$\chi^2=\sum_{i=1}^{5}\frac{(m_i-np_i)^2}{np_i}=3.405$$

自由度 $r-1=5-1=4$,对给定的 $\alpha=0.05$,查 χ^2 分布表得 $\chi^2_{0.05}(4)=9.488$,由于 $\chi^2=3.405<9.488$,所以,接受 H_0,即认为这批产品的寿命分布无显著变化.

此例的 p 值为 $p=P\{\chi^2\geqslant 3.405\}\approx P\{Z\geqslant 3.405\}=0.492\ 8$,其中 $Z\sim\chi^2(4)$,因为 $p=0.492\ 8>\alpha=0.05$,所以,接受原假设 H_0.

2. 理论分布含未知参数的情况

在分布拟合检验中,有时只知理论分布函数 $F(x)$ 的形式,但其中还含有未知参数,具体地说就是:$(X_1,X_2,\cdots,X_n)$ 是来自总体 X 的样本,$F(x;\theta_1,\theta_2,\cdots,\theta_l)$ 是一个函数形式已知的分布函数,其中 $\theta_1,\theta_2,\cdots,\theta_l$ 是未知参数,要利用此样本检验假设

$$H_0: X \text{ 的分布函数为 } F(x;\theta_1,\theta_2,\cdots,\theta_l)$$

$$H_1: X \text{ 的分布函数不是 } F(x;\theta_1,\theta_2,\cdots,\theta_l)$$

在这种情形,先利用样本 $(X_1,X_2,\cdots,X_n)$ 求出 $\theta_1,\theta_2,\cdots,\theta_l$ 的最大似然估计值 $\hat{\theta}_1,\hat{\theta}_2,\cdots,\hat{\theta}_l$,在 $F(x;\theta_1,\theta_2,\cdots,\theta_l)$ 中用 $\hat{\theta}_i$ 代替 $\theta_i(i=1,2,\cdots,l)$,那么 $F(x;\hat{\theta}_1,\hat{\theta}_2,\cdots,\hat{\theta}_l)$ 就变成完全已知的分布函数,然后,再按照前面的步骤进行.有两点需强调:第一点是在第(2)步中计算 $p_i=P(A_i)$ 时,要按 $F(x;\hat{\theta}_1,\hat{\theta}_2,\cdots,\hat{\theta}_l)$ 计算其估计值 $\hat{p}_i(i=1,2,\cdots,r)$;第二点是采用的统计量为

$$\chi^2=\sum_{i=1}^{r}\frac{(m_i-n\hat{p}_i)^2}{n\hat{p}_i}$$

当 $n\to\infty$ 时,其极限分布为自由度 $r-l-1$ 的 χ^2 分布(这是对皮尔逊定理的修正).于是对于给定的显著性水平 α,得拒绝域为

$$\chi^2=\sum_{i=1}^{r}\frac{(m_i-n\hat{p}_i)^2}{n\hat{p}_i}\geqslant\chi_\alpha^2(r-l-1)$$

此检验法的 p 值为 $p=P\{\chi^2\geqslant\chi_0^2\}\approx P\{Z\geqslant\chi_0^2\}$,其中 χ_0^2 是检验统计量 χ^2 的观测值,$Z\sim\chi^2(r-l-1)$.

例 8.17 考察某电话交换台一分钟内被呼叫的次数 X,统计了 100 分钟的记录,每分钟被呼叫次数的频数分布如表 8.3 所示:

表 8.3 某电话交换台每分钟被呼叫次数的频数

被呼叫次数	0	1	2	3	4	5	6	7	8	≥9
频数	0	7	12	18	17	20	13	6	3	4

问:是否可以认为 X 服从泊松分布(取 $\alpha=0.05$)?

解 我们提出原假设 H_0:X 服从泊松分布,即

$$H_0:P\{X=k\}=\frac{\lambda^k}{k!}e^{-\lambda}\quad(k=0,1,2,\cdots)$$

这里 λ 为未知参数,其最大似然估计值为

$$\hat{\lambda}=\bar{x}=\frac{1}{100}(1\times7+2\times12+3\times18+4\times17+5\times20+6\times13+7\times6+8\times3+9\times4)=4.33$$

理论频数为

$$n\hat{p}_i=100\times\frac{(4.33)^i}{i!}e^{-4.33}\quad(i=0,1,2,\cdots,9)$$

计算结果如表 8.4 所示:

表 8.4 被呼叫次数的理论频数表

被呼叫次数 i	0	1	2	3	4	5	6	7	8	≥9
理论频数 $n\hat{p}_i$	1.3	5.7	12.3	17.8	19.3	16.7	12.1	7.5	4.0	3.3
实际频数 m_i	0	7	12	18	17	20	13	6	3	4

由于表 8.4 中第一组的理论频数 1.3 小于 5,把它与第二组合并,$n\hat{p}_i=7.0$,$m_i=7$,最后两组的理论频数 4.0 和 3.3 都小于 5,把它们合并为一组 $n\hat{p}_i=7.3$,$m_i=7$,经合并后,组数 $r=8$,计算得

$$\chi^2=\sum_{i=1}^{8}\frac{(m_i-n\hat{p}_i)^2}{n\hat{p}_i}=1.315$$

参数个数 $l=1$,自由度 $r-l-1=8-1-1=6$,对给定的 $\alpha=0.05$,查 χ^2 分布表得 $\chi_{0.05}^2(6)=12.592$,由于 $\chi^2=1.315<12.592$,故接受 H_0,即认为 X 服从泊松分布.

此例检验的 p 值为 $p=P\{\chi^2\geqslant1.289\}\approx P\{Z\geqslant1.289\}=0.972\ 3$,其中 $Z\sim\chi^2(6)$,

因为$p=0.972\ 3>\alpha=0.05$,所以,接受原假设H_0.

例 8.18(续例 6.4)　问钢材的抗拉强度X是否服从正态分布(取$\alpha=0.05$)?

解　我们提出原假设

$$H_0:X\text{ 服从正态分布 }N(\mu,\sigma^2)$$

其中μ,σ^2为未知参数.由题中所给数据可计算出μ,σ^2的最大似然估计值$\hat{\mu}=\bar{x}=37.354$,$\hat{\sigma^2}=\frac{1}{n}\sum_{i=1}^{n}(x_i-\bar{x})^2=25.867$.我们把$X$可能取值的区间$(-\infty,+\infty)$分为7个小区间,分别计算各组的理论频数$n\hat{p}_i$和实际频数$m_i$,计算结果列表如下:

表 8.5　钢材的抗拉强度的样本分组表

组号 i	1	2	3	4	5	6	7
分组$(t_{i-1},t_i]$	$(-\infty,30]$	$(30,33]$	$(33,36]$	$(36,39]$	$(39,42]$	$(42,45]$	$(45,+\infty)$
$u_i=\frac{t_i-\hat{\mu}}{\hat{\sigma}}$	−1.45	−0.86	−0.27	0.32	0.91	1.50	$+\infty$
$F(t_i)=\Phi(u_i)$	0.073 5	0.194 9	0.393 6	0.625 5	0.818 6	0.933 2	1
$\hat{p}_i=\Phi(u_i)-\Phi(u_{i-1})$	0.073 5	0.121 4	0.198 7	0.231 9	0.193 1	0.114 6	0.066 8
$n\hat{p}_i$	5.586	9.226 4	15.101 2	17.624 4	14.675 6	8.709 6	5.076 8
m_i	8	10	12	17	14	11	4
$\frac{(m_i-n\hat{p}_i)^2}{n\hat{p}_i}$	1.04	0.06	0.64	0.02	0.03	0.60	0.23

由表 8.5 的最后一行计算得

$$\chi^2=\sum_{i=1}^{7}\frac{(m_i-n\hat{p}_i)^2}{n\hat{p}_i}=2.62$$

参数个数$l=2$,自由度$r-l-1=7-2-1=4$,对给定的$\alpha=0.05$,查χ^2分布表得$\chi^2_{0.05}(4)=9.488$,由于$\chi^2=2.62<9.488$,故接受H_0,即认为钢材的抗拉强度X服从正态分布.

此例检验的p值为$p=P\{\chi^2\geqslant 2.62\}\approx P\{Z\geqslant 2.62\}=0.684\ 4$,其中$Z\sim\chi^2(4)$,因为$p=0.684\ 4>\alpha=0.05$,所以,接受原假设$H_0$.

内容小结

假设检验是指对总体提出某种假设,然后利用从总体中抽样所得的样本值来检验所提假设是否正确,若认为该假设正确,则称接受该假设,否则,称拒绝该假设.若要检验的假设是有关总体分布中未知参数或总体的某个数字特征,则称为参数假设检验.若不知道总体的分布,需要根据样本来检验关于总体分布的假设,称为分布假设检验,也称为分布拟合检验,常用χ^2检验法进行分布拟合检验.

要检验的假设H_0称为原假设或零假设,原假设的对立面称为对立假设或备择

假设.为检验假设构造的统计量称为检验统计量.若检验统计量的观测值落在某集合时拒绝原假设,则称该集合为拒绝域,若检验统计量的观测值落在某集合时接受原假设,则称该集合为接受域.拒绝域和接受域的分界点称为临界值.

两类错误:H_0 为真但被拒绝了,称为第Ⅰ类错误,其概率为显著性水平 α;H_0 不真但被接受了,称为第Ⅱ类错误,其概率记作 β.

控制犯第Ⅰ类错误的概率而不考虑犯第Ⅱ类错误的检验问题,称为显著性检验.

若备择假设中参数的取值在原假设参数取值的两边的假设称为双侧假设或双边假设.

在假设检验中,利用样本值做出的拒绝原假设的最小显著性水平称为检验 p 值.

习题8

1. 设总体 X 服从正态分布 $N(\mu,1)$,均值 μ 只能取0或1,$(X_1,X_2,\cdots,X_{16})$ 是来自总体 X 的样本.为了检验假设

$$H_0:\mu=0,\quad H_1:\mu=1$$

采用检验法:当 $\bar{x}\geqslant 0.5$ 时拒绝 H_0,当 $\bar{x}<0.5$ 时接受 H_0.试分别求此检验法犯两类错误的概率.

2. 某种零件的尺寸(单位:mm)服从正态分布 $N(\mu,1.21)$,从一批零件中任取6件,测得尺寸如下:

32.56, 29.66, 31.64, 30.00, 31.87, 31.03

当显著性水平分别为 $\alpha=0.05$ 与 $\alpha=0.01$ 时,能否认为这批零件的平均尺寸为32.25 mm?

3. 已知某炼铁厂的铁水含碳量服从正态分布,在正常情况下,其总体均值为4.55.现在测了10炉铁水,其含碳量分别为4.42,4.38,4.28,4.40,4.42,4.35,4.37,4.52,4.47,4.56,试问总体均值有无显著变化($\alpha=0.05$)?

4. 为了检验一架天平的精度,把一个重为10 g的标准物件在这架天平上称5次,称得结果(单位:g)为9.98,10.01,10.02,9.95,9.92.假定称量值服从正态分布且无系统偏差,问是否可认为总体标准差为0.1($\alpha=0.05$)?

5. 已知维尼纶纤度在正常条件下服从正态分布且标准差 $\sigma=0.048$,从某天产品中抽取5根纤维,测得其纤度为1.32,1.55,1.36,1.40,1.44.问这一天纤度的总体标准差是否正常($\alpha=0.05$)?

1 cal≈4.184 J

6. 使用电学法与混合法两种方法来研究冰的潜热,样品都是-0.72℃的冰块,下列数据是每克冰从-0.72℃变为0℃水的过程中的吸热量(单位:cal):

电学法:79.98 80.04 80.02 80.04 80.03 80.03 80.04 79.97
80.05 80.03 80.02 80.00 80.02

混合法:80.02 79.94 79.97 79.98 79.97 80.03 79.95 79.97

假定用两种方法测得吸热量都服从正态分布,并且它们的总体方差相等,试检验两种方法的总体均值是否相等($\alpha=0.05$)?

7. 甲、乙两台机床加工同一种轴,已知甲、乙两机床加工的轴的直径(单位:mm)都服从正态分布,甲机床的方差为0.2,乙机床的方差为0.4.现从这两台机床加工的轴中分别随机地抽取若干根,测得直径为:

甲机床:20.5 19.8 19.7 20.4 20.1 20.0 19.0 19.9

乙机床:19.7 20.8 20.5 19.8 19.4 20.6 19.2

试问两台机床加工的轴的平均直径有无显著差异($\alpha=0.05$)?

8. 设有甲、乙两厂生产同一种零件,其重量服从正态分布,分别取样8个与9个,测其重量并

计算得样本方差分别为 $s_{甲}^2=0.0961$ 和 $s_{乙}^2=0.0256$，试问甲、乙两厂生产的零件的重量的方差有无区别（$\alpha=0.05$）？

9. 某中药厂从某种药材中提取某种有效成分，采用两种提炼方法.现对同一质量的药材，用两种方法各做了 10 次试验，其得率分别为：

第一种方法：78.1　72.4　76.2　74.3　77.4　78.4　76.0　75.5　76.7　77.3

第二种方法：79.1　81.0　77.3　79.1　80.0　79.1　79.1　77.3　80.2　82.1

假定已知两种方法的得率都服从正态分布，第一种方法的平均得率为 76，第二种方法的平均得率为 79，试问两种方法的得率的方差有无显著差异（$\alpha=0.01$）？

10. 甲、乙两台机床生产同一型号的滚珠，从甲、乙两机床生产的滚珠中分别抽取 8 个与 9 个测量直径得数据如下（单位：mm）：

甲：15.0　14.5　15.2　15.5　14.8　15.1　15.2　14.8

乙：15.2　15.0　14.8　15.2　15.1　15.0　14.8　15.1　14.8

假定滚珠直径服从正态分布，问两台机床产品的直径是否可以认为服从同一分布（$\alpha=0.05$）？

11. 要求一种元件的平均使用寿命不得低于 1 000 h，今从一批这种元件中随机抽取 25 件，测其寿命并计算得样本均值为 950 h，已知该种元件寿命服从标准差为 $\sigma=100$ h 的正态分布，试在显著性水平 $\alpha=0.05$ 下检验这批元件是否合格？

12. 测得一批钢材 20 个样品的屈服点（单位：t/cm^2）为：4.98，5.11，5.20，5.20，5.11，5.00，5.61，4.88，5.27，5.38，5.46，5.27，5.23，4.96，5.35，5.15，5.35，4.77，5.38，5.54.设屈服点服从正态分布，试检验屈服点总体均值是否超过 5.10 t/cm^2（$\alpha=0.05$）？

13. 某种导线，要求其电阻的标准差不得超过 0.005 Ω，今在生产的一批导线中取样 9 根，测得样本标准差为 0.007 Ω.设总体为正态分布，问在显著性水平 $\alpha=0.05$ 下能否认为这批导线的标准差显著地偏大？

14. 在 20 世纪 70 年代后期人们发现，在酿造啤酒时，在麦芽干燥过程中形成致癌物质 N-亚硝基二甲胺（NDMA），到了 80 年代初期开发了一种新的麦芽干燥过程.下面给出分别在新老两种过程中形成的 N-亚硝基二甲胺含量（以 10 亿份中的份数计）.

老过程：6　4　5　5　6　5　5　6　4　6　7　4

新过程：2　1　2　2　1　0　3　2　1　0　1　3

假定两样本分别来自正态总体，且两总体方差相同，两样本独立.以 μ_1,μ_2 记对应于老、新过程的总体均值.试检验假设（取 $\alpha=0.05$）

$$H_0:\mu_1-\mu_2\leqslant 2,\quad H_1:\mu_1-\mu_2>2$$

15. 甲、乙两台机床加工同一种零件，在两台机床加工的产品中分别取 6 个和 9 个，测其长度（单位：cm）并计算得样本方差 $s_{甲}^2=0.245$，$s_{乙}^2=0.357$.假定零件长度服从正态分布，问是否可认为甲机床加工精度比乙机床高？亦即问是否可认为甲机床加工的零件长度的方差小于乙机床（$\alpha=0.05$）？

16. 某厂生产的电器零件的平均电阻一直保持在 2.64 Ω.改变加工工艺后，测得 100 个零件的电阻，并计算得样本均值为 2.62 Ω，样本标准差为 0.06 Ω，问新工艺对此零件的电阻有无显著影响（$\alpha=0.01$）？

17. 为了比较两种枪弹的枪口速度（单位：m/s）.在相同条件下进行速度测定，算得样本均值和样本标准差

枪弹甲：$n_1=110,\bar{x}_1=2\,805,s_1=120.41$

枪弹乙：$n_2=100,\bar{x}_2=2\,680,s_2=105.00$

试检验甲枪弹的平均速度比乙枪弹的平均速度是否显著地大（$\alpha=0.05$）？

18. 某种产品的次品率一直为 0.17，现对此产品进行新工艺试验，从中抽取 400 件检验，发现

有次品56件,能否认为这项新工艺显著地影响产品的质量($\alpha=0.05$)?

19. 对一台设备进行无故障运行时间检测,记录其10次无故障运行时间为(单位:h):520,480,1 200,950,2 150,1 950,1 860,920,2 010,2 041.已知设备无故障运行时间服从指数分布,试问能否认为该设备的平均无故障运行时间超过1 500 h($\alpha=0.05$)?

20. 某药厂研发了一种能够降低血压的新药,为了了解该药的疗效,随机抽取了15名高血压患者,并得到他们使用该药治疗前后的舒张压数据,如下所示:

患者编号	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
治疗前舒张压/mmHg	101.4	110	95	115.6	102.5	113	108	102	100	108	120	118	98	99	102
治疗后舒张压/mmHg	95.9	90.4	88.3	116.8	96	110	100	90	95	88.5	115	118.6	92.5	90.5	102.5

假设舒张压数据来自正态总体,在检验水平0.05下,试检验该药是否有效?

21. 袋中装有8只球,其中红球数未知,在其中任取3只,记录红球的只数X,然后放回,再任取3只,记录红球的只数,然后放回,如此重复进行了112次,其结果如下

红球只数	0	1	2	3
出现次数	1	31	55	25

试取$\alpha=0.05$检验假设

$$H_0:X\text{服从超几何分布,即}P\{X=k\}=\frac{C_5^kC_3^{3-k}}{C_8^3}\quad(k=0,1,2,3)$$

即检验假设H_0:红球的只数为5.

22. 卢瑟福在2 612个相等时间间隔(每个时间间隔为$\frac{1}{8}$min)内,观察了放射性物质放射的粒子数.下表中n_x是在一个时间间隔内观察到x个放射粒子的时间间隔个数:

x	0	1	2	3	4	5	6	7	8	9	10	11	合计
n_x	57	203	383	525	532	408	273	139	49	27	10	6	2 612

试检验在每个时间间隔内观察到的粒子数是否服从泊松分布($\alpha=0.05$)?

23. 在一批灯泡中抽取300只做寿命试验,其结果如下:

寿命t/h	$t\leqslant100$	$100<t\leqslant200$	$200<t\leqslant300$	$t>300$
灯泡只数	121	78	43	58

取$\alpha=0.05$.试检验假设H_0:灯泡寿命服从指数分布,即

$$f(t)=\begin{cases}0.005e^{-0.005t}, & t\geqslant0,\\ 0, & t<0\end{cases}$$

24. 对某汽车零件制造厂所生产的汽缸螺栓口径进行抽样检验,测得100个数据分组列表如下:

组限	10.93~10.95	10.95~10.97	10.97~10.99	10.99~11.01
频数	5	8	20	34
组限	11.01~11.03	11.03~11.05	11.05~11.07	11.07~11.09
频数	17	6	6	4

试检验螺栓口径是否服从正态分布($\alpha=0.05$)?

自测题 8

习题 8 参考答案

第9章 方差分析

方差分析是根据试验数据来推断一个或多个因素在其状态变化时是否会对试验指标起显著作用，从而选出对试验指标起最好影响的试验条件的一种数理统计方法.

9.1 单因素方差分析

9.1.1 数学模型

下面通过一个实例来引入单因素方差分析的数学模型.

例 9.1 表 9.1 给出了小白鼠在接种三种不同菌型伤寒杆菌后的存活天数，问三种菌型的平均存活天数有无显著差异？

表 9.1 小白鼠接种后的存活天数

菌型	接种后存活天数								
Ⅰ型(A_1)	2	4	3	2	4	7	7	2	5
Ⅱ型(A_2)	5	6	8	5	10	7	12	6	6
Ⅲ型(A_3)	7	11	6	6	7	9	5	10	6

在统计学中，把要考察的指标称为试验指标，影响试验指标的条件称为**因素**或**因子**，因素的不同状态称为**水平**.通常，用大写字母 $A,B,\cdots$ 表示因素，用带下标的 $A_1,A_2,\cdots,A_r$ 表示因素 A 的不同水平.在例 9.1 中，对寿命指标可能有影响的因素为伤寒杆菌，记作 A，且因素 A 具有 3 种不同状态：Ⅰ型、Ⅱ型、Ⅲ型伤寒杆菌，分别记为 A_1，A_2,A_3.因此例 9.1 是一个单因素三水平的试验.在单因素试验下进行的方差分析称为**单因素方差分析**.

从表 9.1 中可以看到，即使对于接种了同型伤寒杆菌的小白鼠，它们的存活天数也不尽相同，这表明存活天数 X 是一个随机变量.另外，由于菌型的不同，一般不能把这些数据当作是来自同一总体的，而应看作是来自三个总体 X_1,X_2,X_3 的三个样本 $X_{ij}(i=1,2,3;j=1,2,\cdots,n_i)$，即每个水平对应一个总体，表中的三行数据可看成是来自三个不同总体的样本值.于是要检验三种不同菌型的平均存活天数是否有显著不同，即相当于要检验三个总体的均值是否相等.

由于在实际工作中，具有正态分布的总体最常见，另一方面，在安排试验时，除了让所考察的因素(子)变动外(即让因素取不同的水平)，其他的试验条件都尽可能地保持不变，这就可以假定每个总体的方差是相同的，于是在上述假定条件下所抽象出的单因素方差分析的数学模型为：

设总体 $X_i\sim N(\mu_i,\sigma^2)(i=1,2,3)$，现独立地从各总体中抽出一个样本，记($X_{i1}$，$X_{i2},\cdots,X_{in_i}$)为取自总体 X_i 的样本($i=1,2,3$)，对假设

$$H_0:\mu_1=\mu_2=\mu_3,\quad H_1:\mu_1,\mu_2,\mu_3\text{ 不全相等} \tag{9.1.1}$$

作检验.

在上述模型中,为检验假设 H_0,也可以用 t 检验法,对任何相邻两个总体检验它们的均值是否相等.但是当因素的水平数比较大时,这种方法就相当繁琐.我们采用的是**平方和分解法**.所谓平方和分解法是把整批数据的误差总平方和分解为若干部分,在单因素试验的条件下是分解为两部分,一部分反映因素 A 的效应,称之为因素 A 的效应平方和,另一部分反映随机波动所引起的误差,称之为误差平方和,通过分析两部分平方和在总平方和中所占比例的大小来检验假设 H_0.

现在我们来讨论单因素方差分析.设因素 A 有 r 个水平 $A_1,A_2,\cdots,A_r$,在水平 $A_i(i=1,2,\cdots,r)$ 下,进行 $n_i(n_i\geqslant 2)$ 次独立试验,得到表 9.2 的结果.

表 9.2 单因素方差分析的样本

水平	样本				样本均值
A_1	X_{11}	X_{12}	$\cdots$	X_{1n_1}	$\overline{X}_1$
A_2	X_{21}	X_{22}	$\cdots$	X_{2n_2}	$\overline{X}_2$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$
A_r	X_{r1}	X_{r2}	$\cdots$	X_{rn_r}	$\overline{X}_r$

假定:各个水平 A_i 对应的总体 $X_i(i=1,2,\cdots,r)$ 服从正态分布 $N(\mu_i,\sigma^2)$,且不同水平 A_i 下的样本之间是相互独立的.

由于 $X_{ij}\sim N(\mu_i,\sigma^2)$,因而 $X_{ij}-\mu_i\sim N(0,\sigma^2)$,记 $\varepsilon_{ij}=X_{ij}-\mu_i$,于是

$$\begin{cases} X_{ij}=\mu_i+\varepsilon_{ij}(j=1,2,\cdots,n_i;i=1,2,\cdots,r), \\ \varepsilon_{ij}\sim N(0,\sigma^2),\text{诸 }\varepsilon_{ij}\text{相互独立} \end{cases} \tag{9.1.2}$$

其中 $\mu_i(i=1,2,\cdots,r)$ 以及 σ^2 均为未知参数,(9.1.2)式称为单因素方差分析的数学模型.

方差分析的基本任务是对模型(9.1.2)检验假设

$$H_0:\mu_1=\mu_2=\cdots=\mu_r \tag{9.1.3}$$

为了便于分析,引入下述记号,令

$$n=\sum_{i=1}^{r}n_i,\mu=\frac{1}{n}\sum_{i=1}^{r}n_i\mu_i,\delta_i=\mu_i-\mu(i=1,2,\cdots,r)$$

通常,μ 称为总平均,δ_i 称为水平 A_i 的效应,它反映了因素的第 i 个水平 A_i 对试验指标作用的大小,且满足关系式

$$\sum_{i=1}^{r}n_i\delta_i=0$$

利用这些记号,模型(9.1.2)可改写为

$$\begin{cases} X_{ij}=\mu+\delta_i+\varepsilon_{ij}(j=1,2,\cdots,n_i;\ i=1,2,\cdots,r), \\ \sum_{i=1}^{r}n_i\delta_i=0, \\ \varepsilon_{ij}\sim N(0,\sigma^2),\text{诸 }\varepsilon_{ij}\text{相互独立} \end{cases} \tag{9.1.2}'$$

而假设(9.1.3)等价于假设

$$H_0:\delta_1=\delta_2=\cdots=\delta_r=0 \tag{9.1.3}'$$

9.1.2 统计分析

为了便于下面的讨论,引入以下记号,令

$\bar{\varepsilon}_i=\frac{1}{n_i}\sum_{j=1}^{n_i}\varepsilon_{ij}$,则 $\bar{\varepsilon}_i\sim N\left(0,\frac{\sigma^2}{n_i}\right)$ $(i=1,2,\cdots,r)$;

$\bar{\varepsilon}=\frac{1}{n}\sum_{i=1}^{r}\sum_{j=1}^{n_i}\varepsilon_{ij}=\frac{1}{n}\sum_{i=1}^{r}n_i\bar{\varepsilon}_i$,则 $\bar{\varepsilon}\sim N\left(0,\frac{\sigma^2}{n}\right)$;

$\bar{X}_i=\frac{1}{n_i}\sum_{j=1}^{n_i}X_{ij}$,则 $\bar{X}_i=\mu+\delta_i+\bar{\varepsilon}_i$ $(i=1,2,\cdots,r)$;

$\bar{X}=\frac{1}{n}\sum_{i=1}^{r}\sum_{j=1}^{n_i}X_{ij}=\frac{1}{n}\sum_{i=1}^{r}n_i\bar{X}_i$,则 $\bar{X}=\mu+\bar{\varepsilon}$.

下面我们从平方和的分解着手,导出假设(9.1.3)′的检验统计量.引入总平方和

$$Q_T=\sum_{i=1}^{r}\sum_{j=1}^{n_i}(X_{ij}-\bar{X})^2 \tag{9.1.4}$$

由于 $\bar{X}$ 是整批数据的样本均值,Q_T 是整批数据的样本方差的 $n-1$ 倍,即 Q_T 反映了数据波动的程度,因此 Q_T 又称为**总离差平方和**.把 Q_T 分解为

$$\begin{aligned}Q_T&=\sum_{i=1}^{r}\sum_{j=1}^{n_i}(X_{ij}-\bar{X})^2=\sum_{i=1}^{r}\sum_{j=1}^{n_i}[(X_{ij}-\bar{X}_i)+(\bar{X}_i-\bar{X})]^2\\&=\sum_{i=1}^{r}\sum_{j=1}^{n_i}(X_{ij}-\bar{X}_i)^2+\sum_{i=1}^{r}n_i(\bar{X}_i-\bar{X})^2\end{aligned}$$

最后等号成立用到了

$$\sum_{i=1}^{r}\sum_{j=1}^{n_i}(X_{ij}-\bar{X}_i)(\bar{X}_i-\bar{X})=\sum_{i=1}^{r}(\bar{X}_i-\bar{X})\sum_{j=1}^{n_i}(X_{ij}-\bar{X}_i)=0$$

令

$$Q_E=\sum_{i=1}^{r}\sum_{j=1}^{n_i}(X_{ij}-\bar{X}_i)^2=\sum_{i=1}^{r}\sum_{j=1}^{n_i}(\varepsilon_{ij}-\bar{\varepsilon}_i)^2 \tag{9.1.5}$$

$$Q_A=\sum_{i=1}^{r}n_i(\bar{X}_i-\bar{X})^2=\sum_{i=1}^{r}n_i(\delta_i+\bar{\varepsilon}_i-\bar{\varepsilon})^2 \tag{9.1.6}$$

则

$$Q_T=Q_E+Q_A \tag{9.1.7}$$

Q_E 的各项 $(X_{ij}-\bar{X}_i)^2$ 表示在水平 A_i 下,样本值与样本均值的差异,这是由随机误差所引起的,Q_E 称为**误差平方和**.Q_A 的各项 $(\bar{X}_i-\bar{X})^2$ 表示在水平 A_i 下的样本平均值与数据总平均的差异,这是由水平 A_i 以及随机误差引起的,Q_A 称为因素 A 的**效应平方和**.

为了进一步了解统计量 Q_E 和 Q_A 的统计意义,分别计算它们的数学期望

$$\begin{aligned}E(Q_E)&=E\left[\sum_{i=1}^{r}\sum_{j=1}^{n_i}(\varepsilon_{ij}-\bar{\varepsilon}_i)^2\right]=\sum_{i=1}^{r}E\left[\sum_{j=1}^{n_i}(\varepsilon_{ij}-\bar{\varepsilon}_i)^2\right]\\&=\sum_{i=1}^{r}(n_i-1)\sigma^2=(n-r)\sigma^2\end{aligned}$$

$$E(Q_A)=E\Big[\sum_{i=1}^{r} n_i(\delta_i+\bar{\varepsilon}_i-\bar{\varepsilon})^2\Big]$$

$$=E\Big[\sum_{i=1}^{r} n_i\delta_i^2+\sum_{i=1}^{r} n_i(\bar{\varepsilon}_i-\bar{\varepsilon})^2+2\sum_{i=1}^{r} n_i\delta_i(\bar{\varepsilon}_i-\bar{\varepsilon})\Big]$$

$$=\sum_{i=1}^{r} n_i\delta_i^2+(r-1)\sigma^2$$

由此可见，无论 H_0 是否成立，$\dfrac{Q_E}{n-r}$ 都是 σ^2 的无偏估计量，而仅当假设 H_0 成立时，$\dfrac{Q_A}{r-1}$ 才是 σ^2 的无偏估计量，否则，$\dfrac{Q_A}{r-1}$ 的均值要大于 σ^2，这表明比值

$$F=\frac{Q_A/(r-1)}{Q_E/(n-r)}$$

在假设 H_0 不成立时，有偏大的倾向，因此检验假设 H_0 的拒绝域形式应取为

$$F=\frac{Q_A/(r-1)}{Q_E/(n-r)}\geqslant C$$

为了在 H_0 成立的前提下导出检验统计量 F 的分布，我们介绍平方和分布的科克伦分解定理.

科克伦分解定理 设 $X_1,X_2,\cdots,X_n$ 是 n 个相互独立的标准正态变量，而 $Q=X_1^2+X_2^2+\cdots+X_n^2$ 是自由度为 n 的 χ^2 变量.若 Q 可以表示成

$$Q=Q_1+Q_2+\cdots+Q_k$$

其中 Q_i 是 $(X_1,X_2,\cdots,X_n)$ 的非负定二次型，自由度为 m_i，则 $Q_i(i=1,2,\cdots,k)$ 相互独立，且分别服从于自由度为 m_i 的 χ^2 分布的充要条件是

$$\sum_{i=1}^{k} m_i=n$$

理论探究：科克伦分解定理的证明

当 H_0 成立时，所有的 δ_i 都等于零，因而

$$X_{ij}=\mu+\varepsilon_{ij}\quad(j=1,2,\cdots,n_i;i=1,2,\cdots,r)$$

于是平方和分解式(9.1.7)变成

$$\sum_{i=1}^{r}\sum_{j=1}^{n_i}(\varepsilon_{ij}-\bar{\varepsilon})^2=\sum_{i=1}^{r}\sum_{j=1}^{n_i}(\varepsilon_{ij}-\bar{\varepsilon}_i)^2+\sum_{i=1}^{r} n_i(\bar{\varepsilon}_i-\bar{\varepsilon})^2$$

因为

$$\sum_{i=1}^{r}\sum_{j=1}^{n_i}\varepsilon_{ij}^2=\sum_{i=1}^{r}\sum_{j=1}^{n_i}(\varepsilon_{ij}-\bar{\varepsilon})^2+n\bar{\varepsilon}^2$$

所以有

$$\sum_{i=1}^{r}\sum_{j=1}^{n_i}\varepsilon_{ij}^2=\sum_{i=1}^{r}\sum_{j=1}^{n_i}(\varepsilon_{ij}-\bar{\varepsilon}_i)^2+\sum_{i=1}^{r}[\sqrt{n_i}(\bar{\varepsilon}_i-\bar{\varepsilon})]^2+(\sqrt{n}\bar{\varepsilon})^2$$

上式两端同除以 σ^2，左端 $\dfrac{1}{\sigma^2}\displaystyle\sum_{i=1}^{r}\sum_{j=1}^{n_i}\varepsilon_{ij}^2$ 是自由度为 n 的 χ^2 变量，右端三项分别为

$\dfrac{1}{\sigma^2}Q_E=\dfrac{1}{\sigma^2}\displaystyle\sum_{i=1}^{r}\sum_{j=1}^{n_i}(\varepsilon_{ij}-\bar{\varepsilon}_i)^2$，它是 n 个变量 $(\varepsilon_{ij}-\bar{\varepsilon}_i)/\sigma(j=1,2,\cdots,n_i;i=1,2,\cdots,$

r)的平方和,这些变量之间有 r 个约束条件 $\sum_{j=1}^{n_i}(\varepsilon_{ij}-\bar{\varepsilon}_i)=0(i=1,2,\cdots,r)$,因而$\frac{1}{\sigma^2}Q_E$的自由度为 $n-r$;

$\frac{1}{\sigma^2}Q_A=\frac{1}{\sigma^2}\sum_{i=1}^{r}[\sqrt{n_i}(\bar{\varepsilon}_i-\bar{\varepsilon})]^2$,它是 r 个变量$\sqrt{n_i}(\bar{\varepsilon}_i-\bar{\varepsilon})/\sigma$ 的平方和,相互间仅有一个约束条件 $\sum_{i=1}^{r}\sqrt{n_i}[\sqrt{n_i}(\bar{\varepsilon}_i-\bar{\varepsilon})]=0$,故$\frac{1}{\sigma^2}Q_A$ 的自由度为 $r-1$;

$\frac{1}{\sigma^2}(\sqrt{n}\bar{\varepsilon})^2$ 的自由度为 1.

这样,右端三项的自由度之和$(n-r)+(r-1)+1=n$,因而由科克伦分解定理的充分性知:当 H_0 成立时,

$$\frac{Q_E}{\sigma^2}\sim\chi^2(n-r),\frac{Q_A}{\sigma^2}\sim\chi^2(r-1)$$

且 Q_E 与 Q_A 相互独立.于是,当 H_0 成立时

$$F=\frac{\frac{Q_A}{\sigma^2}\Big/(r-1)}{\frac{Q_E}{\sigma^2}\Big/(n-r)}=\frac{Q_A/(r-1)}{Q_E/(n-r)}\sim F(r-1,n-r)$$

因此,对给定的显著性水平 α,关于 H_0 检验问题的临界值 $C=F_\alpha(r-1,n-r)$,即一次抽样后由样本值算得 F 的数值,若 $F\geqslant F_\alpha(r-1,n-r)$则拒绝 H_0,认为因素 A 对指标有显著影响;若 $F<F_\alpha(r-1,n-r)$则接受 H_0,认为因素 A 对指标无显著影响.

在具体计算时,可将主要结果列成方差分析表(见表 9.3).

表 9.3 单因素方差分析表

方差来源	平方和	自由度	均方	F 值
因素 A 的作用(组间)	$Q_A=\sum_{i=1}^{r}n_i(\bar{X}_i-\bar{X})^2$	$r-1$	$\bar{Q}_A=\frac{Q_A}{r-1}$	$F=\frac{\bar{Q}_A}{\bar{Q}_E}$
误差(组内)	$Q_E=\sum_{i=1}^{r}\sum_{j=1}^{n_i}(X_{ij}-\bar{X}_i)^2$	$n-r$	$\bar{Q}_E=\frac{Q_E}{n-r}$	
总和	$Q_T=\sum_{i=1}^{r}\sum_{j=1}^{n_i}(X_{ij}-\bar{X})^2$	$n-1$		

此检验法的 p 值为 $p=P\{F\geqslant F_0\}$,其中 F_0 是检验统计量 F 的观测值,$F\sim F(r-1,n-r)$.

在实际中,可按下面的便于编程的公式来计算 Q_T,Q_A,Q_E.令

$$S_i=\sum_{j=1}^{n_i}x_{ij},\quad SS_i=\sum_{j=1}^{n_i}x_{ij}^2\quad(i=1,2,\cdots,r)$$

则

$$Q_A=\sum_{i=1}^{r}\frac{S_i^2}{n_i}-\frac{1}{n}\Big(\sum_{i=1}^{r}S_i\Big)^2$$

$$Q_E=\sum_{i=1}^{r}SS_i-\sum_{i=1}^{r}\frac{S_i^2}{n_i}$$

$$Q_T=\sum_{i=1}^{r}SS_i-\frac{1}{n}\left(\sum_{i=1}^{r}S_i\right)^2$$

例 9.1 的计算结果见表 9.4,其中 $r=3,n=27$.

表 9.4 例 9.1 的单因素方差分析表

方差来源	平方和	自由度	均方	F 值
因素	$Q_A=66.888\ 9$	2	33.444 5	7.180 9
误差	$Q_E=111.777\ 8$	24	4.657 4	
总和	$Q_T=178.666\ 7$	26		

对给定的显著性水平 $\alpha=0.05$,查得 $F_{0.05}(2,24)=3.40$,因 $F=7.180\ 9>F_{0.05}(2,24)=3.40$,故拒绝 H_0,即认为接种这三种不同菌型的伤寒杆菌后的平均存活天数有显著差异.

此例检验的 p 值 $p=P\{F\geqslant 7.180\ 9\}=0.003\ 6<\alpha=0.05$,因此拒绝原假设 H_0.

9.1.3 未知参数的估计

当拒绝假设 H_0 时,这就意味着因素的各水平的效应 $\delta_1,\delta_2,\cdots,\delta_r$ 不全为零,因而需根据样本来估计各水平的效应.利用关系式

$$E(\bar{X})=\mu,\quad E(\bar{X}_i)=\mu+\delta_i=\mu_i\quad(i=1,2,\cdots,r)$$

可得 μ,μ_i,δ_i 的无偏估计量

$$\hat{\mu}=\bar{X},\quad \hat{\mu}_i=\bar{X}_i,\quad \hat{\delta}_i=\bar{X}_i-\bar{X}\quad(i=1,2,\cdots,r)$$

此外,无论 H_0 是否为真,σ^2 的无偏估计量为

$$\hat{\sigma^2}=\frac{Q_E}{n-r}=\bar{Q}_E$$

在检验结果为假设 H_0 不成立时,有时还需要对 μ_i 以及 $\mu_i-\mu_k(i\neq k)$ 做区间估计,其做法如下:

对任意 $1\leqslant i\leqslant r$,由定理 6.7 得

$$\frac{\bar{X}_i-\mu_i}{\sigma/\sqrt{n_i}}\sim N(0,1),\quad \frac{1}{\sigma^2}\sum_{j=1}^{n_i}(X_{ij}-\bar{X}_i)^2\sim\chi^2(n_i-1)$$

且相互独立,再由样本之间的独立性以及 χ^2 分布的可加性得

$$Q_E/\sigma^2\sim\chi^2(n-r)$$

且与 $\bar{X}_i(i=1,2,\cdots,r)$ 相互独立.于是

$$\frac{(\bar{X}_i-\mu_i)^2\Big/\frac{\sigma^2}{n_i}}{\frac{Q_E}{\sigma^2}\Big/(n-r)}=\frac{n_i(\bar{X}_i-\mu_i)^2}{\bar{Q}_E}\sim F(1,n-r)$$

对于给定的显著性水平 α,由关系式

$$P\left\{\frac{n_i(\bar{X}_i-\mu_i)^2}{\bar{Q}_E}\geqslant F_\alpha(1,n-r)\right\}=\alpha$$

的等价形式

$$P\left\{\bar{X}_i-\sqrt{\frac{\bar{Q}_E}{n_i}}\sqrt{F_\alpha(1,n-r)}<\mu_i<\bar{X}_i+\sqrt{\frac{\bar{Q}_E}{n_i}}\sqrt{F_\alpha(1,n-r)}\right\}=1-\alpha$$

便得 μ_i 的置信度为 $1-\alpha$ 的置信区间

$$\left(\bar{X}_i-\sqrt{\frac{\bar{Q}_E}{n_i}}\sqrt{F_\alpha(1,n-r)},\bar{X}_i+\sqrt{\frac{\bar{Q}_E}{n_i}}\sqrt{F_\alpha(1,n-r)}\right)\quad(i=1,2,\cdots,r)$$

类似地,因为

$$\frac{\bar{X}_i-\bar{X}_k-(\mu_i-\mu_k)}{\sqrt{\frac{1}{n_i}+\frac{1}{n_k}}\,\sigma}\sim N(0,1)$$

且可以证明 $\bar{X}_i-\bar{X}_k$ 与 Q_E 相互独立,而 $\frac{Q_E}{\sigma^2}\sim\chi^2(n-r)$,所以

$$T=\frac{\bar{X}_i-\bar{X}_k-(\mu_i-\mu_k)}{\sqrt{\frac{1}{n_i}+\frac{1}{n_k}}\sqrt{\bar{Q}_E}}\sim t(n-r)$$

给定置信度 $1-\alpha$,查附表 3 得 $t_{\alpha/2}(n-r)$,使

$$P\{|T|<t_{\alpha/2}(n-r)\}=1-\alpha$$

即

$$P\left\{\bar{X}_i-\bar{X}_k-t_{\alpha/2}(n-r)\sqrt{\frac{1}{n_i}+\frac{1}{n_k}}\sqrt{\bar{Q}_E}<\mu_i-\mu_k<\bar{X}_i-\bar{X}_k+t_{\alpha/2}(n-r)\sqrt{\frac{1}{n_i}+\frac{1}{n_k}}\sqrt{\bar{Q}_E}\right\}=1-\alpha$$

于是,$\mu_i-\mu_k$ 的置信度为 $1-\alpha$ 的置信区间是

$$\left(\bar{X}_i-\bar{X}_k-t_{\alpha/2}(n-r)\sqrt{\frac{1}{n_i}+\frac{1}{n_k}}\sqrt{\bar{Q}_E},\bar{X}_i-\bar{X}_k+t_{\alpha/2}(n-r)\sqrt{\frac{1}{n_i}+\frac{1}{n_k}}\sqrt{\bar{Q}_E}\right)$$

MATLAB 提供命令 [p, table, stats] = anoval(X) 比较单因素方差分析中 X 的各列的均值是否相等.返回值 p 为各列均值相等的概率值,若 p 值接近于 0,则原假设受到怀疑,说明至少有一列均值与其余列均值有明显不同.table 为方差分析表,stats 为分析结果的构造.

例 9.2 求例 9.1 中的未知参数 $\sigma^2,\delta_i(i=1,2,3)$ 的点估计和 $\mu_i(i=1,2,3)$ 以及均值差的置信度为 0.95 的置信区间.

解

$$\hat{\sigma^2}=Q_E/(n-r)=\bar{Q}_E=4.657\,4$$

$$\hat{\delta}_1=\bar{X}_1-\bar{X}=4.000-6.222=-2.222$$

$$\hat{\delta}_2=\bar{X}_2-\bar{X}=7.222-6.222=1.000$$

$$\hat{\delta}_3 = \bar{X}_3 - \bar{X} = 7.444 - 6.222 = 1.222$$

$\mu_i(i=1,2,3)$的区间估计如下：

由 $F_{0.05}(1,n-r) = F_{0.05}(1,24) = 4.26$，得

$$\sqrt{\bar{Q}_E/n_i}\sqrt{F_{0.05}(1,24)} = \sqrt{4.657\ 4/9}\sqrt{4.26} = 1.484\ 8$$

故 μ_1,μ_2,μ_3 的置信度为 0.95 的置信区间分别为

$$(2.515\ 2,5.484\ 8),(5.737\ 2,8.706\ 8),(5.959\ 2,8.928\ 8)$$

均值差的区间估计如下：

由 $t_{0.025}(n-r) = t_{0.025}(24) = 2.063\ 9$，得

$$t_{0.025}(24)\sqrt{\frac{1}{n_i}+\frac{1}{n_k}}\sqrt{\bar{Q}_E} = 2.063\ 9\sqrt{\frac{1}{9}+\frac{1}{9}}\sqrt{4.657\ 4} = 2.099\ 7$$

故 $\mu_1-\mu_2,\mu_1-\mu_3,\mu_2-\mu_3$ 的置信度为 0.95 的置信区间分别为

$$(-5.321\ 7,-1.122\ 3),(-5.543\ 7,-1.344\ 3),(-2.321\ 7,1.877\ 7)$$

9.2 双因素方差分析

双因素方差分析是利用试验数据对两个因素的影响作出合理推断的统计方法. 下面分非重复试验和重复试验两种情形进行讨论.

9.2.1 非重复试验

双因素多水平试验的数据见表 9.5.

表 9.5 双因素多水平试验数据

因素 A	因素 B			
	B_1	B_2	…	B_s
A_1	X_{11}	X_{12}	…	X_{1s}
A_2	X_{21}	X_{22}	…	X_{2s}
⋮	⋮	⋮		⋮
A_r	X_{r1}	X_{r2}	…	X_{rs}

其中因素 A 取 r 种水平，因素 B 取 s 种水平，共有 rs 种不同的组合水平 $A_i\times B_j(i=1,2,\cdots,r;j=1,2,\cdots,s)$，在 A,B 的每种组合水平 $A_i\times B_j$ 上各做一次试验，这种试验称为**双因素非重复试验**，记试验结果为 $X_{ij}(i=1,2,\cdots,r;j=1,2,\cdots,s)$.

1. 数学模型

假定相互独立的总体 X_{ij} 服从正态分布 $N(\mu_{ij},\sigma^2)$，因为做非重复试验，所以试验结果 X_{ij} 亦为总体 X_{ij} 的样本，要求检验

$$H_0:\ \mu_{11}=\mu_{12}=\cdots=\mu_{rs} \tag{9.2.1}$$

为了把影响 X_{ij} 取值的各成分在其表达式中明确地表示出来，把上述数学模型改成另一种更简明直观的形式.

记 $\varepsilon_{ij}=X_{ij}-\mu_{ij}$，则 $\varepsilon_{ij}\sim N(0,\sigma^2)$，于是 $X_{ij}=\mu_{ij}+\varepsilon_{ij}$，其中 $\varepsilon_{ij}\sim N(0,\sigma^2)$，诸 ε_{ij} 相互独立.利用类似于单因素方差分析模型中的想法，把 μ_{ij} 表示成

$$\mu_{ij}=\mu+\alpha_i+\beta_j \tag{9.2.2}$$

而

$$\sum_{i=1}^{r}\alpha_i=0,\quad \sum_{j=1}^{s}\beta_j=0 \tag{9.2.3}$$

称 α_i 为因素 A 的第 i 水平 A_i 对指标的效应；β_j 为因素 B 的第 j 水平 B_j 对指标的效应.这样，原假设 H_0 可改成以下更为明确的假设：

$$H_{01}:\alpha_1=\alpha_2=\cdots=\alpha_r=0 \tag{9.2.4}$$

$$H_{02}:\beta_1=\beta_2=\cdots=\beta_s=0 \tag{9.2.5}$$

如果 H_{01} 为真，那么 μ_{ij} 与 i 无关，这表明因素 A 对指标无显著影响.同样，如果 H_{02} 为真，则 μ_{ij} 与 j 无关，这表明因素 B 对试验结果无显著影响.因而，非重复试验双因素方差分析的数学模型可表示为

$$\begin{cases} X_{ij}=\mu+\alpha_i+\beta_j+\varepsilon_{ij}, \\ \sum\limits_{i=1}^{r}\alpha_i=0,\quad \sum\limits_{j=1}^{s}\beta_j=0, \\ \varepsilon_{ij}\sim N(0,\sigma^2), \end{cases} \tag{9.2.6}$$

$i=1,2,\cdots,r;j=1,2,\cdots,s$，其中诸 ε_{ij} 相互独立.要求检验假设

$$H_{01}:\alpha_1=\alpha_2=\cdots=\alpha_r=0$$

$$H_{02}:\beta_1=\beta_2=\cdots=\beta_s=0$$

为讨论方便起见，引入以下记号，令

$$\bar{\varepsilon}_{i\cdot}=\frac{1}{s}\sum_{j=1}^{s}\varepsilon_{ij}，则\ \bar{\varepsilon}_{i\cdot}\sim N\left(0,\frac{\sigma^2}{s}\right)\ (i=1,2,\cdots,r)；$$

$$\bar{\varepsilon}_{\cdot j}=\frac{1}{r}\sum_{i=1}^{r}\varepsilon_{ij}，则\ \bar{\varepsilon}_{\cdot j}\sim N\left(0,\frac{\sigma^2}{r}\right)\ (j=1,2,\cdots,s)；$$

$$\bar{\varepsilon}=\frac{1}{rs}\sum_{i=1}^{r}\sum_{j=1}^{s}\varepsilon_{ij}，则\ \bar{\varepsilon}\sim N\left(0,\frac{\sigma^2}{rs}\right)；$$

$$\bar{X}_{i\cdot}=\frac{1}{s}\sum_{j=1}^{s}X_{ij}，则\ \bar{X}_{i\cdot}=\mu+\alpha_i+\bar{\varepsilon}_{i\cdot}\ (i=1,2,\cdots,r)；$$

$$\bar{X}_{\cdot j}=\frac{1}{r}\sum_{i=1}^{r}X_{ij}，则\ \bar{X}_{\cdot j}=\mu+\beta_j+\bar{\varepsilon}_{\cdot j}\ (j=1,2,\cdots,s)；$$

$$\bar{X}=\frac{1}{rs}\sum_{i=1}^{r}\sum_{j=1}^{s}X_{ij}，则\ \bar{X}=\mu+\bar{\varepsilon}.$$

2. 统计分析

导出检验假设 H_{01} 与 H_{02} 的方法与单因素方差分析相类似，也是把总平方和 Q_T 进行分解

$$\begin{aligned} Q_T &= \sum_{i=1}^{r}\sum_{j=1}^{s}(X_{ij}-\bar{X})^2 \\ &= \sum_{i=1}^{r}\sum_{j=1}^{s}[(X_{ij}-\bar{X}_{i\cdot}-\bar{X}_{\cdot j}+\bar{X})+(\bar{X}_{i\cdot}-\bar{X})+(\bar{X}_{\cdot j}-\bar{X})]^2 \\ &= Q_E+Q_A+Q_B \end{aligned} \tag{9.2.7}$$

其中

$$Q_E=\sum_{i=1}^{r}\sum_{j=1}^{s}(X_{ij}-\bar{X}_{i\cdot}-\bar{X}_{\cdot j}+\bar{X})^2=\sum_{i=1}^{r}\sum_{j=1}^{s}(\varepsilon_{ij}-\bar{\varepsilon}_{i\cdot}-\bar{\varepsilon}_{\cdot j}+\bar{\varepsilon})^2$$

$$Q_A=s\sum_{i=1}^{r}(\bar{X}_{i\cdot}-\bar{X})^2=s\sum_{i=1}^{r}(\alpha_i+\bar{\varepsilon}_{i\cdot}-\bar{\varepsilon})^2$$

$$Q_B=r\sum_{j=1}^{s}(\bar{X}_{\cdot j}-\bar{X})^2=r\sum_{j=1}^{s}(\beta_j+\bar{\varepsilon}_{\cdot j}-\bar{\varepsilon})^2$$

由于

$$\begin{aligned} E(Q_E)&=E\Big[\sum_{i=1}^{r}\sum_{j=1}^{s}(\varepsilon_{ij}-\bar{\varepsilon}_{i\cdot}-\bar{\varepsilon}_{\cdot j}+\bar{\varepsilon})^2\Big] \\ &=E\Big[\sum_{i=1}^{r}\sum_{j=1}^{s}\varepsilon_{ij}^2-s\sum_{i=1}^{r}\bar{\varepsilon}_{i\cdot}^2-r\sum_{j=1}^{s}\bar{\varepsilon}_{\cdot j}^2+rs\,\bar{\varepsilon}^2\Big] \\ &=rs\sigma^2-r\sigma^2-s\sigma^2+\sigma^2 \\ &=(r-1)(s-1)\sigma^2 \end{aligned}$$

因此

$$\bar{Q}_E=Q_E/[(r-1)(s-1)] \tag{9.2.8}$$

是 σ^2 的无偏估计量.

类似地可以算得

$$\begin{aligned} E(Q_A)&=E\Big[s\sum_{i=1}^{r}(\alpha_i+\bar{\varepsilon}_{i\cdot}-\bar{\varepsilon})^2\Big] \\ &=E\Big[s\sum_{i=1}^{r}\alpha_i^2+s\sum_{i=1}^{r}(\bar{\varepsilon}_{i\cdot}-\bar{\varepsilon})^2+2s\sum_{i=1}^{r}\alpha_i(\bar{\varepsilon}_{i\cdot}-\bar{\varepsilon})\Big] \\ &=s\sum_{i=1}^{r}\alpha_i^2+(r-1)\sigma^2 \end{aligned}$$

同理可得

$$E(Q_B)=r\sum_{j=1}^{s}\beta_j^2+(s-1)\sigma^2$$

令

$$\bar{Q}_A=Q_A/(r-1),\quad \bar{Q}_B=Q_B/(s-1) \tag{9.2.9}$$

则

$$E(\bar{Q}_A)=\sigma^2+\frac{s}{r-1}\sum_{i=1}^{r}\alpha_i^2 \tag{9.2.10}$$

$$E(\bar{Q}_B)=\sigma^2+\frac{r}{s-1}\sum_{j=1}^{s}\beta_j^2 \tag{9.2.11}$$

而

$$E(\bar{Q}_E)=\sigma^2 \tag{9.2.12}$$

构造统计量

$$F_A=\frac{Q_A/(r-1)}{Q_E/[(r-1)(s-1)]}=\frac{\bar{Q}_A}{\bar{Q}_E} \tag{9.2.13}$$

$$F_B=\frac{Q_B/(s-1)}{Q_E/[(r-1)(s-1)]}=\frac{\bar{Q}_B}{\bar{Q}_E} \tag{9.2.14}$$

由(9.2.10)和(9.2.12)式可知,当 H_{01} 不真时,F_A 有偏大的趋势,因而关于 H_{01} 的检验问题,对应的拒绝域形式应取为

$$F_A\geqslant C_1$$

由(9.2.11)和(9.2.12)式可知,当 H_{02} 不真时,F_B 有偏大的趋势,因而关于 H_{02} 的检验问题,对应的拒绝域形式应取为

$$F_B\geqslant C_2$$

不难算得 Q_A,Q_B,Q_E 的自由度依次为 $r-1,s-1,(r-1)(s-1)$,而且,可以证明,当 $H_{01}:\alpha_1=\alpha_2=\cdots=\alpha_r=0$ 为真时,有

$$F_A=\frac{Q_A/(r-1)}{Q_E/[(r-1)(s-1)]}\sim F(r-1,(r-1)(s-1))$$

当 $H_{02}:\beta_1=\beta_2=\cdots=\beta_s=0$ 为真时,有

$$F_B=\frac{Q_B/(s-1)}{Q_E/[(r-1)(s-1)]}\sim F(s-1,(r-1)(s-1))$$

于是,在显著性水平 α 下,关于 H_{01} 检验问题的拒绝域为

$$F_A\geqslant F_\alpha(r-1,(r-1)(s-1)) \tag{9.2.15}$$

在显著性水平 α 下,关于 H_{02} 检验问题的拒绝域为

$$F_B\geqslant F_\alpha(s-1,(r-1)(s-1)) \tag{9.2.16}$$

在具体计算 F_A 与 F_B 的数值时,可把主要结果汇总成下面的双因素方差分析表(见表9.6).

表9.6 双因素方差分析表

方差来源	平方和	自由度	均方	F 值
因素 A	$Q_A=s\sum_{j=1}^{r}(\bar{X}_{i\cdot}-\bar{X})^2$	$r-1$	$\bar{Q}_A=\frac{Q_A}{r-1}$	$F_A=\frac{\bar{Q}_A}{\bar{Q}_E}$
因素 B	$Q_B=r\sum_{j=1}^{s}(\bar{X}_{\cdot j}-\bar{X})^2$	$s-1$	$\bar{Q}_B=\frac{Q_B}{s-1}$	$F_B=\frac{\bar{Q}_B}{\bar{Q}_E}$
误差 E	$Q_E=\sum_{i=1}^{r}\sum_{j=1}^{s}(X_{ij}-\bar{X}_{i\cdot}-\bar{X}_{\cdot j}+\bar{X})^2$	$(r-1)(s-1)$	$\bar{Q}_E=\frac{Q_E}{(r-1)(s-1)}$	
总和	$Q_T=\sum_{i=1}^{r}\sum_{j=1}^{s}(X_{ij}-\bar{X})^2$	$rs-1$		

此检验法的 p 值为 $p_A=P\{F_A\geqslant F_{A0}\}$，$p_B=P\{F_B\geqslant F_{B0}\}$，其中 F_{A0} 是统计量 F_A 的观测值，F_{B0} 是统计量 F_B 的观测值，

$$F_A\sim F(r-1,(r-1)(s-1))$$

$$F_B\sim F(s-1,(r-1)(s-1))$$

方差分析表中各平方和亦可用下面便于编程的方法计算，记

$$S_{i\cdot}=\sum_{j=1}^{s}x_{ij},\quad S_{\cdot j}=\sum_{i=1}^{r}x_{ij}$$

$$SS_{i\cdot}=\sum_{j=1}^{s}x_{ij}^2,\quad SS_{\cdot j}=\sum_{i=1}^{r}x_{ij}^2$$

$$S=\sum_{i=1}^{r}\sum_{j=1}^{s}x_{ij}=\sum_{i=1}^{r}S_{i\cdot}=\sum_{j=1}^{s}S_{\cdot j}$$

$$SS=\sum_{i=1}^{r}\sum_{j=1}^{s}x_{ij}^2=\sum_{i=1}^{r}SS_{i\cdot}=\sum_{j=1}^{s}SS_{\cdot j}$$

则

$$Q_A=\frac{1}{s}\sum_{i=1}^{r}S_{i\cdot}^2-\frac{1}{rs}S^2$$

$$Q_B=\frac{1}{r}\sum_{j=1}^{s}S_{\cdot j}^2-\frac{1}{rs}S^2$$

$$Q_T=SS-\frac{1}{rs}S^2$$

$$\begin{aligned}Q_E&=SS-\frac{1}{s}\sum_{i=1}^{r}S_{i\cdot}^2-\frac{1}{r}\sum_{j=1}^{s}S_{\cdot j}^2+\frac{1}{rs}S^2\\&=Q_T-Q_A-Q_B\end{aligned}$$

例 9.3 车间里有三名工人，有四台不同型号的车床，生产同一品种的产品，现在让每位工人轮流在四台车床上操作，记录其日产量结果如表 9.7 所示. 试问这三位工人技术之间和不同车床型号之间对产量有无显著影响（显著性水平 $\alpha=0.05$）？

表 9.7 某种产品的日产量

车床型号	工人		
	B_1	B_2	B_3
A_1	15	19	16
A_2	17	15	19
A_3	15	18	18
A_4	18	15	17

MATLAB 提供命令 p=anova2(X,reps) 比较双因素方差分析中 X 中两个或多个列（行）的均值是否相等. 不同列的数据表示因素 A 的差异，不同行的数据表示另一因素 B 的差异. 如果行列对有多于一个的观测点，则变量 reps 指出每一单元观测点的数目，每一单元包含 reps 行.

解 Q_A,Q_B,Q_E 以及 F_A,F_B 的计算结果见表 9.8.

对给定的 $\alpha=0.05$，查表得 $F_{0.05}(3,6)=4.76$，$F_{0.05}(2,6)=5.14$，比较 $F_A<4.76$，$F_B<5.14$，所以这三位工人技术之间和不同车床型号之间对生产量都无显著影响.

表 9.8 方差分析表

方差来源	平方和	自由度	均方	F 值
因素 A	$Q_A=0.33$	3	0.11	$F_A=0.03$
因素 B	$Q_B=3.17$	2	1.59	$F_B=0.39$
误差	$Q_E=24.17$	6	4.03	
总和	$Q_T=27.67$	11		

此例检验的 p 值为 $p_A=P\{F_A\geqslant 0.03\}=0.993\ 2>\alpha=0.05$，$p_B=P\{F_B\geqslant 0.39\}=0.691\ 2>\alpha=0.05$，因此，这三位工人技术之间和不同车床型号之间对生产量都无显著影响.

9.2.2 等重复试验

前一段中介绍的双因素方差分析是在每一种组合水平上只做一次试验，这种试验结果只能分析两种因素分别对指标是否有显著影响，而不能分析两种因素的交互作用是否对指标有显著影响.

在多因素方差分析中，通常把因素 A 与因素 B 对试验指标的交互效应设想为某一因素的影响，将该因素记为 $A\times B$，称 $A\times B$ 为因素 A 与 B 的交互作用.要分析交互作用的影响，就要在各组合水平上做重复试验.下面我们要讨论在每一种组合水平上重复试验多次，并且重复试验次数相同的情形.

设有两个因素 A 和 B，其中因素 A 取 r 种水平 $A_1,A_2,\cdots,A_r$，因素 B 取 s 种水平 $B_1,B_2,\cdots,B_s$，在每一种组合 $A_i\times B_j$ 上进行重复试验 l 次（$l\geqslant 2$），其试验结果记为

$$X_{ijk}(i=1,2,\cdots,r;j=1,2,\cdots,s;k=1,2,\cdots,l)$$

为了直观起见，把双因素多水平等重复试验的数据列成表 9.9.

表 9.9 双因素多水平等重复试验数据

因素 A	因素 B			
	B_1	B_2	$\cdots$	B_s
A_1	$X_{111},X_{112},\cdots,X_{11l}$	$X_{121},X_{122},\cdots,X_{12l}$	$\cdots$	$X_{1s1},X_{1s2},\cdots,X_{1sl}$
A_2	$X_{211},X_{212},\cdots,X_{21l}$	$X_{221},X_{222},\cdots,X_{22l}$	$\cdots$	$X_{2s1},X_{2s2},\cdots,X_{2sl}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$
A_r	$X_{r11},X_{r12},\cdots,X_{r1l}$	$X_{r21},X_{r22},\cdots,X_{r2l}$	$\cdots$	$X_{rs1},X_{rs2},\cdots,X_{rsl}$

1. 数学模型

假定总体 X_{ij} 服从正态分布 $N(\mu_{ij},\sigma^2)(i=1,2,\cdots,r;j=1,2,\cdots,s)$，设 $X_{ij1},X_{ij2}\cdots,X_{ijl}$ 为取自 X_{ij} 的样本，且不同总体下的样本之间相互独立.要求检验 $H_0:\mu_{11}=\mu_{12}=\cdots=\mu_{rs}$.

记 $\varepsilon_{ij}=X_{ij}-\mu_{ij}$，则 $\varepsilon_{ij}\sim N(0,\sigma^2)$，于是 $X_{ij}=\mu_{ij}+\varepsilon_{ij}$，其中 $\varepsilon_{ij}\sim N(0,\sigma^2)$.

令 $\varepsilon_{ijk}=X_{ijk}-\mu_{ij}$，则 $\varepsilon_{ijk}\sim N(0,\sigma^2)$ $(k=1,2,\cdots,l)$ 是来自 ε_{ij} 的样本，故各 ε_{ijk} 相互独立 $(i=1,2,\cdots,r;j=1,2,\cdots,s;k=1,2,\cdots,l)$.

再令

$$\mu=\frac{1}{rs}\sum_{i=1}^{r}\sum_{j=1}^{s}\mu_{ij}$$

$$\mu_{i\cdot}=\frac{1}{s}\sum_{j=1}^{s}\mu_{ij},\quad \alpha_i=\mu_{i\cdot}-\mu\quad (i=1,2,\cdots,r)$$

$$\mu_{\cdot j}=\frac{1}{r}\sum_{i=1}^{r}\mu_{ij},\quad \beta_j=\mu_{\cdot j}-\mu\quad (j=1,2,\cdots,s)$$

则有

$$\mu_{ij}=\mu+\alpha_i+\beta_j+\gamma_{ij} \tag{9.2.17}$$

其中

$$\gamma_{ij}=\mu_{ij}-\mu_{i\cdot}-\mu_{\cdot j}+\mu$$

容易验证

$$\sum_{i=1}^{r}\alpha_i=0,\quad \sum_{j=1}^{s}\beta_j=0 \tag{9.2.18}$$

$$\sum_{i=1}^{r}\gamma_{ij}=0(j=1,2,\cdots,s),\ \sum_{j=1}^{s}\gamma_{ij}=0(i=1,2,\cdots,r) \tag{9.2.19}$$

α_i 称为因素 A 的第 i 水平 A_i **对指标的效应**，β_j 称为因素 B 的第 j 水平 B_j **对指标的效应**，γ_{ij} 称为因素 A,B 的组合水平 $A_i\times B_j$ 对指标的**交互效应**.

综合起来，我们可以把等重复试验的双因素方差分析的数学模型改写为

$$\begin{cases}X_{ijk}=\mu+\alpha_i+\beta_j+\gamma_{ij}+\varepsilon_{ijk},\\ \sum\limits_{i=1}^{r}\alpha_i=0,\ \sum\limits_{j=1}^{s}\beta_j=0,\ \sum\limits_{i=1}^{r}\gamma_{ij}=0,\ \sum\limits_{j=1}^{s}\gamma_{ij}=0,\\ \varepsilon_{ijk}\sim N(0,\sigma^2)\ (i=1,2,\cdots,r;j=1,2,\cdots,s;k=1,2,\cdots,l),\text{其中各 }\varepsilon_{ijk}\text{ 相互独立}\end{cases} \tag{9.2.20}$$

要求检验

$$H_{01}:\alpha_1=\alpha_2=\cdots=\alpha_r=0$$

$$H_{02}:\beta_1=\beta_2=\cdots=\beta_s=0$$

$$H_{03}:\gamma_{11}=\gamma_{12}=\cdots=\gamma_{rs}=0$$

为讨论方便起见，引入以下记号：令

$\bar{\varepsilon}_{ij\cdot}=\dfrac{1}{l}\sum\limits_{k=1}^{l}\varepsilon_{ijk}$，则 $\bar{\varepsilon}_{ij\cdot}\sim N\left(0,\dfrac{\sigma^2}{l}\right)$ $(i=1,2,\cdots,r;j=1,2,\cdots,s)$；

$\bar{\varepsilon}=\dfrac{1}{rsl}\sum\limits_{i=1}^{r}\sum\limits_{j=1}^{s}\sum\limits_{k=1}^{l}\varepsilon_{ijk}$，则 $\bar{\varepsilon}\sim N\left(0,\dfrac{\sigma^2}{rsl}\right)$；

$\bar{\varepsilon}_{i\cdot\cdot}=\dfrac{1}{sl}\sum\limits_{j=1}^{s}\sum\limits_{k=1}^{l}\varepsilon_{ijk}$，则 $\bar{\varepsilon}_{i\cdot\cdot}\sim N\left(0,\dfrac{\sigma^2}{sl}\right)$ $(i=1,2,\cdots,r)$；

$\bar{\varepsilon}_{\cdot j\cdot}=\dfrac{1}{rl}\sum\limits_{i=1}^{r}\sum\limits_{k=1}^{l}\varepsilon_{ijk}$，则 $\bar{\varepsilon}_{\cdot j\cdot}\sim N\left(0,\dfrac{\sigma^2}{rl}\right)$ $(j=1,2,\cdots,s)$；

$\overline{X}_{ij\cdot}=\dfrac{1}{l}\sum_{k=1}^{l}X_{ijk}$，则 $\overline{X}_{ij\cdot}=\mu+\alpha_i+\beta_j+\gamma_{ij}+\overline{\varepsilon}_{ij\cdot}$（$i=1,2,\cdots,r;j=1,2,\cdots,s$）；

$\overline{X}=\dfrac{1}{rsl}\sum_{i=1}^{r}\sum_{j=1}^{s}\sum_{k=1}^{l}X_{ijk}$，则 $\overline{X}=\mu+\overline{\varepsilon}$；

$\overline{X}_{i\cdot\cdot}=\dfrac{1}{sl}\sum_{j=1}^{s}\sum_{k=1}^{l}X_{ijk}$，则 $\overline{X}_{i\cdot\cdot}=\mu+\alpha_i+\overline{\varepsilon}_{i\cdot\cdot}$（$i=1,2,\cdots,r$）；

$\overline{X}_{\cdot j\cdot}=\dfrac{1}{rl}\sum_{i=1}^{r}\sum_{k=1}^{l}X_{ijk}$，则 $\overline{X}_{\cdot j\cdot}=\mu+\beta_j+\overline{\varepsilon}_{\cdot j\cdot}$（$j=1,2,\cdots,s$）.

2. 统计分析

导出检验假设 H_{01},H_{02},H_{03} 的方法与 9.2.1 节中的类似，也是把总平方和 Q_T 进行分解

$$\begin{aligned}Q_T&=\sum_{i=1}^{r}\sum_{j=1}^{s}\sum_{k=1}^{l}(X_{ijk}-\overline{X})^2\\&=\sum_{i=1}^{r}\sum_{j=1}^{s}\sum_{k=1}^{l}[(\overline{X}_{i\cdot\cdot}-\overline{X})+(\overline{X}_{\cdot j\cdot}-\overline{X})+\\&\quad(\overline{X}_{ij\cdot}-\overline{X}_{i\cdot\cdot}-\overline{X}_{\cdot j\cdot}+\overline{X})+(X_{ijk}-\overline{X}_{ij\cdot})]^2\\&=Q_A+Q_B+Q_I+Q_E\end{aligned}\tag{9.2.21}$$

其中

$$Q_A=sl\sum_{i=1}^{r}(\overline{X}_{i\cdot\cdot}-\overline{X})^2=sl\sum_{i=1}^{r}(\alpha_i+\overline{\varepsilon}_{i\cdot\cdot}-\overline{\varepsilon})^2$$

$$Q_B=rl\sum_{j=1}^{s}(\overline{X}_{\cdot j\cdot}-\overline{X})^2=rl\sum_{j=1}^{s}(\beta_j+\overline{\varepsilon}_{\cdot j\cdot}-\overline{\varepsilon})^2$$

$$\begin{aligned}Q_I&=l\sum_{i=1}^{r}\sum_{j=1}^{s}(\overline{X}_{ij\cdot}-\overline{X}_{i\cdot\cdot}-\overline{X}_{\cdot j\cdot}+\overline{X})^2\\&=l\sum_{i=1}^{r}\sum_{j=1}^{s}(\gamma_{ij}+\overline{\varepsilon}_{ij\cdot}-\overline{\varepsilon}_{i\cdot\cdot}-\overline{\varepsilon}_{\cdot j\cdot}+\overline{\varepsilon})^2\end{aligned}$$

$$Q_E=\sum_{i=1}^{r}\sum_{j=1}^{s}\sum_{k=1}^{l}(X_{ijk}-\overline{X}_{ij\cdot})^2=\sum_{i=1}^{r}\sum_{j=1}^{s}\sum_{k=1}^{l}(\varepsilon_{ijk}-\overline{\varepsilon}_{ij\cdot})^2$$

由于

$$\begin{aligned}E(Q_E)&=\sum_{i=1}^{r}\sum_{j=1}^{s}E[\sum_{k=1}^{l}(\varepsilon_{ijk}-\overline{\varepsilon}_{ij\cdot})^2]=\sum_{i=1}^{r}\sum_{j=1}^{s}(l-1)\sigma^2\\&=rs(l-1)\sigma^2\end{aligned}$$

类似地可以算得

$$E(Q_A)=(r-1)\sigma^2+sl\sum_{i=1}^{r}\alpha_i^2$$

$$E(Q_B)=(s-1)\sigma^2+rl\sum_{j=1}^{s}\beta_j^2$$

$$E(Q_I)=(r-1)(s-1)\sigma^2+l\sum_{i=1}^{r}\sum_{j=1}^{s}\gamma_{ij}^2$$

于是

$$\begin{cases} E\left(\dfrac{Q_E}{rs(l-1)}\right)=\sigma^2, \\ E\left(\dfrac{Q_A}{r-1}\right)=\sigma^2+\dfrac{sl}{r-1}\sum\limits_{i=1}^{r}\alpha_i^2, \\ E\left(\dfrac{Q_B}{s-1}\right)=\sigma^2+\dfrac{rl}{s-1}\sum\limits_{j=1}^{s}\beta_j^2, \\ E\left(\dfrac{Q_I}{(r-1)(s-1)}\right)=\sigma^2+\dfrac{l}{(r-1)(s-1)}\sum\limits_{i=1}^{r}\sum\limits_{j=1}^{s}\gamma_{ij}^2 \end{cases} \tag{9.2.22}$$

构造统计量

$$F_A=\frac{Q_A/(r-1)}{Q_E/[rs(l-1)]} \tag{9.2.23}$$

$$F_B=\frac{Q_B/(s-1)}{Q_E/[rs(l-1)]} \tag{9.2.24}$$

$$F_I=\frac{Q_I/(r-1)(s-1)}{Q_E/[rs(l-1)]} \tag{9.2.25}$$

由(9.2.22)式可以看出:当 H_{01} 不真时,统计量 F_A 有偏大的倾向,因而作为关于 H_{01} 检验问题的统计量,其拒绝域形式应取为

$$F_A\geqslant C_1$$

当 H_{02} 不真时,统计量 F_B 有偏大的倾向,因而作为关于 H_{02} 检验问题的统计量,其拒绝域形式应取为

$$F_B\geqslant C_2$$

当 H_{03} 不真时,统计量 F_I 有偏大的倾向,因而作为关于 H_{03} 检验问题的统计量,其拒绝域形式应取为

$$F_I\geqslant C_3$$

可以证明:当 H_{01} 为真时

$$F_A=\frac{Q_A/(r-1)}{Q_E/[rs(l-1)]}\sim F(r-1,rs(l-1))$$

当 H_{02} 为真时

$$F_B=\frac{Q_B/(S-1)}{Q_E/[rs(l-1)]}\sim F(s-1,rs(l-1))$$

当 H_{03} 为真时

$$F_I=\frac{Q_I/[(r-1)(s-1)]}{Q_E/[rs(l-1)]}\sim F((r-1)(s-1),rs(l-1))$$

对于给定的显著性水平 α,关于 H_{01},H_{02},H_{03} 检验问题的临界值分别为 $C_1=F_\alpha(r-1,rs(l-1))$,$C_2=F_\alpha(s-1,rs(l-1))$,$C_3=F_\alpha((r-1)(s-1),rs(l-1))$.于是,由一次抽样后所得的样本值算得 F_A,F_B,F_I 的数值,若

$$F_A\geqslant F_\alpha(r-1,rs(l-1))$$

则拒绝 H_{01},认为因素 A 对指标有显著影响;否则,接受 H_{01},认为因素 A 对指标无显

著影响.若

$$F_B \geqslant F_\alpha(s-1, rs(l-1))$$

则拒绝 H_{02},认为因素 B 对指标有显著影响;否则,接受 H_{02},认为因素 B 对指标无显著影响.若

$$F_I \geqslant F_\alpha((r-1)(s-1), rs(l-1))$$

则拒绝 H_{03},认为因素 A 与 B 的交互作用对指标有显著影响,否则,接受 H_{03},认为因素 A 与 B 的交互作用对指标无显著影响.

通常把计算出来的各主要结果汇总成下面的双因素等重复试验方差分析表(见表 9.10),其中 Q_A, Q_B, Q_I, Q_E, Q_T 也可以用如下的便于编程的公式计算.令

$$S_{ij\cdot} = \sum_{k=1}^{l} x_{ijk}, \quad S_{i\cdot\cdot} = \sum_{j=1}^{s}\sum_{k=1}^{l} x_{ijk}, \quad S_{\cdot j\cdot} = \sum_{i=1}^{r}\sum_{k=1}^{l} x_{ijk}$$

$$S = \sum_{i=1}^{r}\sum_{j=1}^{s}\sum_{k=1}^{l} x_{ijk}, \quad SS = \sum_{i=1}^{r}\sum_{j=1}^{s}\sum_{k=1}^{l} x_{ijk}^2$$

则

$$Q_A = \frac{1}{sl}\sum_{i=1}^{r} S_{i\cdot\cdot}^2 - \frac{1}{rsl}S^2$$

$$Q_B = \frac{1}{rl}\sum_{j=1}^{s} S_{\cdot j\cdot}^2 - \frac{1}{rsl}S^2$$

$$\begin{aligned} Q_I &= \frac{1}{l}\sum_{i=1}^{r}\sum_{j=1}^{s} S_{ij\cdot}^2 - \frac{1}{sl}\sum_{i=1}^{r} S_{i\cdot\cdot}^2 - \frac{1}{rl}\sum_{j=1}^{s} S_{\cdot j\cdot}^2 + \frac{1}{rsl}S^2 \\ &= Q_T - (Q_A + Q_B + Q_E) \end{aligned}$$

$$Q_E = SS - \frac{1}{l}\sum_{i=1}^{r}\sum_{j=1}^{s} S_{ij\cdot}^2$$

$$Q_T = SS - \frac{1}{rsl}S^2$$

表 9.10 双因素等重复试验方差分析表

方差来源	平方和	自由度	均方	F 值
因素 A	$Q_A = sl\sum_{i=1}^{r}(\bar{X}_{i\cdot\cdot} - \bar{X})^2$	$r-1$	$\bar{Q}_A = \frac{Q_A}{r-1}$	$F_A = \frac{\bar{Q}_A}{\bar{Q}_E}$
因素 B	$Q_B = rl\sum_{j=1}^{s}(\bar{X}_{\cdot j\cdot} - \bar{X})^2$	$s-1$	$\bar{Q}_B = \frac{Q_B}{s-1}$	$F_B = \frac{\bar{Q}_B}{\bar{Q}_E}$
交互作用 $A\times B$	$Q_I = l\sum_{i=1}^{r}\sum_{j=1}^{s}(\bar{X}_{ij\cdot} - \bar{X}_{i\cdot\cdot} - \bar{X}_{\cdot j\cdot} + \bar{X})^2$	$(r-1)(s-1)$	$\bar{Q}_I = \frac{Q_I}{(r-1)(s-1)}$	$F_I = \frac{\bar{Q}_I}{\bar{Q}_E}$
误差 E	$Q_E = \sum_{i=1}^{r}\sum_{j=1}^{s}\sum_{k=1}^{l}(X_{ijk} - \bar{X}_{ij\cdot})^2$	$rs(l-1)$	$\bar{Q}_E = \frac{Q_E}{rs(l-1)}$	
总和	$Q_T = \sum_{i=1}^{r}\sum_{j=1}^{s}\sum_{k=1}^{l}(X_{ijk} - \bar{X})^2$	$rsl-1$		

此检验法的 p 值为 $p_A=P\{F_A\geqslant F_{A0}\}$，$p_B=P\{F_B\geqslant F_{B0}\}$，$p_I=P\{F_I\geqslant F_{I0}\}$，其中 F_{A0} 是检验统计量 F_A 的观测值，F_{B0} 是检验统计量 F_B 的观测值，F_{I0} 是检验统计量 F_I 的观测值，$F_A\sim F(r-1,rs(l-1))$，$F_B\sim F(s-1,rs(l-1))$，$F_I\sim F((r-1)(s-1),rs(l-1))$.

例 9.4　设例 9.3 中让每位工人轮流在四台车床上操作三天，记录三天的日产量结果如表 9.11 所示. 在显著性水平 $\alpha=0.05$ 下检验这三位工人技术之间的差异是否显著？不同型号的车床之间的差异是否显著？交互影响是否显著？

表 9.11　某种产品的日产量

车床型号	工人								
	B_1			B_2			B_3		
A_1	15	15	17	19	19	16	16	18	21
A_2	17	17	17	15	15	15	19	22	22
A_3	15	17	16	18	17	16	18	18	18
A_4	18	20	22	15	16	17	17	17	17

解　Q_A,Q_B,Q_I,Q_E 以及 F_A,F_B,F_I 的计算结果见表 9.12.

表 9.12　双因素等重复试验方差分析表

方差来源	平方和	自由度	均方	F 值
因素 A	$Q_A=2.75$	3	0.92	$F_A=0.53$
因素 B	$Q_B=27.17$	2	13.59	$F_B=7.90$
交互作用 $A\times B$	$Q_I=73.5$	6	12.25	$F_I=7.12$
误差 E	$Q_E=41.33$	24	1.72	
总和	$Q_T=144.75$	35		

对给定的水平 $\alpha=0.05$，查表得 $F_{0.05}(3,24)=3.01$，$F_{0.05}(2,24)=3.40$，$F_{0.05}(6,24)=2.51$，因

$$F_A<3.01,\quad F_B>3.40,\quad F_I>2.51$$

所以，不同型号的车床之间无显著差异，而三位工人的技术之间的差异以及交互作用的影响都是显著的.

此例检验的 p 值为 $p_A=P\{F_A\geqslant 0.53\}=0.666\,0$，$p_B=P\{F_B\geqslant 7.90\}=0.023$，$p_I=P\{F_I\geqslant 7.12\}=0.000\,2$，因为 $p_A=0.666\,0>\alpha=0.05$，$p_B=0.002\,3<\alpha=0.05$，$p_I=0.000\,2<\alpha=0.05$，所以，不同型号的车床之间无显著差异，而三位工人的技术之间的差异及交互作用的影响都是显著的.

内容小结

统计学上把要考察的指标称为试验指标，影响试验指标的条件称为因素或因子，因素的不同状态称为水平. 在单因素试验下进行的方差分析称为单因素方差分析.

单因素方差分析模型为

$$\begin{cases} X_{ij}=\mu+\delta_i+\varepsilon_{ij} \quad (j=1,2,\cdots,n_i;i=1,2,\cdots,r), \\ \sum\limits_{i=1}^{r} n_i\delta_i=0, \\ \varepsilon_{ij}\sim N(0,\sigma^2),\text{诸 }\varepsilon_{ij}\text{相互独立} \end{cases}$$

其中 μ 是总平均，δ_i 称为因素 A 的第 i 个水平 A_i 的效应.

非重复试验的双因素方差分析模型为

$$\begin{cases} X_{ij}=\mu+\alpha_i+\beta_j+\varepsilon_{ij},(i=1,2,\cdots,r;j=1,2,\cdots,s) \\ \sum\limits_{i=1}^{r}\alpha_i=0, \quad \sum\limits_{j=1}^{s}\beta_j=0, \\ \varepsilon_{ij}\sim N(0,\sigma^2),\text{诸 }\varepsilon_{ij}\text{相互独立} \end{cases}$$

等重复试验的双因素方差分析模型为

$$\begin{cases} X_{ijk}=\mu+\alpha_i+\beta_j+\gamma_{ij}+\varepsilon_{ijk},(i=1,2,\cdots,r;j=1,2,\cdots,s;k=1,2,\cdots,l) \\ \sum\limits_{i=1}^{r}\alpha_i=0, \quad \sum\limits_{j=1}^{s}\beta_j=0, \ \sum\limits_{i=1}^{r}\gamma_{ij}=\sum\limits_{j=1}^{s}\gamma_{ij}=0, \\ \varepsilon_{ijk}\sim N(0,\sigma^2),\text{诸 }\varepsilon_{ij}\text{相互独立} \end{cases}$$

习题9

1. 某钢厂检查一月上旬内的五天中生产的钢锭质量，结果如下(单位:kg)：

日期	质量/kg			
1	5 500	5 800	5 740	5 710
2	5 440	5 680	5 240	5 600
4	5 400	5 410	5 430	5 400
9	5 640	5 700	5 660	5 700
10	5 610	5 700	5 610	5 400

设各日所生产的钢锭质量服从同方差的正态分布.试检验不同日期生产的钢锭的平均质量有无显著差异($\alpha=0.05$)？

2. 考察四种不同催化剂对某一化工产品的得率的影响，在四种不同催化剂下分别做试验得如下数据：

催化剂	得率						n_i
1	0.88	0.85	0.79	0.86	0.85	0.83	6
2	0.87	0.92	0.85	0.83	0.90		5
3	0.84	0.78	0.81				3
4	0.81	0.86	0.90	0.87			4

设在各种催化剂下得率服从同方差的正态分布.试检验在四种不同催化剂下平均得率有无显著差异($\alpha = 0.05$)?

3. 抽查某地区三所小学五年级男学生的身高,得数据如下:

小学	身高数据/cm					
第一小学	128.1	134.1	133.1	138.9	140.8	127.4
第二小学	150.3	147.9	136.8	126.0	150.7	155.8
第三小学	140.6	143.1	144.5	143.7	148.5	146.4

设各小学五年级男学生的身高服从同方差的正态分布.

(1) 试问该地区三所小学五年级男学生的平均身高是否有显著差异($\alpha = 0.05$)?

(2) 试分别求这三所小学五年级男学生的平均身高及方差的点估计值.

4. 将抗生素注入人体会产生抗生素与血浆蛋白质结合的现象,以致减少了药效.下表列出了 5 种常用的抗生素注入牛的体内时,抗生素与血浆蛋白质结合的百分比:

抗生素	青霉素	四环素	链霉素	红霉素	氯霉素
抗生素与血浆蛋白结合的百分比/%	29.6	27.3	5.8	21.6	29.2
	24.3	32.6	6.2	17.4	32.8
	28.5	30.8	11.0	18.3	25.0
	32.0	34.8	8.3	19.0	24.2

设各种抗生素与血浆蛋白质结合的百分比服从正态分布,且方差相同.

(1) 试在水平 $\alpha = 0.05$ 下检验这些抗生素与血浆蛋白质结合的百分比的均值有无显著差异?

(2) 求这 5 种抗生素与血浆蛋白质结合的百分比的均值的置信区间,以及青霉素与链霉素的均值差的置信区间,红霉素与氯霉素的均值差的置信区间(置信度为 0.95).

5. 在某种橡胶的配方中,考虑了 3 种不同的促进剂,4 种不同分量的氧化锌.各种配方试验一次,测得 300%定伸强度如下:

促进剂 A	氧化锌 B			
	B_1	B_2	B_3	B_4
A_1	32	35	35.5	38.5
A_2	33.5	36.5	38	39.5
A_3	36	37.5	39.5	43

假定各种配方的定伸强度服从同方差的正态分布.试问不同促进剂、不同分量氧化锌分别对定伸强度有无显著影响($\alpha = 0.05$)?

6. 对 4 张钛合金材料的两边 S_1 和 S_2、角 CO 和中心 CE 部分测量其抗拉强度(单位:kg/mm^2),结果如下表:

部位	材料			
	1	2	3	4
CO	137.1	142.2	128.0	136.6
CE	140.1	139.4	116.8	136.5
S_1	141.8	139.6	132.5	140.8
S_2	136.1	140.8	132.2	129.0

假定在诸水平搭配下抗拉强度的总体服从正态分布,且方差相等.试检验各张材料之间及每张材料的不同部位之间的抗拉强度有无显著差别($\alpha = 0.05$)?

7. 下表给出某种化工过程在三种浓度、四种温度水平下得率的数据:

浓度/%	温度/℃			
	10	24	33	52
2	14 10	11 11	13 9	10 12
4	9 7	10 8	7 11	6 10
6	5 11	13 14	12 13	14 10

假定在诸水平搭配下得率的总体服从正态分布且方差相等.试在显著性水平 $\alpha = 0.05$ 下检验:在不同浓度下得率有无显著差异;在不同温度下得率是否有显著差异;交互作用的效应是否显著.

8. 为考察合成纤维中对纤维弹性有影响的2个因素:收缩率 A 和总拉伸倍数 B.现就 A 和 B 各取4种水平做试验,整个试验重复一次,试验结果如下:

因素 A	因素 B			
	460	520	580	640
0	71 73	72 73	75 73	77 75
4	73 75	76 74	78 77	74 74
8	76 73	79 77	74 75	74 73
12	75 73	73 72	70 71	69 69

假定在各水平搭配下各总体服从正态分布,且方差相等.试问收缩率和总拉伸倍数分别对纤维弹性有无显著影响?并问两者对纤维弹性有无显著交互作用($\alpha = 0.05$)?

自测题 9

习题 9 参考答案

第10章 回归分析

回归分析是研究变量之间相关关系的一种数理统计方法.本章主要介绍线性回归,其中包括回归分析中的参数估计、假设检验以及预测等方面的内容.

10.1 一元线性回归

客观事物之间总是相互联系、相互制约的,而且每一事物的运动都与它周围的其他事物相互联系着、相互影响着,从而它们之间存在着某种关系.通过大量实践,人们发现在客观世界中变量之间的关系可以分为两种类型:一种类型是变量之间存在着确定性关系,例如,物体做自由落体运动时路程与时间的关系是 $h=\frac{1}{2}gt^2$;当电压一定时,电路中的电流 I 与电阻 R 的关系为 $I=V/R$;当一定质量的气体的温度不变时,气体的压强 p 和体积 V 的关系为 $pV=C$,其中 C 为常量,它由气体的质量与温度来决定.变量之间的这种确定性关系也就是高等数学所研究的函数关系.另一种类型是变量之间存在着非确定性关系,例如,子辈的身高与父辈的身高之间存在关系,一般来说,父辈的身高越高,其子辈的身高也越高,但是对于两个身高相同的人,他们下一代的身高却未必相同;鱼塘的产鱼量与当初鱼苗的投放量之间存在着关系,然而在其他外部条件(鱼塘面积、水质、养殖水平、饵料)基本相同的情况下,相同的鱼苗投放量未必能得到相同的产鱼量;毕业生在校期间所学课程的总成绩与入学考试的总成绩之间的关系也是这样.上面所说的变量关系是非确定性的,其特点表现为:一方面变量之间有某种联系,另一方面这种联系又不同于函数关系,当自变量取定某值时,因变量的取值带有随机性,是不确定的.这是因为在这类非确定性关系中,作为"因变量"的变量都是随机变量.

拓展阅读:关于回归的故事

变量间的这种非确定性关系称为相关关系.相关关系是多种多样的.在变量的相关关系中,如果自变量是可以测量和控制的非随机变量(简称可控变量),而与之相关的因变量是随机变量,那么,对这种相关关系的函数处理就叫做**回归分析**.如果自变量也是随机变量或不可控变量,那么,对这种相关关系的函数处理叫做**相关分析**.

10.1.1 一元线性回归模型

设 x 为可控变量,Y 为与之相关的随机变量.当自变量 x 取确定值时,Y 有一确定的(条件)分布与之对应.如果 Y 的数学期望存在,那么其取值随 x 的取值而定,因而它是 x 的函数,记为 $\mu(x)$,即

$$\mu(x)=E(Y|x)$$

通常称 $\mu(x)$ 为 Y 关于 x 的回归函数.

回归分析的基本任务是利用试验数据来估计 Y 关于 x 的回归函数 $\mu(x)$.为此,首先需要推测 $\mu(x)$ 的形式.在有些实际问题中,我们可以由专业知识来假定 $\mu(x)$ 的形式,否则,我们可以这样做:对 x 取定的一组不全相同的值 $x_1,x_2,\cdots,x_n$,作 n 次独立试验得到 n 对试验数据:

$$(x_1,y_1),(x_2,y_2),\cdots,(x_n,y_n)$$

把每对数据(x_i,y_i)在直角坐标系中描出它的相应点(如例 10.1 中的图 10.1),这种图称为散点图.根据散点图来推测$\mu(x)$的形式.

例 10.1 为研究质量 x(单位:g)对弹簧长度 Y(单位:cm)的影响,对不同质量下的 6 根弹簧进行测量,得如下数据:

质量 x/g	5	10	15	20	25	30
长度 Y/cm	7.25	8.12	8.95	9.90	10.90	11.80

这里 x 是可控变量,Y 是随机变量.画出的散点图如图 10.1 所示,由图大致可以推测$\mu(x)$具有线性函数的形式.

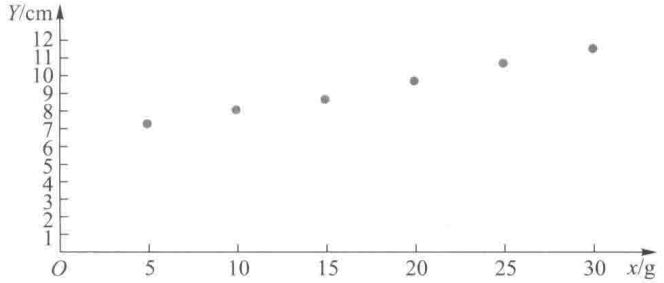

图 10.1

设 Y 关于 x 的回归函数为$\mu(x)$,若$\mu(x)$为线性函数$\mu(x)=a+bx$,此时估计$\mu(x)$的问题称为求一元线性回归问题.下面我们就来讨论这个问题.

设 x 是可控变量,Y 是依赖于 x 的随机变量,假定

$$\begin{cases} Y=a+bx+\varepsilon, \\ \varepsilon\sim N(0,\sigma^2) \end{cases} \tag{10.1.1}$$

其中未知参数 a,b 及 σ^2 都不依赖于 x,(10.1.1)式称为**一元线性回归模型**.

当给定 x 一组不完全相同的值 $x_1,x_2,\cdots,x_n$ 时,对 Y 分别在 $x_1,x_2,\cdots,x_n$ 处进行独立观测,其观测结果记为 $Y_1,Y_2,\cdots,Y_n$,则 $Y_1,Y_2,\cdots,Y_n$ 是相互独立的随机变量,但一般未必服从相同分布,为方便计,我们称

$$(x_1,Y_1),(x_2,Y_2),\cdots,(x_n,Y_n)$$

是模型(10.1.1)的一个样本,相应的样本值记为

$$(x_1,y_1),(x_2,y_2),\cdots,(x_n,y_n)$$

此时,由模型(10.1.1)有

$$\begin{cases} Y_i=a+bx_i+\varepsilon_i, \\ \varepsilon_i\sim N(0,\sigma^2) \quad (i=1,2,\cdots,n),\text{且 } \varepsilon_1,\varepsilon_2,\cdots,\varepsilon_n \text{ 相互独立} \end{cases} \tag{10.1.2}$$

(10.1.2)式称为**一元线性回归模型(10.1.1)的样本形式**,常常也简称为**一元线性回归模型**.

如果由$(x_i,y_i)(i=1,2,\cdots,n)$得到了(10.1.1)式中的未知参数 a,b 的估计值 $\hat{a}$,$\hat{b}$,那么,对于给定的 x,我们可取 $\hat{y}=\hat{a}+\hat{b}x$ 作为$\mu(x)=a+bx$ 的估计值,而方程

$$\hat{y}=\hat{a}+\hat{b}x$$

称为 Y 关于 x 的**经验回归直线方程**，它可作为理论回归直线 $y=a+bx$ 的估计，其中 $\hat{b}$ 称为经验回归系数.

10.1.2 a,b 和 σ^2 的估计

已知变量 x,Y 的 n 对试验数据 $(x_i,y_i)(i=1,2,\cdots,n)$，其中 x_i 不全相同，作离差平方和

$$Q(a,b)=\sum_{i=1}^{n}(y_i-a-bx_i)^2 \tag{10.1.3}$$

选择参数 a,b 使 $Q(a,b)$ 最小，这种方法叫做**最小二乘法**.

为此，取 Q 分别关于 a,b 的一阶偏导，并令它们等于零：

$$\begin{cases}\dfrac{\partial Q}{\partial a}=-2\sum\limits_{i=1}^{n}(y_i-a-bx_i)=0,\\[2ex] \dfrac{\partial Q}{\partial b}=-2\sum\limits_{i=1}^{n}(y_i-a-bx_i)x_i=0\end{cases} \tag{10.1.4}$$

得方程组

$$\begin{cases}na+b\sum\limits_{i=1}^{n}x_i=\sum\limits_{i=1}^{n}y_i,\\[2ex] a\sum\limits_{i=1}^{n}x_i+b\sum\limits_{i=1}^{n}x_i^2=\sum\limits_{i=1}^{n}x_iy_i\end{cases} \tag{10.1.5}$$

(10.1.5)式称为**正规方程组**.

因为 x_i 不全相同，正规方程组的系数行列式

$$\begin{vmatrix} n & \sum\limits_{i=1}^{n}x_i \\ \sum\limits_{i=1}^{n}x_i & \sum\limits_{i=1}^{n}x_i^2 \end{vmatrix}=n\sum_{i=1}^{n}x_i^2-\Big(\sum_{i=1}^{n}x_i\Big)^2=n\sum_{i=1}^{n}(x_i-\bar{x})^2\neq 0$$

所以(10.1.5)式有唯一的一组解，解得 a,b 的估计值为

$$\hat{b}=\frac{n\sum\limits_{i=1}^{n}x_iy_i-\Big(\sum\limits_{i=1}^{n}x_i\Big)\Big(\sum\limits_{i=1}^{n}y_i\Big)}{n\sum\limits_{i=1}^{n}x_i^2-\Big(\sum\limits_{i=1}^{n}x_i\Big)^2}=\frac{\sum\limits_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})}{\sum\limits_{i=1}^{n}(x_i-\bar{x})^2} \tag{10.1.6}$$

$$\hat{a}=\bar{y}-\hat{b}\bar{x} \tag{10.1.7}$$

其中 $\bar{x}=\dfrac{1}{n}\sum\limits_{i=1}^{n}x_i,\bar{y}=\dfrac{1}{n}\sum\limits_{i=1}^{n}y_i$.

于是，所求的经验回归直线方程为

$$\hat{y}=\hat{a}+\hat{b}x \tag{10.1.8}$$

若把 $\hat{a}=\bar{y}-\hat{b}\bar{x}$ 代入(10.1.8)式，则经验回归直线方程为

$$\hat{y}=\bar{y}+\hat{b}(x-\bar{x}) \tag{10.1.9}$$

(10.1.9)式表明经验回归直线过散点图的几何中心$(\bar{x},\bar{y})$.

下面我们来求σ^2的估计,为此,记

$$\hat{y}_i=\hat{a}+\hat{b}x_i \quad (i=1,2,\cdots,n)$$

则$y_i-\hat{y}_i$称为x_i处的**残差**,平方和

$$Q_e=\sum_{i=1}^{n}(y_i-\hat{y}_i)^2=\sum_{i=1}^{n}(y_i-\hat{a}-\hat{b}x_i)^2 \tag{10.1.10}$$

称为**残差平方和**.事实上,残差平方和Q_e就是把$\hat{a},\hat{b}$代入到(10.1.3)式的结果,因此$Q_e=Q_{\min}$.

我们用

$$\hat{\sigma^2}=\frac{Q_e}{n-2}=\frac{1}{n-2}\sum_{i=1}^{n}(y_i-\hat{a}-\hat{b}x_i)^2 \tag{10.1.11}$$

作为σ^2的估计值.

为了便于计算$\hat{\sigma^2}$,下面导出它的另一种表达形式.由(10.1.9)式,有

$$\begin{aligned}
Q_e&=\sum_{i=1}^{n}(y_i-\hat{y}_i)^2\\
&=\sum_{i=1}^{n}[y_i-\bar{y}-\hat{b}(x_i-\bar{x})]^2\\
&=\sum_{i=1}^{n}(y_i-\bar{y})^2-2\hat{b}\sum_{i=1}^{n}(y_i-\bar{y})(x_i-\bar{x})+\hat{b}^2\sum_{i=1}^{n}(x_i-\bar{x})^2\\
&=\sum_{i=1}^{n}(y_i-\bar{y})^2-\hat{b}^2\sum_{i=1}^{n}(x_i-\bar{x})^2
\end{aligned}$$

即得

$$Q_e=\sum_{i=1}^{n}(y_i-\bar{y})^2-\hat{b}^2\sum_{i=1}^{n}(x_i-\bar{x})^2 \tag{10.1.12}$$

于是

$$\hat{\sigma^2}=\frac{1}{n-2}Q_e=\frac{1}{n-2}\sum_{i=1}^{n}(y_i-\bar{y})^2-\frac{\hat{b}^2}{n-2}\sum_{i=1}^{n}(x_i-\bar{x})^2 \tag{10.1.13}$$

例10.2(续例10.1) 设例10.1中的随机变量Y与可控变量x之间的关系符合(10.1.2)式所述的条件.求Y关于x的经验回归直线方程,并计算σ^2的估计值$\hat{\sigma^2}$.

解 按题意$n=6$,计算可得

$$\sum_{i=1}^{6}x_i=105,\quad \sum_{i=1}^{6}x_i^2=2\,275$$

$$\sum_{i=1}^{6}y_i=56.92,\quad \sum_{i=1}^{6}y_i^2=554.659$$

$$\sum_{i=1}^{6}x_iy_i=1\,076.2$$

因而由(10.1.6),(10.1.7)两式,得

MATLAB提供命令[B,BINT,R,RINT,STATS]=regress(Y,X,ALPHA)计算对向量X与Y进行的回归分析,α是显著性水平(缺省为默认值0.05).B是参数的估计值,是列向量,BINT是回归系数的置信区间,R是残差,RINT是残差的置信区间,STATS是用于检验回归模型的统计量,有4个数值:复相关系数R^2,F统计量观测值,检验的p值,误差方差的估计.

$$\hat{b}=\frac{6\times 1\,076.2-105\times 56.92}{6\times 2\,275-105^2}=0.183$$

$$\hat{a}=\frac{1}{6}\times 56.92-\frac{1}{6}\times 105\times 0.183=6.284$$

于是得到经验回归直线方程

$$\hat{y}=6.284+0.183x$$

利用(10.1.13)式,并注意到

$$\sum_{i=1}^{n}(x_i-\bar{x})^2=\sum_{i=1}^{n}x_i^2-n\bar{x}^2=\sum_{i=1}^{n}x_i^2-\frac{1}{n}\left(\sum_{i=1}^{n}x_i\right)^2$$

$$\sum_{i=1}^{n}(y_i-\bar{y})^2=\sum_{i=1}^{n}y_i^2-n\bar{y}^2=\sum_{i=1}^{n}y_i^2-\frac{1}{n}\left(\sum_{i=1}^{n}y_i\right)^2$$

于是

$$\hat{\sigma^2}=\frac{1}{4}\left[554.659-\frac{1}{6}\times 56.92^2-0.183^2\times\left(2\,275-\frac{1}{6}\times 105^2\right)\right]$$

$$=0.007$$

若将(10.1.6),(10.1.7),(10.1.10),(10.1.11)式中的样本值 $y_1,y_2,\cdots,y_n$ 换成随机样本 $Y_1,Y_2,\cdots,Y_n$,并记

$$l_{xx}=\sum_{i=1}^{n}(x_i-\bar{x})^2 \tag{10.1.14}$$

则得到 a,b,σ^2 的估计量和 Q_e 相应的统计量,仍记为 $\hat{a},\hat{b},\hat{\sigma^2}$ 和 Q_e.

$$\hat{b}=\frac{1}{l_{xx}}\sum_{i=1}^{n}(x_i-\bar{x})(Y_i-\bar{Y}) \tag{10.1.6}'$$

$$\hat{a}=\bar{Y}-\hat{b}\bar{x} \tag{10.1.7}'$$

$$Q_e=\sum_{i=1}^{n}(Y_i-\hat{Y}_i)^2=\sum_{i=1}^{n}(Y_i-\hat{a}-\hat{b}x_i)^2 \tag{10.1.10}'$$

$$\hat{\sigma^2}=\frac{1}{n-2}Q_e=\frac{1}{n-2}\sum_{i=1}^{n}(Y_i-\hat{a}-\hat{b}x_i)^2 \tag{10.1.11}'$$

其中 $\bar{Y}=\frac{1}{n}\sum_{i=1}^{n}Y_i,\hat{Y}_i=\hat{a}+\hat{b}x_i(i=1,2,\cdots,n)$.

关于估计量 $\hat{a},\hat{b},\hat{\sigma^2}$ 有如下定理:

定理 10.1 对于一元线性回归模型(10.1.2)有

(1) $\bar{Y}\sim N\left(a+b\bar{x},\frac{\sigma^2}{n}\right)$;

(2) $\hat{b}\sim N\left(b,\frac{\sigma^2}{l_{xx}}\right)$;

(3) $\hat{a}\sim N\left(a,\left(\frac{1}{n}+\frac{\bar{x}^2}{l_{xx}}\right)\sigma^2\right)$.

证 由(10.1.6)′,(10.1.7)′有

$$\hat{b}=\frac{1}{l_{xx}}\sum_{i=1}^{n}(x_i-\bar{x})Y_i=\sum_{i=1}^{n}\frac{x_i-\bar{x}}{l_{xx}}Y_i$$

$$\hat{a}=\frac{1}{n}\sum_{i=1}^{n}Y_i-\bar{x}\sum_{i=1}^{n}\frac{x_i-\bar{x}}{l_{xx}}Y_i=\sum_{i=1}^{n}\left[\frac{1}{n}-\frac{\bar{x}(x_i-\bar{x})}{l_{xx}}\right]Y_i$$

由模型(10.1.2)知 $Y_1,Y_2,\cdots,Y_n$ 是相互独立的,且

$$Y_i=a+bx_i+\varepsilon_i\sim N(a+bx_i,\sigma^2)\quad(i=1,2,\cdots,n)$$

所以 $Y_1,Y_2,\cdots,Y_n$ 的线性组合 $\bar{Y},\hat{b},\hat{a}$ 都服从正态分布,下面计算它们的数学期望和方差:

$$E(\bar{Y})=\frac{1}{n}\sum_{i=1}^{n}E(Y_i)=\frac{1}{n}\sum_{i=1}^{n}(a+bx_i)=a+b\bar{x}$$

$$D(\bar{Y})=\frac{1}{n^2}\sum_{i=1}^{n}D(Y_i)=\frac{1}{n^2}\sum_{i=1}^{n}\sigma^2=\frac{\sigma^2}{n}$$

$$E(\hat{b})=\sum_{i=1}^{n}\frac{x_i-\bar{x}}{l_{xx}}E(Y_i)=\frac{1}{l_{xx}}\sum_{i=1}^{n}(x_i-\bar{x})(a+bx_i)=b$$

$$D(\hat{b})=\frac{1}{l_{xx}^2}\sum_{i=1}^{n}(x_i-\bar{x})^2D(Y_i)=\frac{1}{l_{xx}^2}\sum_{i=1}^{n}(x_i-\bar{x})^2\sigma^2=\frac{\sigma^2}{l_{xx}}$$

$$E(\hat{a})=E(\bar{Y})-E(\hat{b})\bar{x}=a+b\bar{x}-b\bar{x}=a$$

$$\begin{aligned}D(\hat{a})&=\sum_{i=1}^{n}\left[\frac{1}{n}-\frac{\bar{x}(x_i-\bar{x})}{l_{xx}}\right]^2D(Y_i)\\&=\sigma^2\sum_{i=1}^{n}\left[\frac{1}{n^2}+\frac{\bar{x}^2(x_i-\bar{x})^2}{l_{xx}^2}-\frac{2\bar{x}(x_i-\bar{x})}{nl_{xx}}\right]\\&=\sigma^2\left(\frac{1}{n}+\frac{\bar{x}^2}{l_{xx}}\right)\end{aligned}$$

这就证得定理结论.

由此定理可知,$\hat{a},\hat{b}$ 分别是 a,b 的无偏估计量、均方相合估计量,从而也是相合估计量.

定理 10.2 对于一元线性回归模型(10.1.2)有

(1) $\dfrac{1}{\sigma^2}Q_e\sim\chi^2(n-2)$;

(2) $\hat{a},\hat{b}$ 与 Q_e 相互独立;

(3) $\bar{Y},\hat{b},Q_e$ 相互独立.

此定理的证明从略.

由此定理及 χ^2 分布的性质可知

$$E(\hat{\sigma^2})=\sigma^2,\quad D(\hat{\sigma^2})=\frac{2\sigma^4}{n-2}$$

这说明 $\hat{\sigma^2}$ 是 σ^2 的无偏估计量、均方相合估计量,从而也是相合估计量.

定理 10.3 对一元线性回归模型(10.1.2)有

(1) $\dfrac{\hat{b}-b}{\hat{\sigma}}\sqrt{l_{xx}}\sim t(n-2)$;

(2) $\dfrac{\hat{a}-a}{\hat{\sigma}\sqrt{\dfrac{1}{n}+\dfrac{\bar{x}^2}{l_{xx}}}}\sim t(n-2)$,

其中 $\hat{\sigma}=\sqrt{\hat{\sigma}^2}$.

证 由定理 10.1 和定理 10.2 及定理 6.5 立即可得此定理结论.

由定理 10.3 可得 b 和 a 的置信度为 $1-\alpha$ 的置信区间分别为

$$\left(\hat{b}-\frac{\hat{\sigma}}{\sqrt{l_{xx}}}t_{\alpha/2}(n-2),\quad \hat{b}+\frac{\hat{\sigma}}{\sqrt{l_{xx}}}t_{\alpha/2}(n-2)\right)$$

$$\left(\hat{a}-\hat{\sigma}\sqrt{\frac{1}{n}+\frac{\bar{x}^2}{l_{xx}}}t_{\alpha/2}(n-2),\quad \hat{a}+\hat{\sigma}\sqrt{\frac{1}{n}+\frac{\bar{x}^2}{l_{xx}}}t_{\alpha/2}(n-2)\right)$$

由定理 10.2 可得 σ^2 的置信度为 $1-\alpha$ 的置信区间

$$\left(\frac{Q_e}{\chi^2_{\alpha/2}(n-2)},\quad \frac{Q_e}{\chi^2_{1-\alpha/2}(n-2)}\right)$$

10.1.3 一元线性回归中的假设检验

在前面的讨论中,我们假定 Y 关于 x 的回归函数 $\mu(x)$ 为线性函数 $a+bx$,然而,在处理实际问题时,$\mu(x)$ 是否为 x 的线性函数,还需要根据实际观察得到的数据运用假设检验的方法来判断.这就意味着,所求得的经验回归直线是否有实用价值,需要经过假设检验才能断定.

不难看出,若一元线性回归模型(10.1.1)符合实际,则 b 不应为零,因为若 $b=0$,则 Y 就不线性依赖于 x 了.因此我们需要检验假设

$$H_0: b=0,\quad H_1: b\neq 0 \tag{10.1.15}$$

下面我们用 t 检验法来进行检验,取检验统计量

$$T=\frac{\hat{b}}{\hat{\sigma}}\sqrt{l_{xx}}$$

当 H_0 为真时,由定理 10.3 知,$T\sim t(n-2)$,对给定的显著性水平 α,一次抽样后从样本值计算得统计量 T 的观测值 t,若

$$|t|\geqslant t_{\alpha/2}(n-2)$$

则拒绝 $H_0: b=0$,即认为线性回归显著,从而说明求得的经验回归直线有实用价值;若

$$|t|<t_{\alpha/2}(n-2)$$

则接受 $H_0: b=0$,即认为线性回归不显著,从而说明求得的经验回归直线无意义.此检验法的 p 值为 $p=P\{|T|\geqslant|t|\}$,t 是统计量 T 的观测值,$T\sim t(n-2)$.

例 10.3(续例 10.1) 检验例 10.1 中的线性回归是否显著.显著性水平 $\alpha=0.05$.

解 因为 $\hat{b}=0.183$,$\hat{\sigma}^2=0.007$,又

$$\sum_{i=1}^{6}(x_i-\bar{x})^2=\sum_{i=1}^{6}x_i^2-6\bar{x}^2$$
$$=2\ 275-6\times17.5^2=437.5$$

于是

$$t=\frac{0.183}{\sqrt{0.007}}\times\sqrt{437.5}=45.75$$

查附表3,得 $t_{0.05/2}(6-2)=t_{0.025}(4)=2.776\ 4$,因为

$$|t|=45.75>2.776\ 4$$

所以,认为线性回归显著.

此例的检验 p 值为 $p=P\{|T|\geqslant45.75\}=1.364\ 6\times10^{-6}<\alpha=0.05$,所以,可认为线性回归显著.

在判别由(10.1.6),(10.1.7)两式所求得的经验回归直线方程是否具有实用价值时,除了用上面所介绍的假设检验的方法外,我们还可以用一个数量指标来衡量.

由 Q_e 的定义(见(10.1.10)式)和(10.1.12)式,我们可以得到以下几个事实:

(1) 若 $Q_e=0$,即 $\sum_{i=1}^{n}(y_i-\hat{y}_i)^2=0$,则表示试验数据 $(x_i,y_i)(i=1,2,\cdots,n)$ 全在一条直线上,此时,可认为变量 Y 与 x 的对应关系为确定的线性函数关系.

(2)若 $\hat{b}^2\sum_{i=1}^{n}(x_i-\bar{x})^2=0$,则 $Q_e=\sum_{i=1}^{n}(y_i-\bar{y})^2$,即 Q_e 达到最大值,此时,x 的变化对 Y 无任何影响,说明 Y 与 x 之间无任何线性相关关系.

综合上述两点,Q_e 可用来描述变量间线性相关的密切程度.由于 Q_e 是有量纲的量,在使用时会受到所选单位的影响,不大方便,于是令

$$r^2=\frac{\hat{b}^2\sum_{i=1}^{n}(x_i-\bar{x})^2}{\sum_{i=1}^{n}(y_i-\bar{y})^2} \tag{10.1.16}$$

利用(10.1.12)式,可将上式改写成

$$r^2=1-\frac{Q_e}{\sum_{i=1}^{n}(y_i-\bar{y})^2} \tag{10.1.17}$$

注意到 $Q_e\leqslant\sum_{i=1}^{n}(y_i-\bar{y})^2$,故有 $0\leqslant r^2\leqslant1$,不仅如此,由(10.1.17)式可知:

(1) $Q_e=0\Leftrightarrow r^2=1\Leftrightarrow|r|=1$;

(2) $Q_e=\sum_{i=1}^{n}(y_i-\bar{y})^2\Leftrightarrow r^2=0\Leftrightarrow r=0$;

(3) $0<Q_e<\sum_{i=1}^{n}(y_i-\bar{y})^2\Leftrightarrow0<r^2<1\Leftrightarrow0<|r|<1$.

把计算 $\hat{b}$ 的表达式(10.1.6)代入到(10.1.16)式中,可得

$$r^2 = \frac{\left[\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})\right]^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2} \tag{10.1.18}$$

于是

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2}\sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}} \tag{10.1.19}$$

在线性相关的研究中,通常都用 r 来衡量变量间线性相关的密切程度,r 称为**经验相关系数**或**样本相关系数**.

MATLAB 提供了命令 cov(x,y)计算样本 x 与 y 的协方差,corrcoef(x,y)计算样本 x 与 y 的相关系数.

图 10.2 形象地说明了散点图的特点与 r 取值之间的联系.

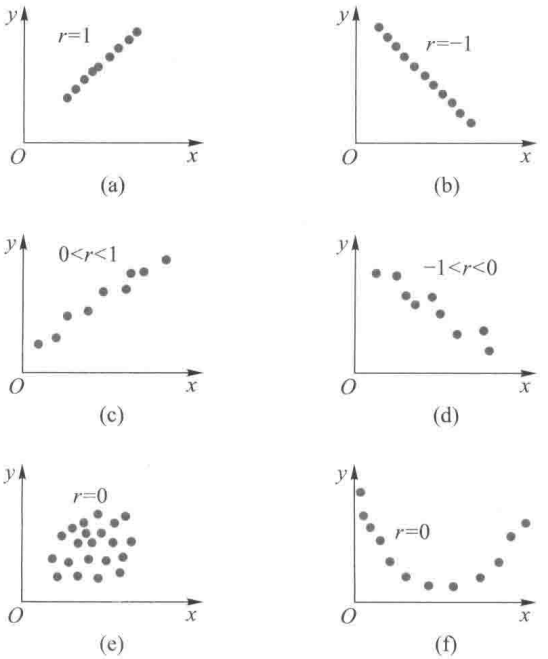

图 10.2

如果散点图中的所有点都处在一条直线上,那么 $|r|=1$,此时称 Y 与 x 完全线性相关.当 $r=1$ 时,称为完全正相关;当 $r=-1$ 时,称为完全负相关.事实上,此时可认为 Y 与 x 之间存在着确定的线性函数关系(图 10.2(a),(b)).一般的情形见图 10.2(c),(d),此时 $0<|r|<1$,表明 Y 与 x 之间有一定的线性相关性.在图 10.2(c)中,散点分布呈 Y 随 x 的增加而增加的趋势,相应的 $r>0$,此时称 Y 与 x 正相关,而在图 10.2(d)所示的情形,称 Y 与 x 负相关.如果散点图中的散点分布呈完全不规则状(见图 10.2(e)),那么,相应的 $r=0$,此时 Y 与 x 毫无线性关系.应当指出,经验相关系数 r 只是描述变量间线性相关的密切程度的量,当 $|r|$ 接近于 0,甚至为 0 时,只表明变量 Y 与 x 的线性相关性极弱,甚至不线性相关,但是并不能说明 Y 与 x 之间就无其他非线性的相关关系.如图 10.2(f)所示,虽然 $r=0$,但从图上明显可以看出 Y 与 x

之间存在着非线性的相关关系.在这种情形,线性回归的方法就不适用了.

利用例 10.1 中所给的数据可以算得相关系数

$$r=\frac{80.1}{\sqrt{437.5}\times\sqrt{14.678}}=0.9996$$

很接近于 1,这表明所配制的经验回归直线方程是有意义的.

10.1.4 预测

如果经检验,认为线性回归方程是可信的,而且拟合得又好,那么接下来就要用它进行预测.所谓预测是指当 $x=x_0$ 时对 Y 做区间估计,说得更确切些就是以一定的置信度预测 Y 的观测值的取值范围,也即所谓的预测区间.

当 $x=x_0$ 时,由(10.1.1)式,对应的 Y 为

$$Y_0=a+bx_0+\varepsilon_0,\quad \varepsilon_0\sim N(0,\sigma^2) \tag{10.1.20}$$

另一方面,我们可取 x_0 处的回归值

$$\hat{y}_0=\hat{a}+\hat{b}x_0=\bar{y}+\hat{b}(x_0-\bar{x}) \tag{10.1.21}$$

作为 Y_0 的预测值.

$\hat{y}_0$ 相应的统计量记为 $\hat{Y}_0$,则

$$\hat{Y}_0=\hat{a}+\hat{b}x=\bar{Y}+\hat{b}(x_0-\bar{x}) \tag{10.1.21}'$$

由定理 10.1 和定理 10.2 可知

$$\hat{Y}_0\sim N\left(a+bx_0,\sigma^2\left[\frac{1}{n}+\frac{(x_0-\bar{x})^2}{l_{xx}}\right]\right) \tag{10.1.22}$$

所以,

$$E(\hat{Y}_0)=a+bx_0,\quad D(\hat{Y}_0)=\sigma^2\left[\frac{1}{n}+\frac{(x_0-\bar{x})^2}{l_{xx}}\right]$$

因此,$\hat{Y}_0$ 也可作为回归函数 $\mu(x)=a+bx$ 在 x_0 处的函数值 $\mu(x_0)$ 的无偏估计量,而且是相合估计量和均方相合估计量.

将 (x_0,Y_0) 设想成是在模型(10.1.1)的条件下又独立地进行了一次试验的结果,则 Y_0 与 $Y_1,Y_2,\cdots,Y_n$ 相互独立,从而 Y_0 与 $\hat{Y}_0$ 相互独立,由(10.1.20)和(10.1.22)式可知

$$Y_0-\hat{Y}_0\sim N\left(0,\sigma^2\left[1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{l_{xx}}\right]\right)$$

于是

$$\frac{Y_0-\hat{Y}_0}{\sqrt{\sigma^2\left[1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{l_{xx}}\right]}}\sim N(0,1)$$

由定理 10.2 知

$$\frac{(n-2)\hat{\sigma}^2}{\sigma^2}\sim\chi^2(n-2)$$

且 $\hat{Y}_0$ 与 Q_e 相互独立，故 $Y_0-\hat{Y}_0$ 与 $\hat{\sigma}^2$ 相互独立，因而

$$\frac{Y_0-\hat{Y}_0}{\hat{\sigma}\sqrt{1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{l_{xx}}}}\sim t(n-2)$$

对给定的置信度 $1-\alpha$，有

$$P\left\{\frac{|Y_0-\hat{Y}_0|}{\hat{\sigma}\sqrt{1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{l_{xx}}}}<t_{\alpha/2}(n-2)\right\}=1-\alpha$$

即

$$P\{\hat{Y}_0-\delta(x_0)<Y_0<\hat{Y}_0+\delta(x_0)\}=1-\alpha$$

其中

$$\delta(x_0)=t_{\alpha/2}(n-2)\hat{\sigma}\sqrt{1+\frac{1}{n}+\frac{(x_0-\bar{x})^2}{l_{xx}}} \tag{10.1.23}$$

所以，Y_0 的置信度为 $1-\alpha$ 的预测区间是

$$(\hat{Y}_0-\delta(x_0),\hat{Y}_0+\delta(x_0))$$

这也是回归函数 $\mu(x)=a+bx$ 在 x_0 处的函数值 $\mu(x_0)=a+bx_0$ 的置信度为 $1-\alpha$ 的置信区间.

当试验得到具体的样本值 $(x_1,y_1),(x_2,y_2),\cdots,(x_n,y_n)$ 时，算出 $\hat{Y}_0$ 的观测值 $\hat{y}_0=\hat{a}+\hat{b}x_0$，便得到 Y_0 的一个具体的预测区间（也是 $\mu(x_0)=a+bx_0$ 的置信区间）

$$(\hat{y}_0-\delta(x_0),\hat{y}_0+\delta(x_0))$$

让 x_0 变动，记 $\hat{y}=\hat{a}+\hat{b}x$，则在 x 处，Y 的置信下限值为

$$y_1(x)=\hat{y}-\delta(x)$$

而置信上限值为

$$y_2(x)=\hat{y}+\delta(x)$$

如果分别作出函数 $\hat{y}=\hat{a}+\hat{b}x$，$y_1(x)$，$y_2(x)$ 的图形（如图 10.3 所示），那么从图上可见：在 x 处预测 Y 的预测区间是横坐标为 x 且平行于 y 轴的直线被夹在两曲线之间的那一部分，其长度为 $2\delta(x)$. 当 $x=\bar{x}$ 时，预测区间的长度最小，估计的精确性最高，而当 x 远离 $\bar{x}$ 时，区间变长，估计的精确性变差.

当 n 很大且 x 在 $\bar{x}$ 附近时，有

$$\delta(x)\approx u_{\alpha/2}\hat{\sigma}$$

于是，Y 的置信下限和置信上限分别近似于直线

$$\begin{cases}y_1(x)\approx\hat{a}+\hat{b}x-u_{\alpha/2}\hat{\sigma},\\ y_2(x)\approx\hat{a}+\hat{b}x+u_{\alpha/2}\hat{\sigma}\end{cases} \tag{10.1.24}$$

它们的图像如图 10.4 所示.

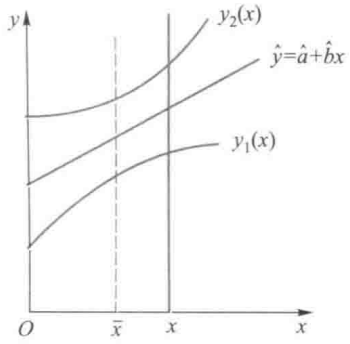

图 10.3

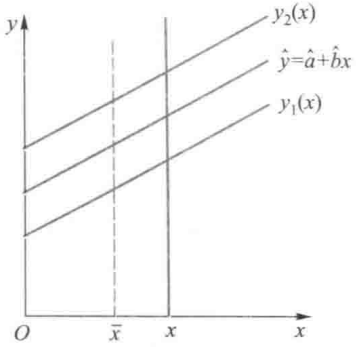

图 10.4

例 **10.4** 在例 10.1 中,对 $x=16$ g 处的 Y 进行预测,取 $1-\alpha=0.95$.

解 因为 $x=16$,故

$$\hat{y}=6.284+0.183\times16=9.212$$

现在 $n=6$,由 $\delta(x)$ 的表达式,可得

$$\delta(16)=t_{0.025}(4)\hat{\sigma}\sqrt{1+\frac{1}{6}+\frac{(16-\bar{x})^2}{\sum_{i=1}^{6}(x_i-\bar{x})^2}}$$

$$=2.776\ 4\times\sqrt{0.007}\times\sqrt{1+\frac{1}{6}+\frac{(16-17.5)^2}{437.5}}=0.251$$

Y 的置信下限是

$$y_1=9.212-0.251=8.961$$

Y 的置信上限是

$$y_2=9.212+0.251=9.463$$

预测区间为

$$(8.961,9.463)$$

10.2 可线性化的一元非线性回归

在回归分析中,回归函数 $\mu(x)$ 不是线性函数的情形也是很常见的.例如,从专业知识上认为变量 Y 对 x 的回归函数是某种非线性函数;或者从试验数据的散点图中看,散点的分布明显地不在一条直线附近;或者对已配制的经验回归直线方程在使用前进行了假设检验,结果认为线性回归不显著等,对这些问题作曲线回归是非常必要的.

配制回归曲线的一个基本方法是通过适当的变量代换把非线性回归化为线性回归.其具体做法如下:对变量 x 和 y 做 n 次试验,得观测值 (x_i,y_i) $(i=1,2,\cdots,n)$,画出散点图,通过散点图与常见的函数曲线对比,经验地选择曲线类型.下面是可供选择的常见的六类曲线:

(1) 双曲线：$\frac{1}{y}=a+\frac{b}{x}$，如图 10.5 所示.

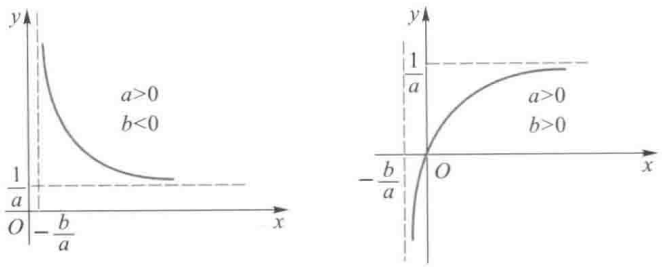

图 10.5

(2) 幂函数曲线：$y=ax^b$，$x>0$，其中 $a>0$，如图 10.6 所示.

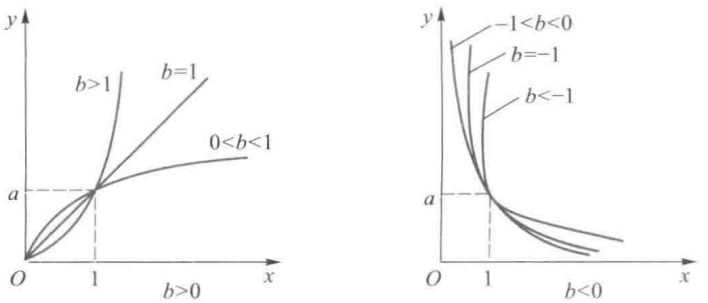

图 10.6

(3) 指数曲线：$y=ae^{bx}$，其中 $a>0$，如图 10.7 所示.

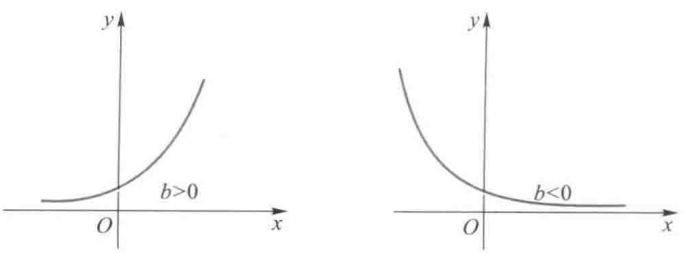

图 10.7

(4) 倒指数曲线：$y=ae^{b/x}$，其中 $a>0$，如图 10.8 所示.

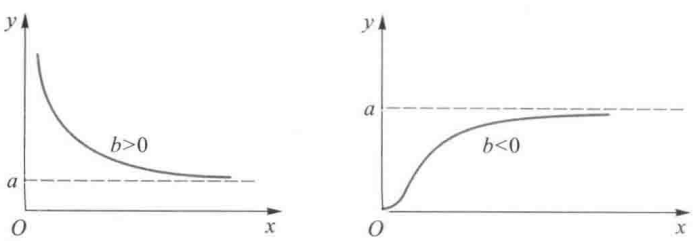

图 10.8

(5) 对数曲线：$y=a+b\ln x$，$x>0$，如图 10.9 所示.

(6) S 形曲线：$y=\frac{1}{a+be^{-x}}$，如图 10.10 所示.

下面我们来讨论把曲线回归问题化成线性回归问题的具体做法.

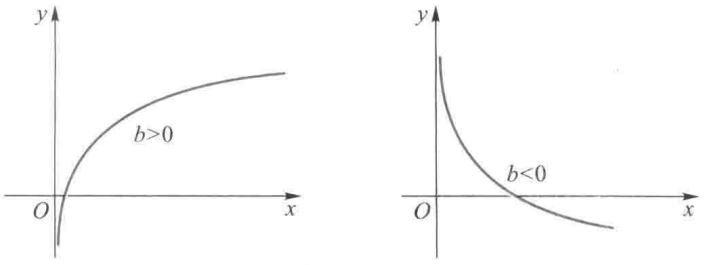

图 10.9

设有模型

$$\frac{1}{Y}=a+\frac{b}{x}+\varepsilon,\varepsilon\sim N(0,\sigma^2) \qquad (10.2.1)$$

作变量代换 $u=\frac{1}{x}$，$V=\frac{1}{Y}$，则模型(10.2.1)转化为线性回归模型

$$V=a+bu+\varepsilon,\quad \varepsilon\sim N(0,\sigma^2) \qquad (10.2.1)'$$

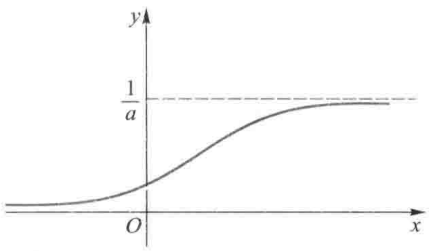

图 10.10

由试验数据$(x_i,y_i)(i=1,2,\cdots,n)$，按 $u_i=\frac{1}{x_i}$，$v_i=\frac{1}{y_i}$算出$(u_i,v_i)(i=1,2,\cdots,n)$，再由(10.1.6)，(10.1.7)式计算参数估计值 $\hat{a}$，$\hat{b}$，最后得

$$\frac{1}{\hat{y}}=\hat{a}+\frac{\hat{b}}{x}$$

如果由试验数据的散点图显示出变量间的关系适宜用倒指数曲线来拟合，即有回归函数

$$y=a\mathrm{e}^{b/x},a>0$$

则在上式两端取自然对数，令 $u=\frac{1}{x}$，$v=\ln y$，并记 $A=\ln a$，则有

$$v=A+bu$$

假定变量 V 与 u 适合模型

$$V=A+bu+\varepsilon',\quad \varepsilon'\sim N(0,\sigma^2)$$

代回原变量，即 Y 与 x 适合模型

$$Y=a\mathrm{e}^{b/x}\varepsilon,\quad \ln\varepsilon=\varepsilon'\sim N(0,\sigma^2) \qquad (10.2.2)$$

于是在上述变换下，模型(10.2.2)可化成线性回归模型

$$V=A+bu+\varepsilon',\quad \varepsilon'\sim N(0,\sigma^2) \qquad (10.2.2)'$$

由试验数据(x_i,y_i)算出$(u_i,v_i)(i=1,2,\cdots,n)$.再由(10.1.6)，(10.1.7)式算出 $\hat{A}$，$\hat{b}$ 的值，由 $\hat{a}=\mathrm{e}^{\hat{A}}$ 可得 $\hat{a}$ 的值，最后得到模型(10.2.2)的经验回归函数

$$\hat{y}=\hat{a}\mathrm{e}^{\hat{b}/x}$$

以上两种曲线回归模型通过适当的变量代换都能转化为线性回归模型.这类回

归模型就称为可线性化的一元非线性回归模型.

关于幂函数曲线、指数曲线、对数曲线和S形曲线的可线性化的曲线回归模型应具有什么样的形式以及如何把它们转化为线性回归问题就留给读者思考.

值得注意的是:并非所有的曲线回归问题都可线性化.例如下面的模型

$$Y=ae^{b/x}+\varepsilon,\quad \varepsilon\sim N(0,\sigma^2) \tag{10.2.3}$$

其中未知参数 a,b 和 σ^2 都与 x 无关,$a>0$.表面上看,模型(10.2.3)比模型(10.2.2)还要简单,然而模型(10.2.3)却无法化成线性回归,因为它是所谓本质上非线性的模型.欲了解该曲线回归问题解法的读者可参考德雷柏和史密斯(N. R. Draper, H. Smith)合著的《应用回归分析》(Applied Regression Analysis)一书.

10.3 多元线性回归

10.3.1 模型与参数估计

在许多实际问题中,随机变量 Y 往往与多个可控变量 $x_1,x_2,\cdots,x_k(k>1)$ 有关,当自变量 $x_1,x_2,\cdots,x_k$ 取定一组值时,Y 有确定的(条件)分布与之对应.若 Y 的数学期望存在,则其值随 $x_1,x_2,\cdots,x_k$ 的取值而定,因而是 $x_1,x_2,\cdots,x_k$ 的函数,记为 $\mu(x_1,x_2,\cdots,x_k)$,并称之为 Y 关于 $x_1,x_2,\cdots,x_k$ 的回归函数.因为自变量的个数 $k>1$,所以 $\mu(x_1,x_2\cdots,x_k)$ 又称为 Y 关于 $x_1,x_2\cdots,x_k$ 的多元回归.在多元回归问题中,最简单但又十分重要的是多元线性回归问题.下面我们来讨论多元线性回归模型.

设 $x_1,x_2,\cdots,x_k$ 是可控变量,Y 是随机变量,它们之间有关系

$$Y=b_0+b_1x_1+\cdots+b_kx_k+\varepsilon,\quad \varepsilon\sim N(0,\sigma^2) \tag{10.3.1}$$

其中 $b_0,b_1,\cdots,b_k,\sigma^2$ 都是与 $x_1,x_2,\cdots,x_k$ 无关的未知参数,这就是 **k 元线性回归模型**.

对变量 $x_1,x_2,\cdots,x_k,Y$ 做 n 次独立观测得样本:

$$(x_{i1},x_{i2},\cdots,x_{ik},Y_i)\quad (i=1,2,\cdots,n) \tag{10.3.2}$$

相应的样本值记为

$$(x_{i1},x_{i2},\cdots,x_{ik},y_i)\quad (i=1,2,\cdots,n) \tag{10.3.3}$$

便有模型(10.3.1)的样本形式

$$\begin{cases} Y_i=b_0+b_1x_{i1}+\cdots+b_kx_{ik}+\varepsilon_i, \\ \varepsilon_i\sim N(0,\sigma^2)\quad (i=1,2,\cdots,n),\text{且 } \varepsilon_1,\varepsilon_2,\cdots,\varepsilon_n \text{ 相互独立} \end{cases} \tag{10.3.4}$$

与一元线性回归的情形类似,我们用最小二乘法来求未知参数的点估计.即找到 $\hat{b}_0,\hat{b}_1,\cdots,\hat{b}_k$,使当 $b_0=\hat{b}_0,b_1=\hat{b}_1,\cdots,b_k=\hat{b}_k$ 时

$$Q(b_0,b_1,\cdots,b_k)=\sum_{i=1}^{n}(y_i-b_0-b_1x_{i1}-\cdots-b_kx_{ik})^2 \tag{10.3.5}$$

达到最小值.

取 Q 分别关于 $b_0,b_1,\cdots,b_k$ 的偏导数,并令它们等于零,得

$$\begin{cases} \dfrac{\partial Q}{\partial b_0} = -2\sum\limits_{i=1}^{n}(y_i - b_0 - b_1x_{i1} - \cdots - b_kx_{ik}) = 0, \\ \dfrac{\partial Q}{\partial b_1} = -2\sum\limits_{i=1}^{n}(y_i - b_0 - b_1x_{i1} - \cdots - b_kx_{ik})x_{i1} = 0, \\ \cdots\cdots\cdots\cdots \\ \dfrac{\partial Q}{\partial b_k} = -2\sum\limits_{i=1}^{n}(y_i - b_0 - b_1x_{i1} - \cdots - b_kx_{ik})x_{ik} = 0 \end{cases} \tag{10.3.6}$$

化简(10.3.6)式得

$$\begin{cases} b_0n + b_1\sum\limits_{i=1}^{n}x_{i1} + b_2\sum\limits_{i=1}^{n}x_{i2} + \cdots + b_k\sum\limits_{i=1}^{n}x_{ik} = \sum\limits_{i=1}^{n}y_i, \\ b_0\sum\limits_{i=1}^{n}x_{i1} + b_1\sum\limits_{i=1}^{n}x_{i1}^2 + b_2\sum\limits_{i=1}^{n}x_{i1}x_{i2} + \cdots + b_k\sum\limits_{i=1}^{n}x_{i1}x_{ik} = \sum\limits_{i=1}^{n}x_{i1}y_i, \\ \cdots\cdots\cdots\cdots \\ b_0\sum\limits_{i=1}^{n}x_{ik} + b_1\sum\limits_{i=1}^{n}x_{ik}x_{i1} + b_2\sum\limits_{i=1}^{n}x_{ik}x_{i2} + \cdots + b_k\sum\limits_{i=1}^{n}x_{ik}^2 = \sum\limits_{i=1}^{n}x_{ik}y_i \end{cases} \tag{10.3.7}$$

(10.3.7)式称为**正规方程组**.为了便于求解正规方程组,我们把(10.3.7)式改写为矩阵形式,令

$$\boldsymbol{X} = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1k} \\ 1 & x_{21} & x_{22} & \cdots & x_{2k} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{nk} \end{pmatrix}, \quad \boldsymbol{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad \boldsymbol{B} = \begin{pmatrix} b_0 \\ b_1 \\ \vdots \\ b_k \end{pmatrix}$$

因为

$$\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X} = \begin{pmatrix} 1 & 1 & \cdots & 1 \\ x_{11} & x_{21} & \cdots & x_{n1} \\ \vdots & \vdots & & \vdots \\ x_{1k} & x_{2k} & \cdots & x_{nk} \end{pmatrix}\begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1k} \\ 1 & x_{21} & x_{22} & \cdots & x_{2k} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{nk} \end{pmatrix}$$

$$= \begin{pmatrix} n & \sum\limits_{i=1}^{n}x_{i1} & \cdots & \sum\limits_{i=1}^{n}x_{ik} \\ \sum\limits_{i=1}^{n}x_{i1} & \sum\limits_{i=1}^{n}x_{i1}^2 & \cdots & \sum\limits_{i=1}^{n}x_{i1}x_{ik} \\ \vdots & \vdots & & \vdots \\ \sum\limits_{i=1}^{n}x_{ik} & \sum\limits_{i=1}^{n}x_{ik}x_{i1} & \cdots & \sum\limits_{i=1}^{n}x_{ik}^2 \end{pmatrix}$$

$$\boldsymbol{X}^{\mathrm{T}}\boldsymbol{Y}=\begin{pmatrix}1 & 1 & \cdots & 1\\ x_{11} & x_{21} & \cdots & x_{n1}\\ \vdots & \vdots & & \vdots\\ x_{1k} & x_{2k} & \cdots & x_{nk}\end{pmatrix}\begin{pmatrix}y_1\\ y_2\\ \vdots\\ y_n\end{pmatrix}=\begin{pmatrix}\sum\limits_{i=1}^{n} y_i\\ \sum\limits_{i=1}^{n} x_{i1}y_i\\ \vdots\\ \sum\limits_{i=1}^{n} x_{ik}y_i\end{pmatrix}$$

所以(10.3.7)式写成矩阵形式为

$$\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X}\boldsymbol{B}=\boldsymbol{X}^{\mathrm{T}}\boldsymbol{Y} \tag{10.3.7)'}$$

当系数矩阵 $\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X}$ 可逆时,可解出

$$\hat{\boldsymbol{B}}=\begin{pmatrix}\hat{b}_0\\ \hat{b}_1\\ \vdots\\ \hat{b}_k\end{pmatrix}=(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1}(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{Y}) \tag{10.3.8}$$

我们取 $\hat{y}=\hat{b}_0+\hat{b}_1x_1+\cdots+\hat{b}_kx_k$ 作为 $\mu(x_1,x_2,\cdots,x_k)=b_0+b_1x_1+\cdots+b_kx_k$ 的估计,并称

$$\hat{y}=\hat{b}_0+\hat{b}_1x_1+\cdots+\hat{b}_kx_k \tag{10.3.9}$$

为**经验回归平面方程**.

下面来求 σ^2 的点估计,为此,考虑残差平方和

$$Q_e=\sum_{i=1}^{n}(y_i-\hat{y}_i)^2=\sum_{i=1}^{n}(y_i-\hat{b}_0-\hat{b}_1x_{i1}-\cdots-\hat{b}_kx_{ik})^2$$

利用矩阵运算把它改写为

$$\begin{aligned}Q_e&=\|\boldsymbol{Y}-\boldsymbol{X}\hat{\boldsymbol{B}}\|^2\\ &=(\boldsymbol{Y}-\boldsymbol{X}\hat{\boldsymbol{B}})^{\mathrm{T}}(\boldsymbol{Y}-\boldsymbol{X}\hat{\boldsymbol{B}})\\ &=\boldsymbol{Y}^{\mathrm{T}}\boldsymbol{Y}-\boldsymbol{Y}^{\mathrm{T}}\boldsymbol{X}\hat{\boldsymbol{B}}-\hat{\boldsymbol{B}}^{\mathrm{T}}\boldsymbol{X}^{\mathrm{T}}\boldsymbol{Y}+\hat{\boldsymbol{B}}^{\mathrm{T}}\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X}\hat{\boldsymbol{B}}\\ &=\boldsymbol{Y}^{\mathrm{T}}\boldsymbol{Y}-\hat{\boldsymbol{B}}^{\mathrm{T}}\boldsymbol{X}^{\mathrm{T}}\boldsymbol{Y}\end{aligned} \tag{10.3.10}$$

其中记号 $\|\cdot\|$ 表示相应向量的模.

当把 $\hat{\boldsymbol{B}}$ 和 Q_e 中的 y_i 换成 $Y_i(i=1,2,\cdots,n)$ 时便得到相应的统计量,仍记作 $\hat{\boldsymbol{B}}$ 和 Q_e.可以证明 $E(Q_e)=(n-k-1)\sigma^2$.所以用

$$\hat{\sigma^2}=\frac{Q_e}{n-k-1}$$

对 σ^2 作点估计,则 $\hat{\sigma^2}$ 是 σ^2 的无偏估计量.

10.3.2 线性回归的另一种形式

在模型(10.3.1)中,令 $\bar{x}_j=\dfrac{1}{n}\sum\limits_{i=1}^{n}x_{ij}(j=1,2,\cdots,k)$,$\mu=b_0+b_1\bar{x}_1+\cdots+b_k\bar{x}_k$,则

(10.3.1)式可改写为另一种形式

$$\begin{cases} Y=\mu+b_1(x_1-\bar{x}_1)+\cdots+b_k(x_k-\bar{x}_k)+\varepsilon, \\ \varepsilon\sim N(0,\sigma^2) \end{cases} \tag{10.3.11}$$

于是对变量 $x_1,x_2,\cdots,x_k,Y$ 的样本 $(x_{i1},x_{i2},\cdots,x_{ik},Y_i)$ $(i=1,2,\cdots,n)$,(10.3.4)式可改写成

$$\begin{cases} Y_i=\mu+b_1(x_{i1}-\bar{x}_1)+\cdots+b_k(x_{ik}-\bar{x}_k)+\varepsilon_i, \\ \varepsilon_i\sim N(0,\sigma^2)\ (i=1,2,\cdots,n),\text{且 } \varepsilon_1,\varepsilon_2,\cdots,\varepsilon_n \text{ 相互独立} \end{cases}$$

从(10.3.1)式化到(10.3.11)式称为对自变量**中心化**,这给计算带来方便.在对中心化的多元线性回归模型(10.3.11)用最小二乘法求未知参数 $\mu,b_1,b_2,\cdots,b_k$ 的点估计时,只要把 10.3.1 小节的公式中 x_{ij} 换成 $x_{ij}-\bar{x}_j$ 就行了.下面我们来看一看代换之后会出现什么样的结果,为此,令

$$l_{jm}=\sum_{i=1}^{n}(x_{ij}-\bar{x}_j)(x_{im}-\bar{x}_m)$$

$$l_{jy}=\sum_{i=1}^{n}(x_{ij}-\bar{x}_j)(y_i-\bar{y})\ (j,m=1,2,\cdots,k)$$

其中 $\bar{y}=\dfrac{1}{n}\sum\limits_{i=1}^{n}y_i$.记

$$\boldsymbol{L}=\begin{pmatrix} l_{11} & l_{12} & \cdots & l_{1k} \\ l_{21} & l_{22} & \cdots & l_{2k} \\ \vdots & \vdots & & \vdots \\ l_{k1} & l_{k2} & \cdots & l_{kk} \end{pmatrix}$$

$$\tilde{\boldsymbol{X}}=\begin{pmatrix} 1 & x_{11}-\bar{x}_1 & x_{12}-\bar{x}_2 & \cdots & x_{1k}-\bar{x}_k \\ 1 & x_{21}-\bar{x}_1 & x_{22}-\bar{x}_2 & \cdots & x_{2k}-\bar{x}_k \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{n1}-\bar{x}_1 & x_{n2}-\bar{x}_2 & \cdots & x_{nk}-\bar{x}_k \end{pmatrix}$$

由于

$$\tilde{\boldsymbol{X}}^{\mathrm{T}}\tilde{\boldsymbol{X}}=\begin{pmatrix} n & 0 & \cdots & 0 \\ 0 & \sum\limits_{i=1}^{n}(x_{i1}-\bar{x}_1)^2 & \cdots & \sum\limits_{i=1}^{n}(x_{i1}-\bar{x}_1)(x_{ik}-\bar{x}_k) \\ \vdots & \vdots & & \vdots \\ 0 & \sum\limits_{i=1}^{n}(x_{ik}-\bar{x}_k)(x_{i1}-\bar{x}_1) & \cdots & \sum\limits_{i=1}^{n}(x_{ik}-\bar{x}_k)^2 \end{pmatrix}$$

$$=\begin{pmatrix} n & 0 & 0 & \cdots & 0 \\ 0 & l_{11} & l_{12} & \cdots & l_{1k} \\ \vdots & \vdots & \vdots & & \vdots \\ 0 & l_{k1} & l_{k2} & \cdots & l_{kk} \end{pmatrix}=\begin{pmatrix} n & 0 \\ 0 & \boldsymbol{L} \end{pmatrix}$$

$$\tilde{\boldsymbol{X}}^{\mathrm{T}}\boldsymbol{Y}=\begin{pmatrix}\sum\limits_{i=1}^{n}y_i\\ \sum\limits_{i=1}^{n}(x_{i1}-\bar{x}_1)y_i\\ \vdots\\ \sum\limits_{i=1}^{n}(x_{ik}-\bar{x}_k)y_i\end{pmatrix}=\begin{pmatrix}n\bar{y}\\ l_{1y}\\ \vdots\\ l_{ky}\end{pmatrix}$$

于是,正规方程组为

$$\begin{pmatrix}n & 0\\ 0 & \boldsymbol{L}\end{pmatrix}\begin{pmatrix}\mu\\ b_1\\ \vdots\\ b_k\end{pmatrix}=\begin{pmatrix}n\bar{y}\\ l_{1y}\\ \vdots\\ l_{ky}\end{pmatrix}\tag{10.3.12}$$

利用分块矩阵乘法得

$$n\mu=n\bar{y}$$

$$\boldsymbol{L}\begin{pmatrix}b_1\\ b_2\\ \vdots\\ b_k\end{pmatrix}=\begin{pmatrix}l_{1y}\\ l_{2y}\\ \vdots\\ l_{ky}\end{pmatrix}\tag{10.3.13}$$

故解得

$$\hat{\mu}=\bar{y},\quad\begin{pmatrix}\hat{b}_1\\ \hat{b}_2\\ \vdots\\ \hat{b}_k\end{pmatrix}=\boldsymbol{L}^{-1}\begin{pmatrix}l_{1y}\\ l_{2y}\\ \vdots\\ l_{ky}\end{pmatrix}\tag{10.3.14}$$

在这种模型中 $\hat{\mu}$ 的计算较简单,并且在计算 $\hat{b}_1,\hat{b}_2,\cdots,\hat{b}_k$ 时,只需求解含 k 个方程的方程组(10.3.13),因而比求解方程组(10.3.7)′简单.应当指出,用(10.3.14)式求得的 $\hat{b}_1,\hat{b}_2,\cdots,\hat{b}_k$ 的值与用(10.3.8)式求得的数值是相等的.实际上由(10.3.8)式得到 $\hat{b}_0,\hat{b}_1,\cdots,\hat{b}_k$,注意到 $\hat{b}_0=\bar{y}-\hat{b}_1\bar{x}_1-\cdots-\hat{b}_k\bar{x}_k$,因而,得经验回归平面方程为

$$\begin{aligned}\hat{y}&=\hat{b}_0+\hat{b}_1x_1+\cdots+\hat{b}_kx_k\\ &=\bar{y}-\hat{b}_1\bar{x}_1-\hat{b}_2\bar{x}_2-\cdots-\hat{b}_k\bar{x}_k+\hat{b}_1x_1+\hat{b}_2x_2+\cdots+\hat{b}_kx_k\\ &=\bar{y}+\hat{b}_1(x_1-\bar{x}_1)+\hat{b}_2(x_2-\bar{x}_2)+\cdots+\hat{b}_k(x_k-\bar{x}_k)\end{aligned}$$

这里的 $\hat{b}_1,\hat{b}_2,\cdots,\hat{b}_k$ 就是由(10.3.14)求出的经验回归系数.

例 10.5 在某次钢材的新型规范试验中,研究含碳量 x_1 和回火温度 x_2 对它的延伸率 Y 的关系,15 批生产试样结果如表 10.1 所示.根据经验,Y 关于 x_1,x_2 有二元线性回归关系

$$Y=b_0+b_1x_1+b_2x_2+\varepsilon,\quad\varepsilon\sim N(0,\sigma^2)$$

试求 Y 对 x_1,x_2 的经验回归平面方程.

表 10.1 含碳量 x_1,回火温度 x_2 与延伸率 y 的关系数据

含碳量 x_1	57	64	69	58	58	58	58	58
回火温度 x_2	535	535	535	460	460	460	490	490
延伸率 y	19.25	17.50	18.25	16.25	17.00	16.75	17.00	16.75
含碳量 x_1	58	57	64	69	59	64	69	
回火温度 x_2	490	460	435	460	490	467	490	
延伸率 y	17.25	16.75	14.75	12.00	17.75	15.50	15.50	

解 现在 $n=15, k=2$,采用线性回归模型(10.3.11)

$$Y=\mu+b_1(x_1-\bar{x}_1)+b_2(x_2-\bar{x}_2)+\varepsilon, \quad \varepsilon\sim N(0,\sigma^2)$$

为求出 $\hat{\mu},\hat{b}_1,\hat{b}_2$ 的值,依次计算下列各数:

$$\bar{y}=16.550, \quad \bar{x}_1=61.333, \quad \bar{x}_2=483.800$$

$$l_{11}=307.333, \quad l_{22}=13\ 552.400, \quad l_{12}=l_{21}=262.000$$

$$l_{1y}=-56.000, \quad l_{2y}=483.900$$

故

$$\hat{\mu}=\bar{y}=16.550$$

由

$$\boldsymbol{L}=\begin{pmatrix}307.333 & 262.000\\ 262.000 & 13\ 552.400\end{pmatrix}, \quad \begin{pmatrix}l_{1y}\\ l_{2y}\end{pmatrix}=\begin{pmatrix}-56.000\\ 483.900\end{pmatrix}$$

解方程组

$$\boldsymbol{L}\begin{pmatrix}b_1\\ b_2\end{pmatrix}=\begin{pmatrix}l_{1y}\\ l_{2y}\end{pmatrix}$$

得

$$\begin{pmatrix}\hat{b}_1\\ \hat{b}_2\end{pmatrix}=\begin{pmatrix}0.003\ 308 & -0.000\ 064\\ -0.000\ 064 & 0.000\ 075\end{pmatrix}\begin{pmatrix}-56.000\\ 483.900\end{pmatrix}=\begin{pmatrix}-0.216\\ 0.040\end{pmatrix}$$

所以

$$\begin{aligned}\hat{y}&=16.550-0.216(x_1-61.333)+0.040(x_2-483.800)\\ &=10.446-0.216x_1+0.040x_2\end{aligned}$$

在有些场合,可控变量 x 与随机变量 Y 适合下述回归模型:

$$Y=b_0+b_1x+b_2x^2+\cdots+b_kx^k+\varepsilon, \quad \varepsilon\sim N(0,\sigma^2)$$

其中 $b_0,b_1,\cdots,b_k,\sigma^2$ 都是与 x 无关的未知参数.

上面的回归模型称为**多项式回归模型**,它是一元非线性回归的一种特殊情况.我们可以通过代换把它转化为多元线性回归模型:令 $x_1=x, x_2=x^2,\cdots,x_k=x^k$,则多项式回归模型就变成

$$Y=b_0+b_1x_1+b_2x_2+\cdots+b_kx_k+\varepsilon, \quad \varepsilon\sim N(0,\sigma^2)$$

利用多元线性回归模型的参数估计的计算方法就可以求得多项式回归模型中的未

知参数 $b_0,b_1,\cdots,b_k$ 的估计.

例 **10.6** 经试验与分析发现,某合金的膨胀系数 Y 与它的两种主要金属成分之和 x(单位:%)有关,现有试验观察得到的一批数据:

x	2.0	2.5	3.0	3.5	4.0	5.0	6.0	6.5	7.0	7.5	8.0	9.0
Y	1.81	1.70	1.65	1.55	1.48	1.40	1.30	1.26	1.24	1.21	1.20	1.18

画出散点图如图 10.11 所示,根据散点图的形状,可选取模型

$$Y=b_0+b_1x+b_2x^2+\varepsilon,\quad \varepsilon\sim N(0,\sigma^2)$$

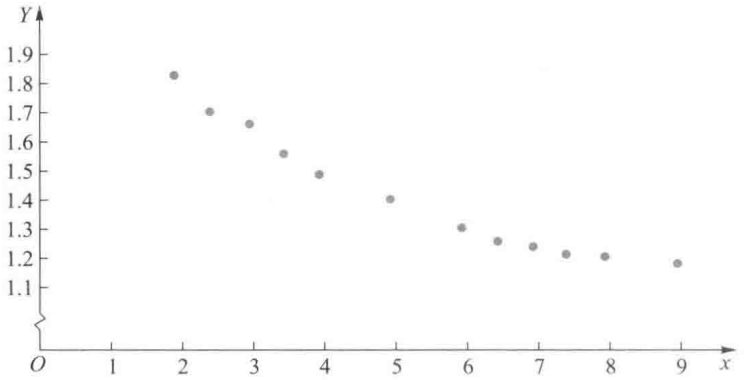

图 10.11

令 $x_1=x,x_2=x^2$,则上述抛物线回归转化为二元线性回归模型

$$Y=b_0+b_1x_1+b_2x_2+\varepsilon,\quad \varepsilon\sim N(0,\sigma^2)$$

利用(10.3.13)式计算未知参数的估计值.由于

$$\bar{y}=1.415,\quad \bar{x}_1=\frac{1}{n}\sum_{i=1}^{n}x_i=5.333,\quad \bar{x}_2=\frac{1}{n}\sum_{i=1}^{n}x_i^2=33.417$$

$$l_{11}=\sum_{i=1}^{n}x_i^2-n\bar{x}_1^2=59.709,\quad l_{22}=\sum_{i=1}^{n}x_i^4-n\bar{x}_2^2=7\,069.899$$

$$l_{12}=l_{21}=\sum_{i=1}^{n}x_i^3-n\bar{x}_1\bar{x}_2=640.446$$

$$l_{1y}=\sum_{i=1}^{n}x_iy_i-n\bar{x}_1\bar{y}=-5.424$$

$$l_{2y}=\sum_{i=1}^{n}x_i^2y_i-n\bar{x}_2\bar{y}=-55.801$$

由

$$\boldsymbol{L}=\begin{pmatrix}59.709 & 640.446\\ 640.446 & 7\,069.899\end{pmatrix},\quad \begin{pmatrix}l_{1y}\\ l_{2y}\end{pmatrix}=\begin{pmatrix}-5.424\\ -55.801\end{pmatrix}$$

解方程组

$$\boldsymbol{L}\begin{pmatrix}b_1\\ b_2\end{pmatrix}=\begin{pmatrix}l_{1y}\\ l_{2y}\end{pmatrix}$$

得

$$\begin{pmatrix}\hat{b}_1\\ \hat{b}_2\end{pmatrix}=\begin{pmatrix}0.591 & -0.054\\ -0.054 & 0.005\end{pmatrix}\begin{pmatrix}-5.424\\ -55.801\end{pmatrix}=\begin{pmatrix}-0.192\\ 0.014\end{pmatrix}$$

而

$$\hat{b}_0=\bar{y}-\hat{b}_1\bar{x}_1-\hat{b}_2\bar{x}_2=1.971$$

因此,经验回归方程为

$$\hat{y}=1.971-0.192x+0.014x^2$$

10.3.3 线性回归的显著性检验

设变量 Y 对 $x_1,x_2,\cdots,x_k$ 的线性回归模型为

$$Y=b_0+b_1x_1+b_2x_2+\cdots+b_kx_k+\varepsilon,\quad \varepsilon\sim N(0,\sigma^2)$$

与一元线性回归类似,要检验变量间有没有这种线性联系,只要检验 k 个系数 b_1, $b_2,\cdots,b_k$ 是否全为零.若全为零,则认为线性回归不显著;否则认为线性回归显著.为此,在上述模型中作假设

$$\begin{cases}H_0:b_1=b_2=\cdots=b_k=0,\\ H_1:b_i\text{ 不全为零}(i=1,2,\cdots,k)\end{cases}\tag{10.3.15}$$

由样本$(x_{i1},x_{i2},\cdots,x_{ik},Y_i)(i=1,2,\cdots,n)$来检验 H_0 是否成立.下面我们采用方差分析法作检验.设经验回归平面方程为

$$\hat{y}=\hat{b}_0+\hat{b}_1x_1+\cdots+\hat{b}_kx_k$$

在上式中代入自变量的观测值,得

$$\hat{y}_i=\hat{b}_0+\hat{b}_1x_{i1}+\cdots+\hat{b}_kx_{ik}\quad(i=1,2,\cdots,n)$$

记 $\hat{y}_i$ 相应的统计量为 $\hat{Y}_i$,$\bar{Y}=\dfrac{1}{n}\sum\limits_{i=1}^{n}Y_i$,则总平方和

$$\begin{aligned}Q_t&=\sum_{i=1}^{n}(Y_i-\bar{Y})^2=\sum_{i=1}^{n}[(Y_i-\hat{Y}_i)+(\hat{Y}_i-\bar{Y})]^2\\&=\sum_{i=1}^{n}(Y_i-\hat{Y}_i)^2+\sum_{i=1}^{n}(\hat{Y}_i-\bar{Y})^2+2\sum_{i=1}^{n}(Y_i-\hat{Y}_i)(\hat{Y}_i-\bar{Y})\end{aligned}$$

利用正规方程组不难算得

$$\sum_{i=1}^{n}(Y_i-\hat{Y}_i)(\hat{Y}_i-\bar{Y})=0$$

所以

$$Q_t=\sum_{i=1}^{n}(Y_i-\hat{Y}_i)^2+\sum_{i=1}^{n}(\hat{Y}_i-\bar{Y})^2$$

记

$$Q_e=\sum_{i=1}^{n}(Y_i-\hat{Y}_i)^2\tag{10.3.16}$$

称之为**残差平方和**.在试验观测值服从线性回归模型的情况下,它是由随机误差 ε 引起的误差平方和;在试验观测值不服从线性回归模型的情况下,它是除了变量对Y的线性影响外的一切因素对 Y 的影响(包括自变量对 Y 的非线性影响)构成的平方和.

又记

$$Q_r = \sum_{i=1}^{n} (\hat{Y}_i - \bar{Y})^2 \tag{10.3.17}$$

称之为**回归平方和**,它是由自变量 $x_1, x_2, \cdots, x_k$ 的取值且通过线性回归模型对 Y 的影响所构成的平方和.

因此,总平方和 Q_t 可分解为

$$Q_t = Q_e + Q_r \tag{10.3.18}$$

由上面 Q_e 的含义可知,当 Y 与自变量 $x_1, x_2, \cdots, x_k$ 符合线性回归模型时,统计量

$$F = \frac{Q_r/k}{Q_e/(n-k-1)} \tag{10.3.19}$$

的取值有偏大的倾向,否则,F 的取值很可能偏小,因而 F 可以作为检验假设(10.3.15)的统计量,下面在 H_0 成立的条件下(即 $Y_i = b_0 + \varepsilon_i, i = 1, 2, \cdots, n$)求出 F 的分布.在(10.3.18)式两端同除以 σ^2,得

$$\frac{Q_t}{\sigma^2} = \frac{Q_e}{\sigma^2} + \frac{Q_r}{\sigma^2} \tag{10.3.20}$$

上式左边

$$\frac{1}{\sigma^2} Q_t = \frac{1}{\sigma^2} \sum_{i=1}^{n} (b_0 + \varepsilon_i - b_0 - \bar{\varepsilon})^2 = \frac{1}{\sigma^2} \sum_{i=1}^{n} (\varepsilon_i - \bar{\varepsilon})^2$$

服从自由度为 $n-1$ 的 χ^2 分布,其中 $\bar{\varepsilon} = \frac{1}{n} \sum_{i=1}^{n} \varepsilon_i$. 考察 $\frac{Q_e}{\sigma^2}$ 的自由度,由正规方程组(10.3.7)得约束条件

$$\sum_{i=1}^{n} (Y_i - \hat{Y}_i) = 0$$

$$\sum_{i=1}^{n} (Y_i - \hat{Y}_i) x_{ij} = 0 \quad (j = 1, 2, \cdots, k)$$

所以 $\frac{Q_e}{\sigma^2}$ 的自由度为 $n-k-1$. 另外可以证明 $\frac{Q_r}{\sigma^2}$ 的自由度是 k,因此,(10.3.20)式右边各项的自由度之和为 $(n-k-1)+k=n-1$,等于左边 $\frac{Q_t}{\sigma^2}$ 的自由度. 由 9.1 节中的平方和分解定理知

$$\frac{Q_e}{\sigma^2} \sim \chi^2(n-k-1)$$

$$\frac{Q_r}{\sigma^2} \sim \chi^2(k)$$

且 $\frac{1}{\sigma^2} Q_e$ 与 $\frac{1}{\sigma^2} Q_r$ 相互独立,于是当 H_0 成立时,统计量

$$F = \frac{Q_r/k}{Q_e/(n-k-1)} \tag{10.3.21}$$

服从自由度为 $(k, n-k-1)$ 的 F 分布,根据上述 F 的取值特点,相应的检验法则为:

对于给定的显著性水平 α,若

$$F \geqslant F_{\alpha}(k, n-k-1)$$

则拒绝 H_0,即认为线性回归显著;反之,若

$$F < F_{\alpha}(k, n-k-1)$$

则接受 H_0,即认为相对于误差的影响而言,$x_1, x_2, \cdots, x_k$ 通过线性回归模型(10.3.1)(或(10.3.11))对 Y 的影响是不重要的,因而利用线性回归方程(10.3.9)预测 Y 是没有什么意义的.

在对线性回归模型进行假设检验时,通常可按方差分析表(表 10.2)来计算检验统计量 F 的数值.

表 10.2 方差分析表

方差来源	平方和	自由度	均方	F 值
回归平方和 (Q_r)	$Q_r = \sum_{i=1}^{n} (\hat{Y}_i - \bar{Y})^2$	k	$\bar{Q}_r = \dfrac{Q_r}{k}$	$F = \dfrac{\bar{Q}_r}{\bar{Q}_e}$
残差平方和 (Q_e)	$Q_e = \sum_{i=1}^{n} (Y_i - \hat{Y}_i)^2$	$n-k-1$	$\bar{Q}_e = \dfrac{Q_e}{n-k-1}$	
总平方和 (Q_t)	$Q_t = \sum_{i=1}^{n} (Y_i - \bar{Y})^2$	$n-1$		

此检验法的 p 值为 $p = P\{F \geqslant F_0\}$,其中 F_0 是检验统计量 F 的观测值,$F \sim F(k, n-k-1)$.

在按表 10.2 计算检验统计量 F 的数值时,通常有两种算法:

(1) 先由(10.3.10)式算出 Q_e,再计算 Q_t,最后有 $Q_r = Q_t - Q_e$;

(2) 先算出 Q_r(可以推证 $Q_r = \sum_{j=1}^{k} \hat{b}_j l_{jy}$),再计算 Q_t,最后有 $Q_e = Q_t - Q_r$.

例 10.7 检验例 10.5 中线性回归的显著性($\alpha = 0.05$).

解 因为 $n = 15, k = 2$,又

$$Q_t = \sum_{i=1}^{n} (y_i - \bar{y})^2 = \sum_{i=1}^{n} y_i^2 - n\bar{y}^2 = 39.775$$

$$\begin{aligned} Q_e &= \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 \\ &\xlongequal{(10.3.10)\text{式}} \sum_{i=1}^{n} y_i^2 - \left(\sum_{i=1}^{n} y_i\right)\hat{b}_0 - \left(\sum_{i=1}^{n} x_{i1} y_i\right)\hat{b}_1 - \left(\sum_{i=1}^{n} x_{i2} y_i\right)\hat{b}_2 \\ &= 8.952 \end{aligned}$$

$$Q_r = Q_t - Q_e = 30.823$$

所以列方差分析表(表 10.3)算得 F 值.

表 10.3 方差分析表

方差来源	平方和	自由度	均方	F 值
回归平方和	30.823	2	15.412	20.660
残差平方和	8.952	12	0.746	
总平方和	39.775	14		

查附表 5,得 $F_{0.05}(2,12)=3.89$,由于 $F=20.660>3.89$,故拒绝 H_0,认为线性回归是显著的.

此例的检验 p 值为 $p=P\{F\geqslant 20.660\}=0.000\ 1<\alpha=0.05$,因此,可认为线性回归显著.

10.3.4 回归系数的假设检验

在拒绝 H_0 的情况下,回归系数 $b_1,b_2,\cdots,b_k$ 不全为零,但这并不意味着每个自变量 $x_1,x_2,\cdots,x_k$ 对 Y 的影响都相同,有的自变量可能会起重要作用,而有的可能起的作用不大甚至不起作用.比如回归系数为零的自变量对 Y 的影响就不起任何作用.因此,在通过线性回归模型(10.3.1)(或(10.3.11))的假设检验,认为 Y 与 $x_1,x_2,\cdots,x_k$ 符合线性回归模型之后,还有必要从线性回归模型中剔除那些次要的、可有可无的自变量,只保留那些起重要作用的自变量,以便重新建立更为简练的线性回归方程,使之有利于实际工作.

通常,线性回归模型中的自变量 x_j 称为"回归因子",其前面的系数 b_j 称为"回归系数",b_j 的大小反映了 x_j 变化一个单位将引起 Y 的均值(即回归函数)变化多少个单位.若假设

$$H_0:b_j=0,\quad \text{其中 } j \text{ 固定且 } 1\leqslant j\leqslant k \tag{10.3.22}$$

经过检验,未被拒绝,则表明回归因子 x_j 对 Y 的作用不显著.因此,在线性回归模型(10.3.1)上对上述假设(10.3.22)作显著性检验,实际上是为挑选重要因子,剔除次要因子提供依据.

设 $(x_{i1},x_{i2},\cdots,x_{ik},Y_i)\ (i=1,2,\cdots,n)$ 是来自线性回归模型(10.3.1)的样本,于是

$$\begin{cases} Y_i=b_0+b_1x_{i1}+\cdots+b_kx_{ik}+\varepsilon_i, \\ \varepsilon_i\sim N(0,\sigma^2),\text{诸 } \varepsilon \text{ 相互独立}(i=1,2,\cdots,n) \end{cases} \tag{10.3.23}$$

记

$$\boldsymbol{\varepsilon}=\begin{pmatrix}\varepsilon_1\\ \varepsilon_2\\ \vdots\\ \varepsilon_n\end{pmatrix},\quad \boldsymbol{B}=\begin{pmatrix}b_0\\ b_1\\ \vdots\\ b_k\end{pmatrix}$$

由 10.3.1 节中有关记号和矩阵乘法,(10.3.23)式可改写成

$$\begin{cases} \boldsymbol{Y}=\boldsymbol{XB}+\boldsymbol{\varepsilon}, \\ \boldsymbol{\varepsilon}\sim N(\boldsymbol{0},\sigma^2\boldsymbol{I}_n) \end{cases} \tag{10.3.24}$$

其中 $\boldsymbol{I}_n$ 为 n 阶单位矩阵.于是

$$\boldsymbol{Y}\sim N(\boldsymbol{XB},\sigma^2\boldsymbol{I}_n)$$

由于

$$\hat{\boldsymbol{B}}=(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1}\boldsymbol{X}^{\mathrm{T}}\boldsymbol{Y}$$

为正态随机向量的线性变换,故 $\hat{\boldsymbol{B}}$ 仍为正态随机向量,且有

$$\hat{\boldsymbol{B}}\sim N(\boldsymbol{B},\sigma^2(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1})$$

因而

$$E(\hat{\boldsymbol{B}})=\boldsymbol{B}$$

亦即

$$E(\hat{b}_m)=b_m\quad(m=0,1,2,\cdots,k)\tag{10.3.25}$$

这表明估计量 $\hat{b}_m$ 是 $b_m(m=0,1,2,\cdots,k)$ 的无偏估计量.记

$$\boldsymbol{C}=(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1}\tag{10.3.26}$$

它是 $k+1$ 阶方阵,若以 c_{ii} 代表 $\boldsymbol{C}$ 的主对角线上的第 i 个元素(注意矩阵 $\boldsymbol{C}$ 的行、列的下标均从零算起),则可以证明

$$b_j\sim N(b_j,\sigma^2c_{jj})$$

且与 Q_e 相互独立.由于

$$\frac{\hat{b}_j-b_j}{\sigma\sqrt{c_{jj}}}\sim N(0,1)$$

且

$$\frac{Q_e}{\sigma^2}\sim\chi^2(n-k-1)$$

因而,在 H_0 成立时,有

$$T=\frac{\hat{b}_j/\sqrt{c_{jj}}}{\sqrt{Q_e/(n-k-1)}}\sim t(n-k-1)$$

对于显著性水平 α,若

$$|t|\geqslant t_{\alpha/2}(n-k-1)$$

则拒绝 H_0,即认为 b_j 显著地不为零;若

$$|t|<t_{\alpha/2}(n-k-1)$$

则接受 H_0,即认为回归系数 b_j 显著地为零.

此检验法的 p 值为 $p=P\{|T|\geqslant|t|\}$,t 是统计量 T 的观测值,$T\sim t(n-k-1)$.

例 10.8 检验例 10.5 中回归系数是否分别为零,显著性水平 $\alpha=0.05$.

解 与例 10.5 相仿,采用线性回归模型(10.3.11)

$$\begin{cases}Y=\mu+b_1(x_1-\bar{x}_1)+b_2(x_2-\bar{x}_2)+\varepsilon,\\ \varepsilon\sim N(0,\sigma^2)\end{cases}$$

由于 $\hat{\mu},\hat{b}_1,\hat{b}_2$ 已在例 10.5 中算出,且此时

$$\boldsymbol{C}=(\tilde{\boldsymbol{X}}^{\mathrm{T}}\tilde{\boldsymbol{X}})^{-1}=\begin{pmatrix}n&0\\0&\boldsymbol{L}\end{pmatrix}^{-1}=\begin{pmatrix}\dfrac{1}{n}&0\\0&\boldsymbol{L}^{-1}\end{pmatrix}$$

$$=\begin{pmatrix}\frac{1}{15} & 0 & 0\\ 0 & 0.003\ 308 & -0.000\ 064\\ 0 & -0.000\ 064 & 0.000\ 075\end{pmatrix}$$

而

$$\frac{Q_e}{n-k-1}=\frac{8.952}{15-2-1}=0.746$$

$$t_1=\frac{\hat{b}_1/\sqrt{c_{11}}}{\sqrt{Q_e/(n-k-1)}}=\frac{-0.216/\sqrt{0.003\ 308}}{\sqrt{0.746}}=-4.348$$

$$t_2=\frac{\hat{b}_2/\sqrt{c_{22}}}{\sqrt{Q_e/(n-k-1)}}=\frac{0.040/\sqrt{0.000\ 075}}{\sqrt{0.746}}=5.348$$

对给定的 $\alpha=0.05$，查得 $t_{0.025}(12)=2.178\ 8$，由于 $|t_1|>2.178\ 8$，$|t_2|>2.178\ 8$，所以回归系数 b_1,b_2 都显著地不等于零.

此例的检验 p 值为

$$p_1=P\{|T_1|\geqslant 4.348\}=0.001\ 5<\alpha=0.05$$

$$p_2=P\{|T_2|\geqslant 5.348\}=0.000\ 2<\alpha=0.05$$

所以，回归系数 b_1,b_2 都显著地不等于零.

对于有回归系数显著地为零的情形，需要剔除自变量，通常可用逐步回归的方法来进行.对此问题感兴趣的读者可以参阅相应专著.

10.3.5 预测

与一元线性回归问题类似，如果经过检验，认为线性回归是显著的，那么剔除了那些次要因子，可以用重新建立的经验回归平面方程对 Y 作预测.在 $x_1=x_{01},x_2=x_{02},\cdots,x_k=x_{0k}$（其中 $x_{01},x_{02},\cdots,x_{0k}$ 为已知数）处记相应的 Y 值为 Y_0，则

$$Y_0=b_0+b_1x_{01}+\cdots+b_kx_{0k}+\varepsilon_0,\quad \varepsilon_0\sim N(0,\sigma^2)$$

这里，我们假定 Y_0 与 $Y_1,Y_2,\cdots,Y_n$ 相互独立.

在 $(x_{01},x_{02},\cdots,x_{0k})$ 处对 Y_0 作预测是指求 Y_0 的预测区间.与一元线性回归中求预测区间的方法类似，记

$$\hat{Y}_0=\hat{b}_0+\hat{b}_1x_{01}+\cdots+\hat{b}_kx_{0k}$$

因为 $Y_0,\hat{Y}_0$ 分别服从正态分布，且二者相互独立，所以 $Y_0-\hat{Y}_0$ 也服从正态分布.由于

$$\begin{aligned}E(Y_0-\hat{Y}_0)&=E(Y_0)-E(\hat{Y}_0)\\&=b_0+b_1x_{01}+\cdots+b_kx_{0k}-b_0-b_1x_{01}-\cdots-b_kx_{0k}\\&=0\end{aligned}$$

$$\begin{aligned}D(Y_0-\hat{Y}_0)&=D(Y_0)+D(\hat{Y}_0)\\&=\sigma^2+D[\overline{Y}+\hat{b}_1(x_{01}-\overline{x}_1)+\cdots+\hat{b}_k(x_{0k}-\overline{x}_k)]\end{aligned}$$

利用 $\overline{Y}$ 与 $\hat{b}_1,\hat{b}_2,\cdots,\hat{b}_k$ 的相互独立性，$\hat{\boldsymbol{B}}\sim N(\boldsymbol{B},\sigma^2\boldsymbol{C})$，其中 $\boldsymbol{C}=(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1}$，可算得

$$D(Y_0 - \hat{Y}_0) = \sigma^2 + \frac{\sigma^2}{n} + \sigma^2 \sum_{i=1}^{k} \sum_{j=1}^{k} c_{ij}(x_{0i} - \bar{x}_i)(x_{0j} - \bar{x}_j)$$

其中 c_{ij} 是矩阵 $\boldsymbol{C}$ 的第 i 行第 j 列元素(注意:这里的行和列分别是从第零行和第零列算起的).因而

$$Y_0 - \hat{Y}_0 \sim N\left(0, \sigma^2\left[1 + \frac{1}{n} + \sum_{i=1}^{k} \sum_{j=1}^{k} c_{ij}(x_{0i} - \bar{x}_i)(x_{0j} - \bar{x}_j)\right]\right)$$

记

$$d_0 = \sqrt{1 + \frac{1}{n} + \sum_{i=1}^{k} \sum_{j=1}^{k} c_{ij}(x_{0i} - \bar{x}_i)(x_{0j} - \bar{x}_j)} \tag{10.3.27}$$

于是

$$\frac{Y_0 - \hat{Y}_0}{\sigma d_0} \sim N(0,1)$$

另一方面$\frac{1}{\sigma^2}Q_e \sim \chi^2(x-k-1)$,而且可以证明 $Y_0 - \hat{Y}_0$ 与$\frac{1}{\sigma^2}Q_e$ 是相互独立的,因此

$$T = \frac{Y_0 - \hat{Y}_0}{\sqrt{\frac{Q_e}{n-k-1}}\, d_0} \sim t(n-k-1)$$

对给定的置信度 $1-\alpha$,有

$$P\left\{\hat{Y}_0 - t_{\alpha/2}(n-k-1)\sqrt{\frac{Q_e}{n-k-1}}\, d_0 < Y_0 < \hat{Y}_0 + t_{\alpha/2}(n-k-1)\sqrt{\frac{Q_e}{n-k-1}}\, d_0\right\} = 1-\alpha$$

即 Y_0 的置信度为 $1-\alpha$ 的预测区间为

$$\left(\hat{Y}_0 - t_{\alpha/2}(n-k-1)\sqrt{\frac{Q_e}{n-k-1}}\, d_0,\ \hat{Y}_0 + t_{\alpha/2}(n-k-1)\sqrt{\frac{Q_e}{n-k-1}}\, d_0\right)$$

其中 d_0 由(10.3.27)式给出.

内容小结

研究一个随机变量与一个或多个可控变量之间相关关系的统计方法称为回归分析.只有一个可控变量的回归分析称为一元回归,多于一个可控变量的回归分析称为多元回归.可控变量与随机变量之间呈线性关系的回归称为线性回归,不呈线性关系的回归称为非线性回归.

回归分析主要包含以下内容:

(1) 建立可控变量与随机变量之间的经验回归方程;

(2) 检验经验回归方程是否有效,并筛选出影响显著的可控变量;

(3) 利用经验回归方程进行预测和控制.

1. 一元线性回归

一元线性回归模型为 $Y_i=a+bx_i+\varepsilon_i,\varepsilon_i\sim N(0,\sigma^2)(i=1,2,\cdots,n)$，且 $\varepsilon_1,\varepsilon_2,\cdots,\varepsilon_n$ 相互独立.

由最小二乘法估计未知参数 a,b，得到估计值 $\hat{b}=\dfrac{\sum\limits_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})}{\sum\limits_{i=1}^{n}(x_i-\bar{x})^2}$，$\hat{a}=\bar{y}-\hat{b}\bar{x}$，可得经验回归直线方程 $\hat{y}=\hat{a}+\hat{b}x$.

非线性回归问题有时可通过适当的变量代换化为线性回归来处理.

2. 多元线性回归

多元线性回归模型为 $Y_i=b_0+b_1x_{i1}+b_2x_{i2}+\cdots+b_kx_{ik}+\varepsilon_i,\quad \varepsilon_i\sim N(0,\sigma^2)(i=1,2,\cdots,n)$，且 $\varepsilon_1,\varepsilon_2,\cdots,\varepsilon_n$ 相互独立.

由最小二乘法估计未知参数，得到估计 $\boldsymbol{B}=(\hat{b}_0,\hat{b}_1,\cdots,\hat{b}_k)^{\mathrm{T}}=(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X})^{-1}\boldsymbol{X}^{\mathrm{T}}\boldsymbol{Y}$，从而建立经验回归平面方程 $\hat{y}=\hat{b}_0+\hat{b}_1x_1+\hat{b}_2x_2+\cdots+\hat{b}_kx_k$.

习题 10

1. 通过原点的一元线性回归模型为

$$Y_i=bx_i+\varepsilon_i\quad(i=1,2,\cdots,n)$$

其中各 ε_i 相互独立，并且都服从正态分布 $N(0,\sigma^2)$. 试由 n 组观测值 $(x_i,y_i)(i=1,2,\cdots,n)$，用最小二乘法估计参数 b.

2. 用最大似然估计法求一元线性回归模型中的参数 a,b 和 σ^2 的估计量.

3. 在考察硝酸钠的可溶性程度时，对一系列不同温度，观察在 100 ml 水中溶解的硝酸钠的质量，获得观察结果如下：

温度 x_i	0	4	10	15	21	29	36	51	68
质量 y_i	66.7	71.0	76.3	80.6	85.7	92.9	99.4	113.6	125.1

从经验和理论知 Y_i 与 x_i 之间有下述关系式：

$$Y_i=a+bx_i+\varepsilon_i\quad(i=1,2,\cdots,9)$$

其中各 ε_i 相互独立，并且都服从正态分布 $N(0,\sigma^2)$. 试用最小二乘法估计参数 a,b 及 σ^2.

4. 在钢线碳含量对于电阻的效应的研究中，得到以下数据：

碳含量 x_i/%	0.10	0.30	0.40	0.55	0.70	0.80	0.95
20℃时的电阻 y_i/μΩ	15	18	19	21	22.6	23.8	26

(1) 作出散点图；

(2) 求经验回归直线方程；

(3) 检验线性回归效果是否显著($\alpha=0.05$)；

(4) 求经验相关系数；

(5) 若线性回归效果显著,求回归系数 b 的置信度为 0.95 的置信区间.

5. 考察温度对产量的影响,测得下列 10 组数据:

温度 x_i/℃	20	25	30	35	40	45	50	55	60	65
产量 y_i/kg	13.2	15.1	16.4	17.1	17.9	18.7	19.6	21.2	22.5	24.3

(1) 求经验回归直线方程;

(2) 检验线性回归效果是否显著($\alpha=0.05$);

(3) 若线性回归效果显著,求 $x=42$℃ 时产量的预测值及置信度为 0.95 的预测区间.

6. 假定某市场每天对橘子的需求量 Y(单位:kg)与销售价格 x(单位:角/kg)之间符合线性回归模型.该市场连续 12 天所卖出橘子的价格与数量的调查数据如下:

x_i/(角 · kg^{-1})	100	90	80	70	70	70	70	65	60	60	55	50
y_i/kg	55	70	90	100	90	105	80	110	125	115	130	130

(1) 试求经验回归直线方程 $\hat{y}=\hat{a}+\hat{b}x$;

(2) 检验线性回归效果是否显著($\alpha=0.05$);

(3) 求参数 a,b,σ^2 的置信度为 0.95 的置信区间;

(4) 解释回归系数 $\hat{b}$ 的含义.

7. 为研究某食品的营养价值,用大白鼠做试验,得大白鼠进食量 x(单位:g)和增加的体重 Y(单位:g)间关系的数据如下:

x_i/g	820	780	720	867	690	787	934	679	639	820
y_i/g	165	158	130	180	134	167	186	145	120	158

(1) 求经验回归直线方程 $\hat{y}=\hat{a}+\hat{b}x$;

(2) 检验线性回归效果是否显著($\alpha=0.05$);

(3) 解释回归系数 $\hat{b}$ 的含义.

8. 炼钢厂出钢时用来盛钢水的钢包由于钢液的侵蚀,其体积不断增大,钢包所盛钢水的质量也增多.设使用次数 x 与盛钢水的质量 Y(单位:kg)有关系

$$\frac{1}{Y}=a+\frac{b}{x}+\varepsilon,\quad \varepsilon\sim N(0,\sigma^2)$$

现得到观测值:

使用次数 x_i/次	2	3	4	5	6	7
钢水质量 y_i/kg	106.42	108.20	109.58	109.50	110.00	109.93
使用次数 x_i/次	8	9	10	11	12	13
钢水质量 y_i/kg	110.49	110.59	110.60	110.90	110.76	111.00

试估计 a,b,并求出经验拟合曲线方程.

9. 混凝土的抗压强度随养护时间的延长而增加,现将一批混凝土做成 12 个试块,记录了养护

时间 x(单位:d)及抗压强度 Y 的数据如下:

养护时间 x_i	2	3	4	5	7	9	12	14	17	21	28	56
抗压强度 y_i	35	42	47	52	59	65	68	73	76	82	86	99

试求 $y=a+b\ln x$ 型经验回归方程.

10. 在彩色显影中,形成染料的光学密度 Y 与析出银的光学密度 x 有密切关系,测得 11 组数据如下:

x_i	0.05	0.06	0.07	0.10	0.14	0.20	0.25	0.31	0.38	0.43	0.47
y_i	0.10	0.14	0.23	0.37	0.59	0.79	1.00	1.12	1.19	1.25	1.29

试求 $y=Ae^{Bx}$ 型经验回归方程.

11. 某种水泥在凝固时放出的热量 Y(单位:cal/g)与水泥中 $3CaO\cdot Al_2O_3$ 成分 x_1(单位:%)和 $3CaO\cdot SiO_2$ 成分 x_2(单位:%)有关.试验数据如下:

$x_{i1}/\%$	7	1	11	11	7	11	3	1	2	21	10
$x_{i2}/\%$	26	29	56	31	52	55	71	31	54	47	68
$y_i/(\text{cal}\cdot\text{g}^{-1})$	78.5	74.3	104.3	87.6	95.9	109.2	102.7	72.5	93.1	115.9	109.4

根据经验,Y 关于 x_1,x_2 有二元线性回归关系

$$Y=b_0+b_1x_1+b_2x_2+\varepsilon,\quad \varepsilon\sim N(0,\sigma^2)$$

(1) 求 b_0,b_1,b_2 的最小二乘估计,写出经验回归平面方程;

(2) 检验线性回归效果是否显著($\alpha=0.05$);

(3) 检验 b_2 是否显著地为零($\alpha=0.05$);

(4) 求 $x_1=9,x_2=50$ 时 Y 的预测值及置信度为 0.95 的预测区间.

12. 一种合金在某种添加剂的不同浓度之下,各做三次试验,得其抗压强度的数据如下:

浓度 x_i	10.0	15.0	20.0	25.0	30.0
抗压强度 y_i	25.2	29.8	31.2	31.7	29.4
	27.3	31.1	32.6	30.1	30.8
	28.7	27.8	29.7	32.3	32.8

(1) 作散点图;

(2) 假定抗压强度 Y 与添加剂的浓度 x 有二次多项式关系

$$Y=b_0+b_1x+b_2x^2+\varepsilon,\quad \varepsilon\sim N(0,\sigma^2)$$

试估计 b_0,b_1,b_2,并写出经验回归曲线方程;

(3) 检验二次多项式回归效果是否显著($\alpha=0.05$).

自测题 10

习题 10 参考答案

第 11 章　随机过程的基本知识

本章首先引入随机过程的概念和记号，其次讨论随机过程的统计描述（分布函数族及数字特征等），最后介绍随机过程的分类.

11.1　随机过程的概念与记号

在概率论部分，我们主要研究一个或有限个随机变量，亦即一维或 n 维随机变量.随着科学技术的发展，人们往往需要观察和研究随机变量随时间的变化过程，也就是随时间演变的随机现象，这就涉及研究无限多个（一族）随机变量的问题.随机过程理论正是在这种要求下，产生于 20 世纪初期，并因物理、生物、通信、控制以及管理科学的需要和促进而逐步发展起来的.

下面，我们来看一些需要从整体上研究无限多个随机变量的例子.

例 11.1（种群生长问题）　考虑一个种群，它由能产生同类后代的个体构成.初始种群的个体数用 X_0 表示，称为第 0 代的总数.第 0 代的全体后代构成第 1 代，其总数用 X_1 表示.一般地，以 X_n 表示第 n 代的总数.欲分析种群生长的变化规律，就要研究随机变量族 $\{X_n, n=0,1,2,\cdots\}$.

例 11.2　研究车站检票口乘客到达的数量.以 $X(t)$ 表示在时间间隔 $(0,t]$ 内到达检票口的人数，$X(t)$ 为取非负整数值的随机变量.要分析客流随时间的演变规律，就要研究一族随机变量 $\{X(t), t\in(0,+\infty)\}$.

例 11.3　为研究极地气候随时间的变化规律.以 $X(t)$ 表示我国南极科考站建立后的第 t 天记录的当地气温值，可以认为 $X(t)$ 是取负数值的随机变量，对每一天做记录，就得到随机变量族 $\{X(t), t=1,2,\cdots\}$.

例 11.4（布朗运动）　英国植物学家布朗发现，一个完全浸没在液体中或在气体里的花粉微粒做不规则运动（后来称这种运动为布朗运动）.这种运动的起因是花粉不断地受到周围介质分子的碰撞，这些微小碰撞力的总和使花粉做随机运动.以 $X(t), Y(t), Z(t)$ 表示 t 时刻花粉微粒的空间坐标，要研究花粉微粒的随机运动规律，就要考虑三维随机变量族 $\{(X(t), Y(t), Z(t)), t\in[0,+\infty)\}$.为了简明起见，我们也可以只考虑其横坐标随时间的演变规律，即研究随机变量族 $\{X(t), t\in[0,+\infty)\}$.

上述例子都涉及依赖于参数而变化的随机变量或者说一族随机变量.在这种随机变量族中，随机变量之间往往不独立.因此，仅对每一个随机变量进行研究是不够的，需要从整体上研究随机变量族，这就引出了随机过程概念.

定义 11.1　设 Ω 为某试验的样本空间，T 为一给定的集合，若对每个 $t\in T$，$X(t,\omega)$ 是定义在 Ω 上的随机变量，则称 $\{X(t,\omega), t\in T\}$ 为**随机过程**，其中，T 称为**参数集**.

随机过程的参数 t 通常解释为时间，这正是称为“过程”的原因.不过在有些场合下，t 也可以表示为别的量，例如序号、距离、高度等，所以一般也称随机过程为**随机函数**.另外，参数 t 也可以是向量，例如 t 是 $\mathbf{R}^3$ 中的点，$X(t)$ 表示 t 点的风速，当参数 t 为向量时也称随机过程为**随机场**.本书仅限于讨论 $T\subset\mathbf{R}$，并把 $t\in T$ 称为时间.

从本质上讲，随机过程 $X(\cdot,\cdot)$ 是关于 $t\in T,\omega\in\Omega$ 的二元映射，即 $X(\cdot,\cdot)$：$T\times\Omega\to\mathbf{R}$.

一方面，当固定 $t\in T$ 时，$X(t,\cdot)$ 是一个随机变量，因此，当 t 取遍 T 中所有元时，$\{X(t,\cdot),t\in T\}$ 代表了一族随机变量；另一方面，当进行一次随机试验，得到样本点 $\omega\in\Omega$ 时，相应地得到了一个 t 的实函数 $X(\cdot,\omega)$，称之为随机过程的**样本函数(样本曲线，路径，轨道)**，因而，与试验的所有可能结果相对应，$\{X(\cdot,\omega),\omega\in\Omega\}$ 代表一族样本函数.此外，与 $t\in T,\omega\in\Omega$ 对应的 $X(t,\omega)$ 是一个实数，称为随机过程的一个**状态**，集合 $S\overset{\text{def}}{=\!=}\{X(t,\omega)\mid t\in T,\omega\in\Omega\}$ 称为随机过程的**状态空间(值域，相空间)**.

随机过程 $\{X(t,\omega),t\in T\}$ 通常简记为 $\{X(t),t\in T\}$.为了简明起见，我们也用记号 X_T 表示随机过程 $\{X(t),t\in T\}$，即

$$X_T\overset{\text{def}}{=\!=}\{X(t),t\in T\}$$

11.2 随机过程的概率特性

11.2.1 有限维分布函数族

掌握分布函数 $F(x)=P\{X\leqslant x\}$ 就能全面地了解随机变量 X.类似地，对于随机过程 X_T，因它代表了彼此可能有关联的一族随机变量，为了描述它的概率特性，我们需要知道对任意一个 $t\in T$，随机变量 $X(t)$ 的分布函数

$$F_t(x)\overset{\text{def}}{=\!=}P\{X(t)\leqslant x\}\tag{11.2.1}$$

称 $F_t(x)$ 为随机过程 X_T 的**一维分布函数**.

我们还需知道对任意两个(一般是不同的)$t_1,t_2\in T$，随机变量 $X(t_1)$ 与 $X(t_2)$ 的联合分布函数

$$F_{t_1,t_2}(x_1,x_2)\overset{\text{def}}{=\!=}P\{X(t_1)\leqslant x_1,X(t_2)\leqslant x_2\}\tag{11.2.2}$$

称 $F_{t_1,t_2}(x_1,x_2)$ 为随机过程 X_T 的**二维分布函数**.

知道了随机过程 X_T 所有的一、二维分布函数，对于研究随机过程仍远远不够.一般地，对任意有限个 $t_1,t_2,\cdots,t_n\in T$，定义过程 X_T 的 n **维分布函数** $F_{t_1,t_2,\cdots,t_n}(x_1,x_2,\cdots,x_n)$ 为

$$F_{t_1,t_2,\cdots,t_n}(x_1,x_2,\cdots,x_n)\overset{\text{def}}{=\!=}P\{X(t_1)\leqslant x_1,X(t_2)\leqslant x_2,\cdots,X(t_n)\leqslant x_n\}\tag{11.2.3}$$

随机过程 X_T 的所有一维分布函数，所有二维分布函数……所有 n 维分布函数，其全体

$$\{F_{t_1,t_2,\cdots,t_n}(x_1,x_2,\cdots,x_n),t_1,t_2,\cdots,t_n\in T,n=1,2,\cdots\}$$

称为 X_T 的**有限维分布函数族**.

掌握了 X_T 的有限维分布函数族就能知道 X_T 中任意有限个随机变量的联合概率分布，从而就能了解这些随机变量之间的相互依赖关系.

不难看出，随机过程的有限维分布函数族具有以下两条性质：

(1) **对称性** 对 $(1,2,\cdots,n)$ 的任一排列 $(j_1,j_2,\cdots,j_n)$，有

$$F_{t_1,t_2,\cdots,t_n}(x_1,x_2,\cdots,x_n)=F_{t_{j_1},t_{j_2},\cdots,t_{j_n}}(x_{j_1},x_{j_2},\cdots,x_{j_n})$$

(2) **相容性** 对 $m<n$,有

$$F_{t_1,t_2,\cdots,t_m}(x_1,x_2,\cdots,x_m)=F_{t_1,t_2,\cdots,t_m,t_{m+1},\cdots,t_n}(x_1,x_2,\cdots,x_m,\infty,\cdots,\infty)$$

理论研究的结果表明,有限维分布函数族能完整地描述随机过程的概率特性.

例 **11.5** 设随机过程 X_T 只有两条样本曲线

$$X(t,\omega_1)=k\cos t, X(t,\omega_2)=k\sin t, \quad -\infty<t<+\infty$$

其中 $k(>0)$ 为常数,$P(\omega_1)=\frac{1}{3}$,$P(\omega_2)=\frac{2}{3}$,求 X_T 的一维分布函数 $F_0(x)$ 和二维分布函数 $F_{0,\pi/2}(x_2,x_2)$.

解 由题意,随机变量 $X(0)$ 服从两点分布:$X(0)\sim\begin{pmatrix}0 & k\\ \frac{2}{3} & \frac{1}{3}\end{pmatrix}$,故有

$$F_0(x)=\begin{cases}0, & x<0,\\ \frac{2}{3}, & 0\leqslant x<k,\\ 1, & x\geqslant k\end{cases}$$

类似地,二维随机向量$\left(X(0),X\left(\frac{\pi}{2}\right)\right)\sim\begin{pmatrix}(0,k) & (k,0)\\ \frac{2}{3} & \frac{1}{3}\end{pmatrix}$,故有

$$F_{0,\pi/2}(x_1,x_2)=\begin{cases}0, & x_1<0 \text{ 或 } x_2<0 \text{ 或 } 0\leqslant x_1<k,0\leqslant x_2<k,\\ \frac{1}{3}, & x_1\geqslant k,0\leqslant x_2<k,\\ \frac{2}{3}, & 0\leqslant x_1<k,x_2\geqslant k,\\ 1, & x_1\geqslant k,x_2\geqslant k\end{cases}$$

11.2.2 随机过程的数字特征

虽然有限维分布函数族完整地刻画了随机过程的概率特性,但实际上,要想获得随机过程的分布函数族往往是困难的,甚至是不可能的.另外,有时也并不需要了解随机过程的全部概率特性,因而,我们来考虑它的局部概率特性——随机过程的数字特征.

设 $X_T=\{X(t),t\in T\}$ 为随机过程,X_T 的**均值函数**定义为

$$m(t)\overset{\text{def}}{=\!=}E[X(t)]=\int_{-\infty}^{+\infty}x\mathrm{d}F_t(x)\text{①} \tag{11.2.4}$$

其中,$F_t(x)$ 为随机过程 X_T 的一维分布函数,$m(t)$ 表示随机过程的样本函数在 t 时刻的状态的理论均值(又称“统计平均”),几何上,它表示 $X(t)$ 在各个时刻的摆动中心.

① 该积分称为黎曼-斯蒂尔切斯积分,其定义见本章附录.

X_T 的**方差函数定义**为

$$D(t)\overset{\text{def}}{=\!=}D[X(t)]=E\{[X(t)-m(t)]^2\} \tag{11.2.5}$$

方差函数也可记为 $V(t)$ 或 $\sigma^2(t)$.

$\sigma(t)=\sqrt{D(t)}$ 称为 X_T 的**标准差函数**.$D(t)$ 和 $\sigma(t)$ 都表示随机过程的样本函数在 t 时刻对 $m(t)$ 的偏离程度.

X_T 的**自相关函数**定义为

$$R_X(t_1,t_2)\overset{\text{def}}{=\!=}E[X(t_1)X(t_2)],\quad t_1,t_2\in T \tag{11.2.6}$$

自相关函数可简称为相关函数,并可简记为 $R(t_1,t_2)$.

X_T 的**自协方差函数**定义为

$$C_X(t_1,t_2)\overset{\text{def}}{=\!=}\text{Cov}(X(t_1),X(t_2)),\quad t_1,t_2\in T \tag{11.2.7}$$

自协方差函数也可简称为协方差函数,并可简记为 $C(t_1,t_2)$.协方差函数 $C(t_1,t_2)$ 的绝对值的大小刻画了过程 X_T 在两个不同时刻所对应的随机变量 $X(t_1)$ 与 $X(t_2)$ 之间的线性相关强弱程度.$C(t_1,t_2)$ 的绝对值越大,$X(t_1)$ 与 $X(t_2)$ 的线性相关程度越强;绝对值越小,两者的线性相关程度越弱.当 $C(t_1,t_2)=0$ 时,$X(t_1)$ 与 $X(t_2)$ 不相关.

当 $m(t)\equiv 0$ 时,由于 $C(t_1,t_2)\equiv R(t_1,t_2)$,因而,相关函数的概率意义可以用零均值过程的协方差函数的概率意义来解释.

因为

$$C(t_1,t_2)=R(t_1,t_2)-m(t_1)m(t_2)$$
$$D(t)=C(t,t)=R(t,t)-m^2(t)$$

所以,均值函数和相关函数是随机过程的两个最基本的数字特征.

设 $X_T=\{X(t),t\in T\}$,$Y_T=\{Y(t),t\in T\}$ 是两个定义在同一样本空间 Ω 上且有同一个参数集 T 的随机过程,X_T 与 Y_T 的**互相关函数**定义为

$$R_{XY}(t_1,t_2)\overset{\text{def}}{=\!=}E[X(t_1)Y(t_2)],\quad t_1,t_2\in T \tag{11.2.8}$$

X_T 与 Y_T 的**互协方差函数**定义为

$$\begin{aligned}C_{XY}(t_1,t_2)&\overset{\text{def}}{=\!=}\text{Cov}(X(t_1),Y(t_2))\\&=E\{[E(t_1)-m_X(t_1)][Y(t_2)-m_Y(t_2)]\},\quad t_1,t_2\in T\end{aligned} \tag{11.2.9}$$

其中 $m_X(t)$,$m_Y(t)$ 分别是 X_T 与 Y_T 的均值函数.

例 11.6 设随机过程 $X_T=\{Vt+b,-\infty<t<+\infty\}$,其中 b 为常数,V 为随机变量且 $V\sim N(0,1)$,求 X_T 的均值函数和相关函数.

解 对任意固定的 $t\in(-\infty,+\infty)$

$$m(t)=E(Vt+b)=tE(V)+b=b$$

对任意固定的 $t_1,t_2\in(-\infty,+\infty)$

$$\begin{aligned}R(t_1,t_2)&=E[(Vt_1+b)(Vt_2+b)]\\&=t_1t_2E(V^2)+b(t_1+t_2)E(V)+b^2\\&=t_1t_2+b^2\end{aligned}$$

例 11.7 设随机过程 $X_T=\{A\cos(\lambda t+\Phi),-\infty<t<+\infty\}$,其中 $\lambda>0$ 为常数,A 和 Φ 为相互独立的随机变量,并且,$A\sim U(0,1)$,$\Phi\sim U(0,2\pi)$,求 X_T 的均值函数和相关

函数.

解 对任意固定的 $t\in(-\infty,+\infty)$,

$$\begin{aligned}m(t)&=E[A\cos(\lambda t+\Phi)]\\&=E(A)\cdot E[\cos(\lambda t+\Phi)]\quad(\text{因为 }A\text{ 与 }\Phi\text{ 相互独立})\\&=\int_0^1 a\mathrm{d}a\cdot\int_0^{2\pi}\cos(\lambda t+\varphi)\frac{1}{2\pi}\mathrm{d}\varphi\\&=0\end{aligned}$$

对任意固定的 $t_1,t_2\in(-\infty,+\infty)$,

$$\begin{aligned}R(t_1,t_2)&=E[A^2\cos(\lambda t_1+\Phi)\cos(\lambda t_2+\Phi)]\\&=E(A^2)E[\cos(\lambda t_1+\Phi)\cos(\lambda t_2+\Phi)]\quad(\text{因为 }A\text{ 与 }\Phi\text{ 相互独立})\\&=\int_0^1 a^2\mathrm{d}a\int_0^{2\pi}\frac{1}{2\pi}\cdot\frac{1}{2}[\cos(\lambda(t_2-t_1))+\cos(\lambda(t_1+t_2)+2\varphi)]\mathrm{d}\varphi\\&=\frac{\cos[\lambda(t_2-t_2)]}{6}\end{aligned}$$

例 11.8 设有两个随机过程 $X_T=\{A\cos(\lambda t+\Theta),-\infty<t<+\infty\}$,$Y_T=\{B\cos(\lambda t+\Theta-\varphi),-\infty<t<+\infty\}$,其中 A,B,λ,φ 为常数,Θ 为随机变量且 $\Theta\sim U(0,2\pi)$,求 X_T 与 Y_T 的互相关函数 $R_{XY}(t_1,t_2)$.

解 对任意固定的 $t_1,t_2\in(-\infty,+\infty)$,

$$\begin{aligned}R_{XY}(t_1,t_2)&=E[A\cos(\lambda t_1+\Theta)B\cos(\lambda t_2+\Theta-\varphi)]\\&=AB\int_0^{2\pi}\cos(\lambda t_1+\theta)\cos(\lambda t_2+\theta-\varphi)\cdot\frac{1}{2\pi}\mathrm{d}\theta\\&=\frac{AB}{2\pi}\int_0^{2\pi}\frac{1}{2}[\cos(\lambda(t_2-t_1)-\varphi)+\cos(\lambda(t_1+t_2)-\varphi+2\theta)]\mathrm{d}\theta\\&=\frac{AB}{2}\cos[\lambda(t_1-t_2)-\varphi]\end{aligned}$$

11.2.3 两个随机过程的不相关与相互独立

设 $X_T=\{X(t),t\in T\}$,$Y_T=\{Y(t),t\in T\}$ 是两个定义在同一样本空间 Ω 上且有同一参数集 T 的随机过程.

若对任意的 $t_1,t_2\in T$,有

$$C_{XY}(t_1,t_2)\equiv 0$$

则称 X_T 与 Y_T 是**不相关的**.

若对任意的正整数 n,m 以及任意的 $t_1,t_2,\cdots,t_n\in T,t_1',t_2',\cdots,t_m'\in T$,$(X(t_1),X(t_2),\cdots,X(t_n))$ 与 $(Y(t_1'),Y(t_2'),\cdots,Y(t_m'))$ 相互独立,则称 X_T 与 Y_T 是**相互独立的**.

由 4.3 节可以推知,如果 X_T 与 Y_T 是相互独立的,并且它们的二阶混合矩存在,那么 X_T 与 Y_T 是不相关的.反之,由 X_T 与 Y_T 的不相关一般并不能得出 X_T 与 Y_T 相互独立的结论.

设 X_T 的均值函数和相关函数为 $m_X(t)$ 和 $R_X(t_1,t_2)$,Y_T 的均值函数和相关函数

为 $m_Y(t)$ 和 $R_Y(t_1,t_2)$，考虑两个过程之和 $Z_T=\{X(t)+Y(t),t\in T\}$ 的均值函数和相关函数

$$m_Z(t)=E[X(t)+Y(t)]=E[X(t)]+E[Y(t)]=m_X(t)+m_Y(t)$$

$$\begin{aligned}R_Z(t_1,t_2)&=E[(X(t_1)+Y(t_1))(X(t_2)+Y(t_2))]\\&=R_X(t_1,t_2)+R_{XY}(t_1,t_2)+R_{YX}(t_1,t_2)+R_Y(t_1,t_2)\end{aligned}$$

当 $m_X(t)\equiv 0\equiv m_Y(t)(\forall t\in T)$，并且 X_T 与 Y_T 是不相关的时，有

$$R_Z(t_1,t_2)=R_X(t_1,t_2)+R_Y(t_1,t_2)$$

11.3 随机过程的基本类型

随机过程通常按两种方式来分类.

11.3.1 按参数集与状态空间分类

按随机过程 $X_T=\{X(t),t\in T\}$ 的参数集 $T(\subset\mathbf{R})$ 与状态空间 S 的可数与否，把过程分为 4 类，即

(1) 可数参数、可数状态的随机过程.

(2) 可数参数、不可数状态的随机过程.

(3) 不可数参数、可数状态的随机过程.

(4) 不可数参数、不可数状态的随机过程.

当 T 可列时，也称 X_T 为**离散参数随机过程**或者**随机序列**(有时也称作**时间序列**).当 T 是实数域 $\mathbf{R}$ 中的有限或无限区间时，称 X_T 为**连续参数随机过程**.

本章的例 11.1~11.4 即分属上述 4 类过程.

11.3.2 按过程的性质特点分类

按过程的性质特点，即依据过程的统计特性(分布族，数字特征)或者按 $X(t)$ 之间的概率法则，对过程进行分类.

1. 二阶矩过程

设 $X_T=\{X(t),t\in T\}$，若对任意 $t\in T$，$E[X^2(t)]$ 都存在，则称 X_T 为**二阶矩过程**.

由第 4 章中柯西-施瓦茨不等式((4.3.9)式)可推知，二阶矩过程的均值函数和相关函数都存在.

在二阶矩过程类中有一些常用的和比较重要的子类，它们是：正态过程、正交增量过程和(宽)平稳过程.

若 $X_T=\{X(t),t\in T\}$ 的任一有限维分布都是多维正态分布，亦即，对任意的 $n\geqslant 1$ 和任意 n 个不同的 $t_1,t_2,\cdots,t_n\in T$，n 维随机向量 $(X(t_1),X(t_2),\cdots,X(t_n))$ 的概率密度为

$$f_{t_1,t_2,\cdots,t_n}(x_1,x_2,\cdots,x_n)=(2\pi)^{-\frac{n}{2}}|\boldsymbol{C}|^{-\frac{1}{2}}\exp\left\{-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{m})^{\mathrm{T}}\boldsymbol{C}^{-1}(\boldsymbol{x}-\boldsymbol{m})\right\}$$

其中

$$\boldsymbol{x}=(x_1,x_2,\cdots,x_n)^{\mathrm{T}},\quad \boldsymbol{m}=(m_X(t_1),m_X(t_2),\cdots,m_X(t_n))^{\mathrm{T}}$$

$$\boldsymbol{C}=\begin{pmatrix} C_X(t_1,t_1) & C_X(t_1,t_2) & \cdots & C_X(t_1,t_n) \\ C_X(t_2,t_1) & C_X(t_2,t_2) & \cdots & C_X(t_2,t_n) \\ \vdots & \vdots & & \vdots \\ C_X(t_n,t_1) & C_X(t_n,t_2) & \cdots & C_X(t_n,t_n) \end{pmatrix}$$

为对称正定矩阵,则称 X_T 为**正态过程(或高斯过程)**.

对于正态过程 X_T 而言,它的均值函数 $m_X(t)$ 和相关函数 $R_X(t_1,t_2)$ 可以完全决定过程的有限维分布,从而不仅可以在二阶矩的范围内,还可以在分布的范围内来研究与过程有关的各种问题,得到一些更强的结果.

设 $X_T=\{X(t),t\geqslant 0\}$ 为二阶矩过程,若对任意的 $0\leqslant t_1<t_2\leqslant t_3<t_4$,恒有

$$E\{[X(t_2)-X(t_1))(X(t_4)-X(t_3)]\}=0$$

则称 X_T 为**正交增量过程**.

对于正交增量过程 $X_T=\{X(t),t\geqslant 0\}$,如果规定 $X(0)=0$,那么,当 $s<t$ 时,有

$$\begin{aligned} E[X(s)X(t)] &= E\{[X(s)-X(0)][X(t)-X(s)+X(s)]\} \\ &= E[X^2(s)] \quad (\text{正交增量性}) \\ &\overset{\text{def}}{=\!=} g(s) \end{aligned}$$

亦即,当 $s<t$ 时,$R_X(s,t)=g(s)$.同理,当 $t\leqslant s$ 时,$R_X(s,t)=g(t)$.因而,一般地,$R_X(s,t)=g(s\wedge t)$,其中记号 $s\wedge t$ 表示 $\min\{s,t\}$.

另外,当 $s<t$ 时,

$$\begin{aligned} E\{[X(t)-X(s)]^2\} &= R_X(t,t)-R_X(t,s)-R_X(s,t)+R_X(s,s) \\ &= g(t)-g(s) \end{aligned}$$

可见,$g(t)$ 是 t 的单调非降函数.

至于(宽)平稳过程,我们将在第 12 章中给予专门的讨论.

2. 独立增量过程

设 $X_T=\{X(t),t\geqslant 0\}$ 为随机过程,若对任意有限个 $0\leqslant t_1<t_2<\cdots<t_n$,增量 $X(t_2)-X(t_1),X(t_3)-X(t_2),\cdots,X(t_n)-X(t_{n-1})$ 相互独立,则称 X_T 为**独立增量过程**.进一步,若独立增量过程 X_T 的任一增量 $X(s+t)-X(s)(s\geqslant 0,t>0)$ 的概率分布与 s 无关,则称 X_T 为**平稳独立增量过程**.

一般而言,独立增量过程并没有要求二阶矩的存在,因而,它未必是二阶矩过程,反之亦然.不过,二阶矩存在的独立增量过程却是独立增量过程类中的重要子类.泊松过程和布朗运动是其中的典型代表.

3. 马尔可夫过程

马尔可夫过程是具有**无后效性**的随机过程.何谓“无后效性”?粗略地说,无后效性是指:当过程在现在时刻 t 所处的状态为已知时,它在将来时刻 $u(u>t)$ 所处状态的概率与它在过去时刻 $s(s<t)$ 的状态无关.或者说得更简单些,“已知‘现在’,‘将来’与‘过去’无关.”

设 $X_T=\{X(t),t\in T\}$ 为随机过程,其中 $T\subset[0,+\infty)$.若对任意 $n\geqslant 1$,任意的 n 个时刻 $0\leqslant t_1<t_2<\cdots<t_n$ 以及任意 $s>0(t_n+s\in T)$,恒有

$$P\{X(t_n+s)\leqslant x \mid X(t_1)=x_1, X(t_2)=x_2, \cdots, X(t_n)=x_n\}$$
$$=P\{X(t_n+s)\leqslant x \mid X(t_n)=x_n\}, x, x_1, \cdots, x_n \in \mathbf{R}$$

成立,则称 X_T 是**马尔可夫过程**,简称为**马氏过程**.

如果马尔可夫过程 X_T 的参数集 $T=\{0,1,2,\cdots\}$ 且状态空间 S 为可数集,那么称 X_T 为**马尔可夫链**,简称为**马氏链**.

如果马尔可夫过程 X_T 的参数集 $T=[0,+\infty)$ 而状态空间 S 为可数集,那么称 X_T 为**连续参数马氏链**.

当马氏过程 X_T 的参数集 T、状态空间 S 均为不可数集时,称其为**一般状态空间上的马氏过程**.

除了前面介绍的三类随机过程外,其他的重要类型还有随机点过程、更新过程和鞅等.限于篇幅,不再一一介绍.

随机过程的两种分类方法各有所长.第一种分类方法把随机过程明确地分为了4类,每一个随机过程属于且仅属于其中的一类,但这种分类法有些流于表面,实际意义并不大.第二种分类方法突出随机过程的性质和特点,强调类中的随机过程的共性,但它没有明确地给出类与类之间的界限.例如,泊松过程既是一个二阶矩过程又是一个独立增量过程,而且它还是一个连续参数的马氏链.

在有些场合,可以将这两种分类法结合起来.比如,把马氏过程进一步地细分为:马氏链、连续参数马氏链和一般状态空间上的马氏过程等不同的子类,以便做个别研究.

11.4 泊松过程与布朗运动

11.4.1 泊松过程的定义与性质

若以 $N(t)$ 表示在时间 $(0,t]$ 内某随机事件 A 的发生次数,则称随机过程 $\{N(t), t\geqslant 0\}$ 为**计数过程**.

显然,计数过程具有以下性质:

(1) $N(t)$ 取非负整数;

(2) 若 $0\leqslant s<t$,则 $N(s)\leqslant N(t)$;

(3) 当 $0\leqslant s<t$ 时,过程的增量 $N(t)-N(s)$ 表示在时间 $(s,t]$ 内随机事件 A 的发生次数.

泊松过程是计数过程中最重要的子类,其定义如下:

定义 11.2 设 $\{N(t), t\geqslant 0\}$ 是计数过程,若它满足条件

(1) $N(0)=0$;

(2) 是独立增量过程;

(3) 对任意的 $s\geqslant 0, t>0$,

$$P\{N(t+s)-N(s)=k\}=\frac{(\lambda t)^k}{k!}e^{-\lambda t}, \quad k=0,1,2,\cdots$$

则称 $\{N(t), t\geqslant 0\}$ 是**强度为 λ 的泊松过程**.

泊松过程还有另一种形式的定义.

定义 11.3 设$\{N(t),t\geqslant 0\}$是计数过程,若它满足条件

(1) $N(0)=0$;

(2) 是独立增量过程;

(3) 对任意的 $t\geqslant 0$ 及充分小的 $\Delta t>0$,

$$P\{N(t+\Delta t)-N(t)=1\}=\lambda\Delta t+o(\Delta t)$$

$$P\{N(t+\Delta t)-N(t)\geqslant 2\}=o(\Delta t)$$

则称$\{N(t),t\geqslant 0\}$是**强度为 λ 的泊松过程**.

泊松过程的两种形式的定义表面上是不一样的,而实质上是等价的.

定理 11.1 定义 11.2 等价于定义 11.3.

证 注意到两种定义的前两个条件完全相同,差别仅在于第三个条件,因而,下面的推证将聚焦在对第三个条件的验证上.

"$\Rightarrow$" 只需运用带佩亚诺余项的泰勒公式,即可由定义 11.2 的(3)推得定义 11.3 的(3)成立(请读者自己完成).

"$\Leftarrow$" 记 $p_n(t)\overset{\text{def}}{=\!=}P\{N(t+s)-N(s)=n\}$,$t\geqslant 0$.

首先,对 $n=0$,考虑 $p_0(t)$.当 $\Delta t>0$ 时,因为

$$\begin{aligned}p_0(t+\Delta t)&=P\{N(t+\Delta t+s)-N(s)=0\}\\&=P\{N(t+s)-N(s)=0,N(t+\Delta t+s)-N(t+s)=0\}\\&=p_0(t)P\{N(t+\Delta t+s)-N(t+s)=0\}\text{(增量的独立性)}\\&=p_0(t)[1-\lambda\Delta t+o(\Delta t)]\text{(由定义 11.3 的(3))}\end{aligned}$$

所以

$$\frac{p_0(t+\Delta t)-p_0(t)}{\Delta t}=-\lambda p_0(t)+\frac{o(\Delta t)}{\Delta t}\tag{11.4.1}$$

在上式两端令 $\Delta t\to 0$,得①

$$p_0'(t)=-\lambda p_0(t)\tag{11.4.2}$$

再由初值条件:$p_0(0)=1$,可解得

$$p_0(t)=\mathrm{e}^{-\lambda t}\tag{11.4.3}$$

其次,对 $n\geqslant 1$,考虑 $p_n(t)$.当 $\Delta t>0$ 时,因为

$$\begin{aligned}p_n(t+\Delta t)&=P\{N(t+\Delta t+s)-N(s)=n\}\\&=P\{N(t+s)-N(s)+N(t+\Delta t+s)-N(t+s)=n\}\\&=\sum_{k=0}^{n}P\{N(t+s)-N(s)=n-k,N(t+\Delta t+s)-N(t+s)=k\}\\&=\sum_{k=0}^{n}p_{n-k}(t)P\{N(t+\Delta t+s)-N(t+s)=k\}\quad\text{(增量的独立性)}\\&=p_n(t)[1-\lambda\Delta t+o(\Delta t)]+p_{n-1}(t)[\lambda\Delta t+o(\Delta t)]+o(\Delta t)\\&=p_n(t)(1-\lambda\Delta t)+p_{n-1}(t)\lambda\Delta t+o(\Delta t)\end{aligned}$$

---

① 当 $\Delta t<0$ 时,采用类似的方法可导出同样的等式,故得到的是关于 $p_0(t)$ 的微分方程,而不仅仅是 $p_0(t)$ 的右导数或者左导数满足的方程.以后为简便起见,只考虑 $\Delta t>0$ 的情形.

所以

$$\frac{p_n(t+\Delta t)-p_n(t)}{\Delta t}=-\lambda p_n(t)+\lambda p_{n-1}(t)+\frac{o(\Delta t)}{\Delta t} \tag{11.4.4}$$

在上式两端令 $\Delta t\to 0$,得

$$p_n'(t)=-\lambda p_n(t)+\lambda p_{n-1}(t) \tag{11.4.5}$$

移项并用 $e^{\lambda t}$ 乘两端,得

$$e^{\lambda t}[p_n'(t)+\lambda p_n(t)]=\lambda e^{\lambda t}p_{n-1}(t)$$

或者

$$\frac{d}{dt}[e^{\lambda t}p_n(t)]=\lambda e^{\lambda t}p_{n-1}(t) \tag{11.4.6}$$

另外,还有初值条件:$p_n(0)=0(n\geqslant 1)$,于是,当 $n=1$ 时,由

$$\begin{cases}\dfrac{d}{dt}[e^{\lambda t}p_1(t)]=\lambda e^{\lambda t}p_0(t)=\lambda,\\ p_1(0)=0\end{cases} \tag{11.4.7}$$

解得

$$p_1(t)=\lambda t e^{-\lambda t} \tag{11.4.8}$$

用数学归纳法,不难解得

$$p_n(t)=\frac{(\lambda t)^n}{n!}e^{-\lambda t}\quad n=1,2,\cdots \tag{11.4.9}$$

综合(11.4.3)和(11.4.9)式,便知结论成立.

其实,泊松过程两种形式的定义的区别就在于,前者从宏观上描述过程增量的概率分布;而后者从微观角度给出过程增量的概率分布.由于在判断某个计数过程是否为泊松过程时,第一种定义中的条件(3)较难验证,因而,有的时候第二种定义比第一种定义实用.

以上定义的泊松过程也称为**齐次泊松过程**.由泊松过程的定义以及概率论的知识,便可推知它的均值函数和方差函数都存在:

因为 $N(t)=N(t)-N(0)\sim P(\lambda t)$,所以 $E[N(t)]=\lambda t, D[N(t)]=\lambda t$.亦即,对任意的 $t>0$,

$$m(t)=E[N(t)]=\lambda t \tag{11.4.10}$$

$$D(t)=D[N(t)]=\lambda t \tag{11.4.11}$$

可见,泊松过程是二阶矩过程.由于泊松过程是独立增量过程,因而,当 $s<t$ 时

$$\begin{aligned}\mathrm{Cov}(N(s),N(t))&=\mathrm{Cov}(N(s),N(t)-N(s)+N(s))\\&=\mathrm{Cov}(N(s),N(s))\quad(\text{增量的独立性})\\&=D[N(s)]=\lambda s\end{aligned}$$

同理,当 $s>t$ 时

$$\mathrm{Cov}(N(s),N(t))=\lambda t$$

故

$$\mathrm{Cov}(N(s),N(t))=\lambda\min\{s,t\} \tag{11.4.12}$$

这样,我们又求得了泊松过程的协方差函数和相关函数:

$$C(s,t)=\lambda\min\{s,t\} \tag{11.4.13}$$

$$R(s,t)=\lambda\min\{s,t\}+\lambda^2 st \tag{11.4.14}$$

由(11.4.10)式知,$\lambda=E[N(t)]/t$,即,数 λ 表示单位时间内事件 A 的平均发生次数,这便是称其为"强度"的来由.

若定义 11.3 中的强度 λ 不是均匀的而是时间 t 的函数 $\lambda=\lambda(t)$,$t\geqslant 0$,则称该过程为强度函数为 $\lambda(t)(t\geqslant 0)$ 的**非齐次泊松过程**.对于非齐次泊松过程,其增量的概率分布为

对强度函数为 $\lambda(t)(t\geqslant 0)$ 的非齐次泊松过程而言,引入"累积强度函数":$A(t)\overset{\text{def}}{=\!=}\int_0^t\lambda(s)\,\mathrm{d}s\,(t\geqslant 0)$ 可使相应的表达式、公式描述起来更加简洁.

$$P\{N(t+s)-N(s)=k\}=\frac{\left(\int_s^{t+s}\lambda(\tau)\,\mathrm{d}\tau\right)^k}{k!}\mathrm{e}^{-\int_s^{t+s}\lambda(\tau)\,\mathrm{d}\tau},\quad k=0,1,2,\cdots$$

其中 $s\geqslant 0,t>0$.

进而可得到非齐次泊松过程的均值函数和相关函数:

$$m(t)=\int_0^t\lambda(\tau)\,\mathrm{d}\tau \tag{11.4.15}$$

$$R(s,t)=\int_0^{\min\{s,t\}}\lambda(\tau)\,\mathrm{d}\tau\left(1+\int_0^{\max\{s,t\}}\lambda(\tau)\,\mathrm{d}\tau\right) \tag{11.4.16}$$

下面,我们回到齐次泊松过程,来讨论与之有关的一些概率问题.设 $\{N(t),t\geqslant 0\}$ 是强度为 λ 的泊松过程,泊松过程是一个计数过程,故 $N(t)$ 表示在时间 $(0,t]$ 内某事件 A 的发生次数.令 $S_0=0$,$S_n(n\geqslant 1)$ 表示事件 A 第 n 次发生的时刻.显然,S_n 是随机变量,直观上,S_n 是从时刻 $t=0$ 开始直到 A 第 n 次发生所需的等待时间.现在来求 S_n 的概率分布,注意到 $\{S_n>t\}=\{N(t)<n\}$,故

$$F_{S_n}(t)=P\{S_n\leqslant t\}=P\{N(t)\geqslant n\}=\sum_{k=n}^{\infty}\frac{(\lambda t)^k}{k!}\mathrm{e}^{-\lambda t},\quad t\geqslant 0$$

在上式两端关于 t 求导,得 S_n 的概率密度

$$f_{S_n}(t)=\begin{cases}\dfrac{\lambda(\lambda t)^{n-1}}{(n-1)!}\mathrm{e}^{-\lambda t}, & t>0,\\ 0, & t\leqslant 0\end{cases} \tag{11.4.17}$$

特别,事件首次发生的等待时间 S_1 服从指数分布

$$f_{S_1}(t)=\begin{cases}\lambda\mathrm{e}^{-\lambda t}, & t>0,\\ 0, & t\leqslant 0\end{cases} \tag{11.4.18}$$

又令 $T_n=S_n-S_{n-1}$,$n=1,2,\cdots$ T_n 表示事件第 n 次发生与第 $n-1$ 次发生的**时间间隔**.现在来求 T_n 的概率分布,首先,因为 $T_1=S_1$,所以 T_1 服从指数分布,亦即

$$P\{T_1\leqslant t\}=\begin{cases}1-\mathrm{e}^{-\lambda t}, & t\geqslant 0,\\ 0, & t<0\end{cases} \tag{11.4.19}$$

其次,对 T_2,考虑如下的条件分布

$$\begin{aligned}P\{T_2\leqslant t\mid T_1=s\}&=1-P\{T_2>t\mid T_1=s\}\\&=1-P\{\text{在}(s,s+t]\text{内事件}A\text{不发生}\mid T_1=s\}\\&=1-P\{N(t+s)-N(s)=0\}\quad(\text{增量的独立性})\\&=1-P\{N(t)=0\}\quad(\text{增量的平稳性})\\&=1-\mathrm{e}^{-\lambda t}\quad(t\geqslant 0)\end{aligned}$$

这表明 T_2 与 T_1 是相互独立的，且 T_2 也服从指数分布((11.4.18)式).对 $T_3,T_4,\cdots$ 依次重复上述步骤，可知对 $n=1,2,\cdots$，

$$f_{T_n}(t)=\begin{cases}\lambda e^{-\lambda t}, & t>0,\\ 0, & t\leqslant 0\end{cases}$$

说明时间间隔序列 $\{T_n\}$ 服从相同的指数分布((11.4.18)式).不仅如此，理论上还可以证明，$T_1,T_2,\cdots,T_n,\cdots$ 是相互独立的随机变量序列.

把上述结论归结起来，便得如下定理：

定理 11.2 强度为 λ 的泊松过程的时间间隔序列 $\{T_n\}$ 是相互独立的随机变量序列，且服从相同的指数分布((11.4.18)式).

此外，上述定理的逆命题也成立，即有：

定理 11.3 设 $\{N(t),t\geqslant 0\}$ 是计数过程，若其时间间隔 $\{T_n\}$ 是相互独立的随机变量序列，且服从相同的指数分布((11.4.18)式)，则 $\{N(t),t\geqslant 0\}$ 是强度为 λ 的泊松过程.

这两个定理刻画了泊松过程的本质特征，即，一个计数过程是泊松过程，当且仅当其时间间隔相互独立且服从同一指数分布.

11.4.2 布朗运动

拓展阅读：噪声和布朗运动

布朗运动现象最先是由布朗观察到的，1905 年爱因斯坦首先给出了这一现象的物理学上的解释，1918 年维纳构造了布朗运动的数学模型，故布朗运动又称为**维纳过程**.

定义 11.4 设 $\{W(t),t\geqslant 0\}$ 为随机过程，若它满足

(1) $W(0)=0$；

(2) 是独立增量过程；

(3) 增量 $W(t)-W(s)\sim N(0,\sigma^2|t-s|),\sigma>0$，

则称 $\{W(t),t\geqslant 0\}$ 为**布朗运动**或**维纳过程**.

布朗运动有下述性质：

设 $\{W(t),t\geqslant 0\}$ 是布朗运动，则有

(1) $\{W(t),t\geqslant 0\}$ 是平稳独立增量过程；

(2) $\{W(t),t\geqslant 0\}$ 是正态过程；

(3) $m_W(t)=0(t\geqslant 0),C_W(s,t)=R_W(s,t)=\sigma^2\min\{s,t\}\quad(s,t\geqslant 0)$.

首先，由定义 11.4 中(2)和(3)可知性质(1)成立.其次，对任意自然数 n 以及任意的 n 个时刻 $0\leqslant t_1<t_2<\cdots<t_n$，考察 n 维随机向量 $(W(t_1),W(t_2),\cdots,W(t_n))$ 的概率分布.因为

$$\begin{aligned}W(t_1)&=W(t_1)-W(0)\\ W(t_2)&=[W(t_1)-W(0)]+[W(t_2)-W(t_1)]\\ &\cdots\cdots\\ W(t_n)&=[W(t_1)-W(0)]+[W(t_2)-W(t_1)]+\cdots+[W(t_n)-W(t_{n-1})]\end{aligned}$$

所以对任意 n 个实数 $a_1,a_2,\cdots,a_n$，有

$$\sum_{k=1}^{n} a_k W(t_k) = \sum_{k=1}^{n} A_k [W(t_k) - W(t_{k-1})]$$

其中，$W(t_0) \overset{\text{def}}{=\!=} W(0) = 0$，$A_k = \sum_{i=k}^{n} a_i \ (1 \leqslant k \leqslant n)$. 上式右端是独立正态变量的线性组合，故仍为正态变量，再由 n 维正态向量的性质(4.3.3 节)可知 $(W(t_1), W(t_2), \cdots, W(t_n))$ 是 n 维正态向量，故 $\{W(t), t \geqslant 0\}$ 是正态过程. 最后，我们来讨论性质(3). 由定义 11.4 的(3)可知，对任意 $t>0$，$W(t) \sim N(0, \sigma^2 t)$，于是

$$m_W(t) = E[W(t)] = 0 \quad (t \geqslant 0)$$

$$D_W(t) = D[W(t)] = \sigma^2 t \quad (t \geqslant 0)$$

因为 $m_W(t) \equiv 0 (t \geqslant 0)$，所以 $C_W(s,t) = R_W(s,t)$. 当 $s<t$ 时

$$\begin{aligned} C_W(s,t) &= \operatorname{Cov}(W(s), W(t)) \\ &= \operatorname{Cov}(W(s), W(t) - W(s) + W(s)) \\ &= \operatorname{Cov}(W(s), W(s)) \quad \text{(增量的独立性)} \\ &= D[W(s)] = \sigma^2 s \end{aligned}$$

同理，当 $s \geqslant t$ 时，$C_W(s,t) = \sigma^2 t$，故有

$$C_W(s,t) = R_W(s,t) = \sigma^2 \min\{s,t\}$$

11.5 附录

黎曼-斯蒂尔切斯积分的定义和性质

设 $g(x)$ 为区间 $[a,b]$ 上的有界实函数，$F(x)$ 为区间 $[a,b]$ 上的单调非降函数. 若对 $[a,b]$ 的任意划分：$a = x_0 < x_1 < \cdots < x_{n-1} < x_n = b$ 以及在每个子区间上任意选取的点 $\xi_i \in [x_{i-1}, x_i]$，$i = 1, 2, \cdots, n$. 当 $d = \max\limits_{1 \leqslant i \leqslant n} \{x_i - x_{i-1}\} \to 0$ 时，和数

$$\sigma_n = \sum_{i=1}^{n} g(\xi_i) \Delta_{[x_{i-1}, x_i]} F = \sum_{i=1}^{n} g(\xi_i) [F(x_i) - F(x_{i-1})]$$

收敛于同一个有限的极限，则称 $g(x)$ 在区间 $[a,b]$ 上对 $F(x)$ 黎曼-斯蒂尔切斯(Riemann-Stieltjes)可积(简称 R-S 可积)，该极限值记为 $\int_a^b g(x) \mathrm{d}F(x)$，称为 $g(x)$ 对 $F(x)$ 在 $[a,b]$ 上的 R-S 积分.

在上述定义中，若取 $F(x) = x$，则 R-S 积分化为普通的黎曼积分. 所以 R-S 积分是黎曼积分的推广.

有限区间上的 R-S 积分概念可推广到无穷区间上. 若 $g(x)$ 在任意的有限区间 $[a,b]$ 上对 $F(x)$ R-S 可积，且当 $a \to -\infty$，$b \to +\infty$ 时，极限 $\lim\limits_{a \to -\infty, b \to +\infty} \int_a^b g(x) \mathrm{d}F(x)$ 存在，则称

$$\int_{-\infty}^{+\infty} g(x) F(x) \overset{\text{def}}{=\!=} \lim_{\substack{a \to -\infty \\ b \to +\infty}} \int_a^b g(x) \mathrm{d}F(x)$$

为 $g(x)$ 对 $F(x)$ 在 $(-\infty, +\infty)$ 上的 R-S 积分.

R-S 积分的性质：

(1) $\int_a^b \mathrm{d}F(x)=F(b)-F(a)$;

(2) 若 $g(x)\geqslant 0$,且 $a<b$,则 $\int_a^b g(x)\mathrm{d}F(x)\geqslant 0$;

(3) $\int_a^b [c_1g_1(x)+c_2g_2(x)]\mathrm{d}F(x)=c_1\int_a^b g_1(x)\mathrm{d}F(x)+c_2\int_a^b g_2(x)\mathrm{d}F(x)(c_1,c_2\in\mathbf{R})$;

(4) $\int_a^b g(x)\mathrm{d}[c_1F_1(x)+c_2F_2(x)]=c_1\int_a^b g(x)\mathrm{d}F_1(x)+c_2\int_a^b g(x)\mathrm{d}F_2(x)(c_1,c_2\in\mathbf{R})$;

(5) 对 $a<c<b$, $\int_a^b g(x)\mathrm{d}F(x)=\int_a^c g(x)\mathrm{d}F(x)+\int_c^b g(x)\mathrm{d}F(x)$.

注　与黎曼积分相似的是,在(3)、(4)的情况下,由右端积分的存在可推得左端积分的存在,与黎曼积分不同的是,在(5)的情形下,要求三个积分皆存在.上述性质中的(2)—(5)对无穷区间上的 R-S 积分同样成立.

关于 R-S 积分,还要指出它的一个重要性质:

(6) 设 $g(x)$ 是 $(-\infty,+\infty)$ 上的连续函数,若 $\int_{-\infty}^{+\infty} g(x)\mathrm{d}F(x)$ 绝对收敛,则

1° 当 $F(x)$ 为跳跃函数,在 $x_i(i=1,2,\cdots)$ 具有跃度 p_i 时,R-S 积分化为一个级数

$$\int_{-\infty}^{+\infty} g(x)\mathrm{d}F(x)=\sum_i g(x_i)p_i$$

2° 当 $F(x)$ 存在导数 $F'(x)=f(x)$ 时,R-S 积分化为黎曼积分

$$\int_{-\infty}^{+\infty} g(x)\mathrm{d}F(x)=\int_{-\infty}^{+\infty} g(x)f(x)\mathrm{d}x$$

下面,把 R-S 积分概念由一维推广到 n 维.

设 $F(x_1,x_2,\cdots,x_n)$ 是 n 元实函数,若对 n 维欧氏空间中的任意区间 $[\boldsymbol{a},\boldsymbol{b}]$(这里 $\boldsymbol{a}=(a_1,a_2,\cdots,a_n)$, $\boldsymbol{b}=(b_1,b_2,\cdots,b_n)$, $-\infty<a_i<b_i<\infty$, $i=1,2,\cdots,n$), F 在 $[\boldsymbol{a},\boldsymbol{b}]$ 上的增量都是非负的,即

$$\Delta_{[\boldsymbol{a},\boldsymbol{b}]}F\overset{\text{def}}{=\!=}\sum_{I\subset\{1,2,\cdots,n\}}(-1)^{|I|}F(a_I,b_{C(I)})\geqslant 0$$

其中 $(a_I,b_{C(I)})$ 表示这样的 n 维向量,下标属于 I 的分量用 $\boldsymbol{a}$ 的相应分量,下标属于余集 $C(I)=\{1,2,\cdots,n\}-I$ 的分量用 $\boldsymbol{b}$ 的相应分量. $|I|$ 表示子集 I 中元素的个数,则称 $F(x_1,x_2,\cdots,x_n)$ 是 n **元单调非降函数**.

在概率论中,设 $F(x,y)$ 为二维随机变量 (X,Y) 的分布函数,因此,对任意的 $x_1<x_2$, $y_1<y_2$,都有

$$\begin{aligned}&F(x_2,y_2)-F(x_1,y_2)-F(x_2,y_1)+F(x_1,y_1)\\&=P\{x_1<X\leqslant x_2,y_1<Y\leqslant y_2\}\geqslant 0\end{aligned}$$

所以,$F(x,y)$ 是二元单调非降函数.一般地,若 $F(x_1,x_2,\cdots,x_n)$ 是 n 维随机变量 $(X_1,X_2,\cdots,X_n)$ 的分布函数,则它必是 n 元单调非降函数.

给定区间 $[\boldsymbol{a},\boldsymbol{b}]$(这里,$\boldsymbol{a}=(a_1,a_2,\cdots,a_n)$, $\boldsymbol{b}=(b_1,b_2,\cdots,b_n)$,且 $a_i<b_i$, $i=1,2,\cdots,n$),设 $g(x_1,x_2,\cdots,x_n)$, $F(x_1,x_2,\cdots,x_n)$ 分别是定义在 $[\boldsymbol{a},\boldsymbol{b}]$ 上的 n 元有界实函数和 n 元单调非降函数.若对 $[\boldsymbol{a},\boldsymbol{b}]$(几何上,$[\boldsymbol{a},\boldsymbol{b}]$ 表示 n 维欧氏空间中的"长方体"区

域)用一组垂直于各坐标轴的坐标平面进行任意划分,把它分成 N 个子区域,以 d_i 表示第 i 个子区域的直径,以 $\Delta_i F$ 表示 F 在第 i 个子区域上的增量,以 $\boldsymbol{\xi}_i=(\xi_1^{(i)},\xi_2^{(i)},\cdots,\xi_n^{(i)})$ 表示在第 i 个子区域上任意选取的一点,当 $d=\max\limits_{1\leqslant i\leqslant N}\{d_i\}\to 0$ 时,和数

$$\sigma_N=\sum_{i=1}^{N} g(\boldsymbol{\xi}_i)\Delta_i F$$

收敛于同一个有限的极限,则把该极限值记为

$$\int_{a_1}^{b_1}\cdots\int_{a_n}^{b_n} g(x_1,x_2,\cdots,x_n)\,\mathrm{d}F(x_1,x_2,\cdots,x_n)$$

称之为 $g(x_1,x_2,\cdots,x_n)$ 对 $F(x_1,x_2,\cdots,x_n)$ 在 $[\boldsymbol{a},\boldsymbol{b}]$ 上的 n 重 R-S 积分.

n 重 R-S 积分也有类似于 R-S 积分的那些性质((1)—(4)),此外,它还有如下性质:

(7) 若积分 $\int_{a_i}^{b_i} g_i(x_i)\,\mathrm{d}F_i(x_i)$ $(i=1,2,\cdots,n)$ 存在,又 $g(x_1,x_2,\cdots,x_n)=g_1(x_1)g_2(x_2)\cdots g_n(x_n)$,$F(x_1,x_2,\cdots,x_n)=F_1(x_1)F_1(x_2)\cdots F_n(x_n)$,则 $g(x_1,x_2,\cdots,x_n)$ 对 $F(x_1,x_2,\cdots,x_n)$ 在 $[\boldsymbol{a},\boldsymbol{b}]$ ($[\boldsymbol{a},\boldsymbol{b}]$ 的含义如前所述)上的 n 重 R-S 积分存在,并且

$$\int_{a_1}^{b_1}\cdots\int_{a_n}^{b_n} g(x_1,x_2,\cdots,x_n)\,\mathrm{d}F(x_1,x_2,\cdots,x_n)=\int_{a_1}^{b_1} g_1(x_1)\,\mathrm{d}F_1(x_1)\cdots\int_{a_n}^{b_n} g_n(x_n)\,\mathrm{d}F_n(x_n)$$

关于反常 n 重 R-S 积分的定义及其性质,因其与前面所讨论的相仿,故不一一赘述.

内容小结

1. 随机过程

T 为给定的集合,Ω 是样本空间,对每个 $t\in T$,$X(t,\omega)$ 都是定义在 Ω 上的随机变量,则 $X_T=\{X(t,\omega),t\in T\}$ 称为随机过程.

对任意的正整数 n,有限个时刻 $t_1,t_2,\cdots,t_n\in T$,定义随机过程 X_T 的 n 维分布函数为 $F_{t_1,t_2,\cdots,t_n}(x_1,x_2,\cdots,x_n)=P\{X(t_1)\leqslant x_1,X(t_2)\leqslant x_2,\cdots,X(t_n)\leqslant x_n\}$.随机过程 X_T 的所有有限维分布函数的全体称为随机过程的有限维分布函数族:

$$\{F_{t_1,t_2,\cdots,t_n}(x_1,x_2,\cdots,x_n),t_1,t_2,\cdots,t_n\in T,n=1,2,\cdots\}$$

随机过程 X_T 的均值函数定义为 $m(t)=E[X(t)]$,方差函数定义为 $D(t)=D[X(t)]$,自相关函数定义为 $R_X(t_1,t_2)=E[X(t_1)X(t_2)]$.

在同一个样本空间 Ω 上,有同一个参数集 T 的两个随机过程 X_T,Y_T 的互相关函数定义为 $R_{XY}(t_1,t_2)=E[X(t_1)Y(t_2)]$.互协方差函数定义为 $C_{XY}(t_1,t_2)=\mathrm{Cov}(X(t_1),Y(t_2))$.

如果对任意的 $t_1,t_2\in T$,$C_{XY}(t_1,t_2)\equiv 0$,则称 X_T,Y_T 是不相关的.如果对任意的正整数 n,m,以及任意的 $t_1,t_2,\cdots,t_n,s_1,s_2,\cdots,s_m\in T$,$(X(t_1),X(t_2),\cdots,X(t_n))$ 与 $(Y(s_1),Y(s_2),\cdots,Y(s_m))$ 相互独立,则称随机过程 X_T 与随机过程 Y_T 相互独立.

2. 泊松过程和布朗运动

假设随机过程 $\{N(t),t\geqslant 0\}$ 是计数过程,满足条件:(1) $N(0)=0$;(2) $\{N(t),t\geqslant 0\}$ 是独立增量过程;(3) 对任意的 $s\geqslant 0,t>0$,

$$P\{N(s+t)-N(t)=k\}=\frac{(\lambda t)^k}{k!}e^{-\lambda t},\quad k=0,1,2,\cdots$$

则称随机过程$\{N(t),t\geqslant 0\}$是强度为 λ 的泊松过程.

假设随机过程$\{W(t),t\geqslant 0\}$满足:(1) $W(0)=0$;(2) $\{W(t),t\geqslant 0\}$是独立增量过程;(3) 增量 $W(t)-W(s)\sim N(0,\sigma^2|t-s|)(\sigma>0)$,则称随机过程$\{W(t),t\geqslant 0\}$是布朗运动或维纳过程.

习题 11

1. 设 ξ 是一个随机变量,$\xi\sim B(1,p)$,$0<p<1$,试求随机过程 $X(t)=t\xi$,$-\infty<t<+\infty$ 的

(1) 一维分布函数 $F_0(x)$,$F_{-1}(x)$,$F_1(x)$;

(2) 二维分布函数 $F_{0,1}(x_1,x_2)$,$F_{-1,1}(x_1,x_2)$.

2. 设 ξ 是一个随机变量,$\xi\sim U[0,1]$,试求随机过程 $X(t)=t\xi$,$-\infty<t<+\infty$ 的一维分布函数.

3. 利用投掷一枚硬币的试验定义随机过程为

$$X(t)=\begin{cases}\cos \pi t, & \text{出现正面},\\ 2t, & \text{出现反面}\end{cases}$$

假设出现"正面"和"反面"的概率各为$\frac{1}{2}$,试求随机过程$\{X(t),-\infty<t<+\infty\}$的

(1) 一维分布函数 $F_{1/2}(x)$,$F_1(x)$;

(2) n 维分布律.

4. 设 $X_1,X_2,\cdots$是一列独立同分布的正态 $N(0,\sigma^2)$随机变量,试求随机序列 $Y(n)=\sum\limits_{i=1}^{n}X_i$,$n=1,2,\cdots$的一维概率密度.

5. 设 $X_1,X_2,\cdots$是一列独立同分布的随机变量,服从参数为 λ 的泊松分布,试求随机序列 $Y(n)=\sum\limits_{i=1}^{n}X_i$,$n=1,2,\cdots$的

(1) 一维分布律;

(2) 二维分布律.

6. 设 A,B 是两个相互独立的标准正态随机变量,试求随机过程 $X(t)=At+B$,$-\infty<t<+\infty$ 的一维和二维概率密度.

7. 设 X 是一个随机变量,其分布函数为 $F(x)$,试求随机过程 $X(t)\equiv X$,$-\infty<t<+\infty$ 的一维和 n 维分布函数.

8. 设$\{X(t),t\in T\}$是一随机过程,a 是任一实数,定义随机过程

$$Y(t)=\begin{cases}1, & X(t)\leqslant a,\\ 0, & X(t)>a,\end{cases}\quad t\in T$$

试将 $Y(t)$的均值函数和自相关函数用 $X(t)$的一维分布函数 $F_t(x)$和二维分布函数 $F_{t_1,t_2}(x_1,x_2)$表示出来.

9. 设随机过程$\{X(t),-\infty<t<+\infty\}$只有四条样本曲线 $X(t,\omega_1)=1$,$X(t,\omega_2)=-1$,$X(t,\omega_3)=\sin t$,$X(t,\omega_4)=\cos t$,且 $P(\{\omega_i\})=\frac{1}{4}$,$i=1,2,3,4$. 求此随机过程的均值函数与自相关函数.

10. 求随机过程$\{X(t),-\infty<t<+\infty\}$的均值函数、自相关函数、自协方差函数、方差函数和标准差函数,

(1) 对第 1 题中的 $X(t)$;

(2) 对第 2 题中的 $X(t)$;

(3) 对第 3 题中的 $X(t)$;

(4) 对第 6 题中的 $X(t)$.

11. 求随机序列 $\{Y(n), n=1,2,\cdots\}$ 的均值函数和自协方差函数,

(1) 对第 4 题中的 $Y(n)$;

(2) 对第 5 题中的 $Y(n)$.

12. 设 X 和 Y 是随机变量,$E(X)=\mu_1$,$E(Y)=\mu_2$,$D(X)=\sigma_1^2$,$D(Y)=\sigma_2^2$,$\rho(X,Y)=\rho$,试求随机过程 $Z(t)=X+Yt$,$-\infty<t<+\infty$ 的均值函数和自协方差函数.

13. 设随机变量 A 服从参数为 λ 的指数分布,试求随机过程 $X(t)=\mathrm{e}^{-At}$,$t>0$ 的

(1) 一维概率密度;

(2) 均值函数;

(3) 自相关函数.

14. 设 $\{X(t), t\in T\}$ 是一个二阶矩过程,$\varphi(t)$ $(t\in T)$ 是一个普通函数,$Y(t)=X(t)+\varphi(t)$,$Z(t)=\varphi(t)X(t)$,

(1) 证明 $\{Y(t), t\in T\}$ 和 $\{Z(t), t\in T\}$ 都是二阶矩过程;

(2) 用 $X(t)$ 的均值函数和自协方差函数分别表示 $Y(t)$ 和 $Z(t)$ 的均值函数、自协方差函数和互协方差函数.

15. 证明第 4 题中的随机序列 $\{Y(n), n=1,2,\cdots\}$ 是独立增量序列,也是正交增量序列.

16. 证明第 5 题中的随机序列 $\{Y(n), n=1,2,\cdots\}$ 是独立增量序列,但不是正交增量序列.

17. 设随机变量 $\xi\sim U[-\pi,\pi]$,$X(t)=\sin t\xi$,$Y(t)=\cos t\xi$,$T=\{0,\pm1,\pm2,\cdots\}$,证明:随机过程 $X_T=\{X(t), t\in T\}$ 与 $Y_T=\{Y(t), t\in T\}$ 互不相关.

18. 在直线上做随机运动的质点,如果在某时刻质点位于整数 i,则下一步质点分别以 $\frac{1}{2}$ 的概率向右移动一格到 $i+1$,或向左移动一格到 $i-1$,若以 $X(n)$ 表示时刻 n 时质点的位置,则 $\{X(n), n=0,1,2,\cdots\}$ 是一个随机过程,称为随机游动,试证明这个过程是马尔可夫过程.

19. 设 $X(t)=A\cos\omega t+B\sin\omega t$,$t\in T=(-\infty,+\infty)$,其中 A,B 是相互独立且同服从正态分布 $N(\mu,\sigma^2)$ 的随机变量,ω 是实常数,

(1) 证明 $X_T=\{X(t), t\in T\}$ 是正态过程;

(2) 求 $X_T=\{X(t), t\in T\}$ 的均值函数和自协方差函数.

20. 设 $X_T=\{X(t), t\geqslant 0\}$ 和 $Y_T=\{Y(t), t\geqslant 0\}$ 是两个相互独立的分别有强度 λ 和 μ 的泊松过程,试证明 $Z_T=\{X(t)+Y(t), t\geqslant 0\}$ 是具有强度 $\lambda+\mu$ 的泊松过程.

21. 设 $\{N(t), t\geqslant 0\}$ 为泊松过程,证明:若 $s<t$,则

$$P\{N(s)=k \mid N(t)=n\}=\mathrm{C}_n^k\left(\frac{s}{t}\right)^k\left(1-\frac{s}{t}\right)^{n-k},\quad k=0,1,2,\cdots,n$$

22. 设通过某路口的汽车流可看作泊松过程,若在 1 分钟内没有车通过的概率为 0.2,求在 2 分钟内有多于 1 辆车通过的概率.

23. 设在时间区间 $(0,t]$ 来到某商店门口的顾客数 $N(t)$ 是强度为 λ 的泊松过程,每个来到商店门口的顾客进入商店的概率为 p,不进入商店就离去的概率是 $1-p$,各个顾客进入商店与否相互独立,令 $X(t)$ 为 $(0,t]$ 内进入商店的顾客数,证明 $\{X(t), t\geqslant 0\}$ 是强度为 λp 的泊松过程.

24. 设 $\{N(t), t\geqslant 0\}$ 是强度为 λ 的泊松过程,S_n $(n\geqslant 1)$ 表示事件 A 第 n 次出现的发生时刻,试求 (S_1,S_2) 的联合概率密度.

25. 设保险公司在 t_i 时发生理赔的金额为 X_i,各 X_i 相互独立同分布,其均值为 μ,方差为 σ^2,若在 $[0,t]$ 内发生理赔的次数 $N(t)$ $(t\geqslant 0)$ 是强度为 λ 的泊松过程,并且与 $\{X_i, i=1,2,\cdots\}$ 独立,试

求保险公司在$[0,t]$内将要支付的总理赔额$Y(t)$的均值与方差.

26. 设$\{N(t),t\geqslant 0\}$是强度为λ的泊松过程,随机变量T服从参数为μ的指数分布,且与$\{N(t),t\geqslant 0\}$相互独立,试证明$N(T)$服从几何分布

$$P\{N(T)=k\}=\frac{\mu}{\lambda+\mu}\left(\frac{\lambda}{\lambda+\mu}\right)^{k},\quad k=0,1,2,\cdots$$

27. 设$\{N(t),t\geqslant 0\}$是强度为λ的泊松过程,试求它的有限维分布律族.

28. 设$\{W(t),t\geqslant 0\}$是布朗运动,$a>0$是常数,试证明下列过程也为布朗运动:

(1) $X(t)=W(t+a)-W(a),t\geqslant 0$;

(2) $Y(t)=aW\left(\frac{t}{a^2}\right),t\geqslant 0$.

29. 设$\{W(t),0\leqslant t\leqslant 1\}$为布朗运动,令

$$X(t)=W(1)-W(1-t),\quad 0\leqslant t\leqslant 1$$

证明$\{X(t),0\leqslant t\leqslant 1\}$也为布朗运动.

30. 设$\{W(t),t\geqslant 0\}$是参数为σ^2的布朗运动,求下列过程的自协方差函数:

(1) $X(t)=W(t+a)-W(a),t\geqslant 0$,其中$a>0$为常数;

(2) $X(t)=aW\left(\frac{t}{a^2}\right),t\geqslant 0$,其中$a>0$为常数;

(3) $X(t)=W(t)+At,t\geqslant 0$,其中$A$为与$\{W(t),t\geqslant 0\}$相互独立的标准正态变量.

自测题 11

习题 11 参考答案

第12章 平稳过程

有两种不同含义的平稳过程——严平稳过程和宽平稳过程.本章着重研究后者并介绍宽平稳过程相关函数的性质、谱密度及其性质以及各态历经等方面的内容.

12.1 平稳过程的概念

粗略地说,“平稳过程”是指它的统计特性不随时间推移而改变的随机过程.在随机过程理论中有两种不同含义的平稳过程,现分别介绍如下.

设 $X_T=\{X(t),t\in T\}$ 是随机过程,若对任意 $n\geqslant 1$,任意 n 个时刻 $t_1,t_2,\cdots,t_n\in T$,和任意的 $\tau(t_1+\tau,t_2+\tau,\cdots,t_n+\tau\in T)$,都有

$$(X(t_1),X(t_2),\cdots,X(t_n))\overset{d}{=}(X(t_1+\tau),X(t_2+\tau),\cdots,X(t_n+\tau))$$

则称 X_T 为严平稳过程.这里符号“$\overset{d}{=}$”表示等号两端的 n 维随机向量具有相同的概率分布,亦即,它们的分布函数是相等的①.

由此可见,严平稳过程的任何有限维分布对时间的推移是保持不变的.

在应用中,要想依据上述等式的成立与否来判定一个随机过程的平稳性,一般是很难办到的.通常的做法是:对于一个被研究的随机过程,如果前后环境和主要因素都不随时间变化的话,那么就认为它是严平稳的.

如果严平稳过程是二阶矩过程,那么,一方面,过程的均值函数和相关函数都存在,另一方面,因为 $X(t)\overset{d}{=}X(t+\tau)$,$(X(0),X(\tau))\overset{d}{=}(X(t),X(t+\tau))$,所以 $E[X(t)]=E[X(t+\tau)]$,$E[X(t)X(t+\tau)]=E[X(0)X(\tau)]$,即

$E[X(t)]=$常数,$t\in T$;

$E[X(t)X(t+\tau)]$与 t 无关而只可能与 τ 有关.

换言之,此时,过程一、二阶矩不随时间推移而改变,这就引出了另一种含义的平稳过程.

定义 12.1 设 $X_T=\{X(t),t\in T\}$ 是二阶矩过程.若它满足条件

(1) 对任意 $t\in T$,$E[X(t)]$为常数;

(2) 对任意 $t\in T$,$t+\tau\in T$,$E[X(t)X(t+\tau)]$不依赖于 t,

则称 X_T 为**宽平稳过程**.此时用 $R_X(\tau)$来表示 X_T 的自相关函数,即 $R_X(\tau)\overset{\text{def}}{=}E[X(t)X(t+\tau)]$.

一般来讲,严平稳过程不一定是宽平稳过程,因为严平稳过程未必都存在二阶矩,反之,宽平稳过程也不一定是严平稳过程,因为宽平稳过程只保证过程的一、二阶矩不随时间推移而改变,而这些条件并不能保证过程的有限维分布也不随时间推移而改变.但在二阶矩过程类中,严平稳过程必定是宽平稳过程,反之,仍未必成立.

命题 12.1 若 $X_T=\{X(t),t\in T\}$ 是正态过程,则 X_T 是严平稳过程的充要条件为 X_T 是宽平稳过程.

---

① 注意:两个随机变量具有相同的概率分布或它们分布函数相等,并不表示这两个随机变量处处相等.

因正态过程是二阶矩过程，故必要条件显然成立，至于充分条件，只需注意以下事实：正态过程的有限维分布是完全由它的均值函数和相关函数所决定的. 现在，既然正态过程的均值函数和相关函数不随时间推移而改变，那么它的有限维分布也不随时间推移而改变. 我们把详尽的推证过程留给读者去完成.

下面讨论的平稳过程若无特别申明均指宽平稳过程.

举几个平稳过程的例子.

例 12.1 设$\{X(n),n=0,\pm1,\pm2,\cdots\}$是互不相关的随机变量序列，且$E[X(n)]=0$，$D[X(n)]=\sigma^2(n=0,\pm1,\pm2,\cdots)$，证明它是平稳的.

证 因为$E[X(n)]=0(n=0,\pm1,\pm2,\cdots)$，又

$$E[X(m)X(m+n)]=\begin{cases}\sigma^2, & \text{当 } n=0,\\ 0, & \text{当 } n\neq 0\end{cases}$$

不依赖于m，所以它是平稳随机序列.

在工程技术上，这种平稳随机序列也称为**纯随机序列或白噪声序列**. 若再加上条件$X(n)\sim N(0,\sigma^2)(n=0,\pm1,\pm2,\cdots)$，则称$\{X(n),n=0,\pm1,\pm2,\cdots\}$为**正态白噪声**.

例 12.2 设$\{X(n),n=0,\pm1,\pm2,\cdots\}$是白噪声序列. 令

$$Y(n)=\sum_{k=0}^{N}a_kX(n-k)\quad(n=0,\pm1,\pm2,\cdots)$$

其中N为自然数，$a_0,a_1,\cdots,a_N$为常数. 证明$\{Y(n),n=0,\pm1,\pm2,\cdots\}$是平稳序列.

证 因为$E[Y(n)]=\sum_{k=0}^{N}a_kE[X(n-k)]=0\quad(n=0,\pm1,\pm2,\cdots)$，

$$\begin{aligned}E[Y(m)Y(m+n)]&=E\Big[\sum_{k=0}^{N}a_kX(m-k)\sum_{j=0}^{N}a_jX(m+n-j)\Big]\\&=E\Big[\sum_{k=0}^{N}\sum_{j=0}^{N}a_ka_jX(m-k)X(m+n-j)\Big]\\&=\sum_{k=0}^{N}\sum_{j=0}^{N}a_ka_jE[X(m-k)X(m+n-j)]\\&=\begin{cases}0, & |n|>N,\\ \sum\limits_{k=0}^{N-|n|}a_ka_{n+k}\sigma^2, & |n|\leqslant N\end{cases}\end{aligned}$$

不依赖于m，所以$\{Y(n),n=0,\pm1,\pm2,\cdots\}$是平稳序列.

通常称$Y(n)$是白噪声序列的**滑动和**.

例 12.3 设随机过程$\{Y(t)=(-1)^{\mu_t}X,t\in[0,\infty)\}$，其中

(1) X为随机变量，且$X\sim\begin{pmatrix}-1 & 1\\ 1/2 & 1/2\end{pmatrix}$；

(2) $\{\mu_t,t\geqslant 0\}$是强度为λ的泊松过程；

(3) X与$\{\mu_t,t\geqslant 0\}$相互独立，

证明$\{Y(t),t\in[0,\infty)\}$是平稳过程.

证 首先，

$$E[Y(t)]=E[(-1)^{\mu_t}X]$$

$$=E[(-1)^{\mu_t}]\cdot E(X) \quad (\text{因为 } X \text{ 与} \{\mu_t, t\geqslant 0\} \text{独立})$$
$$=0 \quad (\text{由 } E(X)=0 \text{ 知})$$

其次,

$$E[Y(t)Y(t+\tau)]=E[(-1)^{\mu_t+\mu_{t+\tau}}X^2]$$
$$=E[(-1)^{\mu_t+\mu_{t+\tau}}]E(X^2) \quad (\text{由条件(3)知})$$

这里,$E(X^2)=(-1)^2\times\frac{1}{2}+1^2\times\frac{1}{2}=1$. 当 $\tau>0$ 时,$\mu_{t+\tau}-\mu_t\sim P(\lambda\tau)$,故

$$E[(-1)^{\mu_t+\mu_{t+\tau}}]=E[(-1)^{2\mu_t+\mu_{t+\tau}-\mu_t}]$$
$$=E[(-1)^{\mu_{t+\tau}-\mu_t}]$$
$$=\sum_{k=0}^{\infty}(-1)^k\frac{(\lambda\tau)^k}{k!}e^{-\lambda\tau}$$
$$=e^{-2\lambda\tau}$$

类似地,当 $\tau<0$ 时,有 $E[(-1)^{\mu_t+\mu_{t+\tau}}]=e^{2\lambda\tau}$,因此

$$E[Y(t)Y(t+\tau)]=E[(-1)^{\mu_t+\mu_{t+\tau}}]E(X^2)=e^{-2\lambda|\tau|}$$

不依赖于 t,故 $\{Y(t), t\in[0,\infty)\}$ 是平稳过程.

本例中的过程 $\{Y(t)=(-1)^{\mu_t}X, t\in[0,\infty)\}$ 称为**随机电报信号过程**.

12.2 相关函数的性质

本节讨论平稳过程相关函数的各种性质.

12.2.1 自相关函数的性质

设 $X_T=\{X(t), t\in T\}$ 是平稳过程,$R_X(\tau)\overset{\text{def}}{=\!=}E[X(t)X(t+\tau)]$ 为 X_T 的自相关函数,则 $R_X(\tau)$ 具有以下性质:

(1) $R_X(0)\geqslant 0$;

(2) $|R_X(\tau)|\leqslant R_X(0)$;

(3) $R_X(-\tau)=R_X(\tau)$;

(4) $R_X(\tau)$ 是非负定的,即对任意正整数 n,任意 n 个实数 $t_1, t_2, \cdots, t_n$ 和复数 $z_1, z_2, \cdots, z_n$,都有

$$\sum_{k=1}^{n}\sum_{l=1}^{n}R_X(t_k-t_l)z_k\overline{z}_l\geqslant 0 \tag{12.2.1}$$

证 (1) $R_X(0)=E[X^2(t)]=\int_{-\infty}^{+\infty}x^2\mathrm{d}F_t(x)\geqslant 0$ (由 R-S 积分性质知)

(2) 由柯西-施瓦茨不等式 $|E(XY)|\leqslant\sqrt{E(X^2)}\sqrt{E(Y^2)}$,可得

$$|R_X(\tau)|=|E[X(t)X(t+\tau)]|$$
$$\leqslant\sqrt{E[X^2(t)]}\sqrt{E[X^2(t+\tau)]}$$
$$=\sqrt{R_X(0)}\sqrt{R_X(0)}=R_X(0)$$

(3) 因为 $E[X(t)X(t+\tau)]$ 不依赖于 t,仅是两时刻之差 $(t+\tau)-t=\tau$ 的函数,而

$-\tau=t-(t+\tau)$，所以 $R_X(-\tau)=E[X(t+\tau)X(t)]=E[X(t)X(t+\tau)]=R_X(\tau)$.

(4) 根据平稳过程自相关函数的定义以及数学期望运算的性质，有

$$\begin{aligned}\sum_{k=1}^{n}\sum_{l=1}^{n}R_X(t_k-t_l)z_k\bar{z}_l &= \sum_{k=1}^{n}\sum_{l=1}^{n}E[X(t_l)X(t_k)]z_k\bar{z}_l\\ &=E\Big[\sum_{k=1}^{n}X(t_k)z_k\sum_{l=1}^{n}X(t_l)\,\bar{z}_l\Big]\\ &=E\Big[\Big|\sum_{k=1}^{n}X(t_k)z_k\Big|^2\Big]\geqslant 0\end{aligned}$$

平稳过程的自协方差函数 $C_X(\tau)=\mathrm{Cov}(X(t),X(t+\tau))$ 同样具有上述四条性质（只需把(1)—(4)中的字母 R 替换成字母 C 即可）.

我们还要指出，上述四条性质中，非负定性是平稳过程自相关函数的本质特性，理论上可以证明，任一（在 $t=0$ 处连续且 $f(0)\neq 0$ 的）函数 $f(t)$，若是非负定的，则它必是某平稳过程的自相关函数.

12.2.2 互相关函数的性质

设 $X_T=\{X(t),t\in T\}$，$Y_T=\{Y(t),t\in T\}$ 是两个平稳过程，若 $E[X(t)Y(t+\tau)]$ 不依赖 t，则称 X_T 与 Y_T 是**平稳相关**的，此时，它们的互相关函数记为 $R_{XY}(\tau)$，即 $R_{XY}(\tau)=E[X(t)Y(t+\tau)]$.因为

$$\begin{aligned}\mathrm{Cov}(X(t),Y(t+\tau)) &= E[X(t)Y(t+\tau)]-m_X(t)m_Y(t+\tau)\\ &=R_{XY}(\tau)-m_Xm_Y\end{aligned}$$

其中 m_X,m_Y 分别是 X_T,Y_T 的均值（二者都是常数）.亦即，X_T 与 Y_T 的互协方差函数也不依赖于 t，因而把它记为 $C_{XY}(\tau)$，即 $C_{XY}(\tau)=\mathrm{Cov}(X(t),Y(t+\tau))$.

平稳相关随机过程的互相关函数具有如下性质：

(1) $R_{XY}(-\tau)=R_{YX}(\tau)$；

(2) $|R_{XY}(\tau)|\leqslant\sqrt{R_X(0)}\sqrt{R_Y(0)}$.

因这两条性质的证明与自相关函数完全相同，故留给读者作为练习.另外，互协方差函数 $C_{XY}(\tau)$ 也有相应的两条性质.

12.3 平稳过程的谱密度

本节讨论如何运用傅里叶变换这一有效的数学工具来确定平稳过程的频率结构——**谱密度**（又称为**功率谱密度**）.

12.3.1 相关函数的谱分解

定理 12.1 (1) 若均方连续[①]的平稳过程 $X_T=\{X(t),-\infty<t<+\infty\}$ 的相关函数为 $R_X(\tau)$，则 $R_X(\tau)$ 可以表示为

① 关于二阶矩过程的均方微积分，请参阅本章的附录.

$$R_X(\tau)=\frac{1}{2\pi}\int_{-\infty}^{+\infty}\mathrm{e}^{\mathrm{i}\tau\omega}\mathrm{d}\widetilde{F}(\omega),-\infty<\tau<+\infty \tag{12.3.1}$$

其中 $\widetilde{F}(\omega)$ 是定义在 $(-\infty,+\infty)$ 上的单调增、右连续的有界函数.

(2) 若平稳随机序列 $X_T\{X(n),n=0,\pm1,\pm2,\cdots\}$ 的相关函数为 $R_X(m)$,则 $R_X(m)$ 可表示为

$$R_X(m)=\frac{1}{2\pi}\int_{-\pi}^{\pi}\mathrm{e}^{\mathrm{i}m\omega}\mathrm{d}\widetilde{F}_1(\omega),m=0,\pm1,\cdots \tag{12.3.2}$$

其中 $\widetilde{F}_1(\omega)$ 是定义在 $[-\pi,\pi]$ 上的单调增、右连续的有界函数.

证 (1)若 $R_X(0)=0$,由 $|R_X(\tau)|\leqslant R_X(0),\tau\in(-\infty,+\infty)$,得 $R_X(\tau)\equiv0$,$-\infty<\tau<+\infty$,此时,取 $\widetilde{F}(\omega)\equiv c$($c$ 为常数),则(12.3.1)式成立.若 $R_X(0)\neq0$,令 $\widetilde{R}(\tau)=R_X(\tau)/R_X(0)$,则易知 $\widetilde{R}(\tau)$ 具有下述性质:①是连续函数;②$\widetilde{R}(0)=1$;③是非负定的.由博赫纳-辛钦定理(参见本章的附录)知,$\widetilde{R}(\tau)$ 可表示为

$$\widetilde{R}(\tau)=\int_{-\infty}^{+\infty}\mathrm{e}^{\mathrm{i}\tau\omega}\mathrm{d}F(\omega) \tag{12.3.3}$$

其中 $F(\omega)$ 是某个随机变量的分布函数.于是

$$\begin{aligned}R_X(\tau)&=\frac{1}{2\pi}\int_{-\infty}^{+\infty}\mathrm{e}^{\mathrm{i}\tau\omega}\mathrm{d}[2\pi R_X(0)F(\omega)]\\&=\frac{1}{2\pi}\int_{-\infty}^{+\infty}\mathrm{e}^{\mathrm{i}\tau\omega}\mathrm{d}\widetilde{F}(\omega)\end{aligned}$$

其中 $\widetilde{F}(\omega)=2\pi R_X(0)F(\omega)$ 是定义在 $(-\infty,+\infty)$ 上的单调增、右连续的有界函数,并且,$\widetilde{F}(+\infty)=2\pi R_X(0)$,$\widetilde{F}(-\infty)=0$,这就证明了(1).

(2) 的结论由赫格洛茨定理(参见本章的附录)直接得到.

(12.3.1)和(12.3.2)式分别称为 $R_X(\tau)$ 和 $R_X(m)$ 的**谱分解式**,而 $\widetilde{F}(\omega)$ 和 $\widetilde{F}_1(\omega)$ 称为平稳过程和平稳随机序列的**谱函数**.如果不计常数之差,那么谱函数是由相关函数唯一确定的.

若 $\widetilde{F}(\omega)$(相应地,$\widetilde{F}_1(\omega)$)是绝对连续的,即存在 $S_X(\omega)$ 使得

$$\widetilde{F}(\omega)=\int_{-\infty}^{\omega}S_X(\lambda)\mathrm{d}\lambda+C$$

(相应地,$\widetilde{F}_1(\omega)=\int_{-\pi}^{\omega}S_X(\lambda)\mathrm{d}\lambda+C$),则称 $S_X(\omega)$ 为平稳过程(相应地,平稳随机序列)X_T 的**谱密度**.

数学上已经证明:若相关函数 $R_X(\tau)$ 满足条件 $\int_{-\infty}^{+\infty}|R_X(\tau)|\mathrm{d}\tau<+\infty$,则必存在谱密度 $S_X(\omega)$,使得

$$R_X(\tau)=\frac{1}{2\pi}\int_{-\infty}^{+\infty}\mathrm{e}^{\mathrm{i}\tau\omega}S_X(\omega)\mathrm{d}\omega,-\infty<\tau<+\infty \tag{12.3.4}$$

其中

$$S_X(\omega)=\int_{-\infty}^{+\infty} e^{-i\tau\omega}R_X(\tau)\,d\tau,\ -\infty<\omega<+\infty \tag{12.3.5}$$

以上两式表明,相关函数 $R_X(\tau)$ 与谱密度 $S_X(\omega)$ 构成了傅里叶变换对,即 $S_X(\omega)=\mathscr{F}[R_X(\tau)]$,$R_X(\tau)=\mathscr{F}^{-1}[S_X(\omega)]$.

对于平稳序列 $X_T=\{X(n),n=0,\pm1,\pm2,\cdots\}$ 的相关函数 $R_X(m)$,若它满足条件:$\sum_{m=-\infty}^{\infty}|R_X(m)|<+\infty$,则必存在谱密度 $S_X(\omega)$,$\omega\in[-\pi,\pi]$,使得

$$R_X(m)=\frac{1}{2\pi}\int_{-\pi}^{\pi} e^{im\omega}S_X(\omega)\,d\omega,\ m=0,\pm1,\pm2,\cdots \tag{12.3.6}$$

其中

$$S_X(\omega)=\sum_{m=-\infty}^{\infty} e^{-im\omega}R_X(m),\ -\pi\leqslant\omega\leqslant\pi \tag{12.3.7}$$

12.3.2 谱密度的物理意义

本段首先介绍确定信号的功率谱密度概念,并由此引申出平稳随机信号的功率谱密度;然后讨论平稳随机信号的功率谱密度与谱密度之间的关系.

1. 确定信号 $x(t)$ 的功率谱密度

当确定信号 $x(t)$($-\infty<t<+\infty$)满足傅里叶积分定理中的条件时,可以对它作频谱分析,即可求得 $x(t)$ 的频谱函数

$$F_X(\omega)=\int_{-\infty}^{+\infty} x(t)e^{-i\omega t}dt$$

并且

$$x(t)=\frac{1}{2\pi}\int_{-\infty}^{+\infty} F_X(\omega)e^{i\omega t}d\omega$$

上式表明,信号 $x(t)$ 可表示为谱波分量 $\frac{1}{2\pi}F_X(\omega)e^{i\omega t}d\omega$ 的无限叠加,其中 ω 为圆频率,谱波分量的振幅为 $\frac{1}{2\pi}|F_X(\omega)|d\omega$.若以 f 表示频率,则由 $\omega=2\pi f$ 可知,谱波分量又可表示为 $F_X(2\pi f)e^{i2\pi ft}df$,相应的振幅为 $|F_X(2\pi f)|df$.由频谱分析理论知,谱波分量在频带 $[f,f+df]$ 中的能量为 $|F_X(2\pi f)|^2df$.

若 $\int_{-\infty}^{+\infty}x^2(t)\,dt<+\infty$,则帕塞瓦尔等式(即能量积分公式)

$$\int_{-\infty}^{+\infty}x^2(t)\,dt=\frac{1}{2\pi}\int_{-\infty}^{+\infty}|F_X(\omega)|^2d\omega$$

成立.

帕塞瓦尔等式表明:若信号的总能量[①]有穷,则它必等于各谐波分量能量的叠加.

---

① 事实上,若把 $x(t)$ 视为加在 1 Ω 电阻上的端电压(或通过该电阻的电流强度),则 $x^2(t)$ 表示 t 时刻的瞬时功率,于是,$\int_{-\infty}^{+\infty}x^2(t)\,dt$ 表示总电功,亦即信号的总能量.

故帕塞瓦尔等式又称为信号总能量的**谱表示式**.式中的 $|F_X(\omega)|^2$ 称为 $x(t)$ 的**能量谱密度**.

但在实际应用中,例如周期信号,其总能量 $\int_{-\infty}^{+\infty} x^2(t)\,\mathrm{d}t=+\infty$,此时,我们转而考虑信号 $x(t)$ 在 $(-\infty,+\infty)$ 上的平均功率

$$\lim_{T\to+\infty}\frac{1}{2T}\int_{-T}^{T}x^2(t)\,\mathrm{d}t$$

因为它往往是有穷的.我们采用截尾法,令

$$x_T(t)=\begin{cases}x(t), & |t|\leqslant T,\\ 0, & |t|>T\end{cases}$$

显然,$x_T(t)$ 也满足傅里叶积分定理的条件,故

$$F_X(\omega;T)=\int_{-\infty}^{+\infty}x_T(t)\mathrm{e}^{-\mathrm{i}\omega t}\mathrm{d}t=\int_{-T}^{T}x(t)\mathrm{e}^{-\mathrm{i}\omega t}\mathrm{d}t$$

另外,因为 $\int_{-\infty}^{+\infty}x_T^2(t)\,\mathrm{d}t=\int_{-T}^{T}x^2(t)\,\mathrm{d}t<+\infty$,所以对 $x_T(t)$ 及其频谱 $F_X(\omega;T)$ 成立帕塞瓦尔等式

$$\int_{-\infty}^{+\infty}x_T^2(t)\,\mathrm{d}t=\frac{1}{2\pi}\int_{-\infty}^{+\infty}|F_X(\omega;T)|^2\mathrm{d}\omega$$

由此可得

$$\begin{aligned}\lim_{T\to+\infty}\frac{1}{2T}\int_{-T}^{T}x^2(t)\,\mathrm{d}t&=\lim_{T\to+\infty}\frac{1}{2\pi}\int_{-\infty}^{+\infty}\frac{1}{2T}|F_X(\omega;T)|^2\mathrm{d}\omega\\&=\frac{1}{2\pi}\int_{-\infty}^{+\infty}\lim_{T\to+\infty}\frac{1}{2T}|F_X(\omega;T)|^2\mathrm{d}\omega\end{aligned}$$

相应于能量谱密度,我们把上述等式右端的被积函数

$$\lim_{T\to+\infty}\frac{1}{2T}|F_X(\omega;T)|^2$$

称为信号 $x(t)$ 的**功率谱密度**.

拓展阅读:功率谱密度图

2. 平稳随机信号 $X(t)$ 的功率谱密度

现在,我们把上面讨论的方法及其结果转到平稳过程 $\{X(t),-\infty<t<+\infty\}$ 的场合中来,如

$$\frac{1}{2T}\int_{-T}^{T}X^2(t)\,\mathrm{d}t=\frac{1}{2\pi}\int_{-\infty}^{+\infty}\frac{1}{2T}|F_X(\omega;T)|^2\mathrm{d}\omega$$

在等式两端取数学期望[①],并令 $T\to+\infty$,得

$$\lim_{T\to+\infty}E\left[\frac{1}{2T}\int_{-T}^{T}X^2(t)\,\mathrm{d}t\right]=\frac{1}{2\pi}\int_{-\infty}^{+\infty}\lim_{T\to+\infty}\frac{1}{2T}E[|F_X(\omega;T)|^2]\mathrm{d}\omega \tag{12.3.8}$$

此式左端表示平稳随机信号 $X(t)$ 的平均功率,若记

$$S(\omega)=\lim_{T\to+\infty}\frac{1}{2T}E[|F_X(\omega;T)|^2] \tag{12.3.9}$$

① 等式两端的积分都是均方积分,对均方积分取期望要用到均方积分的有关性质,请参阅本章的附录.

则称 $S(\omega)$ 为 $X(t)$ 的**功率谱密度**.

根据均方积分的性质并注意到 $E[X^2(t)]=R_X(0)$,则(12.3.8)式的左端为

$$\lim_{T\to+\infty}\frac{1}{2T}\int_{-T}^{T}E[X^2(t)]\,\mathrm{d}t=R_X(0)$$

再由(12.3.9)式,得

$$R_X(0)=\frac{1}{2\pi}\int_{-\infty}^{+\infty}S(\omega)\,\mathrm{d}\omega \tag{12.3.10}$$

由此可见,$R_X(0)$ 表示平稳随机信号的平均功率.

3. 功率谱密度 $S(\omega)$ 与谱密度 $S_X(\omega)$ 的关系

设相关函数 $R_X(\tau)$ 绝对可积,即 $\int_{-\infty}^{+\infty}|R_X(\tau)|\,\mathrm{d}\tau<+\infty$,由上一段的讨论可知,存在谱密度 $S_X(\omega)$,并且,

$$S_X(\omega)=\int_{-\infty}^{+\infty}R_X(\tau)\mathrm{e}^{-\mathrm{i}\omega\tau}\mathrm{d}\tau,\ -\infty<\omega<+\infty$$

另一方面,把 $F_X(\omega;T)=\int_{-T}^{T}X(t)\mathrm{e}^{-\mathrm{i}\omega t}\mathrm{d}t$ 代入(12.3.9)式,得

$$\begin{aligned}S(\omega)&=\lim_{T\to+\infty}\frac{1}{2T}E\left[\int_{-T}^{T}X(t_2)\mathrm{e}^{-\mathrm{i}\omega t_2}\mathrm{d}t_2\int_{-T}^{T}X(t_1)\mathrm{e}^{\mathrm{i}\omega t_1}\mathrm{d}t_1\right]\\&=\lim_{T\to+\infty}\frac{1}{2T}\int_{-T}^{T}\int_{-T}^{T}R_X(t_2-t_1)\mathrm{e}^{-\mathrm{i}\omega(t_2-t_1)}\mathrm{d}t_1\mathrm{d}t_2\end{aligned}$$

对二重积分 $\int_{-T}^{T}\int_{-T}^{T}R_X(t_2-t_1)\mathrm{e}^{-\mathrm{i}\omega(t_2-t_1)}\mathrm{d}t_1\mathrm{d}t_2$ 作变量替换 $\tau_1=t_1+t_2$,$\tau_2=t_2-t_1$,变量替换的雅可比行列式 J 为

$$J=\frac{\partial(t_1,t_2)}{\partial(\tau_1,\tau_2)}=\begin{vmatrix}\dfrac{\partial t_1}{\partial\tau_1}&\dfrac{\partial t_1}{\partial\tau_2}\\[2ex]\dfrac{\partial t_2}{\partial\tau_1}&\dfrac{\partial t_2}{\partial\tau_2}\end{vmatrix}=\frac{1}{2}$$

积分区域的变化见图 12.1.

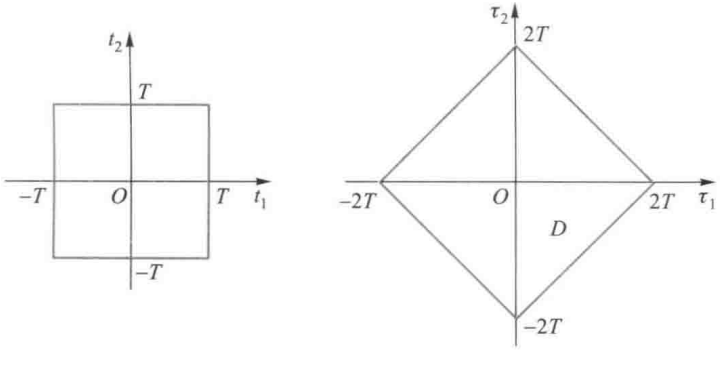

图 12.1

于是，

$$\int_{-T}^{T}\int_{-T}^{T} R_X(t_2-t_1)\mathrm{e}^{-\mathrm{i}\omega(t_2-t_1)}\mathrm{d}t_1\mathrm{d}t_2 = \iint_D R_X(\tau_2)\mathrm{e}^{-\mathrm{i}\omega\tau_2}\mid J\mid \mathrm{d}\tau_1\mathrm{d}\tau_2$$

$$= 2\left\{\int_{-2T}^{0}\left[\int_{0}^{2T+\tau_2} R_X(\tau_2)\mathrm{e}^{-\mathrm{i}\omega\tau_2}\frac{1}{2}\mathrm{d}\tau_1\right]\mathrm{d}\tau_2 + \int_{0}^{2T}\left[\int_{0}^{2T-\tau_2} R_X(\tau_2)\mathrm{e}^{-\mathrm{i}\omega\tau_2}\frac{1}{2}\mathrm{d}\tau_1\right]\mathrm{d}\tau_2\right\}$$

$$= \int_{-2T}^{2T}(2T-\mid\tau_2\mid)R_X(\tau_2)\mathrm{e}^{-\mathrm{i}\omega\tau_2}\mathrm{d}\tau_2$$

因而

$$S(\omega)=\lim_{T\to+\infty}\int_{-2T}^{2T}\left(1-\frac{|\tau|}{2T}\right)R_X(\tau)\mathrm{e}^{-\mathrm{i}\omega\tau}\mathrm{d}\tau$$

令

$$R_X^T(\tau)=\begin{cases}\left(1-\dfrac{|\tau|}{2T}\right)R_X(\tau), & |\tau|\leqslant 2T,\\ 0, & |\tau|>2T\end{cases}$$

显然，$\lim\limits_{T\to+\infty}R_X^T(\tau)=R_X(\tau)$，并因 $\int_{-\infty}^{+\infty}|R_X(\tau)|\mathrm{d}\tau<+\infty$，则

$$\begin{aligned}S(\omega) &= \lim_{T\to+\infty}\int_{-\infty}^{+\infty}R_X^T(\tau)\mathrm{e}^{-\mathrm{i}\omega\tau}\mathrm{d}\tau\\ &= \int_{-\infty}^{+\infty}\lim_{T\to+\infty}R_X^T(\tau)\mathrm{e}^{-\mathrm{i}\omega\tau}\mathrm{d}\tau\\ &= \int_{-\infty}^{+\infty}R_X(\tau)\mathrm{e}^{-\mathrm{i}\omega\tau}\mathrm{d}\tau\\ &= S_X(\omega)\end{aligned}$$

可见，从物理学角度引入的功率谱密度与从数学上引入的谱密度是相同的，故以后统一用 $S_X(\omega)$ 表示平稳过程 X_T 的（功率）谱密度.

12.3.3 谱密度与互谱密度的性质

设平稳过程 $X_T=\{X(t),-\infty<t<+\infty\}$ 的相关函数为 $R_X(\tau)$. 通过前面的介绍，我们知道，当 $\int_{-\infty}^{+\infty}|R_X(\tau)|\mathrm{d}\tau<+\infty$ 时，X_T 的谱密度（有时为了便于区别，也称之为**自谱密度**）$S_X(\omega)$ 定义为

$$S_X(\omega)=\int_{-\infty}^{+\infty}R_X(\tau)\mathrm{e}^{-\mathrm{i}\omega\tau}\mathrm{d}\tau,\ -\infty<\omega<+\infty$$

自谱密度 $S_X(\omega)$ 是实的、非负的偶函数. 这是因为

$$\begin{aligned}S_X(\omega) &= \int_{-\infty}^{+\infty}R_X(\tau)\cos(\omega\tau)\mathrm{d}\tau-\mathrm{i}\int_{-\infty}^{+\infty}R_X(\tau)\sin(\omega\tau)\mathrm{d}\tau\\ &= 2\int_{0}^{+\infty}R_X(\tau)\cos(\omega\tau)\mathrm{d}\tau \quad (\text{因为 } R_X(\tau)\text{ 为偶函数})\end{aligned}$$

可见，$S_X(\omega)$ 是 ω 的实的偶函数. 又因 $\widetilde{F}'(\omega)=S_X(\omega)$，而 $\widetilde{F}(\omega)$ 是单调增的，故 $S_X(\omega)$ 非负. 需要指出，利用功率谱密度的定义（12.3.9）式也能方便地推证上述性质.

设平稳过程 $X_T=\{X(t),-\infty<t<+\infty\}$ 与 $Y_T=\{Y(t),-\infty<t<+\infty\}$ 是平稳相关的，其互相关函数为 $R_{XY}(\tau)$，类似于自谱密度的数学定义，当互相关函数满足

条件：$\int_{-\infty}^{+\infty} |R_{XY}(\tau)| \mathrm{d}\tau < +\infty$ 时，$R_{XY}(\tau)$ 的傅里叶变换

$$S_{XY}(\omega) = \int_{-\infty}^{+\infty} R_{XY}(\tau) \mathrm{e}^{-\mathrm{i}\omega\tau} \mathrm{d}\tau, -\infty < \omega < +\infty \tag{12.3.11}$$

存在，称之为平稳过程 X_T 与 Y_T 的**互谱密度**.

此外，仿照功率谱密度的定义方法，也可以把互谱密度 $S_{XY}(\omega)$ 定义为①

$$S_{XY}(\omega) = \lim_{T\to+\infty} \frac{1}{2T} E[F_X(-\omega;T) F_Y(\omega;T)] \tag{12.3.12}$$

互谱密度通常是 ω 的复函数，它不像自谱密度那样有鲜明的物理意义.引入互谱密度的目的在于从频率角度来刻画两个平稳过程的平稳相关性.

互谱密度具有下列性质：

(1) $S_{XY}(-\omega) = S_{XY}^*(\omega)$，$S_{XY}^*(\omega) = S_{YX}(\omega)$（共轭对称性）；

(2) $\mathrm{Re}[S_{XY}(\omega)]$ 与 $\mathrm{Re}[S_{YX}(\omega)]$ 是实的偶函数，$\mathrm{Im}[S_{XY}(\omega)]$ 与 $\mathrm{Im}[S_{YX}(\omega)]$ 是实的奇函数；

(3) $|S_{XY}(\omega)| \leqslant \sqrt{S_X(\omega)}\sqrt{S_Y(\omega)}$.

证 (1) 因为

$$\begin{aligned} S_{XY}(-\omega) &= \lim_{T\to+\infty} \frac{1}{2T} E[F_X(\omega;T) F_Y(-\omega;T)] \\ &= \lim_{T\to+\infty} \frac{1}{2T} E[F_Y(-\omega;T) F_X(\omega;T)] \\ &= S_{YX}(\omega) \end{aligned}$$

利用共轭运算的性质，知

$$\begin{aligned} S_{XY}^*(\omega) &= \overline{\lim_{T\to+\infty} \frac{1}{2T} E[F_X(-\omega;T) F_Y(\omega;T)]} \\ &= \lim_{T\to+\infty} \frac{1}{2T} E\,\overline{[F_X(-\omega;T) F_Y(\omega;T)]} \\ &= \lim_{T\to+\infty} \frac{1}{2T} E[F_X(\omega;T) F_Y(-\omega;T)] \\ &= S_{XY}(-\omega) \end{aligned}$$

故性质(1)得证.

(2) 由(12.3.11)式

$$S_{XY}(\omega) = \int_{-\infty}^{+\infty} R_{XY}(\tau)\cos(\omega\tau)\mathrm{d}\tau - \mathrm{i}\int_{-\infty}^{+\infty} R_{XY}(\tau)\sin(\omega\tau)\mathrm{d}\tau$$

得

$$\mathrm{Re}[S_{XY}(\omega)] = \int_{-\infty}^{+\infty} R_{XY}(\tau)\cos(\omega\tau)\mathrm{d}\tau$$

$$\mathrm{Im}[S_{XY}(\omega)] = -\int_{-\infty}^{+\infty} R_{XY}(\tau)\sin(\omega\tau)\mathrm{d}\tau$$

① 把 $F_X(-\omega;T)$ 及 $F_Y(\omega;T)$ 的表达式代入(12.3.12)式右端，再利用 12.3.2 小节第 3 小部分中的推导方法，便知两种定义式是并行不悖的.

因而 $\mathrm{Re}[S_{XY}(\omega)]$是实的偶函数,$\mathrm{Im}[S_{XY}(\omega)]$是实的奇函数.再由(1)知 $\mathrm{Re}[S_{YX}(\omega)]=\mathrm{Re}[S_{XY}(\omega)]$,$\mathrm{Im}[S_{YX}(\omega)]=-\mathrm{Im}[S_{XY}(\omega)]$,故性质(2)得证.

(3) 利用柯西-施瓦茨不等式 $|E(XY)|\leqslant\sqrt{E[|X|^2]}\sqrt{E[|Y|^2]}$ 可得

$$\begin{aligned}|S_{YX}(\omega)| &= \lim_{T\to+\infty}\frac{1}{2T}|E[F_X(-\omega;T)F_Y(\omega;T)]| \\ &\leqslant \lim_{T\to+\infty}\frac{1}{2T}\sqrt{E[|F_X(-\omega;T)|^2]}\sqrt{E[|F_Y(\omega;T)|^2]} \\ &= \sqrt{\lim_{T\to+\infty}\frac{1}{2T}E[|F_X(\omega;T)|^2]}\sqrt{\lim_{T\to+\infty}\frac{1}{2T}E[|F_Y(\omega;T)|^2]} \\ &= \sqrt{S_X(\omega)}\sqrt{S_Y(\omega)}\end{aligned}$$

故性质(3)得证.

12.3.4 相关函数与谱密度之间的变换

通过前面的讨论,我们知道,当相关函数 $R_X(\tau)$(相应地,$R_{XY}(\tau)$)绝对可积时,$R_X(\tau)$与谱密度 $S_X(\omega)$构成傅里叶变换对:

$$S_X(\omega)=\int_{-\infty}^{+\infty}R_X(\tau)\mathrm{e}^{-\mathrm{i}\omega\tau}\mathrm{d}\tau\overset{\mathrm{def}}{=\!=}\mathscr{F}[R_X(\tau)]$$

$$R_X(\tau)=\frac{1}{2\pi}\int_{-\infty}^{+\infty}S_X(\omega)\mathrm{e}^{\mathrm{i}\omega\tau}\mathrm{d}\omega\overset{\mathrm{def}}{=\!=}\mathscr{F}^{-1}[S_X(\omega)]$$

(相应地,互相关函数 $R_{XY}(\tau)$与互谱密度 $S_{XY}(\omega)$也构成傅里叶变换对:$S_{XY}(\omega)=\mathscr{F}[R_{XY}(\tau)]$,$R_{XY}(\tau)=\mathscr{F}^{-1}[S_{XY}(\omega)]$.)于是,它们相互之间的换算方法一般有两种.其一,利用傅里叶变换表,结合傅里叶变换的性质,通过查表来完成计算.其二,直接计算积分((12.3.4)式或(12.3.5)式),这会涉及复函数的积分,在一定的条件下,可利用留数定理来进行计算.

相关函数与谱密度都是描述平稳过程某一统计特征的量.若从相关函数角度来分析平稳过程,则称之为"时域分析法",若从谱密度方面来进行分析,则通常称为"频域分析法".

1. 查表计算法

表 12.1 给出了最常用的相关函数和谱密度的变换,因其中出现 $R_X(\tau)$或 $S_X(\omega)$是 δ 函数,故先简单介绍 δ 函数及其广义傅里叶变换.

表 12.1 常用的相关函数和谱密度的变换

	相关函数 $R_X(\tau)$	谱密度 $S_X(\omega)$
1	$\sigma^2\mathrm{e}^{-a\lvert\tau\rvert}\quad(a>0)$	$\dfrac{2a\sigma^2}{\omega^2+a^2}$
2	$R_X(\tau)=\begin{cases}1-\dfrac{\lvert\tau\rvert}{T}, & \lvert\tau\rvert\leqslant T,\\ 0, & \lvert\tau\rvert<T\end{cases}$	$\dfrac{4\sin^2\left(\dfrac{T\omega}{2}\right)}{T\omega^2}$
3	$\sigma^2\mathrm{e}^{-a\lvert\tau\rvert}\cos(\omega_0\tau)\quad(a>0)$	$a\sigma^2\left[\dfrac{1}{(\omega-\omega_0)^2+a^2}+\dfrac{1}{(\omega+\omega_0)^2+a^2}\right]$

续表

	相关函数 $R_X(\tau)$	谱密度 $S_X(\omega)$
4	$\dfrac{\sin(\omega_0\tau)}{\pi\tau}\quad(\omega_0>0)$	$S_X(\omega)=\begin{cases}1, & \lvert\omega\rvert\leqslant\omega_0,\\ 0, & \lvert\omega\rvert>\omega_0\end{cases}$
5	1	$2\pi\delta(\omega)$
6	$\delta(\tau)$	1
7	$\cos(\omega_0\tau)$	$\pi[\delta(\omega-\omega_0)+\delta(\omega+\omega_0)]$

若 $\delta(x-x_0)$ 满足条件

(1) $\delta(x-x_0)=\begin{cases}+\infty, & x=x_0,\\ 0, & x\neq x_0;\end{cases}$

(2) $\int_{-\infty}^{+\infty}\delta(x-x_0)\,\mathrm{d}x=1$,

则称 $\delta(x-x_0)$ 是在 $x=x_0$ 的 **δ 函数**.

上述定义最初是由著名的物理学家狄拉克引入的,因而这种函数也称之为狄拉克函数.δ 函数不是通常意义下的函数.因为按照古典积分理论,定义中的两个条件是彼此矛盾的,所以不存在一个普通的实函数能同时满足这些条件.事实上,δ 函数是一种广义函数,在广义函数论中,它被定义为某基本函数空间上的连续线性泛函.因其中涉及的数学理论已远远超出本课程教学大纲的范围,故不予展开,仅介绍有关 δ 函数的一条重要性质(筛选性).

若 $f(x)$ 为无限次可微函数,则有

$$\int_{-\infty}^{+\infty}\delta(x-x_0)f(x)\,\mathrm{d}x=f(x_0) \tag{12.3.13}$$

工程上,称 $\delta(x)$ 为**单位脉冲函数**,根据 δ 函数的筛选性,形式上有

$$\mathscr{F}[\delta(\tau)]=\int_{-\infty}^{+\infty}\delta(\tau)\mathrm{e}^{-\mathrm{i}\omega\tau}\mathrm{d}\tau=\mathrm{e}^{-\mathrm{i}\omega\tau}\big|_{\tau=0}=1$$

亦即,时域上的单位脉冲函数 $\delta(\tau)$ 与频域上的常值 1 构成了一对(广义)傅里叶变换.

同理,形式上有

$$\mathscr{F}^{-1}[\delta(\omega)]=\frac{1}{2\pi}\int_{-\infty}^{+\infty}\delta(\omega)\mathrm{e}^{\mathrm{i}\omega\tau}\mathrm{d}\omega=\frac{1}{2\pi}\mathrm{e}^{\mathrm{i}\omega\tau}\Big|_{\omega=0}=\frac{1}{2\pi}$$

亦即,时域上的常值 $\dfrac{1}{2\pi}$ 与频域上的单位脉冲函数 $\delta(\omega)$ 构成一对(广义)傅里叶变换.

例 12.4　已知平稳过程 $X_T=\{X(t),-\infty<t<+\infty\}$ 的谱密度为

$$S_X(\omega)=\frac{\omega^2}{\omega^4+3\omega^2+2}$$

求 X_T 的相关函数 $R_X(\tau)$.

解　因为 $S_X(\omega)$ 在 $\omega\in(-\infty,+\infty)$ 上绝对可积,且有

$$S_X(\omega)=\frac{2}{\omega^2+2}-\frac{1}{\omega^2+1}$$

根据傅里叶变换的线性性质以及表 12.1,所以

$$\begin{aligned}R_X(\tau)&=\mathscr{F}^{-1}[S_X(\omega)]\\&=\frac{1}{\sqrt{2}}\mathscr{F}^{-1}\left[\frac{2\sqrt{2}}{\omega^2+2}\right]-\frac{1}{2}\mathscr{F}^{-1}\left[\frac{2}{\omega^2+1}\right]\\&=\frac{1}{\sqrt{2}}e^{-\sqrt{2}|\tau|}-\frac{1}{2}e^{-|\tau|}\end{aligned}$$

例 12.5 求平稳随机电报信号过程(见例 12.3)的谱密度.

解 因为平稳随机电报信号过程的相关函数为 $R_X(\tau)=e^{-2\lambda|\tau|}$,其中 $\lambda>0$ 为常数,显然 $e^{-2\lambda|\tau|}$ 在 $\tau\in(-\infty,+\infty)$ 上是绝对可积的,故谱密度存在,且有

$$S_X(\omega)=\mathscr{F}[R_X(\tau)]=\mathscr{F}[e^{-2\lambda|\tau|}]=\frac{4\lambda}{\omega^2+4\lambda^2}$$

例 12.6 设有随机过程

$$X_T=\{A\cos(\omega_0 t)+B\sin(\omega_0 t),-\infty<t<+\infty\}$$

其中 ω_0 为常数,A 与 B 为相互独立的随机变量,且都服从正态分布 $N(0,\sigma^2)$.

(1) 证明 X_T 是一个平稳过程;

(2) 求 X_T 的谱密度.

解 (1) 记 $X(t)=A\cos(\omega_0 t)+B\sin(\omega_0 t),-\infty<t<+\infty$,因为

$$\begin{aligned}m_X(t)&=E[X(t)]\\&=E(A)\cos(\omega_0 t)+E(B)\sin(\omega_0 t)=0,\ \forall t\in(-\infty,+\infty)\end{aligned}$$

又

$$\begin{aligned}R_X(t,t+\tau)&=E[X(t)X(t+\tau)]\\&=E(A^2)\cos(\omega_0 t)\cos[\omega_0(t+\tau)]+\\&\quad E(B^2)\sin(\omega_0 t)\sin[\omega_0(t+\tau)]\quad(\text{因为 }E(AB)=0)\\&=\sigma^2\cos(\omega_0\tau)\quad(\text{不依赖于 }t)\end{aligned}$$

故 X_T 为平稳过程,且其相关函数为 $R_X(\tau)=\sigma^2\cos(\omega_0\tau)$.

(2) 现在 $R_X(\tau)=\sigma^2\cos(\omega_0\tau)$,由表 12.1 可知

$$\begin{aligned}S_X(\omega)&=\mathscr{F}[R_X(\tau)]=\sigma^2\mathscr{F}[\cos(\omega_0\tau)]\\&=\sigma^2\pi[\delta(\omega-\omega_0)+\delta(\omega+\omega_0)]\end{aligned}$$

需要指出,本题中的相关函数 $\sigma^2\cos(\omega_0\tau)$ 不满足绝对可积条件,因而不能保证可对它进行通常意义下的傅里叶变换,但在引入 δ 函数及其(广义)傅里叶变换之后,由于 $\cos(\omega_0\tau)$ 与 $\pi[\delta(\omega-\omega_0)+\delta(\omega+\omega_0)]$ 构成一对(广义)傅里叶变换,所以可求得 $R_X(\tau)=\sigma^2\cos(\omega_0\tau)$ 的(广义)傅里叶变换.这表明,δ 函数及其(广义)傅里叶变换的引进大大拓宽了可施行傅里叶变换的函数类,并对工程技术上许多重要函数的频谱分析带来了极大的便利.

例 12.7 设平稳过程 $X_T=\{X(t),-\infty<t<+\infty\}$ 的谱密度为

$$S_X(\omega)=\sigma^2,\quad -\infty<\omega<+\infty$$

求 X_T 的相关函数 $R_X(\tau)$.

解 $R_X(\tau)=\mathscr{F}^{-1}[S_X(\omega)]=\mathscr{F}^{-1}[\sigma^2]=\sigma^2\delta(\tau)$.

通常把均值为零而谱密度为常数的平稳过程称为**白噪声过程**(简称白噪声).这个名称来自白光可分解成各种频率的光谱,而且其功率谱是均匀分布的.

2. 直接计算积分法

有时需要直接计算(12.3.4)式或者(12.3.5)式来完成相关函数 $R_X(\tau)$ 与谱密度 $S_X(\omega)$ 之间的换算.

例 12.8 设平稳过程 X_T 的谱密度为

$$S_X(\omega)=\begin{cases}\sigma^2, & |\omega|\leqslant\omega_0,\\ 0, & |\omega|>\omega_0\end{cases}$$

求 X_T 的相关函数 $R_X(\tau)$.

解 因为 $S_X(\omega)$ 在 $(-\infty,+\infty)$ 上绝对可积,所以

$$R_X(\tau)=\frac{1}{2\pi}\int_{-\infty}^{+\infty}S_X(\omega)\mathrm{e}^{\mathrm{i}\omega\tau}\mathrm{d}\omega=\frac{1}{2\pi}\int_{-\omega_0}^{\omega_0}\sigma^2\mathrm{e}^{\mathrm{i}\omega\tau}\mathrm{d}\omega$$

$$=\begin{cases}\dfrac{\sigma^2\omega_0}{\pi}\left(\dfrac{\sin(\omega_0\tau)}{\omega_0\tau}\right), & \tau\neq0,\\ \dfrac{\sigma^2\omega_0}{\pi}, & \tau=0\end{cases}$$

本例中的平稳过程称为**低通白噪声**.

利用复变函数围道积分及留数概念,可以计算形如

$$\int_{-\infty}^{+\infty}f(x)\mathrm{e}^{\mathrm{i}ax}\mathrm{d}x\quad(a>0)$$

的积分.其中 $f(x)$ 为有理函数,分母比分子至少高一次幂,$f(x)$ 在实轴上无奇点,此时积分存在,若记 z_k 为 $f(z)$ 在上半平面内的奇点,由留数定理,则有

$$\int_{-\infty}^{+\infty}f(x)\mathrm{e}^{\mathrm{i}ax}\mathrm{d}x=2\pi\mathrm{i}\sum_k\mathrm{Res}[f(z)\mathrm{e}^{\mathrm{i}az},z_k]\tag{12.3.14}$$

例 12.9 用直接计算积分的方法求例 12.4 中的 $R_X(\tau)$.

解 当 $\tau>0$ 时,

$$R_X(\tau)=\frac{1}{2\pi}\int_{-\infty}^{+\infty}\frac{\omega^2}{\omega^4+3\omega^2+2}\mathrm{e}^{\mathrm{i}\omega\tau}\mathrm{d}\omega$$

$$=\frac{1}{2\pi}\cdot2\pi\mathrm{i}\sum_k\mathrm{Res}\left[\frac{z^2\mathrm{e}^{\mathrm{i}\tau z}}{z^4+3z^2+2},z_k\right]$$

$$=\mathrm{i}\left[\lim_{z\to\mathrm{i}}\frac{(z-\mathrm{i})z^2\mathrm{e}^{\mathrm{i}\tau z}}{z^4+3z+2}+\lim_{z\to\sqrt{2}\mathrm{i}}\frac{(z-\sqrt{2}\,\mathrm{i})z^2\mathrm{e}^{\mathrm{i}\tau z}}{z^4+3z^2+2}\right]$$

$$=\mathrm{i}\left[\frac{-\mathrm{e}^{-\tau}}{2\mathrm{i}}+\frac{\mathrm{e}^{-\sqrt{2}\tau}}{\sqrt{2}\,\mathrm{i}}\right]$$

$$=\frac{1}{\sqrt{2}}\mathrm{e}^{-\sqrt{2}\tau}-\frac{1}{2}\mathrm{e}^{-\tau}$$

即当 $\tau>0$,有

$$R_X(\tau)=\frac{1}{\sqrt{2}}e^{-\sqrt{2}\tau}-\frac{1}{2}e^{-\tau} \tag{12.3.15}$$

另外,当 $\tau<0$ 时,$-\tau>0$,因而,把 $-\tau$ 代入上式,得

$$R_X(-\tau)=\frac{1}{\sqrt{2}}e^{\sqrt{2}\tau}-\frac{1}{2}e^{\tau}$$

由相关函数的性质知,$R_X(\tau)$ 是偶函数,故当 $\tau<0$ 时,有

$$R_X(\tau)=R_X(-\tau)=\frac{1}{\sqrt{2}}e^{\sqrt{2}\tau}-\frac{1}{2}e^{\tau} \tag{12.3.16}$$

把(12.3.15)、(12.3.16)式合并起来,即得

$$R_X(\tau)=\frac{1}{\sqrt{2}}e^{-\sqrt{2}|\tau|}-\frac{1}{2}e^{-|\tau|},\quad \tau\neq 0$$

当 $\tau=0$ 时,

$$\begin{aligned}R_X(0)&=\frac{1}{2\pi}\int_{-\infty}^{+\infty}\frac{\omega^2}{\omega^4+3\omega^2+2}d\omega\\&=\frac{1}{\pi}\int_0^{+\infty}\left(\frac{2}{\omega^2+2}-\frac{1}{\omega^2+1}\right)d\omega\\&=\frac{1}{\pi}\left[\sqrt{2}\arctan\frac{\omega}{\sqrt{2}}-\arctan\ \omega\right]_0^{+\infty}\\&=\frac{\sqrt{2}}{2}-\frac{1}{2}\end{aligned}$$

故对任意 τ,有

$$R_X(\tau)=\frac{1}{\sqrt{2}}e^{-\sqrt{2}|\tau|}-\frac{1}{2}e^{-|\tau|}$$

12.4 各态历经性

12.4.1 各态历经性的概念

设 $X_T=\{X(t),-\infty<t<+\infty\}$ 是平稳过程,它的两个数字特征——均值 m_X 与相关函数 $R_X(\tau)$ 通常是未知的,那么,如何通过试验得到它们的估计 $\hat{m}_X$,$\hat{R}_X(\tau)$ 呢? 最简单自然的方法是进行 n 次重复试验,得到 n 个样本函数 $x_1(t),x_2(t),\cdots,x_n(t)$. 对固定的 t_0,

$$m_X=E[X(t_0)]\approx\frac{1}{n}\sum_{k=1}^{n}x_k(t_0)$$

$$R_X(\tau)=E[X(t_0)X(t_0+\tau)]\approx\frac{1}{n}\sum_{k=1}^{n}x_k(t_0)x_k(t_0+\tau)$$

这需要做 n 次试验,而且为了更精确还需 n 相当大. 这在实际应用中是非常困难的,

甚至是不可能的.由于平稳过程的统计特性不随时间推移而改变,因而我们能否利用一个样本函数去估计过程的均值和相关函数呢?

回忆切比雪夫大数定律的推论,设$\{X_n, n\geqslant 1\}$是相互独立的随机变量序列,$E(X_n)=\mu, D(X_n)=\sigma^2 (n=1,2,\cdots)$,则

$$(p)\lim_{n\to\infty}\frac{1}{n}\sum_{k=1}^{n}X_k=\mu$$

上述等式的左端代表随机序列$\{X_n, n\geqslant 1\}$按时间平均,等式右端表示它的均值(即数学期望),故该推论又可理解为随机序列$\{X_n, n\geqslant 1\}$的时间平均依概率收敛于它的数学期望(也称为统计平均或集平均).此外,由依概率收敛的含义,当n充分大时,我们有很大的把握认为下式成立

$$\frac{1}{n}\sum_{k=1}^{n}x_k\approx\mu$$

其中$x_1, x_2, \cdots, x_n$是对随机序列$\{X_n, n\geqslant 1\}$作一次试验后,所得观测值$x_1, x_2, \cdots$的前n项,换言之,利用随机序列$\{X_n, n\geqslant 1\}$的一次试验后的结果$x_1, x_2, \cdots$,按照观测值的先后顺序求平均,即可用来估计该序列的统计平均μ.

把上述想法推广到平稳过程中,便引出了所谓的各态历经性概念.

设$\{X(t), -\infty<t<+\infty\}$是平稳过程.若以下的均方极限存在

$$\langle X(t)\rangle \overset{\text{def}}{=\!=} (\text{m.s.})\lim_{T\to+\infty}\frac{1}{2T}\int_{-T}^{T}X(t)\,\mathrm{d}x^{①} \tag{12.4.1}$$

则称$\langle X(t)\rangle$为$X(t)$在区间$(-\infty, +\infty)$上的**时间平均**.对固定的τ,若以下的均方极限存在

$$\langle X(t)X(t+\tau)\rangle \overset{\text{def}}{=\!=} (\text{m.s.})\lim_{T\to+\infty}\frac{1}{2T}\int_{-T}^{T}X(t)X(t+\tau)\,\mathrm{d}t \tag{12.4.2}$$

则称$\langle X(t)X(t+\tau)\rangle$为$X(t)$在区间$(-\infty, +\infty)$上的**时间相关函数**.

需要指出,以上两个定义式右端极限号下的积分都是均方积分(参阅本章附录).因此,平稳过程的时间平均以及时间相关函数分别为随机变量.

由于平稳过程的统计特性不随时间推移而改变,因而我们希望得到

$$\langle X(t)\rangle = m_X \quad (\text{a.s.})^{②} \tag{12.4.3}$$

$$\langle X(t)X(t+\tau)\rangle = R_X(\tau) \quad (\text{a.s.}) \tag{12.4.4}$$

其中$m_X=E[X(t)]$,$R_X(\tau)=E[X(t)X(t+\tau)]$,$\tau$固定.

若(12.4.3)式成立,则称$X(t)$具有**数学期望的各态历经性**(也称为遍历性).

若(12.4.4)式成立,则称$X(t)$具有**相关函数的各态历经性**.

若(12.4.3)式和(12.4.4)式都成立,则称$X(t)$具有各态历经性(或者称$X(t)$为**各态历经过程**).

下面是一个具有各态历经性的平稳过程的例子.

---

① m.s.是 mean square 的缩写,具体解释见附录.

② a.s.是 almost surely 的缩写,它表示相应的等式以概率为 1 地成立,亦即$\langle X(t)\rangle = m_X (\text{a.s.}) \Longleftrightarrow P\{\langle X(t)\rangle = m_X\}=1$.下同.

例 12.10 设$\{X(t)=a\cos(\omega_0 t+\Phi),-\infty<t<+\infty\}$,其中 a,ω_0 是正的常数,Φ 是随机变量,且 $\Phi\sim U(0,2\pi)$.试讨论 $X(t)$ 的各态历经性.

解 易知

$$E[X(t)]=a\int_0^{2\pi}\cos(\omega_0 t+\varphi)\frac{1}{2\pi}\mathrm{d}\varphi=0$$

$$E[X(t)X(t+\tau)]=\frac{a^2}{2}\cos(\omega_0\tau)$$

即 $X(t)$ 是平稳过程,且 $m_X=0,R_X(\tau)=\frac{1}{2}a^2\cos(\omega_0\tau)$.而

$$\begin{aligned}\langle X(t)\rangle&=(\text{m.s.})\lim_{T\to+\infty}\frac{1}{2T}\int_{-T}^{T}a\cos(\omega_0 t+\Phi)\,\mathrm{d}t\\&=(\text{m.s.})\lim_{T\to+\infty}\frac{a}{2T}\int_{-T}^{T}(\cos\omega_0 t\cos\Phi-\sin\omega_0 t\sin\Phi)\,\mathrm{d}t\\&=0=m_X\end{aligned}$$

类似地,有

$$\begin{aligned}\langle X(t)X(t+\tau)\rangle&=(\text{m.s.})\lim_{T\to+\infty}\frac{a^2}{2T}\int_{-T}^{T}\cos(\omega_0 t+\Phi)\cos[\omega_0(t+\tau)+\Phi]\,\mathrm{d}t\\&=\frac{a^2}{2}\cos(\omega_0\tau)=R_X(\tau)\end{aligned}$$

故 $X(t)$ 具有各态历经性.

并不是所有的平稳过程都具有各态历经性.请看下面的例子.

例 12.11 设$\{X(t)=\xi,-\infty<t<+\infty\}$,其中 ξ 为随机变量,且 $\xi\sim N(0,\sigma^2)$,试讨论它的各态历经性.

解 一方面,$E[X(t)]=E(\xi)=0,E[X(t)X(t+\tau)]=E(\xi^2)=\sigma^2$,故 $X(t)$ 是平稳过程,且 $m_X=0,R_X(\tau)=\sigma^2$.另一方面,

$$\langle X(t)\rangle=(\text{m.s.})\lim_{T\to+\infty}\frac{1}{2T}\int_{-T}^{T}\xi\,\mathrm{d}t=\xi$$

$$\langle X(t)X(t+\tau)\rangle=(\text{m.s.})\lim_{T\to+\infty}\frac{1}{2T}\int_{-T}^{T}\xi^2\,\mathrm{d}t=\xi^2$$

注意到 ξ 是连续型随机变量,因而 $P\{\xi=0\}=0,P\{\xi^2=\sigma^2\}=0$,亦即,等式 $P\{\xi=0\}=1$ 和 $P\{\xi^2=\sigma^2\}=1$ 均不成立,故这个平稳过程不具有数学期望和相关函数的各态历经性.

12.4.2 各态历经定理

这一段将讨论为使平稳过程具有数学期望的各态历经性或者相关函数的各态历经性,需要对过程本身加上什么样的条件.

定理 12.2 (数学期望的各态历经定理)设$\{X(t),-\infty<t<+\infty\}$是平稳过程,则 $\langle X(t)\rangle=m_X(\text{a.s.})$的充要条件是

$$\lim_{T\to+\infty}\frac{1}{T}\int_0^{2T}\left(1-\frac{\tau}{2T}\right)[R_X(\tau)-m_X^2]\,\mathrm{d}\tau=0 \tag{12.4.5}$$

证 $\langle X(t)\rangle$本身是随机变量,现计算它的数学期望和方差,得

$$E[\langle X(t)\rangle]=E[(\text{m.s.})\lim_{T\to+\infty}\frac{1}{2T}\int_{-T}^{T}X(t)\,\mathrm{d}t]$$

$$=\lim_{T\to+\infty}\frac{1}{2T}\int_{-T}^{T}E[X(t)]\,\mathrm{d}t(\text{根据均方极限及均方积分的性质})$$

$$=m_X$$

$$D[\langle X(t)\rangle]=E\{[\langle X(t)\rangle]^2\}-\{E[\langle X(t)\rangle]\}^2$$

$$=E\left\{\left[(\text{m.s.})\lim_{T\to+\infty}\frac{1}{2T}\int_{-T}^{T}X(t)\,\mathrm{d}t\right]^2\right\}-m_X^2$$

$$=\lim_{T\to+\infty}\frac{1}{4T^2}\int_{-T}^{T}\int_{-T}^{T}R_X(t-s)\,\mathrm{d}s\mathrm{d}t-m_X^2$$

由积分变量的替换和$R_X(\tau)$的偶函数性质,可得(参阅 12.3.2 的 3)

$$\int_{-T}^{T}\int_{-T}^{T}R_X(t-s)\,\mathrm{d}s\mathrm{d}t=2\int_{0}^{2T}(2T-\tau)R_X(\tau)\,\mathrm{d}\tau$$

故

$$D[\langle X(t)\rangle]=\lim_{T\to+\infty}\frac{1}{T}\int_{0}^{2T}\left(1-\frac{\tau}{2T}\right)[R_X(\tau)-m_X^2]\,\mathrm{d}\tau$$

于是,$\langle X(t)\rangle=m_X(\text{a.s.})\Leftrightarrow\langle X(t)\rangle=E[\langle X(t)\rangle](\text{a.s.})\Leftrightarrow D[\langle X(t)\rangle]=0\Leftrightarrow$(12.4.5)式成立.

推论 若平稳过程 X_T 满足 $\lim\limits_{\tau\to+\infty}R_X(\tau)=m_X^2$,即 $\lim\limits_{\tau\to+\infty}C_X(\tau)=0$,则 X_T 具有数学期望的各态历经性.

证 由极限的定义知,对于任意 $\varepsilon>0$,存在 $T(\varepsilon)>0$,当 $\tau\geqslant T(\varepsilon)$时,有 $|C_X(\tau)|=|R_X(\tau)-m_X^2|<\varepsilon$,故

$$\left|\frac{1}{T}\int_{0}^{2T}\left(1-\frac{\tau}{2T}\right)[R_X(\tau)-m_X^2]\,\mathrm{d}\tau\right|$$

$$\leqslant\frac{1}{T}\int_{0}^{2T}|R_X(\tau)-m_X^2|\,\mathrm{d}\tau$$

$$=\frac{1}{T}\left[\int_{0}^{T(\varepsilon)}|C_X(\tau)|\,\mathrm{d}\tau+\int_{T(\varepsilon)}^{2T}|C_X(\tau)|\,\mathrm{d}\tau\right]$$

$$\leqslant\frac{1}{T}[C_X(0)T(\varepsilon)+\varepsilon(2T-T(\varepsilon))]\quad(\text{这里,设 }2T\geqslant T(\varepsilon))$$

$$\leqslant\frac{T(\varepsilon)}{T}C_X(0)+2\varepsilon$$

于是,若对上述的 $\varepsilon>0$,取 $T_0=\max\left\{\frac{T(\varepsilon)}{2},\frac{T(\varepsilon)C_X(0)}{\varepsilon}\right\}$,则当 $T\geqslant T_0$ 时,就有

$$\left|\frac{1}{T}\int_{0}^{2T}\left(1-\frac{\tau}{2T}\right)[R_X(\tau)-m_X^2]\,\mathrm{d}\tau\right|<3\varepsilon$$

故由定理 12.2 可以得到结论.

这个推论给出了平稳过程具有数学期望各态历经性的一个充分条件,它说明,当时间间隔 τ 无限趋大时,$X(t)$与 $X(t+\tau)$之间的线性联系趋近于不相关的平稳过程

具有数学期望各态历经性.

定理 12.3 (相关函数各态历经定理)设$\{X(t),-\infty<t<+\infty\}$是平稳过程,若对任意固定的$\tau$,$\{X(t)X(t+\tau),-\infty<t<+\infty\}$是平稳过程,则$\langle X(t)X(t+\tau)\rangle=R_X(\tau)$(a.s.)的充要条件是

$$\lim_{T\to+\infty}\frac{1}{T}\int_0^{2T}\left(1-\frac{\tau_1}{2T}\right)[R_\tau(\tau_1)-R_X^2(\tau)]\,\mathrm{d}\tau_1=0 \tag{12.4.6}$$

其中$R_\tau(\tau_1)=E[X(t)X(t+\tau)X(t+\tau_1)X(t+\tau_1+\tau)]$.

证 对固定的τ,令$Y_\tau(t)=X(t)X(t+\tau)$,$-\infty<t<+\infty$,则$\{Y_\tau(t),-\infty<t<+\infty\}$是平稳过程,且有$E[Y_\tau(t)]=R_X(\tau)$,$\langle Y_\tau(t)\rangle=\langle X(t)X(t+\tau)\rangle$,故$X(t)$的相关函数各态历经性等价于$Y_\tau(t)$的数学期望各态历经性.又因$Y_\tau(t)$的相关函数为

$$\begin{aligned}R_{Y_\tau}(\tau_1)&=E[Y_\tau(t)Y_\tau(t+\tau_1)]\\&=E[X(t)X(t+\tau)X(t+\tau_1)X(t+\tau_1+\tau)]=R_\tau(\tau_1)\end{aligned}$$

于是,由定理 12.2,可得结论.

在实际应用中通常会考虑时间为$0\leqslant t<+\infty$的平稳过程$\{X(t),0\leqslant t<+\infty\}$,此时,用"$\frac{1}{T}\int_0^T$"替换时间平均和时间相关函数定义中的"$\frac{1}{2T}\int_{-T}^T$",并用"$T$"替换定理 12.2,12.3 中出现的"$2T$",其余的保持不变,就可得到相应的各态历经性定理.此外,对离散参数的平稳序列$\{X(n),n=0,1,2,\cdots\}$也有类似的各态历经性定理.

12.4.3 各态历经性的应用

对于具有各态历经性的平稳过程,如何利用一个样本函数近似计算过程的数学期望m_X和相关函数$R_X(\tau)$呢?先介绍一个有关均方收敛与依概率收敛之间关系的命题.

命题 12.2 设$\{X_n,n\geqslant1\}$为一随机序列,若(m.s.)$\lim\limits_{n\to\infty}X_n=X$,则$(p)\lim\limits_{n\to\infty}X_n=X$.

证 对任意$\varepsilon>0$,由马尔可夫不等式$P\{|Y|\geqslant\varepsilon\}\leqslant E(|Y|^2)/\varepsilon^2$,有

$$P\{|X_n-X|\geqslant\varepsilon\}\leqslant E[|X_n-X|^2]/\varepsilon^2$$

因为(m.s.)$\lim\limits_{n\to\infty}X_n=X$,即$E(|X_n-X|^2)\to0(n\to\infty)$,所以由极限的夹逼法则,得$P\{|X_n-X|\geqslant\varepsilon\}\to0(n\to\infty)$,亦即$X_n$依概率收敛到$X$.

设$\{X(t),0\leqslant t<+\infty\}$为具有各态历经性的平稳过程,过程的数学期望各态历经性表示

$$(\mathrm{m.s.})\lim_{T\to+\infty}\frac{1}{T}\int_0^T X(t)\,\mathrm{d}t=m_X \tag{12.4.7}$$

因该条件隐含$X(t)$在任意区间$[0,T]$上均方可积,故可把均方积分$\int_0^T X(t)\,\mathrm{d}t$表示为下述和式的均方极限

$$\int_0^T X(t)\,\mathrm{d}t=(\mathrm{m.s.})\lim_{N\to\infty}\sum_{k=1}^N X\left(k\frac{T}{N}\right)\cdot\frac{T}{N}$$

于是,有

$$(\text{m.s.})\lim_{T\to+\infty}\frac{1}{T}\left[(\text{m.s.})\lim_{N\to\infty}\sum_{k=1}^{N}X\left(k\frac{T}{N}\right)\cdot\frac{T}{N}\right]=m_X$$

亦即

$$(\text{m.s.})\lim_{T\to+\infty}\lim_{N\to\infty}\frac{1}{N}\sum_{k=1}^{N}X\left(k\frac{T}{N}\right)=m_X$$

这是均方意义下的累次极限，利用上述命题，对任给 $\varepsilon>0$，有

$$\lim_{T\to+\infty}\lim_{N\to\infty}P\left\{\left|\frac{1}{N}\sum_{k=1}^{N}X\left(k\frac{T}{N}\right)-m_X\right|<\varepsilon\right\}=1$$

故当 T 充分大，N 也充分大且 T/N 很小时，

$$P\left\{\left|\frac{1}{N}\sum_{k=1}^{N}X\left(k\frac{T}{N}\right)-m_X\right|<\varepsilon\right\}\approx 1$$

根据实际推断原理，对过程做一次试验得到样本函数 $x(t)$，几乎肯定地认为

$$\left|\frac{1}{N}\sum_{k=1}^{N}x\left(k\frac{T}{N}\right)-m_X\right|<\varepsilon$$

成立，因而

$$m_X\approx\frac{1}{N}\sum_{k=1}^{N}x\left(k\frac{T}{N}\right)\tag{12.4.8}$$

过程的相关函数各态历经性表示

$$(\text{m.s.})\lim_{T\to+\infty}\frac{1}{T}\int_0^T X(t)X(t+\tau)\,\mathrm{d}t=R_X(\tau)\tag{12.4.9}$$

在推出相关函数 $R_X(\tau)$ 的近似计算公式中，限于考虑 $\tau=r\dfrac{T}{N}$ 的情形，其中 r 为固定的非负整数（$0\leqslant r\leqslant m$）.与前面讨论类似，由(12.4.9)式可得

$$\lim_{T\to+\infty}\lim_{N\to\infty}P\left\{\left|\frac{1}{N-r}\sum_{k=1}^{N-r}X\left(k\frac{T}{N}\right)X\left(k\frac{T}{N}+r\frac{T}{N}\right)-R_X\left(r\frac{T}{N}\right)\right|<\varepsilon\right\}=1$$

因而

$$R_X\left(r\frac{T}{N}\right)\approx\frac{1}{N-r}\sum_{k=1}^{N-r}x\left(k\frac{T}{N}\right)x\left(k\frac{T}{N}+r\frac{T}{N}\right)\tag{12.4.10}$$

上式要求 T 很大，$N-r$ 也很大，且 T/N 很小.通常取 m 介于 $N/5$ 与 $N/2$ 之间.

由(12.4.8)和(12.4.10)式可见，在近似计算 m_X 和 $R_X(\tau)$ 时，实际上只需用到样本函数 $x(t)$ 在 $k\dfrac{T}{N}$（$1\leqslant k\leqslant N$）点处的数值.这些点称为采样点，数值 $x\left(k\dfrac{T}{N}\right)$（$1\leqslant k\leqslant N$）称为采样值.

在(12.4.10)式中，取 $\tau=r\dfrac{T}{N}$ 的形式是为了充分利用好手头的采样值 $x\left(k\dfrac{T}{N}\right)$（$1\leqslant k\leqslant N$）.不然的话，为了近似计算 $R_X(\tau)$，除了已采集的数值 $x\left(k\dfrac{T}{N}\right)$（$1\leqslant k\leqslant N$）外，还要额外地采集 $x\left(k\dfrac{T}{N}+\tau\right)$（$1\leqslant k\leqslant N$），这会增大采样负担.

在实际应用中尤其是实时处理时，一般是利用相关分析仪来获得时间相关函数.

最后指出,在实际问题中各态历经定理的充要条件是很难验证的,因为条件中出现的 $R_X(\tau)$,m_X 以及 $R_\tau(\tau_1)$都是未知的.工程上对各态历经性概念往往采取先用后由实践来检验的办法.

12.5 附录

12.5.1 两个补充定理

博赫纳-辛钦定理 函数 $\varphi(t)(-\infty<t<+\infty)$可表示为

$$\varphi(t)=\int_{-\infty}^{+\infty}\mathrm{e}^{\mathrm{i}tx}\mathrm{d}F(x)$$

的充要条件是 $\varphi(t)$非负定、连续且 $\varphi(0)=1$,这里 $F(x)$为某随机变量的分布函数.

赫格洛茨定理 数列$\{c_n,n=0,\pm1,\pm2,\cdots\}$可表示为

$$c_n=\int_{-\pi}^{\pi}\mathrm{e}^{\mathrm{i}nx}\mathrm{d}G(x)\quad(n=0,\pm1,\pm2,\cdots)$$

的充要条件是它为非负定的,这里 $G(x)$是$[-\pi,\pi]$上有界、单调增、右连续函数.

以上两个定理的充分性的证明非常复杂,这里省略.

12.5.2 均方微积分

1. 均方极限

定义 12.2 设有随机序列$\{X_n,n=1,2,\cdots\}$和随机变量 X,且 $E(|X_n|^2)<+\infty$ $(n=1,2,\cdots)$,$E(|X|^2)<\infty$,若有

$$\lim_{n\to\infty}E(|X_n-X|^2)=0$$

则称$\{X_n\}$**均方收敛于** X,或者称 X 是 X_n 当 $n\to\infty$ 时的**均方极限**,记作$(\mathrm{m.s.})\lim\limits_{n\to\infty}X_n=X$,这里 m.s.是 mean square 的缩写.

定理 12.4 若$(\mathrm{m.s.})\lim\limits_{n\to\infty}X_n=X$,且$(\mathrm{m.s.})\lim\limits_{n\to\infty}X_n=Y$,则必有 $P\{X=Y\}=1$,亦即 $X=Y(\mathrm{a.s.})$.

证 因为

$$\begin{aligned}0\leqslant E(|X-Y|^2)&=E(|X-X_n+X_n-Y|^2)\\&\leqslant 2[E(|X_n-X|^2)+E(|X_n-Y|^2)]\to 0\quad(n\to\infty)\end{aligned}$$

所以由极限夹逼法则知,$E[|X-Y|^2]=0$,此即,$P\{X=Y\}=1$.

上述定理指出,均方极限在概率为 1 的意义下是唯一的.

均方极限的性质:

(1) 若$(\mathrm{m.s.})\lim\limits_{n\to\infty}X_n=X$,则$\lim\limits_{n\to\infty}E(X_n)=E(X)$,亦即$\lim\limits_{n\to\infty}E(X_n)=E[(\mathrm{m.s.})\lim\limits_{n\to\infty}X_n]$.

(2) 若$(\mathrm{m.s.})\lim\limits_{n\to\infty}X_n=X$,$(\mathrm{m.s.})\lim\limits_{m\to\infty}Y_m=Y$,则有

$$\lim_{\substack{n\to\infty\\m\to\infty}}E(X_nY_m)=E(XY)$$

(3) 若$(\mathrm{m.s.})\lim\limits_{n\to\infty}X_n=X$,且$(\mathrm{m.s.})\lim\limits_{n\to\infty}Y_n=Y$,则对任意常数 a,b,aX_n+bY_n 也均方收敛,且

$$(\text{m.s.})\lim_{n\to\infty}(aX_n+bY_n)=aX+bY$$

(4) 若$(\text{m.s.})\lim_{n\to\infty}X_n=X$,又$\lim_{n\to\infty}a_n=a$,则$(\text{m.s.})\lim_{n\to\infty}a_nX_n=aX$.

(5) $(\text{m.s.})\lim_{n\to\infty}X_n$ 存在的充要条件是$(\text{m.s.})\lim_{\substack{n\to\infty\\m\to\infty}}(X_m-X_n)=0$,亦即随机序列$\{X_n,n=1,2,\cdots\}$为均方意义下的柯西列①.

利用均方极限的定义以及概率论中的柯西-施瓦茨不等式,不难证明上述性质((5)的充分性的证明除外).

与高等数学类似,同样可以把数列形式的均方极限概念推广到函数形式,并写出相应的均方极限的性质,这留给读者做练习.

有了均方极限概念,就可以来定义均方连续、均方导数和均方积分等概念并研究它们的相应性质.在以下的讨论中恒假定随机过程 X_T,Y_T 是**二阶矩过程**,随机变量 X 是二阶矩存在的随机变量,并且参数集 T 为下述区间之一:$[a,b]$,$[0,+\infty)$,$(-\infty,+\infty)$.

2. 均方连续

定义 12.3 设 $X_T=\{X(t),t\in T\}$,若对固定 $t_0\in T$,有

$$(\text{m.s.})\lim_{t\to t_0}X(t)=X(t_0)$$

则称 X_T 在 $t=t_0$ 处**均方连续**.若 X_T 在 T 上的每一点处都均方连续,则称 X_T 在 T 上均方连续.

定理 12.5 X_T 在 T 上均方连续的充要条件是对任意的 $t\in T$,$R_X(t_1,t_2)$ 在点 (t,t) 处是二元连续的.

证 必要性.设 X_T 在 T 上均方连续,则对 $\forall t\in T$,有$(\text{m.s.})\lim_{\Delta t\to 0}X(t+\Delta t)=X(t_0)$,即 $\lim_{\Delta t\to 0}E[\,|X(t+\Delta t)-X(t)|^2]=0$,因为

$$\begin{aligned}0\leqslant&|R_X(t_1,t_2)-R_X(t,t)|=|E[X(t_1)X(t_2)]-E[X(t)X(t)]|\\\leqslant&|E\{[X(t_1)-X(t)]X(t_2)\}|+|E\{X(t)[X(t_2)-X(t)]\}|\\\leqslant&\sqrt{E[\,|X(t_1)-X(t)|^2]}\sqrt{E[X^2(t_2)]}+\sqrt{E[X^2(t)]}\sqrt{E[\,|X(t_2)-X(t)|^2]}\\\to&0\quad(\text{当 }t_1\to t\text{ 且 }t_2\to t\text{ 时})\end{aligned}$$

所以 $R_X(t_1,t_2)$ 在 (t,t) 点二元连续.

充分性.设对任意 $t\in T$,$R_X(t_1,t_2)$ 在点 (t,t) 处二元连续,现在对任意 $t\in T$,由于 $E[\,|X(t+\Delta t)-X(t)|^2]=R_X(t+\Delta t,t+\Delta t)-R_X(t+\Delta t,t)-R_X(t,t+\Delta t)+R_X(t,t)\to R_X(t,t)-R_X(t,t)-R_X(t,t)+R_X(t,t)=0$(当 $\Delta t\to 0$ 时,由 $R_X(t_1,t_2)$ 在点 (t,t) 处的连续性知).所以 X_T 在 t 点处均方连续,再由 t 的任意性,即知 X_T 在 T 上均方连续.

3. 均方导数

定义 12.4 设 $X_T=\{X(t),t\in T\}$,若对固定 $t_0\in T$,均方极限

$$(\text{m.s.})\lim_{\Delta t\to 0}\frac{X(t_0+\Delta t)-X(t_0)}{\Delta t}$$

① 柯西列是高等数学中讲述的柯西数列在随机变量序列$\{X_n,n=1,2,\cdots\}$中的推广.

存在，则称 X_T 在 t_0 处**均方可导**，并称此极限为 X_T 在 t_0 处的**均方导数**，记为 $X'(t_0)$ 或 $\left.\frac{\mathrm{d}X(t)}{\mathrm{d}t}\right|_{t=t_0}$. 若 X_T 在 T 上的每一点处都均方可导，则称 X_T 在 T 上均方可导，此时，均方导数记为 $X'(t)$ 或 $\frac{\mathrm{d}X(t)}{\mathrm{d}t}$.

$\{X'(t), t\in T\}$ 是一个新的随机过程.

均方导数的性质：

(1) 若 X_T 在 t_0 点处均方可导，则 X_T 在 t_0 点处均方连续.

(2) 若 X_T 在 T 上均方可导，其均方导数为 $X'(t)$，则有

$$E[X'(t)]=\frac{\mathrm{d}}{\mathrm{d}t}E[X(t)]$$

(3) 若 X_T 在 T 上均方可导，其均方导数为 $X'(t)$，则有

$$E[X'(t_1)X'(t_2)]=\frac{\partial^2}{\partial t_1\partial t_2}E[X(t_1)X(t_2)]=\frac{\partial^2}{\partial t_2\partial t_1}E[X(t_1)X(t_2)]$$

(4) 若 X 为随机变量，则 $X'=0$.

(5) 若 $X(t)$，$Y(t)$ 均方可导，a，b 为常数，则 $aX(t)+bY(t)$ 也均方可导，且

$$[aX(t)+bY(t)]'=aX'(t)+bY'(t)$$

(6) 若 $f(t)$ 是可导函数，$X(t)$ 是均方可导的随机过程，则 $f(t)X(t)$ 也是均方可导的随机过程，且

$$[f(t)X(t)]'=f'(t)X(t)+f(t)X'(t)$$

利用均方导数的定义和均方极限的性质不难证明均方导数的上述性质.

4. 均方积分

定义 12.5 设 $X_T=\{X(t), a\leqslant t\leqslant b\}$，把区间 $[a,b]$ 分成 n 个子区间：$a=t_0<t_1<\cdots<t_{n-1}<t_n=b$，记 $\Delta t_k=t_k-t_{k-1}(k=1,2,\cdots,n)$，$\Delta=\max\limits_{1\leqslant k\leqslant n}\{\Delta t_k\}$，作和式

$$\sum_{k=1}^{n}X(\xi_k)\Delta t_k$$

其中 $\xi_k\in[t_{k-1},t_k]$ 为任意选取的一点 $(k=1,2,\cdots,n)$. 若均方极限

$$(\mathrm{m.s.})\lim_{\Delta\to 0}\sum_{k=1}^{n}X(\xi_k)\Delta t_k$$

存在，且与子区间的分法以及 ξ_k 的取法无关，则称 X_T 在区间 $[a,b]$ 上**均方可积**，并称此极限为 X_T 在 $[a,b]$ 上的**均方积分**，记为 $\int_a^b X(t)\,\mathrm{d}t$，即

$$\int_a^b X(t)\,\mathrm{d}t=(\mathrm{m.s.})\lim_{\Delta\to 0}\sum_{k=1}^{n}X(\xi_k)\Delta t_k$$

均方积分的性质：

(1) 若 X_T 在 $[a,b]$ 上均方连续，则它是均方可积的.

(2) $E\left[\int_a^b X(t)\,\mathrm{d}t\right]=\int_a^b E[X(t)]\,\mathrm{d}t$.

(3) $E\left[\int_a^b X(t)\,\mathrm{d}t\mid^2\right]=\int_a^b\int_a^b R_X(s,t)\,\mathrm{d}s\mathrm{d}t$.

(4) $\int_a^b [\alpha X(t)+\beta Y(t)]\,\mathrm{d}t=\alpha\int_a^b X(t)\,\mathrm{d}t+\beta\int_a^b Y(t)\,\mathrm{d}t$，其中 α,β 为常数，X_T,Y_T 在 $[a,b]$ 上均方可积.

(5) 若 X 为随机变量，$f(t)$ 是 $[a,b]$ 上的可积函数，则

$$\int_a^b Xf(t)\,\mathrm{d}t=X\int_a^b f(t)\,\mathrm{d}t$$

(6) $\int_a^b X(t)\,\mathrm{d}t=\int_a^c X(t)\,\mathrm{d}t+\int_c^b X(t)\,\mathrm{d}t$，其中 X_T 在最大的积分区间上均方可积.

(7) 若 X_T 在 $[a,b]$ 上均方连续，则 $Y(t)=\int_a^t X(s)\,\mathrm{d}s$，$a\leqslant t\leqslant b$ 在 (a,b) 内均方可导，且 $Y'(t)=X(t)$.

(8) 若 X_T 在 $[a,b]$ 上均方可导，且 $X'_T\overset{\text{def}}{=\!=}\{X'(t),t\in T\}$ 在 $[a,b]$ 上均方连续，则

$$\int_a^b X'(t)\,\mathrm{d}t=X(b)-X(a)$$

均方积分的上述性质，大部分都可以利用均方积分定义以及均方极限的性质加以证明.

内容小结

假设随机过程 X_T 是二阶矩过程，满足条件：(1) 对任意的 $t\in T$，$m(t)=E[X(t)]$ 都是同一个常数；(2) 对任意的 $t,t+\tau\in T$，$R_X(t,t+\tau)=E[X(t)X(t+\tau)]$ 不依赖于 τ，则称随机过程 X_T 为宽平稳过程。

宽平稳过程 X_T 的自相关函数可以表示为 $R_X(\tau)=E[X(t)X(t+\tau)]$。

在一定条件下，宽平稳过程 X_T 的自相关函数 $R_X(\tau)$ 可以表示为

$$R_X(\tau)=\frac{1}{2\pi}\int_{-\infty}^{+\infty}\mathrm{e}^{\mathrm{i}\tau\omega}S_X(\omega)\,\mathrm{d}\omega,\ -\infty<\tau<+\infty$$

这里有谱密度为

$$S_X(\omega)=\int_{-\infty}^{+\infty}\mathrm{e}^{-\mathrm{i}\tau\omega}R_X(\tau)\,\mathrm{d}\tau,\ -\infty<\omega<+\infty$$

定义 $F_X(\omega;T)=\int_{-T}^{T}X(t)\mathrm{e}^{-\mathrm{i}\omega t}\mathrm{d}t$，称极限 $\lim\limits_{T\to+\infty}\frac{1}{2T}E[\,|F_X(\omega;T)|^2]$ 为信号 $X(t)$ 的功率谱密度。在一定条件下，宽平稳过程的功率谱密度和谱密度是相同的。

对于一个平稳过程，如果以下的均方极限存在

$$\langle X(t)\rangle=(\text{m.s.})\lim_{T\to+\infty}\frac{1}{2T}\int_{-T}^{T}X(t)\,\mathrm{d}t$$

则称 $\langle X(t)\rangle$ 为随机过程 $X(t)$ 在区间 $(-\infty,+\infty)$ 上的时间平均。对固定的 τ，如果以下的均方极限存在

$$\langle X(t)X(t+\tau)\rangle=(\text{m.s.})\lim_{T\to+\infty}\frac{1}{2T}\int_{-T}^{T}X(t)X(t+\tau)\,\mathrm{d}t$$

则称$<X(t)X(t+\tau)>$为随机过程 $X(t)$ 在区间$(-\infty,+\infty)$上的时间相关函数。

如果$<X(t)>=m_X$(a.s.),称随机过程 $X(t)$ 具有数学期望的各态历经性;如果$<X(t)X(t+\tau)>=R_X(\tau)$(a.s.),称随机过程 $X(t)$ 具有相关函数的各态历经性。

习题 12

1.设 X 是一个随机变量,$X(t)\equiv X,-\infty<t<+\infty$,

(1) 如果 X 服从参数为 λ 的泊松分布;

(2) 如果 X 服从标准柯西分布;

(3) 如果 X 服从自由度为 2 的 t 分布(见 6.4.1 小节),

试问:随机过程$\{X(t),-\infty<t<+\infty\}$是否为严平稳过程?是否为(宽)平稳过程?

2.设 A 和 Θ 是两个相互独立的随机变量,$\Theta\sim U[0,2\pi]$,A 服从瑞利分布,其概率密度为

$$f(a)=\begin{cases}\dfrac{a}{\sigma^2}e^{-\frac{a^2}{2\sigma^2}}, & a>0,\\ 0, & a\leqslant 0\end{cases}$$

令 $X(t)=A\cos(\omega_0 t+\Theta),-\infty<t<+\infty$,其中 ω_0 为常数,问此随机过程是否为平稳过程?

3. 设 Θ 是随机变量,$\Theta\sim U[-\pi,\pi]$,$X(t)=\sin t\Theta$,问:

(1) $\{X(t),t=1,2,3,\cdots\}$是否为平稳随机序列?

(2) $\{X(t),-\infty<t<+\infty\}$是否为平稳随机过程?

4. 设 A 和 Θ 是相互独立的随机变量,$\Theta\sim U[-\pi,\pi]$,A 的概率密度 $f(a)$ 是偶函数,证明随机过程 $X(t)=\sin(At+\Theta),-\infty<t<+\infty$ 是平稳过程.

5. 设 $X_T=\{X(t),t\in T\}$ 是平稳随机过程,其均值为 m_X,自相关函数为 $R_X(\tau)$,试证明下列随机过程仍为平稳过程,并求其均值与自相关函数,

(1) $Y_T=\{aX(t)+b,t\in T\}$,其中 a,b 为常数;

(2) $Y_T=\{AX(t)+B,t\in T\}$,其中 A,B 是与 X_T 独立的随机变量,$E(A)=a,E(B)=b,D(A)=\sigma_1^2$,$D(B)=\sigma_2^2,\rho(A,B)=\rho$;

(3) $Y_T=\{X(t+a)-X(t),t\in T\}$,其中 a 为常数.

6. 设 $X_T=\{X(t),t\in T\}$ 与 $Y_T=\{Y(t),t\in T\}$ 是相互独立的平稳随机过程,证明下列随机过程仍是平稳过程:

(1) $Z_T=\{X(t)+Y(t),t\in T\}$;

(2) $Z_T=\{X(t)Y(t),t\in T\}$.

7. 设 $h(x)$ 是周期为 l 的实值连续函数,Θ 是服从$[0,l]$上均匀分布的随机变量,证明 $X(t)=h(t+\Theta),-\infty<t<+\infty$ 是平稳随机过程,并求其均值与自相关函数.

8. 如果平稳过程$\{X(t),-\infty<t<+\infty\}$的自相关函数为 $R_X(\tau)$,$l>0$ 是常数,证明下述三个命题是等价的:

(1) $\{X(t),-\infty<t<+\infty\}$是以 l 为周期的周期平稳过程,即对任何 t 都有 $P\{X(t+l)=X(t)\}=1$;

(2) $R_X(\tau)$ 是以 l 为周期的周期函数;

(3) $R_X(l)=R_X(0)$.

9. 设 A,B,Θ 是相互独立的随机变量,$E(A)=a,E(B)=b,D(A)=\sigma_1^2,D(B)=\sigma_2^2$,$\Theta\sim U[-\pi,\pi]$,$\omega_0$ 为常数,$X(t)=A\sin(\omega_0 t+\Theta),Y(t)=B\cos(\omega_0 t+\Theta)$,试证明$\{X(t),-\infty<t<+\infty\}$与$\{Y(t),-\infty<t<+\infty\}$是平稳相关的平稳过程.

10. 设$\{X(n),n=0,\pm1,\pm2,\cdots\}$是白噪声序列,$Y(n)=\sum\limits_{k=0}^{N}a_kX(n-k)$,其中 N 为自然数,a_0,

$a_1,\cdots,a_N$ 为常数，求 $\{X(n),n=0,\pm1,\pm2,\cdots\}$ 与 $\{Y(n),n=0,\pm1,\pm2,\cdots\}$ 的互相关函数 $R_{XY}(m)$ 及 $R_{YX}(m)$.

11. 设 $X(t)$ 是雷达的发射信号，遇到目标后回波信号是 $aX(t-\tau_1)$，$a\ll1$，τ_1 是信号返回时间，回波信号必然伴有噪声，记为 $N(t)$，于是接收机收到的全信号为 $Y(t)=aX(t-\tau_1)+N(t)$，假定 $X(t)$ 和 $N(t)$ 平稳相关，

(1) 试求互相关函数 $R_{XY}(\tau)$；

(2) 若 $N(t)$ 的数学期望为零，且与 $X(t)$ 相互独立，求 $R_{XY}(\tau)$.

12. 设 $X_T=\{X(t),t\in T\}$ 和 $Y_T=\{Y(t),t\in T\}$ 是平稳相关的两个平稳过程，证明其互相关函数具有如下性质：

(1) $R_{XY}(-\tau)=R_{YX}(\tau)$；

(2) $R_{XY}(\tau)\leqslant\sqrt{R_X(0)}\sqrt{R_Y(0)}$.

13. 设 X 是一随机变量，$E(X)=\mu$，$D(X)=\sigma^2$，证明随机过程 $X(t)\equiv X,-\infty<t<+\infty$ 是平稳过程，并求谱密度.

14. 已知平稳过程 $\{X(t),-\infty<t<+\infty\}$ 的自相关函数 $R_X(\tau)$，求其谱密度 $S_X(\omega)$：

(1) $R_X(\tau)=4e^{-|\tau|}\cos\pi\tau+\cos3\pi\tau$；

(2) $R_X(\tau)=4e^{-3|\tau|}\cos^2 2\tau$；

(3) $R_X(\tau)=\begin{cases}1-\dfrac{|\tau|}{10}, & |\tau|\leqslant10,\\ 0, & |\tau|>10;\end{cases}$

(4) $R_X(\tau)=be^{-a|\tau|}(1+a|\tau|)$，其中 $a>0,b>0$，都是常数；

(5) $R_X(\tau)=\sigma^2e^{-a|\tau|}(\cos b\tau-ab^{-1}\sin b|\tau|)$，其中 $a>0,b>0$ 都是常数.

15. 设 A 和 Θ 是相互独立的随机变量，$E(A)=2,D(A)=4$，$\Theta\sim U[-\pi,\pi]$，ω_0 为常数，$X(t)=A\cos(\omega_0t+\Theta),-\infty<t<+\infty$，

(1) 证明 $X(t)$ 是平稳过程；

(2) 求 $X(t)$ 的谱密度.

16. 设 ξ 和 Θ 为相互独立的随机变量，$\Theta\sim U[0,2\pi]$，ξ 具有概率密度 $f(x)=\dfrac{1}{\pi(1+x^2)}$，$X(t)=\cos(\xi t+\Theta)$，

(1) 证明 $\{X(t),-\infty<t<+\infty\}$ 是平稳随机过程；

(2) 求其自相关函数及谱密度.

17. 设第 5 题中的 X_T 具有谱密度 $S_X(\omega)$，求 Y_T 的谱密度.

18. 已知平稳过程 $\{X(t),-\infty<t<+\infty\}$ 的谱密度 $S_X(\omega)$，试求其自相关函数 $R_X(\tau)$，下面的 $a>0,\sigma>0$ 是常数，

(1) $S_X(\omega)=\begin{cases}1, & |\omega|\leqslant a,\\ 0, & |\omega|>a;\end{cases}$

(2) $S_X(\omega)=\begin{cases}a^2-\omega^2, & |\omega|\leqslant a,\\ 0, & |\omega|>a;\end{cases}$

(3) $S_X(\omega)=\begin{cases}8\delta(\omega)+2a\left(1-\dfrac{|\omega|}{a}\right), & |\omega|\leqslant a,\\ 0, & |\omega|>a;\end{cases}$

(4) $S_X(\omega)=\dfrac{1}{\omega^4+5\omega^2+6}$；

(5) $S_X(\omega)=\dfrac{\omega^2+7}{\omega^4+5\omega^2+4}+4$;

(6) $S_X(\omega)=\begin{cases}\sigma^2, & a\leqslant|\omega|\leqslant 2a,\\ 0, & \text{其他.}\end{cases}$

19. 设$\{X(n),n=0,\pm1,\pm2,\cdots\}$是白噪声序列,$Y(n)=X(n)-\theta X(n-1)$,其中$\theta$为常数,证明$\{Y(n),n=0,\pm1,\pm2,\cdots\}$是平稳序列,并求其自相关函数与谱密度.

20. 设平稳序列$\{X(n),n=0,\pm1,\pm2,\cdots\}$具有谱密度$S_X(\omega)=\sigma^2[1+a_1^2+a_2^2+2(a_1a_2-a_1)\cos\omega-2a_2\cos 2\omega]$,$-\pi\leqslant\omega\leqslant\pi$,求其自相关函数.

21. 证明第 4 题中$X(t)$的谱密度为$S_X(\omega)=\pi f(\omega)$.

22. 求第 9 题中两个平稳过程的自谱密度和互谱密度.

23. 设随机变量$\Theta\sim U[0,2\pi]$,且与平稳过程$\{X(t),-\infty<t<+\infty\}$相互独立,$\omega_0$为常数,记$X(t)$的自相关函数为$R_X(\tau)$,谱密度为$S_X(\omega)$,令

$$Y(t)=X(t)\cos(\omega_0 t+\Theta),-\infty<t<+\infty$$

$$Z(t)=X(t)\sin(\omega_0 t+\Theta),-\infty<t<+\infty$$

证明:

(1) $Y(t)$和$Z(t)$都是平稳过程,且自相关函数为

$$R_Y(\tau)=R_Z(\tau)=\frac{1}{2}R_X(\tau)\cos(\omega_0\tau)$$

(2) $Y(t)$和$Z(t)$的自谱密度为

$$S_Y(\omega)=S_Z(\omega)=\frac{1}{4}[S_X(\omega+\omega_0)+S_X(\omega-\omega_0)]$$

(3) $Y(t)$和$Z(t)$是平稳相关的,且其互相关函数为

$$R_{YZ}(\tau)=-R_{ZY}(\tau)=\frac{1}{2}R_X(\tau)\sin(\omega_0\tau)$$

(4) $Y(t)$和$Z(t)$的互谱密度为

$$S_{YZ}(\omega)=-S_{ZY}(\omega)=\frac{\mathrm{i}}{4}[S_X(\omega+\omega_0)-S_X(\omega-\omega_0)]$$

24. 设平稳过程$\{X(t),-\infty<t<+\infty\}$和$\{Y(t),-\infty<t<+\infty\}$平稳相关,试证明:

$$\mathrm{Re}[S_{XY}(\omega)]=\mathrm{Re}[S_{YX}(\omega)],$$

$$\mathrm{Im}[S_{XY}(\omega)]=-\mathrm{Im}[S_{YX}(\omega)].$$

25. 设$\{X(t),-\infty<t<+\infty\}$和$\{Y(t),-\infty<t<+\infty\}$是两个不相关的平稳过程,均值$m_X$和$m_Y$都不为零,定义

$$Z(t)=X(t)+Y(t),-\infty<t<+\infty$$

(1) 证明$Z(t)$是平稳过程,并求其自相关函数和自谱密度;

(2) 求互相关函数$R_{XY}(\tau)$和$R_{XZ}(\tau)$;

(3) 求互谱密度$S_{XY}(\omega)$和$S_{XZ}(\omega)$.

26. 设第 14 题中各平稳过程的均值$m_X=0$,试判断他们是否具有数学期望的各态历经性.

27. 设ξ是一个随机变量,$X(t)\equiv\xi,-\infty<t<+\infty$,

(1) 如果ξ的二阶矩存在,证明$X(t)$具有数学期望的各态历经性的充要条件是$D(\xi)=0$;

(2) 如果ξ的四阶矩存在,证明$X(t)$具有相关函数的各态历经性的充要条件是$E(\xi^4)=(E\xi^2)^2$.

28. 判断第 16 题中的平稳过程$X(t)$是否具有数学期望的各态历经性,是否具有相关函数的各态历经性.

29. 设$\{X(t),-\infty<t<+\infty\}$是平稳过程,$a,b$是常数,且$a\neq0$,$Y(t)=aX(t)+b,-\infty<t<+\infty$,

(1) 证明 $Y(t)$ 具有数学期望的各态历经性的充要条件是 $X(t)$ 具有数学期望的各态历经性;

(2) 证明 $Y(t)$ 各态历经的充要条件是 $X(t)$ 各态历经.

30. 设有随机过程 $Z(t)=VX(t)Y(t)$, $-\infty<t<+\infty$, 其中平稳过程 $X(t)$ 和 $Y(t)$ 及随机变量 V 三者相互独立, 且 $m_X=0$, $m_Y=0$, $R_X(\tau)=2e^{-2|\tau|}\cos(\omega_0\tau)$ (ω_0 为常数), $R_Y(\tau)=9+e^{-3\tau^2}$, $E(V)=2$, $D(V)=9$,

(1) 证明 $Z(t)$ 是平稳过程, 并求其均值、方差和相关函数;

(2) 分别判断 $X(t)$, $Y(t)$, $Z(t)$ 是否具有数学期望的各态历经性.

自测题 12

习题 12 参考答案

附　表

附表1　标准正态分布表

$$\Phi(z)=\int_{-\infty}^{z}\frac{1}{\sqrt{2\pi}}e^{-u^2/2}du=P\{Z\leqslant z\}$$

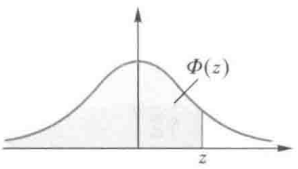

z	0	1	2	3	4	5	6	7	8	9
0.0	0.500 0	0.504 0	0.508 0	0.512 0	0.516 0	0.519 9	0.523 9	0.527 9	0.531 9	0.535 9
0.1	0.539 8	0.543 8	0.547 8	0.551 7	0.555 7	0.559 6	0.563 6	0.567 5	0.571 4	0.575 3
0.2	0.579 3	0.583 2	0.587 1	0.591 0	0.594 8	0.598 7	0.602 6	0.606 4	0.610 3	0.614 1
0.3	0.617 9	0.621 7	0.625 5	0.629 3	0.633 1	0.636 8	0.640 6	0.644 3	0.648 0	0.651 7
0.4	0.655 4	0.659 1	0.662 8	0.666 4	0.670 0	0.673 6	0.677 2	0.680 8	0.684 4	0.687 9
0.5	0.691 5	0.695 0	0.698 5	0.701 9	0.705 4	0.708 8	0.712 3	0.715 7	0.719 0	0.722 4
0.6	0.725 7	0.729 1	0.732 4	0.735 7	0.738 9	0.742 2	0.745 4	0.748 6	0.751 7	0.754 9
0.7	0.758 0	0.761 1	0.764 2	0.767 3	0.770 3	0.773 4	0.776 4	0.779 4	0.782 3	0.785 2
0.8	0.788 1	0.791 0	0.793 9	0.796 7	0.799 5	0.802 3	0.805 1	0.807 8	0.810 6	0.813 3
0.9	0.815 9	0.818 6	0.821 2	0.823 8	0.826 4	0.828 9	0.831 5	0.834 0	0.836 5	0.838 9
1.0	0.841 3	0.843 8	0.846 1	0.848 5	0.850 8	0.853 1	0.855 4	0.857 7	0.859 9	0.862 1
1.1	0.864 3	0.866 5	0.868 6	0.870 8	0.872 9	0.874 9	0.877 0	0.879 0	0.881 0	0.883 0
1.2	0.884 9	0.886 9	0.888 8	0.890 7	0.892 5	0.894 4	0.896 2	0.898 0	0.899 7	0.901 5
1.3	0.903 2	0.904 9	0.906 6	0.908 2	0.909 9	0.911 5	0.913 1	0.914 7	0.916 2	0.917 7
1.4	0.919 2	0.920 7	0.922 2	0.923 6	0.925 1	0.926 5	0.927 8	0.929 2	0.930 6	0.931 9
1.5	0.933 2	0.934 5	0.935 7	0.937 0	0.938 2	0.939 4	0.940 6	0.941 8	0.943 0	0.944 1
1.6	0.945 2	0.946 3	0.947 4	0.948 4	0.949 5	0.950 5	0.951 5	0.952 5	0.953 5	0.954 5
1.7	0.955 4	0.956 4	0.957 3	0.958 2	0.959 1	0.959 9	0.960 8	0.961 6	0.962 5	0.963 3
1.8	0.964 1	0.964 8	0.965 6	0.966 4	0.967 1	0.967 8	0.968 6	0.969 3	0.970 0	0.970 6
1.9	0.971 3	0.971 9	0.972 6	0.973 2	0.973 8	0.974 4	0.975 0	0.975 6	0.976 2	0.976 7
2.0	0.977 2	0.977 8	0.978 3	0.978 8	0.979 3	0.979 8	0.980 3	0.980 8	0.981 2	0.981 7
2.1	0.982 1	0.982 6	0.983 0	0.983 4	0.983 8	0.984 2	0.984 6	0.985 0	0.985 4	0.985 7
2.2	0.986 1	0.986 4	0.986 8	0.987 1	0.987 4	0.987 8	0.988 1	0.988 4	0.988 7	0.989 0
2.3	0.989 3	0.989 6	0.989 8	0.990 1	0.990 4	0.990 6	0.990 9	0.991 1	0.991 3	0.991 6

续表

z	0	1	2	3	4	5	6	7	8	9
2.4	0.991 8	0.992 0	0.992 2	0.992 5	0.992 7	0.992 9	0.993 1	0.993 2	0.993 4	0.993 6
2.5	0.993 8	0.994 0	0.994 1	0.994 3	0.994 5	0.994 6	0.994 8	0.994 9	0.995 1	0.995 2
2.6	0.995 3	0.995 5	0.995 6	0.995 7	0.995 9	0.996 0	0.996 1	0.996 2	0.996 3	0.996 4
2.7	0.996 5	0.996 6	0.996 7	0.996 8	0.996 9	0.997 0	0.997 1	0.997 2	0.997 3	0.997 4
2.8	0.997 4	0.997 5	0.997 6	0.997 7	0.997 7	0.997 8	0.997 9	0.997 9	0.998 0	0.998 1
2.9	0.998 1	0.998 2	0.998 2	0.998 3	0.998 4	0.998 4	0.998 5	0.998 5	0.998 6	0.998 6
3.0	0.998 7	0.999 0	0.999 3	0.999 5	0.999 7	0.999 8	0.999 8	0.999 9	0.999 9	1.000 0

注：表中末行系函数值 $\Phi(3.0)$，$\Phi(3.1)$，…，$\Phi(3.9)$

附表2 泊松分布表

$$1 - F(x-1) = \sum_{r=x}^{\infty} \frac{e^{-\lambda}\lambda^r}{r!}$$

x	$\lambda=0.2$	$\lambda=0.3$	$\lambda=0.4$	$\lambda=0.5$	$\lambda=0.6$
0	1.000 000 0	1.000 000 0	1.000 000 0	1.000 000	1.000 000
1	0.181 269 2	0.259 181 8	0.329 680 0	0.323 469	0.451 188
2	0.017 523 1	0.036 936 3	0.061 551 9	0.090 204	0.121 901
3	0.001 148 5	0.003 599 5	0.007 926 3	0.014 388	0.023 115
4	0.000 056 8	0.000 265 8	0.000 776 3	0.001 752	0.003 358
5	0.000 002 3	0.000 015 8	0.000 061 2	0.000 172	0.000 394
6	0.000 000 1	0.000 000 8	0.000 004 0	0.000 014	0.000 039
7	0.000 000 0	0.000 000 0	0.000 000 2	0.000 000	0.000 003
x	$\lambda=0.7$	$\lambda=0.8$	$\lambda=0.9$	$\lambda=1.0$	$\lambda=1.2$
0	1.000 000	1.000 000	1.000 000	1.000 000	1.000 000
1	0.503 415	0.550 671	0.593 430	0.632 121	0.698 806
2	0.155 805	0.191 208	0.227 518	0.264 241	0.337 373
3	0.034 142	0.047 423	0.062 857	0.080 301	0.120 513
4	0.005 753	0.009 080	0.013 459	0.018 988	0.033 769
5	0.000 786	0.001 411	0.002 344	0.003 660	0.007 746
6	0.000 090	0.000 184	0.000 343	0.000 594	0.001 500
7	0.000 009	0.000 021	0.000 043	0.000 083	0.000 251
8	0.000 001	0.000 002	0.000 005	0.000 010	0.000 037
9	0.000 000	0.000 000	0.000 000	0.000 001	0.000 005
10	0.000 000	0.000 000	0.000 000	0.000 000	0.000 001
x	$\lambda=1.4$	$\lambda=1.6$	$\lambda=1.8$	$\lambda=2.0$	$\lambda=2.2$
0	1.000 000	1.000 000	1.000 000	1.000 000	1.000 000
1	0.753 403	0.798 103	0.834 701	0.864 665	0.889 197
2	0.408 167	0.475 069	0.537 163	0.593 994	0.645 430
3	0.166 502	0.216 642	0.269 379	0.323 324	0.377 286
4	0.053 725	0.078 813	0.108 708	0.142 877	0.180 648
5	0.014 253	0.023 682	0.036 407	0.052 653	0.072 496
6	0.003 201	0.006 040	0.010 378	0.016 564	0.024 910
7	0.000 622	0.001 336	0.002 569	0.004 534	0.007 461
8	0.000 107	0.000 260	0.000 562	0.001 097	0.001 978
9	0.000 016	0.000 045	0.000 110	0.000 237	0.000 470
10	0.000 002	0.000 007	0.000 019	0.000 046	0.000 101
11	0.000 000	0.000 001	0.000 003	0.000 008	0.000 020

续表

x	$\lambda=2.5$	$\lambda=3.0$	$\lambda=3.5$	$\lambda=4.0$	$\lambda=4.5$	$\lambda=5.0$
0	1.000 000	1.000 000	1.000 000	1.000 000	1.000 000	1.000 000
1	0.917 915	0.950 213	0.969 803	0.981 684	0.988 891	0.993 262
2	0.712 703	0.800 852	0.864 112	0.908 422	0.938 901	0.959 572
3	0.456 187	0.576 810	0.679 153	0.761 897	0.826 422	0.875 348
4	0.242 424	0.352 768	0.463 367	0.566 530	0.657 704	0.734 974
5	0.108 822	0.184 737	0.274 555	0.371 163	0.467 896	0.559 507
6	0.042 021	0.083 918	0.142 386	0.214 870	0.297 070	0.384 039
7	0.014 187	0.033 509	0.065 288	0.110 674	0.168 949	0.237 817
8	0.004 247	0.011 905	0.026 739	0.051 134	0.086 586	0.133 372
9	0.001 140	0.003 803	0.009 874	0.021 363	0.040 257	0.068 094
10	0.000 277	0.001 102	0.003 315	0.008 132	0.017 093	0.031 828
11	0.000 062	0.000 292	0.001 019	0.002 840	0.006 669	0.013 695
12	0.000 013	0.000 071	0.000 289	0.000 915	0.002 404	0.005 453
13	0.000 002	0.000 016	0.000 076	0.000 274	0.000 805	0.002 019
14	0.000 000	0.000 003	0.000 019	0.000 076	0.000 252	0.000 698
15	0.000 000	0.000 001	0.000 004	0.000 020	0.000 074	0.000 226
16	0.000 000	0.000 000	0.000 001	0.000 005	0.000 020	0.000 069
17	0.000 000	0.000 000	0.000 000	0.000 001	0.000 005	0.000 020
18	0.000 000	0.000 000	0.000 000	0.000 000	0.000 001	0.000 005
19	0.000 000	0.000 000	0.000 000	0.000 000	0.000 000	0.000 001

附表3 t 分布表

$$P\{t(n)>t_\alpha(n)\}=\alpha$$

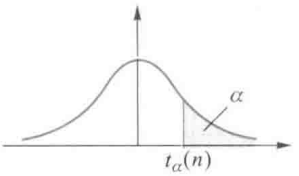

n	$\alpha=0.25$	0.10	0.05	0.025	0.01	0.005
1	1.000 0	3.077 7	6.313 8	12.706 2	31.820 7	63.657 4
2	0.816 5	1.885 6	2.920 0	4.302 7	6.964 6	9.924 8
3	0.764 9	1.637 7	2.353 4	3.182 4	4.540 7	5.840 9
4	0.740 7	1.533 2	2.131 8	2.776 4	3.746 9	4.604 1
5	0.726 7	1.475 9	2.015 0	2.570 6	3.364 9	4.032 2
6	0.717 6	1.439 8	1.943 2	2.446 9	3.142 7	3.707 4
7	0.711 1	1.414 9	1.894 6	2.364 6	2.998 0	3.499 5
8	0.706 4	1.396 8	1.859 5	2.306 0	2.896 5	3.355 4
9	0.702 7	1.383 0	1.833 1	2.262 2	2.821 4	3.249 8
10	0.699 8	1.372 2	1.812 5	2.228 1	2.763 8	3.169 3
11	0.697 4	1.363 4	1.795 9	2.201 0	2.718 1	3.105 8
12	0.695 5	1.356 2	1.782 3	2.178 8	2.681 0	3.054 5
13	0.693 8	1.350 2	1.770 9	2.160 4	2.650 3	3.012 3
14	0.692 4	1.345 0	1.761 3	2.144 8	2.624 5	2.976 8
15	0.691 2	1.340 6	1.753 1	2.131 5	2.602 5	2.946 7
16	0.690 1	1.336 8	1.745 9	2.119 9	2.583 5	2.920 8
17	0.689 2	1.333 4	1.739 6	2.109 8	2.566 9	2.898 2
18	0.688 4	1.330 4	1.734 1	2.100 9	2.552 4	2.878 4
19	0.687 6	1.327 7	1.729 1	2.093 0	2.539 5	2.860 9
20	0.687 0	1.325 3	1.724 7	2.086 0	2.528 0	2.845 3
21	0.686 4	1.323 2	1.720 7	2.079 6	2.517 7	2.831 4
22	0.685 8	1.321 2	1.717 1	2.073 9	2.508 3	2.818 8
23	0.685 3	1.319 5	1.713 9	2.068 7	2.499 9	2.807 3
24	0.684 8	1.317 8	1.710 9	2.063 9	2.492 2	2.796 9
25	0.684 4	1.316 3	1.708 1	2.059 5	2.485 1	2.787 4
26	0.684 0	1.315 0	1.705 6	2.055 5	2.478 6	2.778 7

续表

n	$\alpha=0.25$	0.10	0.05	0.025	0.01	0.005
27	0.683 7	1.313 7	1.703 3	2.051 8	2.472 7	2.770 7
28	0.683 4	1.312 5	1.701 1	2.048 4	2.467 1	2.763 3
29	0.683 0	1.311 4	1.699 1	2.045 2	2.462 0	2.756 4
30	0.682 8	1.310 4	1.697 3	2.042 3	2.457 3	2.750 0
31	0.682 5	1.309 5	1.695 5	2.039 5	2.452 8	2.744 0
32	0.682 2	1.308 6	1.693 9	2.036 9	2.448 7	2.738 5
33	0.682 0	1.307 7	1.692 4	2.034 5	2.444 8	2.733 3
34	0.681 8	1.307 0	1.690 9	2.032 2	2.441 1	2.728 4
35	0.681 6	1.306 2	1.689 6	2.030 1	2.437 7	2.723 8
36	0.681 4	1.305 5	1.688 3	2.028 1	2.434 5	2.719 5
37	0.681 2	1.304 9	1.687 1	2.026 2	2.431 4	2.715 4
38	0.681 0	1.304 2	1.686 0	2.024 4	2.428 6	2.711 6
39	0.680 8	1.303 6	1.684 9	2.022 7	2.425 8	2.707 9
40	0.680 7	1.303 1	1.683 9	2.021 1	2.423 3	2.704 5
41	0.680 5	1.302 5	1.682 9	2.019 5	2.420 8	2.701 2
42	0.680 4	1.302 0	1.682 0	2.018 1	2.418 5	2.698 1
43	0.680 2	1.301 6	1.681 1	2.016 7	2.416 3	2.695 1
44	0.680 1	1.301 1	1.680 2	2.015 4	2.414 1	2.692 3
45	0.680 0	1.300 6	1.679 4	2.014 1	2.412 1	3.689 6

附表4 X^2分布表

$P\{\chi^2(n) > \chi_\alpha^2(n)\} = \alpha$

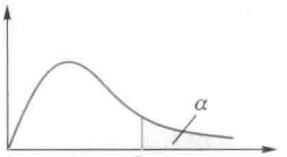

n	$\alpha=0.995$	0.99	0.975	0.95	0.90	0.75
1	—	—	0.001	0.004	0.016	0.102
2	0.010	0.020	0.051	0.103	0.211	0.575
3	0.072	0.115	0.216	0.352	0.584	1.213
4	0.207	0.297	0.484	0.711	1.064	1.923
5	0.412	0.554	0.831	1.145	1.610	2.675
6	0.676	0.872	1.237	1.635	2.204	3.455
7	0.989	1.239	1.690	2.167	2.833	4.255
8	1.344	1.646	2.180	2.733	3.490	5.071
9	1.735	2.088	2.700	3.325	4.168	5.899
10	2.156	2.558	3.247	3.940	4.865	6.737
11	2.603	3.053	3.816	4.575	5.578	7.584
12	3.074	3.571	4.404	5.226	6.304	8.438
13	3.565	4.107	5.009	5.892	7.042	9.299
14	4.075	4.660	5.629	6.571	7.790	10.165
15	4.601	5.229	6.262	7.261	8.547	11.037
16	5.142	5.812	6.908	7.962	9.312	11.912
17	5.697	6.408	7.564	8.672	10.085	12.792
18	6.265	7.015	8.231	9.390	10.865	13.675
19	6.844	7.633	8.907	10.117	11.651	14.562
20	7.434	8.260	9.591	10.851	12.443	15.452
21	8.034	8.897	10.283	11.591	13.240	16.344
22	8.643	9.542	10.982	12.388	14.042	17.240
23	9.260	10.196	11.689	13.091	14.848	18.137
24	9.886	10.856	12.401	13.848	15.659	19.037
25	10.520	11.524	13.120	14.611	16.473	19.939
26	11.160	12.198	13.844	15.379	17.292	20.843
27	11.808	12.879	14.573	16.151	18.114	21.749
28	12.461	13.565	15.308	16.928	18.939	22.657
29	13.121	14.257	16.047	17.708	19.768	23.567

续表

n	$\alpha=0.995$	0.99	0.975	0.95	0.90	0.75
30	13.787	14.954	16.791	18.493	20.599	24.478
31	14.458	15.655	17.539	19.281	21.434	25.390
32	15.134	16.362	18.291	20.072	22.271	26.304
33	15.815	17.074	19.047	20.867	23.110	27.219
34	16.501	17.789	19.806	21.664	23.952	28.136
35	17.192	18.509	20.569	22.465	24.797	29.054
36	17.887	19.233	21.336	23.269	25.643	29.973
37	18.586	19.960	22.106	24.075	26.492	30.893
38	19.289	20.691	22.878	24.884	27.343	31.815
39	19.996	21.426	23.654	25.695	28.196	32.737
40	20.707	22.164	24.433	26.509	29.051	33.660
41	21.421	22.906	25.215	27.326	29.907	34.585
42	22.138	23.650	25.999	28.144	30.765	35.510
43	22.859	24.398	26.785	28.965	31.625	36.436
44	23.584	25.148	27.575	29.787	32.487	37.363
45	24.311	25.901	28.366	30.612	33.350	38.291
n	$\alpha=0.25$	0.10	0.05	0.025	0.01	0.005
1	1.323	2.706	3.841	5.024	6.635	7.879
2	2.773	4.605	5.991	7.378	9.210	10.597
3	4.108	6.251	7.815	9.348	11.345	12.838
4	5.385	7.779	9.488	11.143	13.277	14.860
5	6.626	9.236	11.071	12.833	15.086	16.750
6	7.841	10.645	12.592	14.449	16.812	18.548
7	9.037	12.017	14.067	16.013	18.475	20.278
8	10.219	13.362	15.507	17.535	20.090	21.955
9	11.389	14.684	16.919	19.023	21.666	23.589
10	12.549	15.987	18.307	20.483	23.209	25.188
11	13.701	17.275	19.675	21.920	24.725	26.757
12	14.845	18.549	21.026	23.337	26.217	28.299
13	15.984	19.812	22.362	24.736	27.688	29.819
14	17.117	21.064	23.685	26.119	29.141	31.319
15	18.245	22.307	24.996	27.488	30.578	32.801
16	19.369	23.542	26.296	28.845	32.000	34.267
17	20.489	24.769	27.587	30.191	33.409	35.718

续表

n	$\alpha=0.25$	0.10	0.05	0.025	0.01	0.005
18	21.605	25.989	28.869	31.526	34.805	37.156
19	22.718	27.204	30.144	32.852	36.191	38.582
20	23.828	28.412	31.410	34.170	37.566	39.997
21	24.935	29.615	32.671	35.479	38.932	41.401
22	26.039	30.813	33.924	36.781	40.289	42.796
23	27.141	32.007	35.172	38.076	41.638	44.181
24	28.241	33.196	36.415	39.364	42.980	45.559
25	29.339	34.382	37.652	40.646	44.314	46.928
26	30.435	35.563	38.885	41.923	45.642	48.290
27	31.528	36.741	40.113	43.194	46.963	49.645
28	32.620	37.916	41.337	44.461	48.278	50.993
29	33.711	39.987	42.557	45.722	49.588	52.336
30	34.800	40.256	43.773	46.979	50.892	53.672
31	35.887	41.422	44.985	48.232	52.191	55.003
32	36.973	42.585	46.194	49.480	53.486	56.328
33	38.058	43.745	47.400	50.725	54.776	57.648
34	39.141	44.903	48.602	51.966	56.061	58.964
35	40.223	46.059	49.802	53.203	57.342	60.275
36	41.304	47.212	50.998	54.437	58.619	61.581
37	42.383	48.363	52.192	55.668	59.892	62.883
38	43.462	49.513	53.384	56.896	61.162	64.181
39	44.539	50.660	54.572	58.120	62.428	65.476
40	45.616	51.805	55.758	59.342	63.691	66.766
41	46.692	52.949	56.942	60.561	64.950	68.053
42	47.766	54.090	58.124	61.777	66.206	69.336
43	48.840	55.230	59.304	62.990	67.459	70.616
44	49.913	56.369	60.481	64.201	68.710	71.893
45	50.985	57.505	61.656	65.410	69.957	73.166

附表5　F 分布表

$$P\{F(n_1,n_2)>F_\alpha(n_1,n_2)\}=\alpha$$

$$\alpha=0.10$$

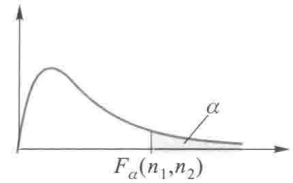

n_2	n_1																		
	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
1	39.86	49.50	53.59	55.83	57.24	58.20	58.91	59.44	59.86	60.19	60.71	61.22	61.74	62.00	62.26	62.53	62.79	63.06	63.33
2	8.53	9.00	9.16	9.24	9.29	9.33	9.35	9.37	9.38	9.39	9.41	9.42	9.44	9.45	9.46	9.47	9.47	9.48	9.49
3	5.54	5.46	5.39	5.34	5.31	5.28	5.27	5.25	5.24	5.23	5.22	5.20	5.18	5.18	5.17	5.16	5.15	5.14	5.13
4	4.54	4.32	4.19	4.11	4.05	4.01	3.98	3.95	3.94	3.92	3.90	3.87	3.84	3.83	3.82	3.80	3.79	3.78	3.76
5	4.06	3.78	3.62	3.52	3.45	3.40	3.37	3.34	3.32	3.30	3.27	3.24	3.21	3.19	3.17	3.16	3.14	3.12	3.10
6	3.78	3.46	3.29	3.18	3.11	3.05	3.01	2.98	2.96	2.94	2.90	2.87	2.84	2.82	2.80	2.78	2.76	2.74	2.72
7	3.59	3.26	3.07	2.96	2.88	2.83	2.78	2.75	2.72	2.70	2.67	2.63	2.59	2.58	2.56	2.54	2.51	2.49	2.47
8	3.46	3.11	2.92	2.81	2.73	2.67	2.62	2.59	2.56	2.54	2.50	2.46	2.42	2.40	2.38	2.36	2.34	2.32	2.29
9	3.36	3.01	2.81	2.69	2.61	2.55	2.51	2.47	2.44	2.42	2.38	2.34	2.30	2.28	2.25	2.23	2.21	2.18	2.16
10	3.29	2.92	2.73	2.61	2.52	2.46	2.41	2.38	2.35	2.32	2.28	2.24	2.20	2.18	2.16	2.13	2.11	2.08	2.06
11	3.23	2.86	2.66	2.54	2.45	2.39	2.34	2.30	2.27	2.25	2.21	2.17	2.12	2.10	2.08	2.05	2.03	2.00	1.97
12	3.18	2.81	2.61	2.48	2.39	2.33	2.28	2.24	2.21	2.19	2.15	2.10	2.06	2.04	2.01	1.99	1.96	1.93	1.90

续表

n_2	n_1																		
	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
13	3.14	2.76	2.56	2.43	2.35	2.28	2.23	2.20	2.16	2.14	2.10	2.05	2.01	1.98	1.96	1.93	1.90	1.88	1.85
14	3.10	2.73	2.52	2.39	2.31	2.24	2.19	2.15	2.12	2.10	2.05	2.01	1.96	1.94	1.91	1.89	1.86	1.83	1.80
15	3.07	2.70	2.49	2.36	2.27	2.21	2.16	2.12	2.09	2.06	2.02	1.97	1.92	1.90	1.87	1.85	1.82	1.79	1.76
16	3.05	2.67	2.46	2.33	2.24	2.18	2.13	2.09	2.06	2.03	1.99	1.94	1.89	1.87	1.84	1.81	1.78	1.75	1.72
17	3.03	2.64	2.44	2.31	2.22	2.15	2.10	2.06	2.03	2.00	1.96	1.91	1.86	1.84	1.81	1.78	1.75	1.72	1.69
18	3.01	2.62	2.42	2.29	2.20	2.13	2.08	2.04	2.00	1.98	1.93	1.89	1.84	1.81	1.78	1.75	1.72	1.69	1.66
19	2.99	2.61	2.40	2.27	2.18	2.11	2.06	2.02	1.98	1.96	1.91	1.86	1.81	1.79	1.76	1.73	1.70	1.67	1.63
20	2.97	2.59	2.38	2.25	2.16	2.09	2.04	2.00	1.96	1.94	1.89	1.84	1.79	1.77	1.74	1.71	1.68	1.64	1.61
21	2.96	2.57	2.36	2.23	2.14	2.08	2.02	1.98	1.95	1.92	1.87	1.83	1.78	1.75	1.72	1.69	1.66	1.62	1.59
22	2.95	2.56	2.35	2.22	2.13	2.06	2.01	1.97	1.93	1.90	1.86	1.81	1.76	1.73	1.70	1.67	1.64	1.60	1.57
23	2.94	2.55	2.34	2.21	2.11	2.05	1.99	1.95	1.92	1.89	1.84	1.80	1.74	1.72	1.69	1.66	1.62	1.59	1.55
24	2.93	2.54	2.33	2.19	2.10	2.04	1.98	1.94	1.91	1.88	1.83	1.78	1.73	1.70	1.67	1.64	1.61	1.57	1.53
25	2.92	2.53	2.32	2.18	2.09	2.02	1.97	1.93	1.89	1.87	1.82	1.77	1.72	1.69	1.66	1.63	1.59	1.56	1.52
26	2.91	2.52	2.31	2.17	2.08	2.01	1.96	1.92	1.88	1.86	1.81	1.76	1.71	1.68	1.65	1.61	1.58	1.54	1.50
27	2.90	2.51	2.30	2.17	2.07	2.00	1.95	1.91	1.87	1.85	1.80	1.75	1.70	1.67	1.64	1.60	1.57	1.53	1.49
28	2.89	2.50	2.29	2.16	2.06	2.00	1.94	1.90	1.87	1.84	1.79	1.74	1.69	1.66	1.63	1.59	1.56	1.52	1.48
29	2.89	2.50	2.28	2.15	2.06	1.99	1.93	1.89	1.86	1.83	1.78	1.73	1.68	1.65	1.62	1.58	1.55	1.51	1.47
30	2.88	2.49	2.28	2.14	2.05	1.98	1.93	1.88	1.85	1.82	1.77	1.72	1.67	1.64	1.61	1.57	1.54	1.50	1.46

续表

n_2	n_1																	
	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
40	2.84	2.44	2.23	2.09	2.00	1.93	1.87	1.83	1.79	1.76	1.71	1.66	1.61	1.57	1.54	1.51	1.47	1.42	1.38
60	2.79	2.39	2.18	2.04	1.95	1.87	1.82	1.77	1.74	1.71	1.66	1.60	1.54	1.51	1.48	1.44	1.40	1.35	1.29
120	2.75	2.35	2.13	1.99	1.90	1.82	1.77	1.72	1.68	1.65	1.60	1.55	1.48	1.45	1.41	1.37	1.32	1.26	1.19
∞	2.71	2.30	2.08	1.94	1.85	1.77	1.72	1.67	1.63	1.60	1.55	1.49	1.42	1.38	1.34	1.30	1.24	1.17	1.00

$\alpha = 0.05$

n_2	n_1																	
	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
1	161.4	199.5	215.7	224.6	230.2	234.0	236.8	238.9	240.5	241.9	243.9	245.9	248.0	249.1	250.1	251.1	252.2	253.3	254.3
2	18.51	19.00	19.16	19.25	19.30	19.33	19.35	19.37	19.38	19.40	19.41	19.43	19.45	19.45	19.46	19.47	19.48	19.49	19.50
3	10.13	9.55	9.28	9.12	9.01	8.94	8.89	8.85	8.81	8.79	8.74	8.70	8.66	8.64	8.62	8.59	8.57	8.55	8.53
4	7.71	6.94	6.59	6.39	6.26	6.16	6.09	6.04	6.00	5.96	5.91	5.86	5.80	5.77	5.75	5.72	5.69	5.66	5.63
5	6.61	5.79	5.41	5.19	5.05	4.95	4.88	4.82	4.77	4.74	4.68	4.62	4.56	4.53	4.50	4.46	4.43	4.40	4.36
6	5.99	5.14	4.76	4.53	4.39	4.28	4.21	4.15	4.10	4.06	4.00	3.94	3.87	3.84	3.81	3.77	3.74	3.70	3.67
7	5.59	4.74	4.35	4.12	3.97	3.87	3.79	3.73	3.68	3.64	3.57	3.51	3.44	3.41	3.38	3.34	3.30	3.27	3.23
8	5.32	4.46	4.07	3.84	3.69	3.58	3.50	3.44	3.39	3.35	3.28	3.22	3.15	3.12	3.08	3.04	3.01	2.97	2.93
9	5.12	4.26	3.86	3.63	3.48	3.37	3.29	3.23	3.18	3.14	3.07	3.01	2.94	2.90	2.86	2.83	2.79	2.75	2.71
10	4.96	4.10	3.71	3.48	3.33	3.22	3.14	3.07	3.02	2.98	2.91	2.85	2.77	2.74	2.70	2.66	2.62	2.58	2.54
11	4.84	3.98	3.59	3.36	3.20	3.09	3.01	2.95	2.90	2.85	2.79	2.72	2.65	2.61	2.57	2.53	2.49	2.45	2.40

续表

n_2	n_1																		
	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
12	4.75	3.89	3.49	3.26	3.11	3.00	2.91	2.85	2.80	2.75	2.69	2.62	2.54	2.51	2.47	2.43	2.38	2.34	2.30
13	4.67	3.81	3.41	3.18	3.03	2.92	2.83	2.77	2.71	2.67	2.60	2.53	2.46	2.42	2.38	2.34	2.30	2.25	2.21
14	4.60	3.74	3.34	3.11	2.96	2.85	2.76	2.70	2.65	2.60	2.53	2.46	2.39	2.35	2.31	2.27	2.22	2.18	2.13
15	4.54	3.68	3.29	3.06	2.90	2.79	2.71	2.64	2.59	2.54	2.48	2.40	2.33	2.29	2.25	2.20	2.16	2.11	2.07
16	4.49	3.63	3.24	3.01	2.85	2.74	2.66	2.59	2.54	2.49	2.42	2.35	2.28	2.24	2.19	2.15	2.11	2.06	2.01
17	4.45	3.59	3.20	2.96	2.81	2.70	2.61	2.55	2.49	2.45	2.38	2.31	2.23	2.19	2.15	2.10	2.06	2.01	1.96
18	4.41	3.55	3.16	2.93	2.77	2.66	2.58	2.51	2.46	2.41	2.34	2.27	2.19	2.15	2.11	2.06	2.02	1.97	1.92
19	4.38	3.52	3.13	2.90	2.74	2.63	2.54	2.48	2.42	2.38	2.31	2.23	2.16	2.11	2.07	2.03	1.98	1.93	1.88
20	4.35	3.49	3.10	2.87	2.71	2.60	2.51	2.45	2.39	2.35	2.28	2.20	2.12	2.08	2.04	1.99	1.95	1.90	1.84
21	4.32	3.47	3.07	2.84	2.68	2.57	2.49	2.42	2.37	2.32	2.25	2.18	2.10	2.05	2.01	1.96	1.92	1.87	1.81
22	4.30	3.44	3.05	2.82	2.66	2.55	2.46	2.40	2.34	2.30	2.23	2.15	2.07	2.03	1.98	1.94	1.89	1.84	1.78
23	4.28	3.42	3.03	2.80	2.64	2.53	2.44	2.37	2.32	2.27	2.20	2.13	2.05	2.01	1.96	1.91	1.86	1.81	1.76
24	4.26	3.40	3.01	2.78	2.62	2.51	2.42	2.36	2.30	2.25	2.18	2.11	2.03	1.98	1.94	1.89	1.84	1.79	1.73
25	4.24	3.39	2.99	2.76	2.60	2.49	2.40	2.34	2.28	2.24	2.16	2.09	2.01	1.96	1.92	1.87	1.82	1.77	1.71
26	4.23	3.37	2.98	2.74	2.59	2.47	2.39	2.32	2.27	2.22	2.15	2.07	1.99	1.95	1.90	1.85	1.80	1.75	1.69
27	4.21	3.35	2.96	2.73	2.57	2.46	2.37	2.31	2.25	2.20	2.13	2.06	1.97	1.93	1.88	1.84	1.79	1.73	1.67
28	4.20	3.34	2.95	2.71	2.56	2.45	2.36	2.29	2.24	2.19	2.12	2.04	1.96	1.91	1.87	1.82	1.77	1.71	1.65
29	4.18	3.33	2.93	2.70	2.55	2.43	2.35	2.28	2.22	2.18	2.10	2.03	1.94	1.90	1.85	1.81	1.75	1.70	1.64

n_2	n_1																		
	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
30	4.17	3.32	2.92	2.69	2.53	2.42	2.33	2.27	2.21	2.16	2.09	2.01	1.93	1.89	1.84	1.79	1.74	1.68	1.62
40	4.08	3.23	2.84	2.61	2.45	2.34	2.25	2.18	2.12	2.08	2.00	1.92	1.84	1.79	1.74	1.69	1.64	1.58	1.51
60	4.00	3.15	2.76	2.53	2.37	2.25	2.17	2.10	2.04	1.99	1.92	1.84	1.75	1.70	1.65	1.59	1.53	1.47	1.39
120	3.92	3.07	2.68	2.45	2.29	2.17	2.09	2.02	1.96	1.91	1.83	1.75	1.66	1.61	1.55	1.50	1.43	1.35	1.25
∞	3.84	3.00	2.60	2.37	2.21	2.10	2.01	1.94	1.88	1.83	1.75	1.67	1.57	1.52	1.46	1.39	1.32	1.22	1.00

$\alpha = 0.025$

n_2	n_1																		
	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
1	647.8	799.5	664.2	899.6	921.8	937.1	948.2	956.7	963.3	368.6	976.7	984.9	993.1	997.2	1 001	1 006	1 010	1 014	1 018
2	38.51	39.00	39.17	39.25	39.30	39.33	39.36	39.37	39.39	39.40	39.41	39.43	39.45	39.46	39.46	39.47	39.48	39.49	39.50
3	17.44	16.04	15.44	15.10	14.88	14.73	14.62	14.54	14.47	14.42	14.34	14.25	14.17	14.12	14.08	14.04	13.99	13.95	13.90
4	12.22	10.65	9.98	9.60	9.36	9.20	9.07	8.98	8.90	8.84	8.75	8.66	8.56	8.51	8.46	8.41	8.36	8.31	8.26
5	10.01	8.43	7.76	7.39	7.15	6.98	6.85	6.76	6.68	6.62	6.52	6.43	6.33	6.28	6.23	6.18	6.12	6.07	6.02
6	8.81	7.26	6.60	6.23	5.99	5.82	5.70	5.60	5.52	5.46	5.37	5.27	5.17	5.12	5.07	5.01	4.96	4.90	4.85
7	8.07	6.54	5.89	5.52	5.29	5.12	4.99	4.90	4.82	4.76	4.67	4.57	4.47	4.42	4.36	4.31	4.25	4.20	4.14
8	7.58	6.06	5.42	5.05	4.82	4.65	4.53	4.43	4.36	4.30	4.20	4.10	4.00	3.95	3.89	3.84	3.78	3.73	3.67
9	7.21	5.71	5.08	4.72	4.48	4.23	4.20	4.10	4.03	3.96	3.87	3.77	3.67	3.61	3.56	3.51	3.45	3.39	3.33
10	6.94	5.46	4.83	4.47	4.24	4.07	3.95	3.85	3.78	3.72	3.62	3.52	3.42	3.37	3.31	3.26	3.20	3.14	3.08

续表

n_2	n_1																		
	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
11	6.72	5.26	4.63	4.28	4.04	3.88	3.76	3.66	3.59	3.53	3.43	3.33	3.23	3.17	3.12	3.06	3.00	2.94	2.88
12	6.55	5.10	4.47	4.12	3.89	3.73	3.61	3.51	3.44	3.37	3.28	3.18	3.07	3.02	2.96	2.91	2.85	2.79	2.72
13	6.41	4.97	4.35	4.00	3.77	3.60	3.48	3.39	3.31	3.25	3.15	3.05	2.95	2.89	2.84	2.78	2.72	2.66	2.60
14	6.30	4.86	4.24	3.89	3.66	3.50	3.38	3.29	3.21	3.15	3.05	2.95	2.84	2.79	2.73	2.67	2.61	2.55	2.49
15	6.20	4.77	4.15	3.80	3.58	3.41	3.29	3.20	3.12	3.06	2.96	2.86	2.76	2.70	2.64	2.59	2.52	2.46	2.40
16	6.12	4.69	4.08	3.73	3.50	3.34	3.22	3.12	3.05	2.99	2.89	2.79	2.68	2.63	2.57	2.51	2.45	2.38	2.32
17	3.04	4.62	4.01	3.66	3.44	3.28	3.16	3.06	2.98	2.92	2.82	2.72	2.62	2.56	2.50	2.44	2.38	2.32	2.25
18	5.98	4.56	3.95	3.61	3.38	3.22	3.10	3.01	2.93	2.87	2.77	2.67	2.56	2.50	2.44	2.38	2.32	2.26	2.19
19	5.92	4.51	3.90	3.56	3.33	3.17	3.05	2.96	2.88	2.82	2.72	2.62	2.51	2.45	2.39	2.33	2.27	2.20	2.13
20	5.87	4.46	3.86	3.51	3.29	3.13	3.01	2.91	2.84	2.77	2.68	2.57	2.46	2.41	2.35	2.29	2.22	2.16	2.09
21	5.83	4.42	3.82	3.48	3.25	3.09	2.97	2.87	2.80	2.73	2.64	2.53	2.42	2.37	2.31	2.25	2.18	2.11	2.04
22	5.79	4.38	3.78	3.44	3.22	3.05	2.93	2.84	2.76	2.70	2.60	2.50	2.39	2.32	2.27	2.21	2.14	2.08	2.00
23	5.75	4.35	3.75	3.41	3.18	3.02	2.90	2.81	2.73	2.67	2.57	2.47	2.36	2.31	2.24	2.18	2.11	2.04	1.97
24	5.72	4.32	3.72	3.38	3.15	2.99	2.87	2.78	2.70	2.64	2.54	2.44	2.33	2.27	2.21	2.15	2.08	2.01	1.94
25	5.69	4.29	3.60	3.35	3.13	2.97	2.85	2.75	2.68	2.61	2.51	2.41	2.30	2.24	2.18	2.12	2.05	1.98	1.91
26	5.66	4.27	3.67	3.33	3.10	2.94	2.82	2.73	2.65	2.59	2.49	2.39	2.28	2.22	2.16	2.09	2.03	1.95	1.88
27	5.63	4.24	3.65	3.31	3.08	2.92	2.80	2.71	2.63	2.57	2.47	2.36	2.25	2.19	2.13	2.07	2.00	1.93	1.85
28	5.61	4.33	3.63	3.29	3.06	2.90	2.78	2.69	2.61	2.55	2.45	2.34	2.23	2.17	2.11	2.05	1.98	1.91	1.83

n_2	n_1																		
	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
29	5.59	4.20	3.61	3.27	3.04	2.88	2.76	2.67	2.59	2.53	2.43	2.32	2.21	2.15	2.09	2.03	1.96	1.89	1.81
30	5.57	4.18	3.59	3.25	3.03	2.87	2.75	2.65	2.57	2.51	2.41	2.31	2.20	2.14	2.07	2.01	1.94	1.87	1.79
40	5.42	4.05	3.46	3.13	2.90	2.74	2.62	2.53	2.45	2.39	2.29	2.18	2.07	2.01	1.94	1.88	1.80	1.72	1.64
60	5.29	3.93	3.34	3.01	2.79	2.63	2.51	2.41	2.33	2.27	2.17	2.06	1.94	1.88	1.82	2.74	1.64	1.58	1.48
120	5.15	3.80	3.23	2.89	2.67	2.52	2.39	2.30	2.22	2.16	2.05	1.94	1.82	1.76	1.69	1.61	2.53	1.43	1.31
∞	5.02	3.69	3.12	2.79	2.57	2.41	2.29	2.19	2.11	2.05	1.94	1.83	1.71	1.64	1.57	1.48	1.39	1.27	1.00

$\alpha = 0.01$

n_2	n_1																		
	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
1	4 052	4 999.5	5 403	5 625	5 764	5 859	5 928	5 982	6 022	6 056	6 106	6 157	6 209	6 235	6 261	6 287	6 313	6 339	6 366
2	98.50	99.00	99.17	99.25	99.30	99.33	99.36	99.37	99.39	99.40	99.42	99.43	99.45	99.46	99.47	99.47	99.48	99.49	99.50
3	34.12	30.82	29.46	28.71	28.24	27.91	27.67	27.49	27.35	27.23	27.05	26.87	26.69	26.60	26.50	26.41	26.32	26.22	26.13
4	21.20	18.00	16.69	15.98	15.52	15.21	14.98	14.80	14.66	14.55	14.37	14.20	14.02	13.93	13.84	13.75	13.65	13.56	13.46
5	16.26	13.27	12.06	11.39	10.97	10.67	10.46	10.29	10.16	10.05	9.89	9.72	9.55	9.47	9.38	9.29	9.20	9.11	9.02
6	13.75	10.92	9.78	9.15	8.75	8.47	8.26	8.10	7.98	7.87	7.72	7.56	7.40	7.31	7.23	7.14	7.06	6.97	6.88
7	12.25	9.55	8.45	7.85	7.46	7.19	6.99	6.84	6.72	6.62	6.47	6.31	6.16	6.07	5.99	5.91	5.82	5.74	5.65
8	11.26	8.65	7.59	7.01	6.63	6.37	6.18	6.03	5.91	5.81	5.67	5.52	5.36	5.28	5.20	5.12	5.03	4.95	4.86
9	10.56	8.02	6.99	6.42	6.06	5.80	5.61	5.47	5.35	5.26	5.11	4.96	4.81	4.73	4.65	4.57	4.48	4.40	4.31

续表

n_2	n_1																		
	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
10	10.04	7.56	6.55	5.99	5.64	5.39	5.20	5.06	4.94	4.85	4.71	4.56	4.41	4.33	4.25	4.17	4.08	4.00	3.91
11	9.65	7.21	6.22	5.67	5.32	5.07	4.89	4.74	4.63	4.54	4.40	4.25	4.10	4.02	3.94	3.86	3.78	3.69	3.60
12	9.33	6.93	5.95	5.41	5.06	4.82	4.64	4.50	4.39	4.30	4.16	4.01	3.86	3.78	3.70	3.62	3.54	3.45	3.36
13	9.07	6.70	5.74	5.21	4.86	4.62	4.44	4.30	4.19	4.10	3.96	3.82	3.66	3.59	3.51	3.43	3.34	3.25	3.17
14	8.86	6.51	5.56	5.04	4.69	4.46	4.28	4.14	4.03	3.94	3.80	3.66	3.51	3.43	3.35	3.27	3.18	3.09	3.00
15	8.68	6.36	5.42	4.89	4.56	4.32	4.14	4.00	3.89	3.80	3.67	3.52	3.37	3.29	3.21	3.13	3.05	2.96	2.87
16	8.53	6.23	5.29	4.77	4.44	4.20	4.03	3.89	3.78	3.69	3.55	3.41	3.26	3.18	3.10	3.02	2.93	2.84	2.75
17	8.40	6.11	5.18	4.67	4.34	4.10	3.93	3.79	3.68	3.59	3.46	3.31	3.16	3.08	3.00	2.92	2.83	2.75	2.65
18	8.29	6.01	5.09	4.58	4.25	4.01	3.84	3.71	3.60	3.51	3.37	3.23	3.08	3.00	2.92	2.84	2.75	2.66	2.57
19	8.18	5.93	5.01	4.50	4.17	3.94	3.77	3.63	3.52	3.43	3.30	3.15	3.00	2.92	2.84	2.76	2.67	2.58	2.49
20	8.10	5.85	4.94	4.43	4.10	3.87	3.70	3.56	3.46	3.37	3.23	3.09	2.94	2.86	2.78	2.69	2.61	2.52	2.42
21	8.02	5.78	4.87	4.37	4.04	3.81	3.64	3.51	3.40	3.31	3.17	3.03	2.88	2.80	2.72	2.64	2.55	2.46	2.36
22	7.95	5.72	4.82	4.31	3.99	3.76	3.59	3.45	3.35	3.26	3.12	2.98	2.83	2.75	2.67	2.58	2.50	2.40	2.31
23	7.88	5.66	4.76	4.26	3.94	3.71	3.54	3.41	3.30	3.21	3.07	2.93	2.78	2.70	2.62	2.54	2.45	2.35	2.26
24	7.82	5.61	4.72	4.22	3.90	3.67	3.50	3.36	3.26	3.17	3.03	2.89	2.74	2.66	2.58	2.49	2.40	2.31	2.21
25	7.77	5.57	4.68	4.18	3.85	3.63	3.46	3.32	3.22	3.13	2.99	2.85	2.70	2.62	2.54	2.45	2.36	2.27	2.17
26	7.72	5.53	4.64	4.14	3.82	3.59	3.42	3.29	3.18	3.09	2.96	2.81	2.66	2.58	2.50	2.42	2.33	2.23	2.13
27	7.68	5.49	4.60	4.11	3.78	3.56	3.39	3.26	3.15	3.06	2.93	2.78	2.63	2.55	2.47	2.38	2.29	2.20	2.10
28	7.64	5.45	4.57	4.07	3.75	3.53	3.36	3.23	3.12	3.03	2.90	2.75	2.60	2.52	2.44	2.35	2.26	2.17	2.06
29	7.60	5.42	4.54	4.04	3.73	3.50	3.33	3.20	3.09	3.00	2.87	2.73	2.57	2.49	2.41	2.33	2.23	2.14	2.03

n_2	n_1																		
	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
30	7.56	5.39	4.51	4.02	3.70	3.47	3.30	3.17	3.07	2.98	2.84	2.70	2.55	2.47	2.39	2.30	2.21	2.11	2.01
40	7.31	5.18	4.31	3.83	3.51	3.29	3.12	2.99	2.89	2.80	2.66	2.52	2.37	2.29	2.20	2.11	2.02	1.92	1.80
60	7.08	4.98	4.13	3.65	3.34	3.12	2.95	2.82	2.72	2.63	2.50	2.35	2.20	2.12	2.03	1.94	1.84	1.73	1.60
120	6.85	4.79	3.95	3.48	3.17	2.96	2.79	2.66	2.56	2.47	2.34	2.19	2.03	1.95	1.86	1.76	1.66	1.53	1.38
∞	6.63	4.61	3.78	3.32	3.02	2.80	2.64	2.51	2.41	2.32	2.18	2.04	1.88	1.79	1.70	1.59	1.47	1.32	1.00

$\alpha = 0.005$

n_2	n_1																		
	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
1	16 211	20 000	21 615	22 500	23 056	23 487	23 715	23 925	24 091	24 224	24 426	24 630	24 836	24 940	25 044	25 148	25 253	25 359	25 465
2	198.5	199.0	199.2	199.2	199.3	199.3	199.4	199.4	199.4	199.4	199.4	199.4	199.4	199.5	199.5	199.5	199.5	199.5	199.5
3	55.55	49.80	47.47	46.19	45.39	44.84	44.43	44.13	43.88	43.69	43.39	43.08	42.78	42.62	42.47	42.31	42.15	41.99	41.83
4	31.33	26.28	24.26	23.15	22.46	21.97	21.62	21.35	21.14	20.97	20.70	20.44	20.17	20.03	19.89	19.75	19.61	19.47	19.32
5	22.78	18.31	16.53	15.56	14.94	14.51	14.20	13.96	13.77	13.62	13.38	13.15	12.90	12.78	12.66	12.53	12.40	12.27	12.14
6	18.63	14.54	12.92	12.03	11.46	11.07	10.79	10.57	10.39	10.25	10.03	9.81	9.59	9.47	9.36	9.24	9.12	9.00	8.88
7	16.24	12.40	10.88	10.05	9.52	9.16	8.89	8.68	8.51	8.38	8.18	7.97	7.75	7.65	7.53	7.42	7.31	7.19	7.08
8	14.69	11.04	9.60	8.81	8.30	7.95	7.69	7.50	7.34	7.21	7.01	6.81	6.61	6.50	6.40	6.29	6.18	6.06	5.95
9	13.61	10.11	8.72	7.96	7.47	7.13	6.88	6.69	6.54	6.42	6.23	6.03	5.83	5.73	5.62	5.52	5.41	5.30	5.19
10	12.83	9.43	8.08	7.34	6.87	6.54	6.30	6.12	5.97	5.85	5.66	5.47	5.27	5.17	5.07	4.97	4.86	4.75	4.64
11	12.23	8.91	7.60	6.88	6.42	6.10	5.86	5.68	5.54	5.42	5.24	5.05	4.86	4.76	4.65	4.55	4.44	4.34	4.23
12	11.75	8.51	7.23	6.52	6.07	5.76	5.52	5.35	5.20	5.09	4.91	4.72	4.53	4.43	4.33	4.23	4.12	4.01	3.90

续表

n_2	n_1																		
	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
13	11.37	8.19	6.93	6.23	5.79	5.48	5.25	5.08	4.94	4.82	4.64	4.46	4.27	4.17	4.07	3.97	3.87	3.76	3.65
14	11.06	7.92	6.68	6.00	5.56	5.26	5.03	4.86	4.72	4.60	4.43	4.25	4.06	3.96	3.86	3.76	3.66	3.55	3.44
15	10.80	7.70	6.48	5.80	5.37	5.07	4.85	4.67	4.54	4.42	4.25	4.07	3.88	3.79	3.69	3.58	3.48	3.37	3.26
16	10.58	7.51	6.30	5.64	5.21	4.91	4.69	4.52	4.38	4.27	4.10	3.92	3.73	3.64	3.54	3.44	3.33	3.22	3.11
17	10.38	7.35	6.16	5.50	5.07	4.78	4.56	4.39	4.25	4.14	3.97	3.79	3.61	3.51	3.41	3.31	3.21	3.10	2.98
18	10.22	7.21	6.03	5.37	4.96	4.66	4.44	4.23	4.14	4.03	3.86	3.68	3.50	3.40	3.30	3.20	3.10	2.99	2.87
19	10.07	7.09	5.92	5.27	4.85	4.56	4.34	4.18	4.04	3.93	3.76	3.59	3.40	3.31	3.21	3.11	3.00	2.89	2.78
20	9.94	6.99	5.82	5.17	4.76	4.47	4.26	4.09	3.96	3.85	3.68	3.50	3.32	3.22	3.12	3.02	2.92	2.81	2.69
21	9.83	6.89	5.73	5.09	4.68	4.39	4.18	4.01	3.88	3.77	3.60	3.43	3.24	3.15	3.05	2.95	2.84	2.73	2.61
22	9.73	6.81	5.65	5.02	4.61	4.32	4.11	3.94	3.81	3.70	3.54	3.36	3.18	3.08	2.98	2.88	2.77	2.66	2.55
23	9.63	6.73	5.58	4.95	4.54	4.26	4.05	3.88	3.75	3.64	3.47	3.30	3.12	3.02	2.92	2.82	2.71	2.60	2.48
24	9.55	6.66	5.52	4.89	4.49	4.20	3.99	3.83	3.69	3.59	3.42	3.25	3.06	2.97	2.87	2.77	2.66	2.55	2.43
25	9.48	6.60	5.46	4.84	4.43	4.15	3.94	3.78	3.64	3.54	3.37	3.20	3.01	2.92	2.82	2.72	2.61	2.50	2.38
26	9.41	6.54	5.41	4.79	4.38	4.10	3.89	3.73	3.60	3.49	3.33	3.15	2.97	2.87	2.77	2.67	2.56	2.45	2.33
27	9.34	6.49	5.36	4.74	4.34	4.06	3.85	3.69	3.56	3.45	3.28	3.11	2.93	2.83	2.73	2.63	2.52	2.41	2.29
28	9.28	6.44	5.32	4.70	4.30	4.02	3.81	3.65	3.52	3.41	3.25	3.07	2.89	2.79	2.69	2.59	2.48	2.37	2.25
29	9.23	6.40	5.28	4.66	4.26	3.98	3.77	3.61	3.48	3.38	3.21	3.04	2.86	2.76	2.66	2.56	2.45	2.33	2.21
30	9.18	6.35	5.24	4.62	4.23	3.95	3.74	3.58	3.45	3.34	3.18	3.01	2.82	2.73	2.63	2.52	2.42	2.30	2.18
40	8.83	6.07	4.98	4.37	3.99	3.71	3.51	3.35	3.22	3.12	2.95	2.78	2.60	2.50	2.40	2.30	2.18	2.06	1.93

n_2	n_1																	
	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
60	8.49	5.79	4.73	4.14	3.76	3.49	3.29	3.13	3.01	2.90	2.74	2.57	2.39	2.29	2.19	2.08	1.96	1.83	1.69
120	8.18	5.54	4.50	3.92	3.55	3.28	3.09	2.93	2.81	2.71	2.54	2.37	2.19	2.09	1.98	1.87	1.75	1.61	1.43
∞	7.88	5.30	4.28	3.72	3.35	3.09	2.90	2.74	2.62	2.52	2.36	2.19	2.00	1.90	1.79	1.67	1.53	1.36	1.00

$\alpha = 0.001$

n_2	n_1																	
	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
1	4 053†	5 000†	5 404†	5 625†	5 764†	5 859†	5 929†	5 981†	6 023†	6 056†	6 107†	6 158†	6 209†	6 235†	6 261†	6 287†	6 313†	6 340†	6 366†
2	998.5	999.0	999.2	999.2	999.3	999.3	999.4	999.4	999.4	999.4	999.4	999.4	999.4	999.5	999.5	999.5	999.5	999.5	999.5
3	167.0	148.5	141.1	137.1	134.6	132.8	131.6	130.6	129.9	129.2	128.3	127.4	126.4	125.9	125.4	125.0	124.5	124.0	123.5
4	74.14	61.25	56.18	53.44	51.71	50.53	49.66	49.00	48.47	48.05	47.41	46.76	46.10	45.77	45.43	45.09	44.75	44.40	44.05
5	47.18	37.12	33.20	31.09	29.75	28.84	28.16	27.64	27.24	26.92	26.42	25.91	25.39	25.14	24.87	24.60	24.33	24.06	23.79
6	35.51	27.00	23.70	21.92	20.81	20.03	19.46	19.03	18.69	18.41	17.99	17.56	17.12	16.89	16.67	16.44	16.21	15.99	15.75
7	29.25	21.69	18.77	17.19	16.21	15.52	15.02	14.63	14.33	14.08	13.71	13.32	12.93	12.73	12.53	12.33	12.12	11.91	11.70
8	25.42	18.49	15.83	14.39	13.49	12.86	12.40	12.04	11.77	11.54	11.19	10.84	10.48	10.30	10.11	9.92	9.73	9.53	9.33
9	22.86	16.39	13.90	12.56	11.71	11.13	10.70	10.37	10.11	9.89	9.57	9.24	8.90	8.72	8.55	8.37	8.19	8.00	7.81
10	21.04	14.91	12.55	11.28	10.48	9.92	9.52	9.20	8.96	8.75	8.45	8.13	7.80	7.64	7.47	7.30	7.12	6.94	6.76
11	19.69	13.81	11.56	10.35	9.58	9.05	8.66	8.35	8.12	7.92	7.63	7.32	7.01	6.85	6.68	6.52	6.35	6.17	6.00
12	18.64	12.97	10.80	9.63	8.89	8.38	8.00	7.71	7.48	7.29	7.00	6.71	6.40	6.25	6.09	5.93	5.76	5.59	5.42
13	17.81	12.31	10.21	9.07	8.35	7.86	7.49	7.21	6.98	6.80	6.52	6.23	5.93	5.78	5.63	5.47	5.30	5.14	4.97
14	17.14	11.78	9.73	8.62	7.92	7.43	7.08	6.80	6.58	6.40	6.13	5.85	5.56	5.41	5.25	5.10	4.94	4.77	4.60

续表

n_2	n_1																		
	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	∞
15	16. 59	11. 34	9. 34	8. 25	7. 57	7. 09	6. 74	6. 47	6. 26	6. 08	5. 81	5. 54	5. 25	5. 10	4. 95	4. 80	4. 64	4. 47	4. 31
16	16. 12	10. 97	9. 00	7. 94	7. 27	6. 81	6. 46	6. 19	5. 98	5. 81	5. 55	5. 27	4. 99	4. 85	4. 70	4. 54	4. 39	4. 23	4. 06
17	15. 72	10. 66	8. 73	7. 68	7. 02	7. 56	6. 22	5. 96	5. 75	5. 58	5. 32	5. 05	4. 78	4. 63	4. 48	4. 33	4. 18	4. 02	3. 85
18	15. 38	10. 39	8. 49	7. 46	6. 81	6. 35	6. 02	5. 76	5. 56	5. 39	5. 13	4. 87	4. 59	4. 45	4. 30	4. 15	4. 00	3. 84	3. 67
19	15. 08	10. 16	8. 28	7. 26	6. 62	6. 18	5. 85	5. 59	5. 39	5. 22	4. 97	4. 70	4. 43	4. 29	4. 14	3. 99	3. 84	3. 68	6. 51
20	14. 82	9. 95	8. 10	7. 10	6. 46	6. 02	5. 69	5. 44	5. 24	5. 08	4. 82	4. 56	4. 29	4. 15	4. 00	3. 86	3. 70	3. 54	3. 38
21	14. 59	9. 77	7. 94	6. 95	6. 32	5. 88	5. 56	5. 31	5. 11	4. 95	4. 70	4. 44	4. 17	4. 03	3. 88	3. 74	3. 58	3. 42	3. 26
22	14. 38	9. 61	7. 80	6. 81	6. 19	5. 76	5. 44	5. 19	4. 99	4. 83	4. 58	4. 33	4. 06	3. 92	3. 78	3. 63	3. 48	3. 32	3. 15
23	14. 19	9. 47	7. 67	6. 69	6. 08	5. 65	6. 33	5. 09	4. 89	4. 73	4. 48	4. 23	3. 96	3. 82	3. 68	3. 53	3. 38	3. 22	3. 05
24	14. 03	9. 34	7. 55	6. 59	5. 98	5. 55	5. 23	4. 99	4. 80	4. 64	4. 39	4. 14	3. 87	3. 74	3. 59	3. 45	3. 29	3. 14	2. 97
25	13. 88	9. 22	7. 45	6. 49	5. 88	5. 46	5. 15	4. 91	4. 71	4. 56	4. 31	4. 06	3. 79	3. 66	3. 52	3. 37	3. 22	3. 06	2. 89
26	13. 74	9. 12	7. 36	6. 41	5. 80	5. 38	5. 07	4. 83	4. 64	4. 48	4. 24	3. 99	3. 72	3. 59	3. 44	3. 30	3. 15	2. 99	2. 82
27	13. 61	9. 02	7. 27	6. 33	5. 73	5. 31	5. 00	4. 76	4. 57	4. 41	4. 17	3. 92	3. 66	3. 52	3. 38	3. 23	3. 08	2. 92	2. 75
28	13. 50	8. 93	7. 19	6. 25	5. 66	5. 24	4. 93	4. 69	4. 50	4. 35	4. 11	3. 86	3. 60	3. 46	3. 32	3. 18	3. 02	2. 86	2. 69
29	13. 39	8. 85	7. 12	6. 19	5. 59	5. 18	4. 87	4. 64	4. 45	4. 29	4. 05	3. 80	3. 54	3. 41	3. 27	3. 12	2. 97	2. 81	2. 64
30	13. 29	8. 77	7. 05	6. 12	5. 53	5. 12	4. 82	4. 58	4. 39	4. 24	4. 00	3. 75	3. 49	3. 36	3. 22	3. 07	2. 92	2. 76	2. 59
40	12. 61	8. 25	6. 60	5. 70	5. 13	4. 73	4. 44	4. 21	4. 02	3. 87	3. 64	3. 40	3. 15	3. 01	2. 87	2. 73	2. 57	2. 41	2. 23
60	11. 97	7. 76	6. 17	5. 31	4. 76	4. 37	4. 09	3. 87	3. 69	3. 54	3. 31	3. 08	2. 83	2. 69	2. 55	2. 41	2. 25	2. 08	1. 89
120	11. 38	7. 32	5. 79	4. 95	4. 42	4. 04	3. 77	3. 55	3. 38	3. 24	3. 02	2. 78	2. 53	2. 40	2. 26	2. 11	1. 95	1. 76	1. 54
∞	10. 83	6. 91	5. 42	4. 62	4. 10	3. 74	3. 47	3. 27	3. 10	2. 96	2. 74	2. 51	2. 27	2. 13	1. 99	1. 84	1. 66	1. 45	1. 00

† 表示要将所列数乘 100.

参考文献

[1] 复旦大学.概率论.北京:高等教育出版社,1979.

[2] 盛骤,谢式千,潘承毅.概率论与数理统计.5版.北京:高等教育出版社,2019.

[3] 陈希孺.概率论与数理统计.合肥:中国科学技术大学出版社,2009.

[4] 茆诗松,程依明,濮晓龙.概率论与数理统计教程.3版.北京:高等教育出版社,2019.

[5] 帕普里斯 A,佩莱 S U.概率、随机变量与随机过程.4版.保铮,冯大政,水鹏朗,译.西安:西安交通大学出版社,2012.

[6] 罗斯 S M.概率论基础教程:原书第9版.童行伟,梁宝生,译.北京:机械工业出版社,2014.

[7] 袁德美,安军,陶宝.概率论与数理统计.北京:高等教育出版社,2016.

[8] 谢邦昌,张波,田金方.应用概率统计教程.北京:高等教育出版社,2010.

[9] 吴翊,汪文浩,杨文强. 概率论与数理统计.北京:高等教育出版社,2016.

[10] 汪荣鑫.数理统计.西安:西安交通大学出版社,1987.

[11] 马逢时,何良材,余明书,等.应用概率统计.北京:高等教育出版社,1989.

[12] 颜钰芬,徐明钧.数理统计.上海: 上海交通大学出版社,1992.

[13] 陈培德.随机数学引论.北京:科学出版社,2001.

[14] 现代应用数学手册编委会.现代应用数学手册:概率统计与随机过程卷.北京:清华大学出版社,2000.

[15] 张波.应用随机过程.北京:中国人民大学出版社,2001.

[16] 汪荣鑫.随机过程.西安:西安交通大学出版社,1987.

[17] 李文林.数学史概论.3版.北京:高等教育出版社,2011.

[18] 博耶 C B.数学史:修订版.秦传安,译.北京:中央编译出版社,2012.

[19] 陈希孺.数理统计学简史.长沙:湖南教育出版社,2002.

[20] 萨尔斯伯格 D.女士品茶:统计学如何变革了科学和生活.刘清山,译.南昌:江西人民出版社,2016.

郑重声明

高等教育出版社依法对本书享有专有出版权。任何未经许可的复制、销售行为均违反《中华人民共和国著作权法》，其行为人将承担相应的民事责任和行政责任；构成犯罪的，将被依法追究刑事责任。为了维护市场秩序，保护读者的合法权益，避免读者误用盗版书造成不良后果，我社将配合行政执法部门和司法机关对违法犯罪的单位和个人进行严厉打击。社会各界人士如发现上述侵权行为，希望及时举报，本社将奖励举报有功人员。

反盗版举报电话　(010)58581999　58582371　58582488

反盗版举报传真　(010)82086060

反盗版举报邮箱　dd@hep.com.cn

通信地址　北京市西城区德外大街4号

高等教育出版社法律事务与版权管理部

邮政编码　100120

防伪查询说明

用户购书后刮开封底防伪涂层，利用手机微信等软件扫描二维码，会跳转至防伪查询网页，获得所购图书详细信息。也可将防伪二维码下的20位密码按从左到右、从上到下的顺序发送短信至106695881280，免费查询所购图书真伪。

反盗版短信举报

编辑短信“JB，图书名称，出版社，购买地点”发送至10669588128

防伪客服电话

(010)58582300

ISBN 978-7-04-056214-9

数字课程网站

定价：49.80 元

[General Information]
书名=概率论与数理统计
页数=328
SS号=14982869